Método Numericos
CAPITULO METODOS DIRECTOS
Solución de Sistemas de Ecuaciones Lineales

Henry R. Moncada

Universidad Nacional del Callao
Facultad de Ingeniería Mecánica y de Energía

11 de octubre de 2026

Contenido

1. Introducción a los sistemas de ecuaciones lineales
2. Aplicaciones prácticas
3. Métodos de solución
4. Vectores y matrices
   - Operaciones con matrices
5. Solución de sistemas de ecuaciones lineales
6. Métodos Directos
   - Regla de Cramer (o método por determinantes)
   - Matriz Inversa
   - Matriz Adjunta
     - Ejemplos
   - Eliminación de Gauss
   - Método de Gauss-Jordan
   - Descomposición LU
   - Norma de un Vector
   - Norma de una matriz
7. Normas, números de condición y estabilidad
   - Número de condición y estabilidad numérica
   - Criterios para evaluar métodos numéricos
8. References

Motivación: sistemas de ecuaciones en ingeniería

Muchos problemas de ingeniería pueden formularse como sistemas de ecuaciones algebraicas. Estos sistemas permiten determinar simultáneamente varias incógnitas a partir de las leyes físicas y las condiciones del problema.

Aplicaciones en ingeniería

- **Mecánica:** cálculo de fuerzas y reacciones en estructuras.
- **Electricidad:** determinación de corrientes y voltajes en circuitos.
- **Transferencia de calor:** cálculo de temperaturas en sólidos y sistemas térmicos.
- **Mecánica de fluidos:** resolución de sistemas algebraicos obtenidos mediante discretización numérica.

Objetivo

Determinar los valores de las incógnitas que satisfacen simultáneamente todas las ecuaciones del modelo matemático.

Planteamiento general del problema
Un **sistema de n ecuaciones con n incógnitas** puede escribirse en la forma general

$$\begin{aligned} f_1(x_1, x_2, \ldots, x_n) &= 0, \\ f_2(x_1, x_2, \ldots, x_n) &= 0, \\ &\vdots \\ f_n(x_1, x_2, \ldots, x_n) &= 0. \end{aligned}$$

Sistemas lineales y no lineales

- **Sistema lineal:** las incógnitas aparecen únicamente en primera potencia y no se multiplican entre sí.
- **Sistema no lineal:** al menos una ecuación contiene términos no lineales, como x_1^2, $\sin(x_1)$ o $x_1 x_2$.

En esta unidad estudiaremos sistemas lineales de la forma

$$\boxed{\mathbf{Ax} = \mathbf{b}}$$

donde $\mathbf{A}$ es la matriz de coeficientes, $\mathbf{x}$ es el vector de incógnitas y $\mathbf{b}$ es el vector de términos independientes.

Sistema de ecuaciones lineales

Un **sistema de n ecuaciones con n incógnitas** se expresa como

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2, \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n. \end{aligned}$$

Coeficientes

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

Matriz de coeficientes.

Incógnitas y datos

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

Vector de incógnitas y vector independiente.

La matriz $\mathbf{A}$ tiene dimensión $n \times n$, mientras que $\mathbf{x}$ y $\mathbf{b}$ tienen dimensión $n \times 1$.

Considérese el sistema

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 + 3x_2 &= 7. \end{aligned}$$

Su representación matricial es

$$\underbrace{\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}}_{\mathbf{A}} \underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_{\mathbf{x}} = \underbrace{\begin{bmatrix} 5 \\ 7 \end{bmatrix}}_{\mathbf{b}}.$$

La matriz ampliada se construye colocando el vector $\mathbf{b}$ a la derecha de la matriz $\mathbf{A}$:

$$[\mathbf{A} \mid \mathbf{b}] = \left[\begin{array}{cc|c} 2 & 1 & 5 \\ 1 & 3 & 7 \end{array}\right]$$

Interpretación: La matriz ampliada permite aplicar operaciones elementales por filas para transformar el sistema y determinar sus incógnitas.

Interpretación de los elementos de una matriz

En una matriz $\mathbf{A} = [a_{ij}]$, el elemento a_{ij} se encuentra en la fila i y la columna j.

$$\mathbf{A} = \begin{bmatrix} \boxed{a_{11}} & a_{12} & a_{13} \\ a_{21} & \boxed{a_{22}} & a_{23} \\ a_{31} & a_{32} & \boxed{a_{33}} \end{bmatrix}$$

- **Fila:** conjunto horizontal de elementos.
- **Columna:** conjunto vertical de elementos.
- **Índice i:** identifica la fila.
- **Índice j:** identifica la columna.
- **Diagonal principal:** elementos $a_{11}, a_{22}, \ldots, a_{nn}$ de una matriz cuadrada.

Importancia computacional

La notación matricial permite implementar algoritmos generales sin escribir una fórmula diferente para cada ecuación.

Ejemplo 1: análisis de un circuito eléctrico

Al aplicar las leyes de Kirchhoff a un circuito eléctrico con dos nodos desconocidos, se obtiene el sistema

$$3V_1 - V_2 = 10,$$
$$-V_1 + 2V_2 = 0.$$

Determinar los voltajes nodales V_1 y V_2.

Representación matricial

$$\begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} V_1 \\ V_2 \end{bmatrix} = \begin{bmatrix} 10 \\ 0 \end{bmatrix}$$

Eliminación de la primera incógnita, de la segunda ecuación despegamos V_1 y sustituyendo en la primera,

$$V_1 - 2V_2 = 0 \quad \Longrightarrow \quad V_1 = 2V_2$$
$$3(2V_2) - V_2 = 10 \quad \Longrightarrow \quad 5V_2 = 10.$$

De los cálculos anteriores se obtiene

$$V_2 = \frac{10}{5} = 2 \text{ V}, \qquad V_1 = 2V_2 = 4 \text{ V}.$$

Por tanto, la solución es

$$\mathbf{x} = \begin{bmatrix} V_1 \\ V_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix} \text{ V}$$

Verificación
Primera ecuación:

$$3(4) - 2 = 12 - 2 = 10.$$

Segunda ecuación:

$$-4 + 2(2) = 0.$$

Interpretación física:

los voltajes nodales son $V_1 = 4$ V y $V_2 = 2$ V. La solución satisface ambas ecuaciones del circuito.

Ejemplo 2: distribución de temperatura en una barra

Considérese una barra unidimensional en estado estacionario, con conductividad térmica constante, sin generación interna de calor y con temperaturas de frontera

$$T_0 = 100\,^\circ\mathrm{C}, \qquad T_3 = 0\,^\circ\mathrm{C}.$$

Al discretizar la ecuación de conducción de calor con diferencias finitas y dos nodos interiores, se obtiene

$$2T_1 - T_2 = 100,$$
$$-T_1 + 2T_2 = 0.$$

Forma matricial

$$\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} T_1 \\ T_2 \end{bmatrix} = \begin{bmatrix} 100 \\ 0 \end{bmatrix}$$

De la segunda ecuación, $T_1 = 2T_2$. Sustituyendo en la primera,

$$2(2T_2) - T_2 = 100 \quad \Longrightarrow \quad 3T_2 = 100.$$

Resolviendo el sistema,

$$T_2 = \frac{100}{3} = 33{,}33\,^\circ\mathrm{C},$$
$$T_1 = 2T_2 = \frac{200}{3} = 66{,}67\,^\circ\mathrm{C}.$$

Por tanto,

$$\begin{bmatrix} T_1 \\ T_2 \end{bmatrix} = \begin{bmatrix} 66{,}67 \\ 33{,}33 \end{bmatrix}\,^\circ\mathrm{C}$$

Interpretación física

La temperatura disminuye desde la frontera caliente hacia la frontera fría. Los valores calculados corresponden a los dos nodos interiores de la barra.

Importancia numérica: este procedimiento se generaliza a mallas con cientos o miles de nodos, para las cuales se requieren algoritmos computacionales de resolución de sistemas lineales.

El sistema $\mathbf{Ax} = \mathbf{b}$ puede resolverse mediante distintos métodos, dependiendo de las características del problema.

Métodos directos

- Eliminación de Gauss.
- Gauss-Jordan.
- Factorización LU.
- Regla de Cramer para sistemas pequeños.

Métodos iterativos

- Jacobi.
- Gauss-Seidel.
- Gradiente conjugado, para sistemas que cumplen las condiciones apropiadas.

Criterio de selección

La elección depende del tamaño y la estructura de la matriz, su dispersidad, las propiedades matemáticas del sistema y la precisión requerida.

¿Qué es un vector? y ¿Qué es una matriz?

Un **vector** es una colección ordenada de componentes. Si tiene n componentes, su dimensión es n.

Vector columna

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} \in \mathbb{R}^{3\times 1}$$

Vector renglón o fila

$$\mathbf{w} = \begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \in \mathbb{R}^{1\times 3}$$

Interpretaciones

- En geometría: posición, desplazamiento, velocidad o fuerza.
- En ingeniería: cargas, temperaturas o valores nodales.
- En programación: secuencia ordenada de datos.

Idea clave

El vector columna tiene una columna; el vector renglón tiene una fila.

Una **matriz** es un arreglo rectangular de elementos organizados en filas y columnas.

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \in \mathbb{R}^{2\times 3}$$

- a_{ij} es el elemento de la fila i y la columna j.
- Una matriz de $m \times n$ tiene m filas y n columnas.
- La matriz del ejemplo contiene 2 filas, 3 columnas y 6 elementos.

Matrices

Matriz densa

$$\mathbf{A} = \begin{bmatrix} 4 & 1 & 2 \\ 3 & 5 & 7 \\ 1 & 6 & 8 \end{bmatrix}$$

Muchos elementos son distintos de cero. Puede ser conveniente almacenarla como un arreglo completo.

Matriz dispersa (ó sparse)

$$\mathbf{B} = \begin{bmatrix} 4 & 1 & 0 & 0 \\ 1 & 5 & 2 & 0 \\ 0 & 2 & 6 & 1 \\ 0 & 0 & 1 & 7 \end{bmatrix}$$

La mayoría de sus elementos son cero. Aparece con frecuencia en discretizaciones de ecuaciones diferenciales y métodos de elementos finitos.

Importante

Una matriz dispersa (ó sparse) se caracteriza por su alta proporción de ceros, no simplemente por ser grande.

Cuadrada

$$\begin{bmatrix} 2 & 1 \\ 3 & 4 \end{bmatrix}_{2\times 2}$$

Tiene igual número de filas m y columnas n,

$$m \times n = 2 \times 2$$

Para $\mathbf{Dx} = \mathbf{b}$, si $d_{ii} \neq 0$:

Diagonal

$$\mathbf{D} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 3 \end{bmatrix}_{3\times 3}$$

Los elementos fuera de la diagonal principal son cero.

$$x_i = \frac{b_i}{d_{ii}}, \qquad i = 1, \ldots, n.$$

Identidad

$$\mathbf{I} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}_{3\times 3}$$

Tiene unos en la diagonal principal y ceros en las demás posiciones.

Matrices

Una matriz cuadrada es **simétrica** si $a_{ij} = a_{ji}$ para todo i, j; equivalentemente, $\mathbf{A} = \mathbf{A}^T$.

$$\mathbf{A} = \begin{bmatrix} 5 & 1 & 2 \\ 1 & 3 & 7 \\ 2 & 7 & 8 \end{bmatrix}, \qquad \mathbf{A}^T = \mathbf{A}.$$

Las matrices de rigidez de muchos problemas de elasticidad lineal son simétricas bajo hipótesis apropiadas. También pueden aparecer en discretizaciones de ecuaciones diferenciales.

La simetría puede permitir algoritmos eficientes. Por ejemplo, la factorización de Cholesky requiere además que la matriz sea definida positiva.

Triangular superior

$$\mathbf{U} = \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix}$$

Los elementos debajo de la diagonal principal son cero.

Triangular inferior

$$\mathbf{L} = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix}$$

Los elementos encima de la diagonal principal son cero.

- $\mathbf{Lx} = \mathbf{b}$: sustitución hacia adelante.
- $\mathbf{Ux} = \mathbf{b}$: sustitución hacia atrás.

Las fórmulas requieren que los elementos diagonales correspondientes sean distintos de cero.

- Para $\mathbf{Lx} = \mathbf{b}$, la sustitución hacia adelante es

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} l_{ij} x_j}{l_{ii}}, \quad i = 1, \ldots, n.$$

- Para $\mathbf{Ux} = \mathbf{b}$, la sustitución hacia atrás es

$$x_i = \frac{b_i - \sum_{j=i+1}^{n} u_{ij} x_j}{u_{ii}}, \quad i = n, n-1, \ldots, 1.$$

Interpretación

En cada paso se calcula una incógnita usando las incógnitas que ya se conocen.

Matrices tridiagonales y pentadiagonales

Una matriz es **tridiagonal** si sus elementos distintos de cero solo pueden aparecer en la diagonal principal y en las dos diagonales adyacentes.

$$\mathbf{A} = \begin{bmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \ddots & \vdots \\ 0 & a_3 & b_3 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{bmatrix}$$

- Surgen, por ejemplo, al discretizar problemas unidimensionales mediante diferencias finitas.
- Su almacenamiento puede requerir $O(n)$ memoria en lugar de $O(n^2)$.
- Hay algoritmos especializados que aprovechan esta estructura.

Una matriz **pentadiagonal** puede tener elementos distintos de cero en la diagonal principal, dos diagonales superiores y dos inferiores.

$$\mathbf{A} = \begin{bmatrix} b_1 & c_1 & d_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & d_2 & \ddots & \vdots \\ e_3 & a_3 & b_3 & c_3 & \ddots & 0 \\ 0 & e_4 & a_4 & b_4 & \ddots & d_4 \\ \vdots & \ddots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & e_n & a_n & b_n \end{bmatrix}$$

- Puede surgir en discretizaciones de ecuaciones diferenciales de orden superior o en ciertos esquemas numéricos.
- El patrón concreto depende de la ecuación y del método de discretización.

Igualdad, suma, multiplicación por un escalar y multiplicación

Igualdad: dos matrices son iguales si tienen las mismas dimensiones y sus elementos correspondientes son iguales.

$$\mathbf{A} = \mathbf{B}, \qquad a_{ij} = b_{ij}$$

suma y la resta: La suma y la resta solo están definidas para matrices de las mismas dimensiones.

$$\mathbf{C} = \mathbf{A} + \mathbf{B}, \qquad c_{ij} = a_{ij} + b_{ij}.$$

Multiplicación por un escalar: cada elemento se multiplica por α.

$$\alpha\mathbf{A} = \begin{bmatrix} \alpha a_{11} & \cdots & \alpha a_{1n} \\ \vdots & \ddots & \vdots \\ \alpha a_{m1} & \cdots & \alpha a_{mn} \end{bmatrix}.$$

Ejemplo

Si $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ y $\mathbf{B} = \begin{bmatrix} 5 & 0 \\ -1 & 2 \end{bmatrix}$:

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix}, \qquad 2\mathbf{A} = \begin{bmatrix} 2 & 4 \\ 6 & 8 \end{bmatrix}.$$

Multiplicación de matrices: El producto $\mathbf{C} = \mathbf{AB}$ está definido si el número de columnas de $\mathbf{A}$ coincide con el número de filas de $\mathbf{B}$.
Si $\mathbf{A} \in \mathbb{R}^{m\times n}$ y $\mathbf{B} \in \mathbb{R}^{n\times p}$, entonces $\mathbf{C} \in \mathbb{R}^{m\times p}$ y

$$c_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}.$$

Ejemplo

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1(2) + 2(1) \\ 3(2) + 4(1) \end{bmatrix} = \begin{bmatrix} 4 \\ 10 \end{bmatrix}.$$

En general, $\mathbf{AB} \neq \mathbf{BA}$; además, uno de los productos podría no estar definido.

Transpuesta, traza e inversa, y Matriz aumentada

Transpuesta

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}, \quad \mathbf{A}^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}.$$

La transpuesta intercambia filas por columnas.

Traza

$$\operatorname{tr}(\mathbf{A}) = \sum_{i=1}^{n} a_{ii}.$$

Se define para matrices cuadradas.

Matriz inversa Si $\mathbf{A}$ es cuadrada y no singular, existe $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}.$$

Esto equivale a $\det(\mathbf{A}) \neq 0$.

Cálculo numérico

Para resolver $\mathbf{Ax} = \mathbf{b}$, suele ser preferible emplear una factorización o un método de solución, en vez de calcular explícitamente $\mathbf{A}^{-1}$.

Matriz aumentada y sistemas lineales

Un sistema de ecuaciones lineales se expresa de forma compacta como

$$\mathbf{Ax} = \mathbf{b}.$$

Por ejemplo,

$$\begin{aligned} 2x + y &= 5, \\ x + 3y &= 6 \end{aligned} \iff \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

La matriz aumentada es

$$[\mathbf{A} \mid \mathbf{b}] = \left[\begin{array}{cc|c} 2 & 1 & 5 \\ 1 & 3 & 6 \end{array}\right].$$

- $\mathbf{A}$: matriz de coeficientes.
- $\mathbf{x}$: vector de incógnitas.
- $\mathbf{b}$: vector del lado derecho.

Ejemplos:

Equilibrio de fuerzas: En un modelo simplificado de una estructura, dos barras ejercen fuerzas desconocidas F_1 y F_2. Las ecuaciones de equilibrio son

$$F_1 + F_2 = 10,$$
$$2F_1 - F_2 = 2.$$

En forma matricial:

$$\begin{bmatrix} 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} F_1 \\ F_2 \end{bmatrix} = \begin{bmatrix} 10 \\ 2 \end{bmatrix}.$$

Sumando las ecuaciones, $3F_1 = 12$, de modo que $F_1 = 4$. Luego, $F_2 = 10 - 4 = 6$.

$$F_1 = 4, \qquad F_2 = 6$$

Las unidades son las mismas que las empleadas para las fuerzas en el planteamiento.

Sistema de una discretización: Considérese el sistema lineal que puede aparecer al discretizar una ecuación diferencial unidimensional:

$$\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} T_1 \\ T_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

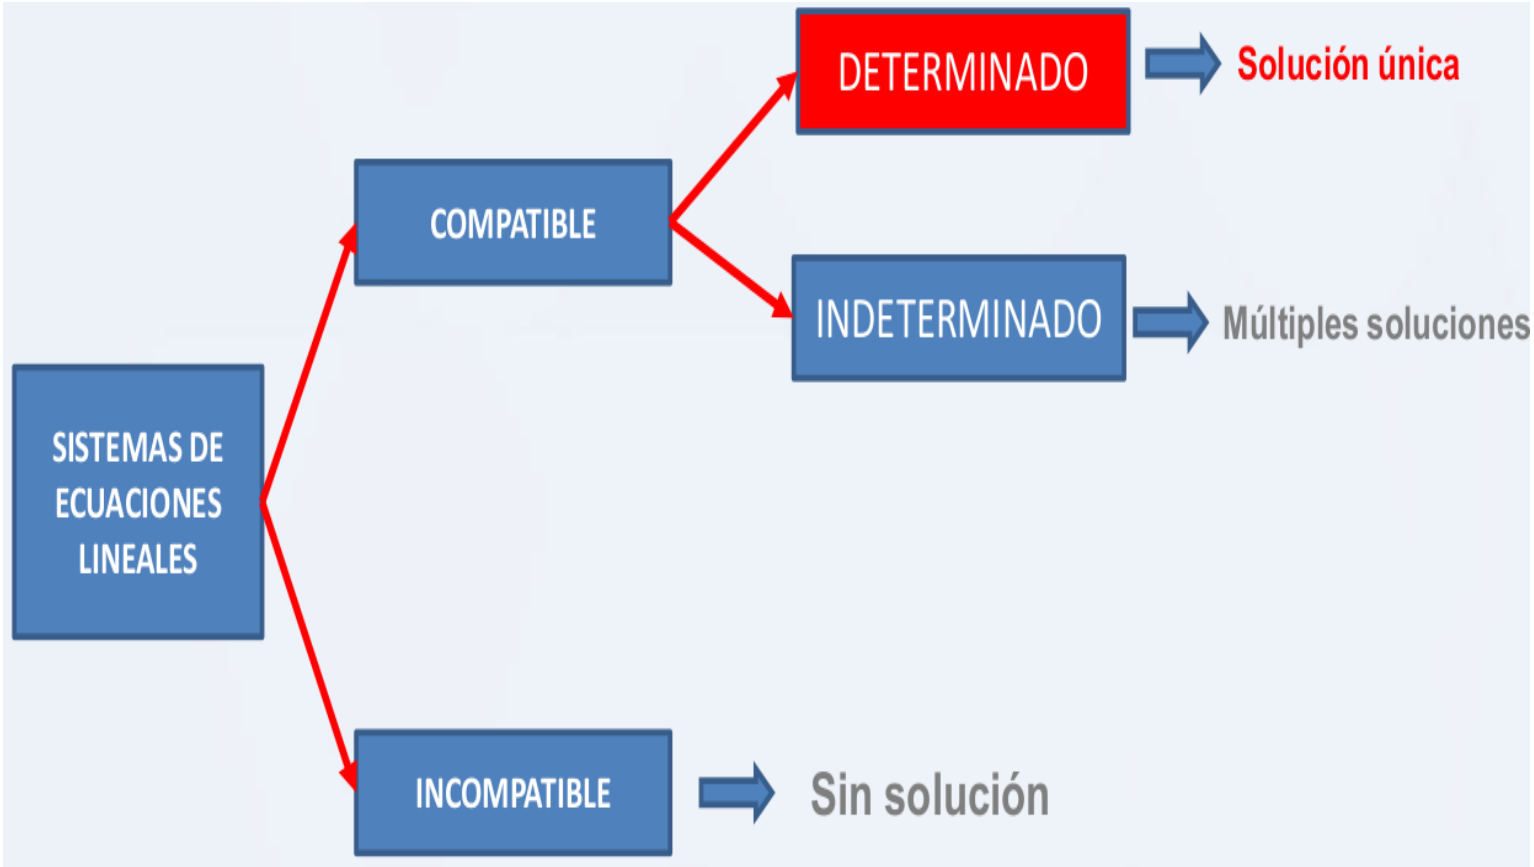
La primera ecuación es $2T_1 - T_2 = 1$ y la segunda es $-T_1 + 2T_2 = 0$. De la segunda ecuación, $T_1 = 2T_2$. Sustituyendo en la primera:

$$4T_2 - T_2 = 1 \quad \Longrightarrow \quad T_2 = \frac{1}{3}, \qquad T_1 = \frac{2}{3}.$$

$$\mathbf{T} = \begin{bmatrix} 2/3 \\ 1/3 \end{bmatrix}$$

La matriz es simétrica y tridiagonal; estas estructuras son comunes en métodos numéricos.

Casos que se pueden presentar:



La estructura matricial que tendría cada una de las alternativas seria parecida a lo siguiente:

$$\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 0 & 0 & 1\end{bmatrix}\begin{bmatrix}x\\ y\\ z\end{bmatrix}=\begin{bmatrix}1\\ 2\\ 3\end{bmatrix} \Rightarrow \textbf{Compatible determinado (solución única)}$$

$$\begin{bmatrix}1 & 0 & 1\\ 0 & 1 & 1\\ 0 & 0 & 0\end{bmatrix}\begin{bmatrix}x\\ y\\ z\end{bmatrix}=\begin{bmatrix}4\\ 5\\ 0\end{bmatrix} \Rightarrow \textbf{Compatible indeterminado (Múltiples soluciones)}$$

$$\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\\ 0 & 0 & 0\end{bmatrix}\begin{bmatrix}x\\ y\\ z\end{bmatrix}=\begin{bmatrix}4\\ 5\\ 0\end{bmatrix} \Rightarrow \textbf{Inompatible (Sin solución)}$$

Con los métodos que se verán en este capítulo se trata de obtener la solución única de un sistema de ecuaciones lineales (sistema compatible determinado) y en caso contrario indicar que el sistema o tiene soluciones múltiples o no tiene solución.

Utilización de métodos numéricos para sistemas de ecuaciones lineales

Como se comentó al inicio del capítulo los métodos numéricos para la solución de este tipo de sistemas solamente nos sirven cuando el sistema tiene una solución única (Compatible determinado). Es recomendable antes de aplicar cualquier método en verificar el valor del determinante de la matriz A.

$$Ax = B, \qquad \det(A) \neq 0$$

¿Preguntas?

sistemas de ecuaciones lineales

Métodos directos

Son aquellos que permiten obtener la solución después de un número finito de operaciones aritméticas. Este número de operaciones es función del tamaño de la matriz. Algunos de estos métodos directos son:

- Regla de Cramer (o método por determinantes)
- Eliminación Gaussiana
- Descomposición LU

Regla de Cramer (o método por determinantes)

- La **Regla de Cramer** es otra técnica de solución adecuada para un sistema pequeño de ecuaciones. Para utilizar la **Regla de Cramer**, es necesario calcular el determinante de una matriz

$$\det[\mathbf{A}] = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix}$$

- Contrario a una matriz, el **determinante de** A**,** $(\det[\mathbf{A}])$ **es un escalar**
- Esta regla establece que cada incógnita de un sistema de ecuaciones lineales puede expresarse como una fracción de los determinantes con un denominador $\det[\mathbf{A}]$ y con el número obtenido a partir de $\det[\mathbf{A}]$ al reemplazar la columna de coeficientes de la incógnita en cuestión (por ejemplo: para x_1) en la columna 1,para x_i) en la columna i) por las constantes $\mathbf{b_1}, \mathbf{b_2}, \cdots, \mathbf{b_n}$

$$\mathbf{x_1} = \frac{\begin{vmatrix} \mathbf{b}_1 & a_{12} & \cdots & a_{1n} \\ \mathbf{b}_2 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{b}_n & a_{n2} & \cdots & a_{nn} \end{vmatrix}}{\det[\mathbf{A}]}, \qquad \mathbf{x_i} = \frac{\begin{vmatrix} a_{11} & a_{12} & \cdots & \mathbf{b}_1 & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & \mathbf{b}_2 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & \mathbf{b}_n & \cdots & a_{nn} \end{vmatrix}}{\det[\mathbf{A}]}$$

Para aplicar este método en primer lugar hay que evaluar $n+1$ determinantes y luego realizar n divisiones.

Regla de Cramer

- La Regla de Cramer es un método para resolver sistemas de ecuaciones lineales de la forma:

$$A\mathbf{x} = \mathbf{b}$$

- Donde A es una matriz cuadrada de coeficientes, $\mathbf{x}$ es el vector incógnita y $\mathbf{b}$ es el vector de términos independientes.
- Para una matriz 3×3, la solución es:

$$x_i = \frac{\det(A_i)}{\det(A)}$$

- A_i es la matriz obtenida reemplazando la i-ésima columna de A con el vector $\mathbf{b}$.

Metodo de Cramer

- Consideremos el siguiente sistema de ecuaciones lineales:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &= b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 &= b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 &= b_3 \end{aligned}$$

- El sistema tiene la forma matricial:

$$A\mathbf{x} = \mathbf{b}$$

donde:

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix}$$

El valor de x es:

$$x_1 = \frac{\det(A_1)}{\det(A)}, \quad x_2 = \frac{\det(A_2)}{\det(A)}, \quad x_3 = \frac{\det(A_3)}{\det(A)}$$

Ejemplo 1

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{bmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

Calcular det(A)

$$\det(A) = (1)\begin{bmatrix} 1 & 4 \\ 6 & 0 \end{bmatrix} - (0)\begin{bmatrix} 2 & 4 \\ 3 & 0 \end{bmatrix} + (5)\begin{bmatrix} 2 & 1 \\ 3 & 6 \end{bmatrix} = -24 + 40 - 15 = 1$$

Para calcular x_1, reemplazamos la primera columna de A con el vector $\mathbf{b}$:

$$A_1 = \begin{pmatrix} b_1 & a_{12} & a_{13} \\ b_2 & a_{22} & a_{23} \\ b_3 & a_{32} & a_{33} \end{pmatrix}, \quad \text{el valor de } x_1 \text{ es:} \quad x_1 = \frac{\det(A_1)}{\det(A)}$$

$$A_1 = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 1 & 4 \\ 3 & 6 & 0 \end{bmatrix} \Rightarrow \det(A_1) = (1)\begin{bmatrix} 1 & 4 \\ 6 & 0 \end{bmatrix} - (2)\begin{bmatrix} 2 & 4 \\ 3 & 0 \end{bmatrix} + (3)\begin{bmatrix} 2 & 1 \\ 3 & 6 \end{bmatrix} = -24 + 24 + 27 = 27$$

$$x_1 = \frac{\det(A_1)}{\det(A)} = \frac{27}{1} = 27$$

Ejemplo 1 - continuación

Calcular x_2 Para calcular x_2, reemplazamos la segunda columna de A con $\mathbf{b}$:

$$A_2 = \begin{pmatrix} a_{11} & b_1 & a_{13} \\ a_{21} & b_2 & a_{23} \\ a_{31} & b_3 & a_{33} \end{pmatrix}, \quad \text{el valor de } x_3 \text{ es:} \quad x_2 = \frac{\det(A_2)}{\det(A)}$$

$$A_2 = \begin{pmatrix} 1 & 1 & 3 \\ 0 & 2 & 4 \\ 5 & 3 & 0 \end{pmatrix} \Rightarrow \det(A_2) = (1)\begin{bmatrix} 2 & 4 \\ 3 & 0 \end{bmatrix} - (1)\begin{bmatrix} 0 & 4 \\ 5 & 0 \end{bmatrix} + (3)\begin{bmatrix} 0 & 2 \\ 5 & 3 \end{bmatrix} = -12 + 20 - 30 = -22$$

$$x_2 = \frac{-22}{1} = -22$$

Calcular x_3 Para calcular x_3, reemplazamos la tercera columna de A con $\mathbf{b}$:

$$A_3 = \begin{pmatrix} a_{11} & a_{12} & b_1 \\ a_{21} & a_{22} & b_2 \\ a_{31} & a_{32} & b_3 \end{pmatrix}, \quad \text{el valor de } x_3 \text{ es:} \quad x_3 = \frac{\det(A_3)}{\det(A)}$$

$$A_3 = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 5 & 6 & 3 \end{pmatrix} \Rightarrow \det(A_3) = (1)\begin{bmatrix} 1 & 2 \\ 6 & 3 \end{bmatrix} - (2)\begin{bmatrix} 0 & 2 \\ 5 & 3 \end{bmatrix} + (1)\begin{bmatrix} 0 & 1 \\ 5 & 6 \end{bmatrix} = -9 + 20 - 5 = 6$$

$$x_3 = \frac{6}{1} = 6$$

Ejemplo 2

Resolver utilizando el **método de Cramer**.

$$\begin{cases} 2x - y + z = 3 \\ 2y - z = 1 \\ -x + y = 1 \end{cases}$$

Reescribiendo el sistema lineal en forma matricial.

$$\begin{bmatrix} 3 & -1 & 1 \\ 1 & 2 & -1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}$$

$$\det A = \begin{vmatrix} 1 & -1 & 1 \\ 0 & 2 & -1 \\ -1 & 1 & 0 \end{vmatrix} = 3 \neq 0$$

$$x = \frac{\begin{vmatrix} 3 & -1 & 1 \\ 1 & 2 & -1 \\ 1 & 1 & 0 \end{vmatrix}}{\det A} = \frac{3}{3} = 1$$

$$y = \frac{\begin{vmatrix} 1 & 3 & 1 \\ 0 & 1 & -1 \\ -1 & 1 & 0 \end{vmatrix}}{\det A} = \frac{6}{3} = 1$$

$$z = \frac{\begin{vmatrix} 1 & -1 & 3 \\ 0 & 2 & 1 \\ -1 & 1 & 1 \end{vmatrix}}{\det A} = \frac{9}{3} = 3$$

Método de Cramer: costo computacional

Para resolver un sistema lineal

$$A\mathbf{x} = \mathbf{b}, \qquad A \in \mathbb{R}^{n\times n},$$

el método de Cramer calcula $n+1$ determinantes:

$$x_i = \frac{\det(A_i)}{\det(A)}, \qquad i = 1, \ldots, n,$$

donde A_i se obtiene reemplazando la columna i de A por el vector $\mathbf{b}$.

El determinante de una matriz A puede expresarse como

$$\det(A) = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^{n} a_{i,\sigma(i)},$$

donde S_n es el conjunto de las permutaciones de n elementos. Como existen $n!$ permutaciones, el cálculo requiere:

- **Multiplicaciones:** cada producto contiene n factores y requiere $n-1$ multiplicaciones. Por tanto, se necesitan $n!(n-1)$ multiplicaciones.
- **Sumas o restas:** combinar los $n!$ términos requiere $n!-1$ sumas o restas.

En consecuencia, el número total de operaciones aritméticas para un determinante es

$$T_{\det}(n) = n!(n-1) + (n!-1) = n\,n! - 1$$

La solución del sistema se expresa como

$$x_i = \frac{\det(A_i)}{\det(A)}, \qquad i = 1, \ldots, n.$$

Para obtener las n incógnitas, debemos calcular:

- Un determinante para la matriz A.
- n determinantes adicionales, uno por cada matriz A_i.

Obtención de la expresión del costo

Por tanto, se calculan en total $n+1$ determinantes.
Si cada determinante requiere $n\,n! - 1$ operaciones, el costo de calcularlos es

$$T_{\text{det,total}}(n) = (n+1)(n\,n! - 1).$$

Además, se necesitan n divisiones para calcular las incógnitas:

$$x_i = \frac{\det(A_i)}{\det(A)}.$$

Sumando las divisiones, obtenemos

$$\begin{aligned} T_C(n) &= (n+1)(n\,n! - 1) + n \\ &= n(n+1)n! - (n+1) + n \\ T_C(n) &= n(n+1)n! - 1 \end{aligned}$$

Si se adopta el modelo simplificado

$$T_{\text{det}}(n) = (n+1)n! - 1,$$

y se calculan $n+1$ determinantes, se obtiene

$$\begin{aligned} T_C(n) &= (n+1)\big[(n+1)n! - 1\big] + n \\ &= (n+1)^2 n! - (n+1) + n \\ T_C(n) &= (n+1)^2 n! - 1 \end{aligned}$$

- Los datos reportados en la siguiente tabla muestran el número de operaciones necesarias para resolver un sistemas de ecuaciones lineales de $5, 10$ y 100 incógnitas.

N	T_c
5	4319
10	4×10^8
100	10^{158}

- Si se dispone de una computadora capaz de realizar 100 millones de operaciones en punto flotante por segundo, el sistema de $n = 100$ necesitaría aproximadamente de 3×10^{142} años para ser resuelto, por lo que es evidente que el método de Cramer resulta inadecuado para resolver cualquier sistema de ecuaciones lineales

Observación

El factorial $n!$ crece muy rápidamente. Por ello, el método de Cramer resulta computacionalmente costoso para sistemas de orden elevado.

¿Preguntas?

Método Cramer

Propiedades de la Matriz Inversa

Una matriz cuadrada A de tamaño $n \times n$ tiene una matriz inversa A^{-1} si y solo si:

- A es invertible (es decir, su determinante es no nulo: $\det(A) \neq 0$).
- $A \cdot A^{-1} = A^{-1} \cdot A = I_n$, donde I_n es la matriz identidad de tamaño $n \times n$.
- La matriz inversa es única.

Para encontrar su inversa, usamos la fórmula:

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A)$$

Para una matrix de 2×2

$$A^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \underbrace{\frac{1}{(ad - bc)}}_{det(A)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

Ejemplo

Considera la matriz:

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

Donde:

$$\det(A) = 1 \cdot 4 - 2 \cdot 3 = -2$$

y la matriz adjunta $\text{adj}(A)$ es:

$$\text{adj}(A) = \begin{pmatrix} 4 & -2 \\ -3 & 1 \end{pmatrix}$$

Por lo tanto:

$$A^{-1} = \frac{1}{-2} \begin{pmatrix} 4 & -2 \\ -3 & 1 \end{pmatrix} = \begin{pmatrix} -2 & 1 \\ 1{,}5 & -0{,}5 \end{pmatrix}$$

Ejemplo

Considera la matriz:

$$B = \begin{pmatrix} 2 & 3 \\ 1 & 4 \end{pmatrix}$$

Para encontrar su inversa:

$$\det(B) = 2 \cdot 4 - 3 \cdot 1 = 5$$

$$\text{adj}(B) = \begin{pmatrix} 4 & -3 \\ -1 & 2 \end{pmatrix}$$

$$B^{-1} = \frac{1}{5} \begin{pmatrix} 4 & -3 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 0{,}8 & -0{,}6 \\ -0{,}2 & 0{,}4 \end{pmatrix}$$

Ejemplo

Considera la matriz:

$$C = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$

Para encontrar su inversa:

$$\det(C) = 5 \cdot 8 - 6 \cdot 7 = -2$$

$$\text{adj}(C) = \begin{pmatrix} 8 & -6 \\ -7 & 5 \end{pmatrix}$$

$$C^{-1} = \frac{1}{-2} \begin{pmatrix} 8 & -6 \\ -7 & 5 \end{pmatrix} = \begin{pmatrix} -4 & 3 \\ 3{,}5 & -2{,}5 \end{pmatrix}$$

¿Preguntas?

Método Matriz Inversa

Matriz Adjunta

Sea A una matriz cuadrada de $n \times n$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

Entonces la matriz adjunta de $\mathbf{A}$, denotada como adj($\mathbf{A}$), es la matriz traspuesta de la matriz de cofactores de $\mathbf{A}$, es decir

$$\text{adj}(\mathbf{A}) = \begin{bmatrix} C_{11} & C_{21} & C_{31} \\ C_{12} & C_{22} & C_{32} \\ C_{13} & C_{23} & C_{33} \end{bmatrix}^T$$

Donde cada C_{ij} es el cofactor de a_{ij}. Para cada elemento a_{ij} de A, calculamos el cofactor C_{ij}:

$$C_{ij} = (-1)^{i+j} \det(M_{ij})$$

donde M_{ij} es la submatriz obtenida al eliminar la fila i y la columna j de A. Si la matriz A es invertible, entonces

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(\mathbf{A}), \quad \text{sabiendo que} \quad \det A \neq 0$$

Ejemplo 1 - Cálculo de la Adjugada

El proceso para obtener la adjugada de una matriz 2×2. Sea $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 4 \end{bmatrix}$

Calculamos los cofactores:

$$C_{11} = (-1)^{1+1} |4| = 4 \qquad C_{12} = (-1)^{1+2} |0| = 0$$
$$C_{21} = (-1)^{2+1} |2| = -2 \qquad C_{22} = (-1)^{2+2} |1| = 1$$

Luego, la matriz de cofactores es:

$$C_{ij} = \begin{bmatrix} 4 & 0 \\ -2 & 1 \end{bmatrix}.$$

Finalmente, la adjunta es la traspuesta de la matriz de cofactores:

$$\text{adj}(\mathbf{A}) = \begin{bmatrix} 4 & 0 \\ -2 & 1 \end{bmatrix}^T = \begin{bmatrix} 4 & -2 \\ 0 & 1 \end{bmatrix}$$

Para encontrar su inversa, usamos la fórmula para una matrix de 2×2

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A) = \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \underbrace{\frac{1}{(ad - bc)}}_{det(A)} \underbrace{\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}}_{\text{adj}(A)}$$

Ejemplo 1: Cálculo de la adjunta

Ejemplo

El proceso para obtener la adjugada de una matriz 3×3. Consideremos la siguiente matriz A:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$$

Para encontrar la matriz adjunta, primero calculamos los cofactores.

Cofactor C_{11}:

$$M_{11} = \begin{pmatrix} 1 & 4 \\ 6 & 0 \end{pmatrix}$$

$$\det(M_{11}) = (1 \cdot 0) - (4 \cdot 6) = -24$$

$$C_{11} = (-1)^{1+1} \cdot (-24) = -24$$

Cofactor C_{12}:

$$M_{12} = \begin{pmatrix} 0 & 4 \\ 5 & 0 \end{pmatrix}$$

$$\det(M_{12}) = (0 \cdot 0) - (4 \cdot 5) = -20$$

$$C_{12} = (-1)^{1+2} \cdot (-20) = 20$$

Cofactor C_{13}:

$$M_{13} = \begin{pmatrix} 0 & 1 \\ 5 & 6 \end{pmatrix}$$

$$\det(M_{13}) = (0 \cdot 6) - (1 \cdot 5) = -5$$

$$C_{13} = (-1)^{1+3} \cdot (-5) = -5$$

Cofactor C_{21}:

$$M_{21} = \begin{pmatrix} 2 & 3 \\ 6 & 0 \end{pmatrix}$$

$$\det(M_{21}) = (2 \cdot 0) - (3 \cdot 6) = -18$$

$$C_{21} = (-1)^{2+1} \cdot (-18) = 18$$

Cofactor C_{22}:

$$M_{22} = \begin{pmatrix} 1 & 3 \\ 5 & 0 \end{pmatrix}$$

$$\det(M_{22}) = (1 \cdot 0) - (3 \cdot 5) = -15$$

$$C_{22} = (-1)^{2+2} \cdot (-15) = -15$$

Cofactor C_{23}:

$$M_{23} = \begin{pmatrix} 1 & 2 \\ 5 & 6 \end{pmatrix}$$

$$\det(M_{23}) = (1 \cdot 6) - (2 \cdot 5) = -4$$

$$C_{23} = (-1)^{2+3} \cdot (-4) = 4$$

Cofactores (continuación 1)

Cofactor C_{31}:

$$M_{31} = \begin{pmatrix} 2 & 3 \\ 1 & 4 \end{pmatrix}$$
$$\det(M_{31}) = (2 \cdot 4) - (3 \cdot 1) = 5$$
$$C_{31} = (-1)^{3+1} \cdot 5 = 5$$

Cofactor C_{32}:

$$M_{32} = \begin{pmatrix} 1 & 3 \\ 0 & 4 \end{pmatrix}$$
$$\det(M_{32}) = (1 \cdot 4) - (3 \cdot 0) = 4$$
$$C_{32} = (-1)^{3+2} \cdot 4 = -4$$

Cofactor C_{33}:

$$M_{33} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}$$
$$\det(M_{33}) = (1 \cdot 1) - (2 \cdot 0) = 1$$
$$C_{33} = (-1)^{3+3} \cdot 1 = 1$$

La matriz de cofactores C es:

$$C = \begin{pmatrix} -24 & 20 & -5 \\ 18 & -15 & 4 \\ 5 & -4 & 1 \end{pmatrix}$$

La matriz adjunta de A es la transpuesta de la matriz de cofactores:

$$\text{adj}(A) = C^T = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

Cofactores (continuación 2)

Vamos a calcular el determinante de la siguiente matriz:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$$

Para calcular el determinante de una matriz 3×3, usamos la fórmula:

$$\det(A) = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix}$$

donde los a_{ij} son los elementos de la matriz A.

Para la matriz dada, el determinante se calcula de la siguiente manera:

$$\det(A) = 1 \cdot \begin{vmatrix} 1 & 4 \\ 6 & 0 \end{vmatrix} - 2 \cdot \begin{vmatrix} 0 & 4 \\ 5 & 0 \end{vmatrix} + 3 \cdot \begin{vmatrix} 0 & 1 \\ 5 & 6 \end{vmatrix}$$

Ahora calculamos los menores:

$$\begin{vmatrix} 1 & 4 \\ 6 & 0 \end{vmatrix} = (1 \cdot 0) - (4 \cdot 6) = -24$$

$$\begin{vmatrix} 0 & 4 \\ 5 & 0 \end{vmatrix} = (0 \cdot 0) - (4 \cdot 5) = -20$$

$$\begin{vmatrix} 0 & 1 \\ 5 & 6 \end{vmatrix} = (0 \cdot 6) - (1 \cdot 5) = -5$$

Sustituyendo en la fórmula del determinante:

$$\det(A) = 1 \cdot (-24) - 2 \cdot (-20) + 3 \cdot (-5)$$

$$\det(A) = -24 + 40 - 15 = 1$$

Por lo tanto, el determinante de la matriz A es $\boxed{1}$.

Encontremos la matriz inversa de A, A^{-1}

$$A^{-1} = \frac{1}{\det(A)} \operatorname{adj}(A)$$

$$A^{-1} = \frac{1}{1} \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

Verificación :

$$A^{-1} \cdot A = A \cdot A^{-1} = I$$

Ejemplo 2: Cálculo de la adjunta

Ejemplo

El proceso para obtener la adjugada de una matriz 3×3. Consideremos la siguiente matriz A:

$$A = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 0 & -2 \\ 1 & -2 & 4 \end{bmatrix}$$

parte 1: Encontrar la matriz adjunta, primero calculamos los cofactores.

Cofactor C_{11}:

$$C_{11} = (-1)^{1+1} \begin{bmatrix} 0 & -2 \\ -2 & 4 \end{bmatrix} = -4$$

Cofactor C_{12}:

$$C_{12} = (-1)^{1+2} \begin{bmatrix} 0 & -2 \\ 1 & 4 \end{bmatrix} = -2$$

Cofactor C_{13}:

$$C_{13} = (-1)^{1+3} \begin{bmatrix} 0 & 0 \\ 1 & -2 \end{bmatrix} = 0$$

Cofactor C_{21}:

$$C_{21} = (-1)^{2+1} \begin{bmatrix} 0 & 0 \\ 0 & -2 \end{bmatrix} = 0$$

Cofactor C_{22}:

$$C_{22} = (-1)^{2+2} \begin{bmatrix} 4 & 0 \\ 1 & 4 \end{bmatrix} = 16$$

Cofactor C_{23}:

$$C_{23} = (-1)^{2+3} \begin{bmatrix} 4 & 0 \\ 1 & -2 \end{bmatrix} = 8$$

Cofactores (continuación)

Cofactor C_{31}:

$$C_{31} = (-1)^{3+1} \begin{bmatrix} 0 & 0 \\ 0 & -2 \end{bmatrix} = 0$$

Cofactor C_{32}:

$$C_{32} = (-1)^{3+2} \begin{bmatrix} 4 & 0 \\ 0 & -2 \end{bmatrix} = 8$$

Cofactor C_{33}:

$$C_{33} = (-1)^{3+3} \begin{bmatrix} 4 & 0 \\ 0 & 0 \end{bmatrix} = 0$$

La matriz de cofactores C es:

$$C = \begin{bmatrix} -4 & 0 & 0 \\ -2 & 16 & 8 \\ 0 & 8 & 0 \end{bmatrix}$$

La matriz adjunta de A es la transpuesta de la matriz de cofactores:

$$\text{adj}(A) = C^T = \begin{bmatrix} -4 & -2 & 0 \\ 0 & 16 & 8 \\ 0 & 8 & 0 \end{bmatrix}$$

parte 2: El determinante de la matriz:

$$A = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 0 & -2 \\ 1 & -2 & 4 \end{pmatrix}$$

Para la matriz dada, el determinante se calcula de la siguiente manera:

$$\det(A) = 4 \cdot \begin{vmatrix} 0 & -2 \\ -2 & 4 \end{vmatrix} - 0 \cdot \begin{vmatrix} 0 & -2 \\ 1 & 4 \end{vmatrix} + 0 \cdot \begin{vmatrix} 0 & 0 \\ 1 & -2 \end{vmatrix} =$$

Sustituyendo en la fórmula del determinante:

$$\det(A) = 4 \cdot (-4) - 0 \cdot (2) + 0 \cdot (0) = -16$$

parte 3: Encontremos la matriz inversa de A, A^{-1}

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A)$$

$$A^{-1} = \frac{1}{16} \begin{pmatrix} -4 & -2 & 0 \\ 0 & 16 & 8 \\ 0 & 8 & 0 \end{pmatrix}$$

parte 4: Verificación

$$A^{-1} \cdot A = A \cdot A^{-1} = I$$

$$A \cdot A^{-1} = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 0 & -2 \\ 1 & -2 & 4 \end{pmatrix} \cdot \frac{1}{16} \begin{pmatrix} -4 & -2 & 0 \\ 0 & 16 & 8 \\ 0 & 8 & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Ejemplo 1 : Verificación

Considera la matriz A:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 0 & 0 & 1 \end{pmatrix}$$

La matriz inversa A^{-1} se calcula como:

$$A^{-1} = \begin{pmatrix} 1 & -2 & -5 \\ 0 & 1 & -4 \\ 0 & 0 & 1 \end{pmatrix}$$

Verificación:

$$A \cdot A^{-1} = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & -2 & -5 \\ 0 & 1 & -4 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Considera la matriz B:

$$B = \begin{pmatrix} 4 & 7 & 2 \\ 3 & 6 & 1 \\ 2 & 5 & 3 \end{pmatrix}$$

La matriz inversa B^{-1} se calcula como:

$$B^{-1} = \frac{1}{1} \begin{pmatrix} 15 & -7 & -5 \\ -12 & 4 & 3 \\ -4 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 15 & -7 & -5 \\ -12 & 4 & 3 \\ -4 & 1 & 2 \end{pmatrix}$$

Verificación:

$$B \cdot B^{-1} = \begin{pmatrix} 4 & 7 & 2 \\ 3 & 6 & 1 \\ 2 & 5 & 3 \end{pmatrix} \cdot \begin{pmatrix} 15 & -7 & -5 \\ -12 & 4 & 3 \\ -4 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Considera la matriz C:

$$C = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{pmatrix}$$

La matriz inversa C^{-1} se calcula como:

$$C^{-1} = \begin{pmatrix} 1 & 0 & -2 \\ 0 & 1 & -3 \\ 0 & 0 & 1 \end{pmatrix}$$

Verificación:

$$C \cdot C^{-1} = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & -2 \\ 0 & 1 & -3 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

¿Preguntas?

Método Matriz Adjunta

Eliminación de Gauss

Este método consiste en transformar la matriz de coeficientes A del sistema de ecuaciones lineales a una matriz U del tipo Triangular Superior haciendo uso de transformaciones elementales que permitan realizar esto

Eliminación de Incógnitas

El procedimiento para eliminar incógnitas para resolver ecuaciones simultáneas consiste en:

- Manipular las ecuaciones para eliminar una de las incógnitas de las ecuaciones.
  - Intercambio de un renglón por otro.
  - Suma o resta entre dos renglones elemento a elemento.
  - Multiplicación de los elementos de un renglón por un escalar, este escalar debe ser necesariamente diferente a cero.
- Resolver la ecuación y el resultado se substituye en le ecuación original para encontrar la incógnita restante

Eliminación Simple

- El método está ideado para resolver un sistema de n ecuaciones

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned} \quad \text{ó} \quad \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{1n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{bmatrix}$$

- Consiste en dos parte, eliminación de incógnitas y solución mediante sustitución hacia atrás

Eliminación hacia Adelante y hacia Atrás

Eliminación hacia Adelante

- El primer paso consiste en eliminar la primera incógnita x_1, desde la segunda hasta la n-ésima ecuación. Multiplicar la ecuación por a_2/a_{11} y obtener

$$a_{21}x_1 + \frac{a_{21}}{a_{11}}x_2 + \cdots + \frac{a_{21}}{a_{11}}a_{1n}x_n = \frac{a_{21}}{a_{21}}b_1$$

- Al restarla de la $2da$ ecuación se obtiene

$$\left(a_{22} - \frac{a_{21}}{a_{11}}a_{12}\right)x_2 + \cdots + \left(a_{2n} - \frac{a_{21}}{a_{11}}a_{1n}\right)x_n = \frac{a_{21}}{a_{21}}b_1$$

- El procedimiento se repite hacia adelante, multiplicando la primera ecuación por a_{31}/a_{11} y restando de la tercera ecuación
- La primera ecuación se denomina ecuación pivote y a_{11} se denomina coeficiente o elemento pivote
- Este procedimiento continúa usando las ecuaciones pivote restantes, la última ecuación afectada es la $(n-1)$ ésima ecuación para eliminar el término x_{n-1} de la **n-ésima** ecuación

Evaluación hacia Atrás

- Finalmente se despeja $x_n = \dfrac{b_n^{n-1}}{a_{nn}^{n-1}}$
- El resultado se sustituye hacia atrás en la **(n-1)-ésima** ecuación, este procedimiento se repite para las x restantes

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ \vdots \quad & \quad \vdots \\ a_{nn}x_n &= b_n \end{aligned}$$

ó

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{1n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & a_{nn}^{n-1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n^{n-1} \end{bmatrix}$$

Ejemplo

Encuentre el conjunto solución del sistema lineal

$$\begin{cases} x + y + z = -3 \\ x + 2y + z = -5 \\ -x - y + z = 13 \end{cases}$$

solución

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & -3 \\ 1 & 2 & 1 & -5 \\ -1 & -1 & 1 & 13 \end{array}\right] \begin{array}{l} \\ \longleftarrow R_2 - R_1 \\ \longleftarrow R_3 + R_1 \end{array}$$

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & -3 \\ 0 & 1 & 0 & -2 \\ 0 & 0 & 2 & 10 \end{array}\right] \longleftarrow \frac{1}{2} R_3$$

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & -3 \\ 0 & 1 & 0 & -2 \\ 0 & 0 & 1 & 5 \end{array}\right] \longleftarrow R_1 - R_3$$

$$\left[\begin{array}{ccc|c} 1 & 1 & 0 & -8 \\ 0 & 1 & 0 & -2 \\ 0 & 0 & 1 & 5 \end{array}\right] \longleftarrow R_1 - R_2$$

$$\left[\begin{array}{ccc|c} 1 & 0 & 0 & -6 \\ 0 & 1 & 0 & -2 \\ 0 & 0 & 1 & 5 \end{array}\right]$$

Luego, la única solución del sistema es $(x, y, z) = (-6, -2, 5)$ (notemos que no hay variables libres).

Ejemplo - Problemas con la Eliminación Simple

- Hay ocasiones que al hacer la eliminación se tendría una división entre cero, por ejemplo en la siguiente ecuación:

$$\begin{aligned} 2x_2 + 3x_3 &= 8 \\ 4x_1 + 6x_2 + 7x_3 &= -3 \\ 2x_1 + x_2 + 6x_3 &= 5 \end{aligned}$$

- Para evitar estos problemas se ha desarrollado la técnica del pivoteo
- Cuando hay pequeña variación entre las gráficas de las ecuaciones, esto puede llevar a problemas de precisión en las raíces

Resolver el siguiente sistema de ecuaciones lineales realizando la prueba de escritorio del algoritmo de eliminación Gaussiana:

$$\begin{aligned} 2x_1 + x_2 - x_3 + x_4 &= 8 \\ x_2 + x_3 - x_4 &= 4 \\ 2x_2 + x_3 - x_4 &= 2 \\ x_1 - x_2 + 2x_4 &= -2 \end{aligned}$$

Método de Gauss-Jordan: Fundamento y Algoritmo

¿En qué consiste?

Es una variación de la eliminación gaussiana. La diferencia principal radica en que cuando se elimina una incógnita, esta se elimina de **todas las demás ecuaciones** (tanto por arriba como por debajo de la diagonal).

- **Normalización:** Cada renglón pivote se divide entre su elemento diagonal para obtener unos (1) en la diagonal principal.
- **Matriz Reducida:** Transforma la matriz de coeficientes A directamente en la **matriz identidad** I (o diagonal), reduciendo el sistema $[A|b]$ a $[I|x]$.
- **Sin sustitución hacia atrás:** La solución x se obtiene de forma directa en la última columna.

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \xrightarrow{\text{Gauss-Jordan}} \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} x_1^* \\ x_2^* \\ \vdots \\ x_n^* \end{bmatrix}$$

Formulación Algorítmica

Para cada etapa de pivoteo $k = 1, 2, \ldots, n$:

1. **Normalización del renglón pivote (k):**

$$a_{kj}^{(k)} = \frac{a_{kj}^{(k-1)}}{a_{kk}^{(k-1)}}, \quad b_k^{(k)} = \frac{b_k^{(k-1)}}{a_{kk}^{(k-1)}} \quad \forall\, j = k, \ldots, n$$

2. **Eliminación en los demás renglones ($i \neq k$):**

$$a_{ij}^{(k)} = a_{ij}^{(k-1)} - a_{ik}^{(k-1)} \cdot a_{kj}^{(k)}$$

$$b_i^{(k)} = b_i^{(k-1)} - a_{ik}^{(k-1)} \cdot b_k^{(k)}$$

Observación Importante

A diferencia de la eliminación gaussiana clásica (que genera una matriz triangular superior U), el cálculo de ceros en $i < k$ evita tener que aplicar la sustitución hacia atrás, pero incrementa el número total de operaciones numéricas.

Ejemplo Práctico 1: Sistema 2×2

Resolver el siguiente sistema mediante el método de Gauss-Jordan:

$$\begin{cases} 2x_1 + 4x_2 = 12 \\ 3x_1 + 5x_2 = 16 \end{cases} \quad \Rightarrow \quad \left[\begin{array}{cc|c} 2 & 4 & 12 \\ 3 & 5 & 16 \end{array}\right]$$

1. **Normalizar Fila 1** ($F_1 \leftarrow F_1/2$):

$$\left[\begin{array}{cc|c} 1 & 2 & 6 \\ 3 & 5 & 16 \end{array}\right]$$

2. **Eliminar en Fila 2** ($F_2 \leftarrow F_2 - 3F_1$):

$$\left[\begin{array}{cc|c} 1 & 2 & 6 \\ 0 & -1 & -2 \end{array}\right]$$

3. **Normalizar Fila 2** ($F_2 \leftarrow F_2/(-1)$):

$$\left[\begin{array}{cc|c} 1 & 2 & 6 \\ 0 & 1 & 2 \end{array}\right]$$

4. **Eliminar arriba en Fila 1** ($F_1 \leftarrow F_1 - 2F_2$):

$$\left[\begin{array}{cc|c} 1 & 0 & 2 \\ 0 & 1 & 2 \end{array}\right] \quad \Rightarrow \quad \mathbf{x_1 = 2}, \quad \mathbf{x_2 = 2}$$

Ejemplo Práctico 2: Sistema 3×3

Resolver el sistema:

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 1 & 3 \\ 3 & 0 & -1 & 0 \end{array}\right]$$

1. Paso 1: Pivote en $(1,1)$
   Eliminar bajo el pivote 1 ($F_2 \leftarrow F_2 - 2F_1$, $F_3 \leftarrow F_3 - 3F_1$):

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 0 & -3 & -4 & -18 \end{array}\right]$$

2. Paso 2: Pivote en $(2,2)$
   Normalizar $F_2 \leftarrow F_2/(-3)$ y eliminar en F_1 y F_3:

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & 1/3 & 3 \\ 0 & -3 & -4 & -18 \end{array}\right] \xrightarrow[F_3 \leftarrow F_3 + 3F_2]{F_1 \leftarrow F_1 - F_2} \left[\begin{array}{ccc|c} 1 & 0 & 2/3 & 3 \\ 0 & 1 & 1/3 & 3 \\ 0 & 0 & -3 & -9 \end{array}\right]$$

3. Paso 3: Pivote en $(3,3)$ Normalizar $F_3 \leftarrow F_3/(-3)$:

$$\left[\begin{array}{ccc|c} 1 & 0 & 2/3 & 3 \\ 0 & 1 & 1/3 & 3 \\ 0 & 0 & 1 & 3 \end{array}\right]$$

Eliminar ceros por encima de la diagonal ($F_1 \leftarrow F_1 - \frac{2}{3}F_3$, $F_2 \leftarrow F_2 - \frac{1}{3}F_3$):

$$\left[\begin{array}{ccc|c} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 1 & 3 \end{array}\right]$$

Resultado final

La solución directa del sistema es:

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 3$$

Cálculo de Incógnitas por Matriz Inversa

- Si se multiplica por la matriz inversa de A la izquierda de ambos lados de una matriz se tiene:

$$\begin{aligned} Ax &= B \\ A^{-1}Ax &= A^{-1}B \\ Ix &= A^{-1}B \\ x &= A^{-1}B \end{aligned}$$

- La inversa de una matriz $|A|$ se define de la siguiente manera

$$A^{-1} = \frac{1}{|A|}(A^*)^T \tag{1}$$

- En donde:
  - A^* es la matriz Adjunta
  - A^T es la matriz Transpuesta

¿Preguntas?

Método Eliminación de Gauss

Descomposición LU

- Es un método de eliminación conocido como de descomposición, aquí el paso de la eliminación se puede plantear de tal manera que las operaciones solo involucran a $|A|$
- Una matriz A puede factorizarse como el producto de una **matriz triangular inferior** L y otra **triangular superior** U

$$A = LU$$

- Separa el tiempo usado en las eliminaciones para la matriz $|A|$ de las manipulaciones de $\{B\}$
- La descomposición LU se basa en

$$[A]X - B = 0 \tag{2}$$

Matriz Triangular Superior U

- Se trata de una matriz Triangular Superior que se expresa de la siguiente manera

$$[U] = \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} \tag{3}$$

$$[U]X - D = 0 \tag{4}$$

Matriz Triangular Inferior L

- Considerar una matriz diagonal inferior, que contiene 1 en la diagonal principal

$$[L] = \begin{bmatrix} 1 & 0 & 0 \\ u_{21} & 1 & 0 \\ u_{31} & u_{32} & 1 \end{bmatrix} \tag{5}$$

Pasos en la Descomposición LU

- Paso de descomposición LU, $[A]$ se factoriza o **descompone** en matrices triangular inferior $[L]$ y superior $[U]$
- Paso de sustitución, $[L]$ y $[U]$ se utilizan para determinar una solución X para un lado derecho B
- La ecuación $[L]\{D\} = \{B\}$ se utiliza para generar un vector $\{D\}$ mediante sustitución hacia adelante, este se sustituye en $[U]\{X\} - \{D\} = 0$ que se resuelve por sustitución hacia atrás para $\{X\}$

Para realizar esta factorización existen tres esquemas:

- **Esquema Doolittle** (mostrado en el ejemplo), este esquema considera $l_{i,i} = 1$
- **Esquema Crout**, este esquema considera $u_{i,i} = 1$
- **Esquema Choleski**, este esquema considera $l_{i,i} = u_{i,i}$

De lo visto con eliminación Gaussiana podemos fácilmente concluir que LU no es un método sencillo y que su utilización puede demandar muchos recursos de la computadora para funcionar.

Ejemplo 1: Matriz 3×3

Descomponer la matriz A en el producto $L \cdot U$:

$$A = \begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix}$$

Generar ceros en la Columna 1

- Multiplicador
  $m_{21} = \frac{4}{2} = 2 \quad \Rightarrow \quad F_2 \leftarrow F_2 - 2F_1$
- Multiplicador
  $m_{31} = \frac{-2}{2} = -1 \quad \Rightarrow \quad F_3 \leftarrow F_3 - (-1)F_1$

$$A^{(1)} = \begin{bmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 8 & 3 \end{bmatrix}$$

Generar ceros en la Columna 2

Partiendo de $A^{(1)}$:

$$A^{(1)} = \begin{bmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 8 & 3 \end{bmatrix}$$

- Multiplicador
  $m_{32} = \frac{8}{-8} = -1 \quad \Rightarrow \quad F_3 \leftarrow F_3 - (-1)F_2$

$$U = \begin{bmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{bmatrix}$$

Resultado de la Factorización

Ubicando los multiplicadores $m_{21} = 2$, $m_{31} = -1$ y $m_{32} = -1$ en la matriz L:

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{bmatrix}$$

Ejemplo 2: Matriz 4×4

Descomponer en $A = L \cdot U$ la matriz:

$$A = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 2 & 5 & 4 & 3 \\ 3 & 6 & 6 & 5 \\ -1 & -2 & 2 & 3 \end{bmatrix}$$

Ceros en Columna 1 Multiplicadores:

$$m_{21} = \frac{2}{1} = 2$$

$$m_{31} = \frac{3}{1} = 3$$

$$m_{41} = \frac{-1}{1} = -1$$

$$A^{(1)} = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 3 & 2 \\ 0 & 0 & 3 & 4 \end{bmatrix}$$

Nota: Los términos debajo del pivote en las filas 3 y 4 en la columna 2 resultaron cero directamente.

Etapa 2 y 3: Ceros en Columnas 2 y 3

- Multiplicadores para Columna 2:

$$m_{32} = 0$$

$$m_{42} = 0$$

- Multiplicador para Columna 3:

$$m_{43} = \frac{3}{3} = 1 \quad \Rightarrow \quad F_4 \leftarrow F_4 - 1 \cdot F_3$$

$$U = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 3 & 2 \\ 0 & 0 & 0 & 2 \end{bmatrix}$$

Resultado Final 4×4

Construyendo L con los multiplicadores m_{ik}:

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 0 & 1 & 0 \\ -1 & 0 & 1 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 3 & 2 \\ 0 & 0 & 0 & 2 \end{bmatrix}$$

Ejemplo 3: Matriz 3×3

Encuentre el conjunto solución del sistema lineal mediante factorización LU:

$$\begin{cases} x + y + z = -3 \\ x + 2y + z = -5 \\ -x - y + z = 13 \end{cases} \quad \Rightarrow \quad A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \\ -1 & -1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} -3 \\ -5 \\ 13 \end{bmatrix}$$

Obtener las matrices L y U mediante eliminación gaussiana

Aplicamos operaciones elementales a A:

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \\ -1 & -1 & 1 \end{bmatrix} \xrightarrow[\substack{R_2 \leftarrow R_2 - (1)R_1 \\ R_3 \leftarrow R_3 - (-1)R_1}]{\substack{\text{Factores:} \\ m_{21}=1, \\ m_{31}=-1, \\ m_{32}=0}} \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} = U$$

Construimos L con los multiplicadores m_{ik}:

$$L = \begin{bmatrix} 1 & 0 & 0 \\ m_{21} & 1 & 0 \\ m_{31} & m_{32} & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix}$$

Verificación:

$$L \cdot U = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \\ -1 & -1 & 1 \end{bmatrix} = A$$

Solución de los Sistemas Triangulares

Resolver $Ly = b$, sustitución hacia adelante:

$$\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} -3 \\ -5 \\ 13 \end{bmatrix}$$

$$\left.\begin{aligned} y_1 &= -3 \\ y_1 + y_2 = -5 &\Rightarrow y_2 = -5 - (-3) = -2 \\ -y_1 + y_3 = 13 &\Rightarrow y_3 = 13 + (-3) = 10 \end{aligned}\right\} \Rightarrow y = \begin{bmatrix} -3 \\ -2 \\ 10 \end{bmatrix}$$

Resolver $Ux = y$, sustitución hacia atrás:

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} -3 \\ -2 \\ 10 \end{bmatrix}$$

$$2z = 10 \Rightarrow z = 5$$

$$y + 0z = -2 \Rightarrow y = -2$$

$$x + y + z = -3 \Rightarrow x = -3 - (-2) - 5 = -6$$

La única solución del sistema es $(x, y, z) = (-6, -2, 5)$.

¿Preguntas?

Método de Descomposición LU

Normas Vectoriales en $\mathbb{R}^n$ (1/3)

Objetivo:

- Disponer de una medida del tamaño de los vectores, con objeto de estudiar convergencias, relaciones de mayor o menor, proximidad a cero, etc.

Normas de vectores

- Estudiadas al hablar de los espacios vectoriales Euclídeos.
- La norma de un vector $\|x\|$ debe satisfacer las tres propiedades siguientes:
  1. $\|x\| \geq 0$ y $\|x\| = 0$, si y solo si $x = 0$
  2. $\|\alpha x\| = |\alpha| \, \|x\|$, para caulquier $\alpha \in \mathbb{R}$
  3. $\|x + y\| \leq \|x\| + \|y\|$, desigualdad triangular
- El **producto escalar** permite definir de modo natural una norma en $\mathbb{R}^n$, que coincide con la longitud de un vector en $\mathbb{R}^2$ y $\mathbb{R}^3$:
- Esta norma, llamada **norma Euclídea**, no es la única posibilidad. Puede considerarse caso particular de una norma más general llamada **norma p**:

$$\|x\|_p = \left(\sum_{j=1}^{n} |x_j|^p \right)^{1/p} \qquad p \geq 1$$

Normas Vectoriales en $\mathbb{R}^n$ (2/3)

Casos particulares más utilizados de la **norma-p**:

- **Norma-1:** Se toma $p = 1$,

$$\|x\|_p = \sum_{j=1}^{n} |x_j| = |x_1| + |x_2| + \ldots + |x_n|$$

- **Norma-2 ó norma Euclídea:** Se toma $p = 2$,

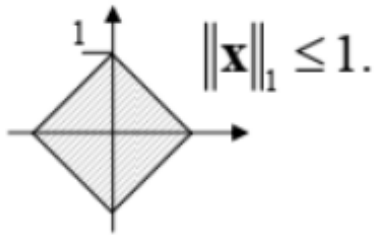
$$\|x\|_p = \sqrt{\sum_{j=1}^{n} |x_j|^2} = \sqrt{x_1^2 + x_2^2 + \ldots + x_n^2}$$

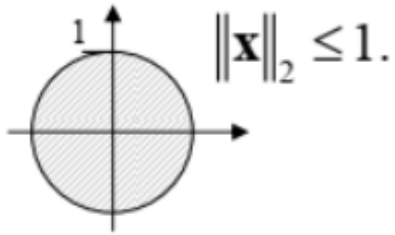
- **Norma-∞ ó norma máxima:** Se toma $p = \infty$

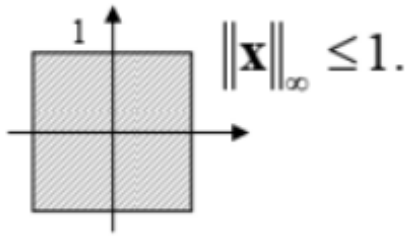
$$\|x\|_\infty = \lim_{p \longrightarrow \infty} \|x\|_p = \lim_{p \longrightarrow \infty} \left(\sum_{j=1}^{n} |x_j|^p \right)^{1/p} = \max_{1 \leq j \leq n} |x_j|$$

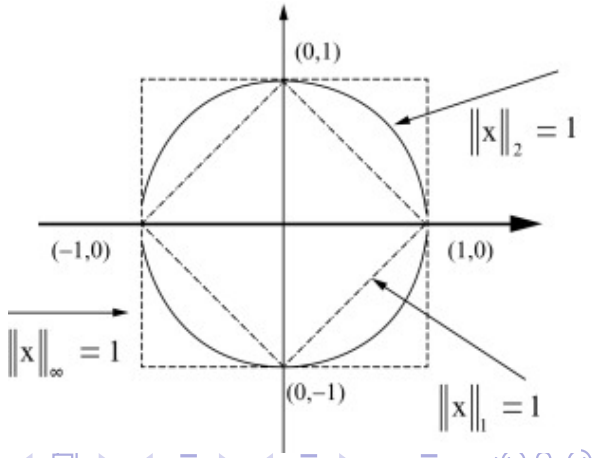
- En la parte derecha de cada norma se muestra el lugar geométrico de los puntos de $\mathbb{R}^2$ que cumplen la condición $\|x\| \leq 1$
- Es inmediato ver que se cumplen las condiciones 1 y 2 de la definición de norma. También se demuestra fácilmente que se cumple la condición 3;

$$\|x+y\| = \sum_{j=1}^{n} |x_j+y_j| \leq \sum_{j=1}^{n} |x_j| + \sum_{j=1}^{n} |y_j| = \|x\|_1 + \|y\|_1$$









Normas Vectoriales en $\mathbb{R}^n$ (3/3)

- Se enuncian dos Teoremas (sin demostración):
- **Teorema 1:**
  - Cada norma vectorial $\|x\|_p$ es una función continua de las componentes del vector x, es decir, de $x_1, x_2, \ldots, x_n$.
- **Teorema 2:**
  - Para cada dos normas vectoriales $\|x\|_i$ y $\|x\|_j$ existen dos constantes positivas m y M tales que:
$$m \|x\|_i \leq \|x\|_j \leq M \|x\|_i \quad \forall x \in \mathbb{R}^n$$
  - Este Teorema establece una **equivalencia** de las normas. Si con una determinada norma una secuencia de vectores tiende por ejemplo a cero, también tenderá a cero con cualquier otra norma

Ejemplo Vectorial 1: Norma $p = 1$ (Manhattan o Taxicab)

Definición de la Norma 1 ($\|v\|_1$)

Corresponde a la **suma de los valores absolutos** de cada una de las componentes del vector:

$$\|v\|_1 = \sum_{i=1}^{n} |v_i| = |v_1| + |v_2| + \cdots + |v_n|$$

Cálculo paso a paso para $v = (3, -4, 2)^T$:

1. Identificar las componentes: $v_1 = 3$, $v_2 = -4$, $v_3 = 2$.
2. Tomar valor absoluto de cada una: $|3| = 3$, $|-4| = 4$, $|2| = 2$.
3. Sumar los resultados:
$$\|v\|_1 = |3| + |-4| + |2| = 3 + 4 + 2 = \mathbf{9}$$

Interpretación

Representa la distancia recorrida a lo largo de los ejes en una cuadrícula urbana (sin atajos diagonales).

Ejemplo Vectorial 2: Norma $p = 2$ (Euclidiana)

Definición de la Norma 2 ($\|v\|_2$)

Es la distancia geométrica habitual (en línea recta) desde el origen hasta el punto final del vector:

$$\|v\|_2 = \sqrt{\sum_{i=1}^{n} |v_i|^2} = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}$$

Cálculo paso a paso para $v = (3, -4, 2)^T$:

1. Elevar cada componente al cuadrado: $3^2 = 9$, $(-4)^2 = 16$, $2^2 = 4$.
2. Sumar los cuadrados: $9 + 16 + 4 = 29$.
3. Extraer la raíz cuadrada principal:

$$\|v\|_2 = \sqrt{3^2 + (-4)^2 + 2^2} = \sqrt{29} \approx \mathbf{5{,}385}$$

Aplicación

Es la medida estándar utilizada en física, geometría y cálculo vectorial para determinar magnitudes reales.

Ejemplo Vectorial 3: Norma Infinito ($p = \infty$ o Máximo)

Definición de la Norma ∞ ($\|v\|_\infty$)

Determina el **máximo valor absoluto** entre todas las componentes del vector:

$$\|v\|_\infty = \max_{1 \le i \le n} |v_i| = \max\left(|v_1|, |v_2|, \ldots, |v_n| \right)$$

Cálculo paso a paso para $v = (3, -4, 2)^T$:

1. Obtener valores absolutos: $|3| = 3$, $|-4| = 4$, $|2| = 2$.
2. Seleccionar el valor mayor del conjunto $\{3, 4, 2\}$:

$$\|v\|_\infty = \max\left(|3|, |-4|, |2| \right) = \max(3, 4, 2) = \mathbf{4}$$

Aplicación

Muy útil en análisis de errores y teoría de control para acotar la peor desviación individual posible.

¿Preguntas?

Norma de un Vector

Norma de una matriz

Normas de matrices y números de condición:

- Sistemas de ecuaciones mal condicionados.
- Normas de matrices: norma de Frobenius y normas asociadas a una norma vectorial.
- Números de condición de una matriz.
- Cálculo del número de condición para la norma Euclídea.
- Inversas de matrices perturbadas.

Observaciones:

- Se va a abordar el problema de la estimación de los errores introducidos en la resolución numérica de los sistemas de ecuaciones lineales mediante los métodos vistos en el curso.
- Para poder hacer este estudio son necesarios varios conceptos introducidos en Álgebra, principalmente el concepto de norma de un vector y de valores y vectores propios.
- Además es necesario introducir el concepto de norma de una matriz, que se basará en la norma de un vector.

Normas Matriciales (1/6)

Norma de una matriz

- Una **norma de una matriz** es un número real positivo que **mide** el tamaño de una matriz, y permite por ejemplo estudiar cuando una matriz tiende a otra matriz o a la matriz nula.
- A la norma de una matriz se le exigen las tres condiciones que debía satisfacer la norma de un vector, y **una condición adicional** relacionada con el producto de matrices:
  1. $\|A\| \geq 0$ y $\|A\| = 0$, si y sólo si $A = 0$
  2. $\|\alpha A\| = \alpha \|A\|$, para cualquier $\alpha \in \mathbb{K}(\mathbb{R}$ o $\mathbb{C})$
  3. $\|A + B\| \leq \|A\| + \|B\|$, (desigualdad triangular)
  4. $\|A \cdot B\| \leq \|A\| \cdot \|B\|$,
- Es posible definir normas de matrices directamente. Por otra parte, las matrices $A \in \mathbb{R}^{(m \times n)}$ forman un espacio vectorial Euclídeo con un producto escalar definido como $< A, B >= traza(A^T \cdot B)$. Este producto escalar induce una norma, llamada **norma de Frobenius**, que responde a la expresión:

- **Norma de Frobenius**

$$\|A\|_F = \sqrt{< A, A >} = \left(\sum_{i=1}^{m} \sum_{j=1}^{n} a_{ij}^2 \right)^{1/2}$$

- **Norma de Magnitud Máxima**

$$A_1 = \max_{1 \leq j \leq n} \sum_{i=1}^{n} a_{ij} = \textbf{Máximo de Suma de Columna}$$

$$A_1 = \max_{1 \leq j \leq n} \sum_{i=1}^{n} a_{ij} = \textbf{Máximo de Suma de Renglones}$$

Cuando se manejan matrices o vectores e
explicar de alguna manera su magnitud e
cuantitativos. Una medida de esa magnit
norma. Esta expresa la exactitud de la so
un sistemas de ecuaciones lineales en térr
cuantitativos determinando la norma del
error (la solución verdadera menos la solu
aproximada). Las normas son también us
estudiar cuantitativamente la convergenci
método iterativo para resolver sistemas d
ecuaciones lineales. Para esto existen vari
de calcular la norma de una matriz, estas
ser:

Normas Matriciales (2/6)

- Norma matricial inducida por una norma vectorial (norma natural):
  - En este caso la norma matricial se define a partir de una norma vectorial:

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{u \neq 0} \|Au\| = \|Ay\| \quad (\|y\| = 1)$$

    donde **y** es el vector concreto de $\mathbb{R}^n$ que produce el máximo (y la igualdad). El máximo se alcanza porque el conjunto de vectores **u** es cerrado y acotado.
  - De esta definición de norma matricial se concluye que:

$$\|A\| \leq \|A\| \, \|x\|$$

  - Se cumplen las cuatro condiciones de la definición de norma matricial:
    1. Si $\|x\| \neq 0, \|A\| \neq 0$ y $\|A\| = 0$ si y solo si $A = 0$
    2. $\|\alpha A\| = \max_{x \neq 0} \frac{\|\alpha Ax\|}{\|x\|} = \max_{x \neq 0} |\alpha| \frac{\|Ax\|}{\|x\|} = |\alpha| \, \|A\| \,, \quad \forall \alpha \in \mathbb{K}(\mathbb{R} \text{ o } \mathbb{C})$
    3. $\|A + B\| = \|(A + B)y\| = \|Ay + By\| \leq \|Ay\| + \|By\| \leq \|A\| + \|B\|$
    4. $\|AB\| = \|(AB)y\| = \|A(By)\| \leq \|A\| \, \|By\| \leq \|A\| \cdot \|B\|$
  - Se pueden estudiar las normas matriciales inducidas por las normas vectoriales: $\|x\|_1$, $\|x\|_2$ y $\|x\|_\infty$ que se denotarán con la notación correspondiente

Normas Matriciales (3/6)

- La expresión de la **norma-1** de una matriz es la siguiente:

$$\|A\|_l = \max_k \sum_{j=1}^{n} |a_{jk}|$$

  - Es decir, la **norma-1** es el máximo de la suma de los valores absolutos de los elementos de cada **columna**.
- Demostración:
  - Supóngase que la igualdad en la definición de la norma se alcanza para un vector y tal que $\|A\|_1 = \|Ay\|_1$, siendo $\|y\|_1 = 1$

$$\|A\|_1 = \|Ay\|_1 = \sum_{j=1}^{n} \left| \sum_{k=1}^{n} a_{jk} y_k \right| \leq \sum_{j=1}^{n} \sum_{k=1}^{n} |a_{jk}| \, |y_k| = \sum_{k=1}^{n} |y_k| \sum_{j=1}^{n} |a_{jk}|$$

$$\leq \sum_{k=1}^{n} |y_k| \max_m \sum_{j=1}^{n} |a_{jk}| = \left(\max_m \sum_{j=1}^{n} |a_{jk}| \right) \sum_{k=1}^{n} |y_k| = \left(\max_m \sum_{j=1}^{n} |a_{jk}| \right) \|y_k\|_1$$

$$= \left(\max_m \sum_{j=1}^{n} |a_{jm}| \right)$$

  - El desarrollo anterior demuestra que el máximo de las sumas de los valores absolutos de cada columna es un límite superior de la **norma-1**, pero para que sea verdaderamente la expresión de la norma este límite debe ser alcanzado.
  - Supóngase que la columna que da el máximo es la columna **K**. Tomando como vector **x** al vector $\mathbf{e_k}$ de la base natural ($\|e_k\|_1 = 1$):

$$\|Ae_k\|_l = \sum_{j=1}^{n} \left| \sum_{k=1}^{n} a_{jk} \delta_{kK} \right| = \sum_{k=1}^{n} |a_{jk}| = \|A\|_l$$

Normas Matriciales (4/6)

- La expresión de la $norma - \infty$ de una matriz es la siguiente

$$\|A\|_\infty = \max_k \sum_{j=1}^{n} |a_{kj}|$$

Es decir, la $norma - \infty$ es el máximo de la suma de los valores absolutos de los elementos de cada **fila**

- Demostración:
  - Supóngase que la igualdad en la definición de la norma se alcanza para un vector y tal que:

$$\|A\|_\infty = \|Ay\|_\infty \text{ siendo } \|y\|_\infty = 1$$

$$\|A\|_\infty = \|Ay\|_\infty \leq \max_j \left| \sum_{k=1}^{n} a_{jk} y_k \right| \leq \max_j \sum_{j=1}^{n} |a_{jk}||y_k|$$

$$\leq \left(\max_k |y_k| \right) \left(\max_j \sum_{k=1}^{n} |a_{jk}| \right) = \max_j \sum_{k=1}^{n} |a_{jk}|$$

  - Al igual que el caso anterior, el máximo de las sumas de los valores absolutos de cada fila es un límite superior de la $norma - \infty$, pero para que sea verdaderamente la expresión de la norma este límite debe ser alcanzado.
  - Supóngase que la fila que da el máximo es la fila J. Se toma un vector x tal que $x_k = aJ_k/|a_{Jk}|$ si $a_{Jk} \neq 0$ y $x_k = 0$ si $a_{Jk} = 0$

$$\|Ax\|_\infty = \max_j \left| \sum_{k=1}^{n} a_{jk} x_k \right| = \left| \sum_{j=1}^{n} a_{jk} x_k \right| = \sum_{k=1}^{n} \left| \frac{a_{jk}^2}{|a_{jk}|} \right| = \sum_{k=1}^{n} |a_{jk}|; \quad \|x\|_\infty = 1$$

Normas Matriciales (5/6)

- La expresión de la norma espectral o $norma-2$ de una matriz es:

$$\|A\|_\infty = \sqrt{\rho(A^H A)}$$

Es decir, la $norma-2$ es la raíz cuadrada del máximo valor propio de la matriz $A^H A$, que es una matriz hermítica y -al menos-**semidefinida positiva**, cuyos valores propios son por tanto **reales y no negativos**.

$$A^H A u_j = \lambda_j u_j \Rightarrow \lambda_j = u_j^H A^H A u_j$$

- Demostración:
  - La matriz $A^H A$ tendrá una base ortonormal de vectores propios $u_1, u_2, \ldots, u_n$
  - El vector y que produce la igualdad en la definición de la norma inducida se puede expresar como combinación lineal de los vectores propios u_j:

$$y = \sum_{k=1}^{n} \alpha_k u_k \qquad \|y\|_2^2 = \sum_{k=1}^{n} |a_k|^2$$

  - Aplicando ahora la definición de la $norma-2$ de un vector:

$$\|A\|_2^2 = \|Ay\|_2^2 = y^H A^H A y = \left(\sum_{j=1}^{n} \alpha_j u_j^H\right) A^H A \left(\sum_{k=1}^{n} \alpha_k u_k\right)$$

$$= \left(\sum_{j=1}^{n} \alpha_j u_j^H\right) \left(\sum_{k=1}^{n} \alpha_k \lambda_k u_k\right) = \left(\sum_{k=1}^{n} \lambda_k |\alpha_k|^2\right) \leq \left(\max_i \lambda_i\right) \left(\sum_{k=1}^{n} |\alpha_k|^2\right)$$

$$= \max_i \lambda_i = \rho(A^H A)$$

  - De nuevo éste es un límite superior, pero dicho límite se alcanza para $x = u_n$

$$\|Au_n\|_2^2 = u_n^H A^H A u_n = u_n^H u_n \lambda_n = \lambda_n = \rho(A^H A)$$

Normas Matriciales (6/6)

- Teoremas relacionados con las normas matriciales (sin demostración)
  - **Teorema 1:** Cualquier norma matricial es una función continua de los $m \times n$ elementos de la matriz $A \in C^{(m \times n)}$.
  - **Teorema 2:** Para cada par de normas matriciales existen unas constantes positivas m y M tales que:
    $$m \|A\|_i \leq \|A\|_i \leq M \|A\|_i$$
    Este Teorema permite hablar de **equivalencia de normas**.
  - **Teorema 3:** Para cualquier norma natural y cualquier matriz cuadrada $A \in C^{(m \times n)}$ se verifica: $\rho(A) \leq \|A\|_i$ pues
    $$\|A\| = \max_{\|x\|=1} \|Ax\| \geq \|Au_n\| = \|\lambda_n u_n\| = |\lambda_n| \, \|u_n\| = |\lambda_n| = \rho(A)$$
  - **Teorema 4:** Para cualquier matriz cuadrada $A \in C^{(n \times n)}$ y cualquier valor ε arbitrariamente pequeño existe alguna norma natural tal que:
    $$\rho(A) \leq \|A\| \leq \rho(A + \varepsilon)$$
    El radio espectral de una matriz cuadrada no es una norma (salvo que la matriz A sea normal, en cuyo caso $\|A\| \leq \rho(A)$, pero puede ser utilizado como tal dada su **cercanía**.
  - **Corolario:** Para cualquier matriz cuadrada A:
    $$\rho(A) = \inf_{\|\|} \|A\|$$

Ejemplo Matricial 1: Norma 1 (Máxima Suma por Columnas)

Definición de $\|A\|_1$

Norma inducida por la norma vectorial 1. Corresponde al **máximo de la suma absoluta de los elementos de cada columna**:

$$\|A\|_1 = \max_{1 \le j \le n} \sum_{i=1}^{m} |a_{ij}|$$

Cálculo paso a paso para $A = \begin{bmatrix} 2 & -3 \\ -5 & 1 \\ 0 & 4 \end{bmatrix}$**:**

1. **Suma absoluta de Columna 1** $(j = 1)$**:**

$$|2| + |-5| + |0| = 2 + 5 + 0 = \mathbf{7}$$

2. **Suma absoluta de Columna 2** $(j = 2)$**:**

$$|-3| + |1| + |4| = 3 + 1 + 4 = \mathbf{8}$$

3. **Seleccionar el máximo:** $\|A\|_1 = \max(7, 8) = \mathbf{8}$

Ejemplo Matricial 2: Norma Infinito (Máxima Suma por Filas)

Definición de $\|A\|_\infty$

Norma inducida por la norma vectorial ∞. Corresponde al **máximo de la suma absoluta de los elementos de cada fila**:

$$\|A\|_\infty = \max_{1 \le i \le m} \sum_{j=1}^{n} |a_{ij}|$$

Cálculo paso a paso para $A = \begin{bmatrix} 2 & -3 \\ -5 & 1 \\ 0 & 4 \end{bmatrix}$**:**

1. **Suma absoluta de Fila 1** $(i = 1)$**:** $|2| + |-3| = 2 + 3 = \mathbf{5}$
2. **Suma absoluta de Fila 2** $(i = 2)$**:** $|-5| + |1| = 5 + 1 = \mathbf{6}$
3. **Suma absoluta de Fila 3** $(i = 3)$**:** $|0| + |4| = 0 + 4 = \mathbf{4}$
4. **Seleccionar el máximo:** $\|A\|_\infty = \max(5, 6, 4) = \mathbf{6}$

Ejemplo Matricial 3: Norma 2 ($\|A\|_2$)

Paso 1: Calcular A^TA

$$A^T = \begin{bmatrix} 1 & 0 \\ 2 & 2 \end{bmatrix} \quad \Rightarrow \quad A^TA = \begin{bmatrix} 1 & 0 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 8 \end{bmatrix}$$

Paso 2: Hallar los autovalores resolviendo $\det(A^TA - \lambda I) = 0$

$$\det \begin{bmatrix} 1-\lambda & 2 \\ 2 & 8-\lambda \end{bmatrix} = 0$$

$$(1-\lambda)(8-\lambda) - (2)(2) = 0 \quad \Rightarrow \quad \lambda^2 - 9\lambda + 8 - 4 = 0$$

$$\lambda^2 - 9\lambda + 4 = 0$$

Paso 3: Obtener las raíces de la ecuación cuadrática Usando la fórmula general $\lambda = \frac{-b \pm \sqrt{b^2-4ac}}{2a}$:

$$\lambda = \frac{9 \pm \sqrt{(-9)^2 - 4(1)(4)}}{2} = \frac{9 \pm \sqrt{81-16}}{2} = \frac{9 \pm \sqrt{65}}{2}$$

Los dos autovalores son:

$$\lambda_1 = \frac{9+\sqrt{65}}{2} \approx \frac{9+8{,}062}{2} \approx \mathbf{8{,}531} \quad (\lambda_{\text{máx}})$$

$$\lambda_2 = \frac{9-\sqrt{65}}{2} \approx \frac{9-8{,}062}{2} \approx 0{,}469$$

Paso 4: Raíz cuadrada del autovalor máximo

$$\|A\|_2 = \sqrt{\lambda_{\text{máx}}} = \sqrt{\frac{9+\sqrt{65}}{2}} \approx \sqrt{8{,}531} \approx \mathbf{2{,}921}$$

Ejemplo Matricial 4: Norma de Frobenius ($\|A\|_F$)

Definición de Norma de Frobenius

Trata a la matriz como si fuese un vector extendido y calcula la raíz de la suma de los cuadrados de todas sus entradas:

$$\|A\|_F = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n} |a_{ij}|^2} = \sqrt{\text{traza}(A^T A)}$$

Cálculo paso a paso para $A = \begin{bmatrix} 2 & -3 \\ -5 & 1 \\ 0 & 4 \end{bmatrix}$**:**

1. Elevar todas las entradas al cuadrado:

$$2^2 = 4, \quad (-3)^2 = 9, \quad (-5)^2 = 25, \quad 1^2 = 1, \quad 0^2 = 0, \quad 4^2 = 16$$

2. Sumar todos los valores: $4 + 9 + 25 + 1 + 0 + 16 = 55$.

3. Extraer la raíz cuadrada:

$$\|A\|_F = \sqrt{55} \approx \mathbf{7{,}416}$$

Cuadro Comparativo de Resultados

Vector de prueba: $v = (3, -4, 2)^T$

Norma Vectorial	Fórmula	Resultado
Norma 1 ($\|v\|_1$)	$\sum \|v_i\|$	**9**
Norma 2 ($\|v\|_2$)	$\sqrt{\sum \|v_i\|^2}$	$\sqrt{29} \approx$ **5,385**
Norma ∞ ($\|v\|_\infty$)	$\max \|v_i\|$	**4**

Matriz de prueba: $A = \begin{bmatrix} 2 & -3 \\ -5 & 1 \\ 0 & 4 \end{bmatrix}$

Norma Matricial	Criterio de Cálculo	Resultado
Norma 1 ($\|A\|_1$)	Máx. suma de columnas	**8**
Norma ∞ ($\|A\|_\infty$)	Máx. suma de filas	**6**
Frobenius ($\|A\|_F$)	Raíz de suma de cuadrados	$\sqrt{55} \approx$ **7,416**

Para la matriz $A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$

Norma	Método / Fórmula	Valor Exacto / Apox.
Norma Infinito ($\|A\|_\infty$)	Máx. suma absoluta por renglón	**3**
Norma 2 ($\|A\|_2$)	$\sqrt{\lambda_{\max}(A^T A)}$	$\sqrt{\frac{9+\sqrt{65}}{2}} \approx$ **2,921**

Las normas son equivalentes pero miden diferentes aspectos de la matriz. La norma infinito es computacionalmente implacable y rápida de calcular, mientras que la norma 2 da la cota geométrica exacta de estiramiento vectorial en el espacio euclídeo.

¿Preguntas?

Norma de una Matriz

Fuentes de error en los cálculos numéricos

Los errores en los resultados numéricos pueden originarse en distintas etapas del proceso de resolución:

1. **Errores del modelo:** simplificaciones de la realidad física. *Ejemplo:* despreciar el rozamiento en un sistema mecánico.
2. **Errores en los datos:** incertidumbre en las mediciones o en los parámetros de entrada. *Ejemplo:* medir una longitud como $L = 1{,}00 \pm 0{,}01\,\text{m}$.
3. **Errores del algoritmo:** errores asociados al procedimiento numérico utilizado. Un algoritmo inestable puede amplificar los errores existentes.
4. **Errores de redondeo:** aparecen porque los números se representan con una cantidad finita de cifras significativas.

Precisión de la aritmética de doble precisión

En el formato IEEE 754 de doble precisión se dispone de 53 bits de significando, incluido el bit implícito para los números normalizados. Esto equivale aproximadamente a 15–16 cifras decimales significativas.

Idea fundamental

No todos los problemas reaccionan de la misma manera ante los errores. La sensibilidad depende del problema y de la calidad del algoritmo empleado.

Condicionamiento: sensibilidad de la solución

Un problema está **mal condicionado** cuando pequeñas perturbaciones en los datos de entrada pueden producir cambios relativamente grandes en la solución.

Consideremos el sistema

$$\underbrace{\begin{bmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{bmatrix}}_{\mathbf{A}} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}.$$

datos originales y solución

$$\begin{bmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \Rightarrow \begin{cases} x_1 = 2 \\ x_2 = 0 \end{cases}$$

pequeña perturbación en los datos

$$\begin{bmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2{,}0001 \end{bmatrix}.$$

Ahora, la solución es

$$\boxed{x_1 = 1, \qquad x_2 = 1}$$

Consideremos el sistema y su solución

$$\left.\begin{aligned} 0{,}0001x_1 + x_2 &= 1, \\ x_1 + x_2 &= 2 \end{aligned}\right\} \Rightarrow \begin{cases} x_1 = \dfrac{1}{0{,}9999} \approx 1{,}00010001, \\ x_2 \approx 0{,}99989999 \end{cases}$$

Eliminación gaussiana sin pivoteo La primera ecuación utiliza como pivote $a_{11} = 0{,}0001$. El multiplicador de eliminación es

$$m_{21} = \frac{1}{0{,}0001} = 10\,000$$

Restando 10 000 veces la primera fila de la segunda:

$$\left[\begin{array}{cc|c} 0{,}0001 & 1 & 1 \\ 1 & 1 & 2 \end{array}\right] \longrightarrow \left[\begin{array}{cc|c} 0{,}0001 & 1 & 1 \\ 0 & -9999 & -9998 \end{array}\right]$$

Con aritmética de solo tres cifras significativas, los valores de la segunda fila pueden redondearse a

$$\left[\begin{array}{cc|c} 0{,}0001 & 1 & 1 \\ 0 & -1{,}00 \times 10^4 & -1{,}00 \times 10^4 \end{array}\right]$$

La **sustitución hacia atrás**, aplicada a este sistema redondeado, produce aproximadamente

$$x_2 \approx 1, \qquad x_1 + x_2 = 1 \Rightarrow x_1 \approx 0,$$

Interpretación

El segundo término independiente cambió solamente en 0,0001, pero la solución cambió de $(2, 0)$ a $(1, 1)$. El sistema es muy sensible a las perturbaciones de los datos.

¿Qué ocurrió?

El pivote pequeño generó un multiplicador enorme. El redondeo durante la eliminación alteró la solución calculada, aunque el sistema original tiene una solución bien definida.

Pivoteo parcial: una estrategia más robusta

Para evitar el pivote inicial pequeño, intercambiamos las filas antes de comenzar la eliminación:

$$\left[\begin{array}{cc|c} 0{,}0001 & 1 & 1 \\ 1 & 1 & 2 \end{array}\right] \longrightarrow \left[\begin{array}{cc|c} 1 & 1 & 2 \\ 0{,}0001 & 1 & 1 \end{array}\right].$$

El nuevo multiplicador es

$$m_{21} = \frac{0{,}0001}{1} = 0{,}0001.$$

Eliminando el primer elemento de la segunda fila:

$$\left[\begin{array}{cc|c} 1 & 1 & 2 \\ 0{,}0001 & 1 & 1 \end{array}\right] \longrightarrow \left[\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & 0{,}9999 & 0{,}9998 \end{array}\right].$$

Por sustitución hacia atrás,

$$x_2 = \frac{0{,}9998}{0{,}9999} \approx 0{,}99989999,$$

$$x_1 = 2 - x_2 \approx 1{,}00010001.$$

Por tanto,

$$\boxed{x_1 \approx 1{,}0001, \qquad x_2 \approx 0{,}9999.}$$

Conclusión

El **pivoteo parcial** selecciona, en cada columna, el elemento de mayor valor absoluto entre las filas disponibles. Ayuda a evitar multiplicadores excesivamente grandes y suele mejorar la estabilidad de la eliminación gaussiana.

¿Preguntas?

Sistemas de Ecuaciones Mal Condicionados

Número de condición de una matriz

Definición

Sea $A \in \mathbb{R}^{n \times n}$ una matriz no singular. El número de condición de A, respecto de una norma matricial subordinada, se define como

$$\boxed{\kappa(A) = \|A\| \, \|A^{-1}\|}.$$

- El número de condición mide la sensibilidad de la solución de un sistema lineal frente a pequeñas perturbaciones en los datos.
- Siempre se cumple que
$$\kappa(A) \geq 1.$$
- Para la matriz identidad,
$$\kappa(I) = \|I\| \, \|I^{-1}\| = 1.$$
- Un valor de $\kappa(A)$ cercano a 1 indica que el sistema está bien condicionado respecto de la norma utilizada.
- Un valor grande de $\kappa(A)$ indica que pequeñas perturbaciones en los datos pueden producir cambios importantes en la solución.

Interpretación

El condicionamiento es una propiedad del problema matemático, no del algoritmo utilizado para resolverlo.

Considérese el sistema lineal

$$A\mathbf{x} = \mathbf{b}.$$

Si el vector independiente experimenta una perturbación $\Delta\mathbf{b}$, la solución también puede cambiar:

$$A(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}.$$

Para una matriz A no singular, se obtiene la cota

$$\boxed{\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \kappa(A)\frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}}.$$

Consecuencia

El número de condición proporciona una cota para la amplificación relativa de las perturbaciones en el vector independiente.

- Si $\kappa(A)$ es pequeño, las perturbaciones suelen tener un efecto limitado sobre la solución.
- Si $\kappa(A)$ es grande, la solución puede ser muy sensible a los errores de medición, representación y redondeo.
- La cota anterior corresponde a perturbaciones en $\mathbf{b}$, con A fija. Si también se perturba A, se necesita un análisis adicional.

Condicionamiento frente a estabilidad numérica

Aunque están relacionados, el condicionamiento y la estabilidad numérica describen aspectos diferentes.

Condicionamiento

Describe la sensibilidad del problema matemático.

- Depende de los datos y del modelo.
- No depende del algoritmo.
- Un problema mal condicionado puede amplificar pequeñas perturbaciones.

Estabilidad

Describe el comportamiento del algoritmo frente a los errores aritméticos.

- Depende del procedimiento numérico.
- Considera los errores de redondeo y su propagación.
- Un algoritmo estable limita los efectos perjudiciales de esos errores.

Idea fundamental

Un problema puede estar mal condicionado y, aun así, resolverse mediante un algoritmo estable. En ese caso, la incertidumbre inherente al problema puede seguir limitando la precisión obtenida.

¿Cómo evaluar un método numérico?

La elección de un método para resolver un sistema lineal $A\mathbf{x} = \mathbf{b}$ debe considerar varios criterios.

1. Costo computacional

Se relaciona con el número de operaciones aritméticas y el tiempo de ejecución.

- Los métodos directos, como la eliminación de Gauss, suelen requerir $O(n^3)$ operaciones para matrices densas.
- Los métodos iterativos pueden ser más económicos cuando la matriz es grande y dispersa.

2. Requerimientos de memoria

Dependen del almacenamiento de la matriz, los vectores y las estructuras auxiliares.

- Una matriz densa requiere, en general, $O(n^2)$ memoria.
- Una matriz dispersa puede almacenarse de manera eficiente guardando únicamente sus elementos no nulos.

3. Aplicabilidad y precisión

La elección depende de las propiedades de la matriz, su tamaño, su estructura, su condicionamiento y la precisión requerida.

Costo, memoria y precisión: comparación

Criterio	**Matriz densa**	**Matriz dispersa**
Almacenamiento	$O(n^2)$	Depende del número de elementos no nulos
Método directo	Costo típico $O(n^3)$	Puede aprovechar la estructura dispersa
Método iterativo	Puede ser costoso para n grande	Puede ser eficiente con productos matriz-vector
Precisión	Depende del condicionamiento y del algoritmo	Depende también de la convergencia y del precondicionamiento

Advertencia

Un menor costo computacional no garantiza una solución más precisa. Siempre es conveniente verificar el residuo

$$\mathbf{r} = \mathbf{b} - A\widehat{\mathbf{x}},$$

donde $\widehat{\mathbf{x}}$ es la solución calculada.

Ejemplo 1: sistema bien condicionado

Considérese el sistema

$$\begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 6 \\ 8 \end{pmatrix}$$

La solución exacta es

$$\mathbf{x} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$$

Usando la norma matricial infinito,

$$\left.\begin{aligned} \|A\|_\infty &= 4 \\ A^{-1} &= \begin{pmatrix} 1/2 & 0 \\ 0 & 1/4 \end{pmatrix} \\ \|A^{-1}\|_\infty &= \frac{1}{2} \end{aligned}\right\} \Rightarrow \kappa_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty = 4\left(\frac{1}{2}\right) = 2$$

Supóngase que el segundo dato cambia de 8 a 8,08. La nueva solución es

$$\widehat{\mathbf{x}} = \begin{pmatrix} 3 \\ 2{,}02 \end{pmatrix}$$

El error relativo en la norma infinito es

$$\frac{\|\Delta \mathbf{x}\|_\infty}{\|\mathbf{x}\|_\infty} = \frac{0{,}02}{3} \approx 0{,}00667$$

Conclusión

Una perturbación del 1 % en el segundo dato produce aquí una variación relativa pequeña en la solución.

Ejemplo 2: sistema mal condicionado

Considérese

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{pmatrix} \qquad \mathbf{b} = \begin{pmatrix} 2 \\ 2{,}0001 \end{pmatrix}.$$

La solución exacta es

$$\mathbf{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

La matriz es casi singular porque sus filas son casi iguales. En la norma infinito,

$$\left.\begin{aligned} \|A\|_\infty &= 2{,}0001 \\ A^{-1} &= \frac{1}{0{,}0001}\begin{pmatrix} 1{,}0001 & -1 \\ -1 & 1 \end{pmatrix}, \\ \|A^{-1}\|_\infty &= 20001 \end{aligned}\right\} \Rightarrow \boxed{\kappa_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty = 40004{,}0001}.$$

Si el segundo dato cambia de 2,0001 a 2,0002, la solución pasa a ser

$$\widehat{\mathbf{x}} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}.$$

Conclusión

Una perturbación de apenas 0,005 % en el segundo dato produce un cambio del 100 % en la norma infinito de la solución. El sistema es muy sensible a pequeñas perturbaciones.

Ejemplo 3: error de redondeo y estabilidad

Considérese el sistema

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{pmatrix}, \qquad \mathbf{b} = \begin{pmatrix} 2 \\ 2{,}0001 \end{pmatrix}.$$

La segunda ecuación puede escribirse como

$$x_1 + 1{,}0001 x_2 = 2{,}0001.$$

Al restar la primera ecuación,

$$0{,}0001 x_2 = 0{,}0001, \qquad x_2 = 1.$$

¿Qué ocurre con el redondeo?

Si los coeficientes o los términos independientes se almacenan con precisión insuficiente, la diferencia entre números muy parecidos puede perder cifras significativas. Como el sistema contiene un coeficiente pequeño, el error en esa diferencia puede amplificarse al calcular x_2.

- El condicionamiento elevado hace que el problema sea sensible a perturbaciones.
- Un algoritmo estable reduce los errores adicionales introducidos por el procedimiento de cálculo.
- Conviene utilizar precisión suficiente y verificar el residuo y el error hacia atrás.

Conclusión

El redondeo no implica automáticamente inestabilidad. La precisión final depende tanto del condicionamiento del problema como de la estabilidad del algoritmo.

¿Preguntas?

Número de Condición

Gracias por su atención

¿Preguntas?

References



Richard L. Burden, J. Douglas Faires, and Annette M. Burden.
Análisis Numérico.
Cengage Learning, 10 edition, 2017.



Antonio Nieves Hurtado and Federico C. Domínguez Sánchez.
Métodos Numéricos Aplicados a la Ingeniería.
1 edition, 2017.