

Análisis Numérico

2. ERRORES, NÚMEROS DE PUNTO FLOTANTE Y ALGORITMOS^{*}

Julio C. Carrillo E.^{**}

Índice

1. Errores	1
2. Números de punto flotante	8
3. Algoritmos	27
Referencias	51

^{*}Para una consulta más detallada de los tópicos acá tratados, consultar la bibliografía recomendada.

^{**}Profesor Escuela de Matemáticas, UIS.

1 Errores

En el modelado de fenómenos físicos es importante conocer a priori las posibles errores que surgen, a fin de poder estar en condiciones de eliminar o reducir sus efectos. El estudio de estos error es un objetivo central del Análisis funcional, el Análisis numérico, y las matemáticas computacionales, entre otras áreas de las matemáticas. Esto no sólo permite analizar, examinar y entender los resultados finales, sino que nos provee de una herramienta que sirve para mejorar los modelos matemáticos y tomar decisiones durante los mismos.

1.1 Fuentes de error

Existen diferentes fuentes de error cuando se modela matemático cuando se resuelve un problema físico. Las más importantes son las siguientes.

1. Errores en la formulación del modelo matemático

Todo modelo matemático es una representación limitada de un fenómeno físico la cual se hace evidente en los errores en:

- a) **Número de datos:** o sea, la cantidad de datos que se consideren en el modelo matemático son necesarios para describir mejor el problema físico. En la gran mayoría de casos, esta selección se reduce bajo algún criterio matemático o físico que define cuántos y cuáles son más adecuados para el estudio del problema; evidentemente, entre más de ellos se consideren, mas difícil resultará resolver el problema.
- b) **Incertidumbre de los datos:** son errores en los datos del modelo matemático como resultado de mediciones físicas (precisión de los instrumentos de medición) y/o cuando estos datos son aproximados mediante números reales. Si los datos del problema no son exactos, la desviación de sus respectivos valores reales son llamados **errores iniciales**. En algunos problemas, la incertidumbre en los datos (usualmente llamados *iniciales*) suelen tener efectos devastadores en la solución numérica del problema (inestabilidad numérica). Adicionalmente, los datos que son constantes deben someterse a la aproximación debido a la limitante de los instrumentos de medición y/o de su aproximación mediante números reales.
- c) **El problema es mal puesto:** Sucede cuando el problema no tiene solución, la solución es única o es inestable (pequeños cambios en los datos de entrada, producen grandes cambios en la solución del problema).

2. Errores en la formulación del modelo de discretización

- a) **El tipo de modelo de discretización:** Este tipo de error es particularmente relevante si los modelos de discretización son discretos o continuos. Entre ellos se tiene por ejemplo, respectivamente, los métodos iterativos que resultan de resolver ecuaciones diferenciales mediante diferencias finitas, o mediante el método de elemento finitos.
- b) **Por aproximación de los datos, variables y valores:** Cuando los datos son números reales, ellos se pueden truncar o redondear en su representación como números reales. En el caso de las funciones, es usual recurrir a la aproximación por truncamiento mediante un polinomio de Taylor. Por ejemplo, como del teorema de Taylor se tiene que

$$e^x = 1 + x + \frac{x^2}{2} + \frac{\xi^3}{6},$$

con ξ entre 0 y x , entonces e^x se puede aproximar mediante el polinomio de Taylor $p_2(x) = 1 + x + \frac{x^2}{2}$, siendo el error de truncamiento $R_2 = \frac{\xi^3}{6}$. El error de aproximación se obtiene como la suma de los errores de truncamiento y de redondeo.

Igualmente, la solución exacta de algunos problemas matemáticos son funciones $v(x)$ continuas en sus respectivas variables independientes. En muchos casos, los métodos numéricos para resolver tales problemas aproximan la solución continua desconocida $v(x)$ por una sucesión $(v(x_n))$ de valores aproximados de la solución en un conjunto discreto o sucesión de puntos (x_n) en el dominio de la función $v(x)$. Por ejemplo, la función $v(x) = x + e^{-x}$ es la solución del problema de valor inicial

$$v' + v = 1 + t, \quad v(0) = 1.$$

En método numérico típico para resolver este problema es mediante diferencias finitas, lo cual da la relación de recurrencia

$$x_0 = 0, v_0 = 1, v_n = (1 - h)v_{n-1} + (1 + t_{n-1})h, \quad n = 2, 3, \dots,$$

con h una distancia constante entre dos valores consecutivos discretos del tiempo t , usualmente llamada la longitud del paso.

-
- c) **Mal condicionamiento.** Los cuales surgen cuando el modelo discreto del problema matemático es inestable o mal condicionado. Es usual que modelos matemáticos mal condicionados produzcan mal condicionamiento en los modelos discretos asociados.

3. Errores en la formulación del modelo computacional

Cuando un modelo discreto se resuelve, es necesario generar un algoritmo en un lenguaje de programación, el cual se ejecuta en una computadora. En tal sentido, se tiene los siguientes errores de tipo computacional.

a) Errores en algoritmos

■ Errores de programación:

- En muchos casos sucede que las operaciones que efectúa el algoritmo diseñado para resolver numéricamente un problema acumula errores debido al tipo de operaciones que este realiza, o por la discretización o truncamiento las funciones involucradas, o porque simplemente tales funciones son sensibles a errores en los valores de las cuales ellas dependen.
- Actualmente los errores de aritmética como consecuencia de errores de máquina son difíciles que sucedan, y son los errores de programación los que actualmente producen las mayores dificultades; estas pueden suceder en los algoritmos y las librerías que se utilicen.
- Por el tipo de programación que se utilice, secuencial o estructurada (punteros y posicionamiento dinámico de memoria)), donde la primera puede eventualmente desbordar la capacidad de la máquina.
- El sistema operativo (OS) y el lenguaje de programación seleccionados.

■ Errores en el software: Errores en las librerías tipo GSL y hasta los mismos lenguajes de programación.

■ Mal condicionamiento.

Los cuales surgen cuando el algoritmo del modelo discreto es inestable o mal condicionado. También es usual que modelos discretos mal condicionados produzcan algoritmos mal condicionados.

b) Errores de máquina

- ##### ■ De representación:
- La representación de números reales se hace mediante números de máquina (o números de punto flotante) y con una precisión dada (simple, 32 bits; doble, 64; cuádruple, 128). Así, un número real eventualmente puede tener una representación decimal infinita mientras que en el caso de los números de máquina no. Por ejemplo, $1/6$ como número real tiene la representación decimal infinita $0.16666\cdots$, que al ser representado

como número de máquina, solo va a tener un número finito de decimales los cuales van a depender de la precisión con la cual se quiere representar éste número. De esta situación tampoco se escapan algunos números reales con representación decimal finita.

■ **De aproximación**

- **En números de máquina:** Son errores que se producen como consecuencia del error que es inherente a la representación de números reales mediante números de máquina. Este tipo de representación trae como consecuencia los errores de redondeo o truncamiento, y los errores de subdesbordamiento o desbordamiento, los cuales se presentan cuando se trabaja con números de máquina muy pequeños o muy grandes.
- **De cómputo por máquina (misiles *patriot*, guerra del Golfo Pérsico):** Anterior a la era de los computadores estos errores provenían de los cálculos numéricos realizados a mano; en la actualidad, se refiere en especial al error que es producto del diseño en la lógica de los procesadores de los computadores.

■ **Propagación de errores**

- **Por aritmética en expresiones numéricas:** Una computadora es un dispositivo que se puede programar para llevar a cabo un conjunto finito de operaciones aritméticas o lógicas, de suma (+), resta (−), multiplicación (×) y división (÷) de números de máquina. Por otro lado, los números de máquina son aproximación de números reales, se tiene un error en esta aproximación. Por tal razón, es posible que se tengan efectos de propagación de estos errores al efectuar operaciones aritméticas con ellos.
- **Por la aritmética en expresiones matemáticas variables:** Aunque hoy día las computadores trabajan con redondeo en la representación de números de máquina, se pueden presentar errores de redondeo importante en la representación de los valores de las expresiones matemáticas variables, los cuales se pueden propagar al efectuar las operaciones matemáticas involucradas. Por ejemplo, en los valores la función $f(x) = \sqrt{x+1} - \sqrt{x}$ cuando $x \gg 1$; en algunos casos en la representación de las soluciones de la ecuación cuadrática $ax^2 + bx + c = 0$ mediante los valores que da la fórmula cuadrática,

$$x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}.$$

1.2 Medidas del error

Para medir los errores antes mencionados, se introducen los conceptos de error absoluto y error relativo.

Definición 1.1. Sea $\tilde{a}$ un valor aproximado de una cantidad cuyo valor exacto es a . Se definen:

1. $a - \tilde{a}$, el error absoluto.
2. $|a - \tilde{a}|$, la magnitud del error absoluto.
3. $\frac{a - \tilde{a}}{a}$, el error relativo si $a \neq 0$.
4. $\frac{|a - \tilde{a}|}{|a|}$, la magnitud del error relativo si $a \neq 0$; en la práctica, se emplea la expresión $\frac{|a - \tilde{a}|}{|\tilde{a}|}$.
5. $m > 0$ es una cota del error absoluto si $|a - \tilde{a}| \leq m$,
6. $m > 0$ es una cota del error relativo si $\frac{|a - \tilde{a}|}{|a|} \leq m$, con $a \neq 0$.

En la práctica, y en general, no se conoce un valor de estos errores, ya que no se dispone del valor exacto a , sino de cotas $\varepsilon_{\tilde{a}}$ y $\rho_{\tilde{a}}$ tales que

$$|a - \tilde{a}| \leq \varepsilon_{\tilde{a}}, \quad \frac{|a - \tilde{a}|}{|\tilde{a}|} \leq \rho_{\tilde{a}}.$$

De acuerdo con esto, el número a se podrá representar como

$$a = \tilde{a} \pm \varepsilon_{\tilde{a}},$$

o bien

$$a = \tilde{a}(1 \pm \rho_{\tilde{a}}),$$

dado que $|a - \tilde{a}| \leq \rho_{\tilde{a}}|\tilde{a}|$.

Observación 1.1. Es usual denotar los errores absoluto y relativo de la forma

$$e_{\tilde{a}} = a - \tilde{a}, \quad r_{\tilde{a}} = \frac{a - \tilde{a}}{a}.$$

Ejemplo 1.1. En las siguientes estimaciones,

$$\begin{aligned} a = 3 \quad \text{y} \quad \tilde{a} = 3.1 &\implies |e_{\tilde{a}}| = 0.1 \quad \text{y} \quad |r_{\tilde{a}}| \approx 0.033, \\ a = 3000 \quad \text{y} \quad \tilde{a} = 3100 &\implies |e_{\tilde{a}}| = 100 \quad \text{y} \quad |r_{\tilde{a}}| \approx 0.033, \end{aligned}$$

se establece que dos aproximaciones distintas tienen el mismo error relativo. En el primer caso el error absoluto es muy pequeño, pero en el segundo es grande.

En las mediciones es más importante el error relativo que el absoluto, pues el primero puede llevar a confusiones mientras que el error relativo es más significativo pues toma en cuenta la magnitud del valor que se está midiendo. Igualmente, al ser un error que no tiene unidades, se puede multiplicar por 100 %, para obtener el error relativo porcentual. En el caso del ejemplo anterior, los errores relativos porcentuales son del 3.3 %. En el segundo caso, aunque el error absoluto es grande, el error relativo porcentual garantiza que $\tilde{a}$ es una buena aproximación de a .

En las siguientes dos definiciones se establecen cotas de los errores absoluto y relativo.

Definición 1.2. Sea $\tilde{a}$ una aproximación del número real a .

1. Si la aproximación se hace mediante truncamiento, se dice que:

a) $\tilde{a}$ aproxima a a con d *dígitos decimales* si d es el mayor entero no negativo para el cual se cumple que

$$|a - \tilde{a}| \leq 10^{-d};$$

b) $\tilde{a}$ aproxima a a con c *cifras significativas* si c es el mayor entero no negativo para el cual se cumple que

$$\frac{|a - \tilde{a}|}{|a|} \leq 10^{1-c}.$$

2. Si la aproximación se hace mediante redondeo, se dice que:

a) $\tilde{a}$ aproxima a a con d *dígitos decimales* si d es el mayor entero no negativo para el cual se cumple que

$$|a - \tilde{a}| \leq 0.5 \cdot 10^{-d}.$$

b) $\tilde{a}$ aproxima a a con c *cifras significativas* si c es el mayor entero no negativo para el cual se cumple que

$$\frac{|a - \tilde{a}|}{|a|} \leq 0.5 \cdot 10^{1-c} = 5 \cdot 10^{-c}.$$

Ejemplo 1.2. Expresé el número $x = 55.47846$ correctamente redondeado a cuatro y tres dígitos decimales. Calcular el error cometido.

Demostración. En el primer caso,

$$x_4 = 35.4785,$$

$$|x - x_4| = |35.47846 - 35.4785| = 4.0 \cdot 10^{-5} \leq \frac{1}{2} \cdot 10^{-4}.$$

En el segundo caso,

$$x_3 = 55.478$$

$$|x - x_3| = |35.47846 - 35.478| = 4.6 \cdot 10^{-4} \leq \frac{1}{2} \cdot 10^{-3}.$$

Note que $x_3 = 35.479$ no es una aproximación correcta dado que

$$|x - x_3| = |35.47846 - 35.479| = 5.4 \cdot 10^{-4} \geq \frac{1}{2} \cdot 10^{-3},$$

la cual es obtenida de x_4 por redondeo. Esto demuestra que no es correcto redondear por exceso cuando el dígito anterior es 5 y proviene de un redondeo previo. $\square$

2 Números de punto flotante

En esta sección se estudia la representación de números reales mediante números de forma de punto flotante, las operaciones aritméticas que con ellos se realizan, así como los errores que resultan de esta representación y de estas operaciones.

2.1 Números de punto flotante

Muchos computadores tienen un modo entero y un modo de punto flotante (o de máquina) para representar números reales que son números enteros y números reales, respectivamente. En la representación en punto flotante se permiten números de gran tamaño, pero existen limitaciones tanto en la magnitud del número como en el número de dígitos. La representación de punto flotante está estrechamente relacionada con lo que se llama notación científica, la cual facilita la representación, en particular, de este tipo de números reales con una cierta precisión (cifras significativas) y facilitar las operaciones aritméticas usuales que con ellos se realizan también.

2.1.1 Sistemas numéricos posicionales

Los números reales usualmente se representan mediante un sistema posicional de base 10, el sistema decimal. En este sistema, los números reales se representan usando diez diferentes caracteres, llamados **dígitos decimales**, a saber, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9. La magnitud con la que un dígito a_i contribuye a la representación del número real depende de su posición en el número, de manera tal que la representación decimal de un número

$$(-1)^s (a_n a_{n-1} \cdots a_1 a_0 \cdot a_{-1} a_{-2} \cdots)$$

corresponde al número real

$$(-1)^s (a_n 10^n + a_{n-1} 10^{n-1} + \cdots + a_1 10^1 + a_0 10^0 + a_{-1} 10^{-1} + a_{-2} 10^{-2} + \cdots),$$

donde s depende del **signo** del número ($s = 0$ si el número es positivo y $s = 1$ si es negativo); los a_i son dígitos decimales del número real, donde a_i es un dígito de la **parte entera** del número si $i \geq 0$ y de la **parte fraccionaria** si $i < 0$.

En principio, cualquier número natural $\beta \geq 2$ puede ser utilizado como base. Fijada esta base, todo número real admite una **representación posicional** en la base β de la forma

$$(-1)^s (a_n \beta^n + a_{n-1} \beta^{n-1} + \cdots + a_1 \beta^1 + a_0 \beta^0 + a_{-1} \beta^{-1} + a_{-2} \beta^{-2} + \cdots),$$

donde los coeficientes $0 \leq a_i \leq \beta - 1$ son los dígitos en el sistema de base β , los cuales se consideran de la parte entera del número real si $i \geq 0$ y de la parte fraccionaria si $i < 0$. Si al igual que en el caso decimal se utiliza un punto para separar tales partes del número, su representación en la base β queda dada como

$$(-1)^s (a_n a_{n-1} \cdots a_1 a_0 \cdot a_{-1} a_{-2} \cdots)_\beta,$$


donde se ha utilizado el subíndice β para evitar cualquier ambigüedad con la base escogida. Esta representación es única, siempre que se excluyan las ambigüedades (tales como $0.999 \cdots = 1$) en el caso decimal.

A pesar de lo anterior, en el ámbito computacional sólo son de interés los sistemas decimal ($\beta = 10$), binario ($\beta = 2$; dígitos 1 y 2), octal ($\beta = 8$; dígitos del 0 al 7) y hexadecimal ($\beta = 16$; dígitos del 0 al 9 y las letras A, B, C, D, E, F).

Por ejemplo, el caso de la representación de un número de binario a decimal,

$$\begin{aligned} 10001.11101_2 &= 1 \times 2^3 + 0 \times 2^2 + 0 \times 2^1 + 1 \times 2^0 + 1 \times 2^{-1} + 1 \times 2^{-2} + 1 \times 2^{-3} + 1 \times 2^{-5} \\ &= 8 + 1 + \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{32} \\ &= 9 + \frac{29}{32} \\ &= 0.990 \cdots \end{aligned}$$

Para cambiar 19.5625_{10} a base 2, se procede primero con la parte entera:



A continuación se procede con la parte entera:

$$\begin{array}{rcl} 0.5625 \times 2 = \underline{1}.125 & \rightarrow & d_1 = 1 \\ 0.125 \times 2 = \underline{0}.25 & \rightarrow & d_2 = 0 \\ 0.25 \times 2 = \underline{0}.5 & \rightarrow & d_3 = 0 \\ 0.5 \times 2 = \underline{1} & \rightarrow & d_4 = 1 \end{array}$$

Dado que

$$19_{10} = 10011_2, \quad 0.5625_{10} = 0.1001_2$$

entonces

$$19.5625_{10} = 10011.1001_2.$$

Una de las grandes ventajas del sistema de posición es que las operaciones aritméticas pueden realizarse de acuerdo a reglas muy sencillas. Cuanto más pequeña es la base más simples son las reglas.

Problema 2.1. Resuelva los siguientes problemas.

1. Muestre que $(13.25)_{10} = (1101.01)_2 = (15.2)_8 = (D.4)_{16}$.
2. Obtenga la representación binaria de los números reales $1/10$, 29 , 0.625 , 0.001 y 5.1265 .
3. ¿Qué conclusiones saca de la representación binaria y la representación decimal?

2.1.2 Representación de punto flotante

Para la representación de números reales grandes o pequeños, con sólo unos pocos dígitos, se utiliza la **notación científica**. Así, todo número real no nulo puede ser escrito en forma única en esta notación de la forma

$$(-1)^s m \times 10^e,$$

donde s es el signo, m es la ***mantisa***, y e es un número entero, llamado el ***exponente***, el cual indica la posición del punto decimal en base 10; además $1 \leq m < 10$, el exponente e es también llamado el orden de magnitud del número real, dado que en esta representación el valor absoluto de tal número se encuentra en el intervalo $[10^e, 10^{1+e})^1$.

Por ejemplo,

$$600000 = (-1)^0 6 \times 10^5, \quad -0.0000567 = (-1)^1 5.67 \times 10^{-5}.$$

Una variación importante de la notación científica es la ***notación científica normalizada***. En ella, todo número real no nulo se puede representar de forma única como

$$(-1)^s 0.a_1 a_2 a_3 \cdots a_k a_{k+1} a_{k+2} \cdots \times 10^e,$$

donde el dígito $a_1 \neq 0$ es diferente de cero. De manera análoga, todo número real no nulo se puede representar en forma única, respecto la base β , en la ***forma de punto flotante normalizada*** como

$$(-1)^s 0.a_1 a_2 a_3 \cdots a_k a_{k+1} a_{k+2} \cdots \times \beta^e, \quad (2.1)$$

donde los dígitos respecto a la base β son tales que $1 \leq a_1 \leq \beta - 1$ y $0 \leq a_i \leq \beta - 1$ para $i \geq 1$, y constituyen la ***parte fraccionaria*** o ***mantisa*** del número real en esta representación, y e es un número entero, llamado el ***exponente***, el cual indica la posición del punto correspondiente a la base β . Si m denota la ***parte fraccionaria*** o ***mantisa*** del número real en la forma de punto flotante normalizada dada en (2.1), entonces su representación en la forma de punto flotante normalizada en la base β es

$$(-1)^s m \cdot \beta^e, \quad (2.2)$$

donde $\beta^{-1} \leq |m| < 1$. En efecto, si $(-1)^s m_c \cdot \beta^e$ corresponde a la notación científica de un número real dado, entonces $1 \leq m_c < \beta$. En consecuencia, $\beta^e \leq m_c \cdot \beta^e < \beta^{1+e}$ de lo cual se sigue que $\beta^{-1} \leq m_c \cdot \beta^{-1} < 1$, donde $m_c \times \beta^{-1}$ corresponde a la mantisa m_n del mismo número pero en forma de punto flotante normalizada en la base β , o sea, $m_n = m_c \cdot \beta^{-1}$.

Por ejemplo,

$$600000 = (-1)^0 0.6 \times 10^6 = (-1)^0 (6)_{10} \cdot 10^{10}, \quad -0.0000567 = (-1)^1 0.567 \times 10^{-4} = (-1)^1 (567)_{10} \cdot 10^{-4}.$$

¹En efecto, sea $x_c = (-1)^s m \times 10^e$ la representación en notación científica del número real x . Dado que $1 \leq |m| < 10$ y $|x_c| = |m| \times 10^e$ entonces $10^e \leq |x_c| < 10^{1+e}$.

Todo dispositivo de cómputo, sea una computadora o una calculadora, tiene un *número finito de dígitos posibles*², digamos k , para representar la mantisa en la base β , y el *exponente sólo puede variar dentro de un rango finito* $L \leq e \leq U$, donde $L < 0$ y $U > 0$. Esto implica que en dispositivos de cómputo sólo un conjunto finito de números reales pueden ser representados bajo estas condiciones, los cuales tienen la forma

$$(-1)^s 0.a_1 a_2 a_3 \cdots a_k \times \beta^e,$$

los cuales se llaman de números de punto flotante con k dígitos (o de precisión k) en la base β y rango (L, U) . A este conjunto se le denota como $\mathbb{F}(\beta, t, L, U)$.

Se tiene en consecuencia lo siguiente:

1. El cero está excluido de $\mathbb{F}$.
2. Si $x \in \mathbb{F}$ entonces su opuesto $-x \in \mathbb{F}$.
3. El número de elementos o la cantidad de números de puntos flotantes de $\mathbb{F}$ es $2(\beta - 1)\beta^{t-1}(U - L + 1)$; es decir, $\mathbb{F}$ es un conjunto discreto de números de punto flotante que tiene este número de elementos.
4. $\mathbb{F}$ es un conjunto acotado, es decir, $x_L \leq |x| \leq x_U$, donde $x_L = \beta^{L-1}$ y $x_U = \beta^U (1 - \beta^{-t})$ son el mayor y menor números de punto flotante positivos que se puede representar bajo las condiciones establecidas sobre $\mathbb{F} = \mathbb{F}(\beta, t, L, U)$. Además, $x_U > x_L > 0$.
5. A partir de lo anterior se tiene que en la recta real existen cinco regiones que no incluyen elementos de $\mathbb{F}$:
 - a) Los números negativos menores que $-x_U$, región denominada *desbordamiento negativo*.
 - b) Los números negativos mayores que $-x_L$, denominada *desbordamiento a cero negativo*.
 - c) El cero.
 - d) Los números positivos menores que x_L , región denominada *desbordamiento a cero positivo*.
 - e) Los números positivos mayores que x_U , denominada *desbordamiento positivo*.

²Debería decirse, dígitos disponibles. Tal número de dígitos desde el punto de vista práctico depende el número de cifras significativas k que se quiere utilizar en la representación de un número real mediante un número de punto flotante.

-
6. Los números de punto flotante no están igualmente espaciados sobre la recta real, sino que están más próximos cerca del origen y más separados a medida que nos alejamos de él.
 7. Una cantidad de gran importancia es el denominado epsilon de la máquina $\epsilon_M = \beta^{1-k}$, el cual representa la distancia entre el número 1 y el número de punto flotante siguiente más próximo.

A fin de ejemplificar la anteriormente mencionado, consideremos todos los números de punto flotante que se pueden representar de la forma

$$x = (-1)^s(0.b_1b_2b_3)_2 \times 2^{\pm k}$$


donde b_1, b_2, b_3 y k son dígitos binarios. En este caso existen dos elecciones para el signo $s = 0, 1$, y dos opciones para b_1, b_2 y b_3 , y tres opciones para el exponente: $\pm 1, 0$. En total, existen $2 \cdot 2 \cdot 2 \cdot 2 \cdot 3 = 48$ diferentes números de punto flotante positivos que tienen esta forma. Los números de este sistema son dados así:

$0.000 \times 2^0 = 0$	$0.000 \times 2^1 = 0$	$0.000 \times 2^{-1} = 0$
$0.001 \times 2^0 = \frac{1}{8}$	$0.001 \times 2^1 = \frac{1}{4}$	$0.001 \times 2^{-1} = \frac{1}{16}$
$0.010 \times 2^0 = \frac{2}{8}$	$0.010 \times 2^1 = \frac{2}{4}$	$0.010 \times 2^{-1} = \frac{2}{16}$
$0.011 \times 2^0 = \frac{3}{8}$	$0.011 \times 2^1 = \frac{3}{4}$	$0.011 \times 2^{-1} = \frac{3}{16}$
$0.100 \times 2^0 = \frac{4}{8}$	$0.100 \times 2^1 = \frac{4}{4}$	$0.100 \times 2^{-1} = \frac{4}{16}$
$0.101 \times 2^0 = \frac{5}{8}$	$0.101 \times 2^1 = \frac{5}{4}$	$0.101 \times 2^{-1} = \frac{5}{16}$
$0.110 \times 2^0 = \frac{6}{8}$	$0.110 \times 2^1 = \frac{6}{4}$	$0.110 \times 2^{-1} = \frac{6}{16}$
$0.111 \times 2^0 = \frac{7}{8}$	$0.111 \times 2^1 = \frac{7}{4}$	$0.111 \times 2^{-1} = \frac{7}{16}$

El menor y el mayor número, no negativos, que se pueden representar en este sistema son, respectivamente,

$$\begin{aligned} 0.001 \times 2^{-1} &= \frac{1}{16} && \text{(menores mantisa y exponente)} \\ 0.111 \times 2^1 &= \frac{7}{4} && \text{(mayores mantisa y exponente)} \end{aligned}$$

Los números positivos de este sistema en este rango es un conjunto discreto el cual es dado en la siguiente figura.



Con el fin de evitar la proliferación de diversos sistemas de puntos flotantes incompatibles entre sí a fines de la década de 1980 se desarrolló los estándares IEEE754/IEC5592, los cuales son implementados en todas las computadoras actuales. Esta norma define dos formatos para la implementación de números de punto flotante en la computadora:

1. Precisión simple: $\mathbb{F}(2, 24, -125, 128)$,
2. Precisión doble: $\mathbb{F}(2, 53, -1021, 1024)$.

Problema 2.2. Resuelva los siguientes problemas.

1. Demuestre los resultados de los numerales 1, 2 y 3 mencionados anteriormente.
2. Considere el conjunto de números de punto flotante $\mathbb{F}(2, 3, -1, 2)$.
 - a) Determine x_L , x_U , y el número de elementos de $\mathbb{F}$.
 - b) Determine los números de punto flotante positivos del conjunto $\mathbb{F}$.
 - c) Graficar sobre la recta real los números de puntos flotantes determinados en el punto anterior.

2.1.3 Redondeo de un número real en su representación de punto flotante

Se considera el conjunto de número de punto flotante $\mathbb{F} = \mathbb{F}(\beta, k, L, U)$. El hecho de que sólo el subconjunto de números reales $\mathbb{F}$ sea representable en una computadora, implica que dado cualquier número real x , para ser representado en su forma

de punto flotante, debe ser aproximado (con k cifras decimales) por un número de punto flotante de tal conjunto; a tal número se denota como $fl(x)$. Es decir, se asume que para todo número $x \in \mathbb{R}$ existe un número $fl(x) \in \mathbb{F}$.

La manera usual de proceder consiste en aproximar ³ a k dígitos a la mantisa de la representación de punto flotante normalizada (infinita) de x , esto es, a partir de

$$x = (-1)^s (0.d_1 d_2 \dots d_k d_{k+1} d_{k+2} \dots)_\beta \times \beta^e,$$

donde se considera que el exponente e se encuentra en el rango $L \leq e \leq U$.

A continuación, se obtiene el número $fl(x)$ terminando la mantisa de x en k cifras decimales, lo cual se puede hacer por *truncamiento* o *redondeo*. En el **método de truncamiento**, simplemente se cortan los dígitos $d_{k+1} d_{k+2} \dots$ para obtener

$$fl(x) = (-1)^s 0.d_1 d_2 \dots d_k \times \beta^e.$$

El **método de redondeo**, si $d_{k+1} \geq \frac{\beta}{2}$, se suma $(-1)^s \frac{\beta}{2} \times \beta^{e-(k+1)}$ a la mantisa de x para luego truncar el resultado. Como

$$x + (-1)^s \frac{\beta}{2} \times \beta^{e-(k+1)} = (-1)^s \left((0.d_1 d_2 \dots d_k d_{k+1} d_{k+2} \dots)_\beta + 0.\underbrace{0 \dots 0}_{k \text{ veces}} \frac{\beta}{2} \times \beta^{-(k+1)} \right) \times \beta^e,$$

en este procedimiento se afecta el dígito d_{k+1} en esta representación, al cual se le suma $\frac{\beta}{2}$. Dado que $d_{k+1} \geq \frac{\beta}{2}$ entonces $d_{k+1} + \frac{\beta}{2} \geq \beta$, lo cual hace que después de sumarle $\frac{\beta}{2}$ a d_{k+1} se le deba sumar 1 a d_k en base β , o sea,

$$x + (-1)^s \frac{\beta}{2} \times \beta^{e-(k+1)} = (-1)^s \left(0.d_1 d_2 \dots d_k d_{k+1} d_{k+2} \dots + (0.\underbrace{0 \dots 0}_{k-1 \text{ veces}} 1)_\beta \right) \times \beta^e.$$

A continuación se trunca. De esta manera se tiene que

$$fl(x) = (-1)^s 0.\delta_1 \delta_2 \dots \delta_k \times \beta^e,$$

³Algunos autores hablan de redondeo simétrico, lo cual no se hará en este caso.

donde

$$\delta_k = \begin{cases} d_k & \text{si } d_{k+1} < \beta/2, & (\text{truncamiento}) \\ d_k + 1 & \text{si } d_{k+1} \geq \beta/2. & (\text{redondeo}) \end{cases}$$

Por ejemplo, al escribir $x = 2.3145697$ en forma normalizada se tiene que $x = 0.23145697 \times 10^1$. Así que la forma de punto flotante de x con un truncamiento de siete cifras es

$$fl(x) = 0.2314569 \times 10^1.$$

Puesto que la octava cifra en la forma normalizada de x es $9 > 5$, entonces se le suma 1 al 9, que es la sexta cifra decimal de x en esta representación. De esta manera se tiene que

$$fl(x) = (0.2314569 + 0.0000001) \times 10^1 = 0.2314570 \times 10^1.$$

Definición 2.1. Si a y $\tilde{a}$ son números reales dados en **representación normalizada** entonces se dice que a es aproximada por $\tilde{a}$ con k **dígitos decimales exactos** si k es el mayor entero para el cual se cumple que

$$|a - \tilde{a}| \leq 0.5 \times 10^{e-k}.$$

El error que resulta de reemplazar un número real por su forma de punto flotante se denomina **error de redondeo**. Una estimación del mismo está dado en el siguiente resultado.

Proposición 2.1. *Todo número real x dentro del rango de los números de punto flotante puede ser representado con un error relativo tal que*

$$\frac{|x - fl(x)|}{|x|} = -\epsilon,$$

donde

$$\begin{aligned} -\frac{1}{2}\beta^{1-t} &\leq \epsilon \leq 0, & (\text{truncamiento de } fl(x)) \\ -\frac{1}{2}\beta^{1-t} &\leq \epsilon \leq \frac{1}{2}\beta^{1-t}. & (\text{redondeo de } fl(x)) \end{aligned}$$

De manera más general,

$$\frac{|x - fl(x)|}{|x|} \leq u_M,$$

donde $u_M = \epsilon_M/2$ es la unidad de redondeo de un computador.

La unidad de redondeo u_M de un computador es el número es un número de punto flotante positivo, el cual es el menor número para el cual se cumple que

$$fl(1 + u_M) > 1.$$

A partir de este resultado se obtiene que un número de punto flotante se puede escribir de forma equivalente como

$$fl(x) = (1 + \epsilon)x. \quad (2.3)$$


La definición de $fl(x)$ y (2.3) se le deben a [9], y es ampliamente utilizada en el análisis de los efectos de redondeo de error.

2.1.4 Forma de almacenamiento de números puntos flotante

Se considera representar una computadora hipotética números de punto flotante de la forma

$$x = (-1)^s (0.m)_2 \cdot 2^e,$$

con una longitud de palabra de 32 bits (dígitos binarios) dando restricciones sobre m y e impuestas por la longitud de palabra. Supongamos que los bits que componen son 1 para el signo s , 1 para el signo del exponente e , 7 para el exponente e y 23 para la mantisa m .



Dado que x se puede normalizar, se puede suponer que el primer bit en m es 1 y por lo tanto no requiere almacenamiento. Los 23 bits que se reservan en la palabra para la mantisa se pueden utilizar para almacenar los dígitos 2 a 24 en m . Así,

$$x = (-1)^s 0.a_1 a_2 a_3 \dots a_{24} \dots \times 2^e \quad a_1 = 1 \quad a_i = 0, 1 \quad i = 2, 3, \dots, 24.$$

Debe notarse que si un decimal x se puede representar exactamente en una palabra de máquina entonces es un número de máquina.

Igualmente, la restricción que $|e|$ no requiera mas de 7 bits significa que

$$|e| \leq 1111111_2 = 2^0 + 2^1 + \dots + 2^6 = 2^6 - 1 = 127,$$

por lo cual $2^{127} \approx 10^{38}$. Esto significa que se pueden manejar números tan pequeños como 10^{-38} y tan grandes como 10^{38} . La restricción de que m requiere no más de 24 bits significa que el número decimal positivo menos representativo, representa unidades de $2^{-24} \approx 10^{-7}$. Por lo tanto los números expresados con más de 7 dígitos decimales serán objeto de una aproximación.

Ejemplo 2.1. Bajo las condiciones anteriores, considere el siguiente número de máquina,

0	0	0001000	101100110000010000000000
---	---	---------	--------------------------

Los dos primeros bit son cero, lo cual nos indica que el número, $s = 0$, y su exponente son positivos. Los siguientes 7 bits son equivalentes al número decimal

$$e = 0001000_2 = 2^3 = 8.$$

La mantisa la dan los 24 bits finales:

$$m = \left(\frac{1}{2}\right)^1 + \left(\frac{1}{2}\right)^3 + \left(\frac{1}{2}\right)^4 + \left(\frac{1}{2}\right)^7 + \left(\frac{1}{2}\right)^8 + \left(\frac{1}{2}\right)^{14} = 0.699279785156,$$

por lo cual el número de máquina en representación decimal es

$$(-1)^0 m \cdot 2^8 = 179.015625.$$

Por otro lado, el siguiente número de punto flotante más pequeño es

0	0	0001000	101100110000010000000001	= 179.0156402587890625
---	---	---------	--------------------------	------------------------

Mientras que el más grande es

0	0	0001000	101100110000001111111111	= 179.0156097412109375
---	---	---------	--------------------------	------------------------

El sistema que se está describiendo usa $2 \times 2 \times 2^7 \times 2^{23} = 2^{32} \approx 10^9$ lugares para representar a todos los números reales. El número de máquina más pequeño mayor que cero que puede representarse es:

0	1	1111111	100000000000000000000000	= $\frac{1}{2} * 2^{-127} \approx 10^{-38}$
---	---	---------	--------------------------	---

mientras que el más grande es

0	1	1111111	111111111111111111111111	= $0.99999940395 * 2^{127} \approx 10^{38}$
---	---	---------	--------------------------	---

Los números con magnitud menor que (10^{-38}) resultan en lo que se llama desbordamiento a cero, y en general se les da el valor cero, mientras que los mayores que (10^{38}) resultan en desbordamiento positivo y causa que los cálculos se detengan.

De manera más general, a continuación se presenta el formato del estándar de la IEEE⁴, para la representación de números de punto flotante. En esta representación de punto flotante, un número es representado internamente en un computador por un bit con signo, un exponente entero exacto e , llamado característica, y una mantisa de la forma $1.f = 1 + f$. Juntas representan el número

$$(-1)^s \cdot \beta^{e-E} \cdot (1.f)_2,$$

donde $s = 0$ corresponde a “+” y $s = 1$ corresponde a “−”, 2 es la base de representación

⁴Institute for Electrical and Electronic Engineers.

Tipo	$\#s$	$\#e$	$\#f$	w	E	p
Media	1	5	10	16	15	11
Simple	1	8	23	32	127	24
Doble	1	11	52	64	1023	53
Extendida	1	15	112	128	16383	113

$\#s$: bits del signo, $\#e$: número de bits del exponente,
 $\#f$: número de bits de la mantisa, $E = 2^{\#e} - 1$,
 w : número total de bits o longitud de la palabra,
 $p = \#f + 1$: bits de precisión.

Formatos binarios del estándar IEEE 754-2008

2.2 Aritmética del computador

2.2.1 La aritmética de punto flotante

La igual que la representación los números en computadoras es inexacta, también lo es su aritmética. Mas aún, el resultado de la operación aritmética sobre dos números de punto flotante no necesariamente es un número de punto flotante. En consecuencia, se debe definir una aritmética en $\mathbb{F}$ que sea lo más semejante posible a la aritmética de los números reales.

Si $\circ$ denota una operación (suma, resta, multiplicación o división) entre dos números reales x e y , y la correspondiente operación de punto flotante ($\oplus$, $\ominus$, $\otimes$, $\oslash$), denotada por $\odot$ es definida como:

$$x \odot y = fl(fl(x) \circ fl(y)).$$

Esta aritmética consiste en efectuar la operación exacta en las representaciones de punto flotante de x e y y luego convertir el resultado a su representación de punto flotante; aunque la implementación efectiva de estas operaciones en una computadora no procede exactamente de esta forma, el resultado final se comporta como se ha indicado.

En particular, si x e y son números de punto flotante, se sigue que existe un número real δ tal que

$$x \odot y = (x \circ y)(1 + \epsilon).$$

Ejemplo 2.2. Sean $k = 4$, $x = 1234.67$, $y = -0.9999 \times 10^{-1}$. Entonces

$$fl(x) = 0.1235 \times 10^4 \quad fl(y) = -0.9999 \times 10^{-1},$$

$$\begin{aligned}
x \oplus y &= fl(fl(x) + fl(y)) = fl(0.1235 \times 10^4 - 0.00009999 \times 10^4) \\
&= fl(0.123490001 \times 10^4) = 0.1235 \times 10^4 = 1235 \\
x \odot y &= fl(fl(x) \cdot fl(y)) = -fl(0.1235 \times 10^4 \cdot 0.9999 \times 10^{-1}) \\
&= -fl(0.12348765 \times 10^3) = -0.1235 \times 10^3 = -123.5
\end{aligned}$$

Vemos que el resultado de una operación en punto flotante es igual al valor redondeado del resultado de la operación y por lo tanto:

$$\frac{|fl(x \odot y) - x \odot y|}{|x \odot y|} \leq \begin{cases} 0.510^{1-k}, & \text{por redondeo} \\ 10^{1-k} & \text{por truncamiento} \end{cases}$$

Problema 2.3. Utilice aritmética de siete dígitos decimales para efectuar los siguientes cálculos. Al comparar los resultados, ¿qué se puede concluir?

1. $a = 1234.567$, $b = 45.67844$, $c = 0.0004$; $(a + b) + c$, $a + (b + c)$.
2. $a = 1234.567$, $b = 1.234567$, $c = 3.333333$; $(a + b) \cdot c$, $a \cdot c + b \cdot c$.

2.2.2 Propagación de errores

Los cálculos que realiza un computador no son exactos ya que los números de punto flotante no son exactos en general y, además, estos errores se van propagando en operaciones aritméticas sucesivas con ellos. Así, si un resultado está afectado de un cierto error y luego se multiplica por un número grande o se divide por un número pequeño, el error se amplifica.

2.2.2.1. Por operaciones aritméticas

Para ver como se pueden propagar los errores en una serie de operaciones aritméticas sucesivas. Sean $x = X + \epsilon$ y $y = Y + \eta$, donde x , y son los respectivos valores aproximados de X , Y , con los respectivos errores de aproximación ϵ y η . Se quiere examinar el efecto del error propagado al usar la operación $\odot$. Sean

$$e_x = X - x = \epsilon, \quad r_x = \frac{e_x}{x} = \frac{\epsilon}{x}, \quad e_y = Y - y = \eta, \quad r_y = \frac{e_y}{y} = \frac{\eta}{y}.$$

1. Multiplicación

Como

$$r_{xy} = \frac{XY - xy}{xy} = \frac{(x + \epsilon)(y + \eta) - xy}{xy} = \frac{\epsilon y + \eta x + \epsilon \eta}{xy} = \frac{\epsilon}{x} + \frac{\eta}{y} + \frac{\epsilon \eta}{xy}$$

entonces⁵

$$r_{xy} = r_x + r_y + r_x r_y$$

Si $|r_x| \ll 1$ y $|r_y| \ll 1$ entonces se tiene que

$$r_{xy} \approx r_x + r_y.$$

2. División

Como

$$r_{x/y} = \frac{\frac{X}{Y} - \frac{x}{y}}{\frac{x}{y}} = \frac{\frac{x + \epsilon}{y + \eta} - \frac{x}{y}}{\frac{x}{y}} = \frac{\frac{xy + \epsilon y - xy - x\eta}{(y + \eta)y}}{\frac{x}{y}} = \frac{\frac{\epsilon y - \eta x}{xy}}{\frac{y + \eta}{y}} = \frac{\frac{\epsilon}{x} - \frac{\eta}{y}}{1 + \frac{\eta}{y}}$$

entonces

$$r_{x/y} = \frac{r_x - r_y}{1 + r_y}.$$

Si $|r_y| \ll 1$ entonces

$$r_{x/y} \approx r_x - r_y.$$

Los anteriores resultados demuestran que para la multiplicación y división, los errores relativos no se propagan rápidamente.

3. Suma y resta

En este caso,

$$r_{x \pm y} = \frac{(X \pm Y) - (x \pm y)}{x \pm y} = \frac{((x + \epsilon) \pm (y + \eta)) - (x \pm y)}{x \pm y} = \frac{\epsilon}{x \pm y} \pm \frac{\eta}{x \pm y} = \frac{x}{x \pm y} \frac{\epsilon}{x} \pm \frac{y}{x \pm y} \frac{\eta}{y},$$

⁵El símbolo $\ll$ significa “mucho menor que”. Así, $a \ll b$ significa que a es mucho más pequeño que b .

entonces

$$r_{x \pm y} = \frac{x}{x \pm y} r_x \pm \frac{y}{x \pm y} r_y.$$

Si x y y tienen el mismo signo,

$$\left| \frac{x}{x + y} \right| \leq 1, \quad \left| \frac{y}{x + y} \right| \leq 1,$$

y por tanto

$$|r_{x \pm y}| \leq \max \{ |r_x|, |r_y| \}.$$

Si los dos tienen signos opuestos, entonces $\left| \frac{x}{x + y} \right| > 1$ ó $\left| \frac{y}{x + y} \right| > 1$, y uno de los errores relativos r_x ó r_y será amplificado. Esto es drástico si $x \approx -y$.

Al contrario, en el caso del error absoluto en $x \pm y$ se tiene que

$$e_{x \pm y} = (X \pm Y) - (x \pm y) = (X - y) \pm (Y - y) = \epsilon \pm \eta,$$

o bien,

$$e_{x \pm y} = e_x \pm e_y.$$

Aunque esto parece razonable, en la práctica se presentan algunas dificultades, pues este error puede ser muy pobre cuando se compara con r_x y r_y .

Ejemplo 2.3. Sean $X = \pi$, $x = 3.1416$, $Y = \frac{22}{7}$, $y = 3.1429$. Entonces

$$\begin{aligned} e_x &= X - x & r_x &\approx -2.34 \times 10^{-6} \\ &\approx -7.35 \times 10^{-6}, & & \\ e_y &= Y - y & r_y &\approx -1.36 \times 10^{-5} \\ &\approx -4.29 \times 10^{-5} & & \\ e_{x-y} &= (X - Y) - (x - y) & r_{x-y} &\approx -0.028 \end{aligned}$$

$$\begin{aligned} &\approx -0.0012645 - (-0.0013) \\ &\approx 3.55 \times 10^{-5} \end{aligned}$$

Aunque el error en $x - y$ es pequeño, el error relativo en $x - y$ es mucho mas grande que solo en x o y .

2.2.2.2. En sumas extendidas

Dado un decimal x y su número de máquina más cercano $fl(x)$ y δ el error relativo, como

$$\delta = \frac{fl(x) - x}{x}$$

entonces

$$fl(x) = x(1 + \delta) \quad |\delta| \leq u_M \times 10^{1-k},$$

donde $u_M \times 10^{1-k}$ se llama el error de redondeo unitario.

Supongamos ahora que se quiere calcular la suma $\sum_{i=1}^n x_i$ siendo $x_i = fl(x_i)$. Sea

$$fl(x_1 + x_2) = (x_1 + x_2)(1 + \varepsilon_2), \quad |\varepsilon_2| \leq \begin{cases} 0.510^{1-k}, & \text{por redondeo} \\ 10^{1-k}, & \text{por truncamiento} \end{cases}$$

Entonces

$$fl(x_1 + x_2 + x_3) = fl(fl(x_1 + x_2) + x_3) = ((x_1 + x_2)(1 + \varepsilon_2) + x_3)(1 + \varepsilon_3),$$

en donde $|\varepsilon_3|$ tiene la misma cota que $|\varepsilon_2|$. En general:

$$\begin{aligned} fl(x_1 + x_2 + x_3 \cdots + x_n) &= (x_1 + x_2)(1 + \varepsilon_2)(1 + \varepsilon_3) \cdots (1 + \varepsilon_n) \\ &\quad + x_3(1 + \varepsilon_3)(1 + \varepsilon_4) \cdots (1 + \varepsilon_n) \\ &\quad + \cdots + x_n(1 + \varepsilon_n) \\ &\approx (x_1 + \cdots + x_n) + (x_1 + x_2)(\varepsilon_2 + \cdots + \varepsilon_n) + \\ &\quad + x_3(\varepsilon_3 + \cdots + \varepsilon_n) \cdots + x_n \varepsilon_n, \end{aligned}$$

resultando que

$$fl(x_1 + \cdots + x_n) - (x_1 + \cdots + x_n) = (x_1 + x_2)(\varepsilon_2 + \cdots + \varepsilon_n) + x_3(\varepsilon_3 + \cdots + \varepsilon_n) + \cdots + x_n\varepsilon_n.$$

Se deduce entonces que la mejor estrategia para la suma es ordenar los números de menor a mayor y luego sumarlos en este orden.

La pérdida de cifras significativas debida al error de redondeo puede evitarse, frecuentemente, reformulando el problema, como se muestra en los ejemplos siguientes.

Problema 2.4. Resolver los siguientes problemas.

1. Encontrar las raíces de $x^2 + 62.10x + 1 = 0$ usando aritmética de redondeo de 4 dígitos.
2. Evaluar $p(x) = x^3 - 6x^2 + 3x - 0.149$ en $x = 4.71$ usando aritmética de tres dígitos.

2.2.3 Pérdida de cifras significativas

Este anterior ejemplo muestra que es posible tener una gran disminución en la precisión, en un sentido del error relativo, al restar cantidades casi iguales. Esta puede ser una forma muy importante de perder la precisión cuando se propaga un error en un cálculo.

Por ejemplo, sean $p = 3.1415926536$ y $q = 3.1415957341$, que son números casi iguales y están ambos expresados con una precisión de 11 cifras significativas. Si se calcula su diferencia, $p - q = -0.0000030805$ se ve que, como las primeras seis cifras de p y de q coinciden, su diferencia $p - q$ sólo contiene cinco cifras decimales. Este fenómeno se conoce como *pérdida de cifras significativas* o *cancelación*, y hay que tener cierto cuidado con él porque puede producir, sin que nos demos cuenta, una reducción en la precisión de la respuesta final calculada.

Se dan a continuación algunos ejemplos de este fenómeno, junto con sugerencias sobre cómo se puede evitar en algunos casos.

Ejemplo 2.4. Cuando se resuelve la fórmula cuadrática $ax^2 + bx + c = 0$, la cual tiene soluciones

$$X_1 = \frac{-b + \sqrt{b^2 - 4ac}}{2a}, \quad X_2 = \frac{-b - \sqrt{b^2 - 4ac}}{2a}.$$

Cuando $b^2 \gg 4ac$ (i.e, $4ac$ es muy pequeño en comparación con b^2) se tiene entonces que

$$x_1 = 0, \quad x_2 = -\frac{b}{a}.$$

Por ejemplo, para la ecuación cuadrática $x^2 + 256x + 1 = 0$ se tiene que

$$X_1 = -128 + \sqrt{16383}, \quad X_2 = -128 - \sqrt{16383}.$$

Utilizando 6 cifras significativas, $\sqrt{16383} \approx 127.996$, y así se tiene que

$$x_1 = 0.004, \quad x_2 = -255.996.$$

Considerando

$$X_1 = \frac{-128 + \sqrt{16383}}{1} \cdot \frac{-128 - \sqrt{16383}}{-128 - \sqrt{16383}} = -\frac{1}{128 + \sqrt{16383}},$$
$$X_2 = \frac{-128 - \sqrt{16383}}{1} \cdot \frac{-128 + \sqrt{16383}}{-128 + \sqrt{16383}} = \frac{1}{-128 + \sqrt{16383}}.$$

Usando nuevamente 6 cifras significativas, $\sqrt{16383} \approx 127.996$,

$$x_1 = -0.0039, \quad x_2 = 250.$$

Se deja como ejercicio calcular los errores relativos en ambos casos.

Ejemplo 2.5. Sea $|x| \ll 1$. Para evitar la pérdida de cifras significativas en el calculo de la expresión $\frac{1}{1+2x} - \frac{1-x}{1+x}$, es conveniente representarla de la forma

$$\frac{1}{1+2x} - \frac{1-x}{1+x} = \frac{(1+x) - (1+2x)(1-x)}{(1+2x)(1+x)} = \frac{2x^2}{(1+2x)(1+x)}.$$

Ejemplo 2.6. Si $|x| \gg 1$, ocurren errores importantes en el cálculo de los valores de la función $f(x) = \sqrt{x+1} - \sqrt{x}$. Para ello se reescribe de la forma

$$f(x) = \frac{\sqrt{x+1} - \sqrt{x}}{1} \cdot \frac{\sqrt{x+1} + \sqrt{x}}{\sqrt{x+1} + \sqrt{x}} = \frac{1}{\sqrt{x+1} + \sqrt{x}}.$$

Ejemplo 2.7. Se considera calcular la suma

$$S = \sum_{j=1}^n x_j$$

con términos positivos y negativos x_j , cada uno de los cuales es un valor aproximado. Además, se supone que la suma S es mucho menor que la magnitud máxima de los x_j . Al calcular dicha suma en una computadora, es probable que ocurra un error de pérdida de cifras significativas. Sea a continuación una ilustración de esto.

Se considera la fórmula de Taylor para e^x para evaluar e^{-5} ,

$$e^{-5} \approx 1 + \frac{(-5)}{1!} + \frac{(-5)^2}{2!} + \frac{(-5)^3}{3!} + \cdots + \frac{(-5)^n}{n!}.$$

Imagine utilizar una computadora con aritmética de coma flotante redondeada decimal de cuatro dígitos, de modo que cada uno de los términos de esta serie deba redondearse a cuatro dígitos significativos. En la Tabla 1.2, damos estos términos redondeados x_j , junto con la suma exacta de los términos hasta el grado dado. El verdadero valor de e es .006738, a cuatro dígitos significativos, y esto es bastante diferente de la suma final en la tabla. Además, si (1.4.17) se calcula exactamente para $n = 25$, entonces el valor correcto de e^{-5} se obtiene con cuatro dígitos.

3 Algoritmos

3.1 Algoritmos y convergencia

Definición 3.1. Un algoritmo es un procedimiento que describe de forma precisa una sucesión de pasos que deben ser ejecutados en un orden especificado para resolver un problema o para obtener una aproximación a dicha solución.

Los algoritmos implementan los métodos numéricos para la resolución de problemas. Estos métodos pueden ser:

-
1. **Iterativos.** Si el método va construyendo una sucesión que en determinadas condiciones converge a la solución exacta del problema, es decir, si el algoritmo es reiterativo, en el sentido de que hay pasos de él que se repiten un número arbitrario de veces hasta que se cumpla cierto criterio de parada. En este tipo de métodos el error de redondeo no suele afectar a la solución obtenida tanto como en los métodos directos.
 2. **Directos.** Si no son iterativos. En estos métodos los errores de redondeo suelen ser preponderantes sobre los de truncamiento.

En el caso de los algoritmos iterativos, se entiende que un método numérico converge si la sucesión formada por las aproximaciones obtenidas en cada iteración: $\{x_n\}_{n=1}^{\infty}$ converge, es decir, tiene como límite la solución exacta x . En términos más sencillos esto también se puede expresar diciendo que las aproximaciones obtenidas en cada iteración, x_n se van aproximando cada vez más al valor exacto solución del problema.

Cuanto menor sea el número de iteraciones necesarias para obtener la solución del problema con una tolerancia fijada de antemano, mayor será la velocidad de convergencia del método.

Es normal que los errores iniciales en los datos se propaguen a lo largo de una cadena de operaciones. Una cualidad deseable de cualquier proceso numérico es que un error pequeño en las condiciones iniciales produzca errores pequeños en el resultado final. Un algoritmo con esta cualidad se llama estable; en otro caso, se llama inestable. Siempre que sea posible, elegiremos métodos que sean estables.

Un algoritmo iterativo estable garantiza la convergencia. Un método numérico no siempre converge. Se dice que un método numérico iterativo diverge si los resultados obtenidos en cada iteración se van alejando cada vez más de la solución exacta. Por este motivo, al implementar un método numérico mediante el correspondiente algoritmo suele ser una buena técnica que el criterio de parada contemple un número máximo de iteraciones a realizar.

Existen métodos numéricos de convergencia rápida pero inestables y otros estables pero de convergencia lenta.

La siguiente definición describe el fenómeno de la propagación de los errores.

Definición 3.2. Supongamos que ε representa un error inicial y que $\varepsilon(n)$ representa el crecimiento de dicho error después de n operaciones. Si se verifica que $|\varepsilon(n)| \approx n\varepsilon$, entonces se dice que el crecimiento es lineal. Si $|\varepsilon(n)| \approx K^n\varepsilon$, entonces se dice que el crecimiento es exponencial. Si $K > 1$, entonces un error exponencial crece cuando $n \rightarrow \infty$ sin que podamos acotarlo; pero si $0 < K < 1$, entonces un error exponencial disminuye a cero cuando $n \rightarrow \infty$. Un error inicial puede propagarse de manera estable o inestable.

Ejemplo 3.1 (Algoritmo de Horner para la evaluación de polinomios). Consiste en una forma eficiente de evaluar un polinomio en la que se reduce el número de multiplicaciones con respecto a la forma tradicional. Sea considera el polinomio:

$$P(x) = a_0x^n + a_1x^{n-1} + \cdots + a_{n-1}x + a_n.$$

Para obtener el valor de $P(x_0)$ consideramos una expresión equivalente de $P(x)$:

$$P(x) = \underbrace{\left(\cdots \overbrace{(a_0x + a_1)}^{b_1} x + \cdots + a_{n-1} \right)}_{b_{n-1}} x + a_n.$$

De esta forma, sustituyendo x por x_0 , $P(x_0) = b_n$. Se pueden describir los pasos del algoritmo de la siguiente forma:

```

1:  $b_0 = a_0$ 
2: for  $k = 1$  to  $n$  do
3:    $b_k = b_{k-1}x_0 + a_k$ 
4: end for
5: print  $P(x_0) = b_n$ 

```

Problema 3.1.

- Sean $f(x) = \frac{e^x - 1 - x}{x^2}$ y $P(x) = \frac{1}{2} + \frac{x}{6} + \frac{x^2}{24}$. Calcular $f(0.01)$ y $P(0.01)$ con cifras significativas. Tenga en cuenta que $P(x)$ es el polinomio de segundo grado de $f(x)$. ¿Cuál de los dos resultados es más correcto?
- Sea $P(x) = x^3 - 3x^2 + 3x - 1$. Calcular $P(2.19)$ directamente y utilizando el algoritmo de Horner con 3 cifras significativas, y comparar con el valor exacto 1.685159.
- Sean $p_1 = 1.414$ y $p_2 = 0.09125$, que están dados con 4 cifras significativas. Hallar el resultado más adecuado para $p_1 + p_2$ y $p_1 \cdot p_2$.
- Realizar los siguientes cálculos directamente indicando qué fenómeno se presenta. Obtener después un valor más preciso.
a) $\frac{\sin\left(\frac{\pi}{4} + 0.00001\right) - \sin\left(\frac{\pi}{4}\right)}{0.00001}$, (b) $\frac{\ln(2 + 0.00005) - \ln(2)}{0.00005}$

-
5. La pérdida de cifras significativas se puede evitar reordenando los cálculos. Hallar en los siguientes casos una forma equivalente que evite la pérdida de cifras significativas para valores grandes de x :

a) $\ln(x+1) - \ln(x)$, b) $\sqrt{x^2+1} - x$.

3.2 El error en algoritmos

1. Supongamos que el algoritmo o proceso iterativo de un problema numérico está definido mediante una condición inicial x_0 y una sucesión de números reales $(x_n)_{n=1}^{\infty}$, o por brevedad (x_n) , que determina las estimaciones sucesivas de la solución x del problema numérico.
2. A priori estamos interesados en determinar que tan exacto y preciso es este proceso iterativo en la obtención de la solución del problema numérico y a que velocidad las estimaciones del proceso iterativo se aproximan a la solución del problema numérico (calidad de las aproximaciones);
3. Adicionalmente, como el proceso iterativo es de carácter infinito, buscamos obtener criterios de parada para este proceso (error de truncamiento en el algoritmo).
4. Estos interrogantes son importantes también resolverlos cuando, como es usual, se desconoce la solución x del proceso iterativo.
5. Como veremos, la medida del error cometido al obtener estimaciones de la solución del problema numérico mediante algoritmos o proceso iterativos es la herramienta adecuada para resolver estos interrogantes.

3.2.1 Exactitud y precisión en procesos iterativos

1. Se dice que el proceso iterativo de un problema numérico es exacto si la magnitud del error absoluto entre la solución del problema numérico y las estimaciones sucesivas del proceso iterativo se hace cada vez mas pequeño.
2. El mismo proceso iterativo se dice que es preciso si la magnitud del error entre aproximaciones sucesivas del proceso iterativo se hace cada vez más pequeña.

A continuación vamos a formalizar estas ideas.

3.2.1.1. Exactitud y precisión de un proceso iterativo Nuevamente supongamos que la sucesión (x_n) está asociada al proceso iterativo el cual determina las estimaciones sucesivas de la solución x de un cierto problema numérico.

1. **Sucesiones convergentes (exactitud):** se dice que el proceso iterativo es exacto si la sucesión (x_n) es convergente a x , o sea, si dado $\epsilon > 0$ existe un $N = N(\epsilon) \in \mathbb{N}$ tal que si $n \geq N$ entonces $|x_n - x| < \epsilon$. En tal caso, se dice que el proceso iterativo (x_n) es exacto y converge a x con una tolerancia ϵ después de N iteraciones.

Nota: en aplicaciones el límite x de la sucesión (x_n) es generalmente desconocido, a menos que se permita que $n \rightarrow \infty$, lo cual no es posible en un computador. En cálculos reales, de máquina, es importante que se pueda detectar la convergencia (numérica) del algoritmo una vez se alcance la tolerancia establecida.

2. **Sucesiones de Cauchy (precisión):** se dice que el proceso iterativo es preciso si la sucesión (x_n) es de Cauchy, es decir, si dado $\epsilon > 0$ existe un $N = N(\epsilon) \in \mathbb{N}$ tal que si $m, n \geq N$ entonces $|x_n - x_m| < \epsilon$. En tal caso se dice que el proceso iterativo (x_n) es preciso con una tolerancia ϵ después de N iteraciones.

En la práctica, la precisión del proceso iterativo se expresa como $|x_{n+1} - x_n| < \delta$ cuando $n > N$. El número de iteraciones N para lograr la precisión del proceso iterativo depende de los valores de δ . En general, cuando δ decrece, N crece. En otras palabras, toma mas tiempo y esfuerzo (trabajo) el lograr la precisión del algoritmo a niveles de tolerancia bajos.

3.2.2 Criterios de error absoluto y relativo

Dado que en general se desconoce la solución exacta x a la cual converge la sucesión (x_n) de un proceso iterativo, se debe recurrir a determinar su precisión. En este caso, los criterios utilizados será

$$|x_n - x_{n-1}| < \Delta_a, \quad \left| \frac{x_n - x_{n-1}}{x_{n-1}} \right| < \delta_r$$

donde Δ_a y δ_r son las tolerancias absoluta y relativas consideradas, respectivamente. Criterio de precisión relativo es usualmente el más práctico, dado que no cambio cuando las escalas en el proceso iterativo son apropiadas. La tolerancia δ_r se puede interpretar como al mayor incertidumbre aceptable con el menor en el dígito menos significativo de los resultados calculados. Así, las tolerancias en precisión relativa son usualmente especificadas como 5×10^{-p} , donde la incertidumbre en el dígito $p - 1$ del resultado es aceptable. Una valor de $\delta_r = 5 \times 10^{-4}$ por ejemplo, implica que la diferencia entre x_n y x_{n-1} se desea sea más pequeño que el tercer dígito de x_{n-1} . El factor de 5 en la tolerancia asume la incertidumbre en el redondeo.

El criterio de error absoluto es conveniente siempre y cuando los términos de la sucesión (x_n) estén cerca de su límite. por tal razón, un criterio de convergencia alternativo se puede obtener al combinar los dos criterios de precisión considerados anteriormente,

$$|x_n - x_{n-1}| < \max \{ \Delta_a, \delta_r |x_{n-1}| \},$$

el cual establece que las iteraciones continúan hasta la máxima tolerancia se obtenga.

Dado que los valores apropiados de Δ_a y δ_r pueden cambiar de problema a problema, la mínima cota superior ε_m para ambos criterios $-\varepsilon_m$ debe ser el menor número real tal que $\Delta_a < \varepsilon_m$ y $\delta_r < \varepsilon_m$ puede dar como resultado en un loop infinito, pues la diferencia $x_n - x_{n-1}$ puede que nunca sea menor que ε_m debido a errores de redondeo, incluso para una sucesión que converge en aritmética exacta.

Problema 3.2. Se puede definir mediante el método de Newton un proceso iterativo que calcular la raíz cuadrada de un número real positivo x . Dada una estimación r_n de la raíz cuadrada de x , las siguiente estimación de la raíz de x se obtienen como $r_{n+1} = (r_n + x/r_n)/2$. La estimación inicial de la raíz de x se puede considerar como $r_0 = x/2$.

1. Escriba un algoritmo que:

- a) Calcule la aproximación de un número real dado con una tolerancia de a lo mas $5 \cdot 10^{-9}$ y que tal aproximación se obtenga hasta con máximo 25 iteraciones (*while loop*).
- b) Reporte el número al cual se le va a encontrar su raíz cuadrada, la raíz cuadrada del número reportada por la computadora, la raíz cuadrada del número obtenido por el algoritmo anterior, el error absoluto y relativo en esta aproximación.

2. Utilice el anterior algoritmo a los números reales 4, 4.04, $4 \cdot 10^{-k}$ ($k = 4, 6, 8, 10, 12$).

3. ¿Qué puede concluir de los resultados anteriores?

3.2.3 Error de truncamiento en algoritmos

El error de truncamiento resulta de aproximar expresiones matemáticas funciones continuas mediante fórmulas algebraicas discretas. A diferencia del error de aproximación, que es controlado por el hardware y el lenguaje de programación utilizado, el error de truncamiento no se puede reducir seleccionando aproximaciones discretas mas precisas.

El análisis del error de truncamiento es propio de cada método numérico. Por ejemplo, la representación de e^x mediante series de Taylor es

$$e^x = 1 + x + \frac{x^2}{2!} + \cdots \quad (3.1)$$

Es imposible, y no necesario, sumar un número infinito de términos en el cálculo de e^x . A partir de un cierto punto, los términos de orden superior se deben suprimir pues ellos no hacen una contribución significativa a la suma. La diferencia entre el valor de e^x y el valor calculado con un número finito de términos de la serie se conoce como error de truncamiento. La palabra truncamiento sugiere la causa del error, es decir, que la serie ha sido truncada. El error de truncamiento en (3.1) depende del argumento de la función e^x . Para $x \ll 1$, el numerador de los términos sucesivos decrecen rápidamente. Para $x \gg 1$, se van a necesitar muchos términos antes que el término factorial en el denominador sobrepase el término de la potencia en el numerador.

El número de términos requerido para logra un valor preciso de e^x es independiente de dígitos utilizado en el cálculo de cada término. En otras palabras, el error de redondeo y de truncamiento son independientes.

Problema 3.3. Sean T_k el término n -ésimo de la serie de e^x y S_k el valor de la suma de k términos:

$$T_k = \frac{x^k}{k!}, \quad S_k = 1 + \sum_{i=1}^k T_i.$$

Cuando la serie de e^x es truncada después de n términos, el error absoluto en aproximación de la serie es

$$e_n = |S_n - e^x|.$$

1. Construya un programa que permita calcular e^{-10} con 15 términos de la serie de e^{-10} y una tolerancia de $5 \cdot 10^{-12}$. Dado que $S_n > T_n$, considere como criterio de parada que

$$\left| \frac{T_k}{S_k} \right| < \text{tol.}$$

Ante posibles problemas de desbordamiento, considere también terminar el proceso con $n = 60$ términos. El programa debe reportar los términos T_n , S_n y el error de truncamiento con el número de términos obtenido en el proceso. Realice una gráfica del error absoluto. ¿Qué concluye?

2. Muestre que los términos T_n de la serie de e^x se pueden escribir de la forma

$$T_k = \frac{x}{n} T_{k-1}, \quad k = 1, 2, \dots$$

Dado que

$$\frac{T_k}{T_{k-1}} = \frac{x}{n},$$

se puede considerar como criterio de parada que

$$\left| \frac{T_k}{T_{k-1}} \right| < \text{tol.}$$

Realice estos dos cambios en el anterior programa y reporte los mismos resultados. ¿Qué concluye?

Para una función que sea de clase $C^{n+1}[a, b]$ y un $x_0 \in [a, b]$, el teorema de Taylor garantiza que existe un ξ entre x_0 y x tal que

$$f(x) = P_n(x) + R_n(x),$$

donde

$$P_n(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$

es el polinomio de Taylor de orden n que aproxima a $f(x)$, y

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0)^{n+1}$$

es el resto o error de truncamiento cuando $P_n(x)$ aproxima a $f(x)$.

La formula de $R_n(x)$ sugiere que el valor del error de truncamiento se puede calcular, aunque esto no es posible en general, pues no se dispone del valor de ξ . Esto no es un problema serio, pues en un algoritmo es mas importante conocer el comportamiento del error de truncamiento que su valor exacto.

En la práctica, el término de la derivada en $R_n(x)$ se trata como una constante desconocida, y el interés se traslada a su coeficiente $(x - x_0)^{n+1}/(n+1)!$. Usualmente se define $h = x - x_0$ y además $h \ll 1$. Bajo esta circunstancia, $h^n/(n+1)! \rightarrow 0$

rápidamente en la medida que n crece. En la medida que las derivadas de f sean acotadas, $R_n \rightarrow 0$ en la medida que n crece.

Problema 3.4. Encuentre el error del truncamiento para la función e^x y utilícelo como criterio parada en el programa definido en el problema 3.3 para obtener e^{-10} . Utilice las mismas condiciones y responda las mismas preguntas.

3.2.4 Orden de aproximación y velocidad de convergencia

El siguiente criterio nos sirve de herramienta para establecer la velocidad y orden de aproximación de un proceso iterativo.

3.2.4.1. Orden de aproximación

Cuando se dispone de un proceso iterativo (x_n) para resolver un problema numérico se necesita saber que tan rápido converge.

1. **Definición de O grande para funciones:** se dice que la función $f(x)$ es O grande de la función $g(x)$, denotado como $f(x) = O(g(x))$, si existen constantes C y c tales que

$$|f(x)| \leq C|g(x)| \quad \text{para todo } x \neq c \text{ en una vecindad de } c,$$

o bien, que

$$\left| \frac{f(x)}{g(x)} \right| \leq C,$$

para todo $x \neq c$ en una vecindad de c . En tal caso, se dice también que $f(x)$ es de orden O grande con respecto a $g(x)$ cuando $x \rightarrow c$; simbólicamente, $f(x) = O(g(x))$ cuando $x \rightarrow c$.

Esta notación es útil para describir la tasa de crecimiento de una función en términos de funciones elementales y conocidas, como x^n , $x^{1/n}$, etc.

2. **Definición de O grande para sucesiones:** sean (x_n) y (y_n) dos sucesiones. Se dice que la sucesión (x_n) es de orden O grande de la sucesión (y_n) , denotado como $x_n = O(y_n)$, si existe una constante positiva C y un número natural N tal que

$$|x_n| \leq C|y_n| \quad \text{para todo } n \geq N.$$

Por ejemplo, como $\frac{n^2 - 1}{n^3} \leq \frac{n^2}{n^3} = \frac{1}{n}$, siempre y cuando $n \geq 1$, entonces $\frac{n^2 - 1}{n^3} = O\left(\frac{1}{n}\right)$.

3. Orden de aproximación $O(h^\alpha)$ para funciones

- a) Consideremos una aproximación numérica $F(x, h)$ a una cantidad exacta $f(x)$. El error en $F(x, h)$ depende del valor de x y un parámetro del algoritmo h . Este parámetro no está relacionado a valor verdadero, pero desconocido, de $f(x)$. Por definición, la diferencia entre $f(x)$ y $F(x, h)$ es el error $e(x, h)$:

$$f(x) = F(x, h) + e(x, h).$$

A menudo es conocida una cota (superior) $C(x)h^\alpha$ de este error.

- b) **Definición de orden de aproximación $O(h^\alpha)$:** asumamos que una función $f(x)$ es aproximada por la función $F(x, h)$ y que existe una constante real positiva $C(x)$ y un entero positivo α tal que

$$\left| \frac{f(x) - F(x, h)}{h^\alpha} \right| \leq C(x), \quad (3.2)$$

para h suficientemente pequeño. Entonces decimos que $F(x, h)$ aproxima a $f(x)$ con orden de aproximación $O(h^\alpha)$ y escribimos

$$f(x) = F(x, h) + O(h^\alpha).$$

Cuando la relación (3.2) la escribimos de la forma

$$|f(x) - F(x, h)| \leq C(x)h^\alpha, \quad (3.3)$$

vemos que la notación $O(h^\alpha)$ se encuentra en lugar de la cota del error $C(x)|h^\alpha|$.

- c) **Propiedades:** Asumamos que $f(h) = p(h) + O(h^m)$ y $g(h) = q(h) + O(h^n)$, y que $r = \min\{m, n\}$. Entonces

$$\begin{aligned} f(h) + g(x) &= p(h) + q(h) + O(h^r), \\ f(h)g(x) &= p(h)q(h) + O(h^r), \\ \frac{f(h)}{g(h)} &= \frac{p(h)}{q(h)} + O(h^r), \quad \text{si } g(h) \neq 0 \text{ y } q(h) \neq 0. \end{aligned}$$

4. **Orden de convergencia de una sucesión:** en aproximaciones numéricas a menudo se obtienen sucesiones de aproximaciones que son precisas y exactas. Al igual que con funciones es necesario establecer la rapidez con que estos resultados se obtienen.

a) **Definición de orden de convergencia** $O(r_n)$: sean (x_n) una sucesión que converge a x y (r_n) una sucesión que converge a 0. Decimos que la sucesión (x_n) converge a x con orden de convergencia $O(r_n)$ si existen una constante positiva C y un $N \in \mathbb{N}$ tal que

$$\frac{|x_n - x|}{|r_n|} \leq C \quad \text{para todo } n \geq N,$$

o bien, que

$$|x_n - x| \leq C|r_n| \quad \text{para todo } n \geq N.$$

Esto se indica de manera breve escribiendo $x_n = x + O(r_n)$ o diciendo que (x_n) converge a x con orden de convergencia $O(r_n)$.

5. Ejemplos

a) El desarrollo de Taylor de la función $f(x) = \cos x$ en $x_0 = 0$ es $\cos(x) = 1 - \frac{1}{2}x^2 + \frac{1}{24}x^4 \cos(\xi)$ donde $\xi \in (0, x)$.

Dado que de esto se sigue que

$$\left| \frac{\cos(x) + 1/2x^2 - 1}{x^4} \right| = \left| \frac{1}{24} \cos(\xi) \right| \leq \frac{1}{24},$$

se concluye que $\cos(x) + x^2/2 - 1 = O(x^4)$. Esto quiere decir que $\cos(x) + x^2/2$ converge a 1 con la misma rapidez que x^4 converge a cero.

b) El desarrollo de Taylor de $f(x) = e^x$ en $x_0 = 0$ hasta la segunda derivada es: $e^x = 1 + x + e^\xi \frac{x^2}{2}$, donde $\xi \in (0, x)$. Entonces,

$$\left| \frac{e^x - (1 + x)}{x^2} \right| = \frac{1}{2}e^\xi$$

y por lo tanto

$$\left| \frac{e^x - (1 + x)}{x^2} \right| \leq \sup_{0 < |x| < 1} \frac{1}{2} e^\xi = C.$$

Esto quiere decir que $e^x - (1 + x) = O(x^2)$ cuando $x \rightarrow 0$, lo cual significa que $e^x - (1 + x)$ igual que x^2 cuando x está en una vecindad de $x_0 = 0$.

Ahora bien, como

$$\left| \frac{e^x - (1 + x)}{x} \right| = \frac{1}{2} e^\xi |x| \leq C|x|,$$

se sigue que

$$\lim_{x \rightarrow 0} \frac{e^x - (1 + x)}{x} = 0,$$

por lo cual $e^x - (1 + x) = o(x)$.

3.2.4.2. Velocidad y orden de convergencia

Caso soluciones conocidas

1. **Velocidad de convergencia:** Supongamos que la sucesión converge a x . Si existe una constante $C \in (0, 1)$ tal que

$$\lim_{n \rightarrow \infty} \frac{|x_{n+1} - x|}{|x_n - x|} < C$$

entonces se dice que (x_n) converge linealmente a x con una tasa o velocidad de convergencia C . Si $C = 0$ se dice que (x_n) converge super linealmente a x .

2. **Orden de aproximación p :** Supongamos que la sucesión converge a x . Si existen un $p \geq 1$ y una constante tal que

$$\lim_{n \rightarrow \infty} \frac{|x_{n+1} - x|}{|x_n - x|^p} < C$$

entonces se dice que (x_n) converge a x con orden p . En particular, la convergencia a x con orden 2 se llama cuadrática y de orden 3 se llama cúbica.

Nota: En general, los métodos que generan sucesiones con alto orden de convergencia se aproximan más rápidamente a la solución que aquellos que generan sucesiones de bajo orden de convergencia.

También se puede definir el orden de convergencia de la sucesión (x_n) al número $p \geq 1$ tal que

$$|x_{n+1} - x| \leq C|x_n - x|^p \quad \text{para algún } C > 0, \quad 0 < C < 1 \text{ para } p = 1.$$

En el caso $p = 1$ podemos decir también que (x_n) converge linealmente a x si existe un $C \in (0, 1)$ tal que

$$|x_n - x| \leq C^n |x_0 - x|, \quad n \geq 0.$$

De esta desigualdad queda claro porque a la constante C se le llama velocidad de convergencia.

3. Crecimiento del error: si $e_0 = |x_0 - x|$ denota el error inicial y $e_n = |x_n - x|$ denota el error después de n iteraciones, decimos que el error crece linealmente si $e_n \approx C^n e_0$, y que crece exponencialmente si $e_n \approx C^n e_0$.

Nota: el error exponencial se debe evitar, y además por lo general el crecimiento del error lineal es inevitable.

Caso soluciones desconocidas

En este caso, el orden del error se puede utilizar como una herramienta de depuración de los procesos iterativos de solución de problemas numéricos.

1. **Justificación:** Supongamos que se tiene un procedimiento para calcular la aproximación $F(x, h)$ de $f(x)$ y que el error de truncamiento es de la forma (3.3). Para probar el procedimiento y su implementación, se aplica a un problema con solución conocida (i.e., $f(x)$ es conocida). Esto permite que el error sea calculado como

$$e(x, h) = f(x) - F(x, h).$$

Suponiendo que los cálculos de $F(x, h)$ son realizados con valores diferentes de h . El cociente entre esos errores, de la relación (3.3),

$$\frac{e(x, h_2)}{e(x, h_1)} = O\left(\frac{h_2}{h_1}\right)^\alpha,$$

de lo cual suponemos que “*podemos obtener*” que

$$\alpha = \frac{\log \left| \frac{e(x, h_2)}{e(x, h_1)} \right|}{\log \left| \frac{h_2}{h_1} \right|} = \frac{\log \frac{e(x, h_2)}{e(x, h_1)}}{\log \frac{h_2}{h_1}},$$

dado que $h_2 < h_1$ y $e(x, h_2) < e(x, h_1)$ son condiciones que se obtienen en este procedimiento. Evidentemente, el valor del orden de convergencia α depende de h_1 y h_2 .

2. **Implementación:** En simulaciones numéricas se considera a h que depende de n , usualmente,

$$h = \frac{1}{N_0} \quad \text{y} \quad h_n = \frac{h}{2^n} = \frac{1}{N_0 2^n}, \quad n = 0, 1, 2, \dots, N,$$

con N_0 y N números enteros positivos tales que $1 < N_0 < N$. Considerando a h_n como el recíproco de los múltiplos pares de N_0 , tenemos que

$$\alpha_n = \frac{\log \left(\frac{e(x, h_n)}{e(x, h_{n+1})} \right)}{\log \left(\frac{h_n}{h_{n+1}} \right)} = \frac{1}{2} \log \left(\frac{e(x, h_n)}{e(x, h_{n+1})} \right)$$

es una estimación del orden de convergencia del algoritmo numérico, la cual sólo depende de n .

Cuando la solución es desconocida, se consideran los errores entre estimaciones consecutivas $e_n = \|u_n - u_{n-1}\|$, siendo e_n una estimación aproximada de $e(x, h_n)$. Por lo tanto, para cada $n \in \mathbb{N}$ se busca el α_n tal que

$$\alpha_n = \frac{1}{2} \log \left(\frac{e_n}{e_{n+1}} \right), \quad (3.4)$$

donde α_n es una estimación del orden de convergencia α del procedimiento. Se tiene en este caso que la sucesión (α_n) converge a α (Ver Tarea 1.).

3.2.5 Criterios de parada

3.2.5.1. Caso error conocido

1. Cuando se conoce el valor x en un cálculo y se obtiene de él un valor aproximado x_n mediante un método iterativo, el error e_c en esta estimación es conocido y se define como la diferencia entre estos dos valores:

$$e_n^c = x - x_n.$$

2. Bajo estas mismas consideraciones, el error relativo r_n^c en esta estimación también es conocido y se define como el cociente entre el error conocido y el valor verdadero:

$$r_n^c = \frac{e_n^c}{x} = \frac{x - x_n}{x} \quad \text{si } x \neq 0.$$

3. Criterio de parada:

- a) Por número de iteraciones.
- b) Por tolerancia: dado que los resultados de mediciones en problemas físicos son usualmente reportados con un cierto número t de cifras significativas de exactitud (tolerancia es 0.5×10^{-t}), los resultados de cálculos aritméticos en algoritmos deben ser reportados con el este mismo número de cifras significativas de exactitud.

- Si se requieren que x_n aproxime a x con k dígitos decimales exactos, entonces el proceso de aproximación se para cuando $|e_n^c| < 0.5 \times 10^{-k}$; i.e., cuando

$$k < -\frac{\ln(2|e_n^c|)}{\ln(10)}.$$

- Si se requieren al menos k cifras significativas en la respuesta final, entonces el proceso de aproximación se para cuando $|r_n^c| < 0.5 \times 10^{-k}$; i.e., cuando

$$k < -\frac{\ln(2|r_n^c|)}{\ln(10)}.$$

-
- c) Por el mismo algoritmo iterativo: por ejemplo, el método de la bisección requiere que se involucre como criterio que después que la función del problema de encontrar los ceros de una función no sea más grande que cierta tolerancia, el criterio se detenga. En tal caso, el criterio de parada no depende del proceso iterativo sino de la función asociada al problema a ser resuelto numéricamente.

3.2.5.2. Caso error desconocido

1. Cuando se desconoce o es difícil de obtener el valor x en un cálculo y se obtienen de él sucesivos valores o estimaciones aproximados x_n (aproximación anterior) y x_{n+1} (aproximación actual), n un entero positivo, mediante un método numérico, el error e_n^d en esta estimación es desconocido y se define como la diferencia entre la aproximación actual y la presente:

$$e_n^d = x_{n+1} - x_n.$$

2. Bajo estas mismas consideraciones, el error relativo r_n^d en esta estimación también es desconocido y se define como el cociente entre el error desconocido y la aproximación actual:

$$r_n^d = \frac{e_n^d}{x_{n+1}} = \frac{x_{n+1} - x_n}{x_{n+1}} \quad \text{si } x_{n+1} \neq 0.$$

3. Criterio de parada:

- Por número de iteraciones.
- Si se requiere que x_n aproxime a x con k decimales correctos, el proceso de aproximación se para cuando $|e_n^d| < 0.5 \times 10^{-k}$; i.e., cuando

$$k < -\frac{\ln(2|e_n^d|)}{\ln(10)}.$$

- Si se requieren al menos m dígitos significativos en la respuesta final, entonces el proceso aproximación se para cuando $|r_d| \leq 0.5 \times 10^{-m}$; i.e.,

$$m < -\frac{\ln(2|r_d|)}{\ln(10)}.$$

4. Por el mismo algoritmo iterativo.

3.2.6 Prueba de la efectividad del algoritmo numérico

Existen diferentes maneras de definir la efectividad de un algoritmo de un problema numérico. En nuestro caso, decimos que tal algoritmo es efectivo si no existen mayores discrepancias entre los resultados que da cuando se asume que la solución del problema numérico es conocida o desconocida; es decir, que no existen mayores diferencias entre la exactitud y la precisión de los resultados del método iterativo definido en el algoritmo. Un reporte de los resultados para realizar este análisis se puede hacer de la manera que lo ilustra la siguiente tabla.

		Solución x conocida				Solución x desconocida			
n	h	x_n^c	e_n^c	r_n^c	α_n^c	x_n^d	e_n^d	r_n^d	α_n^d
0	h_0	x_0^c	e_0^c	r_0^c	α_0^c	x_0^d			
1	h_1	x_1^c	e_1^c	r_1^c	α_1^c	x_1^d	e_1^d	r_1^d	
2	h_2	x_2^c	e_2^c	r_2^c	α_2^c	x_2^d	e_2^d	r_2^d	α_2^d
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
		Exactitud			OC	Precisión			OC
OC: orden de convergencia									

Tabla 3.1: Reporte de resultados para el análisis de la efectividad de un algoritmo.

3.2.7 Ejemplo de análisis de un esquema iterativo

Se busca encontrar la raíz cuadrada de un número real positivo a , es decir, dado un número real $a > 0$ se busca un número real $x > 0$ tal que $\sqrt{a} = x$. Dado que en general este problema no tiene solución exacta x , se busca una solución aproximada de él. Definiendo $f(x) = x^2 - a$ el problema anterior se convierte en el problema de encontrar un x tal que $f(x) = 0$. Si $x_0 > 0$ es una aproximación inicial a la solución $\sqrt{a}$, se obtienen aproximaciones de este número mediante el proceso iterativo

$$x_n = \frac{1}{2} \left(x_{n-1} + \frac{a}{x_{n-1}} \right), \quad n = 1, 2, \dots \quad (3.5)$$

el cual define una sucesión de números reales (x_n) la cual se espera que converja a a con una cierta velocidad de convergencia. Para ello se realiza el siguiente análisis.

1. *Convergencia*

Se tiene que

$$x_n - \sqrt{a} = \frac{1}{2} \left(x_{n-1} + \frac{a}{x_{n-1}} \right) - \sqrt{a} = \frac{x_{n-1}^2 - 2\sqrt{a}x_{n-1} + a}{2x_{n-1}} = \frac{1}{2x_{n-1}} (x_{n-1} - \sqrt{a})^2. \quad (3.6)$$

Dado que $x_{n-1} > 0$, $(x_{n-1} - a)^2 \geq 0$ y $0 < x_0 < \infty$ se sigue por inducción mediante este resultado que $x_n \geq \sqrt{a}$ para $n = 1, 2, \dots$

Además, de esto último y de la definición de x_n se sigue que

$$x_{n-1} - x_n = x_{n-1} - \frac{1}{2} \left(x_{n-1} + \frac{a}{x_{n-1}} \right) = \frac{1}{2x_{n-1}} (x_{n-1}^2 - a) \geq 0,$$

es decir que $x_{n-1} \geq x_n$ para $n = 1, 2, \dots$. Se concluye entonces que la sucesión (x_n) es decreciente y acotada inferiormente por $\sqrt{a}$, por lo cual esta sucesión es convergente. Es decir, existe un $\alpha > 0$ tal que $\lim x_n = \alpha$. De la unicidad del límite se tiene que $\lim x_n = \lim x_{n-1} = \alpha$, por lo cual al tomar el límite en (3.5) se tiene que

$$\alpha = \frac{1}{2} \left(\alpha + \frac{a}{\alpha} \right),$$

de lo cual se sigue que $\alpha = a$. Esto demuestra que la sucesión (x_n) converge a a .

2. *Velocidad y orden de convergencia*

Se considera nuevamente la sucesión (x_n) de término n -ésimo dado por el proceso iterativo dado en (3.5). Se define el error absoluto en la n -ésima iteración en la aproximación de $\sqrt{a}$ mediante x_n como e_n . Por (3.6),

$$e_n = \frac{1}{2x_{n-1}} e_{n-1}^2, \quad n = 1, 2, \dots$$

Dado que $x_n \geq \sqrt{a}$ para $n = 1, 2, \dots$ entonces

$$e_n \leq \frac{1}{2\sqrt{a}} e_{n-1}^2, \quad n = 1, 2, \dots \quad (3.7)$$

Se sigue entonces que

$$\lim_{n \rightarrow \infty} \frac{|e_n|}{|e_{n-1}^2|} \leq \frac{1}{2\sqrt{a}}.$$

Por tal razón el orden de convergencia del proceso iterativo considerado a $\sqrt{a}$ es cuadrático, es decir, el orden de convergencia de los errores absolutos a cero es cuadrático.

En cuanto al error relativo,

$$r_n = \frac{x_n - \sqrt{a}}{\sqrt{a}} = \frac{e_n}{\sqrt{a}}, \quad n = 1, 2, \dots$$

Por (3.7) se sigue que

$$r_n \leq \frac{1}{2} r_{n-1}^2, \quad n = 1, 2, \dots \quad (3.8)$$

Por ejemplo, si $r_0 = 0.1$ entonces $r_1 \leq 0.5 \cdot 10^{-2}$, $r_2 \leq 0.125 \cdot 10^{-4}$, $r_3 \leq 0.8 \cdot 10^{-10}$ y así sucesivamente. Esto demuestra que en cada iteración se duplica por menos el número de cifras significativas.

3. *Prueba de efectividad*

El anterior algoritmo se utilizó para estimar $\sqrt{5}$ con dato inicial $x_0 = 2$ (dado que $4 < 5 < 9$ implica que $2 < \sqrt{5} < 3$). En la siguiente tabla se presentan cuatro pasos en la estimación de $\sqrt{5}$, los cálculos se realizaron con una tolerancia de 15 dígitos decimales exactos, en doble precisión y con reporte en los resultados de 5 dígitos decimales exactos. Como $\sqrt{5}$ se asume como un número real desconocido, en esta tabla se considera que $e_n = x_n - x_{n-1}$, $r_n = e_n/x_n$. Como el proceso iterativo define una sucesión de aproximaciones, se aplican la definición de orden de convergencia de sucesiones (??), con lo cual se tiene que

$$|e_n| = O(|e_{n-1}|^\alpha), \quad n = 1, 2, \dots,$$

por lo cual se puede asumir que

$$\alpha_n \approx \frac{\log |e_n|}{\log |e_{n-1}|}, \quad n = 1, 2, \dots$$

De (3.8), y dado que $2 < \sqrt{5}$, también se puede estimar este orden de convergencia como

$$\begin{aligned} |e_n| \leq \frac{1}{4} |e_{n-1}|^{\hat{\alpha}_n} &\implies 4 |e_n| \leq |e_{n-1}|^{\hat{\alpha}_n} \\ &\implies \frac{\log(4 |e_n|)}{\log |e_{n-1}|} \leq \hat{\alpha}_n. \end{aligned}$$

El factor 4 que aparece en $|e_n|$ debe afectar estos resultados, por lo cual se incluye en comparativo de ellos, el cual se muestra en la última columna de la siguiente tabla, la cual muestra el error relativo de estos resultados en porcentaje, r_n^α (%). A partir de la quinta iteración surgen problemas de desbordamiento a cero positivo en el cálculo del orden de convergencia. Se incluyen los resultados en la siguiente tabla, los errores e_n y r_n son errores en valor absoluto.

n	x_n	e_n	r_n	α_n	$\hat{\alpha}_n$	r_n^α (%)
0	2.000000000000000					
1	2.250000000000000	0.250000000000000	0.111111111111111			
2	2.236111111111111	0.013888888888889	0.006211180124224	3.084962500721159	2.084962500721159	32.41530487862450
3	2.236067977915804	0.000043133195307	0.000019289751355	2.350246052610880	2.026093003824636	13.79230265810470
4	2.236067977499790	0.000000000416014	0.000000000186047	2.149023450459318	2.011100423878275	6.41793957862868

Se puede establecer de estos resultados que el orden de convergencia del método es de segundo orden, y dado que el error relativo $r_4 = 0.186047 \cdot 10^{-9} < 5 \cdot 10^{-15}$, se puede considerar que $x_5 = 2.236067977499790$ aproxima a $\sqrt{5}$ con 15 cifras significativas, por ello, se puede considerar $\sqrt{5} \approx 2.23606797749979$. Igualmente, se puede notar que las dos últimas aproximaciones, x_3 y x_4 coinciden en exactamente en 10 cifras significativas. En estas cinco iteraciones se logra la precisión propuesta debido a que $r_4 = 0.186047 \cdot 10^{-9} < 5 \cdot 10^{-15}$. Esta condición fue incluida en el algoritmo y así estuviera programado para realizar $N = 10$ iteraciones, el proceso se detuvo en el n para el cual $|r_n| < 5 \cdot 10^{-15}$, en este caso $n = 4$.

n	x_n	e_n	r_n	α_n	$\hat{\alpha}_n$	r_n^α (%)
0	3.000000000000000					
1	2.333333333333333	0.666666666666667	0.285714285714286			
2	2.238095238095238	0.095238095238095	0.042553191489362	5.799204938088552	2.380182355385644	143.64540493994900
3	2.236068895643363	0.002026342451875	0.000906207521523	2.637402447771954	2.047834977885326	28.78979391666810
4	2.236067977499978	0.000000918143385	0.000000410606205	2.241532052965635	2.017991094935249	11.0774006184 3850
5	2.236067977499790	0.000000000000188	0.000000000000084	2.107830924617276	2.008104062476433	4.96621982915841

De estos resultados se puede establecer nuevamente que el orden de convergencia del método es de segundo orden, y dado que el error relativo $r_5 = 0.84 \cdot 10^{-13}$, se puede considerar que $x_5 = 2.236067977499790$ aproxima a $\sqrt{5}$ con 13 cifras significativas, por ello, se puede considerar $\sqrt{5} \approx 2.236067977499790$. Igualmente, se puede notar que las dos últimas aproximaciones, x_4 y x_5 coinciden en exactamente en 13 cifras significativas. En estas cinco iteraciones se logra la precisión propuesta debido a que $r_5 = 0.84 \cdot 10^{-13} < 5 \cdot 10^{-15}$. Esta condición fue incluida en el algoritmo y así estuviera programado para realizar $N = 10$ iteraciones, el proceso se detuvo en el n para el cual $|r_n| < 5 \cdot 10^{-15}$, en este caso $n = 5$.

Observaciones:

1. Las dos anteriores variaciones del esquema iterativo propuesto dan la misma aproximación de $\sqrt{5}$, 2.23606797749979.
2. En este caso no se dispuso de un conocimiento previo de la raíz cuadrada de 5. No obstante, bajo la misma precisión, la librería `cmath` de C++ reporta exactamente el mismo valor 2.236067977499790.
3. Se puede observar en este caso que el proceso iterativo con $x_0 = 2$ da los resultados de manera más rápida.
4. En ambas variaciones del esquema iterativo propuesto, el orden de convergencia teórica y numérico coinciden. No obstante, la aproximación que se obtiene mediante el segundo esquema da un error de aproximadamente el 5.0 %, en el primero es de aproximadamente el 6.4 %

3.2.8 Ejercicios

1. Si aproxima a π mediante los números reales 3.1416 y 3.1415927, encuentre el error relativo para el caso que se conoce y se desconoce el valor real, y en cada caso encuentre el número de dígitos significativos en cada aproximación.

-
2. La función exponencial e^x puede ser estimada por la serie

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots$$

Estime $e^{0.5}$ mediante la suma finita

$$s_n = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots + \frac{x^n}{n!}, \quad n = 0, 1, \dots$$

hasta que la estimación tenga tres cifras significativas.

3. Sea $f(x) = 7e^{0.5x}$, $x = 2$, $h = 1.3, 1.35$. Realice un estudio de la velocidad y orden de convergencia del método de la aproximación de $f'(2)$ mediante los cociente de diferencias de Newton

$$\frac{f(2+h) - f(2)}{h}.$$

4. Para este mismo problema realice el estudio numérico de la exactitud y la presión.
5. Defina un criterio de parada apropiado.
6. ¿Podría estimar en cada paso el número de dígitos significantes que obtiene en cada paso del proceso?
- Nota:** el problema se debe resolver con **C++** o **(wx)Maxima**, considerando la debida precisión y produciendo una tabla de resultados.
7. Demostrar que la sucesión (α_n) de términos dados en (3.4) es convergente a α .
8. (Método de Arquímedes) Por argumentos geométricos se encuentra que la longitud a del n -ésimo lado del polígono regular inscrito en el círculo de diámetro d es

$$a = d \sin \frac{\alpha}{2},$$

siendo θ el ángulo que subviene la cuerda de longitud a . En tal caso, $\theta = 2\pi/n$. Como el perímetro p del polígono es na , entonces

$$p = nd \sin \frac{2\pi}{n}.$$

Si el perímetro es tomado como una aproximación de la circunferencia del círculo, entonces el error $e(d, n)$ en la estimación es

$$e(d, n) = d \left(n \sin \frac{2\pi}{n} - \pi \right)$$

Note que $e \rightarrow 0$, dado que como $\pi/n \rightarrow 0$, $\sin(\pi/n) \rightarrow \pi/n$. La meta es estimar que tan *rápido* $e \rightarrow 0$. Por conveniencia se hace $h = 1/n$. Entonces, en la notación de la sección anterior, $e(d, h) \rightarrow O(h^\alpha)$, donde α es desconocido. El procedimiento siguiente permite calcular estimaciones de este α . Para $h = 1/n$ y $n = 2^{i+2}$, para $i = 0, 1, 2, 3, 4$; $N_0 = 4$ y N apropiado, escriba un programa en C++ que permita establecer el comportamiento de las soluciones y del error correspondiente cuando se conoce y se desconoce su solución, y con un criterio de parada. No olvide incluir el algoritmo en pseudocódigo.

9. Una empresa de salto de bungee busca predecir la velocidad de un saltador en función del tiempo durante la parte de caída libre del salto. Esta información se utilizará como parte de un análisis más amplio para determinar la longitud y la resistencia requerida de la cuerda elástica para saltadores de diferente masa.

De acuerdo con la segunda ley de Newton, la aceleración es igual a la razón de la fuerza con respecto a la masa (segunda ley de Newton). Basado en este conocimiento y su conocimiento de mecánica de fluidos, se desarrollo el siguiente modelo para la razón de cambio de la velocidad con respecto al tiempo:

$$\frac{dv}{dt} = g - \frac{c_d}{m} v^2$$

donde v es la velocidad vertical (m/s), t es tiempo (s), g es la aceleración debida a la gravedad (aprox. 9.81 m/s^2), c_d es coeficiente de resistencia al movimiento del saltador (kg/m), m es la masa del saltador (kg).

Debido a que el saltador parte del reposo, la solución de este problema es

$$v(t) = \sqrt{\frac{gm}{c_d}} \tanh \left(\sqrt{\frac{gc_d}{m}} t \right) \quad t > 0. \quad (3.9)$$

De esta representación se deduce que la velocidad del saltador crece el tiempo y alcanza una velocidad terminal, la cual se denota como v_{ter} m/sg.

Se considera que

$$\frac{dv(t_i)}{dt} \approx \frac{\Delta v}{\Delta t} = \frac{v(t_{i+1}) - v(t_i)}{t_{i+1} - t_i},$$

donde Δv y Δt son las diferencias en velocidad y tiempo calculadas en un intervalo, $v(t_i)$ es la velocidad en el tiempo inicial t_i y $v(t_{i+1})$ es la velocidad en algún tiempo t_{i+1} . Se puede considerar que $dv(t_i)/dt \approx \Delta v/\Delta t$ puesto que Δt es finito. Considerando que $v(t_i) \approx v_i$, se obtiene que

$$\frac{v_{i+1} - v_i}{t_{i+1} - t_i} = g - c_d v_i^2,$$

lo cual da que

$$v_{i+1} = v_i + \left[g - \frac{c_d}{m} v_i^2 \right] (t_{i+1} - t_i). \quad (3.10)$$

- a) Considere que la masa del saltador es de 68.1 kg. Utilice (3.9) y (3.10) para determinar la velocidad durante los primeros 12 segundos de salto libre, en longitudes del paso del tiempo de $\Delta t = t_{i+1} - t_i = 1$ segundo. Use un coeficiente de resistencia al movimiento de 0.125 kg/m.
- b) Determine la velocidad terminal que debe logra para una gran cuerdo de longitud infinita.
- c) Realice un análisis de efectividad de este método numérico mediante $n = 5$ iteraciones completas. Realice para cada iteración completa, una gráfica que muestre la velocidad real y la estimada (5 gráficas); incluya en cada gráfica de la velocidad terminal.
- d) Se puede estimar el orden de convergencia de este método; de cuánto es; en caso que no sea posible, qué cree que esté sucediendo.

Referencias

- [1] Kendall E. Atkinson. *An introduction to numerical analysis*. John Wiley & Sons, 2008.
- [2] Kendall Atkinson E. and Weimin Han. *Theoretical numerical analysis*, volume 39. Springer, 2005.
- [3] Richard L. Burden and Douglas J. Faires. *Análisis Numérico*. Thomson Learning, Mexico, 7a edition, 2002.
- [4] Federico Fagúndez. *Análisis numérico y programación*. Notas de clase, 2013.
- [5] Walter Gautschi. *Numerical analysis*. Springer Science & Business Media, 1997.
- [6] Curtis F. Gerald. *Applied numerical analysis*. Pearson Education India, 2004.
- [7] A. Han and K. E. Atkinson. *Elementary numerical analysis*. John Wiley, New York, 2004.
- [8] Gerald W Recktenwald. *Numerical methods with MATLAB: Implementation and application*. Prentice Hall New Jersey, 2000.
- [9] James Hardy Wilkinson. *Rounding errors in algebraic processes*. Courier Corporation, 1994. 2.1.3