

Rudimentos matemáticos
para el dominio de la

Ingeniería de los
Algoritmos Numéricos

José Luis de la Fuente O'Connor

Rudimentos matemáticos para el dominio de la ingeniería de los algoritmos numéricos

Primera edición: abril 2017

Depósito legal: AL 856-2017

ISBN: 978-84-9160-826-4

Impresión y encuadernación: Editorial Círculo Rojo

© Del texto: JLFO

© Maquetación y diseño: Equipo de Editorial Círculo Rojo

© Fotografía de cubierta: Fotolia

Editorial Círculo Rojo

www.editorialcirculorojo.com

info@editorialcirculorojo.com

Impreso en España - Printed in Spain

Ninguna parte de esta obra puede ser reproducida por algún medio, sin el permiso expreso de sus autores. Círculo Rojo no se hace responsable del contenido de la obra y/o las opiniones que el autor manifieste en ella.

Dirijase a CEDRO (Centro Español de Derechos Reprográficos) si necesita fotocopiar o escanear algún fragmento de esta obra (www.conlicencia.com; 91 702 19 70 / 93 272 04 47).

El papel utilizado para imprimir este libro es 100% libre de cloro y, por tanto, **ecológico**.

A mi familia.

Índice

Prefacio	IX
1 Conjuntos	1
2 Espacios vectoriales	5
2.1 Espacios vectoriales con estructuras adicionales	9
2.1.1 Espacios normados y espacios métricos	9
2.1.2 Espacios con producto interior	21
2.1.3 Espacios de Hilbert	21
2.1.4 Espacios de Lebesgue y espacios de Sobolev	25
3 Matrices	29
3.1 Normas de matrices	32
3.2 Matrices interesantes	35
3.3 Valores propios, valores singulares y formas cuadráticas	39
3.3.1 Valores propios	39
3.3.2 Valores singulares	45
3.4 Formas cuadráticas	48
4 Funciones, sucesiones y series de funciones	51
4.1 Derivada y diferenciabilidad	53
4.1.1 Subgradiente y subdiferencial	56
4.2 Integral	58
4.3 Sucesiones de funciones, series funcionales y de potencias. Convergencia	58
4.3.1 Convergencia puntual	58
4.3.2 Convergencia uniforme	59
4.3.3 Series funcionales	61
4.3.4 Series de potencias	61
4.4 Resultados importantes de análisis funcional	62
5 Optimización y Programación Matemática	69
5.1 Condiciones necesarias y suficientes de existencia de un punto mínimo de una función	69
5.2 Conjuntos convexos y geometría de la convexidad	70
5.2.1 Conos apropiados y desigualdades generalizadas	80
5.2.2 Elementos mínimos y minimales. Cono dual	80
5.2.3 Hiperplano separador. Lema de Farkas	84
5.3 Caracterización de las soluciones del problema de optimización y condiciones que cumple un punto óptimo	90

5.4	Dualidad en optimización	94
5.4.1	Dualidad Lagrangiana	99
5.4.2	Dualidad de Wolfe	102
5.5	Funciones conjugadas-funciones de Fenchel	103
5.6	Optimización SDP	106
5.6.1	Definiciones y planteamiento del problema	107
5.7	Optimización vectorial y multicriterio o multiobjetivo	111
5.7.1	Óptimo y óptimos de Pareto	112
5.7.2	Escalarización	114
5.7.3	Optimización multicriterio	115
6	Elementos de cálculo integral, campos escalares y campos vectoriales	119
6.1	Integrales de línea	122
6.1.1	Integrales de línea en campos vectoriales	124
6.2	El teorema de Green	126
6.3	El teorema de Stokes	129
7	Sobre el método de los elementos finitos de Ritz-Galerkin para resolver ecuaciones en derivadas parciales	131
7.1	Solución de una ecuación en derivadas parciales	134
7.1.1	El problema en forma débil o variacional	136
7.1.2	Espacios de trabajo	137
7.1.3	Discretización del problema en un subespacio de elementos finitos lineales	139
7.1.4	Reformulación del problema como un sistema de ecuaciones lineales	143
7.2	Fundamentos de funcionales y cálculo de variaciones	145
7.2.1	Proposiciones esenciales	149
8	Análisis de componentes principales	153
8.1	Algunos conceptos de estadística	154
8.2	Planteamiento del problema matemático	156
9	Números complejos, funciones e integración	161
9.1	Integración. Teorema de Cauchy	165
10	Análisis de Fourier	167
10.1	Series de Fourier	168
10.1.1	Expresión compleja de la serie de Fourier	171
10.1.2	Convergencia de las series de Fourier	173
10.1.3	Propiedades de las series de Fourier	175
10.2	La Transformada de Fourier	179
10.2.1	Propiedades de la transformada de Fourier	181
10.2.2	La Transformada de Fourier discreta	183
11	La Transformada del coseno discreta	189
12	La Transformada de Laplace	195
13	Cálculo estocástico y simulación	199
13.1	Variables aleatorias y espacios de probabilidad	199

13.2	Procesos estocásticos	206
13.2.1	Ejemplos	207
13.3	Simulación	213
13.3.1	Generación de números aleatorios	213
13.3.2	Simulación de variables aleatorias	214
13.3.3	El método Montecarlo	217
13.4	Ecuaciones diferenciales estocásticas	218
13.4.1	Integración numérica de ecuaciones diferenciales es- tocásticas	220
13.5	Aplicación del cálculo estocástico a la cobertura y valoración de derivados financieros. El modelo de Black y Scholes	221
Bibliografía		225
Índice de materias y autores		249

Prefacio

ESTE libro tiene que ver con el análisis numérico, la computación científica e ingenieril y los elementos de matemáticas que yo entiendo son fundamentales para entender una parte de sus porqués. Los componentes que se presentan se explican de forma sucinta y directa con el objeto de poder poner en marcha, o analizar, herramientas y métodos numéricos para modelizar y resolver problemas reales que surgen en las ciencias y la ingeniería.

El contenido del libro complementa el programa de la asignatura *Matemáticas de la Especialidad-Ingeniería Eléctrica*, que desde hace varios años dicto en la Escuela Técnica Superior de Ingenieros Industriales, de la Universidad Politécnica de Madrid, en España.

Todo el material —bastante estándar— que se expone en las páginas de este libro es una síntesis muy densa de lo que este autor entiende puede ser una buena base para consolidar (y consultar) unos fundamentos matemáticos sólidos de mucho de lo que se basan las técnicas y algoritmos numéricos que permiten, mediante el Cálculo y Análisis Matemático, y la Ingeniería de sus Métodos Numéricos, modelizar y simular la realidad con la que ingenieros y científicos se enfrentan a diario para poner sus conocimientos al servicio de resolver los diversos problemas prácticos que acucian a la sociedad. La experiencia del autor se refiere a este respecto a algo tan amplio como *la ingeniería de los sistemas económico-eléctricos*, aunque es extensible a otros muchos campos del conocimiento y la ciencia aplicada. Esos puntos de vista deben ser ampliados en muchas direcciones si se quieren construir otros edificios de conocimiento matemático aplicado a otras áreas del saber práctico.

Los aspectos más generales cubiertos en este libro son el análisis matemático y funcional básico, el álgebra matricial, la optimización matemática de problemas lineales y no lineales, la convexidad y dualidad de estos, elementos de cálculo integral básico, campos escalares y vectoriales, los números complejos y el cálculo estocástico y la simulación numérica. Con el fin de hacer mucho más intuitiva la comprensión de cómo funcionan las matemáticas y los algoritmos detrás de muchos de los procedimientos y métodos que hoy en día están presentes en los desarrollos del *Big Data*, la simulación y la optimización matemática, y otras cada día más extensas cuestiones de la *economía digital* con la que convivimos asiduamente, también se presentan el método de los elementos finitos para resolver ecuaciones en derivadas parciales, el análisis de componentes principales, el análisis y la transformada de Fourier, la transformada del coseno para compresión de imágenes y vídeo y la transformada de Laplace.

Al final del libro se listan quinientas ochenta y una referencias de las que he sacado casi todo el conocimiento que utilizo sobre la temática objeto del libro. Deberían ser muchas más pues hay muchos pequeños detalles que expongo que apenas consulté unos

minutos en algún libro, artículo o en Internet para retener la idea, el resultado, o el efecto de un figura para resaltarlo. No me quedé con el nombre del autor, el departamento o departamentos universitarios que lo utilizan, o la editorial que lo publicó. Si omito por error la reseña o el trabajo correspondiente, ruego su clemencia a esos mis inspiradores.

El resultado que es materialmente este libro no habría sido posible sin el concurso, inconsciente o perfectamente consciente, de muchas personas individuales y colectivas. Me gustaría mencionar aquí las contribuciones concretas de autores —a los que he seguido fundamentalmente— como Stephen Boyd, colega de la Universidad de Stanford, David Nualart, Ignacio Villanueva, Timothy Sauer, David Luenberger, Francisco Javier Sayas, David Aledo y Manuel Contreras. También a mis compañeros del Departamento de Ingeniería Matemática de la Universidad Politécnica de Madrid. Sobre su esfuerzo me han permitido aupar mis humildes conocimientos a hombros de los de ellos. Me gustaría también agradecer sus materiales e inmateriales aportaciones a todos mis alumnos de la Escuela Técnica Superior de Ingenieros Industriales de Madrid, de los que he aprendido muchísimas cosas en mi tarea como profesor en la cotidianidad de las clases en las que trato de transmitirles lo que creo es bueno para su formación, además del conocimiento práctico sobre el que baso mis aportaciones.

La elaboración del libro ha sido posible gracias al editor WinEdt y al *software* para preparación de documentos científicos y técnicos denominado L^AT_EX. Este sistema y la multitud de programas y aplicaciones que lo soportan y potencian es una maravilla de la expresión técnica digital moderna de la tipografía de siempre. También quiero mencionar, y agradecer, lo útil que me ha sido WIKIPEDIA como fuente de inspiración, material, verificación y conocimiento.

José Luis de la Fuente O'Connor

Alcobendas, Madrid, España, 10 de mayo de 2017

www.jldelafuenteoconnor.es

1 | Conjuntos


L OS algoritmos —como agrupación ordenada y finita de operaciones y reglas que permiten *hallar la solución de un problema*, o realizar una actividad relativamente compleja— y las matemáticas modernas, tienen mucho que ver con colecciones abstractas de objetos como lo es un conjunto.

Definición 1.1 Un **conjunto** es una construcción matemática que se refiere a una colección de objetos considerada en sí misma un objeto: los números naturales, las soluciones de un problema determinado, los municipios de una provincia, etc.

Un conjunto se identifica por una letra mayúscula: el conjunto S , el conjunto de los números naturales $\mathbb{N}$, el de los enteros $\mathbb{Z}$, el de los reales $\mathbb{R}$, complejos $\mathbb{C}$, racionales $\mathbb{Q}$, etc.

“Conjuntos” es un concepto primitivo, en el sentido de que no es posible definirlos en términos de nociones más elementales, por lo que su estudio puede realizarse de manera informal, apelando a la intuición y a la lógica. Son el concepto fundamental de las matemáticas modernas: mediante ellos puede formularse el resto de objetos matemáticos, como los números y las funciones, entre otros. Su estudio detallado requiere pues la introducción de axiomas y conduce a la *teoría de conjuntos*.

El proponente o inventor de la *teoría de conjuntos* fue Georg Ferdinand Ludwig Philipp Cantor —Rusia 1845, Alemania 1918—. Lo hizo en la segunda mitad del siglo XIX.



Cada uno de los objetos de la colección a la que se refiere un conjunto es un *elemento* o *miembro* del conjunto. Si un elemento a pertenece a un conjunto C se indica $a \in C$. Los conjuntos se definen mediante la enumeración entre llaves de sus elementos, $C = \{a, b, \dots\}$, o especificando, también entre llaves, la propiedad que los caracteriza. Por ejemplo, $C = \{x : x \in \mathbb{R}, x \leq 2\}$ designa los números reales menores o iguales que dos; el conjunto C de los números reales x que son mayores que 1 y menores que 0 se designa de esta manera: $C = \{x \in \mathbb{R} : x > 1, x < 0\}$.

El conjunto sin elementos se denomina *vacío*, designándose mediante el símbolo $\emptyset$.

Si S y S' son dos conjuntos y todos los elementos del conjunto S' lo son de S , se dice que S' es un *subconjunto* del conjunto S , o que está contenido en S' , expresándose

$S' \subset S$ o $S \supset S'$. El conjunto de los números, por ejemplo, se clasifica en diversos subconjuntos de acuerdo con lo que refiere la figura 1.1.




Figura 1.1: Clasificación de los números en diversos subconjuntos. Fuente: WIKIPEDIA mas pequeños ajustes del autor

La *unión* de dos conjuntos S y T , expresada $S \cup T$, es el conjunto formado por los elementos que pertenecen a S o a T . La *intersección* de S y T , expresada $S \cap T$, es el conjunto formado por los elementos que pertenecen a S y a T .

Si S' es un subconjunto de S , el *complemento del subconjunto* S' en S es el conjunto formado por los elementos de S que no pertenecen a S' .

Si a y b son números reales, es decir, $a \in \mathbb{R}$, $b \in \mathbb{R}$, y $a \leq b$, el conjunto de números x de la recta real tales que $a \leq x \leq b$ se indica $[a, b]$. El formado por los x tales que $a < x \leq b$, por $(a, b]$. El de los x que verifican que $a < x < b$, por (a, b) .

Si S es un conjunto no vacío de números reales acotados superiormente —mayorados—, existe un número real mínimo y tal que $x \leq y$ para todo $x \in S$. Al número y se le denomina *cota superior mínima* o *supremo* de S ; se expresa así:

$$\sup (x) \quad \text{o} \quad \sup \{x : x \in S\}.$$

$x \in S$

De forma similar se define la *cota inferior máxima* —o *ínfimo*— de un conjunto S no vacío de números reales acotados inferiormente o minorados:

$$\inf (x) \quad \text{o} \quad \inf \{x : x \in S\}.$$

$x \in S$

Dados dos conjuntos S y T , una *aplicación*, *transformación* o *mapeo* f de S en T , expresada como $f : S \rightarrow T$, es una asociación o criterio que a cada elemento de S hace corresponder uno de T .

Una *función* es un caso particular de aplicación en donde los conjuntos origen e imagen suelen ser —en este libro; no necesariamente en general— conjuntos de números: fundamentalmente $\mathbb{R}$, $\mathbb{C}$, $\mathbb{Z}$, $\mathbb{N}$, etc.

Como regla general, las funciones que tienen interés en ingeniería, y cualesquiera aplicaciones de las matemáticas, son funciones que tienen algún tipo de “buen comportamiento” que nos permite utilizarlas de forma habitual para modelizar y simular fenómenos de la vida cotidiana.

La *imagen* de un elemento $x \in S$ con la aplicación $f : S \rightarrow T$ es el elemento $f(x) \in T$. El *conjunto imagen* $f(S) = \{f(x) \in T, \text{ para todo } x \in S\}$. La imagen de un subconjunto $S' \subset S$ con la aplicación f sería, por consiguiente, el subconjunto imagen $f(S')$. El conjunto S se conoce como *origen* o *dominio de definición* de la aplicación, o función, y el T como *dominio de valores*.

Una aplicación $f : S \rightarrow T$ se dice *inyectiva* si para cualquier par de elementos $x, y \in S$, $x \neq y$, se cumple que $f(x) \neq f(y)$. Ejemplo, la aplicación $f : \mathbb{R} \rightarrow \mathbb{R}$, definida por $f(x) = x^2$, no es inyectiva, pues $f(1) = f(-1) = 1$.

Una aplicación $f : S \rightarrow T$ se dice *suprayectiva* —sobreyectiva, epiyectiva, suryectiva o exhaustiva— si el conjunto imagen $f(S)$ es igual a todo el conjunto T ; es decir, para todo $y \in T$ existe un $x \in S$ tal que $f(x) = y$.

Una aplicación se dice *biyectiva* si es inyectiva y suprayectiva. Ejemplo, si J_n es el conjunto de los números enteros de 1 a n , $J_n = \{1, \dots, n\}$, y se define una aplicación $\sigma : J_n \rightarrow J_n$ que modifica el orden de disposición de los elementos de J_n —estas aplicaciones se denominan *permutaciones*—, tal aplicación es biyectiva.

Un conjunto S se dice *numerable* si existe una biyección entre $\mathbb{N}$ y S : a cada uno de los n elementos k , $1 \leq k \leq n$, se le asocia un elemento $a_k \in S$, esto es: $k \mapsto a_k$.

Una *sucesión* de elementos de un conjunto T es una aplicación de $\mathbb{N}$ en T : a cada elemento $n \geq 1$ se le hace corresponder un $x^{(n)} \in T$: $n \mapsto x^{(n)}$. Tal sucesión se designa $x_1, x_2, \dots, x_n, \dots$, o $\{x^{(1)}, x^{(2)}, \dots\}$. También en algunos casos $\{x^{(n)}\}_{n \geq 1}$ e incluso $\{x_n\}_{n=1}^\infty$.

Si $\{x_i\}$ es una sucesión de números reales y existe un número real S tal que 1: para cada $\varepsilon > 0$ existe un N tal que para todo $n > N$ se tiene que $x_n < S + \varepsilon$ y 2: para cada $\varepsilon > 0$ y $M > 0$ existe un $n > M$ tal que $x_n > S - \varepsilon$, entonces S se denomina *límite superior* de la sucesión $\{x_n\}$, escribiéndose $S = \limsup_{n \rightarrow \infty} x_n$. Si $\{x_n\}$ no está acotada por arriba —mayorada— se escribe $\limsup x_n = +\infty$. El *límite inferior* de la sucesión $\{x_n\}$ es $\liminf x_n = -\limsup(-x_n)$. Si $\limsup x_n = \liminf x_n = S$, entonces $\lim x_n = S$.

Los conjuntos dotados de ciertas leyes de composición o asociación interna —adición, multiplicación, división o cualquier otra—, se dice que poseen una *estructura algebraica*. Algunas estructuras algebraicas fundamentales son el *grupo*, el *anillo* ($\mathbb{Z}$ por ejemplo), el *cuerpo* ($\mathbb{R}$ y $\mathbb{C}$, por ejemplo), el *espacio vectorial*, el *álgebra*, etc.

2 | Espacios vectoriales

Definición 2.1 Un **espacio vectorial** E es una estructura algebraica creada a partir de un conjunto no vacío, una ley de composición interna definida para los elementos del conjunto, *adición*, $+$, con las siguientes propiedades —grupo conmutativo—

$x + y = y + x$	conmutativa
$(x + y) + z = x + (y + z)$	asociativa
$x + \emptyset = x$	existencia de elemento neutro
$x + (-x) = \emptyset$,	

y una ley de composición externa, *producto por un escalar*, $\cdot$, definida entre dicho conjunto y otro conjunto con estructura de *cuerpo*, K , con las siguientes propiedades,

$1 \cdot x = x, \quad 0 \cdot x = \emptyset$	
$\alpha(\beta x) = (\alpha\beta)x$	asociativa
$(\alpha + \beta)x = \alpha x + \beta x$	distributiva
$\alpha(x + y) = \alpha x + \alpha y,$	distributiva
$\alpha \cdot \emptyset = \emptyset,$	

válidas cualesquiera que sean x, y, z en E y α, β en K .

A $\emptyset$ se le denomina *elemento neutro*, o *nulo*, y a $-x$ el opuesto de x . Es usual denominar *vectores* a los elementos de E y *escalares* a los de K .

Ejemplo 2.1 Quizás el espacio vectorial más simple y utilizado es el conjunto de los números reales. Es un espacio vectorial con la adición definida en los términos usuales y el producto o, multiplicación por escalares (reales), definido por la multiplicación ordinaria. El vector nulo es el número real cero. Las propiedades de adición ordinaria y multiplicación de números reales satisfacen las propiedades de la definición anterior. Este espacio vectorial se suele denominar el espacio unidimensional de números reales, o simplemente la *recta real*. Se designa por $\mathbb{R}$. Todo lo dicho se aplica igualmente al espacio vectorial de los números complejos, $\mathbb{C}$.

En las aplicaciones que se estudian habitualmente en este libro los casos más importantes ocurren cuando $K = \mathbb{R}$ o $K = \mathbb{C}$. Con la notación $\mathbf{K}$ designaremos a cualquiera de los cuerpos $\mathbb{R}$ o $\mathbb{C}$ y por $\mathbf{x}$ un vector cualquiera de un espacio vectorial. ●

Ejemplo 2.2 La extensión natural del anterior, y paradigma de espacio vectorial en este libro, lo constituye el formado por sucesiones ordenadas de n elementos cualesquiera de

K , o n -uplas $\mathbf{x} = [x_1, \dots, x_n]$, definiendo la suma de vectores mediante

$$[x_1, \dots, x_n] + [y_1, \dots, y_n] = [x_1 + y_1, \dots, x_n + y_n]$$

y el producto por un escalar mediante

$$\alpha[x_1, \dots, x_n] = [\alpha x_1, \dots, \alpha x_n].$$

Si los elementos están definidos en $\mathbb{R}$, el espacio vectorial se denomina $\mathbb{R}^n$, si lo están en $\mathbb{C}$, el espacio vectorial es $\mathbb{C}^n$.

En general, cuando en el libro nos refiramos a un espacio vectorial, salvo que se indique lo contrario, podemos sobreentender que nos estamos refiriendo a $\mathbb{R}^n$. ●

Ejemplo 2.3 Si se denota por $\mathbb{R}^{\mathbb{N}}$ el conjunto cuyos vectores son las sucesiones infinitas de números reales, es decir,

$$\mathbb{R}^{\mathbb{N}} = \{\mathbf{x} = \{x_n\}_{n=1}^{\infty} : x_n \in \mathbb{R} \text{ para todo } n \in \mathbb{N}\},$$

éste tiene estructura de espacio vectorial sobre el cuerpo $\mathbb{R}$. Análogamente, el conjunto $\mathbb{C}^{\mathbb{N}}$ de todas las sucesiones de números complejos tiene estructura de espacio vectorial. La adición y la multiplicación en estos espacios vectoriales se definen elemento a elemento como en el ejemplo 2.2. Se dice que una sucesión está acotada si existe una constante M tal que $\{x_n\}_{n=1}^{\infty} < M$ para todo n . La colección de todas las sucesiones infinitas acotadas también conforman un espacio vectorial ya que la suma de dos sucesiones acotadas o el múltiplo escalar de una sucesión acotada están acotadas. Este espacio se suele denominar *espacio de sucesiones de números reales acotadas*. ●

Ejemplo 2.4 El conjunto de sucesiones infinitas de números reales que convergen a cero es un espacio vectorial ya que la suma de dos sucesiones convergentes a cero o el múltiplo escalar de una sucesión que converge a cero también converge a cero. ●

Ejemplo 2.5 Si consideramos un intervalo $[a, b]$ en la recta real. El conjunto de todas las funciones continuas de valores reales en este intervalo forman un espacio vectorial. Escribamos $x = y$ si $x(t) = y(t)$ para todo $t \in [a, b]$ y sea el vector nulo la función idénticamente igual a cero en $[a, b]$. Si x y y son vectores de este espacio vectorial y α es un escalar (real), las funciones $(x + y)(t) = x(t) + y(t)$ y $(\alpha x)(t) = \alpha x(t)$ son obviamente continuas por lo que la estructura de espacio vectorial es clara. Este espacio se conoce como el *espacio vectorial de funciones continuas reales en $[a, b]$* . ●

Ejemplo 2.6 El conjunto $\mathbb{P}_n$ de polinomios de grado n ,

$$p_n(x) = \sum_{k=0}^n a_k x^k,$$

con coeficientes a_k reales —definidos en toda la recta real o en un intervalo $[a, b]$ —, o complejos, también conforman sendos espacios vectoriales. El vector nulo y la adición o suma, así como la multiplicación por un escalar, se definen de la misma manera que en el ejemplo anterior. La suma de dos polinomios y un múltiplo escalar de cualesquiera de ellos son obviamente polinomios. ●

Dejamos aquí de momento los ejemplos pues otros que enunciaremos y utilizaremos en el libro requieren la introducción de otras estructuras adicionales en los espacios vectoriales como son una norma y el producto interior. Seguiremos enunciando ejemplos al introducir estas estructuras.

Proposición 2.1 En cualquier espacio vectorial se cumple que:

1. $x + y = x + z$ implica que $y = z$.
2. $\alpha x = \alpha y$ con $\alpha \neq 0$ implica $x = y$.
3. $\alpha x = \beta x$ con $x \neq \emptyset$ implica $\alpha = \beta$.
4. $(\alpha - \beta)x = \alpha x - \beta x$.
5. $\alpha(x - y) = \alpha x - \alpha y$.
6. $\alpha \emptyset = \emptyset$.
7. $(-\alpha)x = \alpha(-x) = -(\alpha x)$.

Definición 2.2 Un **subespacio vectorial** M de un espacio vectorial E sobre un cuerpo K es un subconjunto no vacío que es un espacio vectorial sobre K . Es decir, es cerrado respecto de las operaciones de adición y producto por un escalar por lo que cumple que

$$\begin{aligned}\forall x, y \in M &\implies x + y \in M, \\ \forall x \in M \text{ y } \forall \lambda \in K &\implies \lambda x \in M.\end{aligned}$$

La intersección de una familia cualquiera de subespacios de E es un subespacio de E .

Un conjunto de vectores $x_1, x_2, \dots, x_k$ se dicen *linealmente dependientes* si existen escalares λ_i , no todos cero, tales que $\sum_{i=1}^k \lambda_i x_i = \mathbf{0}$; *linealmente independientes*, si

$$\sum_{i=1}^k \lambda_i x_i = \mathbf{0} \implies \lambda_i = 0, \quad 0 \leq i \leq k.$$

Definición 2.3 La **dimensión** de un subespacio es el máximo número de vectores linealmente independientes en el subespacio.

Definición 2.4 Si X es un subconjunto cualquiera de E el subespacio $\text{Gen}\{X\}$, **generado o engendrado** por X , es la intersección de todos los subespacios que contienen a X . Cuando $\text{Gen}\{X\} = E$, se dice que X es una *parte generadora* de E .

Definición 2.5 Dados vectores $x_1, \dots, x_n$ y escalares $\lambda_1, \dots, \lambda_n$, el vector formado según la expresión

$$x = \lambda_1 x_1 + \dots + \lambda_n x_n$$

se dice que es una **combinación lineal** de los vectores $x_1, \dots, x_n$ con coeficientes $\lambda_1, \dots, \lambda_n$.

Un subconjunto X de E es un subespacio si y sólo si contiene a cualquier combina-

ción lineal de cualquier subconjunto finito de vectores de X . También se demuestra que el subespacio $\text{Gen}\{X\}$ es el conjunto de todas las combinaciones lineales de vectores de X .

Definición 2.6 Una parte X de un espacio vectorial E se dice que es una **familia libre** si los vectores de cualquier subconjunto finito de X son linealmente independientes.

Definición 2.7 Una **base** de un espacio vectorial E es cualquier subconjunto B de E que sea, simultáneamente, una parte libre y generadora de E ; dicho de otra forma, una base de un espacio vectorial es un conjunto —normalmente se supone ordenado (numerado)— de vectores linealmente independientes que generan (o engendran) dicho espacio.

Se demuestra que cualquier espacio vectorial tiene una base y que todas las bases de un mismo espacio tienen la misma cardinalidad —se pueden poner en biyección—. Cuando el cardinal de las bases es un número natural, $n \in \mathbb{N}$, se dice que el espacio es de dimensión finita n .

Definición 2.8 En un espacio vectorial K^n ,

$$e_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, e_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \dots, e_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix},$$

forman una base en dicho espacio; éste, por tanto, tiene dimensión n . Esta base se denomina **base canónica** o **base estándar** de K^n . En esta base, cualquier vector $x^T = [x_1, x_2, \dots, x_n]$ se puede expresar de la siguiente forma:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} + \dots + x_n \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}.$$

Es decir $\mathbb{R}^n = \text{Gen}\{e_1, \dots, e_n\}$. La base estándar de $\mathbb{P}_n$ es $S = \{1, t, t^2, \dots, t^n\}$.

Proposición 2.2 Si M y N son dos subespacios vectoriales de un espacio X , la intersección, $M \cap N$, de M y N es un subespacio de X .

Si A y B son subconjuntos de un espacio vectorial E , el conjunto $A + B$ se define como:

$$A + B = \{a + b : a \in A, b \in B\}.$$

Cuando A y B son subespacios, también lo es la suma $A + B$. Si además $A \cap B = \emptyset$, la suma se denomina *directa*, escribiéndose $A \oplus B$. Si $A \oplus B = E$, cualquier vector $c \in E$ se descompone de manera única como $c = a + b$, con $a \in A$ y $b \in B$; también se dice

que A y B son *subespacios suplementarios*.

En el espacio tridimensional el subespacio generado por un círculo bidimensional centrado en el origen es un plano. El subespacio generado por un plano que no pase por el origen es el espacio entero. Un subespacio es una generalización de nuestra noción intuitiva de un plano o línea recta a través del origen. La traslación de un subespacio, por lo tanto, es una generalización de un plano arbitrario o una recta.

Definición 2.9 La traslación de un subespacio se denomina **variedad lineal** o **subespacio afín**.

Una variedad lineal V se puede expresar como $V = x_0 + M$, donde M es un subespacio. En la figura 2.1 se representa un subespacio M y una variedad lineal derivada de él para un x_0 cualquiera de V .




Figura 2.1: Variedad lineal o subespacio afín

2.1 Espacios vectoriales con estructuras adicionales

LOS espacios vectoriales de mayor interés, tanto en el análisis abstracto como en las aplicaciones, tienen más estructura que la implicada únicamente por las propiedades presentadas. Los axiomas del espacio vectorial sólo describen propiedades algebraicas de los elementos del espacio: adición, multiplicación por un escalar y combinaciones de éstas. Faltan conceptos topológicos como apertura, envoltura, convergencia y completitud, para hacer frente a cuestiones fundamentales para el análisis como es si una sucesión de funciones converge a otra función, la continuidad de funciones, medir distancias, etc.

Las necesidades del análisis funcional requieren considerar nuevas estructuras. Todos estos conceptos se pueden proporcionar introduciendo una forma de medir y la distancia en un espacio.

2.1.1 Espacios normados y espacios métricos

La idea detrás de una *norma* es poder medir vectores y calcular distancias.

Definición 2.10 Si en un espacio vectorial E sobre K ($\mathbb{R}$ o $\mathbb{C}$) se define una **norma vectorial** como una aplicación $\|\cdot\| : E \rightarrow \mathbb{R}$ que verifica

$$\|v\| = 0 \implies v = 0 \quad \text{y} \quad x \neq 0 \implies \|x\| > 0,$$

$$\|\alpha v\| = |\alpha| \|v\| \quad \text{para } \alpha \in K \text{ y } v \in E,$$

$$\|u + v\| \leq \|u\| + \|v\| \quad \forall u, v \in E,$$

se dice que E es un *espacio vectorial normado*.

La condición $\|u + v\| \leq \|u\| + \|v\|$ es la desigualdad de Minkowski —por Hermann Minkowski, Lituania 1864-1909—,



que se conoce también como *regla del triángulo*. Es una generalización del hecho de que un lado de un triángulo no puede ser mayor que la suma de los otros dos en un espacio euclídeo multidimensional, como se puede constatar en la figura 2.2.




Figura 2.2: Representación gráfica de la regla del triángulo

Lema 2.3 En un espacio vectorial normado se cumple que $\|x\| - \|y\| \leq \|x - y\|$ para cualesquiera dos vectores x e y .

Demostración. $\|x\| - \|y\| = \|x - y + y\| - \|y\| \leq \|x - y\| + \|y\| - \|y\| = \|x - y\|$. $\square$

Definición 2.11 En un espacio vectorial normado se define la **distancia** entre dos elementos u y v mediante

$$d(u, v) = \|u - v\|.$$

Esta definición convierte a cualquier espacio vectorial normado en un **espacio métrico**. El espacio de los números reales, por ejemplo, con la distancia $d(x, y) = |x - y|$, es el espacio métrico $\mathbb{R}^1$.

Con la introducción de normas adecuadas, casi todos los ejemplos de espacios vectoriales arriba indicados se pueden convertir en espacios vectoriales normados.

Ejemplo 2.7 El espacio vectorial $C[a, b]$ de funciones continuas en el intervalo de la recta real $[a, b]$ junto con la norma $\|x\| = \max_{a \leq t \leq b} |x(t)|$ es un espacio vectorial normado.

Comprobemos si esta norma satisface las propiedades requeridas. Es obvio que $\|x\| \geq 0$ y es cero sólo si la función $x(t)$ es igual a cero. La regla del triángulo se obtiene de la expresión

$$\max |x(t) + y(t)| \leq \max(|x(t)| + |y(t)|) \leq \max |x(t)| + \max |y(t)|.$$

Finalmente, la propiedad que falta se deduce de

$$\max |\alpha x(t)| = \max |\alpha| |x(t)| = |\alpha| \max |x(t)|. \quad \bullet$$

Ejemplo 2.8 El espacio vectorial $D[a, b]$ de todas las funciones continuas en el intervalo $[a, b]$ de la recta real, con derivadas continuas de primer orden, junto con la norma definida así, $\|x\| = \max_{a \leq t \leq b} |x(t)| + \max_{a \leq t \leq b} |\dot{x}(t)|$, es un espacio vectorial normado. $\bullet$

Ejemplo 2.9 El *espacio euclídeo* n -dimensional, denotado como $\mathbb{R}^n$ o E^n , es el espacio vectorial normado por excelencia con la *norma euclídea* dada por la expresión $\|x\|_2 = \sqrt{|x_1|^2 + \cdots + |x_n|^2}$. Sus elementos lo constituyen sucesiones ordenadas de n elementos cualesquiera de K , o n -uplas $x = [x_1, \dots, x_n]$. Si los elementos son complejos se tendría el espacio $\mathbb{C}^n$. $\bullet$

En el espacio vectorial K^n , para $1 \leq p < \infty$, se tiene la familia de normas

$$\|x\|_p = \sqrt[p]{|x_1|^p + \cdots + |x_n|^p}$$

denominadas *normas p de Hölder* —por Otto Hölder, Alemania 1859-1937—.



Casos particulares lo constituyen las correspondientes a $p = 1$ y $p = 2$:

$$\begin{aligned} \|x\|_1 &= \sum_{i=1}^n |x_i| \\ \|x\|_2 &= \sqrt{|x_1|^2 + \cdots + |x_n|^2}. \end{aligned}$$

Esta última es una vez más la norma euclídea en $\mathbb{R}^n$. Toma su nombre de Euclides de Alejandría, Grecia, 325-265 a.C.

También en $\mathbf{K}^n$ es una norma la dada por

$$\|\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} |x_i|.$$

Esta norma también se conoce como *norma infinito* o *norma del supremo*.

Estas normas cumplen, cualquiera que sea $x \in \mathbf{K}^n$, que

$$\|\mathbf{x}\|_{\infty} \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq n \|\mathbf{x}\|_{\infty}.$$

Si la bola cerrada unidad en $\mathbb{R}^2$ es el conjunto $\{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\| \leq 1\}$, su forma en espacios vectoriales normados por la 1, 2, ∞ y p son las que representa la figura 2.3.




Figura 2.3: Forma de la bola unidad para diferentes normas en $\mathbb{R}^2$

2.1.1.1 Estructura topológica en espacios vectoriales

En un espacio vectorial normado se define una *bola abierta*, $S(\mathbf{x}_0, r)$, de centro $\mathbf{x}_0$ y radio r , como el conjunto de puntos $\mathbf{x}$ que verifican $\|\mathbf{x} - \mathbf{x}_0\| < r$. Es decir:

$$S(\mathbf{x}_0, r) = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{x}_0\| < r\}.$$

Una *bola cerrada*, $\bar{S}(\mathbf{x}_0, r)$, se define, por el contrario, como el conjunto de puntos $\mathbf{x}$ que verifican $\|\mathbf{x} - \mathbf{x}_0\| \leq r$. Es decir:

$$\bar{S}(\mathbf{x}_0, r) = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{x}_0\| \leq r\}.$$

Consideraremos en lo que sigue de este apartado un subconjunto S del espacio vectorial métrico hasta ahora estudiado (puede ser, por ejemplo, $\mathbb{R}^n$).

Definición 2.12 Sea S un conjunto de puntos del espacio vectorial normado X . Un punto $y \in S$ es un **punto interior** de S si existe un $\varepsilon > 0$ tal que todos los vectores x que satisfacen $\|x - y\| < \varepsilon$ pertenecen a S . En otras palabras, existe una bola abierta $S(y, \varepsilon)$ de centro y y radio ε contenida íntegramente en S . El conjunto de todos los puntos interiores del conjunto S se denomina **interior** de S y se designa mediante $\overset{\circ}{S}$.

El interior de un conjunto puede, evidentemente, ser vacío. Por ejemplo un conjunto con un único punto, una línea en $\mathbb{R}^2$ o un plano del espacio $\mathbb{R}^3$.

Definición 2.13 Un conjunto, o subconjunto S de un espacio normado, se dice **abierto** si coincide con su interior: $S = \overset{\circ}{S}$. Es decir, si alrededor de todo punto de S existe una bola abierta contenida íntegramente en S .

Dos ejemplos: la bola abierta unidad, $S(x, 1) = \{x : \|x\| < 1\}$ y el espacio $\mathbb{R}^n$ en su totalidad. En general los subconjuntos o conjuntos abiertos se caracterizan por no tener límites definidos o ser disjuntos de su frontera (ver más adelante la definición del concepto frontera).

Definición 2.14 Un *entorno* de un punto x , $\mathcal{E}(x)$, es un conjunto abierto que contiene a x . En otras palabras, $\mathcal{E}(x)$ es un entorno de x si contiene una bola abierta de centro x .

Definición 2.15 Se dice que un punto x es un *punto de acumulación* del subconjunto S si en todo entorno de x existen un número infinito de puntos de S .

Definición 2.16 Un punto x se denomina **punto de adherencia** de un subconjunto S de un espacio vectorial cuando todo entorno de dicho punto x contiene al menos un punto de S ; es decir, para todo ε existe un $y \in S$ tal que $\|x - y\| < \varepsilon$. El conjunto de todos los puntos de adherencia de S se denomina **adherencia** —en la literatura anglosajona y latinoamericana, se denomina *clausura* $cl(S)$ o *cerramiento*—. Se designa por $\bar{S}$. La adherencia de la bola abierta $S(x, 1) = \{x : \|x\| < 1\}$ es la cerrada $\bar{S}(x, 1) = \{x : \|x\| \leq 1\}$.

Definición 2.17 Se denomina *frontera* o *borde* de un conjunto a la parte de la adherencia que no está en el interior.

Definición 2.18 Un conjunto, o subconjunto, se dice **cerrado** si coincide con su adherencia.

2.1.1.2 Convergencia

La adherencia de cualquier conjunto S es el conjunto cerrado más pequeño que contiene a S . Se puede demostrar que un conjunto es cerrado si y sólo si toda sucesión convergente de elementos de S tiene un límite en ese conjunto.

Definición 2.19 Se dice que en un espacio vectorial normado una sucesión infinita de vectores $\{x_n\}$ **converge** a un vector x si la sucesión $\{\|x - x_n\|\}$ converge a cero. En este caso se escribe $x_n \rightarrow x$.

Todos los elementos del vector deben converger a cero, lo que hace difícil caracterizar la convergencia en espacios que no sean $\mathbb{R}^n$.

Proposición 2.4 Si la sucesión infinita de vectores converge, el límite es único.

Demostración. Supongamos que $x_n \rightarrow x$ y que $x_n \rightarrow y$. Entonces

$$\|x - y\| = \|x - x_n + x_n - y\| \leq \|x - x_n\| + \|x_n - y\| \rightarrow 0.$$

Como consecuencia de esto, $x = y$. □

En términos de esferas o bolas, una sucesión infinita de vectores $\{x_n\}$ **converge** a un vector x si y sólo si dado un $\varepsilon > 0$ la bola $S(x_0, \varepsilon)$ contiene un x_n para todo n mayor que algún número N .

Proposición 2.5 Un conjunto F es **cerrado** si y sólo si cualquier sucesión convergente de elementos de F tiene límite en F .

Proposición 2.6 La intersección de un número finito de conjuntos abiertos es abierta. La unión de una colección arbitraria de conjuntos abiertos es abierta.

Proposición 2.7 La unión de un número finito de conjuntos cerrados es cerrada. La intersección de una colección arbitraria de conjuntos cerrados es cerrada.

Definición 2.20 Un conjunto, o subconjunto, se dice **compacto** si es cerrado y acotado (contenido en una bola de radio $r < \infty$).

El término general de una *sucesión* $\{x_n\}_{n \geq 1}$ de números reales tiene límite, l , cuando n tiende a ∞ , si para todo valor $\varepsilon > 0$ por pequeño que sea, existe un valor n_0 a partir del cual si $n > n_0$ tenemos que la distancia de l a x_n es menor que ε , es decir, $\forall \varepsilon > 0, \exists n_0 > 0 : \forall n > n_0, d(x_n, l) < \varepsilon$.

Un importante resultado debido a Karl Theodor Wilhelm Weierstraß, Alemania 1815-1897,



dice que si S es un conjunto compacto, de cada sucesión o sucesión infinita $\{x_n\}_{n \in \mathbb{N}}$ de elementos de dicho conjunto es posible extraer una subsucesión $\{x_\ell\}_{\ell \in L}, L \subset \mathbb{N}$ que converge a un elemento del propio conjunto S .

Si $\{r_k\}$ es una sucesión de números reales y $s_k = \sup \{r_i : i \geq k\}$, entonces $\{s_k\}$ converge a un número real s_0 ; a este número se le denomina *límite superior* de $\{r_k\}$ y se expresa como $\limsup (r_k)$ o $\lim_{k \rightarrow \infty} (r_k)$. El límite superior de una sucesión de números reales es el mayor punto de acumulación de la sucesión. De forma similar se define el límite inferior.


Sea E un espacio vectorial normado; se dice que una sucesión $\{x_n\}$ en E converge a un límite $v \in E$, si para todo $\varepsilon > 0$, existe un $N \in \mathbb{N}$ tal que a partir de él, $n \geq N$, se cumple que $\|x_n - v\| < \varepsilon$.

Cuando una sucesión $\{x_n\}$ admite un vector límite v sólo tiene ese vector como límite (si existe límite es único.) Se escribe $\lim_{n \rightarrow \infty} \{x_n\} = v$, lo que es equivalente a $\lim_{n \rightarrow \infty} \|x_n - v\| = 0$. En particular, $x_n \rightarrow 0$ si y sólo si $\|x_n\| \rightarrow 0$.

Definición 2.21 Una sucesión $\{x_n\}$ en un espacio vectorial normado por $\|\cdot\|$ se denomina **sucesión de Cauchy**, por Augustin Louis Cauchy, Francia 1789-1857, si $\|x_n - x_m\| \rightarrow 0$ al tender $n, m \rightarrow \infty$. En otras palabras, si para todo $\varepsilon > 0$ existe un $N \in \mathbb{N}$ tal que cualesquiera que sean $n, m \geq N$, se cumple que $\|x_n - x_m\| < \varepsilon$. Toda sucesión convergente es una sucesión de Cauchy pero pueden existir espacios normados con sucesiones de Cauchy que no son convergentes.



Definición 2.22 Un espacio vectorial normado se dice **completo** si toda sucesión de Cauchy en él tiene límite. Un espacio vectorial normado completo es un **espacio de Banach**, por Stefan Banach, Polonia 1892-1945.



Si se tiene la sucesión $x = \{x_n\}_{n=1}^{\infty}$, se puede definir

$$\|x\|_1 = \sum_{n=1}^{\infty} |x_n|, \quad \|x\|_2 = \sqrt{\sum_{n=1}^{\infty} |x_n|^2} \quad \text{y} \quad \|x\|_{\infty} = \sup_{n \in \mathbb{N}} |x_n|.$$

Estas cantidades no estarán definidas para cualquier sucesión en $\mathbb{R}^{\mathbb{N}}$ o $\mathbb{C}^{\mathbb{N}}$ y estarán

asociadas a un subespacio específico de sucesiones. Si se define

$$\ell^1(\mathbb{N}) = \left\{ \mathbf{x} = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}} \text{ tal que } \sum_{n=1}^{\infty} |x_n| < \infty \right\},$$

se comprueba que $\ell^1(\mathbb{N})$ es un subespacio vectorial de $\mathbb{C}^{\mathbb{N}}$ y que $\|\mathbf{x}\|_1$ para $\mathbf{x} \in \ell^1(\mathbb{N})$ define una norma. Se obtiene así un espacio normado. De la misma manera se definen

$$\ell^2(\mathbb{N}) = \left\{ \mathbf{x} = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}} \text{ tal que } \sum_{n=1}^{\infty} |x_n|^2 < \infty \right\}$$

y

$$\ell^{\infty}(\mathbb{N}) = \{ \mathbf{x} = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}} \text{ tal que } \mathbf{x} \text{ esté acotada} \}.$$

Si $\Omega \subset \mathbb{R}^n$ es un conjunto abierto de $\mathbb{R}^n$, el conjunto de todas las funciones continuas en Ω forman un espacio vectorial lineal, $C(\Omega)$, en $\mathbb{R}^n$, con las operaciones suma y producto por un escalar,

$$\begin{aligned} (f + g)(\mathbf{x}) &= f(\mathbf{x}) + g(\mathbf{x}), \quad \mathbf{x} \in \Omega \\ (\alpha f)(\mathbf{x}) &= \alpha f(\mathbf{x}), \quad \mathbf{x} \in \Omega. \end{aligned}$$

Recordemos antes de introducir otros ejemplos de espacios vectoriales en los que la norma es importante, que una función f se supone continua (o uniformemente continua) en Ω si para cualquier $\varepsilon > 0$ existe un $\delta = \delta(f, \varepsilon) > 0$ tal que $|f(\mathbf{x}) - f(\mathbf{y})| < \varepsilon$, cualesquiera sean $\mathbf{x}, \mathbf{y} \in \Omega$ con $\|\mathbf{x} - \mathbf{y}\| < \delta$.

Mediante $C(\overline{\Omega})$ se designa el espacio vectorial lineal de las funciones continuas en el conjunto cerrado $\overline{\Omega}$. Este último espacio, y $C(\Omega)$, son una variedad de espacio vectorial denominada *espacio funcional* pues sus elementos son funciones en vez de vectores propiamente dichos. Cualquier función continua en $C(\overline{\Omega})$ es claramente continua en $C(\Omega)$. Igualmente, si $f \in C(\Omega)$ es continua en el conjunto abierto Ω y éste está acotado, la función f se puede suponer continua también en $\partial\Omega$, la *frontera* o *borde* de Ω , y entenderse que es continua por tanto en $C(\Omega)$ y pertenece a dicho conjunto.

Otro espacio vectorial interesante es $C^m(\Omega)$, el de funciones continuas con derivadas parciales continuas hasta orden m en Ω , o $C^m(\overline{\Omega})$ en $\overline{\Omega}$. También $C_p(2\pi)$, de funciones continuas periódicas- 2π , es decir, funciones $f \in C(-\infty, \infty)$ tales que $f(x + 2\pi) = f(x)$, $-\infty < x < \infty$. O $C_p^k(2\pi)$ de funciones continuas periódicas- 2π con derivadas continuas hasta orden k . Alguna vez se indica $C_p^0(2\pi)$ para referirse a $C_p(2\pi)$.

Definición 2.23 El conjunto $L^1[a, b]$, de todas las funciones del cuerpo de los números reales cuyo valor absoluto es integrable en el intervalo $[a, b]$, es un espacio vectorial funcional. También lo es $L^2[a, b]$, el conjunto de todas las funciones reales al cuadrado integrables en $[a, b]$. Es de destacar que en ambos casos estas funciones no tienen por que ser continuas en ese intervalo.

2.1.1.3 Transformaciones, aplicaciones y operadores. Continuidad

Definición 2.24 Dados dos espacios vectoriales X e Y y un subconjunto D de X , una regla que asocia a cada elemento $x \in D$ un elemento $y \in Y$ se dice una **transformación**, o **aplicación**, de X en Y con dominio de definición D . Si y corresponde a x con la transformación T se escribe $y = T(x)$.

Definición 2.25 Una transformación de un espacio vectorial X en un espacio vectorial de números reales o complejos se denomina **función**.

Definición 2.26 Dados dos espacios vectoriales E y F sobre el mismo cuerpo K se define una **aplicación lineal**, **transformación lineal**, **mapeo**, **operador lineal** u **homomorfismo**, f , de E en F , como una aplicación $f : E \rightarrow F$ que verifica

$$f(\lambda x + \mu y) = \lambda f(x) + \mu f(y),$$

cualesquiera que sean los vectores x, y de E y los escalares λ y μ .

Existen dos casos particulares interesantes: el primero cuando $E = F$, en este caso se dice que f es un *operador lineal* de E o *endomorfismo* de E ; el segundo cuando $F = K$ —el cuerpo base—, en cuyo caso la aplicación se denomina *forma lineal* sobre E .

El conjunto $\mathcal{L}(E, F)$ de todas las aplicaciones lineales del espacio E en el espacio F se estructura como un espacio vectorial si se definen las siguientes operaciones:

$$\text{adición } (f + g) : (f + g)(x) = f(x) + g(x), \quad \forall x \in E;$$

$$\text{producto por un escalar } \lambda f : (\lambda f)(x) = \lambda f(x), \quad \forall x \in E \text{ y } \forall \lambda \in K.$$

En particular, el conjunto $\mathcal{L}(E, K)$ de formas lineales es un espacio vectorial denominado *dual* de E , representándose con E^* .

Para una aplicación lineal $f : E \rightarrow F$, el conjunto de vectores de F que son la imagen de los de un subespacio de E forma un subespacio de F . En particular, la imagen de todo E es un subespacio de F que se denomina *subespacio imagen* de f , representándose mediante $\text{Im}(f)$. Análogamente, el conjunto anti-imagen de un subespacio de F forma un subespacio de E . En particular, la anti-imagen del subespacio nulo de F forma lo que se denomina el *núcleo* de la aplicación, representándose por $\ker(f)$. Así pues

$$\ker(f) = \{x \in E : f(x) = \mathbf{0}\}.$$

Si $b \in F$, la ecuación lineal $f(x) = b$ tiene solución si y sólo si $b \in \text{Im}(f)$. En ese caso el conjunto de todas las soluciones es la *variedad lineal* —traslación de un subespacio— dada por $x_0 + \ker(f)$, donde x_0 es una solución particular de la ecuación. En particular, la aplicación es inyectiva si y sólo si $\ker(f) = \mathbf{0}$.

El ejemplo más inmediato de transformación lineal lo proporciona una matriz rectangular $m \times n$ que asocia elementos de $\mathbb{R}^n$ en $\mathbb{R}^m$. Volvemos sobre esto unas líneas más abajo.

Oro ejemplo de transformación lineal de $X = C[a, b]$ en X lo constituye la integral $T(x) = \int_a^b k(t, \tau)x(\tau) d\tau$, donde $k(t, \tau)$ es una función continua en espacio cuadrado $a \leq t \leq b, a \leq \tau \leq b$.

Definición 2.27 Una transformación o aplicación T de un espacio vectorial normado X en otro espacio vectorial normado Y es **continua** en $x_0 \in X$ si para todo $\varepsilon > 0$ existe un $\delta > 0$ tal que $\|x - x_0\| < \delta$ implica que $\|T(x) - T(x_0)\| < \varepsilon$.

La continuidad depende de la norma elegida. Si todo punto de un espacio vectorial normado es continuo, el espacio se dice continuo.

Proposición 2.8 Una transformación T de un espacio vectorial normado en otro Y también normado se dice **continua** en el punto $x_0 \in X$ si y sólo si $x_n \rightarrow x_0$ implica que $T(x_n) \rightarrow T(x_0)$.

Dada una transformación lineal, aplicación lineal, o mapeo, $f : E \rightarrow E$, se dice que un subespacio W de E es un *subespacio invariante* frente a f (o f -invariante) si para todo vector $w \in W$ se cumple que $f(w) \in W$. Dicho de otra manera, W es un subespacio invariante si $f(W) \subset W$.

2.1.1.3.1 Los espacios ℓ^p y L^p

Volvemos sobre ellos en este contexto.

Definición 2.28 Sea p un número real tal que $1 \leq p < \infty$. El **espacio ℓ^p** está formado por todas las sucesiones $x = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}}$ tales que

$$\sum_{n=1}^{\infty} |x_n|^p < \infty.$$

Es decir

$$\ell^p(\mathbb{N}) = \left\{ x = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}} \text{ tal que } \sum_{n=1}^{\infty} |x_n|^p < \infty \right\}.$$

El espacio ℓ^∞ es $\ell^\infty(\mathbb{N}) = \{x = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}} \text{ tal que } x \text{ esté acotada}\}.$

La norma de un elemento $x = \{x_n\}_{n=1}^{\infty} \in \mathbb{C}^{\mathbb{N}}$ de ℓ^p está definida por

$$\|x\|_p = \left(\sum_{i=1}^{\infty} |x_i|^p \right)^{1/p}.$$

En $\ell^\infty(\mathbb{N})$ por $\|x\|_\infty = \sup_i |x_i|$.

Los espacios (funcionales) $L^p[a, b]$, e incluso $\mathbb{R}^p$ se definen, de forma análoga, para $p \geq 1$, como el espacio de las funciones medibles x en el intervalo $[a, b]$ para las cuales

la integral de Lebesgue (Riemann) existe. La norma de este espacio se define como

$$\|x\|_p = \left(\int_a^b |x(t)|^p dt \right)^{1/p}.$$

2.1.1.4 Espacios de Banach

Definición 2.29 Un **Espacio de Banach** es un espacio vectorial normado completo respecto de la norma a él asociada. Todo espacio vectorial normado de dimensión finita es un espacio de Banach.

Ejemplo 2.10 De Luenberger [1969] sacamos la sucesión, del espacio X de funciones continuas en $[0, 1]$ con la norma que define $\|x\| = \int_0^1 |x(t)| dt$, que expresa

$$x_n(t) = \begin{cases} 0 & \text{para } 0 \leq t \leq \frac{1}{2} - \frac{1}{n} \\ nt - \frac{n}{2} + 1 & \text{para } \frac{1}{2} - \frac{1}{n} \leq t \leq \frac{1}{2} \\ 1 & \text{para } t \geq \frac{1}{2}. \end{cases}$$

Su gráfica es la de la figura 2.4. Este espacio no es $C[0, 1]$ pues la norma es diferente.

Cada elemento de la sucesión es una función continua del espacio X . La sucesión es de Cauchy pues $\|x_n - x_m\| = \frac{1}{2}|1/n - 1/m| \rightarrow 0$. Sin embargo, es obvio que no converge a ninguna función continua. El espacio X es incompleto. ●




Figura 2.4: Gráfica de sucesión de Cauchy que no converge a una función continua

Ejemplo 2.11 También es fácil ver que en $C[0, 1]$ la sucesión de funciones cuyas gráficas son las de la figura 2.5 es una sucesión de Cauchy para cualquier norma $\|\cdot\|_p$, pero no tiene límite en $C[0, 1]$. ●

Ejemplo 2.12 El espacio normado $C[0, 1]$ es un espacio de Banach. Para probar que es completo tendríamos que probar que toda sucesión de Cauchy en él tiene límite.




Figura 2.5

Supongamos que $\{x_n\}$ es una sucesión de Cauchy en $C[0, 1]$. Para cada $t \in [0, 1]$, $|x_n(t) - x_m(t)| \leq \|x_n - x_m\| \rightarrow 0$ por lo que $\{x_n\}$ es una sucesión de Cauchy de números reales. Como el conjunto de los números reales es completo existe un número real $x(t)$ al que converge la sucesión: $x_n(t) \rightarrow x(t)$. Las funciones x_n convergen en consecuencia punto a punto a la función x .

Ahora probemos que esta convergencia punto a punto es uniforme en $t \in [0, 1]$, es decir, dado un $\varepsilon > 0$ existe un N tal que $|x_n(t) - x(t)| < \varepsilon$ para todo $t \in [0, 1]$ y $n \geq N$. Dado un $\varepsilon > 0$ escogemos un N tal que $\|x_n - x_m\| < \varepsilon/2$ para $n, m > N$. Entonces para $n > N$

$$\begin{aligned} |x_n(t) - x(t)| &\leq |x_n(t) - x_m(t)| + |x_m(t) - x(t)| \\ &\leq \|x_n - x_m\| + |x_m(t) - x(t)|. \end{aligned}$$

Escogiendo un m suficientemente grande (que dependerá de t), cada término del miembro de la derecha de la expresión anterior se puede hacer menor que $\varepsilon/2$ de tal manera que $|x_n(t) - x(t)| < \varepsilon$ para $n > N$.

Queda por probar que la función x es continua y que la sucesión $\{x_n\}$ converge a x de acuerdo con la norma de $C[0, 1]$. Para probar la continuidad de x , fijamos $\varepsilon > 0$. Para todo δ, t y m ,

$$\begin{aligned} |x(t + \delta) - x(t)| &\leq |x(t + \delta) - x_n(t + \delta)| \\ &\quad + |x_n(t + \delta) - x_n(t)| + |x_n(t) - x(t)|. \end{aligned}$$

Como $\{x_n\}$ converge uniformemente a x , n se puede escoger de tal manera que los términos primero y último de esta expresión se hagan menores que $\varepsilon/3$ para todo δ . Como x_n es continua, se puede escoger un δ que haga el segundo término menor que $\varepsilon/3$. Como consecuencia de ello, x es continua. La convergencia de x_n a x en $C[0, 1]$ se desprende directamente de la convergencia uniforme. ●

Es bastante instructivo conciliar la completitud de $C[0, 1]$ con el ejemplo 2.10 en el que la sucesión de funciones era de Cauchy pero no convergente con respecto a la norma que allí se definía. La diferencia es que, con respecto a la norma de $C[0, 1]$, la sucesión del ejemplo 2.10 no es de Cauchy.

Los espacios ℓ^p , $1 \leq p \leq \infty$ y L^p , $1 \leq p \leq \infty$, son espacios de Banach.

2.1.2 Espacios con producto interior

Definición 2.30 Sea E un espacio vectorial sobre un cuerpo K ($\mathbb{R}$ o $\mathbb{C}$); una **forma sesquilineal** —vez y media lineal— sobre E es una aplicación $\langle \cdot | \cdot \rangle : E \times E \rightarrow K$ que verifica (la barra designa complejo conjugado):

$$\begin{aligned} 1) \quad & \langle \alpha u + \beta v | w \rangle = \alpha \langle u | w \rangle + \beta \langle v | w \rangle \quad \text{y} \\ 2) \quad & \langle u | \alpha v + \beta w \rangle = \overline{\alpha} \langle u | v \rangle + \overline{\beta} \langle u | w \rangle, \end{aligned}$$

cualesquiera que sean u, v, w en E y α, β en K . Si además se cumple que $\langle u | v \rangle = \overline{\langle v | u \rangle}$, la forma se denomina *hermítica*. Es claro que $\langle u | u \rangle$ es siempre un número real. Cuando se cumple que

$$u \neq 0 \implies \langle u | u \rangle > 0,$$

se dice que la forma es definida positiva, denominándose la también **producto escalar** o **producto interior**. Una forma sesquilineal sobre $\mathbb{R}$ es siempre una *forma bilineal*.

2.1.3 Espacios de Hilbert

Un *espacio prehilbertiano* —por David Hilbert, Prusia Oriental 1862-1943—



es un espacio vectorial, sobre un cuerpo K , dotado de una forma hermítica definida positiva. Todo espacio prehilbertiano es un espacio normado mediante

$$\|v\| = \sqrt{\langle v | v \rangle}.$$

En la demostración de que esta definición corresponde a la de una norma en E juega un papel importante la *desigualdad de Cauchy-Schwarz* —por Augustin Louis Cauchy,

Francia 1789-1857 y Karl Hermann Amandus Schwarz, Prusia 1843-Alemania 1921—



que tiene por expresión

$$|\langle \mathbf{u} | \mathbf{v} \rangle| \leq \|\mathbf{u}\| \cdot \|\mathbf{v}\|.$$

Sean E y F dos espacios prehilbertianos sobre el cuerpo $\mathbf{K}$; si $f : E \rightarrow F$ es una aplicación lineal, la *aplicación traspuesta* de f es la aplicación $f^* : F \rightarrow E$ que cumple

$$\langle \mathbf{x} | f^*(\mathbf{y}) \rangle = \langle f(\mathbf{x}) | \mathbf{y} \rangle,$$

cualesquiera que sean los vectores $\mathbf{x} \in E$ e $\mathbf{y} \in F$. Particularmente importante es el caso en que $E = F$: f^* se dice entonces que es el *operador adjunto* de f . Cuando un operador f de E cumple que $f^* = f$ se denomina *operador autoadjunto*. En el caso de que E sea un espacio vectorial real, también se dice que f es un *operador simétrico* y cuando es un espacio vectorial complejo, que f es un *operador hermítico*. Un operador simétrico cumple que

$$\langle \mathbf{x} | f(\mathbf{y}) \rangle = \langle f(\mathbf{x}) | \mathbf{y} \rangle,$$

mientras que uno hermítico, que

$$\langle \mathbf{x} | f(\mathbf{y}) \rangle = \overline{\langle f(\mathbf{x}) | \mathbf{y} \rangle}.$$

Un operador f de E es *unitario* cuando es invertible y su inverso coincide con su adjunto. Es decir, si $f^* = f^{-1}$. Para un operador unitario se tiene que

$$\langle f(\mathbf{x}) | f(\mathbf{y}) \rangle = \langle f^*(f(\mathbf{x})) | \mathbf{y} \rangle = \langle \mathbf{x} | \mathbf{y} \rangle,$$

de manera que $\|f(\mathbf{x})\| = \|\mathbf{x}\|$. Por este motivo a los operadores unitarios también se les denomina *operadores isométricos*.

Definición 2.31 Un **espacio de Hilbert** es un espacio prehilbertiano completo respecto de la norma asociada al producto escalar $\|\cdot\| = \sqrt{\langle \cdot, \cdot \rangle}$. Dicho de otra forma, un espacio prehilbertiano que con esta norma da un espacio de Banach. Todo espacio de Hilbert es un espacio de Banach, pero el recíproco no es cierto.

El *espacio euclídeo* n -dimensional, expresado $\mathbb{R}^n$ o $\mathbf{E}^n$, es un espacio de Hilbert de dimensión finita. Visto así, *un espacio de Hilbert sería la generalización de un espacio euclídeo, incluida la dimensión infinita*. El producto escalar en un espacio euclídeo es una forma bilineal. En particular, dados dos vectores en $\mathbb{R}^2$ de la forma $\mathbf{u} = [a, b]^T$ y

$\mathbf{v} = [c, d]^T$, su producto escalar viene dado por $\langle \mathbf{u}, \mathbf{v} \rangle = ac + bd$, que se puede verificar que es una forma bilineal.

Dos vectores cuyo producto escalar es cero se denominan *ortogonales*; si sus $\|\cdot\|_2$ son la unidad se denominan *ortonormales*. Para dos vectores ortogonales se tiene la identidad

$$\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2,$$

que es una generalización del teorema de Pitágoras. En un espacio prehilbertiano el único vector ortogonal a todos los vectores del espacio es el vector nulo; si este espacio es de dimensión finita es posible construir una base ortonormalizada.

En un espacio euclídeo n -dimensional el ángulo entre dos vectores $\mathbf{x}$ e $\mathbf{y}$ es

$$\theta = \arccos \left(\frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} \right),$$

donde

$$\rho = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

cumple que $-1 \leq \rho \leq 1$, para cualesquiera $\mathbf{x}$ e $\mathbf{y}$.

Dos vectores son ortogonales si $\mathbf{x}^T \mathbf{y} = 0$ ($\theta = \pi/2, \rho = 0$); alineados, si $\mathbf{x}^T \mathbf{y} = \|\mathbf{x}\| \|\mathbf{y}\|$ ($\theta = 0, \rho = 1$); opuestos, si $\mathbf{x}^T \mathbf{y} = -\|\mathbf{x}\| \|\mathbf{y}\|$ ($\theta = \pi, \rho = -1$). Forman un ángulo agudo si $\mathbf{x}^T \mathbf{y} > 0$ ($\theta < \pi/2, \rho > 0$) y un ángulo obtuso si $\mathbf{x}^T \mathbf{y} < 0$ ($\theta > \pi/2, \rho < 0$).

Una familia cualquiera de vectores distintos del nulo y ortogonales dos a dos es una familia libre. Si M es un subespacio de un espacio prehilbertiano E de dimensión finita, el *subespacio ortogonal* de M , $M^\perp$, es el subespacio formado por todos los vectores ortogonales a los de M , siendo un subespacio suplementario de M ; es decir $M \oplus M^\perp = E$. Cualquier $\mathbf{x} \in E$, por consiguiente, se puede expresar como $\mathbf{x} = \mathbf{a} + \mathbf{b}$, con $\mathbf{a} \in M$ y $\mathbf{b} \in M^\perp$.

2.1.3.1 Teorema de la proyección

Gran parte de las teorías de sistemas de ecuaciones y de optimización están basadas en unos pocos resultados simples e intuitivos. Entre estos, quizás el más sencillo y usado sea el teorema de la proyección. Su aplicación en la teoría de mínimos cuadrados lineales es fundamental. En un espacio Euclídeo ordinario de tres dimensiones determina que la distancia más corta de un punto exterior a un plano a ese plano la proporciona la perpendicular al plano desde dicho punto. La expresión formal de este teorema en espacios de Hilbert es la que sigue.

Teorema 2.9 Sea H un espacio de Hilbert y M un subespacio cerrado de H . Para todo vector $\mathbf{x} \in H$ existe un único vector $\mathbf{m}_0 \in M$ tal que $\|\mathbf{x} - \mathbf{m}_0\|_2 \leq \|\mathbf{x} - \mathbf{m}\|_2$, para todo $\mathbf{m} \in M$. La condición necesaria y suficiente además para que $\mathbf{m}_0 \in M$ sea el vector mínimo único es que $\mathbf{x} - \mathbf{m}_0$ sea ortogonal a M .

Demostración. Primero probaremos que si $\mathbf{m}_0$ es un vector que minimiza $\|\mathbf{x} - \mathbf{m}\|$, $\mathbf{x} - \mathbf{m}_0$ es ortogonal a M . Supongamos para ello, por el contrario, que existe un $\mathbf{m}$ que no es ortogonal a $\mathbf{x} - \mathbf{m}_0$; sin pérdida de generalidad podemos suponer que $\|\mathbf{m}\| = 1$ y que $\langle \mathbf{x} - \mathbf{m}_0 | \mathbf{m} \rangle = \delta \neq 0$. Definamos el vector $\mathbf{m}_1 \in M$ como $\mathbf{m}_1 = \mathbf{m}_0 + \delta \mathbf{m}$. Tendremos que

$$\begin{aligned}\|\mathbf{x} - \mathbf{m}_1\|_2^2 &= \|\mathbf{x} - \mathbf{m}_0 - \delta \mathbf{m}\|_2^2 \\ &= \|\mathbf{x} - \mathbf{m}_0\|_2^2 - \langle \mathbf{x} - \mathbf{m}_0 | \delta \mathbf{m} \rangle - \langle \delta \mathbf{m} | \mathbf{x} - \mathbf{m}_0 \rangle + |\delta|^2 \\ &= \|\mathbf{x} - \mathbf{m}_0\|_2^2 - |\delta|^2 < \|\mathbf{x} - \mathbf{m}_0\|_2^2.\end{aligned}$$

De esta manera, si $\mathbf{x} - \mathbf{m}_0$ no es ortogonal a M , $\mathbf{m}_0$ no es el mínimo que decíamos.

Veamos ahora cómo, si $\mathbf{x} - \mathbf{m}_0$ es ortogonal al subespacio M , $\mathbf{m}_0$ es el único vector de M que minimiza $\|\mathbf{x} - \mathbf{m}\|_2$. En efecto, para todo $\mathbf{m} \in M$, el teorema de Pitágoras dice que

$$\|\mathbf{x} - \mathbf{m}\|_2^2 = \|\mathbf{x} - \mathbf{m}_0 + \mathbf{m}_0 - \mathbf{m}\|_2^2 = \|\mathbf{x} - \mathbf{m}_0\|_2^2 + \|\mathbf{m}_0 - \mathbf{m}\|_2^2.$$

Por lo tanto $\|\mathbf{x} - \mathbf{m}\|_2 > \|\mathbf{x} - \mathbf{m}_0\|_2$ para $\mathbf{m} \neq \mathbf{m}_0$.

Demostraremos ahora la existencia de un $\mathbf{m}_0$ que minimiza $\|\mathbf{x} - \mathbf{m}\|_2$. Si $\mathbf{x} \in M$, entonces $\mathbf{m}_0 = \mathbf{x}$ y todo estaría probado como es obvio. Si $\mathbf{x} \notin M$, definamos un $\delta = \inf_{\mathbf{m} \in M} \|\mathbf{x} - \mathbf{m}\|_2$; lo que queremos es obtener un $\mathbf{m}_0 \in M$ tal que $\|\mathbf{x} - \mathbf{m}_0\|_2 = \delta$.

A tal fin, sea $\{\mathbf{m}^{(i)}\}$ una sucesión de vectores en M tal que $\|\mathbf{x} - \mathbf{m}^{(i)}\|_2 \rightarrow \delta$. Por la ley del paralelogramo, para $\mathbf{u}, \mathbf{w} \in M$, $|\mathbf{u} + \mathbf{w}|^2 + |\mathbf{u} - \mathbf{w}|^2 = 2|\mathbf{u}|^2 + 2|\mathbf{w}|^2$, se tiene que

$$\begin{aligned}\|(\mathbf{m}^{(j)} - \mathbf{x}) + (\mathbf{x} - \mathbf{m}^{(i)})\|_2^2 + \|(\mathbf{m}^{(j)} - \mathbf{x}) - (\mathbf{x} - \mathbf{m}^{(i)})\|_2^2 &= \\ 2\|\mathbf{m}^{(j)} - \mathbf{x}\|_2^2 + 2\|\mathbf{x} - \mathbf{m}^{(i)}\|_2^2.\end{aligned}$$

Reordenando, se obtiene

$$\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\|_2^2 = 2\|\mathbf{m}^{(j)} - \mathbf{x}\|_2^2 + 2\|\mathbf{x} - \mathbf{m}^{(i)}\|_2^2 - 4\left\|\mathbf{x} - \frac{\mathbf{m}^{(i)} + \mathbf{m}^{(j)}}{2}\right\|_2^2.$$

Para todo i, j , el vector $(\mathbf{m}^{(i)} + \mathbf{m}^{(j)})/2$ está en M pues éste es un espacio vectorial (lineal). De la definición de δ se deduce que $\|\mathbf{x} - (\mathbf{m}^{(i)} + \mathbf{m}^{(j)})/2\|_2 \geq \delta$, por lo que

$$\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\|_2^2 \leq 2\|\mathbf{m}^{(j)} - \mathbf{x}\|_2^2 + 2\|\mathbf{x} - \mathbf{m}^{(i)}\|_2^2 - 4\delta^2.$$

Como $\|\mathbf{m}^{(i)} - \mathbf{x}\|_2^2 \rightarrow \delta^2$ cuando $i \rightarrow \infty$, $\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\|_2^2 \rightarrow 0$ cuando $i, j \rightarrow \infty$. Es decir, $\{\mathbf{m}^{(i)}\}$ es una sucesión de Cauchy; como M es un subespacio cerrado, la sucesión $\{\mathbf{m}^{(i)}\}$ tiene un límite $\mathbf{m}_0$ en M y, debido a la continuidad de la norma, $\|\mathbf{x} - \mathbf{m}_0\|_2 \rightarrow \delta$. $\square$

El teorema de la proyección pone en evidencia que la solución del problema

$$\underset{t}{\text{minimizar}} \|\mathbf{t}\mathbf{x} - \mathbf{y}\|$$

es el vector proyección ortogonal de $\mathbf{y}$ sobre $\mathbf{x}$: $\mathbf{t}\mathbf{x}$ en la figura 2.6.




Figura 2.6: Solución de minimizar $_t \|tx - y\|$

2.1.4 Espacios de Lebesgue y espacios de Sobolev

Los espacios de Lebesgue y Sobolev son dos casos importantes de espacios vectoriales de Hilbert.

Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ tiene como *derivada* la función

$$f'(x) = \frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

supuesto ese límite existe. Una función f que es derivable en un punto $x = a$ es continua en a . La derivada es una medida de la rapidez, o tasa (gradiente), con la que cambia el valor de dicha función según cambie el valor de su variable independiente.

Por otro lado, si $f : \mathbb{C} \rightarrow \mathbb{C}$, se define la *integral definida* de esta función en el intervalo $[a, b]$,

$$I(f) = \int_a^b f(x) dx,$$

como el límite de las sumas de Riemann —por Georg Friedrich Bernhard Riemann, Alemania 1826-1866—



$R_n = \sum_{i=1}^n (x_{i+1} - x_i) f(t_i)$, $x_1 = a$, $x_{n+1} = b$, $x_i \leq t_i \leq x_{i+1}$, cuando la partición en subintervalos se hace muy fina.

La integración, proceso inverso a la derivación, se basa en la idea de sumar todas las partes constituyentes de un todo.

Definición 2.32 Un **espacio de Lebesgue**, por Henri Léon Lebesgue, Francia 1875-1941, es el espacio vectorial de las *funciones al cuadrado integrables* en $\Omega \subset \mathbb{R}^n$, es

decir,

$$L^2(\Omega) = \left\{ f : \Omega \rightarrow \mathbb{R} \mid \int_{\Omega} |f|^2 < \infty \right\}.$$

El número 2 se refiere a la potencia del integrando.



Esta definición requiere la introducción de la *integral de Lebesgue* que extiende el concepto de integral de Riemann a clases o familias de funciones más amplias —por ejemplo, sucesiones de funciones, definidas en espacios más abstractos que $\mathbb{R}$ o $\mathbb{R}^n$, con más discontinuidades, etc.— y donde, en general, se pueda saber cómo y cuándo es posible tomar límites bajo el signo de la integral. La forma tradicional de explicitar gráficamente cómo se obtiene la integral de Riemann frente a la de Lebesgue se ve en la figura 2.7. En pocas palabras, la diferencia entre ambas integrales es que para la integral de Riemann interesan los valores que toma la función que está siendo integrada, mientras que en la integral de Lebesgue importa más el tamaño de subconjuntos en el dominio del integrando.




Figura 2.7: Integración de Riemann (izquierda-azul) e integración de Lebesgue (derecha-rojo)

También habría que definir el concepto de métrica, tamaño o medida de Lebesgue —una forma sistemática de asignar un número (no negativo) a cada subconjunto de un conjunto— y el *espacio de Lebesgue*.

Simplificadamente, si $\int_{\Omega} f(x) dx$ es la integral de Lebesgue de $f(x)$ y se define la norma $\|f\|_{L^p(\Omega)} = (\int_{\Omega} f^p dx)^{1/p}$, para $1 \leq p < \infty$, los espacios de Lebesgue son

$$L^p(\Omega) = \{f(x) : \|f\|_{L^p(\Omega)} < \infty\}.$$

El requerir que las funciones sean integrables no supone ninguna limitación importante en la práctica ingenieril o científica pues como hemos aprendido durante mucho tiempo toda función “continua a trozos”, es decir con a lo sumo una cantidad finita o numerable de discontinuidades, es integrable. El 99,99 % de las funciones que se utilizan en ingeniería, economía y ciencias sociales en general son integrables.

El espacio vectorial $L^2(\Omega)$ dotado del producto interior $\langle f, g \rangle = \int_{\Omega} f(x)g(x)dx$ es un espacio de Hilbert.

En el espacio $C[0, 1]$ de funciones continuas del intervalo $[0, 1]$ en $\mathbb{C}$, son normas las dadas por

$$\|f\|_p = \left[\int_0^1 |f(t)|^p dt \right]^{1/p}.$$

También en una norma la dada por

$$\|f\|_{\infty} = \max_{t \in [0,1]} |f(t)|.$$

Insistimos en la idea de que la norma $\|\cdot\|_2$ es la norma euclídea en $\mathbb{R}^n$, sustituyendo el sumatorio por una integral (recordemos que esta es la forma de pasar de *lo discreto* a *lo continuo*). Esto hace que los espacios de Lebesgue L^2 sean “buenos” y se caractericen porque son los únicos espacios vectoriales infinito dimensionales en los que siguen siendo válidos muchos de los aspectos de nuestra intuición espacial y geométrica habitual.

Desde el punto de vista físico, cuando $f(t)$ represente algún tipo de “señal”, la norma $\|f\|_2$ representará su energía, por lo que la condición $f \in L^2$ se interpretará como que la energía de f sea finita. En concreto, si $f(t)$ representa la tensión —voltage— de una onda electromagnética como función del tiempo, $f^2(t)$ es, salvo producto por una constante, su potencia, por lo que $\int_a^b f^2(t) dt$ será la energía de la onda en el intervalo temporal $[a, b]$. Pedir que f pertenezca a $L^2[a, b]$ equivale a pedir que f no sea demasiado discontinua (sea integrable en algún sentido) y que su energía sea finita en $[a, b]$.

Los espacios de funciones $L^p([0, 1])$, $p > 1$, con la norma

$$\|x\| = \left(\int_0^1 |x(t)|^p dt \right)^{1/p}, \text{ donde } x(t) \in L^2([0, 1]),$$

en los que si $y(t) \in L^p([0, 1])$ se cumple que

$$\left(\int_0^1 |x(t)|^p dt \right)^{1/p} < \infty$$

son también espacios normados. Casos particulares son $L^1([a, b])$ de funciones cuyo valor absoluto es integrable en $[a, b]$ y $L^2([a, b])$ de funciones al cuadrado integrables en $[a, b]$.

En particular, el conjunto de todas las funciones tales que

$$\int f^2(x) dx < \infty$$

con la distancia entre dos de ellas $f_1(x)$ y $f_2(x)$ definida por

$$\sqrt{\int (f_1(x) - f_2(x))^2 dx}$$

es el espacio métrico $L^2(\mathbb{R})$.

El *producto escalar* (producto interior) en un espacio de Lebesgue $L^2(\Omega)$ es

$$u * v = \langle u | v \rangle = \int_{\Omega} uv \, dx.$$

Definición 2.33 Un **espacio de Sobolev** —por Sergéi Lvóvich Sobolév, Rusia 1908-1989— es un espacio vectorial de funciones dotado de una norma que es combinación de normas L^p de la función y de sus derivadas hasta un orden dado. Formalmente para dos dimensiones es

$$W^{1,2}(\Omega) = \left\{ u \in L^2(\Omega) \left| \frac{\partial u}{\partial x_1}, \frac{\partial u}{\partial x_2} \in L^2(\Omega) \right. \right\}.$$

El número 1 se refiere al orden de las derivadas parciales y el 2 que las mismas deben pertenecer a $L^2(\Omega)$.



Las funciones que pertenecen a $W^{1,2}(\Omega)$ no tienen que ser derivables en todos los puntos; es suficiente que sean continuas con derivadas parciales continuas por tramos en el dominio de definición y que satisfagan las condiciones apuntadas. Esto se explicita en que las derivadas de este espacio se entienden en un *sentido débil* que hagan que el espacio sea completo —si toda sucesión de Cauchy en él tiene límite— y por lo tanto sea un espacio de Banach. En sentido débil no es sino una generalización del concepto de derivada a funciones no necesariamente derivables pero si integrables localmente en el sentido de Lebesgue en un dominio dado Ω de $L^p(\Omega)$.

La norma correspondiente de este espacio completo es

$$\|u\|_{W^{1,2}(\Omega)} = \left(\int_{\Omega} |\nabla u|^2 + \int_{\Omega} |u|^2 \right)^{1/2} = \left(\int_{\Omega} \left| \frac{\partial u}{\partial x_1} \right|^2 + \int_{\Omega} \left| \frac{\partial u}{\partial x_2} \right|^2 + \int_{\Omega} |u|^2 \right)^{1/2},$$

denominada en ingeniería *norma de energía*. Las funciones que usan esta forma finita son funciones de energía finita. Intuitivamente, un espacio de Sobolev es un espacio de funciones con derivadas de orden suficiente para un dominio de aplicación determinado y equipado con una norma que mida adecuadamente tamaño y regularidad en las funciones.

El *producto escalar* (producto interior) en un espacio de Sobolev $W^{1,2}(\Omega)$ es

$$u * v = \langle u | v \rangle = \int_{\Omega} uv \, dx + \int_{\Omega} \nabla u \cdot \nabla v \, dx.$$

3 | Matrices

Definición 3.1 Una **matriz** es una formación rectangular de números reales o complejos ordenados en m filas y n columnas

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

El conjunto de todas las matrices de números reales o complejos se designa, respectivamente, $\mathbb{R}^{m \times n}$ y $\mathbb{C}^{m \times n}$. Si $m = n$ la matriz es cuadrada y de orden n . Un vector columna es también una matriz $\mathbb{R}^{m \times 1}$, que se escribe $\mathbb{R}^m$.

Las matrices de m filas y n columnas con coeficientes en el cuerpo $\mathbb{R}$ o $\mathbb{C}$ forman un espacio vectorial, $\mathbb{R}^{m \times n}$ o $\mathbb{C}^{m \times n}$, sobre dichos cuerpos.

Todo lo que sigue en esta sección es material bastante estándar en libros de texto y monografías al respecto. En el apartado de referencias hay un buen número de ellas sobre matrices y álgebra matricial.

El primero en usar el término matriz en matemáticas fue James Joseph Sylvester, Reino Unido 1814-1897.



Arthur Cayley, Reino Unido 1821-1895,



contribuyó de forma decisiva a que $\mathbf{A} = (a_{ij})$ se concibiese como una cantidad algebraica única.

Si en álgebra lineal E y F son dos espacios vectoriales de dimensiones finitas n y m sobre el mismo cuerpo K . Una aplicación lineal $g : E \rightarrow F$, $g \in \mathcal{L}(E, F)$, está

caracterizada o representada en dos bases $\{e_1, e_2, \dots, e_n\}$ de E y $\{f_1, f_2, \dots, f_m\}$ de F por una tabla de coeficientes, *matriz* asociada, de m filas y n columnas:

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in K^{m \times n}.$$

Los coeficientes a_{ij} están definidos por

$$g(e_j) = \sum_{i=1}^m a_{ij} f_i, \quad 1 \leq j \leq n.$$

El vector columna j -ésimo

$$\begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{bmatrix}$$

representa el vector $g(e_j)$ en la base (f_i) . A partir de la matriz A se pueden calcular los coeficientes $y_1, y_2, \dots, y_m$ del vector $y = g(x)$ en la base (f_i) , conociendo los coeficiente $x_1, x_2, \dots, x_n$ en la base (e_j) . En efecto:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = x_1 \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{bmatrix}.$$

Expresión que también se puede escribir de la siguiente forma:

$$y = \sum_{i=1}^n x_i a_i,$$

donde a_i es el vector columna i -ésimo de la matriz A . Así pues, si se fijan dos bases en E y F , cada aplicación lineal, $g : E \rightarrow F$, queda unívocamente representada por una matriz. Recíprocamente, toda matriz en $K^{m \times n}$ define unívocamente una aplicación lineal entre dos espacios E y F de dimensiones n y m en los que se han fijado dos bases. En particular, se pueden identificar las matrices $m \times n$ con las aplicaciones lineales de K^n en K^m .

Las matrices de m filas y n columnas con coeficientes en el cuerpo K forman un espacio vectorial, $K^{m \times n}$, sobre dicho cuerpo K .

Si E y F son dos espacios de dimensión finita dotados de un producto escalar y la aplicación $\alpha \in \mathcal{L}(E, F)$ se representa en dos *bases ortonormalizadas* mediante una matriz A , la aplicación $\alpha^T \in \mathcal{L}(F, E)$, traspuesta de α , viene representada por la matriz A^T , traspuesta de A .

Definición 3.2 El **núcleo** y la **imagen** de una matriz $A \in K^{m \times n}$, $\ker(A)$ y $\text{Im}(A)$, respectivamente, se definen como los subespacios de K^n y K^m que son el núcleo y la imagen de la aplicación lineal asociada:

$$\left. \begin{aligned} \ker(A) &= \{x \in K^n : Ax = 0\} \\ \text{Im}(A) &= \{y \in K^m : y = Ax, x \in K^n\} \end{aligned} \right\}_{A \in K^{m \times n}}.$$

Dicho de otra forma, la imagen de una matriz es el subespacio generado por los vectores columna de la matriz; los vectores fila también generan un subespacio que no es otro que la imagen de A^T .

Para una matriz $A \in \mathbb{R}^{m \times n}$ se cumple que:

$$\begin{aligned} \ker(A^T) &= (\text{Im}(A))^\perp \\ \text{Im}(A^T) &= (\ker(A))^\perp \\ \ker(A) &= (\text{Im}(A^T))^\perp \\ \text{Im}(A) &= (\ker(A^T))^\perp. \end{aligned}$$

De acuerdo con esto, si $A \in \mathbb{R}^{m \times n}$, se cumple que

$$\ker(A) \oplus \text{Im}(A^T) = \mathbb{R}^n.$$

En la figura 3.1 se muestran estos subespacios.




Figura 3.1: Subespacios fundamentales determinados por $A^{m \times n}$

Definición 3.3 El **rango** de una matriz es la dimensión (máximo número de vectores linealmente independientes) de su subespacio imagen:

$$\text{rango}(A) = \dim(\text{Im}(A)).$$

Una matriz $A \in K^{m \times n}$ se dice de **rango completo** si $\text{rango}(A) = \min(m, n)$. Una matriz cuadrada $A \in K^{n \times n}$ se denomina **singular** si $\text{rango}(A) < n$; **regular** si $\text{rango}(A) = n$. También se cumple que $\text{rango}(A) = \text{rango}(A^T)$.

La aplicación asociada a una matriz $A \in \mathbb{R}^{m \times n}$ es suprayectiva cuando $\text{rango}(A) = m$. Para una matriz $A \in K^{m \times n}$ se cumple que

$$\dim(\ker(A)) + \text{rango}(A) = n,$$

o, alternativamente, $\dim(\ker(A)) = n - \text{rango}(A)$. La aplicación lineal asociada a A es, por tanto, inyectiva, si y sólo si $\text{rango}(A) = n$. Por otro lado $\dim(\ker(A^T)) + \text{rango}(A^T) = m$.

Definición 3.4 El **producto exterior** uv^T de un vector columna $n \times 1$ por un vector fila $1 \times n$ es una matriz $A^{n \times n}$ de rango 1,

$$A = uv^T = \begin{bmatrix} u_1 v_1 & u_1 v_2 & \cdots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \cdots & u_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ u_n v_1 & u_n v_2 & \cdots & u_n v_n \end{bmatrix}.$$

3.1 Normas de matrices

Aun cuando en gran parte de lo que sigue nos limitaremos a *matrices cuadradas*, la mayor parte de las definiciones y resultados son extensibles a matrices rectangulares; también supondremos que las matrices son reales.

Las matrices cuadradas de orden n forman un espacio vectorial con un producto, esto es, un *álgebra*.

Definición 3.5 Una **norma matricial** sobre $\mathbb{R}^{m \times n}$ es una aplicación $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ que cumple:

- 1) $\|A\| = 0 \implies A = 0$.
- 2) $\|\lambda A\| = |\lambda| \cdot \|A\|$.
- 3) $\|A + B\| \leq \|A\| + \|B\|$.
- 4) $\|AB\| \leq \|A\| \cdot \|B\|$.

Existen normas sobre el espacio $\mathbb{R}^{m \times n}$ que no son normas matriciales pues no cumplen la propiedad 4). Así, si se define

$$\|A\| = \max_{1 \leq i, j \leq n} |a_{ij}|,$$

se satisfacen 1), 2) y 3); sin embargo, tomando $A = B = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ es fácil ver que $\|AB\| = 2 > \|A\| \cdot \|B\| = 1$, por lo que no se cumple 4).

Definición 3.6 La norma de Frobenius es la dada por

$$\|A\|_F^2 = \sum_{1 \leq i, j \leq n} a_{ij}^2 = \text{traza}(A^T A),$$

donde la *traza* de una matriz A de orden n es $\sum_{i=1}^n a_{ii}$. La norma de Frobenius cumple que

$$\|AB\|_F \leq \|A\|_F \cdot \|B\|_F.$$

Toma su nombre de Ferdinand Georg Frobenius, Alemania 1849-1917.



Es fácil ver que esta norma deriva del producto escalar

$$\langle A | B \rangle = \text{traza}(A^T B) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij},$$

para $A^{m \times n}$ y $B^{m \times n}$, que configura al espacio de las matrices $m \times n$ como un espacio prehilbertiano. El producto escalar en el espacio $\mathbb{S}^n$ de las matrices simétricas $n \times n$ está dado por

$$\langle X | Y \rangle = \text{traza}(XY) = \sum_{i=1}^n \sum_{j=1}^n x_{ij} y_{ij} = \sum_{i=1}^n a_{ii} b_{ii} + 2 \sum_{i < j} a_{ij} b_{ij}.$$

Definición 3.7 Una norma matricial $\|\cdot\|$ sobre $\mathbb{R}^{m \times n}$ se dice **consistente** o compatible con una norma vectorial $\|\cdot\|'$ sobre $\mathbb{R}^n$ cuando para cada matriz A y cada vector x se cumple que

$$\|Ax\|' \leq \|A\| \cdot \|x\|'.$$

Por ejemplo, la norma de Frobenius y la norma euclídea de $\mathbb{R}^n$ son consistentes pues

$$\|Ax\|_2 \leq \|A\|_F \cdot \|x\|_2.$$

Se demuestra que para toda norma matricial es posible construir una norma vectorial consistente. Recíprocamente, a toda norma vectorial sobre $\mathbb{R}^n$ se le puede asociar una norma matricial consistente. Una norma matricial consistente con una cierta norma vectorial $\|\cdot\|$ se construye mediante la definición

$$\|A\| = \sup_{0 \neq x \in \mathbb{R}^n} \frac{\|Ax\|}{\|x\|}.$$

Esta norma matricial se dice *inducida* por la norma vectorial.

Definición 3.8 La norma matricial inducida por la norma euclídea de $\mathbb{R}^n$ es la *norma espectral*:

$$\|A\|_2 = \sup_{\mathbf{0} \neq \mathbf{x} \in \mathbb{R}^n} \left[\frac{\mathbf{x}^T A^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \right]^{1/2} = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A),$$

donde λ designa un valor propio de A y σ un valor singular.

Si $\|\cdot\|$ es la norma inducida por una cierta norma vectorial y $\|\cdot\|'$ es una norma matricial cualquiera consistente con esa norma vectorial, se cumple, para toda matriz A , que $\|A\| \leq \|A\|'$. En particular, para la norma espectral y la norma de Frobenius, se cumple que

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{n} \|A\|_2.$$

También que $\|AB\|_F \leq \|A\|_F \cdot \|B\|_2$ y $\|AB\|_F \leq \|A\|_2 \cdot \|B\|_F$. Como casos particulares, $\|I\|_2 = 1$ y para una matriz diagonal, $\|D\|_2 = \max_i |d_i|$.

Las normas matriciales inducidas más usadas son

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad \text{y}$$

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

Ejemplo 3.1 El efecto que produce aplicar la transformación lineal basada en la matriz

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$$

sobre la bola unidad, explicado a partir de las normas $\|\cdot\|_1$, $\|\cdot\|_2$ y $\|\cdot\|_\infty$ en $\mathbb{R}^2$, se representa en la figura 3.2.

La aplicación transforma el vector $\mathbf{e}_1 = [1, 0]^T$ en sí mismo y $\mathbf{e}_2 = [0, 1]^T$ en $[2, 2]^T$. Con la norma 1, el vector unitario que más se amplifica al aplicarle la transformación es $[0, 1]^T$ (o $[0, -1]^T$), que pasa a ser $[2, 2]^T$. Su factor de amplificación, en términos de la norma 1, es 4.

Con la norma 2, el vector unitario que más se amplifica es el que se representa en la figura con una recta discontinua. El factor de amplificación es 2,9208.

Para la norma ∞ , igualmente, el vector unitario que más se amplifica es el que se representa también con la recta discontinua: $[1, 1]^T$, que pasa a transformarse en $[3, 2]^T$. El factor de amplificación correspondiente es en este caso 3 ya que

$$\|[1, 1]^T\|_\infty = 1$$

$$\|[3, 2]^T\|_\infty = 3.$$






Figura 3.2: Efecto de una aplicación lineal sobre la bola unidad para diferentes normas

Además de las normas vectoriales y matriciales ya presentadas, otra norma vectorial muy utilizada es

$$\|x\|_A = \|A^{1/2}x\|_2 = \sqrt{\langle Ax|x \rangle} = \sqrt{x^T A x},$$

denominada *norma A* o *norma de energía* —pues suele corresponder con la energía física de ciertos sistemas— del vector x , para una matriz A simétrica y definida positiva. Al resultado de $\langle x|y \rangle_A = \langle Ax|y \rangle$ se le denomina *producto interior de A* o *producto escalar de energía*. La matriz $A^{1/2}$ es la única matriz definida positiva solución de la ecuación matricial $X^2 = X \cdot X = A$.

3.2 Matrices interesantes

Definición 3.9 Una $Q \in \mathbb{R}^{m \times n}$ es una **matriz ortogonal** si verifica que $Q^T Q = I$; es decir, cuando sus vectores columna son ortogonales dos a dos y de norma euclídea unitaria (ortonormales). Si $Q \in \mathbb{R}^{n \times n}$ es ortogonal, se cumple que $Q Q^T = Q^T Q = I$.

Una matriz ortogonal no modifica ni los ángulos ni las normas de los vectores a los que se aplica la transformación que representan: $(Qx)^T (Qy) = x^T Q^T Q y = x^T y$. Si $y = x$, $\|Qx\|_2 = \|x\|_2$.

Las matrices ortogonales $\mathbf{Q} \in \mathbb{R}^{m \times n}$ verifican:

$$\left. \begin{array}{l} \|\mathbf{Q}\|_2 = 1 \\ \|\mathbf{Q}\|_F = n^{1/2} \\ \|\mathbf{Q}\mathbf{A}\|_2 = \|\mathbf{A}\|_2 \\ \|\mathbf{Q}\mathbf{A}\|_F = \|\mathbf{A}\|_F \end{array} \right\} \quad \text{si } m \geq n \quad y \quad \left. \begin{array}{l} \|\mathbf{Q}\|_2 = 1 \\ \|\mathbf{Q}\|_F = m^{1/2} \\ \|\mathbf{A}\mathbf{Q}\|_2 = \|\mathbf{A}\|_2 \\ \|\mathbf{A}\mathbf{Q}\|_F = \|\mathbf{A}\|_F \end{array} \right\} \quad \text{si } m \leq n.$$

La extensión de las matrices ortogonales al campo complejo son las matrices *unitarias*.

Definición 3.10 Una matriz $\mathbf{U} \in \mathbb{C}^{n \times n}$, cuya inversa es su compleja conjugada, $\mathbf{U}^H \mathbf{U} = \mathbf{U} \mathbf{U}^H = \mathbf{I}$, es una **matriz unitaria**

Todos los valores propios de las matrices unitarias tienen módulo unidad. Como las ortogonales, una matriz unitaria no modifica ni los ángulos ni las normas, $(\mathbf{U}\mathbf{x})^H (\mathbf{U}\mathbf{y}) = \mathbf{x}^H \mathbf{U}^H \mathbf{U} \mathbf{y} = \mathbf{x}^H \mathbf{y}$. Si $\mathbf{y} = \mathbf{x}$, $\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2$.

Definición 3.11 Una **matriz de permutación** es una matriz cuadrada cuyas columnas están formadas por las de la matriz unidad permutadas. Una matriz de permutación es una matriz ortogonal.

Definición 3.12 Una matriz se dice **simétrica** si se verifica que $\mathbf{A} = \mathbf{A}^T$. Para una matriz cualquiera $\mathbf{A} \in \mathbb{R}^{m \times n}$, la matriz $\mathbf{A}^T \mathbf{A}$ es simétrica. Si $\mathbf{A} \in \mathbb{C}^{n \times n}$ es igual a su traspuesta conjugada, $\mathbf{A} = \mathbf{B} = \mathbf{A}^H$, $b_{ij} = \bar{a}_{ji}$, se dice **hermítica**. El conjunto de las matrices simétricas $n \times n$ se designa mediante $\mathbb{S}^n$.

Definición 3.13 Una matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ se dice **definida positiva** si es simétrica y $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$ para todo vector $\mathbf{x} \neq \mathbf{0}$. Se designa como $\mathbf{A} > 0$. De forma similar se definen matrices **semidefinida positiva**, $\mathbf{A} \geq 0$, **definida negativa**, $\mathbf{A} < 0$ y **semidefinida negativa**, $\mathbf{A} \leq 0$, si $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$, < 0 y ≤ 0 , respectivamente, para todo vector $\mathbf{x} \neq \mathbf{0}$. La matriz $\mathbf{A}$ se dice **indefinida** si $\mathbf{x}^T \mathbf{A} \mathbf{x}$ es positivo para algún $\mathbf{x}$ y negativo para otros.

También $\mathbf{A} \in \mathbb{C}^{n \times n}$ se dice definida positiva si es hermítica y para todo $\mathbf{x} \in \mathbb{C}^n$, $\mathbf{x} \neq \mathbf{0}$, se cumple que $\mathbf{x}^* \mathbf{A} \mathbf{x} > 0$.

El conjunto de matrices $n \times n$ definidas positivas se designa por $\mathbb{S}_{++}^n$ y el de semidefinidas positivas, o no negativas definidas, por $\mathbb{S}_{+}^n$.

Si $\mathbf{A} \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva se puede descomponer de la forma $\mathbf{A} = \mathbf{Q} \mathbf{D} \mathbf{Q}^T$ donde $\mathbf{Q}$ es una matriz ortogonal y $\mathbf{D}$, diagonal, tiene todos sus coeficientes positivos por lo que $\mathbf{A}^{\frac{1}{2}} = \mathbf{Q} \mathbf{D}^{\frac{1}{2}} \mathbf{Q}^T$ satisfaciéndose que $\mathbf{A}^{\frac{1}{2}} \mathbf{A}^{\frac{1}{2}} = \mathbf{A}$.

Definición 3.14 Se dice que una matriz $A \in \mathbb{C}^{n \times n}$ de coeficientes a_{ij} es de **diagonal dominante** por filas cuando cumple que

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, \dots, n.$$

Análogamente, se dice diagonal dominante por columnas si

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ji}|, \quad i = 1, \dots, n.$$

Si las desigualdades se verifican estrictamente la matriz A se denomina **diagonal estrictamente dominante**.

Lema 3.1 Para que una matriz simétrica sea definida positiva es necesario que todos los coeficientes de la diagonal principal sean positivos.

Lema 3.2 Para que una matriz simétrica A sea definida positiva es necesario que el coeficiente de mayor valor absoluto esté en la diagonal principal. Más concretamente, $\max_{i \neq j} |a_{ij}| < \max_k a_{kk}$.

Lema 3.3 Si en cada fila de una matriz simétrica A el coeficiente de la diagonal principal es mayor que la suma de los valores absolutos de todos los demás coeficientes de la fila, es decir, si

$$a_{kk} > \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \quad k = 1, \dots, n,$$

A es definida positiva.

Es importante destacar que este último criterio define una condición suficiente, no necesaria. En efecto, la matriz $Q = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}$ es definida positiva pues

$$\mathbf{x}^T Q \mathbf{x} = x_1^2 + x_2^2 + x_3^2 + 2(x_1 + x_2 + x_3)^2,$$

cualquiera que sea $\mathbf{x} \neq \mathbf{0}$, es siempre positiva. Esa matriz, sin embargo, no satisface el lema 3.2.

Definición 3.15 Una **matriz de Vandermonde** es una matriz que presenta una progresión geométrica en cada fila; como esta:

$$V = \begin{bmatrix} 1 & \alpha_1 & \alpha_1^2 & \dots & \alpha_1^{n-1} \\ 1 & \alpha_2 & \alpha_2^2 & \dots & \alpha_2^{n-1} \\ 1 & \alpha_3 & \alpha_3^2 & \dots & \alpha_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \alpha_n & \alpha_n^2 & \dots & \alpha_n^{n-1} \end{bmatrix}.$$

Su nombre se debe a Alexandre-Théophile Vandermonde, Francia 1735-1796.


Definición 3.16 Una **matriz de Hankel** es una matriz cuadrada con todas sus diagonales de derecha a izquierda paralelas numéricamente. Es decir, tiene la forma

$$H = \begin{bmatrix} a & b & c & d & e \\ b & c & d & e & f \\ c & d & e & f & g \\ d & e & f & g & h \\ e & f & g & h & i \end{bmatrix}.$$

El primero que formuló esta matriz fue Hermann Hankel, Alemania 1839-1873.



Definición 3.17 Una **matriz de Hessenberg** es una matriz triangular excepto por una subdiagonal adyacente a la diagonal principal.



Fue formulada por primera vez por Karl Adolf Hessenberg, Alemania 1904-1959.



Cualquier matriz se puede reducir a la forma de *Hessenberg* mediante transformaciones ortogonales de *Householder* o *Givens*. Si la matriz original es *simétrica*, al reducirla a la forma de *Hessenberg* se obtendrá una *tridiagonal*.

Definición 3.18 Se denomina **proyector** o **matriz de proyección** a una matriz $P \in \mathbb{R}^{n \times n}$ que verifica que $P^2 = P$. Si P además es simétrica, se denomina **proyector ortogonal** o **matriz de proyección ortogonal**. Si, en este último caso, F es el subespacio imagen de la matriz P (el mismo que el de la matriz P^T), Px define la *proyección ortogonal* del vector x sobre F .

Definición 3.19 Se denomina **proyector suplementario** de P al proyector $S = I - P$. Si $F = \text{Im}(P)$ y $G = \text{ker}(P)$, entonces $F = \text{ker}(S)$ y $G = \text{Im}(S)$.

En el caso de un proyector ortogonal P en el que $F = \text{Im}(P)$, se tiene que $\mathbb{R}^n = F \oplus F^\perp$, verificándose que $\|Px\|_2 \leq \|x\|_2$ y que

$$\|x - Px\|_2 = \min_{y \in \text{Im}(P)=F} \|x - y\|_2.$$

3.3 Valores propios, valores singulares y formas cuadráticas

3.3.1 Valores propios

Definición 3.20 Si A es una matriz cuadrada de orden n y coeficientes en K ($\mathbb{R}$ o $\mathbb{C}$), un vector no nulo $u \in K^n$ se denomina **vector propio** de A si para algún $\lambda \in K$ se cumple que

$$Au = \lambda u.$$

A este λ se le denomina **valor propio** o *autovalor* de la matriz A . El conjunto de los valores propios de una matriz A se denomina **espectro** de A , designándose por $\Lambda(A)$. El **radio espectral**, $\rho(A)$, se define de la siguiente manera:

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|.$$

Para que un número λ sea valor propio de A , el sistema lineal y homogéneo de ecuaciones dado por $(\lambda I - A)x = 0$ debe tener soluciones distintas de la trivial $x = 0$. Esto equivale a que

$$\det(A - \lambda I) = 0.$$

Esta es una ecuación polinómica de grado n en λ que se denomina *ecuación característica*, o *polinomio característico*, de la matriz A . La ecuación característica admite la raíz $\lambda = 0$ si y sólo si $\det(A) = 0$. Una matriz es invertible, por tanto, si y sólo si no admite al cero como vector propio.

Para que exista una solución distinta de la trivial $x = 0$, el valor propio λ deberá ser raíz del *polinomio característico* de grado n asociado a A , esto es $\det(A - \lambda I) = 0$. Lo que es igual a $\lambda^n + g_1\lambda^{n-1} + g_2\lambda^{n-2} + \dots + g_n = 0$.

El *Teorema fundamental del álgebra* establece que cada ecuación polinómica de grado n , con coeficientes complejos, tiene n raíces en el cuerpo de los complejos.

La *multiplicidad algebraica* del valor propio λ de A es la multiplicidad de la raíz correspondiente del polinomio característico asociado a A . La *multiplicidad geométrica* de λ es el número de vectores propios linealmente independientes que se corresponden con λ . La multiplicidad geométrica de un valor propio es menor o igual que su multiplicidad algebraica.

Por ejemplo, si $A = I$, $\lambda = 1$ es un valor propio con multiplicidad algebraica y geométrica n . El polinomio característico de A es $p(z) = (z - 1)^n$ y $e_i \in \mathbb{C}^n$, $i = 1, \dots, n$, sus vectores propios. Si el valor propio λ tiene una multiplicidad geométrica menor que la algebraica, se dice *defectuoso*. Se dice que una matriz es defectuosa si tiene al menos un valor propio defectuoso. La matriz $\begin{bmatrix} 2 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & 2 \end{bmatrix}$ tiene un valor propio, 2, de multiplicidad algebraica 3 y multiplicidad geométrica 1; $u = [100]^T$. Si una matriz $A \in \mathbb{C}^{n \times n}$ no es defectuosa, dispone de un conjunto de n vectores propios linealmente independientes.

Un resultado interesante debido a dos matemáticos del siglo XIX, Arthur Cayley, Reino Unido 1821-1895, y William Rowan Hamilton, Irlanda 1805-1865,



dice que cualquier matriz $A \in \mathbb{C}^{n \times n}$ satisface su propia ecuación característica. Es decir,

$$A^n + g_1 A^{n-1} + g_2 A^{n-2} + \dots + g_n I = 0.$$

Si A es invertible, como consecuencia de ello,

$$A^{-1} = -\frac{1}{g_n} A^{n-1} - \frac{g_1}{g_n} A^{n-2} - \dots - \frac{g_{n-1}}{g_n} I.$$


A partir del teorema de Cayley-Hamilton también es fácil comprobar que existe un polinomio p de grado máximo $n - 1$ tal que $A^{-1} = p(A)$. Como ejemplo, la matriz $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ tiene como polinomio característico $x^2 - 5x - 2$. El teorema de Cayley-Hamilton dice que $A^2 - 5A - 2I = 0$, lo cual se puede comprobar inmediatamente. La inversa de A se puede obtener de esta ecuación a partir de $A(A - 5I) = 2I$. En efecto, $A^{-1} = \frac{1}{2}(A - 5I)$.

Definición 3.21 Para $A \in \mathbb{C}^{n \times n}$ y $0 \neq b \in \mathbb{C}^{n \times 1}$, al subespacio

$$\mathcal{K}_j(A, b) = \text{Gen}\{b, Ab, \dots, A^{j-1}b\}$$

se le denomina **subespacio de Krylov**.

Estos subespacios deben su nombre y formulación al trabajo de Alekséi Nikoláyevich Krylov, Rusia 1863-1945.



Igual que cualquier matriz tiene asociado un polinomio característico, cualquier polinomio tiene asociado una *matriz compañera*.

Un polinomio $a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ se dice que es mónico si $a_n = 1$.

La matriz compañera de un *polinomio mónico* $p(t) = c_0 + c_1t + \dots + c_{n-1}t^{n-1} + t^n$ es

$$C(p) = \begin{bmatrix} 0 & 0 & \dots & 0 & -c_0 \\ 1 & 0 & \dots & 0 & -c_1 \\ 0 & 1 & \dots & 0 & -c_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & -c_{n-1} \end{bmatrix}$$

Los valores propios de esta matriz $C(p)$ son las raíces del polinomio $p(t)$. El *polinomio mínimo* $q(t)$ de una matriz A es el polinomio mónico único de grado mínimo tal que $q(A) = 0$.

Una matriz real de orden n no tiene necesariamente valores propios reales pero, como consecuencia del teorema fundamental del álgebra, cualquier matriz compleja tiene al menos un valor propio complejo. Su número máximo de valores propios es n .

Proposición 3.4 *Al aplicársele a cualquier vector la transformación que representa A ese vector tiende a orientarse en la dirección del vector propio dominante de A . Si aquel vector está en la dirección de alguno de los vectores propios de A , se expande o contrae por un factor que determina el correspondiente valor propio.*

La matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ tiene como valores propios 3 y 1. Los vectores propios asociados son $[1 \ 1]^T$ y $[-1 \ 1]^T$. El efecto de aplicarla sobre distintos vectores se puede ver en la figura 3.3: en magenta y azul (en grises con mayor o menor intensidad) los vectores propios; otros en rojo que si se orientan.

Siendo λ un valor propio de una matriz A , el conjunto de soluciones del sistema de ecuaciones

$$(\lambda I - A)x = 0$$

es un subespacio de K^n que se denomina *subespacio propio* asociado al valor propio λ , designándose con E_λ . Si n_λ es la multiplicidad de λ como raíz de la ecuación característica de A , se cumple que

$$\dim(E_\lambda) \leq n_\lambda.$$

La intersección de subespacios propios correspondientes a valores propios distintos se reduce al subespacio nulo; esto es $\lambda \neq \mu \implies E_\lambda \cap E_\mu = \emptyset$.




Figura 3.3: Efecto de aplicársele a diversos vectores la transformación que representa la matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

De este modo, la suma de subespacios propios es directa. Se cumple que $\bigoplus_{\lambda \in \Lambda(A)} E_\lambda = K^n$ si y sólo si para cada $\lambda \in \Lambda(A)$, $\dim(E_\lambda) = n_\lambda$; en ese caso existe una base de K^n formada toda ella por vectores propios de A .

El teorema central en el estudio de los métodos y algoritmos numéricos para el cálculo y análisis de valores y vectores propios es el de la descomposición de Schur —por Issai Schur, Alemania 1875-1941—.



Teorema 3.5 *Descomposición o triangularización de Schur. Para cualquier $A \in \mathbb{C}^{n \times n}$ existe una matriz unitaria U y una matriz triangular superior, T , tal que*

$$AU = UT \quad \text{o} \quad U^H AU = T.$$

Los valores propios de A son los coeficientes de la diagonal principal de R .

Teorema 3.6 *Para cualquier matriz hermítica $A \in \mathbb{C}^{n \times n}$ existe una matriz unitaria U tal que*

$$U^H AU = D,$$

donde D es una matriz diagonal.

1. *Los valores propios de A son números reales.*
2. *Se pueden obtener vectores propios de A que sean ortonormales.*

En este caso se dice que la matriz A es *semejante* a una matriz diagonal: la matriz A

es *diagonalizable por semejanza*. Dos matrices semejantes tienen el mismo polinomio característico y los mismos valores propios. Una matriz $A \in \mathbb{C}^{n \times n}$ es normal, es decir $AA^H = A^H A$, si y sólo si $A = U \Lambda U^H$, donde U es una matriz unitaria y Λ una diagonal cuyos coeficientes son los valores propios de A . Los vectores propios son los vectores columna de U .

Teorema 3.7 Toda matriz real y simétrica tiene todos sus valores propios reales y es diagonalizable por semejanza. Se demuestra además que los subespacios propios correspondientes a valores propios distintos son ortogonales. De aquí se sigue que es siempre posible formar una base ortonormalizada de vectores propios para una matriz real y simétrica A . Existe entonces una matriz ortogonal Q tal que verifica $Q^T A Q = D$, con $Q^T = Q^{-1}$ y, de aquí que, toda matriz real y simétrica es congruente ortogonal con su reducida diagonal. Este resultado fundamental de la teoría de matrices es la versión para matrices simétricas del denominado **Teorema espectral**. Da lugar a la **Descomposición espectral** de A .

Teorema 3.8 Descomposición de Jordan. Para una matriz $A \in \mathbb{C}^{n \times n}$ existe una matriz regular $X \in \mathbb{C}^{n \times n}$ tal que $X^{-1} A X = \text{diag}(J_1, \dots, J_k)$ donde

$$J_i = \begin{bmatrix} \lambda_i & 1 & & 0 \\ & \lambda_i & 1 & \\ & & \ddots & \\ 0 & & & \lambda_i \end{bmatrix} \in \mathbb{C}^{n_i \times n_i}$$

y $n_1 + \dots + n_k = n$. Las J_i son las matrices o bloques de Jordan y los λ_i los valores propios de A .

Debe su nombre a Marie Ennemond Camille Jordan, Francia 1838-1922.



Una matriz simétrica definida positiva tiene todos sus valores propios reales y positivos; si es semidefinida, alguno es cero. Si la matriz es negativa definida, todos sus valores propios son negativos.

Si A es hermítica, el producto $x^H A x$ es un número real. Los *valores propios* de una *matriz hermítica*, en consecuencia, son *números reales*. En una matriz hermítica los vectores propios correspondientes a dos valores propios distintos son ortogonales entre sí.

Un resultado importante para averiguar el orden de magnitud de los valores propios de una matriz es el que sigue.

Teorema 3.9 De Geršgorin. Los valores propios de una matriz $A \in \mathbb{C}^{n \times n}$ se encuentran en la unión de los n discos de Gershgorin, cada uno de los cuales está centrado en a_{kk} , $k = 1, \dots, n$, y tiene de radio

$$r_k = \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|.$$

Fue formulado por Semyon Aranovich Geršgorin, Rusia, 1901-1933.



Demostración. Sea λ un valor propio de A y $\mathbf{x}$ su vector propio asociado. De $A\mathbf{x} = \lambda\mathbf{x}$ y $(\lambda I - A)\mathbf{x} = \mathbf{0}$ se tiene que

$$(\lambda - a_{kk})x_k = \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}x_j, \quad k = 1, \dots, n,$$

donde x_k es el componente k -ésimo del vector $\mathbf{x}$.

Si x_i es el coeficiente de $\mathbf{x}$ más grande en valor absoluto, como $|x_j|/|x_i| \leq 1$ para $j \neq i$, se tiene que

$$|\lambda - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|.$$

Luego λ está contenido en el disco $\{\lambda : |\lambda - a_{ii}| \leq r_i\}$. □

Teorema 3.10 Sea A una matriz simétrica $n \times n$. Las siguientes propiedades de A son equivalentes.

$$A \succeq 0.$$

$$A \succ 0.$$

$$\lambda(A) \geq 0.$$

$$\lambda(A) > 0.$$

$A = D^T D$ para alguna D rectangular.

$A = D^T D$ para alguna D rectangular de rango n .

$A = \Delta^T \Delta$ para alguna $\Delta^{n \times n}$ triangular superior.

$A = \Delta^T \Delta$ para alguna $\Delta^{n \times n}$ triangular superior no degenerada.

$A = B^2$ para alguna B simétrica.

$A = B^2$ para alguna B simétrica no degenerada.

$A = B^2$ para alguna $B \succeq 0$.

$A = B^2$ para alguna $B \succ 0$.

3.3.2 Valores singulares

La noción de valor propio, o autovalor, no tiene significado para matrices rectangulares. En éstas, por el contrario, si lo tiene, como en las cuadradas, el concepto de *valor singular*.

Definición 3.22 Si A es una matriz cualquiera $m \times n$ con coeficientes en $\mathbb{R}$, se definen sus **valores singulares** $\sigma_i, i = 1, \dots, \min\{m, n\}$, como las raíces cuadradas positivas de los valores propios de la matriz cuadrada $A^T A \in \mathbb{R}^{n \times n}$.

Definición 3.23 Los valores singulares de A son las longitudes de los semiejes del hiperelipsoide E definido, a partir de la esfera unidad y el operador A , por

$$E = \{y : y = Ax, \|x\|_2 = 1\}.$$

En la figura 3.4 se describe gráficamente el caso en que $m = n = 2$.




Figura 3.4: Representación en dos dimensiones de una transformación lineal de la esfera unidad

Teorema 3.11 *Descomposición en valores singulares.* Si $A \in \mathbb{R}^{m \times n}$ es una matriz de rango r existen matrices ortogonales $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ tales que

$$A = U \Sigma V^T,$$

donde $\Sigma = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix}$, $\Sigma \in \mathbb{R}^{m \times n}$ y $\Sigma_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$. Si las matrices U y V se escriben como $U = [u_1, \dots, u_m]$ y $V = [v_1, \dots, v_n]$, los u_i y v_i son los vectores singulares izquierdos y derechos, respectivamente, correspondientes a los valores singulares $\sigma_i, i = 1, \dots, r$.

Demostración. Sean $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dos vectores tales que

$$\|x\|_2 = \|y\|_2 = 1 \quad \text{y} \quad Ax = \sigma y, \quad \text{con} \quad \sigma = \|A\|_2.$$

La existencia de estos vectores $\mathbf{x}$ e $\mathbf{y}$ está garantizada por la definición de $\|\mathbf{A}\|_2$.

Sean las dos matrices ortogonales

$$\mathbf{V} = [\mathbf{x} \ \mathbf{V}_1] \in \mathbb{R}^{n \times n} \quad \text{y} \quad \mathbf{U} = [\mathbf{y} \ \mathbf{U}_1] \in \mathbb{R}^{m \times m}$$

(siempre es posible ampliar un conjunto de vectores ortogonales hasta formar una base ortonormal de $\mathbb{R}^n$). Como $\mathbf{U}_1^T \mathbf{A} \mathbf{x} = \sigma \mathbf{U}_1^T \mathbf{y} = \mathbf{0}$, la matriz $\mathbf{U}^T \mathbf{A} \mathbf{V}$ tiene la siguiente estructura:

$$\mathbf{A}_1 = \mathbf{U}^T \mathbf{A} \mathbf{V} = \begin{bmatrix} \mathbf{y}^T \\ \mathbf{U}_1^T \end{bmatrix} \mathbf{A} [\mathbf{x} \ \mathbf{V}_1] = \begin{bmatrix} \sigma & \mathbf{w}^T \\ \mathbf{0} & \mathbf{B} \end{bmatrix},$$

donde $\mathbf{B} = \mathbf{U}_1^T \mathbf{A} \mathbf{V}_1 \in \mathbb{R}^{(m-1) \times (n-1)}$ y $\mathbf{w}^T = \mathbf{y}^T \mathbf{A} \mathbf{V}_1$. Dado que $\|\mathbf{A}_1 [\frac{\sigma}{\mathbf{w}}]\|_2 = \left\| \begin{bmatrix} \sigma^2 + \mathbf{w}^T \mathbf{w} \\ \mathbf{B} \mathbf{w} \end{bmatrix} \right\|_2 \geq \sigma^2 + \mathbf{w}^T \mathbf{w}$, como

$$\|\mathbf{A}_1 [\frac{\sigma}{\mathbf{w}}]\|_2 \leq \|\mathbf{A}_1\|_2 \|\frac{\sigma}{\mathbf{w}}\|_2 = \|\mathbf{A}_1\|_2 \sqrt{(\sigma^2 + \mathbf{w}^T \mathbf{w})^2},$$

se cumple que $\|\mathbf{A}_1\|_2 \geq (\sigma^2 + \mathbf{w}^T \mathbf{w})^{1/2}$. Como las matrices $\mathbf{U}$ y $\mathbf{V}$ son ortogonales, $\|\mathbf{A}_1\|_2 = \|\mathbf{A}\|_2 = \sigma$ y por consiguiente $\mathbf{w} = \mathbf{0}$. La argumentación de la demostración se completa por inducción. $\square$

La matriz $\mathbf{A}^{m \times n} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$, de rango r , se puede escribir como la suma de r matrices de rango uno así

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T,$$

donde los $\mathbf{u}_i$ y $\mathbf{v}_i$ son los vectores columna i -ésimos de $\mathbf{U}$ y $\mathbf{V}$.

La mejor aproximación de $\mathbf{A}$ de rango $p \leq r$, en el sentido de mínimos cuadrados, se obtiene de la suma de los primeros p términos de esta última suma. Por ejemplo — de Sauer [2013]—, el mejor subespacio de dimensión uno de los puntos $[3, 2]$, $[2, 4]$, $[-2, -1]$ y $[-3, -5]$ en el sentido de mínimos cuadrados se obtiene de

$$\begin{aligned} \mathbf{A} &= \begin{bmatrix} 3 & 2 & -2 & -3 \\ 2 & 4 & -1 & -5 \end{bmatrix} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \\ &= \begin{bmatrix} 0,5886 & -0,8084 \\ 0,8084 & 0,5886 \end{bmatrix} \begin{bmatrix} 8,2809 & 0 & 0 & 0 \\ 0 & 1,8512 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0,4085 & 0,5327 & -0,2398 & -0,7014 \\ -0,6741 & 0,3985 & 0,5554 & -0,2798 \\ 0,5743 & -0,1892 & 0,7924 & -0,0801 \\ 0,2212 & 0,7223 & 0,0780 & 0,6507 \end{bmatrix}. \end{aligned}$$

Como $p = 1$, la mejor aproximación de $\mathbf{A}$ es $\mathbf{u}_1 = [0,5886, 0,8084]$. Del sumatorio anterior, haciendo $\sigma_2 = 0$,

$$\begin{aligned} \mathbf{A}_1 &= \begin{bmatrix} 0,5886 & -0,8084 \\ 0,8084 & 0,5886 \end{bmatrix} \begin{bmatrix} 8,2809 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0,4085 & 0,5327 & -0,2398 & -0,7014 \\ -0,6741 & 0,3985 & 0,5554 & -0,2798 \\ 0,5743 & -0,1892 & 0,7924 & -0,0801 \\ 0,2212 & 0,7223 & 0,0780 & 0,6507 \end{bmatrix} \\ &= \begin{bmatrix} 1,9912 & 2,5964 & -1,1689 & -3,4188 \\ 2,7364 & 3,5657 & -1,6052 & -4,6951 \end{bmatrix}. \end{aligned}$$

El proceso se esquematiza en la figura 3.5.




Figura 3.5: Proyección de cuatro vectores en el subespacio de dimensión uno que mejor los representa: recta de trazos

Dada la descomposición en valores singulares de A , de rango r , los vectores singulares a la izquierda $\{u_1, \dots, u_r\}$ conforman una base ortonormal de $\text{Im}(A)$ y los restantes, $\{u_{r+1}, \dots, u_m\}$, otra base ortonormal de $\ker(A^T)$. Igualmente, $\{v_{r+1}, \dots, v_n\}$ es una base ortonormal de $\ker(A)$ y $\{v_1, \dots, v_r\}$ una base ortonormal de $\text{Im}(A^T)$.

Definición 3.24 El **número de condición** de una matriz es la relación entre sus valores singulares mayor y menor. Una matriz se dice mal condicionada si ese número es grande o muy grande. Una matriz singular tiene un número de condición infinito.

Definición 3.25 Si A es una matriz $n \times n$, $|\det(A)| = \sigma_1 \cdot \sigma_2 \cdots \sigma_n$. Para una matriz $A \in \mathbb{R}^{m \times n}$ cuya descomposición en valores singulares es $A = U \Sigma V^T$, se define su **matriz pseudoinversa**, $A^\dagger$, como

$$A^\dagger = V \Sigma^\dagger U^T,$$

donde

$$\Sigma^\dagger = \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}, 0, \dots, 0) \in \mathbb{R}^{n \times m}.$$

Si $A \in \mathbb{R}^{m \times n}$ es de rango completo y $m > n$, $A^\dagger = (A^T A)^{-1} A^T$; si $m < n$, $A^\dagger = A^T (A A^T)^{-1}$.

Para cualquier matriz $A \in \mathbb{R}^{m \times n}$, la matriz $A^\dagger A$ es la matriz $n \times n$ de proyección ortogonal sobre el subespacio de los vectores fila de A , $A A^\dagger$ la $m \times m$ de proyección ortogonal sobre la imagen de la matriz A (subespacio de sus vectores columna) y $(I - A^\dagger A)$ la de proyección ortogonal sobre el núcleo de A , $\ker(A)$.

3.4 Formas cuadráticas

Definición 3.26 Una **forma cuadrática**, o forma bilineal simétrica, en n variables es un polinomio homogéneo de segundo grado en esas variables. La expresión más general de una forma cuadrática es

$$q(\mathbf{x}) = \mathbf{x}^T \mathbf{Q} \mathbf{x},$$

donde $\mathbf{Q} = \mathbf{Q}^T$ es una matriz simétrica de orden n .

Nos limitaremos al análisis de formas cuadráticas con coeficientes reales.

Mediante una transformación lineal de variables, $\mathbf{x} = \mathbf{T} \mathbf{y}$, una forma cuadrática se puede reducir a la forma canónica de *suma de cuadrados* siguiente:

$$q(\mathbf{x}) = \sum_{i=1}^p y_i^2 - \sum_{i=p+1}^{p+q} y_i^2.$$

El *rango* de la forma es $p + q$ y la *signatura* $p - q$ (p números positivos y q negativos).

Una forma cuadrática real es *definida positiva* si para todo vector $\mathbf{x} \neq \mathbf{0}$, $q(\mathbf{x}) > 0$. El rango y signatura de una forma cuadrática definida positiva valen n . Si $\mathbf{Q}$ la forman los coeficientes q_{ij} y se introducen los números *menores* como

$$\Delta_i = \det \begin{bmatrix} q_{11} & q_{12} & \cdots & q_{1i} \\ q_{21} & q_{22} & \cdots & q_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ q_{i1} & q_{i2} & \cdots & q_{ii} \end{bmatrix},$$

la forma cuadrática asociada a $\mathbf{Q}$ es definida positiva si y sólo si todos los menores Δ_i son positivos. Otros gráficos de formas cuadráticas son estos los de la figura 3.6. En (a) la matriz $\mathbf{Q}$ es definida positiva, en (b) definida negativa, en (c) semidefinida positiva (singular) y en (d) indefinida.

Sean $\lambda_1, \dots, \lambda_n$ los valores propios —que sabemos son reales— de la matriz $\mathbf{Q}$. Por el teorema espectral, existe una matriz ortogonal $\mathbf{P}$ tal que $\mathbf{P}^T \mathbf{Q} \mathbf{P} = \text{diag}(\lambda_1, \dots, \lambda_n)$. Haciendo en la forma cuadrática $q(\mathbf{x}) = \mathbf{x}^T \mathbf{Q} \mathbf{x}$ el cambio de variables $\mathbf{x} = \mathbf{P} \mathbf{y}$, se tiene que

$$q(\mathbf{x}) = \mathbf{y}^T \mathbf{P}^T \mathbf{Q} \mathbf{P} \mathbf{y} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2,$$

por lo que el rango de la forma cuadrática es el número total —teniendo en cuenta las multiplicidades— de valores propios no nulos de $\mathbf{Q}$, mientras que la signatura coincide con la diferencia entre los números de valores propios positivos y negativos. En particular, la forma cuadrática asociada a $\mathbf{Q}$ es definida positiva si y sólo si todos los valores propios de $\mathbf{Q}$ son positivos.

En ciertos casos es importante acotar el cociente de una forma cuadrática al cuadrado




Figura 3.6: Formas de funciones cuadráticas

de la norma euclídea, es decir, el cociente

$$r(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{Q} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}, \quad \mathbf{x} \neq \mathbf{0}.$$

Mediante una transformación ortogonal $\mathbf{x} = \mathbf{P} \mathbf{y}$, este cociente se escribe como

$$r(\mathbf{x}) = \frac{\lambda_1 y_1^2 + \cdots + \lambda_n y_n^2}{y_1^2 + \cdots + y_n^2},$$

de manera que se deducen las acotaciones

$$\lambda_{\min}(\mathbf{Q}) \leq \frac{\mathbf{x}^T \mathbf{Q} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \leq \lambda_{\max}(\mathbf{Q}).$$

Estas acotaciones no se pueden mejorar ya que si $\mathbf{Q} \mathbf{v} = \lambda \mathbf{v}$, $\frac{\mathbf{v}^T \mathbf{Q} \mathbf{v}}{\mathbf{v}^T \mathbf{v}} = \lambda$.

4 | Funciones, sucesiones y series de funciones

RECORDEMOS que una función es un caso particular de aplicación entre espacios vectoriales o conjuntos donde los conjuntos origen e imagen son conjuntos de números.

El *gráfico de una función* $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se define como el conjunto $\{(x, f(x)) : x \in \text{dom}(f)\}$, donde $\text{dom}(f)$ es una forma abreviada de referirse al el conjunto de puntos dominio de definición de la función f . Es un subconjunto de $\mathbb{R}^{n+1}$. El *epigrafo* de la función es el conjunto $\text{epi}(f) = \{(x, t) : x \in \text{dom}(f), f(x) \leq t\}$. También es un subconjunto de $\mathbb{R}^{n+1}$. Es el conjunto de puntos situados en o por encima de la función. Igualmente el *hipografo* es el conjunto de punto situados en o por debajo de la función. En la figura 4.1 se muestra el grafo de dos funciones y, sombreados, sus epigrafos.




Figura 4.1: Gráfico de una función (convexa) y su epigrafo. Otra función sinusoidal (no convexa) y su epigrafo

Definición 4.1 Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se dice **continua** en x si para toda sucesión $\{x_k\}$ que converge a x (expresado $x_k \rightarrow x$), se cumple que $f(x_k) \rightarrow f(x)$. De forma equivalente, f se dice continua en x si dado un $\varepsilon > 0$, existe un $\delta > 0$ tal que

$$\|y - x\| < \delta \implies \|f(y) - f(x)\| < \varepsilon.$$

Definición 4.2 Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ se dice satisface la **condición de Lipschitz** con constante γ en un conjunto X si para todo x e y pertenecientes a X se cumple que

$$|f(x) - f(y)| \leq \gamma|x - y|.$$

Una función que satisface la condición de Lipschitz en un conjunto X se dice **continua γ -Lipschitz** en ese X , designándose $f \in \text{Lip}_\gamma(X)$. Si nos referimos a una función diciendo que es Lipschitz, o *continua-Lipschitz*, se está diciendo que es algo más que continua, que no cambia radicalmente.

Esta condición debe su nombre a Rudolf Otto Sigismund Lipschitz, Alemania 1832-1903.



Definición 4.3 Dada una norma vectorial $\|\cdot\|$ en $\mathbb{R}^n$ y otra matricial $\|\cdot\|$ en $\mathbb{R}^{m \times n}$, $m, n > 0$, una función $g : \mathbb{R}^n \rightarrow \mathbb{R}^{m \times n}$ se dice satisface la *condición de Lipschitz* con constante γ en un abierto $D \subset \mathbb{R}^n$, si para todo x e y pertenecientes a D se cumple que

$$\|g(x) - g(y)\| \leq \gamma \|x - y\|.$$

Una función g que satisface la condición de Lipschitz en D se dice *continua γ -Lipschitz* en ese D , designándose $g \in \text{Lip}_\gamma(D)$. Una vez más, si nos referimos a una función diciendo que es Lipschitz, o *continua-Lipschitz*, se está diciendo que es algo más que continua, que no cambia radicalmente a lo largo de todas las direcciones posibles.

Un conjunto de funciones $f_1, f_2, \dots, f_m$ de $\mathbb{R}^n$ en $\mathbb{R}$ se puede considerar como una función vectorial

$$\mathbf{f} = [f_1, f_2, \dots, f_m]^T.$$

Esta función asigna a todo vector $\mathbf{x} \in \mathbb{R}^n$ otro vector $\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})]^T$ de $\mathbb{R}^m$. Tal función vectorial se dice continua si lo es cada uno de sus componentes $f_1, f_2, \dots, f_m$.

Si cada una de las funciones de $\mathbf{f} = [f_1, f_2, \dots, f_m]^T$ es continua en algún conjunto abierto de $\mathbb{R}^n$, se dice $\mathbf{f} \in C$. Si además cada función componente tiene derivadas parciales de primer orden continuas en ese abierto, se dice que $\mathbf{f} \in C^1$. En general, si las funciones componentes tienen derivadas parciales de orden p continuas, se indica $\mathbf{f} \in C^p$.

Teorema 4.1 Teorema de Weierstrass. Dada una función continua definida en un conjunto compacto $C \subset \mathbb{R}^n$, existe un punto donde alcanza un mínimo en C . Es decir, existe un $\mathbf{x}^* \in C$ tal que para todo $\mathbf{x} \in C$, $f(\mathbf{x}) \geq f(\mathbf{x}^*)$. También otro donde alcanza un máximo.

Volvemos a dos conceptos esenciales del cálculo: la derivada y la integral definida.

4.1 Derivada y diferenciabilidad

Definición 4.4 Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ tiene como **derivada** la función

$$f'(x) = \frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

si ese límite existe. Una función f que es derivable en un punto $x = a$ es continua en a .

La derivada es una medida de la rapidez, o tasa (gradiente), con la que cambia el valor de dicha función según cambie el valor de su variable independiente. Representa, desde el punto de vista geométrico, la pendiente de la recta tangente a la función en el punto $x = a$.

En el caso de funciones escalares de varias variables, $f : \mathbb{R}^n \rightarrow \mathbb{R}$, o funciones vectoriales, $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, definidas en un entorno de $\mathbf{x}$, se introduce el concepto de **diferenciabilidad**.

Una función de varias variables en general, f , es diferenciable en un entorno de un punto $\mathbf{x}$ si existen todas las derivadas parciales de la función, la aplicación $Df(\mathbf{x})$ y además se verifica que

$$\lim_{\mathbf{h} \rightarrow 0} \frac{\|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) - Df(\mathbf{x})\mathbf{h}\|}{\|\mathbf{h}\|} = 0.$$

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ la aplicación $Df(\mathbf{x})$ es el vector **gradiente de la función**,

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T.$$

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ la aplicación $Df(\mathbf{x})$ es la **matriz Jacobiana de la función**, por Carl Gustav Jacob Jacobi, Alemania (Prusia), 1804-1851,

$$\nabla f(\mathbf{x}) = \mathbf{J}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_1(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \frac{\partial f_m(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$$



Este concepto de diferenciabilidad, que es el que se usa habitualmente, es debido a

Maurice Fréchet, Francia 1878-1973,



y da lugar a la **derivada de Fréchet**. Existe otro que conocemos como *derivada direccional*, o **derivada de Gâteaux** —por René Eugène Gâteaux, Francia 1889-1914—



(muerto en la primera guerra mundial muy joven), que dice que la función f es diferenciable Gâteaux a lo largo de cualquier vector h de $\mathbb{R}^n$ si existe la función

$$g(h) = \lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t}.$$

Si una función es Fréchet diferenciable en x es también Gâteaux diferenciable en ese punto. Lo contrario no siempre es así. Esto es análogo al hecho de que la existencia de derivadas en todas las direcciones en un punto no garantiza la total diferenciabilidad (e incluso la continuidad) en ese punto.

Ejemplo 4.1 La función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$f(x, y) = \begin{cases} \frac{x^3}{x^2+y^2} & \text{si } (x, y) \neq (0, 0) \\ 0 & \text{si } (x, y) = (0, 0) \end{cases}$$

cuya gráfica es la de la figura 4.2, es continua y diferenciable Gâteaux en el punto $(0, 0)$, con derivada

$$g(a, b) = \begin{cases} \frac{a^3}{a^2+b^2} & \text{si } (a, b) \neq (0, 0) \\ 0 & \text{si } (a, b) = (0, 0) \end{cases}$$

La función g no es un operador lineal y no es diferenciable en el sentido de Fréchet. ●

Ejemplo 4.2 La función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ dada por

$$f(x, y) = \begin{cases} \frac{x^3 y}{x^6+y^2} & \text{si } (x, y) \neq (0, 0) \\ 0 & \text{si } (x, y) = (0, 0) \end{cases}$$




Figura 4.2: Función del ejemplo 4.1

cuya gráfica es la de la figura 4.3, es diferenciable Gâteaux en el punto $(0, 0)$, con derivada $g(a, b) = 0$ en todas las direcciones. Sin embargo f no es continua en $(0, 0)$, lo que se puede ver acercándose al origen de coordenadas a lo largo de la curva $y = x^3$, por lo que f no puede ser diferenciable Fréchet en el origen. ●




Figura 4.3: Función del ejemplo 4.2

Si se tiene la función escalar de varias variables $f : \mathbb{R}^n \rightarrow \mathbb{R}$, con derivadas parciales hasta segundo orden y $f \in C^2$, se define la *matriz Hessiana* de f en x —por Ludwig Otto Hesse, Alemania 1811-1874—



como la matriz $n \times n$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_n} \end{bmatrix}.$$

A esta matriz también se la puede ver designada como $\mathbf{F}(\mathbf{x})$.

Definición 4.5 Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es *afín* si es la suma de una función lineal y una constante; es decir, tiene la forma $f(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$, donde $\mathbf{A} \in \mathbb{R}^{m \times n}$ y $\mathbf{b} \in \mathbb{R}^m$.

4.1.1 Subgradiente y subdiferencial

Definición 4.6 Se dice que $\mathbf{g} \in \mathbb{R}^n$ es un **subgradiente** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en un entorno de un punto $\mathbf{x}$ que pertenece al dominio de definición de esta función si para todo $\mathbf{z}$ del dominio de definición de la función se cumple que

$$f(\mathbf{z}) \geq f(\mathbf{x}) + \mathbf{g}^T(\mathbf{z} - \mathbf{x}),$$

Si la función es convexa diferenciable su gradiente en $\mathbf{x}$ es el subgradiente.

En la figura 4.4, de Boyd y Vandenberghe [2004], se ilustra gráficamente esta definición. En ella, si $\mathbf{g}$ es un subgradiente de f en el punto $\mathbf{x}$ la función afín (de $\mathbf{z}$), $f(\mathbf{x}) + \mathbf{g}^T(\mathbf{z} - \mathbf{x})$ es un *subestimador* global de f .




Figura 4.4: $f(x)$ es diferenciable en x_1 . Su derivada, g_1 , es el único subgradiente. En x_2 la función no es diferenciable pero tiene múltiples subgradienes, además de g_2 y g_3

Geométricamente, $\mathbf{g}$ es un subgradiente de f en $\mathbf{x}$ si el vector $[\mathbf{g}, -1]^T$ soporta lo que se denomina el *epígrafo* de la función f (conjunto de puntos situados en o por encima de la función), $\text{epi}(f)$, en el punto $(\mathbf{x}, f(\mathbf{x}))$. Ver figura 4.5




Figura 4.5: Un vector $g \in \mathbb{R}^n$ es un subgradiente de f en x si y sólo si el vector $[g, -1]^T$ define un hiperplano soporte, o de apoyo, del $\text{epi}(f)$ en $[x, f(x)]^T$

Definición 4.7 Una función se denomina **subdiferenciable** en un punto x si existe al menos un subgradiente de la función en ese punto. El conjunto de todos los subgradiientes de f en el punto x se denomina **subdiferencial** de f en x y se designa por $\partial f(x)$.

La idea del subdiferencial generaliza la diferenciabilidad. La función f es diferenciable en un punto x si y sólo si $\partial f(x) = \{\nabla f(x)\}$. La importancia de los subgradiientes, sobre todo en optimización, radica en que el mínimo de una función f en un punto x se da cuando $0 \in \partial f(x)$.

Ejemplo 4.3 La función valor absoluto, $f(x) = |x|$. Para $x < 0$ el subgradiente es único: $\partial f(x) = -1$. Para $x > 0$, igualmente, el subgradiente es único: $\partial f(x) = 1$. En $x = 0$ el subdiferencial está definido por la desigualdad $|z| \geq gz$, para todo z , lo que se satisface siempre y cuando $g \in [-1, 1]$. Es decir $\partial f(0) = [-1, 1]$. Ver figura 4.6. ●




Figura 4.6: La función valor absoluto y su subdiferencial $\partial f(x)$ en función de x . Ejemplo 4.1.1

4.2 Integral

Definición 4.8 Si $f : \mathbb{C} \rightarrow \mathbb{C}$, se define la **integral definida** de esta función en el intervalo $[a, b]$,

$$I(f) = \int_a^b f(x) dx,$$

como el límite de las sumas de Riemann $R_n = \sum_{i=1}^n (x_{i+1} - x_i) f(t_i)$, $x_1 = a$, $x_{n+1} = b$, $x_i \leq t_i \leq x_{i+1}$, cuando la partición en subintervalos se hace muy fina.

La integración, proceso inverso a la derivación, se basa en la idea de sumar todas las partes constituyentes de un todo.

Teorema 4.2 *Teorema fundamental del cálculo.* Supongamos $f : \mathbb{R} \rightarrow \mathbb{R}$ una función continua en el intervalo $[a, b]$.

1. Si $g(x) = \int_a^x f(t) dt$ entonces $g'(x) = f(x)$.
2. $\int_a^b f(x) dx = F(b) - F(a)$, donde F es la función primitiva de f , es decir, $F' = f$.

4.3 Sucesiones de funciones, series funcionales y de potencias. Convergencia

Si suponemos un intervalo $I \subset \mathbb{R}$, que podemos empezar pensando en $[0, 1]$, una sucesión de funciones en este intervalo no es más que una colección de funciones $\{f_n\}_{n \in \mathbb{N}}$ (o en algunos casos $(f_n)_{n \in \mathbb{N}}$), donde, para cada $n \in \mathbb{N}$, f_n es una función $f_n : [0, 1] \rightarrow \mathbb{R}$.

En una sucesión de funciones $\{f_n\}$ hay dos variables en juego: la n , que va tomando valores naturales, y la x que, fijado un $n_0 \in \mathbb{N}$, le asigna a cada valor $x \in [0, 1]$ el número $f_{n_0}(x)$.

4.3.1 Convergencia puntual

Consideremos el intervalo $I \subset \mathbb{R}$ y, para cada $n \in \mathbb{N}$, la función $f_n : I \rightarrow \mathbb{R}$. La sucesión de funciones $\{f_n\}$ converge puntualmente a la función $f : I \rightarrow \mathbb{R}$ si para cada $x_0 \in I$ se tiene

$$\lim_{n \rightarrow \infty} f_n(x_0) = f(x_0).$$

Ese límite es un número, como el de una sucesión numérica. Todas las funciones de la sucesión deben estar definidas en el mismo intervalo, así como la función límite. El límite de una sucesión de funciones continuas no tiene por qué ser una función continua. Lo mismo ocurre con la derivabilidad y la integrabilidad, que no se mantienen.

4.3.2 Convergencia uniforme

Alguna de las circunstancias mencionadas en la convergencia puntual hace que sea conveniente en ocasiones trabajar con otro tipo de convergencia —la *convergencia uniforme*— que sí mantiene las buenas propiedades de las funciones. Lógicamente esta convergencia es más restrictiva: si una sucesión de funciones converge uniformemente también lo hace puntualmente; lo contrario no siempre ocurre.

La idea detrás de la convergencia uniforme es trabajar en torno a la norma infinito o norma del supremo. Si $\{a_n\} \subset \mathbb{R}$ es una sucesión de números reales, decir $\lim_{n \rightarrow \infty} a_n = a$ es lo mismo que $\lim_{n \rightarrow \infty} a_n - a = 0$ o

$$\lim_{n \rightarrow \infty} |a_n - a| = 0.$$

Es decir el límite de una sucesión es a si y sólo si la distancia de la sucesión a a tiende a 0.

Podemos pasar esta definición a funciones sustituyendo escalares por funciones y el valor absoluto por la norma. Si escogemos para ésta la norma infinito se tiene lo que sigue

Definición 4.9 Sea $I \subset \mathbb{R}$ un intervalo y la función $f_n : I \rightarrow \mathbb{R}$, para cada $n \in \mathbb{N}$. Decimos que la sucesión de funciones $\{f_n\}$ converge uniformemente a la función $f : I \rightarrow \mathbb{R}$ si

$$\lim_{n \rightarrow \infty} \|f_n - f\|_\infty = 0$$

o, de forma equivalente, si

$$\lim_{n \rightarrow \infty} \sup_{x \in I} \{|f_n(x) - f(x)|\} = 0.$$

Es fácil comprobar que la convergencia uniforme implica la convergencia puntual.

Proposición 4.3 Sea $I \subset \mathbb{R}$ un intervalo y la función $f_n : I \rightarrow \mathbb{R}$, para cada $n \in \mathbb{N}$. Si la sucesión de funciones $\{f_n\}$ converge uniformemente a la función $f : I \rightarrow \mathbb{R}$, entonces $\{f_n\}$ también converge puntualmente a la misma función f .

Demostración. Sea $x_0 \in I$. Puesto que sabemos por hipótesis que $\lim_{n \rightarrow \infty} \sup_{x \in I} \{|f_n(x) - f(x)|\} = 0$, y además

$$|f_n(x_0) - f(x)| \leq \sup_{x \in I} \{|f_n(x) - f(x)|\} = 0,$$

se sigue que $\lim_{n \rightarrow \infty} |f_n(x_0) - f(x_0)| = 0$, lo que implica que $\lim_{n \rightarrow \infty} f_n(x_0) = f(x_0)$. $\square$

La implicación recíproca no es cierta. Una sucesión puede converger puntualmente y no hacerlo uniformemente.

Teorema 4.4 Sea $\{f_n\}$ una sucesión de funciones $f_n : [a, b] \rightarrow \mathbb{R}$ para cada $n \in \mathbb{N}$. Supongamos que $\{f_n\}$ converge uniformemente a la función $f_n : [a, b] \rightarrow \mathbb{R}$. Entonces se tiene que:

1. Si f_n es continua en $[a, b]$ para cada $n \in \mathbb{N}$ entonces f es continua.
2. Si f_n es integrable en $[a, b]$ para cada $n \in \mathbb{N}$ entonces f es integrable.

Teorema 4.5 Sea $\{f_n\}$ una sucesión de funciones $f_n : [a, b] \rightarrow \mathbb{R}$ para cada $n \in \mathbb{N}$. Supongamos que para cada $n \in \mathbb{N}$, f_n es derivable en $[a, b]$ y sea f'_n su derivada. Supongamos además que la sucesión $\{f'_n\}$ converge uniformemente a una función $g : [a, b] \rightarrow \mathbb{R}$ y que existe $x_0 \in [a, b]$ tal que el $\lim_n f_n(x_0)$ existe. Entonces existe $f : [a, b] \rightarrow \mathbb{R}$ derivable en $[a, b]$ tal que $f' = g$ y tal que $\{f_n\}$ converge uniformemente a f .

Sentado el patrón para estudiar la convergencia uniforme se pueden estudiar otras forma de convergencia como la convergencia en norma 2.

Definición 4.10 Sea $I \subset \mathbb{R}$ un intervalo y para cada $n \in \mathbb{N}$ la función $f_n : I \rightarrow \mathbb{R}$. Decimos que la sucesión de funciones $\{f_n\}$ converge en media cuadrática, o en norma 2, a la función $f : I \rightarrow \mathbb{R}$ si $\lim_{n \rightarrow \infty} \|f_n - f\|_2 = 0$ o, de forma equivalente, si

$$\lim_{n \rightarrow \infty} \left(\int_I (f_n(t) - f(t))^2 dt \right)^{\frac{1}{2}} = 0.$$

Aunque pueda parecer lo contrario, las relaciones de esta convergencia con las otras que hemos formulado anteriormente no son sencillas.

Proposición 4.6 Si I es un intervalo acotado, para toda $f : I \rightarrow \mathbb{R}$ la norma 2 de f en I es menor o igual que una constante por la norma del supremo de f en I .

Proposición 4.7 Para cada $n \in \mathbb{N}$, sea $f_n : I \rightarrow \mathbb{R}$. Si la sucesión $\{f_n\}$ converge uniformemente a $f : I \rightarrow \mathbb{R}$, también converge en media cuadrática.

La recíproca no es cierta.

Proposición 4.8 Supongamos que la sucesión de funciones $\{f_n\}$ converge en norma 2 a la función f . Entonces existe una subsucesión $\{f_{n_k}\}$ que converge a f en casi todo punto.

Corolario 4.9 Si la sucesión $\{f_n\}$ converge puntualmente a la función f y sabemos que la sucesión $\{f_n\}$ converge en norma 2, entonces necesariamente $f_n \xrightarrow{\|\cdot\|_2} f$

4.3.3 Series funcionales

Definición 4.11 Sea $I \subset \mathbb{R}$ un intervalo y sea $\{f_n\}$ una sucesión de funciones $f_n : I \rightarrow \mathbb{R}$. Se definen las funciones $S_m : I \rightarrow \mathbb{R}$ como $S_m(x) = \sum_{n=1}^m f_n(x)$. Se dice que la serie $\sum_{n=1}^{\infty} f_n$ converge puntualmente a $f : I \rightarrow \mathbb{R}$ si, para cada $x \in I$, $\lim_m S_m(x) = f(x)$ escribiéndose

$$\sum_{n=1}^{\infty} f_n(x) = f(x).$$

Si además la sucesión $\{S_m\}$ converge uniformemente a f , entonces decimos que la serie $\sum_{n=1}^{\infty} f_n$ converge uniformemente a $f : I \rightarrow \mathbb{R}$.

Si $\sum_n f_n$ converge uniformemente a f en un intervalo $[a, b]$ y las funciones f_n son continuas (integrables) en ese intervalo, por lo enunciado antes f es continua (integrable) en $[a, b]$. Igual se razona para la derivabilidad.

Teorema 4.10 *Criterio de Weierstrass.* Sea $\{f_n\}$ una sucesión de funciones $f_n : I \rightarrow \mathbb{R}$ y sea $\{M_n\} \subset \mathbb{R}$ una sucesión numérica que verifica las dos condiciones siguientes:

1. Para cada $n \in \mathbb{N}$ y para cada $x \in I$,

$$|f_n(x)| \leq M_n.$$

2. La serie $\sum_n M_n$ converge.

Entonces existe una función $f : I \rightarrow \mathbb{R}$ tal que, para todo $x \in I$ la serie $\sum_n f_n(x)$ converge absolutamente a $f(x)$. Además, dicha serie converge uniformemente a f .

4.3.4 Series de potencias

Una serie de potencias centrada en a (en lo sucesivo suponemos $a = 0$) tiene la expresión

$$\sum_{n=0}^{\infty} a_n(x-a)^n.$$

Definición 4.12 Dada una serie de potencias $\sum_{n=0}^{\infty} a_n x^n$, su **radio de convergencia** es el número

$$\rho = \sup \left\{ |x_0| \in \mathbb{R} \text{ tales que } \sum_{n=0}^{\infty} a_n x_0^n \text{ converge} \right\}.$$

Si el conjunto entre llaves no es acotado decimos que $\rho = +\infty$.

El teorema que sigue fue formulado por Niels Henrik Abel, Noruega 1802-1829. En su nombre se da anualmente desde 2003, por la Academia Noruega de Ciencias y Letras, el Premio Abel, que es considerado como el Premio Nobel de Matemáticas. De hecho, su montante es el mismo que un equivalente Nobel.



Teorema 4.11 *Teorema de Abel.* Sea una serie de potencias $\sum_{n=0}^{\infty} a_n x^n$ de modo que existe un $x_0 \in \mathbb{R}$ tal que la serie numérica $\sum_{n=0}^{\infty} a_n x_0^n$ es convergente. Sea ahora $r \in \mathbb{R}$ tal que $r < |x_0|$. Entonces, para todo $x \in \mathbb{R}$ tal que $|x| \leq r$ la serie $\sum_{n=0}^{\infty} a_n x^n$ converge absolutamente. Además se tiene que la serie de potencias converge uniformemente en el intervalo $[-r, r]$. Además la función $f : [-r, r] \rightarrow \mathbb{R}$ definida como

$$f(x) = \sum_{n=0}^{\infty} a_n x^n$$

es derivable y

$$f'(x) = \sum_{n=1}^{\infty} n a_n x^{n-1},$$

es decir, la derivación se puede hacer término a término.

Teorema 4.12 Sea ρ el radio de convergencia de una serie de potencias $\sum_{n=0}^{\infty} a_n x^n$. Ocurre uno de los tres casos siguientes:

1. $\rho = 0$. En ese caso la serie converge para $x = 0$ y diverge para todo $x \neq 0$.
2. $0 < \rho < \infty$. En ese caso, para todo $r < \rho$ la serie converge uniformemente en $[-r, r]$ y diverge si $|x| > \rho$. En los puntos frontera $(\pm \rho)$ la serie puede converger o diverger.
3. $\rho = \infty$. En ese caso la serie converge para todo $x \in \mathbb{R}$ y para todo $r > 0$ la serie converge uniformemente en $[-r, r]$.

4.4 Resultados importantes de análisis funcional

Dada la función $f : \mathbb{R} \rightarrow \mathbb{R}$ n -veces derivable en x_0 de un intervalo $I \subset \mathbb{R}$, se llama *polinomio de Taylor* de f de grado n en el punto x_0 a

$$P_{n,x_0}(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k.$$

Se debe a Brook Taylor, Reino Unido, 1685-1731,



Se define el *resto de Taylor* como $R_{n,x_0}(x) = f(x) - P_{n,x_0}(x)$.

Teorema 4.13 *Teorema de Taylor (1712).* Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $f \in C^1$ en una región que contiene el segmento $[x_1, x_2]$, es decir puntos $\alpha x_1 + (1 - \alpha)x_2$, $0 \leq \alpha \leq 1$, existe un θ , $0 \leq \theta \leq 1$, tal que $f(x_2) = f(x_1) + \nabla^T f(\theta x_1 + (1 - \theta)x_2)(x_2 - x_1)$. Además, si $f \in C^2$, existe un θ , $0 \leq \theta \leq 1$, tal que $f(x_2) = f(x_1) + \nabla^T f(x_1)(x_2 - x_1) + \frac{1}{2}(x_2 - x_1)^T F(\theta x_1 + (1 - \theta)x_2)(x_2 - x_1)$, donde F denota la matriz Hessiana de f . Si la función $f : \mathbb{R} \rightarrow \mathbb{R}$ es continua y derivable $k + 1$ veces en un intervalo, o segmento, $[x, x_0]$, existe un b entre x y x_0 tal que

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \frac{f'''(x_0)}{3!}(x - x_0)^3 + \dots + \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k + \frac{f^{(k+1)}(b)}{(k+1)!}(x - x_0)^{k+1}.$$

Las siete primeras aproximaciones de la función $\sin(x)$ por este teorema se pueden ver en la figura 4.7.

El teorema de Taylor nos dice que el polinomio de Taylor aproxima a la función f tanto mejor cuanto mayor es n y más cerca estemos de x_0 . También, que si conocemos el valor de una función y sus derivadas en un punto x_0 , entonces podemos aproximar el valor de la función en un punto x por un polinomio y la aproximación será tanto mejor cuanto más cerca esté el punto y cuantas más derivadas consideremos.

Resulta natural extender la noción de polinomio de Taylor, dejando que n tienda a infinito, a la de *serie de Taylor* centrada en x_0 como

$$\sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k.$$

También, preguntarse si, dada una función infinitamente derivable f , la serie de Taylor converge en todo punto a la función f .

Existe una clase muy amplia de funciones f , denominadas *analíticas*, que verifican que su serie de Taylor converge al menos puntualmente a la función f . Obviamente

$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k$$




Figura 4.7: Función $\sin(x)$ y, en $x = 0$, las aproximaciones por Taylor de **primer orden**, de orden **3, 5, 7, 9, 11 y 13**

si y sólo si $R_{n,x_0}(x) \rightarrow 0$.

La función, por ejemplo

$$f(x) = \begin{cases} e^{-\frac{1}{x^2}} & \text{si } x \neq 0 \\ 0 & \text{si } x = 0 \end{cases}$$

es infinitamente derivable y sin embargo la serie de Taylor *no converge* a $f(x)$ en ningún $x \neq 0$.

Teorema 4.14 *Teorema del valor intermedio. Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$, toma todos los valores entre $f(a)$ y $f(b)$. Más concretamente, si y es un número entre $f(a)$ y $f(b)$, existe un número c dentro de $[a, b]$, es decir, tal que $a \leq c \leq b$, en el que $f(c) = y$.*

El gráfico de la figura 4.8 esquematiza este resultado.

Teorema 4.15 *Teorema del valor medio. Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua y derivable en el intervalo $[a, b]$, existe un número c entre a y b tal que $f'(c) = (f(b) - f(a))/(b - a)$.*

El gráfico de la figura 4.9 ayuda a la comprensión de este resultado.




Figura 4.8: Teorema del valor intermedio




Figura 4.9: Teorema del valor medio

Teorema 4.16 *Teorema de Rolle.* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua y derivable en el intervalo $[a, b]$ y suponemos que $f(a) = f(b)$, existe un número c , entre a y b , tal que $f'(c) = 0$. **GENERALIZACIÓN** Si f es continua y derivable $n - 1$ veces en $[a, b]$ y la derivada de orden n existe en el abierto (a, b) , y existen n intervalos $a_1 < b_1 \leq a_2 < b_2 \leq \dots \leq a_n < b_n$ en $[a, b]$, tales que $f(a_k) = f(b_k)$ para todo $k = 1 \dots n$, existe un número c en (a, b) tal que la derivada de orden n de f en c es cero.

Fue formulado por Michel Rolle, Francia 1652-1719.



El gráfico de la figura 4.10 esquematiza lo obtenido por este teorema.




Figura 4.10: Teorema de Rolle

Teorema 4.17 *Primer teorema del valor medio de las integrales.* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$, existe entonces al menos un número c entre a y b tal que

$$\int_a^b f(x) dx = f(c)(b - a).$$

La figura 4.11 ayuda a entender gráficamente este teorema.




Figura 4.11: Teorema del valor medio de las integrales

Teorema 4.18 *Segundo teorema del valor medio de las integrales.* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$ y $g : \mathbb{R} \rightarrow \mathbb{R}$ una función integrable que no cambia de signo en $[a, b]$, existe entonces un número c entre a y b tal que

$$\int_a^b f(x)g(x) dx = f(c) \int_a^b g(x) dx.$$

Teorema 4.19 Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$ y $a \leq c \leq b$, entonces

$$\frac{d}{dx} \int_c^x f(t) dt = f(x)$$

para todo x en $[a, b]$.

Teorema 4.20 Integración por partes. Sean $u(x)$ y $v(x)$ funciones reales continuas con derivadas continuas. Entonces

$$\int u'(x)v(x) dx = u(x)v(x) - \int u(x)v'(x) dx.$$

Supóngase que se tiene una función vectorial $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ que cumple que $f_i(x) = 0, i = 1, 2, \dots, m$. El teorema de la función implícita que sigue estudia, si $n - m$ de las variables son fijas, si el problema se puede resolver en m incógnitas. Es decir, si $x_1, x_2, \dots, x_m$ se pueden expresar en función de las restantes $n - m$ de la forma

$$x_i = \phi_i(x_{m+1}, x_{m+2}, \dots, x_n), \quad i = 1, 2, \dots, m.$$

A las funciones $\phi_i : \mathbb{R}^{n-m} \rightarrow \mathbb{R}$, si existen, se las denomina *funciones implícitas*.

Teorema 4.21 Teorema de la función implícita. Sea $\mathbf{x}_0 = [x_{01}, x_{02}, \dots, x_{0n}]^T$ un punto de $\mathbb{R}^n$ que satisface:

1. Las m funciones $f_i \in C^p, i = 1, 2, \dots, m$, en algún entorno de $\mathbf{x}_0$, para alguna $p \geq 1$.
2. $f_i(\mathbf{x}_0) = 0, i = 1, 2, \dots, m$.

$$3. \text{ La matriz Jacobiana de la función vectorial, } \nabla f(\mathbf{x}_0) = \begin{bmatrix} \frac{\partial f_1(\mathbf{x}_0)}{\partial x_1} & \dots & \frac{\partial f_1(\mathbf{x}_0)}{\partial x_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x}_0)}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x}_0)}{\partial x_m} \end{bmatrix},$$

es regular.

Entonces existe un entorno de $\hat{\mathbf{x}}_0 = [x_{0m+1}, x_{0m+2}, \dots, x_{0n}]^T \in \mathbb{R}^{n-m}$ tal que para $\hat{\mathbf{x}} = [x_{m+1}, x_{m+2}, \dots, x_n]^T$ en ese entorno existen funciones $\phi_i(\hat{\mathbf{x}}), i = 1, 2, \dots, m$ tales que:

1. $\phi_i \in C^p$.
2. $x_{0i} = \phi_i(\hat{\mathbf{x}}_0), i = 1, 2, \dots, m$.
3. $f_i(\phi_1(\hat{\mathbf{x}}), \phi_2(\hat{\mathbf{x}}), \dots, \phi_m(\hat{\mathbf{x}}), \hat{\mathbf{x}}) = 0, i = 1, 2, \dots, m$.

Este teorema, formulado por Cauchy, sirve para caracterizar puntos óptimos en programación matemática con y sin condiciones, solución de ecuaciones lineales y no lineales y otras bastantes cosas.

Ejemplo 4.4 Consideremos la ecuación $x_1^2 + x_2 = 0$. Una solución de la misma es $x_1 = x_2 = 0$. En un entorno de esta solución, sin embargo, no hay función ϕ tal que $x_1 = \phi(x_2)$. En esta solución no se cumple la condición (c) del teorema de la función

implícita. En cualquier otra solución si existe dicha ϕ . ●

Ejemplo 4.5 Sea A una matriz $m \times n$, $m < n$, y considérese el sistema de ecuaciones lineales $Ax = b$. Si A se estructura así, $A = [B, C]$, donde B es $m \times m$, entonces se satisface la condición (c) del teorema de la función implícita si, y sólo si, B es regular. Esta condición se corresponde con los requisitos y enunciados de la teoría de ecuaciones lineales. ●

De acuerdo con este último ejemplo, la teoría de la función implícita se puede considerar como una generalización no lineal de la teoría lineal.

5 | Optimización y Programación Matemática

La *Optimización* o *Programación Matemática* tiene por objeto el estudio del problema

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimizar}} && f(\mathbf{x}) \\ & \text{sujeta a} && c_i(\mathbf{x}) = 0, \quad i \in \mathcal{E}, \\ & && c_j(\mathbf{x}) \geq 0, \quad j \in \mathcal{I}. \end{aligned} \tag{1}$$

Si no existen las *condiciones* c_i y c_j , o restricciones, el problema es de *optimización sin condiciones*. La *función objetivo* f y las *condiciones* c_i y c_j son, en general, no lineales, continuas y tienen derivadas parciales continuas hasta al menos primer orden. Los conjuntos $\mathcal{E}$ y $\mathcal{I}$ contienen los índices de las condiciones que son de igualdad y de desigualdad, respectivamente. El conjunto de puntos que satisfacen todas las condiciones se denomina *región factible*. Como referencia básica de la temática de esta sección está Boyd y Vandenberghe [2004]. También se puede seguir a Luenberger y Ye [2016].

5.1 Condiciones necesarias y suficientes de existencia de un punto mínimo de una función

Cuando el problema de optimización no tiene restricciones es importante conocer cuáles son las condiciones necesarias y suficientes en que se puede determinar si dada $f : \Omega \rightarrow \mathbb{R}$, $\Omega \subseteq \mathbb{R}^n$, un punto $\mathbf{x}^*$ hace mínima esa función.

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se dice **convexa** (figura 5.1) si cumple que $f(\alpha \mathbf{x} + \beta \mathbf{y}) \leq \alpha f(\mathbf{x}) + \beta f(\mathbf{y})$ para todo $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ y todo $\alpha, \beta \in \mathbb{R}$, con $\alpha + \beta = 1$, $\alpha \geq 0$, $\beta \geq 0$. Si $S \subseteq \mathbb{R}^n$ es un conjunto convexo y $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es una función afín, la imagen de $\mathbf{f}(S) = \{\mathbf{f}(\mathbf{x}) : \mathbf{x} \in S\}$ es un **conjunto convexo**. De forma similar, si $\mathbf{f} : \mathbb{R}^k \rightarrow \mathbb{R}^n$ es una función afín, la imagen inversa $\mathbf{f}^{-1}(S) = \{\mathbf{x} : \mathbf{f}(\mathbf{x}) \in S\}$ también es convexa.

Un punto $\mathbf{x}^* \in \Omega$ se dice que es un **mínimo local** de la función $f : \Omega \rightarrow \mathbb{R}$ si existe un $\epsilon > 0$ tal que $f(\mathbf{x}) \geq f(\mathbf{x}^*)$ para todo $\mathbf{x} \in \Omega$ a una distancia menor que ϵ de $\mathbf{x}^*$. Es decir, para todo $\mathbf{x} \in \Omega$ tal que $|\mathbf{x} - \mathbf{x}^*| < \epsilon$. Si $f(\mathbf{x}) > f(\mathbf{x}^*)$ para todo $\mathbf{x} \in \Omega$, $\mathbf{x} \neq \mathbf{x}^*$, a una distancia menor que ϵ de $\mathbf{x}^*$, se dice que $\mathbf{x}^*$ es un **mínimo local estricto** de f en Ω .

Teorema 5.1 *Condiciones necesarias de primer orden. Teorema de Fermat, por Pierre de Fermat, Francia 1607-1665. Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^1$. Si $\mathbf{x}^*$ es un mínimo local de f en Ω , se cumple que $\nabla f(\mathbf{x}^*) = 0$.*




Figura 5.1: Función convexa



Si en $\mathbf{x}^*$ se cumple que $\nabla f(\mathbf{x}^*) = 0$, $\mathbf{x}^*$ se denomina **punto estacionario**.

Teorema 5.2 *Condiciones necesarias de segundo orden.* Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^2$. Si $\mathbf{x}^*$ es un mínimo local de f en Ω , se cumple que $\nabla f(\mathbf{x}^*) = 0$ y $\nabla^2 f(\mathbf{x}^*)$ es semidefinida positiva.

Teorema 5.3 *Condiciones suficientes de segundo orden.* Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^2$. Si se cumple que $\nabla f(\mathbf{x}^*) = 0$ y $\nabla^2 f(\mathbf{x}^*)$ es definida positiva, $\mathbf{x}^*$ es un mínimo local estricto de f en Ω .

Teorema 5.4 *Si f es convexa, cualquier mínimo local $\mathbf{x}^*$ es un mínimo global de f . Si además f es derivable, cualquier mínimo local $\mathbf{x}^*$ es un mínimo global.*

5.2 Conjuntos convexos y geometría de la convexidad

En optimización se presta una atención fundamental a los conjuntos convexos. En ellos es más fácil caracterizar las soluciones de los problemas y definir algoritmos y procedimientos de resolución robustos. En la figura 5.2 se ilustran algunos conjuntos que son convexos y otros que no lo son. Volveremos sobre la cuestión de cómo saber si hay convexidad o no más adelante.

Si el entorno en el que se define un problema de optimización es convexo, se puede tener la seguridad de conseguir un óptimo del problema, con los algoritmos adecuados, y que éste sea el único. Si hay condiciones no convexas o la función objetivo no lo es,




Figura 5.2: Conjuntos convexos a la izquierda; no convexos a la derecha

puede que no se pueda conseguir nada del problema ni saber si hay uno o varios óptimos.

El análisis de la convexidad de funciones y de problemas de optimización fue fundado en la segunda mitad del siglo XX por Moritz Werner Fenchel, Alemania 1905-1988, Jean Jaques Moreau, Francia 1923-2014, y Ralph Tyrrell Rockafellar, EE.UU. 1935.



Se refiere esencialmente a conjuntos, espacios y funciones convexas y sus aplicaciones en optimización.

Un conjunto $C \subseteq \mathbb{R}^n$ se dice **convexo** si y sólo si para todo par de puntos $\mathbf{x}_1, \mathbf{x}_2 \in C$ todas las combinaciones de la forma $\mathbf{x} = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2$, con $0 \leq \lambda \leq 1$, están en C . Es decir, cuando para cada par de puntos del conjunto convexo todos los de la recta que los une están en el conjunto.

La expresión $\mathbf{x} = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2$, $0 \leq \lambda \leq 1$, define la *combinación convexa* de $\mathbf{x}_1$ y $\mathbf{x}_2$. Si $0 < \lambda < 1$, es decir $\lambda \in (0, 1)$, la combinación se denomina *estrictamente convexa*. En la figura 5.3 se ilustra la fundamental diferencia que hay entre optimizar una función en una región factible convexa y en otra que no lo es.

El concepto de combinación convexa se puede generalizar a cualquier número finito de puntos de la siguiente manera:

$$\mathbf{x} = \sum_{i=1}^p \lambda_i \mathbf{x}_i,$$

donde $\sum_{i=1}^p \lambda_i = 1$, $\lambda_i \geq 0$, $i = 1, \dots, p$.

Definición 5.1 El conjunto intersección de todos los conjuntos convexos que contienen a un subconjunto $S \subseteq \mathbb{R}^n$ se llama **envoltura convexa** —*convex hull*— de S (figura 5.4) y se designa por $\text{conv}(S)$.




Figura 5.3: Optimización (minimización) de $f(x, y) = -x - y$ en un conjunto convexo y en otro que no lo es




Figura 5.4: Envoltura convexa de dos conjuntos de $\mathbb{R}^2$. La de la izquierda de 15 puntos; la de la derecha de un conjunto no convexo

Un conjunto $C \subseteq \mathbb{R}^n$ se dice que es **afín** (también se dice que C es una **variedad afín** o una **variedad lineal**) si para cualesquiera $x, y \in C$ y cualquier $\lambda \in \mathbb{R}$ se tiene que $(1 - \lambda)x + \lambda y \in C$. El conjunto vacío es afín. Una *combinación afín* de vectores $v_1, v_2, \dots, v_n$ es una combinación lineal $c_1 v_1 + \dots + c_n v_n$ en la que $c_1 + \dots + c_n = 1$.

Un conjunto $C \subseteq \mathbb{R}^n$ es afín si y sólo si es de la forma

$$C = \{a + l : a \in \mathbb{R}^n, l \in L\},$$

donde L es un subespacio vectorial de $\mathbb{R}^n$ asociado a C . Es decir, un conjunto afín es un subespacio desplazado del origen. La dimensión de un conjunto afín $x + L$ es la de su correspondiente subespacio L . Un *plano afín* en $\mathbb{R}^n$ es un traslado de un subespacio de $\mathbb{R}^n$. Una *recta* en $\mathbb{R}^n$ es un plano afín de dimensión 1. Es evidente que cualquier conjunto afín es convexo aunque el recíproco no es cierto en general.

Si $S \subseteq \mathbb{R}^n$, la **envoltura afín** de S , $\text{aff}(S)$, es la intersección de todos los conjuntos afines que contienen a S . Como se puede comprobar, $\text{aff}(S) = \text{aff}(\text{conv}(S))$.

Un conjunto de puntos o vectores $\{v_1, \dots, v_p\}$ de $\mathbb{R}^n$ es *afínmente dependiente* si existen números reales $c_1, \dots, c_p$ no todos cero tales que $c_1 + \dots + c_p = 0$ y $c_1 v_1 + \dots + c_p v_p = \mathbf{0}$. De lo contrario será *afínmente independiente*.

Un **simplex** o *simplejo* es la envoltura convexa de un conjunto finito de vectores

afinmente independientes.




Figura 5.5: El simplex S^1 es un segmento de recta. El triángulo S^2 proviene de seleccionar un punto v_3 que no está en la recta que contiene a S^1 y después formar la envolvente convexa con S^1 . El tetraedro S^3 se produce al elegir un punto v_4 que no esté en el plano de S^2 y después formar la envolvente convexa con S^2 .

Para construir un simplex k -dimensional —o k -simplex— se procede como sigue (ver figura 5.5):

- 0-simplex S^0 : un solo punto $\{v_1\}$
- 1-simplex S^1 : $\text{conv}(S^0 \cup \{v_2\})$ con v_2 no en $\text{aff}(S^0)$
- 2-simplex S^2 : $\text{conv}(S^1 \cup \{v_3\})$ con v_3 no en $\text{aff}(S^1)$
- $\vdots$
- k -simplex S^k : $\text{conv}(S^{k-1} \cup \{v_{k+1}\})$ con v_{k+1} no en $\text{aff}(S^{k-1})$.

Un *simplex unidad* es un subconjunto particular del ortante no negativo que se define así

$$\mathcal{S} = \{s \mid s \geq 0, \mathbf{1}^\top s \leq 1\} \subseteq \mathbb{R}_+^n.$$

Es un poliedro convexo acotado con $n + 1$ vértices y $n + 1$ y de dimensión n . En la figura 5.6 se ve uno de $\mathbb{R}^3$: un tetraedro sólido pero no regular.




Figura 5.6: Simplex unidad en $\mathbb{R}^3$. Un tetraedro sólido aunque no regular

Sea $S = \{v_1, \dots, v_k\}$ un conjunto afínmente independiente. Para cada punto p en $\text{aff}(S)$ los coeficientes $c_1, \dots, c_k$ de la representación (única) $p = c_1 v_1 + \dots + c_k v_k$ son las *coordenadas baricéntricas* de p . Estas coordenadas tienen interpretaciones físicas y geométricas de interés. Fueron originalmente definidas en 1827 por August F. Möbius, Alemania 1790-1868.



Si $a = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, $b = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$, $c = \begin{bmatrix} 9 \\ 3 \end{bmatrix}$ y $p = \begin{bmatrix} 5 \\ 3 \end{bmatrix}$, el punto p en el centro de la figura 5.7 tiene por coordenadas baricéntricas tres números no negativos m_a, m_b y m_c tales que p es el centro de masa de un sistema que consiste en el triángulo (sin masa) y las masas m_a, m_b y m_c en los vértices correspondientes. Las masas están unívocamente determinadas al requerir que su suma sea 1.




Figura 5.7: Punto $p = ra + sb + tc$. En este caso $r = \frac{1}{4}$, $s = \frac{1}{3}$ y $t = \frac{5}{12}$.

Proposición 5.5 El conjunto de soluciones de un sistema de ecuaciones lineales, $C = \{x : Ax = b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m\}$, es un conjunto afín.

Demostración. En efecto, supongamos que $x_1, x_2 \in C$, es decir, $Ax_1 = b$, $Ax_2 = b$. Entonces, para cualquier θ ,

$$\begin{aligned} A(\theta x_1 + (1 - \theta)x_2) &= \theta Ax_1 + (1 - \theta)Ax_2 \\ &= \theta b + (1 - \theta)b \\ &= b, \end{aligned}$$

lo que prueba que la combinación afín $\theta x_1 + (1 - \theta)x_2$ está también en el conjunto C . El subespacio asociado con el conjunto afín C en este caso es el espacio nulo de A , $\ker(A)$. □

Definición 5.2 Un conjunto $C \subseteq \mathbb{R}^n$ se dice un **cono** si para todo $\mathbf{x} \in C$ y todo escalar $0 \leq \lambda \in \mathbb{R}$, se tiene que $\lambda \mathbf{x} \in C$. Un cono que también es convexo se denomina **cono convexo**. En este caso, para todo $\mathbf{x}_1, \mathbf{x}_2 \in C$ y $\theta_1, \theta_2 \geq 0$, $\theta_1 \mathbf{x}_1 + \theta_2 \mathbf{x}_2 \in C$.




Figura 5.8: Tres conos: el primero y el segundo no son convexos; el tercero sí

El conjunto $\{\mathbf{x} \in \mathbb{R}^m : \mathbf{x} = \mathbf{A}\boldsymbol{\alpha}, \mathbf{A} \in \mathbb{R}^{m \times n}, \boldsymbol{\alpha} \in \mathbb{R}^n, \boldsymbol{\alpha} \geq \mathbf{0}\}$ es un cono convexo generado por los vectores columna de la matriz $\mathbf{A}$.

El conjunto de todas las combinaciones cónicas de los puntos de un conjunto C , $\theta_1 \mathbf{x}_1 + \cdots + \theta_k \mathbf{x}_k$, $\theta_1, \dots, \theta_k \geq 0$, es la **envoltura cónica** de C , $\text{cone}(C)$.




Figura 5.9: Envoltura cónica de los dos conjuntos de la figura 5.4

Definición 5.3 Un punto $\mathbf{x}$ es un **punto extremo o vértice** de un conjunto convexo C si y sólo si no es interior a un segmento de recta contenido en C . Es decir, si y sólo si

$$\mathbf{x} = (1 - \beta)\mathbf{y} + \beta\mathbf{z} \text{ con } 0 < \beta < 1 \text{ y } \mathbf{y}, \mathbf{z} \in C \Rightarrow \mathbf{x} = \mathbf{y} = \mathbf{z}.$$

Dos resultados importantes de Constantin Carathéodory —Alemania, 1873-1950—



dicen que si $X \subseteq \mathbb{R}^n$ y $\mathbf{x} \in \text{cone}(X)$, existen $\mathbf{x}_i$ y λ_i , $i = 1, \dots, n$, tales que $\mathbf{x} = \sum_{i=1}^n \lambda_i \mathbf{x}_i$. Es decir, como expresa la figura 5.10, cualquier elemento de la envoltura




Figura 5.10: El teorema de Carathéodory

cónica de X es combinación cónica de, a lo sumo, n puntos de X . Igualmente, si $X \subseteq \mathbb{R}^n$ y $\mathbf{x} \in \text{conv}(X)$, existen $\mathbf{x}_i$ y λ_i , $i = 1, \dots, n + 1$, tales que $\mathbf{x} = \sum_{i=1}^{n+1} \lambda_i \mathbf{x}_i$. Es decir, cualquier elemento de la envoltura convexa de X es combinación convexa de, a lo sumo, $n + 1$ puntos de X .

Definición 5.4 Llamaremos **hiperplano** H de **vector característico** $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{a} \neq \mathbf{0}$, al conjunto $H = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}^T \mathbf{x} = c\}$, con $c \in \mathbb{R}$. Un hiperplano es el *conjunto de soluciones de una ecuación lineal en $\mathbb{R}^n$* .

Definición 5.5 Un hiperplano en $\mathbb{R}^n$ es un **espacio afín** o una variedad lineal $(n - 1)$ dimensional.

Definición 5.6 Dado un hiperplano H , $\mathbf{a}^T \mathbf{x} = c$, llamaremos **semiespacios cerrados de borde** H a los conjuntos $H_+ = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}^T \mathbf{x} \geq c\}$ y $H_- = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}^T \mathbf{x} \leq c\}$. **Semiespacios abiertos de borde** H a $\mathring{H}_+ = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}^T \mathbf{x} > c\}$ y $\mathring{H}_- = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}^T \mathbf{x} < c\}$. Los semiespacios de borde H son convexos; la unión de H_+ y H_- es el espacio $\mathbb{R}^n$.

En la figura 5.11 se representa el hiperplano $-x_1 + 4x_2 = 11$, su vector característico $\mathbf{a} = [-1, 4]^T$ y los semiespacios H_+ y H_- .

En un hiperplano $\mathbf{a}^T \mathbf{x} = c$ la constante c determina el desplazamiento del hiperplano del origen. Un hiperplano se puede expresar de la forma $\{\mathbf{x} : \mathbf{a}^T (\mathbf{x} - \mathbf{x}_0) = 0\}$, donde $\mathbf{x}_0$ es cualquier punto del hiperplano ($\mathbf{a}^T \mathbf{x}_0 = c$). Esa última expresión se puede trabajar un poco más pues $\{\mathbf{x} : \mathbf{a}^T (\mathbf{x} - \mathbf{x}_0) = 0\} = \mathbf{x}_0 + \mathbf{a}^\perp$, donde $\mathbf{a}^\perp$ es el complemento ortogonal de $\mathbf{a}$, es decir $\{\mathbf{v} : \mathbf{a}^T \mathbf{v} = 0\}$. Lo que lleva a que un hiperplano consiste en un desplazamiento $\mathbf{x}_0$ más todos los vectores ortogonales al vector característico $\mathbf{a}$: el conjunto de soluciones de $\mathbf{a}^T \mathbf{x} = c$: $\mathbf{x}_0 + \ker(\mathbf{a})$, recordemos.

Hacemos en este punto una incursión en Dattorro [2016] para incluir la figura 5.12 que aclara lo expresado de forma compacta.




Figura 5.11: Hiperplano $-x_1 + 4x_2 = 11$ y los semiespacios en los que divide $\mathbb{R}^2$




Figura 5.12: De Dattorro [2016] con su notación: un hiperplano $\partial \mathcal{H}$, desplazado del origen una distancia Δ y los semiespacios H_+ y H_- ; el $\ker(a^T) = \mathcal{N}(a^T)$, contenido en H_- . La zona sombreada es una pieza rectangular de semiespacio H_- con respecto al cual el vector a es normal, saliendo de esa zona, hacia H_+ . Los puntos c y d son equidistantes del hiperplano y el vector $c - d$ es normal al mismo

Definición 5.7 Un **politopo** es un conjunto formado por la intersección de un número finito de semiespacios cerrados. Un **politopo cónico** es un conjunto formado por la intersección de un número finito de semiespacios cerrados que pasan por un punto.

Definición 5.8 Un **poliedro** es un politopo acotado y no vacío (figura 5.13).




Figura 5.13: Diversos politopos; el del centro es un poliedro

Definición 5.9 Se denomina **hiperplano soporte** o **hiperplano de apoyo** de un conjunto convexo C a un hiperplano H tal que $H \cap C \neq \emptyset$ y $C \subseteq H_+$ o $C \subseteq H_-$. Es decir, a un hiperplano que contiene al conjunto C en uno de sus semiespacios cerrados de borde H y algún punto frontera de C

Definición 5.10 Si P es un politopo convexo y H cualquier hiperplano soporte de P , la intersección $F = P \cap H$ define una **cara** de P .

Existen tres tipos especiales de caras.

Definición 5.11 Un **vértice**, una **arista** y una **faceta** son caras de un politopo convexo n -dimensional de dimensiones cero, uno y $n - 1$, respectivamente.

Es fácil comprobar que la intersección de conjuntos convexos es convexa y que, por lo tanto, los *politopos* y los *poliedros* son conjuntos convexos. Si un politopo P es un poliedro, cualquier punto se puede expresar como combinación convexa de sus puntos extremos o vértices.

Ya conocemos el concepto de esfera o bola unidad. Ésta se puede definir también en el espacio euclídeo n -dimensional $\mathbb{R}^n$ como

$$B(\mathbf{x}_c, r) = \{\mathbf{x}_c + r\mathbf{u} \mid \|\mathbf{u}\| \leq 1\}.$$

Una bola euclídea es un conjunto convexo. Si $\|\mathbf{x}_1 - \mathbf{x}_c\|_2 \leq r$, $\|\mathbf{x}_2 - \mathbf{x}_c\|_2 \leq r$ y $0 \leq \theta \leq 1$, se tiene que

$$\begin{aligned} \|\theta\mathbf{x}_1 + (1 - \theta)\mathbf{x}_2 - \mathbf{x}_c\|_2 &= \|\theta(\mathbf{x}_1 - \mathbf{x}_c) + (1 - \theta)(\mathbf{x}_2 - \mathbf{x}_c)\|_2 \\ &\leq \theta\|\mathbf{x}_1 - \mathbf{x}_c\|_2 + (1 - \theta)\|\mathbf{x}_2 - \mathbf{x}_c\|_2 \\ &\leq r \end{aligned}$$

Una familia de conjuntos convexos similar es la de los **elipsoides**. Se definen así

$$\mathcal{E} = \{\mathbf{x} \mid (\mathbf{x} - \mathbf{x}_c)^\top \mathbf{P}^{-1}(\mathbf{x} - \mathbf{x}_c) \leq 1\},$$

donde la matriz $\mathbf{P} \succ 0$, es decir es simétrica y definida positiva. Los valores singulares —raíces cuadradas positivas de los valores propios— de $\mathbf{P}$, como apuntamos antes en este apéndice, son las longitudes de los semiejes del hiperelipsoide $\mathcal{E}$. Una bola es un elipsoide en el que $\mathbf{P} = r^2 \mathbf{I}$. Otra forma de definir el elipsoide es

$$\mathcal{E} = \{\mathbf{x}_c + \mathbf{A}\mathbf{u} \mid \|\mathbf{u}\|_2 \leq 1\},$$

donde $\mathbf{A}$ es cuadrada y regular. Asumiendo que $\mathbf{A}$ es simétrica y definida positiva, $\mathbf{A} = \mathbf{P}^{\frac{1}{2}}$ proporciona el elipsoide $\mathcal{E}$. Si $\mathbf{A}$ es semidefinida positiva y regular, la última definición de $\mathcal{E}$ da un *elipsoide degenerado*. Un elipsoide degenerado es también convexo.

Definición 5.12 Dada una norma cualquiera $\|\cdot\|$ en $\mathbb{R}^n$, se define la **norma bola** de radio r y centro $\mathbf{x}_c$ como $\{\mathbf{x} \mid \|\mathbf{x} - \mathbf{x}_c\| \leq r\}$. Es convexa. La **norma cono** asociada a $\|\cdot\|$ es el conjunto

$$C = \{(\mathbf{x}, t) \mid \|\mathbf{x}\| \leq t\} \subseteq \mathbb{R}^{n+1}.$$

Ejemplo 5.1 La norma cono de segundo orden con respecto a la norma euclídea es

$$\begin{aligned} C &= \{(\mathbf{x}, t) \mid \|\mathbf{x}\|_2 \leq t\} \\ &= \left\{ \begin{bmatrix} \mathbf{x} \\ t \end{bmatrix} \mid \begin{bmatrix} \mathbf{x} \\ t \end{bmatrix}^\top \begin{bmatrix} \mathbf{I} & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ t \end{bmatrix} \leq 0, t \geq 0 \right\}. \end{aligned}$$

Su forma geométrica se puede ver en la figura 5.14. ●




Figura 5.14: Frontera de la norma cono en $\mathbb{R}^3$: $\{(x_1, x_2, t) \mid (x_1^2 + x_2^2)^{\frac{1}{2}} \leq t\}$

5.2.1 Conos apropiados y desigualdades generalizadas

Definición 5.13 Un cono $K \subseteq \mathbb{R}^n$ se denomina **cono verdadero**, o *cono apropiado*—*proper cone*, si es convexo, cerrado, sólido, en el sentido de que su interior no es vacío ($K + (-K) = \mathbb{R}^n$), y puntiagudo (*pointed*) lo que significa que no contiene una línea o que $x \in K, -x \in K \implies x = 0$, o $K \cap -K = \{0\}$.

Un cono apropiado o verdadero induce **desigualdades generalizadas**, que son una ordenación parcial, $\preceq_K$, de $\mathbb{R}^n$, con muchas de las propiedades de un orden estándar de $\mathbb{R}^n$, definida así

$$x \preceq_K y \iff y - x \in K.$$

También se escribe $x \succeq_K y$ si $y \preceq_K x$. De forma similar se define la ordenación parcial estricta asociada

$$x \prec_K y \iff y - x \in \text{int } K.$$

Si nos referimos como cono apropiado al ortante $\mathbb{R}_+^n$ la ordenación parcial $\preceq_K$ pasa a ser $\preceq_{\mathbb{R}_+^n}$ que es la usual $\leq$ de $\mathbb{R}^n$ (y la estricta $<$). Formalmente $x \preceq_{\mathbb{R}_+^n} y$ si $x_i \leq y_i$ para todo i .

El cono semidefinido positivo $\mathbb{S}_+^n$ es un cono apropiado que induce la desigualdad generalizada $X \preceq_{\mathbb{S}_+^n} Y$ si y sólo si $Y - X$ es semidefinida positiva.

Una forma de pensar en un cono convexo cerrado y puntiagudo es como un nuevo tipo de sistema de coordenadas cuya base es generalmente no ortogonal. Un sistema cónico sería muy parecido al sistema cartesiano habitual cuyo cono es análogo al primer cuadrante u ortante no negativo.

Las desigualdades generalizadas son un medio para determinar la pertenencia o no a cualquier cono convexo cerrado, mientras que la denominada *expansión biortogonal* sería simplemente una expresión de las coordenadas en un sistema cónico de coordenadas cuyos ejes son linealmente independientes pero no necesariamente ortogonales.

Cuando el cono K es el ortante no negativo de $\mathbb{R}^n$, estos tres conceptos se corresponden con el prototipo cartesiano. La expansión biortogonal se convierte en la ortogonal.

5.2.2 Elementos mínimos y minimales. Cono dual

Se dice que un $x \in S$ es el **elemento mínimo** de S con respecto a la desigualdad generalizada $\preceq_K$ si para todo $y \in S$ se cumple que $x \preceq_K y$. Es decir, si

$$S \subseteq x + K.$$

En esta expresión $x + K$ se refiere a todos los puntos que son comparables con x y mayores o iguales que x de acuerdo con $\preceq_K$. El **elemento máximo** se define de manera similar. Si un conjunto tiene un elemento mínimo es único.

Se dice que un $x \in S$ es un **elemento minimal** de S con respecto a la desigualdad generalizada $\preceq_K$ si para un $y \in S$ se cumple que $y \preceq_K x$ sólo si $y = x$. Es decir, si y sólo si

$$(x - K) \cap S = \{x\}.$$

En esta expresión $x - K$ se refiere a todos los puntos que son comparables con x y menores o iguales que x de acuerdo con $\leq_K$. El único punto en común con S es x . El elemento mínimo es un elemento minimal.

Si $K = \mathbb{R}_+$ el concepto de elemento mínimo y minimal coinciden en el sentido tradicional de mínimo. En la figura 5.15 se describen geoméricamente estos últimos conceptos. También, con algún detalle más general, en 5.16.




Figura 5.15: El conjunto S_1 tiene un elemento mínimo x_1 con respecto a la desigualdad componente a componente en $\mathbb{R}^2$. El conjunto $x_1 + K$ es el sombreado más tenue; x_1 es el elemento mínimo de S_1 dado que $S_1 \subseteq x_1 + K$. El punto x_2 es un elemento minimal de S_2 . El conjunto $x_2 - K$ se muestra en esa parte de la figura de forma más tenue. El punto x_2 es minimal pues $x_2 - K$ y S_2 sólo tienen como elemento común x_2 .

Definición 5.14 Si K es un cono, se define el **cono dual** de K como el conjunto

$$K^* = \{y \mid x^\top y \geq 0 \text{ para todo } x \in K\}.$$

El cono dual siempre es convexo aunque el original K no lo sea. En la figura 5.17 se ve la construcción geométrica del cono dual en dos y tres dimensiones.

Un vector y pertenecerá al cono dual K^* si y sólo si $-y$ es normal de un hiperplano que soporta a K en su origen. La geometría de eso se ilustra en la figura 5.18.

Si el cono K es apropiado también lo es su cono dual. Si K tiene un interior no vacío su cono dual es puntiagudo. Si K es convexo y cerrado, $K^{**} = K$.

Ejemplo 5.2 El cono dual de un subespacio $V \subseteq \mathbb{R}^n$ es su complemento ortogonal $V^\perp = \{y \mid y^\top v = 0 \text{ para todo } v \in V\}$. ●

Ejemplo 5.3 El cono dual del **ortante no negativo** $\mathbb{R}_+^n$ es el propio ortante no negativo: $y^\top x \geq 0$ para todo $x \geq 0 \iff y \geq 0$. ●

Ejemplo 5.4 El cono dual de $\mathbb{S}_+^n$ es el propio $\mathbb{S}_+^n$. ●

Ejemplo 5.5 Si $\|\cdot\|$ es una norma en $\mathbb{R}^n$, el cono dual del cono $K = \{(x, t) \in \mathbb{R}^{n+1} \mid \|x\| \leq t\}$ es el cono definido por la norma dual, es decir,

$$K^* = \{(u, v) \in \mathbb{R}^{n+1} \mid \|u\|_* \leq v\}.$$

●




Figura 5.16: De Dattorro [2016]. El conjunto C_1 tiene un elemento mínimo x con respecto al cono K pues dicho cono trasladado a x contiene todo el conjunto C_1 . El conjunto C_2 tiene un punto minimal en y con respecto al cono K pues el negativo de este trasladado a $y \in C_2$ sólo contiene a y




Figura 5.17: De Dattorro [2016]. Cómo se construyen los conos duales de sendos conos K en $\mathbb{R}^2$ a partir de los ángulos rectos de los extremos de K




Figura 5.18: El semiespacio con normal hacia dentro y contiene al cono K por lo que $y \in K^*$. El semiespacio con normal hacia dentro z no contiene a K por lo que $z \notin K^*$

Si un cono K es apropiado e induce la desigualdad generalizada $\preceq_K$, su dual K^* es también apropiado e induce por consiguiente una desigualdad generalizada $\preceq_{K^*}$ dual de $\preceq_K$. Algunas de sus propiedades son

$$x \preceq_K y \text{ si y sólo si } \lambda^\top x \leq \lambda^\top y \text{ para todo } \lambda \succeq_{K^*} 0$$

$$x \prec_K y \text{ si y sólo si } \lambda^\top x < \lambda^\top y \text{ para todo } \lambda \succeq_{K^*} 0, \lambda \neq 0.$$

Es interesante poder caracterizar un elemento mínimo o minimal de un conjunto mediante desigualdades duales. Un x es el elemento mínimo de un conjunto S , con respecto a la desigualdad generalizada $\preceq_K$ si y sólo si para todo $\lambda \succ_{K^*} 0$ x es el único mínimo de $\lambda^\top z$, con $z \in S$. Geométricamente esto significa que para cualquier $\lambda \succ_{K^*} 0$, el hiperplano

$$\{z \mid \lambda^\top (z - x) = 0\}$$

es un hiperplano que soporta estrictamente a S en x (sólo en el punto x). Esto es lo que ilustra la figura 5.19.




Figura 5.19: Un elemento mínimo caracterizado mediante desigualdades duales. El punto x es el elemento mínimo del conjunto S con respecto a $\mathbb{R}_+^2$. Esto es equivalente a que para cada $\lambda \succ 0$ el hiperplano $\{z \mid \lambda^\top (z - x) = 0\}$ soporta estrictamente a S en x . Ese hiperplano contiene a S en uno de sus lados y lo toca sólo en x

De forma similar veamos cómo caracterizar un elemento minimal. Si $\lambda \succ_{K^*} 0$ y

x minimiza $\lambda^\top z$ para todo $z \in S$, entonces x es minimal. Esto es lo que expresa la figura 5.20.




Figura 5.20: El conjunto de puntos minimales de $S \subseteq \mathbb{R}^2$ con respecto a $\mathbb{R}_+^2$ están en la línea más oscura inferior del borde de S . El que minimiza $\lambda_1^\top z$ en S es x_1 y es minimal porque $\lambda_1 \succ 0$. El que minimiza $\lambda_2^\top z$ en S es el punto x_2 , otro punto minimal de S pues $\lambda_2 \succ 0$.

Para probarlo, supongamos que $\lambda \succ_{K^*} 0$ y que x minimiza $\lambda^\top z$ para todo $z \in S$ pero x no es minimal, es decir, existe un $z \in S$, $z \neq x$ tal que $z \leq_K x$. Entonces $\lambda^\top (x - z) > 0$, lo que contradice la suposición de que x es el que minimiza $\lambda^\top z$ en S para todo $z \in S$.

Lo contrario es en general falso: un punto x puede ser minimal en S pero no el que minimize $\lambda^\top z$ en S para todo $z \in S$. El ejemplo que lo demuestra es el de la figura 5.21. Este ejemplo pone de manifiesto la importancia de la convexidad. Si S es convexo, se




Figura 5.21: El punto x es un punto minimal de $S \subseteq \mathbb{R}^2$ con respecto a $\mathbb{R}_+^2$. Sin embargo, no existe un λ para el cual x minimiza $\lambda^\top z$ para todo $z \in S$.

puede decir que para cualquier elemento minimal x existe un $\lambda \succeq_{K^*} 0$, no cero, tal que x minimiza $\lambda^\top z$ en S para todo $z \in S$.

5.2.3 Hiperplano separador. Lema de Farkas

Teorema 5.6 Sea C un conjunto convexo e y un punto exterior a la adherencia de C . Existe un vector a tal que $a^\top y < \inf_{x \in C} a^\top x$.

Demostración. Sea

$$\delta = \inf_{x \in C} \|x - y\|_2 > 0.$$

Existe un x_0 en la frontera de C tal que $\|x_0 - y\|_2 = \delta$. Esto es así pues la función continua $f(x) = \|x - y\|_2$ alcanza su mínimo en cualquier conjunto cerrado y acotado por lo que sólo es necesario considerar x en la intersección de la adherencia de C y la bola abierta de centro y y radio 2δ .

A continuación probaremos que $a = x_0 - y$ satisface las condiciones del enunciado del teorema. En efecto, para cualquier α , $0 \leq \alpha \leq 1$, al ser C un conjunto convexo, el punto $x_0 + \alpha(x - x_0) \in C$, por lo que

$$\|x_0 + \alpha(x - x_0) - y\|_2^2 \geq \|x_0 - y\|_2^2.$$

Desarrollando,

$$2\alpha(x_0 - y)^T(x - x_0) + \alpha^2\|x - x_0\|_2^2 \geq 0.$$

Considerando esta expresión cuando $\alpha \rightarrow 0+$, se tiene que

$$(x_0 - y)^T(x - x_0) \geq 0$$

o que

$$\begin{aligned} (x_0 - y)^T x &\geq (x_0 - y)^T x_0 = (x_0 - y)^T y + (x_0 - y)^T(x_0 - y) \\ &= (x_0 - y)^T y + \delta^2. \end{aligned}$$

Haciendo $a = x_0 - y$ queda probado el teorema. □

La interpretación geométrica de este teorema es que dado un conjunto convexo C y un punto y exterior a la adherencia de C existe un hiperplano que contiene a y , sin tocar a C , estando C en uno de sus semiespacios abiertos. Ese hiperplano, de vector




Figura 5.22: Hiperplano separador entre C y D

característico a en el teorema, se denomina **hiperplano separador** de C e y .

Si C y D son dos conjuntos convexos disjuntos, $C \cap D = \emptyset$, existe entonces un $\mathbf{a} \neq 0$ y un $\mathbf{b}$ tales que $\mathbf{a}^T \mathbf{x} \leq \mathbf{b}$, para todo $\mathbf{x} \in C$, y $\mathbf{a}^T \mathbf{x} \geq \mathbf{b}$, para todo $\mathbf{x} \in D$. Dicho de otra manera, la función $\mathbf{a}^T \mathbf{x} - \mathbf{b}$ es no positiva en C y no negativa en D . El hiperplano $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = \mathbf{b}\}$ es un hiperplano separador de los conjuntos C y D como se ve en la figura 5.22.

Existen bastantes principios de *dualidad* (en especial en la teoría y técnicas de optimización) que relacionan un problema en términos de vectores en un espacio vectorial con otro en términos de subespacios en ese espacio. En varios de esos principios está presente la relación que se ilustra en la figura 5.23 que indica que la distancia más corta de un punto a un conjunto convexo es igual al máximo de las distancias desde el punto a los hiperplanos que separan el conjunto convexo del punto. El problema original de minimización sobre vectores se convierte en otro de maximización sobre hiperplanos.




Figura 5.23: Distancia más corta de un punto a un conjunto convexo en términos de hiperplanos separadores. Dattorro [2016]

Teorema 5.7 Sea C un conjunto convexo e $\mathbf{y}$ un punto frontera de C . Existe un hiperplano que contiene a $\mathbf{y}$ y a C en uno de sus semiespacios cerrados.

Demostración. Sea $\{\mathbf{y}^{(k)}\}$ una sucesión de puntos exteriores a la adherencia de C . Sea $\{\mathbf{a}^{(k)}\}$ la sucesión de puntos normalizados, $\|\mathbf{a}^{(k)}\|_2 = 1$, obtenida de aplicar el teorema anterior a la sucesión anterior, tales que,

$$\left(\mathbf{a}^{(k)}\right)^T \mathbf{y}^{(k)} < \inf_{\mathbf{x} \in C} \left(\mathbf{a}^{(k)}\right)^T \mathbf{x}.$$

Como $\{\mathbf{a}^{(k)}\}$ es una sucesión acotada, una subsucesión $\{\mathbf{a}^{(k)}\}$, $k \in \mathcal{H}$, convergerá a un límite $\mathbf{a}$. Para este $\mathbf{a}$ se tiene que, para cualquier $\mathbf{x} \in C$,

$$\mathbf{a}^T \mathbf{y} = \lim_{k \in \mathcal{H}} \left(\mathbf{a}^{(k)}\right)^T \mathbf{y}^{(k)} \leq \lim_{k \in \mathcal{H}} \left(\mathbf{a}^{(k)}\right)^T \mathbf{x} = \mathbf{a}^T \mathbf{x}.$$

□

Un hiperplano que contiene un conjunto convexo C en uno de sus semiespacios cerrados y que contiene algún punto frontera de C se denomina **hiperplano de apoyo** o **hiperplano soporte** de C .

De acuerdo con esta definición, el teorema anterior dice que dado un conjunto convexo C y un punto frontera y de C existe un hiperplano de apoyo de C que contiene y .

En la figura 5.24 $\{x : a^T x = a^T x_0\}$ es el hiperplano de apoyo de C en el punto




Figura 5.24: Hiperplano soporte de C en x_0

x_0 : el punto x_0 y el conjunto C están separados por el hiperplano $\{x : a^T x = a^T x_0\}$. Geométricamente quiere decir que el hiperplano $\{x : a^T x = a^T x_0\}$ es tangente al conjunto C en x_0 y el semiespacio $x : a^T x \leq a^T x_0$ contiene a C .

Si S es un politopo de dimensión 3 en $\mathbb{R}^3$ —un cubo— y H un plano que se traslada en $\mathbb{R}^3$ hasta que apenas se apoya en el cubo, pero no corta el interior de éste, hay tres posibilidades para $H \cap S$ dependiendo de la orientación de H . Se ven en la figura 5.25.




Figura 5.25: $H \cap S$ es una cara cuadrada bidimensional del cubo, una arista unidimensional del cubo o un vértice de dimensión 0 del cubo

Lema 5.8 Lema de Farkas. El sistema de ecuaciones

$$(I) \quad Ax = b, \quad x \geq 0,$$

no tiene solución si y sólo si la tiene el sistema

$$(II) \quad \mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T, \quad \mathbf{b}^T \mathbf{y} > 0,$$

donde $\mathbf{A} \in \mathbb{R}^{m \times n}$.

Se debe a Gyula Farkas, Hungría 1847-1930.



Demostración. El lema se puede reformular de la siguiente manera. Si existe un $\mathbf{x} \geq \mathbf{0}$ tal que $\mathbf{A}\mathbf{x} = \mathbf{b}$, no existe ningún $\mathbf{y}$ tal que $\mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T$ y $\mathbf{b}^T \mathbf{y} > 0$. Recíprocamente, si no existe ningún $\mathbf{x} \geq \mathbf{0}$ tal que $\mathbf{A}\mathbf{x} = \mathbf{b}$, existe un $\mathbf{y}$ tal que $\mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T$ y $\mathbf{b}^T \mathbf{y} > 0$.

Supongamos que el sistema (I) tiene una solución $\mathbf{x}$ tal que $\mathbf{A}\mathbf{x} = \mathbf{b}$ y $\mathbf{x} \geq \mathbf{0}$. Sea $\mathbf{y}$ un punto tal que $\mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T$. En este caso $\mathbf{b}^T \mathbf{y} = \mathbf{x}^T \mathbf{A}^T \mathbf{y} \leq 0$ pues $\mathbf{x} \geq \mathbf{0}$ y $\mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T$. Esto demuestra que $\mathbf{b}^T \mathbf{y}$ no puede ser positivo y, por lo tanto, el sistema (II) no tiene solución.

Supongamos ahora que el sistema (I) no tiene solución. Esto quiere decir que $\mathbf{b} \notin S = \{\mathbf{v} = \mathbf{A}\mathbf{x} : \mathbf{x} \geq \mathbf{0}\}$; es decir que $\mathbf{b}$ no pertenece al politopo cónico S . Observando la figura 5.26, está claro que si $\mathbf{b} \notin S$, existe un hiperplano separador definido por un $\mathbf{y}$, que separa S y $\mathbf{b}$, y para el cual $\mathbf{y}^T \mathbf{a}_i \leq 0, i = 1, \dots, n$ y $\mathbf{y}^T \mathbf{b} > 0$, es decir, $\mathbf{y}$ forma un ángulo de más de 90 grados con cada uno de los vectores columna de $\mathbf{A}$ y de menos de 90 grados con $\mathbf{b}$ (el hiperplano separador del politopo cónico S de la figura debería “casi” tocar a éste a lo largo de $\mathbf{a}_5$. El hiperplano de apoyo correspondiente, sí tocaría a $\mathbf{a}_5$). Esto verifica que el sistema (II) tiene solución. $\square$

El lema de Farkas es un resultado importante para el estudio de sistemas lineales de inecuaciones. Su interpretación geométrica es la siguiente:

1. Si $\mathbf{a}_i, i = 1, \dots, n$, son los n vectores columna de la matriz $\mathbf{A}$, que se cumpla que $\mathbf{b} = \mathbf{A}\mathbf{x}, \mathbf{x} \geq \mathbf{0}$, quiere decir que el vector $\mathbf{b} = \sum_{i=1}^n \mathbf{a}_i x_i, x_i \geq 0$; en otras palabras, que $\mathbf{b}$ pertenece al politopo cónico generado por los vectores columna de $\mathbf{A}$. En la figura 5.27, a la izquierda, se muestra un ejemplo donde el sistema (I) no tiene solución: el vector $\mathbf{b}$ no pertenece al cono generado por $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$ y $\mathbf{a}_n$. La intersección del cono $\{\mathbf{y} : \mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T\}$ (conjunto formado por los vectores $\mathbf{y}$ que forman un ángulo mayor o igual de 90° con los vectores columna de la matriz $\mathbf{A}$) y el semiespacio abierto $\{\mathbf{y} : \mathbf{b}^T \mathbf{y} > 0\}$, no es el conjunto vacío: el sistema (II) tiene solución, pues $\mathbf{b}$ y cualquier $\mathbf{y}$ en el cono que define la zona sombreada forma un ángulo menor de 90° y, por lo tanto, $\mathbf{b}^T \mathbf{y} > 0$.
2. El sistema (II) no tiene solución si la intersección del cono $\{\mathbf{y} : \mathbf{y}^T \mathbf{A} \leq \mathbf{0}^T\}$ y el semiespacio abierto $\{\mathbf{y} : \mathbf{b}^T \mathbf{y} > 0\}$ es el conjunto vacío. En la figura 5.27 a la




Figura 5.26: Demostración del lema de Farkas




Figura 5.27: Izquierda: El sistema (I) del lema de Farkas no tiene solución; si (II). Derecha: El sistema (II) no tiene solución; la tiene (I)

derecha se muestra un ejemplo donde el sistema (II) no tiene solución. Todo vector y en la zona que define el cono indicado forma un ángulo mayor de 90° con b . La tiene sin embargo (I) pues b pertenece al cono generado por a_1 , a_2 y a_n .

5.3 Caracterización de las soluciones del problema de optimización y condiciones que cumple un punto óptimo

Volvamos al problema general de Optimización

$$\begin{aligned} & \underset{x \in \mathbb{R}^n}{\text{minimizar}} && f(x) \\ & \text{sujeta a} && c_i(x) = 0, \quad i \in \mathcal{E}, \\ & && c_j(x) \geq 0, \quad j \in \mathcal{I}, \end{aligned}$$


donde las *función objetivo* f y las *condiciones* c_i y c_j son, en general, no lineales, continuas y tienen derivadas parciales continuas hasta al menos primer orden. Los conjuntos $\mathcal{E}$ y $\mathcal{I}$ contienen los índices de las condiciones que son de igualdad y de desigualdad, respectivamente. El conjunto de puntos que satisfacen todas las condiciones se denomina *región factible*.

Un punto x que satisfaga todas las condiciones se dice *regular* si los vectores gradiente del conjunto de condiciones activas en ese punto son linealmente independientes.

Teorema 5.9 *Condiciones de óptimo de primer orden de Karush-Kuhn-Tucker. Supóngase que x^* es un punto regular y mínimo local del problema general de programación matemática anterior. Existe un vector de multiplicadores de Lagrange, λ^* , con coeficientes λ_i , $i \in \mathcal{E} \cup \mathcal{I}$, tal que se cumple que*

$$\begin{aligned} \nabla_x L(x^*, \lambda^*) &= \nabla f(x^*) - \lambda^{*T} c(x^*) = 0, \\ c_i(x^*) &= 0, \text{ para todo } i \in \mathcal{E}, \\ c_i(x^*) &\geq 0, \text{ para todo } i \in \mathcal{I}, \\ \lambda_i^* &\geq 0, \text{ para todo } i \in \mathcal{I}, \\ \lambda_i^* c_i(x^*) &= 0, \text{ para todo } i \in \mathcal{E} \cup \mathcal{I}. \end{aligned}$$

Estas condiciones fueron formuladas por Harold William Kuhn, EE.UU., 1925-2014, y Albert William Tucker, Canadá, 1905-1995, en 1951, con el fin de extender la teoría de Lagrange a la caracterización de los puntos óptimos de problemas de programación lineal y no lineal sometidos a restricciones. Posteriormente se descubrió que en 1939 William Karush, EE.UU., 1917-1997, ya había trabajado sobre estas condiciones, por lo que desde ese momento se les pasó a denominar condiciones de **Karush-Kuhn-Tucker**.



Un caso particular del problema de programación matemática enunciado es el de *Programación Lineal*:

$$\begin{aligned} \min. & \mathbf{c}^T \mathbf{x} \\ \text{s. a} & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Así expresado se denomina en *forma estándar*. La región factible, o conjunto de soluciones del programa lineal, $P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$, es un politopo convexo.

Teorema 5.10 *Equivalencia entre puntos extremos y soluciones básicas. Sean $\mathbf{A} \in \mathbb{R}^{m \times n}$ una matriz de rango m , $\mathbf{b} \in \mathbb{R}^m$ y el politopo convexo*

$$P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}.$$

Un $\mathbf{x} \in P$ es un punto extremo de P si y sólo si los vectores columna de $\mathbf{A}$ asociados a los coeficientes positivos de $\mathbf{x}$ son linealmente independientes.

Demostración. $\mathbf{x} = [\bar{\mathbf{x}}^T, \mathbf{0}^T]^T$, $\bar{\mathbf{x}} > \mathbf{0}$, y designamos por $\bar{\mathbf{A}}$ las p primeras columnas de la matriz $\mathbf{A}$, se tiene que $\mathbf{Ax} = \bar{\mathbf{A}}\bar{\mathbf{x}} = \mathbf{b}$.

Probemos primero la necesidad de la condición enunciada. Supongamos que las columnas de $\bar{\mathbf{A}}$ no son linealmente independientes. En este caso existirá un vector $\bar{\mathbf{w}} \neq \mathbf{0}$ tal que $\bar{\mathbf{A}}\bar{\mathbf{w}} = \mathbf{0}$. De aquí que $\bar{\mathbf{A}}(\bar{\mathbf{x}} \pm \varepsilon\bar{\mathbf{w}}) = \bar{\mathbf{A}}\bar{\mathbf{x}} = \mathbf{b}$ y, para un ε suficientemente pequeño, que $(\bar{\mathbf{x}} \pm \varepsilon\bar{\mathbf{w}}) \geq \mathbf{0}$. Los puntos $\mathbf{y}' = [\bar{\mathbf{x}} + \varepsilon\bar{\mathbf{w}}, \mathbf{0}]^T$ y $\mathbf{y}'' = [\bar{\mathbf{x}} - \varepsilon\bar{\mathbf{w}}, \mathbf{0}]^T$ están, por consiguiente, en P . Además, dado que $\mathbf{x} = (\mathbf{y}' + \mathbf{y}'')/2$, $\mathbf{x}$ no puede ser un punto extremo de P . Como consecuencia de esto, si $\mathbf{x}$ es un punto extremo, las columnas de la matriz $\bar{\mathbf{A}}$ son linealmente dependientes.

Probemos ahora la suficiencia. Supongamos que $\mathbf{x}$ no es un punto extremo de P . Esto quiere decir que $\mathbf{x} = \lambda\mathbf{y}' + (1 - \lambda)\mathbf{y}''$, donde $\mathbf{y}', \mathbf{y}'' \in P$, $\mathbf{y}' \neq \mathbf{y}''$ y $0 < \lambda < 1$. Como $\mathbf{x}$ e $\mathbf{y}'$ están en P , $\mathbf{A}(\mathbf{x} - \mathbf{y}') = \mathbf{Ax} - \mathbf{Ay}' = \mathbf{b} - \mathbf{b} = \mathbf{0}$. Además, dado que λ y $1 - \lambda$ son estrictamente positivos, los últimos $n - p$ coeficientes de $\mathbf{y}'$ y, por consiguiente, de $\mathbf{x} - \mathbf{y}'$, han de ser cero pues lo son los de $\mathbf{x}$. Las columnas de la matriz $\bar{\mathbf{A}}$, en consecuencia, son linealmente dependientes. De aquí que, si las columnas de $\bar{\mathbf{A}}$ son linealmente independientes, $\mathbf{x}$ es un punto extremo. $\square$

Definición 5.15 Una **dirección del politopo** $P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ es un vector no nulo, $\mathbf{d} \in \mathbb{R}^n$, tal que para todo $\mathbf{x}_0 \in P$ el rayo $\{\mathbf{x} \in \mathbb{R}^n : \mathbf{x} = \mathbf{x}_0 + \lambda\mathbf{d}, \lambda \geq 0\}$ pertenece a P .

Una *dirección* $\mathbf{d}$ de un politopo P se dice *extrema* si no puede ponerse como combinación lineal no negativa de dos direcciones diferentes de P . Es decir, no existen dos direcciones $\mathbf{d}_1$ y $\mathbf{d}_2$ en P , $\mathbf{d}_1 \neq \mathbf{d}_2$, y unos $\alpha_1, \alpha_2 > 0$, tales que $\mathbf{d} = \alpha_1\mathbf{d}_1 + \alpha_2\mathbf{d}_2$.

Cualquier dirección de un politopo se puede expresar como combinación lineal no negativa de las direcciones extremas del politopo. Si P es un poliedro, obviamente, no tiene direcciones.

Teorema 5.11 *Teorema de la representación. Todo punto del politopo $P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$ se puede expresar de la forma*

$$x = \sum_{i \in I} \lambda_i v_i + d,$$

donde $\{v_i : i \in I\}$ es el conjunto de puntos extremos o vértices de P , $\sum_{i \in I} \lambda_i = 1$, $\lambda_i \geq 0$, y d , o es una dirección de P , o $d = 0$.

Demostración. La haremos por inducción en p , número de coeficientes positivos de x . Si $p = 0$, el teorema es obvio, pues $x = 0$ es un punto extremo. Supongamos que se cumple lo enunciado para puntos con menos de p coeficientes positivos y que x tiene p coeficientes positivos.

Si x es un punto extremo, como $x = v_i$ para algún $i \in I$, el teorema es obvio. Supongamos por tanto que x no es un punto extremo. En este caso existe un vector $w \neq 0$, con $w_i = 0$ si $x_i = 0$, tal que $Aw = 0$. Se pueden dar los tres casos siguientes:

- (a) *Que w tenga coeficientes positivos y negativos.* Consideremos los puntos $x(\theta) = x + \theta w$ en la recta que pasa por x que determina w , y sean θ' y θ'' el menor valor positivo y mayor valor negativo, respectivamente, de θ para los que $x(\theta)$ tiene al menos un coeficiente cero más que los que tiene x . Los puntos $x' = x(\theta')$ y $x'' = x(\theta'')$ pertenecen claramente a P por lo que, por la hipótesis de inducción, al tener un coeficiente nulo más, se pueden expresar según lo enunciado en el teorema. En consecuencia, como x está en la recta que une x' y x'' , se puede expresar de la siguiente manera

$$\begin{aligned} x &= \mu x' + (1 - \mu)x'' && \text{donde } \mu = -\theta''/(\theta' - \theta'') \\ &= \mu \left(\sum_{i \in I} \lambda'_i v_i + d' \right) + (1 - \mu) \left(\sum_{i \in I} \lambda''_i v_i + d'' \right) \\ &= \sum_{i \in I} \left(\mu \lambda'_i + (1 - \mu) \lambda''_i \right) v_i + \mu d' + (1 - \mu) d''. \end{aligned}$$

Como $0 < \mu < 1$, $\lambda'_i \geq 0$ y $\lambda''_i \geq 0$ para todo $i \in I$, $\sum_{i \in I} \lambda'_i = \sum_{i \in I} \lambda''_i = 1$ y $Ad' = Ad'' = 0$, $d' \geq 0$ y $d'' \geq 0$. Se deduce entonces que

$$\begin{aligned} \lambda_i &= \mu \lambda'_i + (1 - \mu) \lambda''_i \geq 0 && \text{para todo } i \in I, \quad \sum_{i \in I} \lambda_i = 1, \\ d &= \mu d' + (1 - \mu) d'' \geq 0 && \text{y } Ad = 0, \end{aligned}$$

quedando probado que x se puede expresar de la forma enunciada.

- (b) *Que $w \leq 0$.* Definamos x' como en el caso (a). El punto x se puede expresar como $x = x' + \theta'(-w)$, con $\theta' > 0$. Como x' se puede expresar por inducción en la forma deseada y $(-w)$ es una dirección en P , x también se puede expresar de la forma enunciada.

- (c) Que $w \geq 0$. Este caso se prueba igual que el caso (b) sin más que sustituir x' , θ' y $-w$ por x'' , $-\theta''$ y w , respectivamente.

□

Corolario 5.12 Si el politopo $P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$ es no vacío, tiene al menos un punto extremo o vértice.

Corolario 5.13 Si el politopo $P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$ es cerrado y acotado (es un poliedro), todo punto $x \in P$ se puede expresar como combinación convexa de sus puntos extremos.




Figura 5.28: Representación de un punto de un politopo (poliedro) como combinación convexa de puntos extremos

Teorema 5.14 Teorema fundamental de la Programación Lineal. Dado un politopo no vacío $P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$ de soluciones de un PL, el valor mínimo de la función objetivo $c^T x$, para $x \in P$, se alcanza en un punto extremo de P (solución básica factible óptima), o $c^T x$ no está acotada inferiormente en P .

Demostración. Sea $V = \{v_i : i \in I\}$ el conjunto de puntos extremos de P . Como P es no vacío, al menos tiene un punto extremo $v_i \in V$. De acuerdo con el teorema de la representación, o el politopo P posee una dirección d tal que $c^T d < 0$, o tal dirección no existe. Consideremos estos dos casos.

- (a) El politopo P tiene una dirección d tal que $c^T d < 0$. En este caso P no está acotado y el valor de la función objetivo tiende a $-\infty$ en la dirección d .
- (b) El politopo P no tiene una dirección d tal que $c^T d < 0$. En este caso cualquier $x \in P$ se puede expresar de una de las dos maneras siguientes:

$$x = \sum_{i \in I} \lambda_i v_i \quad \text{donde} \quad \sum_{i \in I} \lambda_i = 1, \quad \lambda_i \geq 0 \text{ o}$$

$$x = \sum_{i \in I} \lambda_i v_i + \bar{d} \quad \text{donde} \quad \sum_{i \in I} \lambda_i = 1, \quad \lambda_i \geq 0 \text{ y} \quad c^T \bar{d} \geq 0.$$

En ambos casos, suponiendo que $\mathbf{c}^T \mathbf{v}_{min}$ es el menor de los elementos del conjunto $\{\mathbf{c}^T \mathbf{v}_i : i \in I\}$, se tiene que

$$\mathbf{c}^T \mathbf{x} \geq \sum_{i \in I} \lambda_i (\mathbf{c}^T \mathbf{v}_i) \geq \mathbf{c}^T \mathbf{v}_{min} \left(\sum_{i \in I} \lambda_i \right) = \mathbf{c}^T \mathbf{v}_{min}.$$

Es decir, el mínimo de $\mathbf{c}^T \mathbf{x}$ se alcanza en un punto extremo de P : $\mathbf{v}_{min}$.

□

5.4 Dualidad en optimización

Las variables duales y los conjuntos de elementos duales tienen interpretaciones y significaciones muy relevantes en optimización. Se dan en muchos problemas matemáticos y modelos de realidades físicas, donde se toman decisiones u optimizan recursos. Por ejemplo:

- Las tensiones (variables primales) y las intensidades (duales) en circuitos eléctricos donde se optimizan los flujos de energía y los costes para satisfacer la demanda.
- La descripción de señales en el dominio del tiempo (problema primal) y en el de frecuencia (dual).
- Los niveles de producción de productos (variables primales) y los precios (duales) a los que los pagan los consumidores o clientes.
- Las tensiones (variables primales) y los desplazamientos (duales) en el análisis o diseño de estructuras mecánicas.
- Los conjuntos, o unión de elementos, convexos (variables primales) y la intersección de semiespacios (duales) que los delimitan, como se ve en la figura 5.29.




Figura 5.29: Unión de puntos e intersección de semiespacios que lo delimita

Los problemas duales, en general, posibilitan acotar los valores alcanzables por los primales. Permiten poder saber cuándo una aproximación a la solución de un problema es “suficientemente” buena.


La solución óptima de un problema dual de otro primal, en optimización, *certifica* que se ha alcanzado o se puede alcanzar la del primal.

Por estas consideraciones y porque los problemas duales en optimización a menudo tienen una estructura más agradable o manejable que los primales es por lo que pasamos a exponer —a grandes rasgos— sus principales características y cómo deben ser estudiados.

La Dualidad juega un papel destacado en la optimización de problemas de programación lineal y de programación no lineal. Sirve para caracterizar y verificar la condición de un óptimo de un proceso iterativo, y las condiciones en que se da, para analizar la sensibilidad de una solución a la variación de los parámetros del problema, para estudiar la velocidad de convergencia de determinados algoritmos de optimización que usan su formulación y para contemplar diversos aspectos geométricos que permiten interpretar mejor lo que se está haciendo en la búsqueda de una solución.

Las ideas y formulación que exponemos a continuación siguen muy de cerca lo que se presenta en los libros de Boyd y Vandenberghe [2004], Luenberger [1969] y Luenberger y Ye [2016]. Se basa en una forma elegante y global de contemplar la dualidad en términos de conjuntos e hiperplanos que tocan esos conjuntos.

Los métodos numéricos basados en la dualidad siguen el enfoque o punto de vista de que las incógnitas fundamentales asociadas a un problema de optimización con condiciones son los Multiplicadores de Lagrange —por Joseph-Louis Lagrange, Turin, 1736-París, 1813—.



Una vez se conocen estos multiplicadores la determinación del punto de solución es simple (al menos en algunas situaciones). Los métodos duales, por lo tanto, no acometen el problema original con condiciones —problema primal—, sino que atacan un problema alternativo, el problema dual, cuyas incógnitas son los multiplicadores de Lagrange del problema primal. Para un problema con n variables y m restricciones o condiciones de igualdad, los métodos duales trabajan en el espacio m -dimensional de los multiplicadores de Lagrange. Debido a que estos multiplicadores miden sensibilidades del problema, a menudo tienen interpretaciones intuitivas significativas, como precios asociados con recursos escasos, por lo que su búsqueda es a menudo la materialización de un problema práctico de la vida cotidiana, y tan atractivo o más como el de buscar los valores del óptimo del problema original o problema primal.

Los multiplicadores de Lagrange definen hiperplanos que pueden ser considerados los duales de puntos en un espacio vectorial. Esta forma teórica de interpretar la dualidad proporciona una simetría entre los problemas primal y dual, la cual puede considerarse perfecta si los problemas son convexos. Si no lo son, la *imperfección* la plasma el denominado *gap de dualidad*, o *brecha dual*, que tiene una interpretación geométrica muy sencilla en este contexto y mucha importancia en los algoritmos actuales de programación lineal y no lineal.

Los *multiplicadores de Lagrange* del problema primal, que miden las sensibilidades del problema original a variaciones en los coeficientes que determinan las condiciones de este problema, determinan una especie de penalizaciones que se introducen en su función objetivo por no utilizar adecuadamente los recursos que fijan esas condiciones. La función de Lagrange incorpora así toda la información disponible del problema.

La teoría que se expone en este apartado es la base general sobre la que construir dualidades de tipo local de los diversos problemas lineales y no lineales, incluso sin la existencia de convexidad. Sirve también para comprender mejor los algoritmos de punto interior especializados en problemas de Programación Lineal, el dual del Símplex y otros afines.

De momento vamos a referirnos a problemas de programación matemática como

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimizar}} && f(\mathbf{x}) \\ & \text{sujeta a} && \mathbf{g}(\mathbf{x}) \leq \mathbf{0} \\ & && \mathbf{x} \in \Omega, \end{aligned} \quad (2)$$

donde $\Omega \in \mathbb{R}^n$ es un conjunto convexo y las funciones, la escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y la vectorial $\mathbf{g} : \mathbb{R}^p \rightarrow \mathbb{R}^p$, están definidas en Ω . Este problema no es necesariamente convexo pero se asume que tiene al menos un punto factible. Esta notación es perfectamente compatible con otras que se utilizan sin más que adoptar la convención de signos adecuada.

La *función primal* asociada al problema (2) se define, para un $\mathbf{z} \in \mathbb{R}^p$, como

$$\omega(\mathbf{z}) = \inf \{ f(\mathbf{x}) : \mathbf{g}(\mathbf{x}) \leq \mathbf{z}, \mathbf{x} \in \Omega \}. \quad (3)$$

Se llega a ella dejando que el término de la derecha de la inecuación que definen las condiciones pueda tomar valores arbitrarios. Se entiende que (3) está definida en el conjunto $D = \{ \mathbf{z} : \mathbf{g}(\mathbf{x}) \leq \mathbf{z}, \text{ para algunos } \mathbf{x} \in \Omega \}$.

Si el problema (2) tiene una solución $\mathbf{x}^*$ con un valor de la función objetivo igual a $f^* = f(\mathbf{x}^*)$, entonces f^* es el punto de eje vertical de $\mathbb{R}^{p+1}$ donde la función primal se cruza con ese eje. Si (2) no tiene solución ese punto de cruce es $f^* = \inf \{ f(\mathbf{x}) : \mathbf{g}(\mathbf{x}) \leq \mathbf{0}, \mathbf{x} \in \Omega \}$.

El principio de dualidad se deduce de la consideración de todos los hiperplanos que quedan por debajo de la función primal. Como ilustra la figura 5.30, todos los hiperplanos que se indican se cruzan con el eje vertical por debajo de f^* , o en f^* .

Para expresar esta propiedad se define la **función dual** en el cono positivo de $\mathbb{R}^p$, $\mathbb{R}_+^p$, como

$$\phi(\boldsymbol{\mu}) = \inf \{ f(\mathbf{x}) + \boldsymbol{\mu}^T \mathbf{g}(\mathbf{x}) : \mathbf{x} \in \Omega \}.$$

En general, ϕ puede que no sea finita dentro del *ortante* —el equivalente en n dimensiones a un cuadrante en el plano o un octante en tres dimensiones— positivo, $\mathbf{R}_+^p$, pero la región donde está definida y es finita es convexa.

Proposición 5.15 La función dual es cóncava en la región donde es finita.




Figura 5.30: Hiperplano por debajo de $w(z)$.

Demostración. Supóngase que μ_1 y μ_2 están en la región finita y sea $0 \leq \alpha \leq 1$. Entonces

$$\begin{aligned} \phi(\alpha\mu_1 + (1-\alpha)\mu_2) &= \inf \{f(x) + (\alpha\mu_1 + (1-\alpha)\mu_2)^T g(x) : x \in \Omega\} \\ &\geq \inf \{\alpha f(x_1) + \alpha\mu_1^T g(\mu_1) : x_1 \in \Omega\} \\ &\quad + \inf \{(1-\alpha)f(x_2) + (1-\alpha)\mu_2^T g(x_2) : x_2 \in \Omega\} \\ &= \alpha\phi(\mu_1) + (1-\alpha)\phi(\mu_2), \end{aligned}$$

lo que concluye la demostración. $\square$

Se define $\phi^* = \sup \{\phi(\mu) : \mu \geq \mathbf{0}\}$, suponiéndose que el supremo se extiende a toda la región donde ϕ es finita.

Proposición 5.16 *Forma débil de dualidad.* $\phi^* \leq f^*$.

Demostración. Para todo $\mu \geq \mathbf{0}$ se tiene que

$$\begin{aligned} \phi(\mu) &= \inf \{f(x) + \mu^T g(x) : x \in \Omega\} \\ &\leq \inf \{f(x) + \mu^T g(x) : g(x) \leq \mathbf{0}, x \in \Omega\} \\ &\leq \inf \{f(x) : g(x) \leq \mathbf{0}, x \in \Omega\} = f^*. \end{aligned}$$

Tomando supremos en el miembro de la izquierda, $\phi(x)$, se llega a que $\phi^* \leq f^*$. $\square$

De acuerdo con este resultado la función dual proporciona cotas inferiores del valor óptimo de f , lo cual es muy interesante desde el punto de vista de su aplicación a problemas prácticos.

La *función dual* tiene una interpretación geométrica muy interesante. Si se considera el vector $[1 \ \mu^T]^T \in \mathbb{R}^{p+1}$, con $\mu \geq \mathbf{0}$ y la constante c , el conjunto de vectores $[r \ z^T]^T \in \mathbb{R}^{p+1}$ tales que el producto interior $[1 \ \mu^T][r \ z^T]^T \equiv r + \mu^T z = c$ define un hiperplano en $\mathbb{R}^{p+1}$. Para diferentes valores de c se tiene diferentes hiperplanos, todos paralelos entre si.

Para un vector dado $[1 \ \mu^T]^T$ consideremos el hiperplano más bajo posible de esa forma que casi toca —soporta— la región de encima de la función primal del problema (2). Supongamos que $\mathbf{x}_1$ define ese punto de contacto y que $r = f(\mathbf{x}_1)$ y $\mathbf{z} = \mathbf{g}(\mathbf{x}_1)$. Se tendrá que $c = f(\mathbf{x}_1) + \mu^T \mathbf{g}(\mathbf{x}_1) = \phi(\mu)$.

Ese hiperplano se cruzará con el eje vertical en un punto de la forma $[r_0 \ \mathbf{0}]^T$. Este punto también satisfará que $[1 \ \mu^T]^T [r_0 \ \mathbf{0}]^T = c = \phi(\mu)$. Lo que lleva a que $c = r_0$. Por lo que ese punto dará será el valor $\phi(\mu)$ directamente. La función dual en μ es igual al punto donde se cruzan el hiperplano definido por μ que justo toca el *epigrafo* —el conjunto de puntos situados en o por encima del gráfico de una función— de la función primal.

Además, como indica la figura 5.31, ese punto de cruce (y el valor de la función dual) se maximiza con el multiplicador de Lagrange que corresponde al hiperplano más alto posible que intercepta el eje vertical y casi toca a la función, siendo el punto de esa intercepción menor o igual que el valor óptimo f^* . La diferencia constituye el *gap de dualidad*.




Figura 5.31: Hiperplano más alto

Si se incorporan suposiciones de convexidad el análisis que estamos haciendo se completa con el teorema de la dualidad fuerte cuando no hay gap de dualidad y la intersección de esos planos con el eje vertical es el propio f^* . Se puede ver en la figura 5.32.

El teorema siguiente se refiere al problema

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimizar}} && f(\mathbf{x}) \\ & \text{sujeta a} && \mathbf{h}(\mathbf{x}) = \mathbf{0} \\ & && \mathbf{g}(\mathbf{x}) \leq \mathbf{0} \\ & && \mathbf{x} \in \Omega, \end{aligned} \tag{4}$$

donde $\mathbf{h} : \mathbb{R}^m \rightarrow \mathbb{R}^n$ es afín, $\mathbf{g} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ es convexa y Ω es convexo. La *función dual* de este problema es

$$\phi(\lambda, \mu) = \inf \{ f(\mathbf{x}) + \lambda^T \mathbf{h}(\mathbf{x}) + \mu^T \mathbf{g}(\mathbf{x}) : \mathbf{x} \in \Omega \},$$

y $\phi^* = \sup \{\phi(\lambda, \mu) : \lambda \in \mathbb{R}^m, \mu \in \mathbb{R}^p, \mu \geq 0\}$.

Teorema 5.17 Teorema de la dualidad fuerte. Supongamos que en el problema (4) h es regular con respecto a Ω y que existe un punto $x \in \Omega$ en el que $h(x) = 0$ y $g(x) \leq 0$. Supongamos que el problema tiene como solución x^* con un valor de la función objetivo $f(x^*) = f^*$. Entonces, para todo $\lambda, \mu \geq 0$ se cumple que

$$\phi^* \leq f^*.$$

Además, existen unos $\lambda, \mu \geq 0$ tales que $\phi(\lambda, \mu) = f^*$ y por lo tanto $\phi^* = f^*$. Los vectores λ y μ son los multiplicadores de Lagrange del problema.

Un punto x que satisfaga todas las condiciones que se cumplen se dice *regular* si los vectores gradiente del conjunto de condiciones activas en ese punto son linealmente independientes. Una función $h(x)$ es *regular* con respecto a Ω si el conjunto $C = \{y : h(x) = y \text{ para algún } x \in \Omega\}$ de $\mathbb{R}^n$ contiene una bola abierta en torno a 0 ; es decir, C contiene un conjunto de la forma $\{y : |y| < \varepsilon\}$ para algún $\varepsilon > 0$. Esto viene a decir que $h(x)$ puede hacerse 0 y variar arbitrariamente en torno a 0 en cualquier dirección. Esta condición es similar a la definición de punto regular en el contexto de las condiciones de óptimo de primer orden.

5.4.1 Dualidad Lagrangiana

Es una forma de denominar lo que acabamos de exponer. La *función de Lagrange* del problema (4) escrito

$$\begin{aligned} &\text{minimizar}_{x \in \mathbb{R}^n} f(x) \\ &\text{sujeta a } \begin{aligned} &h(x) = 0 \\ &g(x) \leq 0 \\ &x \in \Omega, \end{aligned} \end{aligned} \quad (5)$$




Figura 5.32: Expresión gráfica del teorema de la dualidad fuerte . No hay gap de dualidad

es $L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{h}(\mathbf{x}) + \boldsymbol{\mu}^T \mathbf{g}(\mathbf{x})$. Esta función penaliza que $\mathbf{g}(\mathbf{x})$ sea positiva y que $\mathbf{h}(\mathbf{x})$ no sea cero. La *función de Lagrange dual* es

$$q(\boldsymbol{\lambda}, \boldsymbol{\mu}) \stackrel{\text{def}}{=} \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}).$$

Esta *función es cóncava* por ser afín, aunque no lo sean ni $\mathbf{h}(\mathbf{x})$ y $\mathbf{g}(\mathbf{x})$. Puede ser $-\infty$ para algunos valores de $\boldsymbol{\lambda}$ y $\boldsymbol{\mu}$. La **función de Lagrange dual define una cota inferior del valor óptimo de la función objetivo de (5)**. Es decir $q(\boldsymbol{\lambda}, \boldsymbol{\mu}) \leq p^*$ si $\boldsymbol{\mu} \geq \mathbf{0}$. El problema dual de 5 es este:

$$\begin{aligned} &\text{maximizar } q(\boldsymbol{\lambda}, \boldsymbol{\mu}) \\ &\text{sujeta a } \boldsymbol{\mu} \geq \mathbf{0}, \end{aligned}$$

que es siempre convexo.

5.4.1.1 Interpretación geométrica

En este apartado seguimos lo que exponen Boyd y Vandenberghe [2004], J-P Vert y R. Freund. Consideraremos una versión bastante simple del problema 5 con una sola condición:

$$\begin{aligned} &\text{minimizar } f(\mathbf{x}) \\ &\text{sujeta a } \begin{aligned} &\mathbf{g}(\mathbf{x}) \leq \mathbf{0} \\ &\mathbf{x} \in \Omega, \end{aligned} \end{aligned}$$

donde $f, g \in \mathbb{R}^n \rightarrow \mathbb{R}$. Y a este respecto el subconjunto de $\mathbb{R}^2$ definido así:

$$S = \{(g(\mathbf{x}), f(\mathbf{x})) | \mathbf{x} \in \mathbb{R}^n\}.$$

El valor óptimo del problema, f^* , estará determinado por

$$f^* = \inf \{t | (t, u) \in S, u \leq 0\},$$

como se puede ver en la figura 5.33, pues es el punto en t más bajo en la parte de la región factible (fijada por los valores a la izquierda del eje t en el conjunto S). El planteamiento de este problema sería, por ejemplo, la abstracción de uno de determinar el coste mínimo global de una planta de fabricación de productos diversos con varios tipos de recursos, el balance global de los cuales a lo largo de un periodo de tiempo debe ser menor o igual que cero. Es decir, que no se consuman más de los disponibles.

La función de Lagrange de este problema es $L(\mathbf{x}, \mu) = f(\mathbf{x}) + \mu g(\mathbf{x})$. La función de Lagrange dual, o simplemente la *función dual*, es

$$q(\mu) = \inf_{(u,t) \in S} \{t + \mu u\}.$$

Según la figura 5.34, el punto donde corta al eje t en su punto más bajo posible el hiperplano soporte del conjunto S que define $t + \mu u = \text{cte}$. —en este caso una línea recta— será el valor de la función dual.




Figura 5.33: Sencillo esquema de un problema de optimización para interpretar geométricamente la dualidad lagrangiana




Figura 5.34: Función dual del problema para interpretar geométricamente la dualidad lagrangiana

De todos esos hiperplanos soporte, con $\mu \geq 0$, el que obtiene el **óptimo del problema dual**,

$$d^* = \underset{\mu \geq 0}{\text{maximizar}} \, q(\mu) = \underset{\mu \geq 0}{\text{maximizar}} \, \inf_{(u,t) \in S} \{t + \mu u\},$$

lo dará la intersección con el eje t del que se esquematiza en la figura 5.35 que toca los dos puntos más bajos de S que se ven. El **gap de dualidad** en este ejemplo es la diferencia entre f^* y d^* : $d^* \leq f^*$, dualidad débil.

En el caso de dualidad fuerte, sin gap de dualidad, se darían formas como la de la figura 5.36.




Figura 5.35: Óptimo de la función dual del problema para interpretar geoméricamente la dualidad lagrangiana





Figura 5.36: Dualidad fuerte: $f^* = d^*$

5.4.2 Dualidad de Wolfe

Es ligeramente distinta de las anteriores. Se debe a Philip Starr Wolfe, EE.UU. 1927-.



Es la que sirve de referencia a los métodos de punto interior. El problema dual es

$$\begin{aligned} \max. \quad & L(x, \lambda, \mu) \\ \text{s. a} \quad & \nabla_x L(x, \lambda, \mu) = \mathbf{0} \\ & \mu \geq \mathbf{0}. \end{aligned}$$

Ejemplo 5.6 En el caso de un problema de Programación Lineal en forma estándar

$$\begin{aligned} & \underset{x \in \mathbb{R}^n}{\text{minimizar}} && c^T x \\ & \text{sujeta a} && Ax = b \\ & && x \geq 0, \end{aligned}$$

la función de Lagrange es $L(x, \lambda, \mu) = c^T x - \lambda^T (Ax - b) - \mu^T x$, o

$$L(x, \lambda, \mu) = \lambda^T b + (c - A^T \lambda - \mu)^T x.$$

Su problema dual

$$\begin{aligned} \max. \quad q(\lambda, \mu) &= \inf \{L(x, \lambda, \mu)\} = \lambda^T b + \inf_x \{(c - A^T \lambda - \mu)^T x\} \\ &= \begin{cases} \lambda^T b & \text{si } c - A^T \lambda - \mu = 0 \\ -\infty & \text{si } c - A^T \lambda - \mu \neq 0 \end{cases} \\ \text{s. a} \quad &\mu \geq 0. \end{aligned}$$

Si $c - A^T \lambda - \mu \neq 0$ el ínfimo es claramente $-\infty$, por lo que hay que excluir del problema aquellos λ para los que se den esos casos. De acuerdo con ello, el problema dual queda

$$\begin{aligned} & \text{maximizar} && \lambda^T b \\ \text{s. a} &&& c - A^T \lambda - \mu = 0, \quad \mu \geq 0. \end{aligned}$$

El dual de Wolfe sería exactamente el mismo. El *gap de dualidad* es

$$c^T x - \lambda^T b = c^T x - \lambda^T Ax = x^T (c - A^T \lambda) = x^T \mu.$$

5.5 Funciones conjugadas-funciones de Fenchel

Al introducir este apartado dedicado a la dualidad nos referíamos a los pares primal-dual, y concretamente a La Transformada de Fourier para analizar señales en el dominio de tiempos y, o, de frecuencias. Una contrapartida en el caso de análisis y optimización de funciones convexas la constituye la Conjugada de Fenchel o Función Conjugada, y la transformación conjugada.

Definición 5.16 Si consideramos la función $f : \mathbb{R}^n \rightarrow [-\infty, \infty]$, se define la **función conjugada** de f —también **conjugada de Fenchel** o **transformación de Fenchel**—, a la función $f^* : \mathbb{R}^n \rightarrow [-\infty, \infty]$ dada por

$$f^*(y) = \sup_{x \in \mathbb{R}^n} \{x^T y - f(x)\}.$$

La función conjugada es de mucha utilidad en optimización para “convexificar” una función y para el cálculo del subdiferencial de una función convexa .

La transformación de Fenchel coincide con la **transformación de Legendre**, por Andrien-Marie Legendre, Francia, 1752-1833.



cuando se refieren a funciones convexas y diferenciables en todas direcciones (existen todas sus derivadas parciales).

En la figura 5.37 se proporciona una interpretación geométrica de esta definición. La función (convexa en este caso) $f(x)$ y su epigrafo están descritos por hiperplanos




Figura 5.37: Visualización de la conjugada de Fenchel

soporte. Uno de estos, la función conjugada, está asociado con un punto de cruce con el eje vertical que es $-f^*(y) = \inf_{x \in \mathbb{R}^n} \{f(x) - x^T y\}$.

Una interpretación económica de la función conjugada identifica $x^T y - f(x)$ con el beneficio de producir la cantidad x de bienes cuando los precios están dados por el vector y . El máximo de ese beneficio asociado a y es la función conjugada $f^*(y)$.

Cualquiera que sea la estructura de f , su función conjugada f^* es convexa y cerrada pues es el supremo, punto a punto, de la colección de funciones afines

$$x^T y - f(x), \text{ para todo } x \text{ tal que } f(x) \text{ es finita.}$$

Si la función $f(x)$ no es convexa, el correspondiente gráfico para interpretar la función conjugada sería el de la figura 5.38.




Figura 5.38: Conjugada de Fenchel de una función no convexa

Una consecuencia inmediata de la definición de función conjugada es la *desigualdad de Fenchel-Young*,

$$f(x) + f^*(y) \geq x^\top y,$$

por Fenchel y William Henry Young, Reino Unido 1863-1942.



Para que esta desigualdad se haga igualdad es necesario y suficiente que

$$f(x) + f^*(y) = x^\top y \Leftrightarrow y \in \partial f(x) \Leftrightarrow x \in \partial f^*(y).$$

En la figura 5.39 se indican algunos ejemplos de funciones conjugadas habituales. Son de Bertsekas [2009]. Se puede verificar en cada una de ellas que la conjugada de la conjugada es la función original.

Ejemplo 5.7 La función cuadrática $f(x) = \frac{1}{2}x^\top Qx$, donde $Q \succ 0$. La expresión $y^\top x - \frac{1}{2}x^\top Qx$ es estrictamente cóncava con respecto a x y tiene un punto máximo en $x = Q^{-1}y$ por lo que

$$f^*(y) = \frac{1}{2}y^\top Q^{-1}y. \quad \bullet$$

Ejemplo 5.8 La función $f(x) = -\log(x)$.

$$f^*(y) = \sup_{x>0} (x^\top y + \log(x)) = \begin{cases} -1 - \log(-y) & y < 0 \\ \infty & \text{en cualquier otro caso.} \end{cases} \quad \bullet$$




Figura 5.39: Ejemplo de funciones conjugadas de funciones habituales

Ejemplo 5.9 La función $f(x) = \|x\|$, una norma en $\mathbb{R}^n$, siendo su norma dual asociada $\|x\|_* = \sup_{\|u\| \leq 1} u^\top x$, tiene por función conjugada

$$f^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{en cualquier otro caso.} \end{cases}$$

Esto se denomina *función indicador* de la norma dual de la esfera unidad. La norma dual de la norma euclídea es la propia norma euclídea. ●

5.6 Optimización SDP

O, realmente, *Programación Semidefinida*. Se refiere a un problema de optimización convexa que trata de maximizar o minimizar una función objetivo lineal de una incógnita, que es una matriz simétrica a la que se impone la condición de ser semidefinida positiva. El óptimo también debe satisfacer el encontrarse en la intersección del cono que genera

la condición de la matriz y un subespacio afín. El diagrama de la figura 5.40 muestra dónde se ubica la Programación Semidefinida en un entorno de programas convexos.




Figura 5.40: Jerarquía de los problemas o programas convexos y su tratamiento. Dattorro [2016]

Uno de los elementos que lanzaron al estrellato este tipo de problemas fue el contar con la potencia de los algoritmos de punto interior para tratar problemas de grandes dimensiones. Hay una amplia variedad de problemas de optimización convexa no lineal que se pueden presentar como problemas de este tipo —que implican desigualdades denominadas de matriz lineal (LMI)— y resolverse hoy en día muy eficientemente usando esos métodos de punto interior.

La programación semidefinida es una importante herramienta numérica para el análisis y resolución de problemas en sistemas y teoría de control. También se usan cada día más en la optimización combinatoria como una técnica valiosa para obtener límites en la solución de problemas NP-duros (de toma de decisiones). Sus aplicaciones crecen día a día en geometría computacional, diseño de experimentos, teoría de información y comunicación, optimización de valores propios en diseño de estructuras, diagnóstico médico y otros.

5.6.1 Definiciones y planteamiento del problema

Se designa el espacio vectorial de matrices reales de orden n simétricas por

$$\mathcal{S}^n := \{\mathbf{M} \in \mathbb{R}^{n \times n} : \mathbf{M}^\top = \mathbf{M}\}.$$

A la parte de este $\mathcal{S}^n$ que forman la matrices simétricas semidefinidas positivas como

$$\mathcal{S}_+^n := \{\mathbf{M} \in \mathcal{S}^n : \mathbf{M} \succcurlyeq 0\},$$

donde mediante $\mathbf{M} \succcurlyeq 0$ se designa una tal matriz y a

$$\mathcal{S}_{++}^n := \{\mathbf{M} \in \mathcal{S}^n : \mathbf{M} \succ 0\}$$

como la parte de $\mathcal{S}^n$ que definen la matrices definidas positivas.

El espacio $\mathcal{S}^n$ está dotado de un producto escalar o producto interior

$$\langle \cdot, \cdot \rangle : (\mathbf{M}, \mathbf{N}) \in \mathcal{S}^n \times \mathcal{S}^n \mapsto \langle \mathbf{M}, \mathbf{N} \rangle = \text{tr}(\mathbf{M}\mathbf{N}) = \sum_{ij} M_{ij} N_{ij},$$

donde $\text{tr}(\mathbf{M}\mathbf{N})$ denota la traza del producto matricial $\mathbf{M}\mathbf{N}$.

El producto interior de matrices generales se calcula de forma similar al de vectores: Primero transformando o vectorizando la matriz $\mathbb{R}^{p \times k}$, donde p es el número de filas de la matriz y k el número de columnas, en un vector de $\mathbb{R}^{pk}$ concatenando para ello los vectores columna en un orden natural. Por ejemplo, la vectorización de $\mathbf{Y} = [y_1 \ y_2 \ \cdots \ y_k] \in \mathbb{R}^{p \times k}$ es

$$\text{vec } \mathbf{Y} \triangleq \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_k \end{bmatrix} \in \mathbb{R}^{pk}.$$

De acuerdo con esto, el producto interior de dos matrices no necesariamente simétricas $\mathbf{Y}$ y $\mathbf{Z}$ es

$$\langle \mathbf{Y}, \mathbf{Z} \rangle \triangleq \text{tr}(\mathbf{Y}^\top \mathbf{Z}) = \text{vec}(\mathbf{Y})^\top \text{vec } \mathbf{Z}.$$

Además

$$\text{tr}(\mathbf{Y}^\top \mathbf{Z}) = \text{tr}(\mathbf{Z}\mathbf{Y}^\top) = \text{tr}(\mathbf{Y}\mathbf{Z}^\top) = \text{tr}(\mathbf{Z}^\top \mathbf{Y}) = \mathbf{1}^\top (\mathbf{Y} \circ \mathbf{Z}) \mathbf{1},$$

donde el signo $\circ$ indica el *producto de Hadamard*, por Jacques Salomon Hadamard, Francia 1865-1963.



De igual manera $\text{vec}(\mathbf{Y} \circ \mathbf{Z}) = \text{vec}(\mathbf{Y}) \text{vec}(\mathbf{Z})$.

Si las matrices son simétricas en $\mathcal{S}^n$ la vectorización transforma la matriz en $\mathbb{R}^{n^2}$. Como antes, si $\mathbf{Y} = [y_1 \ y_2 \ \cdots \ y_n] \in \mathbb{R}^{n \times n}$ la vectorización simétrica es

$$\text{svec } \mathbf{Y} \triangleq \begin{bmatrix} y_{11} \\ \sqrt{2}y_{12} \\ y_{22} \\ \sqrt{2}y_{13} \\ \sqrt{2}y_{23} \\ y_{33} \\ \vdots \\ y_{nn} \end{bmatrix} \in \mathbb{R}^{n(n+1)/2}.$$

Para ignorar coeficientes redundantes, y reducir el subespacio a $\mathbb{R}^{n(n+1)/2}$, en la transformación se han escalado los coeficientes que no están en la diagonal principal. En este caso, si $Y, Z \in \mathcal{S}^n$,

$$\langle Y, Z \rangle \triangleq \text{tr}(Y^\top Z) = \text{vec}(Y)^\top \text{vec } Z = \mathbf{1}^\top (Y \circ Z) \mathbf{1} = \text{svec}(Y)^\top \text{svec } Z.$$

Volviendo a los *conos* apuntados más arriba, $\mathcal{S}_+^n$ y $\mathcal{S}_{++}^n$, tienen las siguientes propiedades:

1. $M \succcurlyeq 0 \iff \forall N \succcurlyeq 0$, se tiene que $\langle M, N \rangle \geq 0$.
2. $M \succ 0 \iff \forall N \succcurlyeq 0$ no nula, se tiene que $\langle M, N \rangle > 0$
3. Si M y $N \in \mathcal{S}_+^n$, se tiene que $\langle M, N \rangle = 0 \iff MN = 0$.

Con la notación y definiciones expuestas, el problema SDP se plantea así.

$$\begin{aligned} & \text{minimizar } \langle C, X \rangle \\ & \quad X \in \mathcal{S}^n \\ & \text{sujeta a } \quad \langle A, X \rangle = b \\ & \quad X \succcurlyeq 0, \end{aligned}$$

donde $C \in \mathcal{S}^n$, $A : \mathcal{S}^n \rightarrow \mathbb{R}^m$ es una aplicación lineal y $b \in \mathbb{R}^m$. Es el problema primal de SDP. Se trata de minimizar en él un criterio lineal en la intersección del cono de matrices semidefinidas positivas y un subespacio afín como esquematiza la figura 5.41. La función objetivo es lineal así como las condiciones. El requisito de pertenencia al cono $\mathcal{S}_+^n$ es no lineal y en algún caso no derivable.




Figura 5.41: Visualización de un cono semidefinido positivo en 3D. Dattorro [2016]

La aplicación lineal se puede representar mediante m matrices, $A_i \in \mathcal{S}^n$ —teorema

de Riesz-Fréchet—, por Frigyes Riesz, Hungría 1880-1956,



y Maurice Fréchet, así

$$\langle A, X \rangle = \begin{bmatrix} \langle A_1, X \rangle \\ \vdots \\ \langle A_m, X \rangle \end{bmatrix}.$$

Si el espacio $\mathbb{R}^m$ está dotado de un producto escalar, o producto interior, también expresado mediante $\langle \cdot, \cdot \rangle$, y se introduce el operador $A^* : \mathbb{R}^m \rightarrow \mathcal{S}^n$, adjunto a A y definido así

$$\forall X \in \mathcal{S}^n, \forall y \in \mathbb{R}^m : \langle A(X), y \rangle = \langle X, A^*(y) \rangle$$

el problema dual de SDP se plantea así

$$\begin{aligned} & \underset{(y, S) \in \mathbb{R}^m \times \mathcal{S}^n}{\text{maximizar}} && \langle b, y \rangle \\ & \text{sujeta a} && \langle A^*, y \rangle + S = C \\ & && S \succeq 0, \end{aligned}$$

Ejemplo 5.10 De Freund [2009]. Estudiemos un ejemplo de SDP con $n = 3$, $m = 2$ y las matrices

$$A_1 = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 3 & 7 \\ 1 & 7 & 5 \end{bmatrix}, \quad A_2 = \begin{bmatrix} 0 & 2 & 8 \\ 2 & 6 & 0 \\ 8 & 0 & 4 \end{bmatrix} \quad \text{y} \quad C = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 9 & 0 \\ 3 & 0 & 7 \end{bmatrix}.$$

El vector $b = [11 \ 19]^\top$.

La variable del problema es la matriz simétrica 3×3

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{bmatrix}.$$

Calculemos el producto

$$C \circ X = \begin{bmatrix} x_{11} & 2x_{12} & 3x_{13} \\ 2x_{21} & 9x_{22} & 0x_{23} \\ 3x_{31} & 0x_{32} & 7x_{33} \end{bmatrix}$$

La función objetivo sale de

$$\begin{aligned}\mathbf{1}^\top [C \circ C] \mathbf{1} &= x_{11} + 2x_{21} + 3x_{31} + 2x_{12} + 9x_{22} + 0x_{32} + 3x_{13} + 0x_{23} + 7x_{33} \\ &= x_{11} + 4x_{12} + 6x_{13} + 9x_{22} + 0x_{23} + 7x_{33}.\end{aligned}$$

Se ha tenido en cuenta ya la simetría de la matriz X .

El problema de optimización SDP es pues

$$\begin{aligned}\text{minimizar} \quad & x_{11} + 4x_{12} + 6x_{13} + 9x_{22} + 0x_{23} + 7x_{33} \\ \text{sujeta a} \quad & x_{11} + 0x_{12} + 2x_{13} + 3x_{22} + 14x_{23} + 5x_{33} = 11 \\ & 0x_{11} + 4x_{12} + 16x_{13} + 6x_{22} + 0x_{23} + 4x_{33} = 19 \\ & X = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{bmatrix} \succeq 0.\end{aligned}$$

Su dual,

$$\begin{aligned}\text{maximizar} \quad & 11y_1 + 19y_2 \\ \text{sujeta a} \quad & y_1 \begin{bmatrix} 1 & 0 & 1 \\ 0 & 3 & 7 \\ 1 & 7 & 5 \end{bmatrix} + y_2 \begin{bmatrix} 0 & 2 & 8 \\ 2 & 6 & 0 \\ 8 & 0 & 4 \end{bmatrix} + S = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 9 & 0 \\ 3 & 0 & 7 \end{bmatrix} \\ & S \succeq 0.\end{aligned}$$

Formulación que puede tener sus ventajas en muchos casos frente a la del primal. ●

5.7 Optimización vectorial y multicriterio o multiobjetivo

Los avances actuales de la técnicas de optimización e inteligencia artificial permiten extender la toma de decisiones a diversos criterios u objetivos en los que, en términos matemáticos, la función a optimizar es vectorial. En lo que presentamos a continuación seguimos a Boyd y Vandenberghe [2004].

Un problema de optimización vectorial tiene la forma

$$\begin{aligned}\text{minimizar (con respecto a } K) \quad & f_0(\mathbf{x}) \\ \text{sujeta a} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & h_i(\mathbf{x}) = 0, \quad i = 1, \dots, p.\end{aligned} \tag{6}$$

Aquí $\mathbf{x} \in \mathbb{R}^n$ es el vector a optimizar, $K \subseteq \mathbb{R}^q$ es un cono no vacío convexo, $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}^q$, $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son la condiciones de desigualdad y $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ las condiciones de igualdad. El cono K tiene por objeto comparar los diversos valores de las funciones objetivo.

Esta forma de expresar el problema se suele denominar así en contraposición al *problema de optimización escalar* que definamos en 1.

Se dice que el problema de optimización vectorial 6 es convexo si la función objetivo f_0 es convexa en K , las condiciones de desigualdad son convexas y las de igualdad afines (usualmente expresadas mediante $A\mathbf{x} = \mathbf{b}$, donde $A \in \mathbb{R}^{p \times n}$).

De acuerdo con lo visto hasta ahora, qué interpretación tiene el problema de optimización vectorial. Supongamos que $\mathbf{x}$ y $\mathbf{y}$ son dos puntos del problema factibles y que por lo tanto cumplen las condiciones. Sus valores asociados de la función objetivo son $f_0(\mathbf{x})$ y $f_0(\mathbf{y})$, respectivamente, y se compararán mediante la desigualdad generalizada $\preceq_K$, de tal manera que $f_0(\mathbf{x}) \preceq_K f_0(\mathbf{y})$ si $\mathbf{x}$ es mejor o igual que $\mathbf{y}$ de acuerdo con todos y cada uno de los valores de la función objetivo. El aspecto clave que introduce una cierta confusión en este análisis es que los valores $f_0(\mathbf{x})$ y $f_0(\mathbf{y})$ puede que no necesiten ser comparados.

Consideremos el conjunto de valores factibles del problema

$$\mathcal{O} = \{f_0(\mathbf{x}) | \exists \mathbf{x} \in \mathcal{D}, f_i(\mathbf{x}) \leq 0, i = 1, \dots, m, h_i(\mathbf{x}) = 0, i = 1, \dots, p\} \subseteq \mathbb{R}^q,$$

denominado de *valores objetivo alcanzables*. Si este conjunto tiene un elemento mínimo, ello quiere decir que existe un $\mathbf{x}^*$ factible tal que $f_0(\mathbf{x}^*) \preceq_K f_0(\mathbf{y})$ para todo $\mathbf{y}$ factible por lo que $\mathbf{x}^*$ es el óptimo de 6 con un valor de la función objetivo óptimo único igual a $f_0(\mathbf{x}^*)$. Es óptimo si y sólo si $\mathcal{O} \subseteq f_0(\mathbf{x}^*) + K$.




Figura 5.42: Conjunto $\mathcal{O}$ de valores objetivo alcanzables y óptimo, $\mathbf{x}^*$, de un problema de optimización vectorial con valores en $\mathbb{R}^2$

El conjunto $\mathcal{O} \subseteq f_0(\mathbf{x}^*) + K$ se puede interpretar como el de valores que son peores, o iguales, a $f_0(\mathbf{x}^*)$. La mayoría de los problemas de optimización vectorial no tienen un punto óptimo ni valor óptimo.

5.7.1 Óptimo y óptimos de Pareto

En el caso de que el conjunto de puntos factibles del problema no tenga un valor mínimo y por lo tanto el problema no tenga un punto óptimo ni valor óptimo, los elementos mínimos en el sentido de Pareto —por Vilfredo Federico Pareto, Paris 1848-Céligy 1923—

del conjunto $\mathcal{O}$ adquieren una importancia fundamental. Un punto factible x es **óptimo de Pareto**, por Vilfredo Federico Pareto Italia, 1848-1923,



si $f_0(x)$ es un mínimo de $\mathcal{O}$. En este caso decimos que $f_0(x)$ es un **valor óptimo de Pareto**¹ del problema 6. Esto quiere decir que x es un óptimo de Pareto si es factible y para cualquier otro y factible, el que $f_0(y) \preceq_K f_0(x)$ implica que $f_0(y) = f_0(x)$. En otras palabras, cualquier punto factible y que es mejor que x , es decir $f_0(y) \preceq_K f_0(x)$, tiene el mismo valor de la función objetivo que x . Esto se ilustra en la figura 5.43. El conjunto de puntos óptimos de Pareto del problema de optimización vectorial como se ve en la figura está en la frontera (frontera de Pareto) o borde de $\mathcal{O}$.




Figura 5.43: Conjunto $\mathcal{O}$ de valores objetivo alcanzables de un problema de optimización vectorial con valores en $\mathbb{R}^2$ y óptimos de Pareto (en el borde o frontera de ese conjunto). El punto $f_0(x^{op})$ es óptimo de Pareto con ese valor de la función objetivo del problema. La zona sombreada mas tenue es $f_0(x^{op}) - K$, el conjunto de puntos de $\mathbb{R}^2$ que tienen un valor de la función objetivo mejor o igual que $f_0(x^{op})$

La frontera de Pareto puede ser lineal, cóncava, convexa, continua o discontinua dependiendo de las funciones objetivo integrantes del problema. Todas las soluciones pertenecientes a la frontera son igualmente buenas y no se puede especificar si alguna de las soluciones es preferible a las otras, excepto en aquellos casos en que se haya definido una preferencia a priori.

¹En análisis económico se denomina óptimo de Pareto a aquel punto de equilibrio en el que ninguno de los agentes afectados podrá mejorar su situación sin reducir el bienestar de cualquiera de los otros agentes.

5.7.2 Escalarización

La escalarización es una técnica para encontrar puntos óptimos de Pareto en un problema de optimización vectorial. Se basa en la caracterización de puntos mínimos y minimales vía desigualdades generalizadas duales tal como se introdujeron antes en este apéndice. Si se escoge un $\lambda \succ_{K^*} 0$ que es positivo en las desigualdades duales generalizadas, consideremos el *problema escalar*

$$\begin{aligned} & \text{minimizar } \lambda^\top f_0(x) \\ & \text{sujeta a } \begin{aligned} f_i(x) &\leq 0, & i = 1, \dots, m \\ h_i(x) &= 0, & i = 1, \dots, p, \end{aligned} \end{aligned} \quad (7)$$

y en él sea x un punto óptimo. Este punto es óptimo de Pareto del problema 6 de optimización vectorial. Esto se deduce de la caracterización mediante desigualdades duales de los puntos minimales de las desigualdades de la página 84, así como de una observación directa. Si no lo fuera, existiría un y factible, que satisfaría $f_0(y) \preceq_K f_0(x)$ y que además $f_0(x) \neq f_0(y)$. Como $f_0(x) - f_0(y) \succeq_K 0$ y no es cero, se tiene que $\lambda^\top(f_0(x) - f_0(y)) > 0$, es decir, $\lambda^\top f_0(x) > \lambda^\top f_0(y)$. Lo que contradice el supuesto de que x es óptimo del problema escalar 7. El método de la escalarización se puede




Figura 5.44: Escalarización. El conjunto $\mathcal{O}$ de valores alcanzables para un problema de optimización vectorial en el cono $K = \mathbb{R}_+^2$ y los valores óptimos de Pareto $f_0(x_1)$, $f_0(x_2)$ y $f_0(x_3)$. Los primeros dos puntos se pueden obtener mediante escalarización: $f_0(x_1)$ minimiza $\lambda_1^\top u$ para todo $u \in \mathcal{O}$ y $f_0(x_2)$ minimiza $\lambda_2^\top u$ para todo $u \in \mathcal{O}$, donde $\lambda_1, \lambda_2 \succ 0$. El valor $f_0(x_3)$ es óptimo de Pareto pero no se puede obtener mediante escalarización

interpretar geoméricamente con la ayuda de la figura 5.44. Un punto x es óptimo del problema escalar 7, es decir minimiza $\lambda^\top f_0(x)$ en el conjunto de puntos factibles, si y sólo si $\lambda^\top(f_0(y) - f_0(x)) \geq 0$ para todos los y factibles. Esto es lo mismo que decir que el conjunto $\{u \mid -\lambda^\top(u - f_0(x)) = 0\}$ es un hiperplano soporte o de apoyo del conjunto de soluciones alcanzables $\mathcal{O}$ en el punto $f_0(x)$. En particular,

$$\{u \mid \lambda^\top(u - f_0(x)) < 0\} \cap \mathcal{O} = \emptyset.$$

En consecuencia, cuando se encuentre un punto óptimo del problema escalar no sólo se encuentra un punto óptimo de Pareto del problema vectorial original sino un semiespacio en $\mathbb{R}^q$ como el de esta última expresión, de valores de la función objetivo que no se pueden alcanzar.

Si el problema vectorial 6 es convexo el problema escalar es también convexo por lo que se pueden obtener todos (casi) los óptimos de Pareto resolviendo el problema escalar convexo. Para cada elección del vector de pesos $\lambda \succ_{K^*} 0$ se obtiene un punto óptimo de Pareto (normalmente) diferente.

5.7.3 Optimización multicriterio

Cuando un problema de optimización vectorial tiene que ver con el cono $K = \mathbb{R}_+^q$ se denomina multicriterio o multiobjetivo. Los componentes de la función vectorial f_0 son funciones $F_1, F_2, \dots, F_q : \mathbb{R}^n \rightarrow \mathbb{R}$ que se pueden interpretar como q diferentes requisitos escalares que hay que optimizar o mejorar. El problema será convexo si lo son cada una de esas funciones u objetivos a cumplir.

Lo expuesto antes sirve para este caso pues el conjunto de funciones objetivo es una función vectorial en si misma. No obstante, para los problemas de multicriterio podemos extendernos un poco en su interpretación. Si x es factible, podemos pensar en cada $F_i(x)$ en términos del valor que toma el objetivo i -ésimo. Si x e y son ambos factibles, el que $F_i(x) \leq F_i(y)$ significa que x es al menos tan buena como y , de acuerdo con el objetivo i -ésimo; $F_i(x) < F_i(y)$ significa que x es mejor que y , o que x supera a y , de acuerdo con el objetivo i -ésimo. Si x e y son ambos factibles, decimos que x es mejor que y , o que x domina a y , si $F_i(x) \leq F_i(y)$, para $i = 1, \dots, q$, y, para al menos un j , $F_j(x) < F_j(y)$. En términos aproximados, x es mejor que y si x supera a y en todos los objetivos y lo domina en al menos un objetivo.

En un problema de optimización multicriterio un punto óptimo x^* cumple que

$$F_i(x^*) \leq F_i(y), \quad i = 1, \dots, q,$$

para cada y . Es decir, x^* es simultáneamente óptimo para cada problema escalar

$$\begin{aligned} &\text{minimizar } F_j(x) \\ &\text{sujeta a } f_i(x) \leq 0, \quad i = 1, \dots, m \\ &\quad h_i(x) = 0, \quad i = 1, \dots, p, \end{aligned}$$

con $j = 1, \dots, q$. Cuando existe un punto óptimo, decimos que los objetivos son *no competidores*, ya que no hay que establecer compromisos o hacer concesiones entre los objetivos: cada objetivo es tan pequeño como es posible hacerlo, incluso si se ignorasen los demás.

Un punto óptimo de Pareto x^{op} cumple lo siguiente: si y es factible y $F_i(y) \leq F_i(x^{po})$, para $i = 1, \dots, q$, entonces $F_i(x^{po}) = F_i(y)$, $i = 1, \dots, q$. Lo que se puede expresar de esta manera: un punto en óptimo de Pareto si y sólo si es factible y no hay un punto factible mejor. En particular, si un punto factible no es óptimo de Pareto, al

menos existe otro punto factible que es mejor. Todo esto conduce a que para determinar el óptimo del problema nos podemos limitar a analizar los puntos que son óptimo de Pareto.

Supongamos pues que $\mathbf{x}$ y $\mathbf{y}$ son óptimos de Pareto y que

$$F_i(\mathbf{x}) < F_i(\mathbf{y}), \quad i \in A$$

$$F_i(\mathbf{x}) = F_i(\mathbf{y}), \quad i \in B$$

$$F_i(\mathbf{x}) > F_i(\mathbf{y}), \quad i \in C,$$

donde $A \cup B \cup C = \{1, \dots, q\}$. Dicho de otra forma, A es el conjunto de índices de las funciones objetivo para las cuales $\mathbf{x}$ domina a $\mathbf{y}$, B el de aquellas en las que $\mathbf{x}$ iguala a $\mathbf{y}$ y C el de las que $\mathbf{y}$ bate a $\mathbf{x}$. Si A y C están vacíos, los dos puntos $\mathbf{x}$ e $\mathbf{y}$ tiene exactamente los mismos valores de la función objetivo. Si no es el caso, A y C deben ser simultáneamente no vacíos. Es decir, al comparar dos puntos óptimos de Pareto, u obtienen las mismas prestaciones en términos de función objetivo, o uno mejora al otro en al menos uno de los objetivos.

Al comparar los puntos $\mathbf{x}$ e $\mathbf{y}$ decimos que hemos *intercambiado* mejores valores de funciones objetivos de $i \in A$ por los peores de $i \in C$. El análisis del intercambio óptimo es el estudio de cuánto peor pueden resultar diversas funciones objetivo haciendo otras mejor, o más en general, el estudio de qué conjuntos de funciones objetivo son alcanzables y cuáles no.

Como ejemplo, consideremos un problema con dos funciones objetivo (dos criterios de optimización). Supongamos que $\mathbf{x}$ es un punto óptimo de Pareto con valores de las funciones objetivo $F_1(\mathbf{x})$ y $F_2(\mathbf{x})$. La pregunta que se podría uno hacer es cuánto más grande debería ser $F_2(\mathbf{z})$ para determinar un punto factible $\mathbf{z}$ tal que $F_1(\mathbf{z}) \leq F_1(\mathbf{x}) - a$, donde $a > 0$ es cualquier constante. Grosso modo, nos preguntamos cuánto debemos pagar a la segunda función objetivo para obtener una mejora de a en la primera. Si se debe admitir un incremento importante en F_2 para obtener un pequeño decremento en F_1 , decimos que existe una *contrapartida fuerte* entre objetivos cerca de los puntos óptimos de Pareto de valor $(F_1(\mathbf{x}), F_2(\mathbf{x}))$. Si, por otro lado, se puede conseguir un decremento grande de F_1 con un pequeño incremento de F_2 , decimos que la contrapartida entre esos objetivos es *débil* cerca de los puntos óptimos de Pareto de valor $(F_1(\mathbf{x}), F_2(\mathbf{x}))$.

De igual manera se puede considerar el caso de qué contrapartidas negativas se consiguen en la primera función objetivo mejorando la segunda. Aquí buscamos cuánto menor se puede hacer $F_2(\mathbf{z})$ para obtener un punto factible $\mathbf{z}$ en el que $F_1(\mathbf{z}) \leq F_1(\mathbf{x}) + a$, con $a > 0$ una constante como antes. En este caso se obtiene una mejora (reducción) en F_2 comparada con $F_2(\mathbf{x})$. Si esa mejora o beneficio es grande (aumentando un poco F_1 se obtiene una reducción importante de F_2 , decimos que los objetivos presentan *contrapartidas fuertes*. Si es pequeño, contrapartidas débiles cerca del valor óptimo de Pareto $(F_1(\mathbf{x}), F_2(\mathbf{x}))$.

El conjunto de valores óptimos de Pareto de un problema de optimización multicriterio se denomina *superficie óptima de contrapartida*, si $q > 2$, o *curva óptima de contrapartidas* cuando $q = 2$. En general, su análisis se reduce a los puntos óptimos de Pareto.

Ejemplo 5.11 Consideraremos como ejemplo de todo esto el problema de mínimos cuadrados regularizado definido así: dada $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, encontrar un $x \in \mathbb{R}^n$ que cumpla estos dos criterios u objetivos:

- $F_1(x) = \|Ax - b\|_2^2 = x^\top A^\top A x - 2b^\top A x + b^\top b$. Una medida de la bondad del ajuste.
- $F_2(x) = \|x\|_2^2 = x^\top x$. Una medida del tamaño del vector solución.

La idea es encontrar un vector x para el cual el ajuste sea bueno y su norma no muy grande.

En la figura 5.45 se puede ver la superficie o curva de contrapartidas de este problema. La zona sombreada es el conjunto de valores alcanzables por el problema. La línea más gruesa es la óptima de contrapartidas formada por puntos óptimos de Pareto.




Figura 5.45: Curva óptima de contrapartidas del problema de mínimos cuadrados regularizado. La zona sombreada es el conjunto de puntos alcanzables, $(\|Ax - b\|_2^2, \|x\|_2^2)$, que considera el problema con $A \in \mathbb{R}^{100 \times 10}$ y $b \in \mathbb{R}^{10}$. La curva de óptimos de Pareto es la destacada en la parte inferior izquierda

Es esta curva se puede destacar:

- El punto más a la derecha de la curva indica el valor más pequeño posible de F_2 (sin tener en cuenta F_1).
- El punto más a la izquierda de la curva indica el valor más pequeño posible de F_1 (sin tener en cuenta F_2).
- La intersección de la curva con la línea vertical que define $F_1 = \alpha$ muestra lo grande que tiene que ser F_2 para conseguir un $F_1 \leq \alpha$.
- La intersección de la curva con la línea horizontal que define $F_2 = \beta$ muestra lo grande que tiene que ser F_1 para conseguir un $F_2 \leq \beta$.
- La pendiente de la curva en la zona de puntos óptimos de Pareto indica las contrapartidas locales óptimas entre los dos objetivos del problema. Una pendiente

pronunciada indica que pequeños cambios en F_1 van acompañados de cambios elevados en F_2 .

- Un punto de curvatura pronunciada es aquel en el que pequeñas reducciones en uno de los objetivos sólo lo pueden obtener grandes incrementos en el otro.

El problema que se plantea es entonces

$$\text{minimizar (con respecto a } \mathbb{R}_+^2) \quad f_0(\mathbf{x}) = (F_1(\mathbf{x}), F_2(\mathbf{x})).$$

Su escalarización lleva a una ponderación de los dos objetivos así

$$\begin{aligned} \boldsymbol{\lambda}^T f_0(\mathbf{x}) &= \lambda_1 F_1(\mathbf{x}) + \lambda_2 F_2(\mathbf{x}) \\ &= \mathbf{x}^T (\lambda_1 \mathbf{A}^T \mathbf{A} + \lambda_2 \mathbf{I}) \mathbf{x} - 2\lambda_1 \mathbf{b}^T \mathbf{A} \mathbf{x} + \lambda_1 \mathbf{b}^T \mathbf{b}, \end{aligned}$$

lo que da como resultado

$$\mathbf{x}(\gamma) = (\lambda_1 \mathbf{A}^T \mathbf{A} + \lambda_2 \mathbf{I})^{-1} \lambda_1 \mathbf{A}^T \mathbf{b} = (\mathbf{A}^T \mathbf{A} + \gamma \mathbf{I})^{-1} \mathbf{A}^T \mathbf{b},$$

donde $\gamma = \lambda_2/\lambda_1$. Cualquier $\gamma > 0$ determina un punto óptimo de Pareto del problema. ●

6 | Elementos de cálculo integral, campos escalares y campos vectoriales

VOLVIENDO a la integral definida de funciones de una variable, si $f(x)$ está definida en el intervalo $a \leq x \leq b$ y se divide éste en n subintervalos $[x_{i-1}, x_i]$ de igual longitud $\Delta x = (b - a)/n$, y de cada uno de ellos se escogen puntos de muestra x_i^* , conformando la suma de Riemann

$$\sum_{i=1}^n f(x_i^*) \Delta x$$

y tomando el límite de esas sumas cuando $n \rightarrow \infty$, se obtiene la integral definida de f entre a y b

$$\int_a^b f(x) dx = \lim_{n \rightarrow \infty} \sum_{i=1}^n f(x_i^*) \Delta x.$$

Como sabemos la interpretación geométrica es la de la figura 6.1.




Figura 6.1: Integral definida como suma de Riemann. Stewart [2015]

De la misma manera, consideremos ahora la función f de dos variables definida en el rectángulo cerrado

$$R = [a, b] \times [c, d] = \{(x, y) \in \mathbb{R}^2 \mid a \leq x \leq b, c \leq y \leq d\}.$$

de la figura 6.2. Supongamos de momento que $f(x, y) \geq 0$. La gráfica de la función es la superficie $z = f(x, y)$ que se ve en esa figura. Llamemos S al volumen sólido comprendido entre la superficie R y que toca a f , es decir

$$S = \{(x, y, z) \in \mathbb{R}^3 \mid 0 \leq z \leq f(x, y), (x, y) \in R\}.$$




Figura 6.2: Volumen e integral. Stewart [2015]

Calculemos el volumen de S .

Para ello dividimos el rectángulo R en pequeños subrectángulos como se aprecia en la figura 6.3. El intervalo $[a, b]$ lo dividimos en m subintervalos $[x_{i-1}, x_i]$, de igual longitud $\Delta x = (b-a)/m$, y $[c, d]$ en n subintervalos $[y_{j-1}, y_j]$ de igual longitud $\Delta y = (d-c)/n$. Cada subrectángulo $R_{ij} = [x_{i-1}, x_i] \times [y_{j-1}, y_j] = \{(x, y) \mid x_{i-1} \leq x \leq x_i, y_{j-1} \leq y \leq y_j\}$ tiene un área $\Delta A = \Delta x \Delta y$.

Si de cada R_{ij} escogemos un punto de muestra (x_{ij}^*, y_{ij}^*) , la parte de S encima de ese trocito se puede aproximar por una “columna” o paralelepípedo rectangular de base R_{ij} y altura $f(x_{ij}^*, y_{ij}^*)$. El volumen de esta columna es $f(x_{ij}^*, y_{ij}^*) \Delta A$. Siguiendo este patrón de actuación con todos los rectángulos de R el volumen aproximado de S será

$$V \approx \sum_{i=1}^m \sum_{j=1}^n f(x_{ij}^*, y_{ij}^*) \Delta A.$$

Aproximación que será tanto mejor cuanto más se amplíen las divisiones m y n , es decir,

$$V = \lim_{m, n \rightarrow \infty} \sum_{i=1}^m \sum_{j=1}^n f(x_{ij}^*, y_{ij}^*) \Delta A.$$

Definición 6.1 La **integral doble** de f sobre el rectángulo R es

$$\iint_R f(x, y) dA = \lim_{m, n \rightarrow \infty} \sum_{i=1}^m \sum_{j=1}^n f(x_{ij}^*, y_{ij}^*) \Delta A,$$

si existe ese límite existe.




Figura 6.3: División o mallado de R . Stewart [2015]

Teorema 6.1 Teorema de Fubini. Si f es continua en el rectángulo $R = \{(x, y) \in \mathbb{R}^2 \mid a \leq x \leq b, c \leq y \leq d\}$ entonces

$$\iint_R f(x, y) dA = \int_a^b \int_c^d f(x, y) dy dx = \int_c^d \int_a^b f(x, y) dx dy.$$

En general, esto es cierto si se supone que f está acotada en R , f es discontinua sólo en un número finito de curvas y las integrales existen.

Se debe a la formulación que hizo Guido Fubini, Venecia, 19 de enero de 1879-Nueva York, 6 de junio de 1943.



6.1 Integrales de línea

La integral de línea es una integral similar a la definida en un intervalo $[a, b]$ pero cuya función es evaluada sobre una curva C . En el caso de una curva cerrada en dos dimensiones, o del plano complejo, también se denomina integral de contorno.

Los ejemplos prácticos de su utilización están en el cálculo de la longitud de una curva en el espacio, longitud o peso de un cable tendido en el espacio que une dos puntos, o también en el cálculo del trabajo que se realiza para mover algún objeto a lo largo de una trayectoria teniendo en cuenta campos de fuerzas (descritos por campos vectoriales) que actúen sobre dicho objeto.

Para modelizar y simular estas y otras realidades físicas, económicas y sociales que nos rodean, es natural trabajar con magnitudes escalares y vectoriales que representan fuerzas y otras magnitudes de regiones conexas planas, o del espacio al que estamos habituados.

Definición 6.2 Un **campo escalar** es una función real de varias variables $f : A \subset \mathbb{R}^n \rightarrow \mathbb{R}$ que a cada punto de su dominio le asigna el valor que toma una determinada magnitud escalar en dicho punto. Ejemplos de estos son la temperatura, la densidad, la altura de un cuerpo, en nuestro espacio tridimensional. Si un campo escalar no depende del tiempo se denomina *estacionario*.

Definición 6.3 Un **campo vectorial** es una función vectorial de varias variables $\mathbf{F} : A \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$ que a cada punto de su dominio le asigna el vector correspondiente a una determinada magnitud vectorial que actúa en dicho punto. Representa la distribución espacial de una magnitud vectorial. Ejemplos son los campos eléctricos, los gravitatorios, los del movimiento del viento, las corrientes oceánicas, los flujos de un fluido, del calor, etc. Si un campo vectorial no depende del tiempo se denomina *estacionario*. En los campos vectoriales se definen las líneas de fuerza o *líneas de campo*, como las curvas tangentes en cada punto a los vectores definidos en ellos.

Un campo vectorial en un dominio tridimensional se puede definir como $\mathbf{F}(x, y, z) = M(x, y, z)\mathbf{i} + N(x, y, z)\mathbf{j} + P(x, y, z)\mathbf{k}$. Es continuo si lo es cada una de las funciones o campos escalares que lo conforman, M , N y P ; es derivable si lo es cada una de las funciones. En el caso bidimensional, los vectores tendrían la forma $\mathbf{F}(x, y) = M(x, y)\mathbf{i} + N(x, y)\mathbf{j}$.

Estos conceptos tienen sentido físico si $n = 2$ o $n = 3$. En ocasiones los campos vectoriales se refieren a $\mathbf{F} : A \subset \mathbb{R}^n \rightarrow \mathbb{R}^m$, siendo en general $m \neq n$.

También son campos vectoriales los vectores $\mathbf{T}$ tangentes y los $\mathbf{N}$ normales a lo largo de una determinada curva en el espacio, el de vectores gradiente de una función escalar $f(x, y, z)$ a un determinado nivel, etc. En la figura 6.4 se ilustran algunos ejemplos de campos vectoriales.

Empezamos con una curva $C = f(x, y, z)$ definida por las ecuaciones paramétricas

$$x = g(t), \quad y = h(t), \quad z = k(t), \quad a \leq t \leq b$$




Figura 6.4: Distintos campos vectoriales: El flujo de viento alrededor de un ala, el agua al pasar por el estrechamiento de un canal y los vectores gradiente ∇f de una superficie $f(x, y, z) = c$

pues puede ser conveniente pensar en C y en t como la trayectoria de un objeto en el tiempo y en espacio.

También se puede definir por la ecuación vectorial $\mathbf{r}(t) = g(t)\mathbf{i} + h(t)\mathbf{j} + k(t)\mathbf{k}$, $a \leq t \leq b$. Los valores de f a lo largo de la curva son los dados por $f(g(t), h(t), k(t))$.

Para integrar la curva C entre a y b se divide en un número de subarcos n —como se ve en la figura 6.5—, cada uno de longitud Δs_k y representado por el punto de muestra (x_k, y_k, z_k) . Si se forma la suma

$$S_n = \sum_{k=1}^n f(x_k, y_k, z_k) \Delta s_k,$$

y se cumple que f es continua y las funciones g , h y k tienen derivadas de primer orden continuas, esta suma tiende a un límite cuando n tiende a infinito y las longitudes Δs_k a cero.

Definición 6.4 Si la función f está definida en la curva C , paramétricamente dada por $\mathbf{r}(t) = g(t)\mathbf{i} + h(t)\mathbf{j} + k(t)\mathbf{k}$, $a \leq t \leq b$, la **integral de línea** de f en C es

$$\oint_C f(x, y, z) = \lim_{n \rightarrow \infty} \sum_{k=1}^n f(x_k, y_k, z_k) \Delta s_k,$$

supuesto exista ese límite.




Figura 6.5: Curva C troceada entre a y b en n porciones de arco

La longitud de C se sabe que es

$$L = \int_a^b \sqrt{\left(\frac{dx}{dt}\right)^2 + \left(\frac{dy}{dt}\right)^2 + \left(\frac{dz}{dt}\right)^2} dt$$

por lo que

$$\oint_C f(x, y, z) = \int_a^b f(x_k, y_k, z_k) \sqrt{\left(\frac{dx}{dt}\right)^2 + \left(\frac{dy}{dt}\right)^2 + \left(\frac{dz}{dt}\right)^2} dt.$$

En forma vectorial

$$\oint_C f(x, y, z) = \int_a^b f(\mathbf{r}(t)) |\mathbf{r}'(t)| dt.$$

6.1.1 Integrales de línea en campos vectoriales

El trabajo realizado por una fuerza constante $\mathbf{F}$ moviendo un objeto de un punto P a otro Q en el espacio es $W = \mathbf{F} \cdot \mathbf{D}$, donde $\mathbf{D} = \overrightarrow{PQ}$ es el vector de desplazamiento.

Si suponemos que $\mathbf{F} = P\mathbf{i} + Q\mathbf{j} + R\mathbf{k}$ es un campo de fuerzas en $\mathbb{R}^3$, como por ejemplo el campo gravitatorio o un campo eléctrico, para calcular el trabajo que realiza esa fuerza para mover una determinada partícula a lo largo de una curva continua C en el intervalo paramétrico $[a, b]$ (que se corresponde con los puntos de la curva P_0 y P_n) —se ve en la figura 6.6—, se divide ese intervalo en subintervalos de igual longitud, que se corresponderán con subarcos $P_{i-1}P_i$ de longitudes Δs_i . Cada uno de estos subarcos estarán representados por un punto de muestra $P_i^*(x_i^*, y_i^*, z_i^*)$ correspondiente al parámetro t_i^* .

Si Δs_i es pequeño, al moverse la partícula entre p_{i-1} y p_i sigue aproximadamente la dirección $\mathbf{T}(t_i^*)$, tangente a la curva en P_i^* . El trabajo que hace $\mathbf{F}$ entre P_{i-1} y P_i es

$$\mathbf{F}(x_i^*, y_i^*, z_i^*) \cdot [\Delta s_i \mathbf{T}(t_i^*)] = [\mathbf{F}(x_i^*, y_i^*, z_i^*) \cdot \mathbf{T}(t_i^*)] \Delta s_i$$




Figura 6.6: Integral de línea en un campo de fuerzas. Stewart [2015]

y en el total en toda la curva C , aproximadamente

$$\sum_{i=1}^n [\mathbf{F}(x_i^*, y_i^*, z_i^*) \cdot \mathbf{T}(x_i^*, y_i^*, z_i^*)] \Delta s_i$$

donde $\mathbf{T}(x, y, z)$ es el vector unitario tangente a C en el punto (x, y, z) . Esta aproximación será tanto mejor cuanto más grande sea n y en el límite cuanto $n \rightarrow \infty$ el trabajo será (el límite de las sumas de Riemann)

$$R = \oint_C \mathbf{F}(x, y, z) \cdot \mathbf{T}(x, y, z) ds = \oint_C \mathbf{F} \cdot \mathbf{T} ds.$$

El trabajo es pues la integral de línea con respecto a la longitud del arco del componente tangencial de la fuerza.

Si la curva se expresa paramétricamente mediante $\mathbf{r}(t) = x(t)\mathbf{i} + y(t)\mathbf{j} + z(t)\mathbf{k}$, entonces $\mathbf{T}(t) = \mathbf{r}'(t)/|\mathbf{r}'(t)|$ por lo que la expresión del trabajo queda

$$W = \int_a^b \left[\mathbf{F}(\mathbf{r}(t)) \cdot \frac{\mathbf{r}'(t)}{|\mathbf{r}'(t)|} \right] |\mathbf{r}'(t)| dt = \int_a^b \mathbf{F}(\mathbf{r}(t)) \cdot \mathbf{r}'(t) dt.$$

Definición 6.5 Sea $\mathbf{F}$ un campo vectorial continuo definido en una curva C dada por la función $\mathbf{r}(t)$, $a \leq t \leq b$. La **integral de línea** de $\mathbf{F}$ a lo largo de C es

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \int_a^b \mathbf{F}(\mathbf{r}(t)) \cdot \mathbf{r}'(t) dt = \oint_C \mathbf{F} \cdot \mathbf{T} ds$$

Teorema 6.2 Teorema fundamental de las integrales de línea. Sea C una curva continua dada por la función $\mathbf{r}(t)$, $a \leq t \leq b$. Sea f una función derivable de dos o tres variables cuyo vector gradiente ∇f es una función continua en C . Entonces

$$\oint_C \nabla f \cdot d\mathbf{r} = f(\mathbf{r}(b)) - f(\mathbf{r}(a)).$$

6.2 El teorema de Green

Formulado por George Green, Reino Unido 1793-1841.



Este teorema proporciona la relación entre la integral de línea alrededor de una curva cerrada C y la integral doble, de superficie, de la región D contenida en C y adherida a ésta. Supondremos que la región D consiste en todos los puntos interiores a C y los de esta curva. También que su orientación es positiva, según indica la figura 6.7. Este teorema es la contrapartida del teorema fundamental del cálculo para integrales dobles.




Figura 6.7: Curva C de orientación positiva y región D . Stewart [2015]

Teorema 6.3 Teorema de Green. Sean C , una curva continua por tramos, orientada positivamente y cerrada en el espacio $\mathbb{R}^2$, y D la unión de la región acotada por C , ($\partial D = C$), y la propia C . Si $\mathbf{F} = (P, Q) : D \rightarrow \mathbb{R}^2$ es un campo vectorial expresado por $\mathbf{F}(x, y) = P(x, y)\mathbf{i} + Q(x, y)\mathbf{j}$, en el que las dos funciones P y Q tienen derivadas parciales continuas en una región abierta que contiene a D , se tiene que

$$\oint_C P dx + Q dy = \oint_C \mathbf{F} \cdot d\mathbf{r} = \iint_D \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dA.$$

Algunas veces se puede encontrar la notación

$$\oint_{\partial D} P dx + Q dy \text{ en vez de } \oint_C P dx + Q dy.$$

Simplemente ∂D indica el contorno de D , que es la curva C .

Ejemplo 6.1 Sea C el círculo unidad orientado en el sentido contrario a las agujas del reloj y el campo vectorial

$$\mathbf{F}(x, y) = -y \mathbf{i} + x \mathbf{j}.$$

Comprobemos que se cumple el teorema de Green. Primero calculamos el flujo de $\mathbf{F}$ alrededor de la frontera de C . La región que define C se puede expresar en forma paramétrica como

$$\mathbf{r}(t) = \cos(t) \mathbf{i} + \sin(t) \mathbf{j} \quad 0 \leq t \leq 2\pi.$$

Entonces $\mathbf{r}'(t) = -\sin(t) \mathbf{i} + \cos(t) \mathbf{j}$ y $\mathbf{F}(x(t), y(t)) = -\sin(t) \mathbf{i} + \cos(t) \mathbf{j}$. Lo que hace que

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \int_0^{2\pi} (\sin^2(t) + \cos^2(t)) dt = 2\pi.$$

Calculemos ahora la integral doble del teorema de Green en la que $P = -y$ y $Q = x$. Se obtiene que

$$\begin{aligned} \iint_D \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dA &= \iint_D (1 - (-1)) dA \\ &= 2 \iint_D 1 dA \\ &= 2 \times (\text{área del círculo unidad}) \\ &= 2\pi. \end{aligned}$$

Esto hace que

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \iint_D \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dA = 2\pi.$$

Definición 6.6 Si $\mathbf{F} = P \mathbf{i} + Q \mathbf{j} + R \mathbf{k}$ es un campo vectorial en $\mathbb{R}^3$ y las funciones P , Q y R tienen derivadas parciales de primer orden, se define el *rotacional* de $\mathbf{F}$ como el *campo vectorial* en $\mathbb{R}^3$ que expresa

$$\text{rot } \mathbf{F} = \left(\frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) \mathbf{i} + \left(\frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) \mathbf{j} + \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) \mathbf{k}.$$

Si se piensa en el operador ∇ como un vector de coeficientes $\partial/\partial x$, $\partial/\partial y$ y $\partial/\partial z$, el producto vectorial de ∇ con el campo vectorial $\mathbf{F}$ es

$$\begin{aligned}\nabla \times \mathbf{F} &= \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ \frac{\partial}{\partial x} & \frac{\partial}{\partial y} & \frac{\partial}{\partial z} \\ P & Q & R \end{vmatrix} \\ &= \left(\frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) \mathbf{i} + \left(\frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) \mathbf{j} + \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) \mathbf{k} \\ &= \mathbf{rot} \mathbf{F}.\end{aligned}$$

De aquí que

$$\mathbf{rot} \mathbf{F} = \nabla \times \mathbf{F}.$$

Definición 6.7 La **divergencia** de un campo vectorial $\mathbf{F}$ es el *campo escalar* de tres variables

$$\operatorname{div} \mathbf{F} = \frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z}.$$

Como $\nabla = (\partial/\partial x)\mathbf{i} + (\partial/\partial y)\mathbf{j} + (\partial/\partial z)\mathbf{k}$, la divergencia de $\mathbf{F}$ se puede escribir así

$$\operatorname{div} \mathbf{F} = \nabla \cdot \mathbf{F}$$

Con estos conceptos, la expresión del teorema de Green puede adoptar estas dos nuevas formas

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \iint_D (\mathbf{rot} \mathbf{F}) \cdot \mathbf{k} \, dA$$

$$\oint_C \mathbf{F} \cdot \mathbf{n} \, ds = \iint_D \operatorname{div} \mathbf{F}(x, y) \, dA$$

donde el vector $\mathbf{n}$ es el que se indica en la figura 6.8.




Figura 6.8: Región D y vector $\mathbf{n}$. Stewart [2015]

6.3 El teorema de Stokes

Este teorema, debido a George Gabriel Stokes, Irlanda, 1819-1903,



es una versión del de Green para dimensiones superiores a las que se define éste. Relaciona un integral de superficie en una superficie S con una integral de línea alrededor de una curva que acota a S .




Figura 6.9: Teorema de Stokes. Superficie S y vector $\mathbf{n}$. Stewart [2015]

Teorema 6.4 *Teorema de Stokes. Sea S una superficie orientada, continua a tramos y acotada por una curva C continua por tramos, orientada positivamente y cerrada en el espacio $\mathbb{R}^3$. Si $\mathbf{F}$ es un campo vectorial en $\mathbb{R}^3$ cuyos componentes tienen derivadas parciales continuas en una región abierta de $\mathbb{R}^3$ que contiene a S , se tiene que*

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \iint_S \text{rot } \mathbf{F} \cdot d\mathbf{S}.$$

El caso especial en el que la superficie S sea bidimensional y esté en el plano (x, y) , con orientación hacia arriba (en el sentido contrario a las agujas del reloj), su vector unitario normal es $\mathbf{k}$, la integral de superficie es una integral doble y el teorema de Stokes se convierte en

$$\oint_C \mathbf{F} \cdot d\mathbf{r} = \iint_S \text{rot } \mathbf{F} \cdot d\mathbf{S} = \iint_S (\text{rot } \mathbf{F}) \cdot \mathbf{k} \, dA$$

que es la forma vectorial del teorema de Green que se formulaba anteriormente.

7 | Sobre el método de los elementos finitos de Ritz-Galerkin para resolver ecuaciones en derivadas parciales

DESDE tiempos de C.F. Gauss, Alemania 1777-1855 y W. Thompson, Irlanda 1775-1833, la equivalencia entre los problemas de ecuaciones en derivadas parciales con condiciones de contorno y los de cálculo de variaciones ha ocupado un puesto destacado en el análisis matemático. En un principio el esfuerzo se concentró en los aspectos teóricos de los problemas; posteriormente, dos físicos, Lord Rayleigh —John William Strutt, Reino Unido 1842-1919— y Walther Ritz, Suiza 1878-1909,



independientemente al parecer, concibieron la idea de utilizar esa equivalencia para calcular numéricamente soluciones de problemas habituales de física mediante la sustitución de los problemas de cálculo de variaciones por otros más simples de obtención de extremos con un número finito de parámetros por determinar.

Sus métodos atrajeron pronto a ingenieros y físicos —los principios físicos de la mecánica son más sugestivos que las ecuaciones diferenciales— y se empezaron a aplicar a muchos problemas cercanos. El resultado era lógica consecuencia del esquema conceptual de cómo se tratan en análisis matemático —y en muchos aspectos de la vida cotidiana— los problemas difíciles: Un problema P con solución S se reemplaza por otro más o menos relacionado o próximo, P_n , más simple de resolver, cuya solución es S_n . Luego se mejora la aproximación P_n de P de tal forma que la solución S_n , paso a paso, tienda a la deseada S . Lo esencial es escoger la sucesión de aproximaciones P_n de una manera adecuada.

Una de las cuestiones más interesantes y con más posibilidades de futuro que contemplan las aplicaciones de las matemáticas para simular y resolver muchos problemas de la vida cotidiana es el de utilizar modelos matemáticos expresados en forma de ecuaciones diferenciales e integrales que reproducen procesos y fenómenos complejos de la física y otras ciencias naturales y sociales cuyos orígenes y evolución suelen estar distribuidos en el tiempo y en el espacio. Se modelan de esta forma la propagación del sonido o del calor, la electrostática, la electrodinámica, la dinámica de fluidos, la elasticidad, la

mecánica cuántica, las emisiones de contaminantes, los fenómenos meteorológicos, la valoración de opciones y derivados financieros y muchos otros. El enfoque para resolverlos de forma práctica sigue exactamente el principio enunciado más arriba.

La idea esencial que seguiremos en estas notas es la de convertir el problema con ecuaciones diferenciales, integrales o ecuaciones en derivadas parciales, suponiendo que tiene solución con unas determinadas características, en uno formulado en términos de cálculo de variaciones de funciones continuas — la minimización de un funcional— para así caracterizar en qué condiciones se da una solución u óptimo del mismo. Luego se discretiza ese problema continuo con un número infinito de grados de libertad mediante un problema discreto, o sistema de ecuaciones, con un número de variables finito y más fácil de resolver y se resuelve mediante alguna de las diversas técnicas que existen para ello.

Cuando se empieza a trabajar y aprender métodos numéricos para resolver problemas matemáticos el de las diferencias finitas sigue ideas muy intuitivas: simplemente se aproxima una derivada de una curva en un punto de ella por una línea secante. Si se estudia el método del volumen finito, también su idea es bastante sencilla: cada elemento de volumen es simplemente un pequeño equilibrio del flujo o de fuerzas. El método de los elementos finitos sigue esa senda más o menos, con alguna pequeña modificación.

La base matemática para el método de los elementos finitos se encuentra en el entorno de los espacios de Hilbert. Un espacio de Hilbert es una manera de tratar una función como un vector, por lo que podemos hacer algunos trucos de matemáticas vectoriales con él. Recordemos que un vector es una serie de valores, o escalares, multiplicados por un conjunto de vectores de una base ortogonal (como los vectores unitarios que definen las direcciones x , y y z , o los $\mathbf{i}$, $\mathbf{j}$ y $\mathbf{k}$). Podemos utilizar una técnica paralela para definir una función. Primeramente seleccionamos un conjunto de funciones de base en vez de aquellos vectores (esas funciones deben ser ortogonales entre sí) y luego definimos la función original como una suma de unos coeficientes multiplicados por las funciones de la base: de esta forma

$$u = \sum_{k=1}^{\infty} \alpha_k \phi_k,$$

donde cada una de las ϕ_k es una función de la base.

El siguiente paso es convertir nuestra ecuación diferencial en algo llamado *su formulación débil*. Esto se hace básicamente multiplicando por una *función de prueba* y luego integrando en el espacio. Sin entrar en los detalles de momento, se trata de hacer lo mínimo necesario para convertir nuestra ecuación diferencial en algo en lo que podamos utilizar nuestras matemáticas de espacios vectoriales. Esencialmente, donde exista una forma de "producto interior", en nuestro caso con funciones como la de prueba en vez de vectores, y la solución. Este producto interior será una integral y podremos usar integración por partes para convertirlo en formatos más manejables.

Después nos desharemos de alguna manera de la abstracción empleada y comprobaremos que realmente estamos tratando con un espacio vectorial de dimensión finita: los vectores función no son infinitos ni estamos sumando infinitos términos.




Figura 7.1: Discretización en malla de una pieza de geometría sencilla

Este proceso es lo que se entiende por *discretización* en las técnicas de los elementos finitos. La discretización que se utiliza está determinada por una malla o retícula (una retícula de por ejemplo 20×20 daría como resultado 441 funciones base únicas) —*mesh* como la de la figura 7.1— y normalmente se emplean dos funciones de base a cada lado de un elemento de la malla.

Con esas funciones de base la solución de nuestra ecuación diferencial se representaría de esta manera

$$u' = \sum_{k=1}^n \alpha_k \phi_k.$$

La única diferencia con la expresión anterior es el límite superior del sumatorio.

El siguiente paso es hacer que nuestra función de prueba sea una función de base. También habrá que asegurarse que las funciones base no se superpongan, lo cual garantiza el que sean ortogonales como pretendíamos antes y nos permite aproximar más fácilmente la solución en el dominio de interés. Las funciones de base que se suelen usar son polinomios (especialmente polinomios lineales o cuadráticos).

Después de lo que puede parecer que es complicar el problema original agregando toda esta abstracción y matemáticas para llegar a lo que hemos llegado, ¿qué hemos conseguido realmente? Pues convertir el problema en una ecuación algebraica matricial sencilla para poderlo resolver por medio del álgebra que conocemos. Si el problema fuese lineal, simplemente tendríamos que resolver la ecuación $\mathbf{Ax} = \mathbf{b}$.

Para un problema simple como el de la *ecuación de Poisson*

$$\Delta u(x, y) = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y),$$



por Siméon Denis Poisson, Francia, 1781-1840. la matriz $\mathbf{A}$ es muy fácil de calcular y se denomina la *matriz de rigidez* en homenaje a los principios de las técnicas de elementos

finitos en problemas de elasticidad. Esta matriz —muy dispersa (con pocos coeficientes distintos de cero) y diagonal dominante— está formada por el producto interior de las funciones de base con ellas mismas, multiplicadas si es el caso por la constante que aparezca en la ecuación original. El vector solución de ese sistema se multiplica por el de las funciones de base y se obtiene la del problema original, o una que se aproxima mucho a la misma.

Resumiendo, el procedimiento de resolución del método de los elementos finitos consta de las siguientes fases u operaciones:

- Conversión del problema original de dimensión infinita, mediante las propiedades de los espacios de Hilbert, en uno similar próximo en un espacio vectorial de dimensión finita. En éste se estudia la existencia y unicidad de la solución.
- Creación de una *formulación débil* del problema original con la que podamos usar las herramientas de producto interior y medida.
- Discretización del dominio de definición del problema y elección de una base de funciones que sean ortogonales entre si.
- Conversión de los productos interiores entre funciones de base en sistemas lineales de ecuaciones.
- Resolución de ese sistema lineal resultante mediante técnicas de matrices dispersas.

Las ventajas de este método frente a otros son muchas en bastantes ámbitos de la ingeniería, la ciencia y la investigación por lo que su extensión y precisión, así como los algoritmos que emplea, cada vez son más amplios, ambiciosos y potentes.

Para concretar con cierto detalle los pasos del método, vamos a desarrollar el estudio de un problema preciso habitual. Seguiremos esencialmente el trabajo de Francisco Javier Sayas [2015].

7.1 Solución de una ecuación en derivadas parciales

Consideraremos en lo que sigue el siguiente problema de una ecuación en derivadas parciales elíptica de segundo orden con condiciones de contorno:

$$\begin{cases} -\Delta u(x, y) + cu(x, y) = f(x, y) & \text{dentro de } \Omega \\ u(x, y) = g_0(x, y) & \text{en la frontera } \Gamma_D \\ \partial_n u(x, y) = g_1(x, y) & \text{en la frontera } \Gamma_N. \end{cases}$$

Esta forma de formularlo se denomina *formulación fuerte*.

- La geometría del entorno físico esquemático en el que se desenvolverá será tan simple como la de la figura 7.2, o una generalización de ella. En este caso concreto es un subconjunto abierto $\Omega \in \mathbb{R}^d$ representado por un polígono en el plano $\mathbb{R}^2$, “pegado” o adherido en su frontera a la curva que define Γ , dividida ésta en dos partes: la que define Γ_D , que materializan unas *condiciones de contorno de*





Figura 7.2: Dominio de definición Ω y condiciones de contorno

Dirichlet —por Johann Peter Gustav Lejeune Dirichlet, Alemania 1805-1859—



y la Γ_N , con *condiciones de contorno de Neumann* —por Karl Gottfried Neumann, Alemania 1832-1925—. En términos físicos, las condiciones de Dirichlet determinan unos posibles desplazamientos físicos de esa frontera, mientras que las de Neumann unas posibles tensiones máximas o mínimas.

- La ecuación en derivadas parciales propiamente dicha, la primera en la formulación, se denomina habitualmente *ecuación difusión-reacción*. El término que representa la difusión es $-\Delta u$ y el de reacción cu , cuando $c > 0$. La constante c es no negativa; en principio puede adoptar los valores 0 ó 1.
- La función escalar $u(x, y) : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida en el dominio Ω , es la incógnita de este problema.
- La función $f(x, y)$ está definida en Ω y se puede considerar como una densidad superficial de fuerzas.
- Las dos funciones que expresan las condiciones de contorno, $g_0(x, y)$ y $g_1(x, y)$, están definidas en dos partes diferentes de la frontera. La función g_0 deberá ser continua; la g_1 puede ser discontinua.
- El símbolo ∂_n designa la derivada normal hacia afuera, es decir

$$\partial_n u = \nabla u \cdot \mathbf{n},$$

donde $\mathbf{n}$ es el vector unidad hacia afuera en puntos de la frontera Γ y ∇u es el gradiente de u . Supondremos que existe.

7.1.1 El problema en forma débil o variacional

Siguiendo cada uno de los pasos de la estrategia enunciada para resolver este problema, vamos a formularlo de una forma diferente de la original denominada *forma débil* o *forma variacional*.

Para ello utilizaremos el teorema de Green, a menudo denominado *primera fórmula o identidad de Green*, derivada del *teorema de la divergencia*, que no es sino una forma de integración por partes. Aplicado a nuestro caso dice que

$$\int_{\Omega} (\Delta u) v + \int_{\Omega} \nabla u \cdot \nabla v = \int_{\Gamma} (\partial_n u) v.$$

La función v es una *función de prueba*, continua, en principio definida en $\overline{\Omega} = \Omega \cup \Gamma$. En esa expresión hay dos tipos de integrales: las dos del miembro de la izquierda son integrales de superficie, en el dominio Ω . La del derecho es una integral lineal en el borde o frontera Γ . Hemos prescindido de los diferenciales correspondientes para compactar la notación. El punto de la segunda integral del miembro de la izquierda se refiere al producto interior de dos vectores, es decir $\nabla u \cdot \nabla v = \frac{\partial u}{\partial x} \frac{\partial v}{\partial x} + \frac{\partial u}{\partial y} \frac{\partial v}{\partial y}$.

El resultado sería aplicable también a tres dimensiones: las dos integrales de la izquierda serían de volumen; la de la derecha de superficie.




Figura 7.3: Región o volumen V acotada por la superficie o frontera $S = \partial V$ con la normal a la superficie $\mathbf{n}$

La identidad expresada es una consecuencia del resultado del *teorema de la divergencia* que dice que para un subconjunto $V \in \mathbb{R}^n$ —en el caso de tres dimensiones V representa un volumen como el de la figura 7.3—, en principio compacto, de superficie, o borde, S continua a trozos (expresada por $\partial V = S$), si $\mathbf{F}$ es un campo vectorial con derivadas parciales de primer orden continuas definido en un entorno de V , se cumple que

$$\iiint_V (\nabla \cdot \mathbf{F}) dV = \oint_S (\mathbf{F} \cdot \mathbf{n}) dS.$$

Aplicado a una función escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y un vector constante $\mathbf{c}$ distinto de cero

$$\iiint_V \mathbf{c} \cdot \nabla f dV + \iiint_V f(\nabla \cdot \mathbf{c}) dV = \oint_S (\mathbf{c} f) \cdot d\mathbf{S},$$

donde $d\mathbf{S}$ expresa de forma compacta $\mathbf{n}dS$.

Haciendo $f = \nabla u$ y $\mathbf{c} = v$ se tiene la expresión anterior de la primera identidad de Green.

Si sustituimos $\Delta u = f - cu$ en la expresión obtenida a partir de la identidad de Green en donde se integra en Ω y que $\partial_n u = g_1$ en Γ_N , después de reordenar un poco se llega a

$$\int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v + \int_{\Gamma_D} (\partial_n u) v.$$

Como no sabemos el valor de $\partial_n u$ en Γ_D imponemos que la función v sea cero en esa parte de la frontera o borde: $v = 0$ en Γ_D . A partir de ahí,

$$\int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \quad \text{si } v = 0 \text{ en } \Gamma_D.$$

La expresión del miembro de la izquierda es lineal en las funciones u y v . Es una forma bilineal de las variables u y v . La de la derecha es lineal en v . Todavía no hemos hecho uso de la condición de Dirichlet en la frontera, $u = g_0$ en Γ_D .

La **formulación débil** del problema queda por fin así:

$$\text{Determinar una función } u \text{ tal que: } \begin{cases} u = g_0 & \text{en } \Gamma_D \\ \int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \\ \text{para todo } v \text{ tal que } v = 0 \text{ en la frontera } \Gamma_D. \end{cases}$$

En esta formulación la condición de Dirichlet —desplazamientos dados— se impone como una condición aparte que ha de cumplir la función de prueba v . Se denomina *condición esencial de borde o frontera*. La condición de Neumann —fuerzas normales— aparece como una *condición de frontera natural* dentro de la formulación del problema.

Como indicábamos anteriormente, la función de prueba v chequea la ecuación que satisface u . Juega un papel de función de ponderación para comprobar el comportamiento medio de la ecuación. En alguna referencia interesante se la denomina *desplazamiento virtual* para enfatizar que no es una incógnita sino algo utilizado para formular el problema de esta manera: mediante desplazamientos virtuales de la realidad, si se llega a conocer.

7.1.2 Espacios de trabajo

Hasta ahora hemos dado por hecho que el contexto matemático donde se desenvuelve este problema y las formulaciones que estamos utilizando cumplen una serie de requisitos matemáticos que permiten su existencia y solución. Vamos a formalizarlo un poco. El primer espacio que estamos utilizando es el espacio vectorial de las *funciones al cuadrado integrables* en Ω , es decir,

$$L^2(\Omega) = \left\{ f : \Omega \rightarrow \mathbb{R} \mid \int_{\Omega} |f|^2 < \infty \right\}.$$

Como vimos en la sección dedicada a espacios vectoriales, la definición requiere la *integral de Lebesgue*, la métrica o medida de Lebesgue y el *espacio de Lebesgue*. Simplificadamente, si $\int_{\Omega} f(x) dx$ es la integral de Lebesgue de $f(x)$ y se define la norma $\|f\|_{L^p(\Omega)} = (\int_{\Omega} f^p dx)^{1/p}$, para $1 \leq p < \infty$, los espacios de Lebesgue son

$$L^p(\Omega) = \{f(x) : \|f\|_{L^p(\Omega)} < \infty\}.$$

El segundo es el *espacio de Sobolev* —por Sergéi Lvóvich Sobolév, Rusia 1908-1989—. Es un espacio vectorial de funciones dotado de una norma que es combinación de normas L^p de la función y de sus derivadas hasta un orden dado. Formalmente para dos dimensiones es

$$H^1(\Omega) = \left\{ u \in L^2(\Omega) \left| \frac{\partial u}{\partial x_1}, \frac{\partial u}{\partial x_2} \in L^2(\Omega) \right. \right\}.$$

Las derivadas de este espacio se entienden en un *sentido débil* que hagan que el espacio sea completo —si toda sucesión de Cauchy en él tiene límite— y por lo tanto sea un espacio de Banach. En sentido débil no es sino una generalización del concepto de derivada a funciones no necesariamente derivables pero si integrables localmente en el sentido de Lebesgue en un dominio dado Ω de $L^p(\Omega)$.

La norma correspondiente de este espacio completo es

$$\|u\|_{1,\Omega} = \left(\int_{\Omega} |\nabla u|^2 + \int_{\Omega} |u|^2 \right)^{1/2} = \left(\int_{\Omega} \left| \frac{\partial u}{\partial x_1} \right|^2 + \int_{\Omega} \left| \frac{\partial u}{\partial x_2} \right|^2 + \int_{\Omega} |u|^2 \right)^{1/2},$$

denominada en ingeniería *norma de energía*. Las funciones que usan esta forma finita son funciones de energía finita. Intuitivamente, un espacio de Sobolev es un espacio de funciones con derivadas de orden suficiente para un dominio de aplicación determinado y equipado con una norma que mida adecuadamente tamaño y regularidad en las funciones. Un subespacio de interés de ese espacio $H^1(\Omega)$ es

$$H_{\Gamma_D}^1(\Omega) = \{v \in H^1(\Omega) | v = 0 \text{ en } \Gamma_D\}.$$

Establecido todo este aparato matemático, la formulación débil del problema original queda así:

$$\begin{cases} \text{Determinar una función } u \in H^1(\Omega) \text{ tal que} \\ u = g_0 \text{ en } \Gamma_D \\ \int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \text{ para todo } v \in H_{\Gamma_D}^1(\Omega). \end{cases}$$

La condición que se impone a la función de prueba, $v \in H_{\Gamma_D}^1(\Omega)$, es la misma que

$$v \in H^1(\Omega) \text{ tal que } v = 0 \text{ en } \Gamma_D,$$

lo que quiere decir que v está en el mismo espacio de la función que se busca u pero satisface una versión homogénea de la condición esencial de borde o frontera.

Los datos del problema están en los siguientes espacios $f \in L^2(\Omega)$, $g_1 \in L^2(\Gamma_N)$ y $g_0 \in H^{1/2}(\Gamma_D)$. El segundo espacio restringe el dominio de las integrales en la línea que marca Γ_N en vez de en Ω . Que $g_0 \in H^{1/2}(\Gamma_D)$ quiere decir que existe al menos una función $u_0 \in H^1(\Omega)$ tal que $u_0 = g_0$ en Γ_D . De hecho, todas las demás que cumplen esta condición pertenecen a $u_0 + H_{\Gamma_D}^1(\Omega) = \{u_0 + v | v \in H_{\Gamma_D}^1(\Omega)\} = \{w \in H^1(\Omega) | w = g_0 \text{ en } \Gamma_D\}$. Que g_0 pertenezca a $H^{1/2}(\Gamma_D)$ significa que no se busca la solución en el conjunto vacío.

7.1.3 Discretización del problema en un subespacio de elementos finitos lineales

Como venimos anunciando, la resolución del problema que estudiamos con el concurso de “elementos finitos” está basada en la aproximación, debida a Boris Grigoryevich Galerkin, Rusia 1871-194,



del espacio $H^1(\Omega)$ mediante funciones polinomiales sencillas por tramos o trozos. Esto transformará el espacio original de dimensión infinita en un subespacio de dimensión finita de funciones admisibles fáciles de obtener.

Para conseguirlo se utiliza una partición del dominio de cálculo Ω en subdominios, a los que se denomina *mallado*. El más sencillo es aquel en el que Ω es un intervalo de la recta real, por ejemplo el abierto $(0, 1)$, en el que se tiene la partición $0 = x_0 < x_1 < \dots < x_n = 1$ dividida en subintervalos $I_j = (x_{j-1}, x_j)$ de longitud $h_j = x_j - x_{j-1}$, $j = 1, \dots, n$. Si $h = \max h_j$ y V_h es el espacio lineal de funciones v tal que $v \in C^0([0, 1])$, $v|_{[x_{i-1}, x_i]}$ es un polinomio lineal, $i = 1, \dots, n$, perteneciente por tanto a $\mathbb{P}_1$, y $v(0) = 0$.

Para cada $i = 1, \dots, n$ se define la función ϕ_i como una *delta de Kronecker*,



Leopold Kronecker, Polonia 1823-Alemania 1891

de tal forma que

$$\phi_i(x_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases},$$

según se indica en la figura 7.4.




Figura 7.4: Función de base lineal por tramos

Se tiene que $\{\phi_i : 1 \leq i \leq n\}$ es una base de V_h . El conjunto $\{\phi_i\}$ es una *base nodal* de V_h y $\{v(x_i)\}$ son los valores nodales de una función v . Los puntos (x_i) se denominan *nodos* o *nudos*.

Dada una función $v \in C^0([0, 1])$, el *interpolante*, o función de interpolación, $v_h \in V_h$ de v se obtiene mediante $v_h = \sum_{i=1}^n v(x_i)\phi_i$ como se aprecia en la figura 7.5. Si $v \in V_h \Rightarrow v = v_i$.




Figura 7.5: Aproximación mediante v_h de una función de base lineal por tramos

Otra partición —quizás la más utilizada— consiste en *triangularizar* un dominio de dos dimensiones, como Ω , en pequeños triángulos que lo cubran enteramente. En la figura 7.6 se ve la correspondiente al dominio con el que venimos experimentando en estas notas.

Para simplificar se supone que la frontera o borde, Γ , del dominio Ω es una curva poligonal. Si no lo es, primero se le aproxima a un polígono. La triangularización consiste en dividir Ω en un conjunto de triángulos $\mathcal{T}_h = K_1, \dots, K_m$ que no se solapen y que solo compartan lados completos, o lo que es lo mismo, que ningún vértice de ningún triángulo caiga en algún lado de otro. Se cumplirá que

$$\Omega = \bigcup_{K \in \mathcal{T}_h} K = K_1 \cup K_2 \cdots \cup K_m.$$




Figura 7.6: Triangularización del dominio Ω

El subespacio V_h de $H^1(\Omega)$ es ahora

$$V_h = \left\{ \text{funciones } v \in C(\Omega) \mid v|_K \text{ es lineal para todo } K \in \mathcal{T}_h, v = 0 \text{ en } \Gamma \right\},$$

donde $v|_K \in \mathbb{P}_1$ se refiere a la función v restringida a K . Recordemos que $\mathbb{P}_1$ es el espacio de polinomios lineales del tipo $a_0 + a_1x_1 + a_2x_2$, donde los coeficientes a_0 , a_1 y a_2 serían los parámetros de cada triángulo.

Los parámetros que definirán la función $v \in V_h$ serán los valores $v(N_i)$ de v en los nodos $N_i, i = 1, \dots, M$ de $\mathcal{T}_h$ excluyendo aquellos en los bordes pues $v = 0$ en Γ . Los valores de los nodos de la triangularización del dominio son los grados de libertad que determinan un elemento de V_h . Una numeración de esos nodos para nuestro dominio de trabajo sería la de la figura 7.7. Los nodos se indican mediante el vector $\mathbf{x}_i$, donde $i = 1, \dots, M$, el número de nodos.




Figura 7.7: Numeración de los nodos del dominio Ω

Si se fija un nodo del dominio y se le asocia el valor 1 y 0 a todos los demás, existe

una función única, $\phi_i \in V_h$, *función de base de nodo*, tal que

$$\phi_i(\mathbf{x}_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}, \quad i, j = 1, \dots, M.$$

El aspecto de una de estas funciones es el de la figura 7.8. Si un triángulo K no tiene a




Figura 7.8: Gráfica de la funciones de base de los nodos del dominio Ω

$\mathbf{x}_i$ como uno de sus vértices, ϕ_i es cero en todo el triángulo pues el valor de la función en todos sus vértices es cero. El soporte por tanto de ϕ_i —la envoltura del conjunto de puntos donde ϕ_i no es cero— es la misma que la unión de todos los triángulos que comparten $\mathbf{x}_i$ como vértices. Ver figura 7.9.




Figura 7.9: Soporte de dos funciones de base del dominio Ω

Una función cualquiera $u_h \in V_h$ se representa entonces como

$$u_h = \sum_{j=1}^M u_h(\mathbf{x}_j) \phi_j(\mathbf{x}_i) = \sum_{j=1}^M u_h(\mathbf{x}_j) \delta_{ji} = \sum_{j=1}^M u_h(\mathbf{x}_j) \phi_j.$$

El conjunto $\{\phi_i, i = 1, \dots, M\}$ es una base de V_h .

Hasta ahora no hemos tenido en cuenta si los nodos de la frontera están en el segmento de borde tipo Dirichlet o Neumann. Si teníamos hasta ahora el espacio

$$H_{\Gamma_D}^1(\Omega) = \{v \in H^1(\Omega) \mid v = 0, \text{ en } \Gamma_D\},$$

ahora nos interesa

$$V_h^{\Gamma_D} = V_h \cap H_{\Gamma_D}^1(\Omega) = \{v_k \in V_h \mid v_h = 0, \text{ en } \Gamma_D\}.$$

La idea es llevar constancia de qué nodos son Dirichlet —Dir— y cuáles no, independientes, —Ind—. En el caso del ejemplo que tratamos,

$$\text{Dir} = \{9, 13, 14, 15, 17, 18\}$$

$$\text{Ind} = \{1, 2, 3, 4, 5, 6, 7, 8, 10, 11, 12, 16\}.$$

Entonces, un elemento de V_h se podría escribir como

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} u_j \phi_j, \quad u_j = u_h(\mathbf{x}_j)$$

y uno de $V_h^{\Gamma_D}$ así

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j.$$

7.1.4 Reformulación del problema como un sistema de ecuaciones lineales

Recapitulando, el método nos ha hecho llegar a la siguiente formulación:

Obtener una función $u_h \in V_h$

$$\text{tal que} \begin{cases} u_h(\mathbf{x}_j) = g_0(\mathbf{x}_j) \quad \forall j \in \text{Dir} \\ \int_{\Omega} \nabla u_h \cdot \nabla \phi_i + c \int_{\Omega} u_h \phi_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i, \quad \forall i \in \text{Ind}. \end{cases}$$

Para ello:

- Hemos convertido el espacio de Sobolev en el que buscamos la función solución en uno de dimensión finita, V_h . Es decir, hemos reducido el problema a calcular u_h en los vértices de una triangularización —los nodos— y a un número finito de incógnitas.
- Hemos sustituido las condiciones tipo Dirichlet fijando condiciones a los nodos Dirichlet, lo que reduce aún más el número de incógnitas: a los nodos *independientes*.
- Hemos reducido el espacio de prueba de $H_{\Gamma_D}^1(\Omega)$ a un subespacio discreto $V_h^{\Gamma_D}$, lo que reduce un número infinito de pruebas en la formulación débil a un número finito de ecuaciones lineales.

Para obtener finalmente el sistema de ecuaciones lineales escribimos u_h en términos de las funciones de base de los nodos:

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} u_j \phi_j.$$

Luego sustituimos en esta expresión las condiciones de Dirichlet discretizadas:

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} g_0(\mathbf{x}_j) \phi_j.$$

Finalmente incorporamos esta expresión en la formulación variacional discreta:

$$\int_{\Omega} \nabla u_h \cdot \nabla \phi_i + c \int_{\Omega} u_h \phi_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i,$$

linealizando, teniendo en cuenta que

$$\nabla u_h = \sum_{j \in \text{Ind}} u_j \nabla \phi_j + \sum_{j \in \text{Dir}} g_0(\mathbf{x}_j) \nabla \phi_j$$

y reordenando llegamos a

$$\begin{aligned} \sum_{j \in \text{Ind}} \left(\int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i + c \int_{\Omega} \phi_j \phi_j \right) u_j &= \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i \\ &\quad - \sum_{j \in \text{Dir}} \left(\int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i + c \int_{\Omega} \phi_j \phi_j \right) g_0(\mathbf{x}_j). \end{aligned}$$

Este es un sistema de ecuaciones lineales con un número de ecuaciones igual al número de incógnitas ($\# \text{Ind} = \dim V_h^{\Gamma_D}$), que son precisamente los valores de la función u_h en los nodos libres de la triangularización llevada a cabo.

Hay dos matrices importantes en este sistema de ecuaciones, la *matriz de rigideces*,

$$\mathbf{W}_{ij} = \int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i$$

y la *matriz de masas*

$$\mathbf{M}_{ij} = \int_{\Omega} \phi_j \phi_i.$$

Ambas son simétricas. La de masas es definida positiva. La de rigideces semidefinida positiva. Si hacemos $\mathbf{b}_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i$, $i \in \text{Ind}$, se llega a

$$\sum_{j \in \text{Ind}} \left(\mathbf{W}_{ij} + c \mathbf{M}_{ij} \right) u_j = \mathbf{b}_i - \sum_{j \in \text{Dir}} \left(\mathbf{W}_{ij} + c \mathbf{M}_{ij} \right) g_0(\mathbf{x}_j), \quad i \in \text{Ind}.$$

Estas matrices poseen *patrones de dispersidad* muy pronunciados pues sólo interactúan nodos que están unidos entre sí por lados de triángulos. Ello las hacen propicias para ordenaciones en torno a la diagonal principal. Su manipulación es sencilla y las operaciones necesarias para resolver los gigantescos sistemas de ecuaciones lineales a que pueden dar lugar son perfectamente tratables por los ordenadores disponibles actualmente.

7.2 Fundamentos de funcionales y cálculo de variaciones

Definición 7.1 Un **funcional** es una función que tiene funciones como argumento a las que asigna un valor real. Es decir, una función cuyo dominio es un conjunto de funciones.

En la figura 7.10 se esquematiza² la diferencia entre una función ordinaria y un funcional.




Figura 7.10: Diagrama de bloques que ilustra la diferencia formal en una dimensión entre una función ordinaria y un funcional. (a) Una función ordinaria $y = y(x) = f(x)$ de una variable independiente x ; (b) Un funcional $J(y) = J(x, y)$ de la función $y(x)$; Un funcional $J(y) = J(x, y, y')$ de la función $y(x)$ y su derivada $y' = dy/dx$

El *funcional básico unidimensional* lineal más típico tiene la forma

$$J(y) = \int_a^b F(x, y(x), y'(x)) dx, \quad x = [a, b], \quad a \leq b, \quad y(a) = \hat{y}_a, \quad y(b) = \hat{y}_b.$$

En palabras, la función $y = y(x)$ está definida en el segmento $x \in [a, b]$, $a \leq b$, de la recta real. Dado un x , $y(x)$ se supone real y único. Además, $y(x)$ es continua y derivable por lo que $y'(x)$ existe al igual que la integral enunciada. La función debe satisfacer

²Fuente: <http://www.colorado.edu/engineering/CAS/courses.d/AVMM.d/AVMM.Ch01.d/AVMM.Ch01.pdf>.

en $x = a$ y en $x = b$ unas determinadas *condiciones de contorno*: concretamente, $\hat{y}_a = y(a)$ y $\hat{y}_b = y(b)$.

Así era cómo la palabra funcional fue utilizada inicialmente en el cálculo de variaciones, donde el integrando a ser minimizado debía ser un funcional, aplicada a una todavía desconocida función que satisfacía solamente una cierta condición de contorno, y condiciones de derivabilidad.

Otro funcional lineal habitual es la *función delta de Dirac*, $\delta_t[f(\cdot)] = f(t)$, —por Paul Adrien Maurice Dirac, Reino Unido, 1902-1984—



que se puede escribir también como

$$\delta_t[f(\cdot)] = \int_a^b f(x)\delta(x-t) dt.$$

Un problema de cálculo de variaciones o *problema variacional* típico sería el de encontrar la función $y \in [a, b] \rightarrow \mathbb{R}$ que minimiza el funcional anterior, $J(y)$, con las condiciones de contorno indicadas.

En varios campos de la ingeniería, la física matemática, el reconocimiento de imágenes y otros muchos, el cálculo de variaciones es un interesante problema matemático consistente en buscar máximos y mínimos (o más generalmente extremos relativos) de funcionales continuos definidos sobre algún espacio funcional. Constituyen una generalización del cálculo elemental de máximos y mínimos de funciones reales de una variable. Muchos problemas de este tipo³ son fáciles de formular pero sus soluciones implican a menudo, a su vez, difíciles procedimientos de cálculo diferencial, los cuales generalmente suponen usar ecuaciones diferenciales ordinarias —*Ordinary Differential Equations*—, así como las ecuaciones (diferenciales) en derivadas parciales —*Partial Differential Equations*—.

En la figura 7.11 se pueden ver algunos problemas clásicos de funcionales en una dimensión.

Por regla general, no todas las funciones pueden encajar en un funcional. La figura 7.12 ilustra grosso modo algunos tipos de funciones permitidas y otras no admisibles.

Si se considera un funcional general

$$I = \int_{x_1}^{x_2} F(x, y, y') dx$$

³Por ejemplo el de encontrar la curva de longitud más corta que una dos puntos.




Figura 7.11: Ejemplos unidimensionales de funcionales: (a) Área debajo de una curva, $\int_a^b y(x) dx$; (b) Longitud de un arco de curva, $\int_a^b \sqrt{1 + (y'(x))^2} dx$; (c) Curva braquistócrona, $\int_a^b \sqrt{\frac{1 + (y'(x))^2}{2gy}} dx$

donde F es una función conocida con derivadas continuas hasta segundo orden respecto a x , y y y' . El valor de I dependerá de la trayectoria de la función entre (x_1, y_1) y (x_2, y_2) ; es decir, dependerá de la función $y(x)$ que se escoja.

Si se introduce como prueba la familia de trayectorias

$$\tilde{y}(x) = y(x) + \varepsilon \eta(x),$$

donde ε es un parámetro y $\eta(x)$ una función derivable a la que se le pide que $\eta(x_1) = \eta(x_2) = 0$, resulta que se pueden generar una infinidad de trayectorias para una $\eta(x)$ dada sin más que variar el parámetro ε . Todas ellas pasan por (x_1, y_1) y (x_2, y_2) . Consideremos

$$\tilde{I} = \int_{x_1}^{x_2} F(x, \tilde{y}, \tilde{y}') dx = \int_{x_1}^{x_2} F(x, y + \varepsilon \eta, y' + \varepsilon \eta') dx$$

Es evidente que los funcionales I y $\tilde{I}$ alcanzarán el mismo valor extremo (valor máximo o mínimo) cuando $\varepsilon = 0$. Desarrollando, se tiene que

$$\tilde{I} = (\tilde{I})_{\varepsilon=0} + \left(\frac{d\tilde{I}}{d\varepsilon} \right)_{\varepsilon=0} \varepsilon + \left(\frac{d^2\tilde{I}}{d\varepsilon^2} \right)_{\varepsilon=0} \frac{\varepsilon^2}{2!} + \dots$$

Para que $\tilde{I}$ sea extremo cuando $\varepsilon = 0$ es necesario que

$$\left(\frac{d\tilde{I}}{d\varepsilon} \right)_{\varepsilon=0} = 0.$$




Figura 7.12: Muestrario de funciones admisibles en un funcional: (a) Funciones continuas, C^1 , con un sólo valor para cada x y que cumplen las condiciones de contorno; (b) Inadmisibles: La 1 y la 3 tienen derivadas discontinuas; la 2 es discontinua y admite varios valores para un x ; la 4 admite varios valores para un x y la 5 no cumple las condiciones de contorno

Es decir que

$$\left\{ \int_{x_1}^{x_2} \left(\frac{\partial F}{\partial \tilde{y}} \frac{d\tilde{y}}{d\varepsilon} + \frac{\partial F}{\partial \tilde{y}'} \frac{d\tilde{y}'}{d\varepsilon} \right) dx \right\}_{\varepsilon=0} = 0.$$

Dado que $d\tilde{y}/d\varepsilon = \eta$, que $d\tilde{y}'/d\varepsilon = \eta'$ y que quitar las tildes de $\tilde{y}$ y de $\tilde{y}'$ en las derivadas de F es lo mismo que hacer $\varepsilon = 0$ según se requería más arriba, la ecuación anterior se puede reescribir así:

$$\int_{x_1}^{x_2} \left(\frac{\partial F}{\partial y} \eta + \frac{\partial F}{\partial y'} \eta' \right) dx = 0.$$

Integrando por partes el segundo término,

$$\int_{x_1}^{x_2} \frac{\partial F}{\partial y'} \eta' dx = \left. \frac{\partial F}{\partial y'} \eta \right|_{x_1}^{x_2} - \int_{x_1}^{x_2} \left[\frac{d}{dx} \left(\frac{\partial F}{\partial y'} \right) \right] \eta dx.$$

Cuando $\eta = 0$ en los extremos la primera expresión del miembro de la derecha de esta

ecuación se hace cero. Sustituyendo lo que queda en la anterior se tiene que

$$\int_{x_1}^{x_2} \left[\frac{\partial F}{\partial y} - \frac{d}{dx} \left(\frac{\partial F}{\partial y'} \right) \right] \eta \, dx = 0.$$

Cualquiera que sea la función $\eta(x)$ entre los puntos extremos, según la *fórmula de Euler-Lagrange* se tiene que

$$\frac{d}{dx} \frac{\partial F}{\partial y'} - \frac{\partial F}{\partial y} = 0$$

que es la condición que debe cumplir $y(x)$ para ser un máximo o un mínimo: un extremo. Si en esta expresión se sustituye F por su expresión $F(x, y, y')$ resulta una ecuación diferencial de segundo orden en $y(x)$.

7.2.1 Proposiciones esenciales

Lema 7.1 *Lema fundamental del Cálculo de Variaciones. Sea $M(x)$ una función continua definida en el intervalo $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$ se tiene que*

$$\int_a^b M(x) \zeta(x) \, dx = 0.$$

Se cumple entonces que

$$M(x) = 0 \text{ para todo } x \in [a, b].$$

Demostración. Supongamos que $M(x)$ no es cero en algún punto $x_0 \in (a, b)$. Concretamente que $M(x_0) > 0$. Por la continuidad de $M(x)$, existe un $\delta > 0$ tal que

$$-\frac{M(x_0)}{2} < M(x) - M(x_0) < \frac{M(x_0)}{2} \quad \text{para } |x - x_0| < \delta \quad \text{con } x \in [a, b].$$

En consecuencia, $M(x) > M(x_0)/2$ en ese intervalo. Escojamos una función $\zeta(x)$ tal que, como se ve en la figura 7.13,

$$\zeta(x) = \begin{cases} 0 & \text{si } a \leq x \leq a_1 = \max(x_0 - \delta, a) \\ > 0 & \text{si } |x - x_0| < \delta, x \in [a, b] \\ 0 & \text{si } \min(x_0 + \delta, b) = b_1 \leq x \leq b. \end{cases}$$

Se tiene entonces que

$$0 = \int_a^b M(x) \zeta(x) \, dx = \int_{a_1}^{b_1} M(x) \zeta(x) \, dx > \frac{1}{2} M(x_0) \int_{a_1}^{b_1} \zeta(x) \, dx > 0,$$




Figura 7.13: Lema fundamental del Cálculo de Variaciones

lo cual es una contradicción.

Si $M(x_0) < 0$ el argumento sería idéntico sustituyendo $M(x)$ por $-M(x)$. Si $x_0 = a$ o $x_0 = b$ la demostración sería casi igual con pequeñas modificaciones en la línea argumental. $\square$

Corolario 7.2 El resultado del Lema 7.2.1 sigue siendo aplicable si $\zeta(a) = \zeta(b) = 0$.

Corolario 7.3 Supóngase que $M(x)$ es continua en el intervalo $I = [a, b]$ y que $\{\varphi_n(x)\}_{n=1}^{\infty}$ es un conjunto de funciones base. Supóngase además que

$$\int_a^b M(x)\varphi_n(x) dx = 0 \quad \text{para } n = 1, 2, \dots$$

Se cumple entonces que $M(x) = 0$ para todo $x \in [a, b]$.

Lema 7.4 Sea $M(x)$ una función continua en $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$, de derivada continua, se tiene que

$$\int_a^b M(x)\zeta'(x) dx = 0$$

para $\zeta(a) = \zeta(b) = 0$. Se cumple así que $M(x) = cte$ para todo $x \in [a, b]$.

Lema 7.5 Sea $M(x)$ una función continua definida en el intervalo $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$, de derivadas continuas al menos

hasta segundo grado, se tiene que

$$\int_a^b M(x) \zeta''(x) dx = 0$$

para $\zeta(a) = \zeta(b) = 0$ y $\zeta'(a) = \zeta'(b) = 0$. Se cumple entonces que $M(x) = c_0 + c_1 x$ para todo $x \in [a, b]$, donde c_0 y c_1 son constantes.

8 | Análisis de componentes principales

El análisis de componentes principales —ACP en español, PCA en inglés— tiene como objetivo representar la información de n observaciones de p variables con un número sustancialmente menor de unas nuevas variables construidas como combinaciones lineales de las originales. Sirve para hallar las causas fundamentales de la variabilidad de un conjunto de datos y ordenarlas por importancia. Es uno de los instrumentos básicos del análisis de datos y del Big_Data que tanto interés teórico y práctico despiertan en la actualidad para explicar multitud de tendencias y comportamientos de la vida cotidiana.

Técnicamente el ACP busca la proyección del espacio original de variables en un subespacio en el cual los datos queden adecuadamente representados en términos de mínimos cuadrados lineales de unos *componentes principales* (variables artificiales independientes entre sí), perdiéndose la menor cantidad de información original posible. Comporta el cálculo de la descomposición en valores propios de la matriz de covarianza de los datos, una vez centrados en la media de cada atributo. La PCA Es una extensión inmediata de lo apuntado en la sección 3.3.2, en la página 45, dedicada a valores singulares.

El análisis de componentes principales fue formulado por Harold Hotelling, EE.UU. 1895-1973.



Sus orígenes se remontan al trabajo sobre ajustes ortogonales por mínimos cuadrados de Karl Pearson, Reino Unido, 1857-1936.



Como apuntábamos, permite transformar las variables originales de los datos de un problema, en general correladas, en un número menor de nuevas variables incorreladas, facilitando así la interpretación de esos datos.

8.1 Algunos conceptos de estadística

Sea $[X_1 \cdots X_n]$ una matriz $p \times n$ de n observaciones de p variables. La *media* de esta muestra es

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

La *desviación típica*, o estándar,

$$\sigma(X) = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}}.$$

La *varianza*, medida de la dispersidad de la muestra, es la desviación típica al cuadrado, esto es,

$$\text{Var}(X) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}.$$

El grado de asociación lineal más simple de cada variable con las demás, dos a dos, es lo que configura la *matriz de covarianzas*, de dimensión $p \times p$,

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n} = \Gamma.$$

Si la covarianza entre dos variables es positiva, cuando una de ellas se incrementa la otra hace lo mismo. Si es negativa, cuando una de ellas se incrementa, la otra decrece. Si es cero, las dos variables son independientes entre si. Los coeficientes de la diagonal principal de la matriz de covarianzas son las varianzas de cada variable individual. La matriz de covarianzas es simétrica. La varianza total de los datos es la suma de cada varianza individual por lo que la traza de la matriz de covarianzas es precisamente esa varianza total. En la figura 8.1 se ilustran unos patrones de datos y las matrices de covarianzas correspondientes.

La matriz de covarianzas es semidefinida positiva, es decir, $\mathbf{x}^T \text{cov}(X, Y) \mathbf{x} \geq 0$ para cualquier vector $\mathbf{x} \neq \mathbf{0}$.

La covarianza como medida de asociación tiene el inconveniente de que depende de las unidades de medida de las variables. Si por ejemplo la covarianza entre la estatura de una persona, medida en centímetros, y su peso, en gramos, es 200, si se expresa el peso en kilogramos, la covarianza será 0,002. Para construir una media adimensional se divide la covarianza por un término con sus mismas dimensiones. Se define así el **coeficiente de correlación** y a partir de él la **matriz de correlación**, de dimensión también $p \times p$, es

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X)\sigma(Y)} = \mathbf{R}.$$

Esta matriz se utiliza para *estandarizar* los diversos datos. Es también semidefinida positiva.




Figura 8.1: La matriz de covarianzas expresa la forma de los datos. La variabilidad en torno a la diagonal la determina la covarianza mientras que alrededor de los ejes la define la varianza

La matriz de covarianzas y la matriz de correlación están relacionadas mediante la expresión $\text{corr}(X, Y) = D^{-1} \text{cov}(X, Y) D^{-1}$, donde D es una matriz diagonal construida con las desviaciones típicas de las variables.

Una medida global escalar de la variabilidad conjunta de k variables es la *varianza generalizada*, que es el determinante de la matriz de covarianzas. Mide aproximadamente el área, volumen o hipervolumen ocupado por el conjunto de datos.

La *matriz de covarianzas* —o la matriz de correlación— determinará si existen altas correlaciones entre las variables y por tanto existe información redundante entre ellas, es decir, una misma información vista desde varias perspectivas. Cuanto mayor sea la variabilidad de los datos (varianza), más rica la información disponible.

Si

$$M = \frac{1}{n} (X_1 + \dots + X_n)$$

y $\hat{X}_k = X_k - M$, la matriz de covarianzas es

$$\text{cov}(X, Y) = \frac{1}{n} \begin{bmatrix} \hat{X}_1 & \hat{X}_2 & \dots & \hat{X}_n \end{bmatrix} \begin{bmatrix} \hat{X}_1^T \\ \hat{X}_2^T \\ \vdots \\ \hat{X}_n^T \end{bmatrix} = \frac{1}{n} B B^T.$$

8.2 Planteamiento del problema matemático

Se trata de encontrar un subespacio de dimensión menor a p tal que al proyectar sobre él los puntos de la muestra se conserve su estructura con la menor distorsión posible.

Para conseguirlo se construye una transformación lineal que determina un nuevo sistema ortogonal de coordenadas para el conjunto de datos original en el cual la varianza de mayor tamaño de los datos define el primer eje —primer *Componente Principal*—, la segunda varianza el segundo eje y así sucesivamente. Esto se lleva a efecto mediante la *descomposición espectral* de la matriz de covarianzas,

$$\text{cov}(X, Y) = \mathbf{\Gamma} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T,$$

donde $\mathbf{U}$, $\mathbf{U}^T \mathbf{U} = \mathbf{U} \mathbf{U}^T = \mathbf{I}$, es una matriz ortogonal $p \times p$ formada por los vectores propios correspondientes a los valores propios $\lambda_1, \dots, \lambda_p$ y $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$. Se cumple que $\lambda_1 \geq \dots \geq \lambda_p$ y que los Componentes Principales son los p vectores fila de la matriz, $p \times n$, $\mathbf{U}^T \mathbf{B}$.

El subespacio generado por los k primeros vectores propios es, de todos los posibles del espacio de dimensión p , el que mejor representa los datos originales en términos de mínimos cuadrados lineales.

Si la matriz de covarianzas de los datos es diagonal las varianzas son iguales a los valores propios de esa matriz y los vectores propios coinciden con los ejes x e y —las covarianzas son cero—. Si la matriz de covarianzas no es diagonal, la covarianzas no son cero pero los valores propios siguen indicando la magnitud de la varianza en las direcciones ortogonales de los vectores propios, de mayor a menor, que ya no coinciden con x e y . Esto se ilustra en la figura⁴ 8.2 donde un mismo conjunto de datos está rotado diversos ángulos para visualizar en qué consiste la matriz de covarianzas. La matriz de covarianzas, desde el punto de vista del álgebra lineal, representa una transformación lineal. El utilizarla en estos algoritmos es como tratar de descorrelar los datos originales para encontrar sus componentes subyacentes o *principales* —llevar los datos a unos ejes donde se perciba el menor ruido posible—.

Para proceder numéricamente con este método y obtener la transformación que se busca primero se adaptan los datos originales para tratarlos según convenga. Luego de construye la matriz de covarianzas. A continuación, como esquematiza⁵ el diagrama de bloques numéricos de la figura 8.3, se puede proceder de dos maneras:

- Se calculan los valores propios y los correspondientes vectores propios de la matriz de covarianzas. Luego se proyectan en esos vectores propios los datos. Una versión de esta forma de actuar en MATLAB sería el programa `pca1` del cuadro 8.1.
- Se calcula la descomposición en valores singulares de $\frac{\mathbf{B}}{\sqrt{n}}$ y se obtienen las varianzas. El programa `pca2` materializa esta variante.

Como ejemplo de introducción a este análisis por componentes principales estudiamos los datos del cuadro 8.2. En él se presenta información sobre pisos construidos por

⁴Fuente: <http://www.visiondummy.com/2014/04/geometric-interpretation-covariance-matrix/>.

⁵Fuente: <http://mengnote.blogspot.com/2013/05/an-intuitive-explanation-of-pca.html>.




Figura 8.2: Valores y vectores propios de un mismo conjunto de datos pero rotado ángulos distintos

10 constructoras distintas en diversos lugares de España. Se trata de considerar sólo tres variables X_1 , X_2 y X_3 . La salida que proporciona una sesión de MATLAB con los datos de la tabla y los programas apuntados es la que se puede ver en la figura 8.4.

Como se puede ver en el listado, la matriz de covarianzas de los datos estudiados es

$$\Gamma = \begin{bmatrix} 56,9685 & 5,1705 & 30,4775 \\ 5,1705 & 0,8941 & 3,6479 \\ 30,4775 & 3,6479 & 18,7641 \end{bmatrix}.$$

Los valores propios son $\Lambda = \text{diag}(74,3739, 2,1580, 0,0948)$.

Los componentes principales de este ejemplo son

$$\begin{aligned} PC_1 &= 0,8714X_1 + 0,0853X_2 + 0,4832X_3, \\ PC_2 &= 0,4798X_1 - 0,3542X_2 - 0,8027X_3 \quad \text{y} \\ PC_3 &= -0,1026X_1 + 0,9313X_2 + 0,3495X_3. \end{aligned}$$




Figura 8.3: Esquema de la transformación del ACP mediante descomposición en valores propios y descomposición en valores singulares

Los porcentajes de variabilidad que explica cada componente principal son

$$\frac{74,3739}{76,6267} \times 100 = 97,06 \%, \quad \frac{2,1580}{76,6267} \times 100 = 2,82 \% \text{ y } \frac{0,0948}{76,6267} \times 100 = 0,12 \%.$$

Con el primer componente, y por supuesto con los dos primeros, sería suficiente para representar casi perfectamente este conjunto de datos.

```

function [signals,PC,V] = pca1(data)
% Se analizan datos por Componentes Principales
% Datos: data-matriz MxN, M dimensiones y N datos
% signals: matriz MxN de datos proyectados;
% PC: componentes en columnas
% V: Mx1 matriz de varianzas
%
[~,N] = size(data);
mn = mean(data,2); data = data-repmat(mn,1,N); % datos-media
covariance = 1/N * (data*data') % Matriz covarianzas
[PC,V] = eig(covariance); % Valores y vectores propios
V = diag(V); % Diagonal principal
[~,rindi] = sort(-1*V); % Orden decreciente varianzas
V = V(rindi); PC = PC(:,rindi);
signals = PC'*data; % Proyecta datos de origen
end

```

```

function [signals,PC,V] = pca2(data)
% Se analizan datos por Componentes Principales
% Datos: data-matriz MxN, M dimensiones y N datos
% signals: matriz MxN de datos proyectados;
% PC: componentes en columnas
% V: Mx1 matriz de varianzas
%
[~,N] = size(data);
mn = mean(data,2); data = data-repmat(mn,1,N); % datos-media
Y = data'/sqrt(N); % matriz Y
[u,S,PC] = svd(Y); % Valores singulares
S = diag(S); V = S.* S; % Varianzas
signals = PC' * data; % Proyecta datos de origen
end

```

Cuadro 8.1: Dos programas de MATLAB para llevar a cabo un análisis PCA

Construcción	X_1 =Duración media hipoteca (años)	X_2 =Precio medio (millones euros)	X_3 =Superficie media (m ²) de cocina
1	8,7	0,3	3,1
2	14,3	0,9	7,4
3	18,9	1,8	9,0
4	19,0	0,8	9,4
5	20,5	0,9	8,3
6	14,7	1,1	7,6
7	18,8	2,5	12,6
8	37,3	2,7	18,1
9	12,6	1,3	5,9
10	25,7	3,4	15,9

Cuadro 8.2: Datos sobre pisos que promocionan diversas constructoras en España

```
>> datos=[1 2 3 4 5 6 7 8 9 10;
8.7 14.3 18.9 19.0 20.5 14.7 18.8 37.3 12.6 25.7;
0.3 0.9 1.8 0.8 0.9 1.1 2.5 2.7 1.3 3.4;3.1 7.4 9.0 9.4 8.3 7.6 12.6 18.1 5.9 15.9]

datos =
    1.0000    2.0000    3.0000    4.0000    5.0000    6.0000    7.0000    8.0000    9.0000   10.0000
    8.7000   14.3000   18.9000   19.0000   20.5000   14.7000   18.8000   37.3000   12.6000   25.7000
    0.3000    0.9000    1.8000    0.8000    0.9000    1.1000    2.5000    2.7000    1.3000    3.4000
    3.1000    7.4000    9.0000    9.4000    8.3000    7.6000   12.6000   18.1000    5.9000   15.9000

>> [signal PC V]=pca1(datos(2:4,1:10))

covariance =
    56.9685    5.1705    30.4775
    5.1705    0.8941    3.6479
    30.4775    3.6479   18.7641

signal =
-12.3303   -5.3219   -0.4638   -0.2687    0.5154   -4.8597    1.2482   20.0429   -7.4938    8.9318
 0.8063   -0.1713    0.4326    0.5136    2.0809   -0.2107   -2.7532    1.6367    0.0756   -2.4105
-0.0723    0.2971   -0.4540    0.6069   -0.0247    0.1397    0.1627   -0.0000   -0.4252   -0.2302

PC =
    0.8714    0.4798   -0.1026
    0.0853   -0.3542   -0.9313
    0.4832   -0.8027    0.3495

V =
    74.3739
    2.1580
    0.0948

>> [signal PC V]=pca2(datos(2:4,1:10))
signal =
-12.3303   -5.3219   -0.4638   -0.2687    0.5154   -4.8597    1.2482   20.0429   -7.4938    8.9318
 0.8063   -0.1713    0.4326    0.5136    2.0809   -0.2107   -2.7532    1.6367    0.0756   -2.4105
-0.0723    0.2971   -0.4540    0.6069   -0.0247    0.1397    0.1627   -0.0000   -0.4252   -0.2302

PC =
    0.8714    0.4798   -0.1026
    0.0853   -0.3542   -0.9313
    0.4832   -0.8027    0.3495

V =
    74.3739
    2.1580
    0.0948
```

Figura 8.4: Sesión de MATLAB para analizar los datos sobre pisos construidos

9 | Números complejos, funciones e integración

LOS números del cuerpo $\mathbb{C}$ de lo complejos surgen para dar sentido a raíces de números negativos, $\sqrt{-a^2} = \pm a\sqrt{-1}$ pues así se usan para representar modelos y problemas en muchas áreas de la ciencia e ingeniería. Para ello se utiliza la *unidad imaginaria* $i = \sqrt{-1}$.

Cualquier número complejo $z = x + yi$, donde x es la parte real e y la imaginaria (ambas reales), se representa geoméricamente en el plano complejo como se ve en la figura 9.1. El *módulo* de z , $|z| = r = \sqrt{x^2 + y^2}$.




Figura 9.1: Un número en el plano complejo

Las operaciones elementales con números complejos, si $z = a + ib$ y $w = c + id$, son la suma, $z + w = (a + c) + (b + d)i$ y la multiplicación, $zw = (ac - bd) + i(ad + bc)$. Como $i \cdot i = i^2 = -1$, $\frac{1}{i} = -i$ y $i(-i) = 1$.

El *complejo conjugado* de un número complejo $z = x + iy$ es $\bar{z} = x - iy$. Sólo si z es real se cumple que $z = \bar{z}$. Es decir, su imagen en el espejo que define el eje x . Además, $\overline{z + w} = \bar{z} + \bar{w}$, $\overline{zw} = \bar{z} \bar{w}$ y $\overline{\bar{z}} = z$. Estas fórmulas se extienden a sumas y productos de más de dos números complejos y a integrales (recordemos que son el límite de una suma de infinitos sumandos), así

$$\overline{\int f(t)g(t) dt} = \int \overline{f(t)} \overline{g(t)} dt.$$

El cociente z/w es

$$\begin{aligned} \frac{z}{w} &= \frac{a + bi}{c + di} \\ &= \frac{a + bi}{c + di} \cdot \frac{c - di}{c - di} \\ &= \frac{(a + bi)(c - di)}{c^2 + d^2} = \frac{(ac + bd) + (bc - ad)i}{c^2 + d^2}. \end{aligned}$$

En su *forma polar* un número complejo se escribe $z = re^{i\varphi} = r(\cos \varphi + i \sin \varphi)$, donde $r = \sqrt{x^2 + y^2}$ y $\varphi = \arctan(y/x)$. A $e^{i\varphi} = \cos \varphi + i \sin \varphi$ se la conoce como *identidad de Euler*.

La *circunferencia de radio unidad* en el plano complejo es el lugar geométrico de los números complejos con $r = 1$ —figura 9.2—. Si se multiplican dos números $e^{i\theta}$ y $e^{i\gamma}$ de esa circunferencia,

$$\begin{aligned} e^{i\theta} e^{i\gamma} &= (\cos \theta + i \sin \theta)(\cos \gamma + i \sin \gamma) \\ &= \cos \theta \cos \gamma - \sin \theta \sin \gamma + i(\sin \theta \cos \gamma + \sin \gamma \cos \theta). \end{aligned}$$

Reordenando, y recordando que $\cos \theta = \frac{e^{i\theta} + e^{-i\theta}}{2}$ y $\sin \theta = i \frac{e^{-i\theta} - e^{i\theta}}{2}$, resulta que $e^{i(\theta+\gamma)} = \cos(\theta + \gamma) + i \sin(\theta + \gamma)$. Por tanto, el producto de dos números complejos en la circunferencia de radio unidad es otro número de la misma circunferencia cuyo *ángulo es la suma* de los dos precedentes.





Figura 9.2: Circunferencia de radio unidad en el plano complejo

Los números *Moivre*, z tales que $z^n - 1 = 0$, *raíces n -ésimas de la unidad*, por Abraham de Moivre, Francia, 1667-1754,



tienen un especial interés en aplicaciones prácticas:

- En la recta de números reales sólo hay dos: -1 y 1 .
- En el plano complejo hay muchos. Por ejemplo, i es una raíz cuarta de 1 : $i^4 = (\sqrt{-1})^4 = (-1)^2 = 1$.

Están localizados en la circunferencia del plano complejo de radio la unidad: forman los vértices de un polígono regular de n lados con un vértice en 1 como se ve en la figura 9.3 para $n = 5$.




Figura 9.3: Circunferencia de radio unidad en el plano complejo y números de Moivre para $n = 5$

Una raíz n -ésima de la unidad se denomina *primitiva* si no es una raíz k -ésima para $k < n$. Así, -1 es una raíz segunda primitiva de la unidad y cuarta no primitiva de ella.

Visto de otra manera, la raíz n -ésima de la unidad α es primitiva, si sólo si sus k -ésimas potencias, $k = 0, 1, \dots, n-1$ son distintas. Las raíces cuartas de 1 son: $1, -1, i, -i$. En el caso de 1 sus potencias de grado 0, 1, 2 y 3 son iguales; no es raíz primitiva. Para i , se calcula que las potencias de grado 0, 1, 2, 3 son, respectivamente, $1, i, -1, -i$, distintas, luego i es una raíz cuarta primitiva de 1.

Lema 9.1 Sea ω una raíz primitiva n -ésima de la unidad y k un número entero. Entonces

$$\sum_{j=0}^{n-1} \omega^{jk} = \begin{cases} n & \text{si } k/n \text{ es un entero,} \\ 0 & \text{en cualquier otro caso.} \end{cases}$$

Es fácil ver que, para una n cualquiera, el número complejo $\omega_n = e^{-i2\pi/n}$ es una raíz n -ésima primitiva de la unidad (también lo es $\omega_n = e^{i2\pi/n}$). En la figura 9.4 se ve la raíz cuarta primitiva de la unidad, $\omega_4 = e^{-i2\pi/4}$, y las otras tres. Son, en general, las potencias ω_4^k , $k = 0, 1, 2, 3$. Las ω_n^k se denominan también *factores twiddle*. Se puede verificar que la raíz n -ésima de la unidad, $\omega = e^{-i2\pi/n}$, con $n > 1$, cumple que

$$1 + \omega + \omega^2 + \omega^3 + \dots + \omega^{n-1} = 0,$$




Figura 9.4: Raíz cuarta primitiva de la unidad $\omega_4 = e^{-i2\pi/4}$ y las otras tres. Números de Moivre de $n = 8$

$$\begin{aligned}
 1 + \omega^2 + \omega^4 + \omega^6 + \cdots + \omega^{2(n-1)} &= 0, \\
 1 + \omega^3 + \omega^6 + \omega^9 + \cdots + \omega^{3(n-1)} &= 0, \\
 &\vdots \\
 1 + \omega^{n-1} + \omega^{(n-1)2} + \omega^{(n-1)3} + \cdots + \omega^{(n-1)(n-1)} &= 0.
 \end{aligned}$$

También que $1 + \omega^n + \omega^{2n} + \omega^{3n} + \cdots + \omega^{n(n-1)} = 1 + 1 + 1 + 1 + \cdots + 1 = n$. Además, si k es un número entero,

$$\sum_{j=0}^{n-1} \omega^{jk} = \begin{cases} n & \text{si } k/n \text{ es entero,} \\ 0 & \text{en otro caso.} \end{cases}$$

9.1 Integración. Teorema de Cauchy

Las funciones de números reales se integran en intervalos. Las de números complejos en o sobre curvas y tienen muchas de sus propiedades en común con las integrales de línea de los campos vectoriales

El teorema de Cauchy es una de las piezas esenciales de la teoría de integración de las funciones de números complejos.

Si hay una curva continua, simple y cerrada en el plano, γ , la misma separa a ese plano en tres partes: la curva en sí misma, una zona denominada *interior* de γ , que no es sino una región abierta y acotada por la propia curva, y la zona exterior a γ , que es una región o conjunto no acotada —ver figura 9.5—.




Figura 9.5: Interior y exterior de una curva

Nos referiremos en lo que sigue a una curva simple, continua por tramos, como *camino* o ruta. Un camino en un conjunto S es un camino cuya trayectoria y gráfica queda enteramente dentro de S .

Un conjunto de números complejos está *conectado* si cualesquiera dos puntos de S son principio y final de un camino de S . En términos más coloquiales esto quiere decir que desde cualquier punto de S podemos llegar a cualquier otro, también de S , moviéndonos a través de algún camino sin abandonar S . Un conjunto abierto y conectado se denomina *dominio*. Por ejemplo, el cuadrante del plano $x > 0$, $y > 0$.

Un conjunto S de números complejos es *simplemente conexo* si cualquier camino cerrado en S encierra dentro de él puntos de S .

Teorema 9.2 *Teorema integral de Cauchy. Si la función f es derivable en un dominio simplemente conexo G , entonces*

$$\oint_{\gamma} f(z) dz = 0$$

para todo camino cerrado γ de G .

Este teorema quiere decir que $\oint_{\gamma} f(z) dz = 0$ si f es derivable en el camino γ y en todos los puntos que encierra γ . Las curvas o caminos se suponen orientados en el

sentido contrario a las agujas del reloj.

Édouard Goursat —Francia, 1858-1936—



demostró que el teorema es válido igualmente aunque dentro de G haya un número finitos de puntos que aun siendo derivables su derivada no es continua, como se exigía previamente. El teorema se conoce en la actualidad como de Cauchy-Goursat.

10 | Análisis de Fourier

LAS series y polinomios de Taylor permiten aproximar funciones mediante polinomios, o hallan una serie de potencias que converja a una determinada función.

El análisis de Fourier va en esa misma línea de intenciones, pero aproximando la función mediante combinaciones de funciones seno y coseno adecuadamente elegidas. Lo que sigue sale básicamente de Villanueva [2016] y Contreras [2016].

En muchas ramas de la ingeniería y de la ciencia —análisis de circuitos, tratamiento digital de señales, compresión de imágenes y archivos digitales, etc.— las funciones que se analizan son periódicas (o van moduladas sobre funciones periódicas), es decir, existe un *período* $T > 0$ tal que

$$f(t + T) = f(t + nT) = f(t) \quad \text{para cualquier } t \in \mathbb{R} \text{ y } n \in \mathbb{Z}.$$

Conocido el valor que adopta la función en un intervalo de longitud T , por ejemplo el $[0, T]$, o $[-\frac{T}{2}, \frac{T}{2}]$, se conoce en todo $\mathbb{R}$.

Ejemplos típicos de funciones periódicas son las funciones trigonométricas $\sin(t)$ y $\cos(t)$, que son periódicas con período 2π . Las funciones $\sin(2t)$ y $\cos(2t)$ también tienen período 2π . En general, para $w_0 > 0$ y $n \in \mathbb{N}$, las funciones $\sin(nw_0 t)$ y $\cos(nw_0 t)$ son periódicas de período

$$T = \frac{2\pi}{nw_0}.$$

Para medir la velocidad de repetición de una función con período T se utiliza la *frecuencia*, a veces denominada *frecuencia angular*, definida por

$$\text{frecuencia} = \frac{2\pi}{\text{período}} = \frac{2\pi}{T},$$

que se mide en radianes por segundo (en algunos textos la palabra frecuencia se reserva para la inversa del período, $1/T$, y se mide en ciclos por segundo o hertzios).

Definición 10.1 Un **polinomio trigonométrico** con período T y frecuencia $w_0 = 2\pi/T$ es una función de la forma

$$f(t) = \frac{1}{2}a_0 + \sum_{n=1}^{n_0} [a_n \cos(nw_0 t) + b_n \sin(nw_0 t)].$$

Es decir, una combinación lineal de senos y cosenos que tienen un período común T . Los coeficientes a_0 , a_n y b_n se denominan **coeficientes de Fourier** del polinomio, w_0 es la **frecuencia fundamental** y el índice n_0 , el **grado del polinomio**.

10.1 Series de Fourier

Jean Baptiste Joseph Fourier, Francia, 1768-1830,



fue pionero en el análisis de funciones periódicas para describir fenómenos físicos. Nacido en Auxerre y profesor de la École Polytechnique, en 1807 formuló la ecuación de difusión del calor mediante ecuaciones matemáticas. Concretamente, la ecuación en derivadas parciales (parabólica):

$$\frac{\partial u}{\partial t} = \frac{1}{2} \frac{\partial^2 u}{\partial x^2} \quad \text{o} \quad u_t = Du_{xx}.$$

La constante $D > 0$ se denomina *coeficiente de difusión* y representa la difusividad térmica del material del cuerpo que se estudia.

Para resolver el problema de la distribución de temperaturas en el cuerpo a partir de la distribución en un instante inicial necesitaba escribir la función que da el dato inicial como suma de una serie trigonométrica. Este es el aspecto de sus múltiples contribuciones al conocimiento científico que vamos a considerar aquí brevemente.

Aunque se presenta de varias maneras según el tipo de problema estudiado, en general, para una función de periodo T , el problema consiste en, dada una función $f(x)$, encontrar una *serie trigonométrica de Fourier*

$$\frac{a_0}{2} + \sum_{n=1}^{\infty} [a_n \cos(nw_0x) + b_n \operatorname{sen}(nw_0x)],$$

donde $w_0 = \frac{2\pi}{T}$, que converja a aproximar a $f(x)$ en cada punto x . Para todo $w_0 > 0$ las funciones $\operatorname{sen}(w_0x)$ y $\cos(w_0x)$ son periódicas de periodo $T = \frac{2\pi}{w_0}$. Si conocemos una función en un intervalo de longitud T conocemos su valor en todo $\mathbb{R}$.

Para determinar adecuadamente esa serie, lo primero es obtener los coeficientes a_n y b_n . Para ello hay que usar de nuevo la noción de *ortogonalidad* y el ángulo entre vectores. Recordemos que dos vectores del espacio euclídeo n -dimensional son ortogonales si se cruzan formando un ángulo de 90 grados. Es decir, si su producto interior $\langle \cdot | \cdot \rangle$ es cero: $f \perp g$ y $\langle f | g \rangle = 0$. La ortogonalidad y las bases ortogonales de espacios vectoriales son el fundamento de múltiples técnicas numéricas, estadísticas y científicas a las que nos referimos en este libro.

Para construir el razonamiento necesitamos introducir un producto interior (escalar) que sea conveniente para espacios de funciones de dimensión infinita. Con ese objetivo

utilizaremos el del espacio de Lebesgue $L^2(I)$, concreta el que define

$$\langle f | g \rangle = \frac{1}{2} \int_I f(x)g(x) dx$$

de funciones integrables en el intervalo I . La norma asociada a partir de ese producto interior es

$$\|f\| = \sqrt{\langle f | f \rangle} = \sqrt{\frac{1}{\pi} \int_I f(x)^2 dx}.$$

Lema 10.1 Con el producto interior (escalar) de L^2 definido por

$$\langle f | g \rangle = \frac{1}{2} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x)g(x) dx$$

la familia de funciones trigonométricas

$$\{1, \sin(nw_0x), \cos(mw_0x); n, m \in \mathbb{N}\}$$

satisface las relaciones de ortogonalidad

$$\begin{aligned} \langle \cos(kw_0x) | \cos(lw_0x) \rangle &= \langle \sin(kw_0x) | \sin(lw_0x) \rangle = 0 && \text{para } k \neq l \\ \langle \cos(kw_0x) | \sin(lw_0x) \rangle &= 0 && \text{para todo } k, l \\ \|\mathbf{1}\| = \sqrt{2}, \quad \|\cos(kw_0x)\| &= \|\sin(kw_0x)\| = 1 && \text{para } k \neq 0, \end{aligned}$$

por lo que esa familia es ortogonal sobre $[-\frac{T}{2}, \frac{T}{2}]$, con $T = \frac{2\pi}{w_0}$ y para $k, l \geq 0$.

Demostración. Las fórmulas de las relaciones se obtienen inmediatamente de estas integrales:

$$\begin{aligned} \int_{-\frac{T}{2}}^{\frac{T}{2}} \cos(kw_0x) \cos(lw_0x) dx &= \begin{cases} 0, & k \neq l \\ 2\pi, & k = l = 0 \\ \pi, & k = l \neq 0, \end{cases} \\ \int_{-\frac{T}{2}}^{\frac{T}{2}} \sin(kw_0x) \sin(lw_0x) dx &= \begin{cases} 0, & k \neq l \\ \pi, & k = l \neq 0, \end{cases} \\ \int_{-\frac{T}{2}}^{\frac{T}{2}} \cos(kw_0x) \sin(lw_0x) dx &= 0 \end{aligned}$$

que son válidas para todos los enteros $k, l \geq 0$. □

Si de momento dejamos a un lado los asuntos de convergencia, estas relaciones de ortogonalidad permiten el cálculo de los coeficientes de Fourier. En efecto, tomando el

producto interior por $\cos(lw_0x)$, $l > 0$, en los dos términos de la ecuación $f(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} [a_n \cos(nw_0x) + b_n \sin(nw_0x)]$ se tiene que

$$\begin{aligned}\langle f | \cos(lw_0x) \rangle &= \frac{a_0}{2} \langle 1 | \cos(lw_0x) \rangle + \\ &+ \sum_{n=1}^{\infty} [a_n \langle \cos(nw_0x) | \cos(lw_0x) \rangle + b_n \langle \sin(nw_0x) | \cos(lw_0x) \rangle] \\ &= a_l \langle \cos(lw_0x) | \cos(lw_0x) \rangle = a_l,\end{aligned}$$

obteniéndose así el coeficiente a_l . De la misma manera, operando con $\sin(lw_0x)$ se obtiene el coeficiente b_l . Tomando el producto interior en la misma ecuación por la función constante 1 se tiene que

$$\begin{aligned}\langle f | 1 \rangle &= \frac{a_0}{2} \langle 1 | 1 \rangle + \sum_{n=1}^{\infty} [a_n \langle \cos(nw_0x) | 1 \rangle + b_n \langle \sin(nw_0x) | 1 \rangle] \\ &= \frac{a_0}{2} \|1\|^2 = a_0.\end{aligned}$$

Esta expresión de a_0 explica también el por qué de introducir en la formulación de la serie el sumando a_0 dividido por 2.

En consecuencia, si la serie de Fourier converge a la función $f(x)$, los coeficientes de la misma resultan de tomar productos interiores con las funciones trigonométricas básicas; es decir, son

$$\begin{aligned}a_0 &= \frac{2}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) dx \\ a_k &= \langle f | \cos(lw_0x) \rangle = \frac{2}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) \cos(kw_0x) dx, \quad k = 0, 1, 2, \dots \\ b_k &= \langle f | \sin(lw_0x) \rangle = \frac{2}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) \sin(kw_0x) dx, \quad k = 1, 2, 3, \dots\end{aligned}$$

Las integrales deben estar bien definidas y ser finitas. Queda por demostrar que existe convergencia hacia $f(x)$.

Ejemplo 10.1 Consideremos la función $f(x) = x$ en $[-\frac{\pi}{2}, \frac{\pi}{2}]$. Calculemos los coeficientes de Fourier de su aproximación por series trigonométricas:

$$\begin{aligned}a_0 &= \frac{2}{\pi} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} x dx = 0 \\ a_k &= \frac{2}{\pi} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} x \cos(kw_0x) dx = \frac{2}{\pi} \left[\frac{x \sin(kw_0x)}{k} + \frac{\cos(kw_0x)}{k^2} \right]_{x=-\frac{\pi}{2}}^{\frac{\pi}{2}} = 0\end{aligned}$$

$$\begin{aligned}
 b_k &= \frac{2}{\pi} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} x \operatorname{sen}(k w_0 x) dx = \frac{2}{\pi} \left[-\frac{x \cos(k w_0 x)}{k} + \frac{\operatorname{sen}(k w_0 x)}{k^2} \right]_{x=-\frac{\pi}{2}}^{\frac{\pi}{2}} = \\
 &= \frac{2}{k} (-1)^{k+1}.
 \end{aligned}$$

La serie de Fourier es pues

$$f(x) \sim 2 \left(\operatorname{sen} x - \frac{\operatorname{sen} 2x}{2} + \frac{\operatorname{sen} 3x}{3} - \frac{\operatorname{sen} 4x}{4} + \dots \right).$$

Demostrar que es convergente (que lo es) dista mucho de ser evidente y más de ser trivial el hacerlo. ●

Ejemplo 10.2 Otro ejemplo interesante para la aplicabilidad de las series de Fourier lo constituye la función “escalón” definida así:

$$f(x) = \begin{cases} 0, & -\pi < x < 0, \\ h, & 0 < x < \pi. \end{cases}$$

El coeficiente $a_0 = h$ dado que el valor medio de $f(x)$ en el intervalo completo es $h/2$. Los demás coeficientes son

$$a_n = \frac{1}{\pi} \int_0^{+\pi} h \cos nx dx = 0$$

y

$$b_n = \frac{1}{\pi} \int_0^{+\pi} h \operatorname{sen} nx dx = \frac{h}{n\pi} (1 - \cos n\pi),$$

que simplificando es

$$b_n = \begin{cases} \frac{2h}{n\pi}, & \text{si } n \text{ es impar,} \\ 0, & \text{si } n \text{ es par.} \end{cases}$$

La serie de Fourier es pues

$$f(x) \sim \frac{h}{2} + \frac{2h}{\pi} \left(\operatorname{sen} x + \frac{\operatorname{sen} 3x}{3} + \frac{\operatorname{sen} 5x}{5} + \dots \right).$$

En la figura 10.1 se presenta esta función y los cuatro primeros términos de la serie de Fourier, lo que esboza el denominado fenómeno de Gibbs. ●

10.1.1 Expresión compleja de la serie de Fourier

Recordemos la expresión

$$e^{i\theta} = \cos \theta + i \operatorname{sen} \theta.$$




Figura 10.1: Cuatro primeros términos de la serie de Fourier de la función escalón, con $h = 1$, y fenómeno de Gibbs

De la misma se derivan

$$\cos \theta = \frac{e^{i\theta} + e^{-i\theta}}{2} \quad \text{y} \quad \sin \theta = \frac{e^{i\theta} - e^{-i\theta}}{2i}.$$

Si $f(t)$ es una función periódica de período T con desarrollo en serie de Fourier

$$f(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} a_n \cos(nw_0 t) + \sum_{n=1}^{\infty} b_n \sin(nw_0 t),$$

sustituyendo los senos y cosenos por la expresiones anteriores se tiene que

$$f(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty} a_n \frac{e^{inw_0 t} + e^{-inw_0 t}}{2} + \sum_{n=1}^{\infty} b_n \frac{e^{inw_0 t} - e^{-inw_0 t}}{2i}.$$

Reordenando un poco

$$f(t) = c_0 + \sum_{n=1}^{\infty} c_n e^{inw_0 t} + \sum_{n=-1}^{-\infty} c_n e^{inw_0 t} = \sum_{n=-\infty}^{+\infty} c_n e^{inw_0 t},$$

donde $c_0 = a_0/2$, $c_n = (a_n - i b_n)/2$ y $c_{-n} = (a_n + i b_n)/2$

Como en el caso de funciones reales definimos ahora un producto escalar de funciones complejas $f, g : I \subset \mathbb{R} \rightarrow \mathbb{C}$ como

$$\langle f | g \rangle = \int_I f(t) \overline{g(t)} dt$$

donde $\bar{z}$ denota el complejo conjugado de z .

Las funciones f y g son ortogonales si su producto escalar (interior) es 0. La norma 2 de una función compleja $f : I \rightarrow \mathbb{C}$ es

$$\|f\|_2 = \sqrt{\langle f | f \rangle} = \left(\int_I f(t) \overline{f(t)} dt \right)^{\frac{1}{2}}.$$

Proposición 10.2 La familia $\{e^{inw_0 t}\}_{n \in \mathbb{Z}}$ es ortogonal en el intervalo $[-\frac{T}{2}, \frac{T}{2}]$ (o en $[0, T]$), donde $T = \frac{2\pi}{w_0}$.

Demostración. Sea $n \neq m$. Entonces

$$\begin{aligned} \langle e^{inw_0 t} | e^{imw_0 t} \rangle &= \int_{-\frac{T}{2}}^{\frac{T}{2}} e^{inw_0 t} \overline{e^{imw_0 t}} dt = \int_{-\frac{T}{2}}^{\frac{T}{2}} e^{inw_0 t} e^{-imw_0 t} dt = \\ &= \int_{-\frac{T}{2}}^{\frac{T}{2}} (\cos nw_0 t + i \sin nw_0 t)(\cos mw_0 t - i \sin mw_0 t) dt = 0. \end{aligned}$$

□

Con este resultado podemos calcular los coeficientes c_n para representar una función $f : [-\frac{T}{2}, \frac{T}{2}] \rightarrow \mathbb{C}$ de la forma

$$f(t) = \sum_{n=-\infty}^{+\infty} c_n e^{inw_0 t}.$$

Son

$$c_n = \frac{\int_{-\frac{T}{2}}^{\frac{T}{2}} f(t) \overline{e^{inw_0 t}} dt}{T}.$$

Muchas señales se representan de manera natural como una función con valores reales —por ejemplo una señal sonora— mientras que otras, en particular los campos electromagnéticos, se representan como una función de valores complejos.

10.1.2 Convergencia de las series de Fourier

A falta de demostraciones sobre sus resultados, lo que Fourier legó fue un problema en el que estaban implicados los conceptos de función integral, suma de series y tipo de convergencia. La influencia de este problema en el desarrollo posterior de conceptos de análisis matemático ha sido muy importante.

Los intentos de probar la convergencia de la serie de Fourier aparecieron pronto. Poisson y Cauchy publicaron sendas pruebas incorrectas. Fue Dirichlet en 1829 el que publicó el primer resultado correcto.

Definición 10.2 Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función periódica de período T . Se dice que f satisface las **condiciones de Dirichlet** si en cada período la función $f : [0, T] \rightarrow \mathbb{R}$ es continua salvo un número finito de discontinuidades de salto y sólo tiene una cantidad finita de máximos y mínimos locales estrictos.

Prácticamente todas las funciones —señales— de interés en las aplicaciones cotidianas verifican las condiciones de Dirichlet.


Teorema 10.3 *Convergencia de Dirichlet de la serie de Fourier.* Sea $f : I \rightarrow \mathbb{R}$ una función periódica de período T que satisface las condiciones de Dirichlet. La serie de Fourier de f converge a $f(t_0)$ en todo $t_0 \in I$ en el que f sea continua. En los puntos $t_0 \in I$ en los que f no sea continua se tiene que la serie de Fourier converge al punto medio del salto,

$$\frac{f(t_0^+) + f(t_0^-)}{2},$$

donde $f(t_0^+) = \lim_{t \rightarrow t_0^+} f(t)$ y $f(t_0^-) = \lim_{t \rightarrow t_0^-} f(t)$.

El teorema de Dirichlet nos dice que, en los puntos de discontinuidad, la gráfica de la suma de la serie de Fourier pasa por el punto medio del salto. Si se dibujan las sumas parciales se ve que en las cercanías de los puntos de discontinuidad se reduce la velocidad de convergencia de la serie y que la gráfica de la suma parcial oscila alrededor de la gráfica de la función. Cuando se aumenta el número de términos, las oscilaciones se condensan a ambos lados del punto pero su amplitud no parece decrecer.

Esto se conoce como el *fenómeno de Gibbs* —Josiah Willard Gibbs, EE.UU. 1839-1903—,



quien lo analizó en 1899. Este fenómeno ocurre en las proximidades de una discontinuidad importante de la señal. Apunta a que no importa cuántos términos de la serie de Fourier se incluyan, siempre se producirá un error o salto en esa discontinuidad. Ese salto es un porcentaje adicional al valor de la señal en ese punto. La amplitud de la oscilación a cada lado de la gráfica de la función tiende a ser $\frac{1}{2\pi} \int_0^\pi \frac{\sin t}{t} dt - 1 \approx 0,0895$ veces el tamaño del salto: en torno al 9 % de ese salto. Consideramos la función *onda cuadrada* de período 2π definida en $[-\pi, \pi]$ por

$$f(t) = \begin{cases} -1 & \text{si } -\pi < t < 0, \\ 1 & \text{si } 0 < t < \pi \end{cases}$$

y extendida periódicamente a $\mathbb{R}$. Su serie de Fourier es

$$\frac{4}{\pi} \left(\sin t + \frac{\sin 3t}{3} + \frac{\sin 5t}{5} + \frac{\sin 7t}{7} + \frac{\sin 9t}{9} + \dots \right).$$

En la figura 10.2 se ilustra esta señal de onda cuadrada y cómo las series de Fourier se ajustan bien en todos los puntos pero es muy perceptible el salto aludido. En la figura “max n=9” quiere decir que se han incluido los términos $n = 1, 3, 5, 7$ y 9 en la serie de Fourier.

Para la convergencia en norma 2 consideramos este resultado.

Teorema 10.4 *Teorema de la mejor aproximación y convergencia en media cuadrática de la serie de Fourier. Sea $f : I \rightarrow \mathbb{R}$ una función periódica de período T que satisface las condiciones de Dirichlet. Sea la serie de Fourier de f*

$$f(t) \sim \frac{1}{2}a_0 + \sum_{n=1}^{\infty} [a_n \cos(nw_0t) + b_n \sin(nw_0t)] = \sum_{n=-\infty}^{\infty} c_n e^{inw_0t}$$

y el polinomio trigonométrico obtenido como la suma m -ésima de dicha serie:

$$f_m(t) = \frac{1}{2}a_0 + \sum_{n=1}^m [a_n \cos(nw_0t) + b_n \sin(nw_0t)] = \sum_{n=-m}^m c_n e^{inw_0t}.$$

Entonces f_m es, de todos los polinomios trigonométricos de grado m y período T , el que mejor se aproxima a f en media cuadrática. Es decir, si g_m es un polinomio trigonométrico de grado m distinto de f_m , entonces

$$\int_{-\frac{T}{2}}^{\frac{T}{2}} |f(t) - f_m(t)|^2 dt < \int_{-\frac{T}{2}}^{\frac{T}{2}} |f(t) - g_m(t)|^2 dt$$

y, además, $\lim_{m \rightarrow \infty} \int_{-\frac{T}{2}}^{\frac{T}{2}} |f(t) - f_m(t)|^2 dt = 0$.

10.1.3 Propiedades de las series de Fourier

En lo que sigue se supone que f y g son funciones periódicas de período T (reales o complejas) que verifican las condiciones de Dirichlet y cuyos desarrollos o series de Fourier son, respectivamente,

$$f(t) = \sum_{n=-\infty}^{\infty} c_n e^{inw_0t} \quad \text{y} \quad g(t) = \sum_{n=-\infty}^{\infty} d_n e^{inw_0t},$$

siendo $w_0 = 2\pi/T$.




Figura 10.2: Fenómeno de Gibbs en la onda cuadrada

10.1.3.1 Linealidad

Si p y q son números complejos, entonces la serie de Fourier de $pf(t) + qg(t)$ es

$$pf(t) + qg(t) = \sum_{n=-\infty}^{\infty} (pc_n + qd_n)e^{inw_0t}.$$

10.1.3.2 Traslación en el tiempo

Si t_0 es un número real, entonces la serie de Fourier de la función trasladada $f(t - t_0)$ es

$$f(t - t_0) = \sum_{n=-\infty}^{\infty} c_n e^{-inw_0t} e^{inw_0t} = \sum_{n=-\infty}^{\infty} c_n e^{inw_0(t-t_0)}.$$

10.1.3.3 Escalado en el tiempo

Si p es un número real, entonces función $f(pt)$ es periódica de período T/p y frecuencia pw_0 . Su serie de Fourier es

$$f(pt) = \sum_{n=-\infty}^{\infty} c_n e^{in(pw_0)t}.$$

Es decir, $f(t)$ y $f(pt)$ tienen las mismas amplitudes y fases pero correspondientes a frecuencias distintas.

10.1.3.4 Derivación

La regla de la cadena muestra que la derivada de una función periódica es periódica y tiene el mismo período. Si f es una función continua y periódica de período T y su derivada f' verifica las condiciones de Dirichlet, entonces, la serie de Fourier de f puede derivarse término a término de manera que si

$$f(t) = \frac{1}{2}a_0 + \sum_{n=1}^{\infty} [a_n \cos(nw_0t) + b_n \sin(nw_0t)],$$

entonces

$$f'(t) \cong \sum_{n=1}^{\infty} [nb_n w_0 \cos(nw_0t) - na_n w_0 \sin(nw_0t)]$$

para cada $t \in \mathbb{R}$.

10.1.3.5 Integración

A diferencia de la derivación, la integral de una función no necesariamente vuelve a ser periódica. Sea f una función periódica con período T y consideremos la función $F(t) = \int_{t_0}^t f(\tau) d\tau$. La función F es T -periódica si y sólo si $a_0 = 2/T \int_0^T f(t) dt = 0$. En caso contrario, se tiene que la función $\int_{t_0}^t f(\tau) d\tau - 1/2a_0(t - t_0)$ es T -periódica. Si la función f verifica las condiciones de Dirichlet, entonces la serie de Fourier de f puede integrarse término a término de manera que si

$$f(t) = \frac{1}{2}a_0 + \sum_{n=1}^{\infty} [a_n \cos(nw_0t) + b_n \sin(nw_0t)]$$

y $t_0, t \in [-T/2, T/2]$, entonces

$$\begin{aligned} & \int_{t_0}^t f(\tau) d\tau - 1/2a_0(t - t_0) = \\ &= \sum_{n=1}^{\infty} \left[\frac{b_n(\cos(nw_0t_0) - \cos(nw_0t))}{nw_0} + \frac{a_n(\sin(nw_0t) - \sin(nw_0t_0))}{nw_0} \right]. \end{aligned}$$

10.1.3.6 Convolución

Los coeficientes complejos de Fourier de la *convolución* $f(t)g(t) = \sum_{n=-\infty}^{\infty} h_n e^{inw_0 t}$ son

$$h_n = \sum_{k=-\infty}^{\infty} c_k d_{n-k} = \sum_{k=-\infty}^{\infty} c_{n-k} d_k.$$

10.1.3.7 Multiplicación

Se verifica que

$$\frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(t)g(t) dt = \sum_{n=-\infty}^{\infty} c_n \overline{d_n}.$$

10.1.3.8 Igualdad de Parseval

Un resultado muy interesante en análisis de Fourier es el Teorema de Parseval, por Marc-Antoine Parseval des Chênes, Francia 1755-1836.



Físicamente se puede leer como que la energía de una señal periódica es igual a la suma de las energías de sus componentes. Geométricamente se puede interpretar como una consecuencia de una versión infinito dimensional del Teorema de Pitágoras.

Proposición 10.5 Sean $f_1, f_2 \in L^2([-\frac{T}{2}, \frac{T}{2}])$ y $(c_n^1)_{n \in \mathbb{Z}}, (c_n^2)_{n \in \mathbb{Z}}$ sus respectivos coeficientes de Fourier. Entonces

$$\frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f_1(t) \overline{f_2(t)} dt = \sum_{n \in \mathbb{Z}} c_n^1 \overline{c_n^2}.$$

Teorema 10.6 Teorema de Parseval. Sean $f \in L^2([-\frac{T}{2}, \frac{T}{2}])$ y (c_n^1) sus coeficientes de Fourier. Entonces

$$\frac{1}{T} (\|f\|_2)^2 = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(t) \overline{f(t)} dt = \sum_{n \in \mathbb{Z}} |c_n|^2.$$

Cuando $f(t)$ es una señal periódica de período fundamental T , la igualdad de Parseval puede interpretarse de la siguiente manera

$$P = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} |f(t)|^2 dt.$$

Esta integral se denomina *media cuadrática* o *potencia media* de f . Por ejemplo, si $f(t)$ representa la tensión en voltios que se aplica a una resistencia de 1 ohmio, entonces la potencia media de f coincide con la potencia eléctrica media (energía por unidad de tiempo medida en vatios) disipada por la resistencia en cada período. Ahora bien, la potencia media de cada uno de los armónicos presentes en la señal es

$$P_0 = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} [a_0/2]^2 dt = \frac{1}{4} a_0^2,$$

$$P_n = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} [a_n \cos(nw_0 t) + b_n \sin(nw_0 t)]^2 dt = \frac{1}{2} b_n^2 = 2|c_n|^2,$$

para $n = 1, 2, \dots$. La igualdad de Parseval nos dice que la potencia media de la señal es la suma de las potencias medias de sus componentes armónicos, $P = \sum_{n=0}^{\infty} P_n = \sum_{n=-\infty}^{\infty} |c_n|^2$. Por eso, la representación de los valores $|c_n|^2$ cuando situamos las frecuencias en el eje de abscisas se llama *espectro discreto de potencias*.

10.2 La Transformada de Fourier

Lo visto hasta ahora sobre análisis de Fourier se aplicaba al estudio de funciones periódicas, o funciones definidas en un intervalo $[a, b]$. Para ciertas aplicaciones esto no es suficiente y necesitamos estudiar funciones $f : \mathbb{R} \rightarrow \mathbb{R}$ ó $\mathbb{C}$ no periódicas. Este tipo de funciones no puede ser representado por medio de una serie de Fourier, pero sí por medio de una *integral de Fourier*. Un ejemplo típico es la función $f : \mathbb{R} \rightarrow \mathbb{R}$ dada por

$$f(t) = \begin{cases} 1 & \text{si } t \in [-\frac{1}{2}, \frac{1}{2}] \\ 0 & \text{si } |t| > \frac{1}{2}. \end{cases}$$

La idea, más o menos intuitiva, que utilizó Fourier fue considerar una función no periódica como una función periódica de período infinito, lo que le llevó a representarla no como una serie cuyos términos corresponden a múltiplos de la frecuencia fundamental $0, w, 2w, 3w, \dots$, sino como una integral cuya variable de integración es una frecuencia que se mueve de manera continua.

Cuando hablábamos del espectro de una función periódica, representada por una serie de Fourier $\sum_n c_n e^{inw_0 t}$, con la frecuencia fundamental $w_0 = 2\pi/T$, apuntábamos que los coeficientes c_n podían ser entendidos como una función $c(w) : \mathbb{R} \rightarrow \mathbb{C}(\mathbb{R})$ que toma valores distintos de 0 sólo en los puntos $w = nw_0$, con $n \in \mathbb{Z}$, en los que vale c_n .

Al hacer tender el período T a infinito, la frecuencia fundamental, w_0 , tiende a 0, por lo que los puntos nw_0 —los *armónicos*— están cada vez más próximos. Parece razonable pensar que en el límite el espectro se hace continuo, por lo que podemos definir $c(w)$ para todo w . Las amplitudes $c_n = c(nw_0)$ tenderán también a 0.

Concretando, sea $f(t)$ una función periódica de período T . Su serie de Fourier es

$$f(t) = \sum_{n=-\infty}^{\infty} c_n e^{inw_0 t},$$

donde

$$c_n = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(t) e^{-inw_0 t} dt \quad y \quad w_0 = \frac{2\pi}{T}.$$

Sustituyendo estas dos expresiones en la serie

$$\begin{aligned} f(t) &= \sum_{n=-\infty}^{\infty} \left(\frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) e^{-inw_0 x} dx \right) e^{inw_0 t} = \\ &= \sum_{n=-\infty}^{\infty} \left(\frac{1}{2\pi} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) e^{-inw_0 x} dx \right) w_0 e^{inw_0 t}. \end{aligned}$$

Recordando la definición de integral de Riemann y el paso de las sumas de Riemann a la integral, si tenemos una función $h : [a, b] \rightarrow \mathbb{R}$ integrable y suponemos elegida una partición equiespaciada $P(w_0) = \{a = x_0, x_1, \dots, x_k = b\}$ de $[a, b]$ en la que $x_i - x_{i-1} = w_0$ para cada $i \in \{1, \dots, k\}$, tenemos que

$$\lim_{w_0 \rightarrow 0} \sum_{n=1}^k h(a + nw_0) w_0 = \int_a^b h(t) dt.$$

Con esto en la memoria y volviendo a la última expresión de $f(t)$, llamemos

$$h(w) = \left(\frac{1}{2\pi} \int_{-\frac{T}{2}}^{\frac{T}{2}} f(x) e^{-iwx} dx \right) e^{iwt}.$$

Haciendo el paso a una integral impropia tenemos que, cuando w_0 tiende a 0 —o cuando T tiende a infinito—

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \left(\int_{-\infty}^{+\infty} f(x) e^{-iwx} dx \right) e^{iwt} dw.$$

Si se define la *transformada de Fourier* $\mathbf{F}(w)$ de f como

$$\mathbf{F}(w) = \int_{-\infty}^{+\infty} f(t) e^{-iwx} dt,$$

entonces

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathbf{F}(w) e^{iwx} dt.$$

Definición 10.3 Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ (ó $\mathbb{C}$). Su **transformada integral de Fourier** es una función

$$\mathcal{F}(f) = \mathbf{F} : \mathbb{R} \rightarrow \mathbb{C}$$

dada por

$$\mathcal{F}(f)(w) = \mathbf{F}(w) = \int_{-\infty}^{\infty} f(t) e^{-iwt} dt.$$

Definición 10.4 Sea $\mathbf{F} : \mathbb{R} \rightarrow \mathbb{C}$. Su **transformada inversa de Fourier** es una función

$$\mathcal{F}^{-1}(\mathbf{F}) : \mathbb{R} \rightarrow \mathbb{R} \text{ (ó } \mathbb{C} \text{)}$$

dada por

$$\mathcal{F}^{-1}(\mathbf{F})(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathbf{F}(w) e^{iwt} dt.$$

10.2.1 Propiedades de la transformada de Fourier

Las que siguen son algunas de sus propiedades y resultados más interesantes. En cualquier caso, hay que tener en cuenta que la transformada de Fourier viene definida por una integral impropia que puede ser convergente o no serlo.

Teorema 10.7 Sea $f \in L^2(\mathbb{R})$. Entonces existe la transformada de Fourier de f y es una función $\mathbf{F} : \mathbb{R} \rightarrow \mathbb{C}$.

La condición $f \in L^2(\mathbb{R})$ es suficiente pero no necesaria para la existencia de la transformada $\mathbf{F}$. Algunas propiedades básicas de la transformada de Fourier son las que siguen:

10.2.1.1 Linealidad

Si $f, g \in L^2(\mathbb{R})$ y $\alpha, \beta \in \mathbb{R}$, entonces $\mathcal{F}(\alpha f + \beta g) = \alpha \mathcal{F}(f) + \beta \mathcal{F}(g)$.

10.2.1.2 Escalado en el dominio del tiempo

Si $0 \neq \alpha \in \mathbb{R}$, $f \in L^2(\mathbb{R})$ y $g(t) = f(\alpha t)$ entonces

$$\mathcal{F}(g)(w) = \frac{1}{|\alpha|} \mathcal{F}(f)\left(\frac{w}{\alpha}\right).$$

10.2.1.3 Desplazamiento en el dominio de la frecuencia

Si $g(t) = f(t)e^{i\alpha t}$ entonces $\mathcal{F}(g)(w) = \mathcal{F}(f)(w - \alpha)$.

10.2.1.4 Desplazamiento en el dominio del tiempo

Si $f \in L^2(\mathbb{R})$, $t_0 \in \mathbb{R}$ y $g(t) = f(t - t_0)$ entonces $\mathcal{F}(g)(w) = \mathcal{F}(f)(w)e^{-iw t_0}$.

Los dos resultados que siguen son interesantes para la resolución de ecuaciones diferenciales pues garantizan el buen comportamiento de la transformada de Fourier.

Proposición 10.8 Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función derivable que admite transformada de Fourier $\mathcal{F}(f)$ y tal que $\lim_{t \rightarrow \pm\infty} f(t) = 0$ (esta condición se verifica siempre que $f \in L^2(\mathbb{R})$). Entonces $\mathcal{F}(f')(w) = iw\mathcal{F}(f)(w)$.

Teorema 10.9 Si $f \in L^2(\mathbb{R})$ entonces $\mathcal{F}(f)$ es continua y

$$\lim_{w \rightarrow \pm\infty} \mathcal{F}(f)(w) = 0.$$

Aunque $f \in L^2(\mathbb{R})$ puede no ser continua, su transformada siempre lo es. El hecho de que

$$\lim_{w \rightarrow \pm\infty} \mathcal{F}(f)(w) = 0$$

indica que, para cualquier señal, la amplitud de sus componentes en frecuencia tiende a 0 cuando la frecuencia tiende a infinito.

Teorema 10.10 Inversión. Si $f \in L^2(\mathbb{R})$ entonces $\mathcal{F}(f) \in L^2(\mathbb{R})$ y además la función

$$g(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \mathcal{F}(f)(w)e^{iwt} dw,$$

la transformada inversa de la transformada de f , verifica que $f(t) = g(t)$ en casi todo punto.

La expresión “en casi todo punto” tiene un significado matemático muy preciso. Quiere decir que $f(t) = g(t)$ excepto en, a lo sumo, un conjunto de medida cero. Aunque esto habría que desarrollarlo un poco más, la idea intuitiva es que cualquier intervalo no vacío *no es* de medida cero, mientras que un sólo punto, o una cantidad finita, o incluso numerable, de puntos, *sí forman* un conjunto de medida cero. Por tanto, el teorema de inversión nos dice que si tomo una función $f \in L^2(\mathbb{R})$, hallo su transformada de Fourier $\mathcal{F}(f)$ y a continuación hallo la transformada inversa de $\mathcal{F}(f)$, entonces recupero f salvo quizás en unos pocos puntos, que no van a tener ninguna importancia en la gran mayoría de las aplicaciones. Esto es lo que nos permite decir que “no perdemos información” al considerar $\mathcal{F}(f)$ en lugar de f , puesto que podemos recuperar f (salvo quizás en unos pocos puntos) a partir de $\mathcal{F}(f)$.

Definición 10.5 Sean $f, g : \mathbb{R} \rightarrow \mathbb{R}$. Se define su **convolución** $f * g$ como

$$(f * g)(x) = \int_{-\infty}^{\infty} f(x - y)g(y) dy,$$

siempre y cuando la integral impropia exista.

Teorema 10.11 Sean $f, g \in L^2(\mathbb{R})$. Entonces $f * g$ existe, $f * g \in L^2(\mathbb{R})$ y además

1. $\mathcal{F}(f * g)(w) = \mathcal{F}(f)(w) \cdot \mathcal{F}(g)(w)$ para todo $w \in \mathbb{R}$.
2. $\mathcal{F}(f \cdot g)(w) = \mathcal{F}(f)(w) * \mathcal{F}(g)(w)$ para todo $w \in \mathbb{R}$.

Estos últimos resultados tienen una importancia fundamental para la realización de *filtros en frecuencia*, que permitan, dada una señal, quedarnos con sus componentes en cierto rango de frecuencias y desechar las demás. Junto con el *teorema de Nyquist*, o teorema de muestreo, que proporciona información esencial para el paso de una señal analógica, o continua, a una señal digital, conforman la base para el estudio y procesamiento digital de señales —DSP, *digital signal processing*—.

10.2.2 La Transformada de Fourier discreta

La *Transformada de Fourier discreta* se refiere al tratamiento de funciones discretas en el tiempo y frecuencia. Su objetivo es transformar una sucesión discreta de valores, f_n , $n = 0, \dots, N - 1$, en otra F_k , $k = 0, \dots, N - 1$.

Las sucesiones objeto de análisis pueden ser el resultado de un registro de una señal propiamente dicha, con valores periódicos, o el resultado de una señal continua que se ha digitalizado. Esto último consiste en muestrearla, o “samplearla”, es decir, no quedarse con toda la señal sino con la sucesión de valores de la señal tomados cada T segundos (este es el caso del muestreo uniforme en el tiempo), aunque para ciertas señales puede ser más interesante un muestreo no uniforme. En la figura 10.3 se ve una muestra de esta idea.




Figura 10.3

Definición 10.6 Para un vector de coeficientes reales, $\mathbf{x} = [x_0, x_1, \dots, x_{n-1}]^T$, su **Transformada de Fourier Discreta, TFD**, es el vector n -dimensional $\mathbf{y} = [y_0, y_1, \dots, y_{n-1}]^T$ tal que

$$y_k = \frac{1}{\sqrt{n}} \sum_{j=0}^{n-1} x_j \omega^{jk},$$

donde $\omega = e^{-i2\pi/n}$.

De acuerdo con el Lema 9, de la página 163, la transformada de Fourier discreta de $\mathbf{x} = [1, 1, \dots, 1]^T$ es $\mathbf{y} = [\sqrt{n}, 0, \dots, 0]^T$.

En forma matricial, la definición dice que

$$\begin{bmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{n-1} \end{bmatrix} = \begin{bmatrix} a_0 + ib_0 \\ a_1 + ib_1 \\ a_2 + ib_2 \\ \vdots \\ a_{n-1} + ib_{n-1} \end{bmatrix} = \frac{1}{\sqrt{n}} \begin{bmatrix} \omega^0 & \omega^0 & \omega^0 & \dots & \omega^0 \\ \omega^0 & \omega^1 & \omega^2 & \dots & \omega^{n-1} \\ \omega^0 & \omega^2 & \omega^4 & \dots & \omega^{2(n-1)} \\ \vdots & \vdots & \vdots & & \vdots \\ \omega^0 & \omega^{n-1} & \omega^{2(n-1)} & \dots & \omega^{(n-1)^2} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_{n-1} \end{bmatrix}.$$

A la matriz simétrica

$$\mathbf{F}_n = \frac{1}{\sqrt{n}} \begin{bmatrix} \omega^0 & \omega^0 & \omega^0 & \dots & \omega^0 \\ \omega^0 & \omega^1 & \omega^2 & \dots & \omega^{n-1} \\ \omega^0 & \omega^2 & \omega^4 & \dots & \omega^{2(n-1)} \\ \vdots & \vdots & \vdots & & \vdots \\ \omega^0 & \omega^{n-1} & \omega^{2(n-1)} & \dots & \omega^{(n-1)^2} \end{bmatrix}$$

se la denomina *matriz de Fourier*. Todas sus filas y columnas, excepto las primeras, suman cero. La inversa de la matriz de Fourier es

$$\mathbf{F}_n^{-1} = \frac{1}{\sqrt{n}} \begin{bmatrix} \omega^0 & \omega^0 & \omega^0 & \dots & \omega^0 \\ \omega^0 & \omega^{-1} & \omega^{-2} & \dots & \omega^{-(n-1)} \\ \omega^0 & \omega^{-2} & \omega^{-4} & \dots & \omega^{-2(n-1)} \\ \vdots & \vdots & \vdots & & \vdots \\ \omega^0 & \omega^{-(n-1)} & \omega^{-2(n-1)} & \dots & \omega^{-(n-1)^2} \end{bmatrix}$$

y la *Transformada Discreta de Fourier inversa* de $\mathbf{y}$ es $\mathbf{x} = \mathbf{F}_n^{-1} \mathbf{y}$.

El algoritmo por excelencia para calcular la transformada de Fourier discreta es el conocido por *Transformada Rápida de Fourier* —FFT—, debido a James William Cooley, EE.UU. 1926 y John Tukey, EE.UU. 1915-2000.



Las fórmulas para el cálculo de la transformada de Fourier discreta son generales y se pueden aplicar a cualquier conjunto de datos $\{x_0, x_1, x_2, \dots, x_{n-1}\}$, sin que necesariamente provengan del muestreo de una señal continua.

Volviendo a ese muestreo de señales continuas, su digitalización, o *sampleo*, tiene una ventaja evidente, que permite trabajar con una sucesión de números en lugar de con toda la señal, lo que es muy útil sobre todo para el tratamiento digital de la señal. También un inconveniente obvio, la señal muestreada no contiene, en principio, toda la información que había en la señal original. Parece claro que cuantas más muestras por segundo se tomen (esto es, cuanto menor sea T) menos información se perderá, pero también costará más muestrear, almacenar y manipular la información. Entonces ¿cuál es intervalo de muestreo que debemos usar? La respuesta a esto la da el teorema de Nyquist-Shannon, que veremos a continuación.


Antes, veamos un ejemplo concreto muy próximo en nuestro devenir cotidiano: un CD de música. Hasta hace no muchos años la música se almacenaba siempre en vinilo o en cinta magnética, y ambos soportes partían de una señal analógica y almacenaban también una señal analógica. El progreso de la tecnología y la relativamente baja calidad y durabilidad de ambos soportes llevaron a plantearse el almacenamiento digital de la música en forma de CD, ya que el soporte físico es muchísimo más duradero y el tratamiento de la señal digital más versátil. El problema una vez más es ¿a qué velocidad hemos de muestrear una señal sonora para que la señal muestreada sea de la máxima calidad?

Primero un par de consideraciones biológicas: nuestro oído “oye en frecuencias” (al igual que nuestros ojos ven en frecuencias) y está limitado en frecuencia: nadie oye señales de frecuencia superior a 20KHz, al igual que nadie ve luz infrarroja o ultravioleta. Este límite no es común a todos los animales: algunos, como ratas y perros tienen la capacidad de oír señales de frecuencia superior, y los famosos ultrasonidos usados en ocasiones para intentar ahuyentar ratas no son sino sonidos de frecuencia superior a 20KHz y gran volumen, que nosotros no oímos pero ellas sí. Esta limitación de nuestro oído tiene consecuencias prácticas: si consideramos una señal sonora y le quitamos sus componentes de frecuencias superiores a 20 KHz, nuestros oídos no son capaces de percibir ninguna diferencia entre ambas señales. Por tanto la respuesta a la pregunta anterior, ¿a qué velocidad hemos de muestrear una señal sonora para que la señal muestreada sea gran calidad?, es “A la velocidad necesaria para mantener las componentes de la señal de frecuencias inferiores a 20 KHz.” Y aquí es donde interviene por fin el teorema de Nyquist-Shannon.

Teorema 10.12 *Teorema de Nyquist-Shannon. Sea $f : \mathbb{R} \rightarrow \mathbb{C}$ una señal que admite transformada de Fourier F (lo que ocurre por ejemplo si $f \in L^2(\mathbb{R})$). Si $F(\omega) = 0$ para todo $\omega > \omega_M = 2\pi f_M$ entonces se puede determinar f en casi todo punto por medio de sus valores separados por intervalos uniformes menores que $\frac{1}{2f_M}$ segundos.*

Este teorema es fruto del trabajo de Harry Nyquist, Suecia 1889-EE.UU. 1976 y

Claude Elwood Shannon, EE.UU. 1916-2001.



Al parecer, no obstante, científicos como E. T. Whittaker, Vladimir Kotelnikov y otros estaban trabajando también sobre este mismo asunto, por lo que en algunos casos se referencia en la literatura especializada como teorema de Nyquist-Shannon-Kotelnikov, Whittaker-Shannon-Kotelnikov o Whittaker-Nyquist-Kotelnikov-Shannon, además de teorema cardinal de interpolación.

A partir de este teorema se puede demostrar que la manera de recuperar $f(t)$, a partir de los datos muestreados y el resultado, es

$$f(t) = \sum_{n=-\infty}^{\infty} f(nT) \frac{\sin \omega_M(t - nT)}{\omega_M(t - nT)},$$

para el caso de que $\omega_M = 2\pi f_M$ y $T = \frac{1}{2f_M}$.

Está demostrado que para evitar el fenómeno conocido como *aliasing* —efecto que causa que señales continuas distintas se tornen indistinguibles cuando se muestrean digitalmente— es necesario asegurarse de que en la señal analógica a muestrear, con una frecuencia f_s , no tenga componentes sinusoidales de frecuencia mayor a $f_s/2$. Esta condición es llamada el *criterio de Nyquist*, y es equivalente a decir que la frecuencia de muestreo f_s debe ser al menos dos veces mayor que el ancho de banda de la señal. En la figura 10.4 se ven dos sinusoides que pueden ser representados por la misma muestra y que daría lugar al efecto aliasing.




Figura 10.4

El Teorema de Nyquist indica que la frecuencia de muestreo mínima que tenemos que utilizar debe ser mayor que $2f_M$ (*frecuencia crítica de Nyquist*), donde f_M es la frecuencia máxima de la señal compleja. Si utilizamos esa frecuencia de muestreo, podremos

reproducir posteriormente la señal a partir de las muestras tomadas. En la práctica, debido a las limitaciones de los circuitos, la utilización de una frecuencia más alta que la que nos dice Nyquist permite obtener una representación más exacta de la señal de entrada.

11 | La Transformada del coseno discreta

A lo largo de este libro estamos constatando lo útil que es el concepto de ortogonalidad par representar y comprimir datos de diversos tipos.

La *Transformada del coseno discreta* —DCT o TCD— se utiliza habitualmente para la compresión de imágenes y vídeo. Los formatos JPEG, MP3 y AAC son conocidos, para compresión de imágenes, audio y vídeo, y utilizan esencialmente las técnicas de la transformada del coseno discreta.

La transformada del coseno discreta es una transformada basada en la de Fourier discreta que utiliza únicamente números reales. Aunque la parte real de la TFD y la TCD están relacionadas, la DCT no es la parte real de la TFD. Como la TFD, la TCD consiste en dividir una señal (discreta) en la suma de una serie de funciones (también discretas) ponderadas por unos coeficientes. Estas funciones, llamadas funciones base, son ortogonales y por tanto independientes (no existe la posibilidad de que una de estas funciones pueda representarse a través de una combinación de las demás, sin embargo, el conjunto completo pueden representar cualquier señal cuando se ponderan mediante coeficientes y se suman entre si). Las funciones base sólo dependen del número de muestras de la señal, y fijado éste las funciones base siempre son iguales. El conjunto de coeficientes que ponderan las funciones base son el resultado de la transformación directa. Al proceso de reconstruir la señal a partir de los coeficientes de la transformada directa se denomina transformación inversa.

La diferencia entre la TFD y la TCD es que ésta utiliza únicamente funciones coseno, y por lo tanto sus coeficientes son números reales. Formalmente, la transformada de coseno discreta unidimensional es una función lineal invertible de $\mathbb{R}^n$ en $\mathbb{R}^n$, equivalente a una matriz cuadrada $n \times n$ ortogonal de coeficientes reales.

Existen ocho variantes diferentes de TCD unidimensionales. Las utilizadas en compresión de imágenes son la DCT-II, cuya inversa es la DCT-III, también llamadas transformada directa del coseno, FDCT —*Forward Discrete Cosine Transform*—, y transformada inversa del coseno, IDCT —*Inverse Discrete Cosine Transform*—, respectivamente.

La transformada de coseno discreta unidimensional es una función lineal $f : \mathbb{R}^N \rightarrow \mathbb{R}^N$, equivalente a una matriz cuadrada $N \times N$, invertible, que transforma un vector $\mathbf{x} = [x_0, \dots, x_{N-1}]^T$ en otro $\mathbf{y} = [y_0, \dots, y_{N-1}]^T$ de acuerdo con las siguientes fórmulas:

DCT-I

$$y_k = \frac{1}{2} \left(x_0 + (-1)^k x_{N-1} \right) + \sum_{n=1}^{N-2} x_n \cos \left[\frac{\pi}{N-1} nk \right], \quad k = 0, \dots, N-1.$$

DCT-II

$$y_k = \sum_{n=0}^{N-1} x_n \cos \left[\frac{\pi}{N} \left(n + \frac{1}{2} \right) k \right], \quad k = 0, \dots, N-1.$$

DCT-III

$$y_k = \frac{1}{2} x_0 + \sum_{n=1}^{N-1} x_n \cos \left[\frac{\pi}{N} n \left(k + \frac{1}{2} \right) \right], \quad k = 0, \dots, N-1.$$

DCT-IV

$$y_k = \sum_{n=0}^{N-1} x_n \cos \left[\frac{\pi}{N} \left(n + \frac{1}{2} \right) \left(k + \frac{1}{2} \right) \right], \quad k = 0, \dots, N-1.$$

También existen fórmulas DCT de V a VIII, para otras tantas transformaciones.

La transformación se puede expresar matricialmente de la forma

$$\mathbf{y} = \mathbf{C} \mathbf{x}.$$

Para que la matriz $\mathbf{C}$ sea una matriz ortonormal (y por tanto su inversa coincida con su transpuesta) se han de multiplicar las ecuaciones anteriores por unos coeficientes de escalado y normalización que pueden depender de k y n . Para la DCT-II son

$$c_{kn} = w(k) \cos \left(\frac{\pi}{N} k \left(n + \frac{1}{2} \right) \right), \quad \text{con } w(k) = \begin{cases} \frac{1}{\sqrt{N}} & \text{si } k = 0 \\ \frac{2}{\sqrt{N}} & \text{si } k \neq 0. \end{cases}$$

Se pueden componer dos (o más) grupos de funciones básicas para crear transformadas de dos (o más) dimensiones. La DCT bidimensional (DCT-2D) es una función lineal invertible de $\mathbb{R}^{N \times N} \rightarrow \mathbb{R}^{N \times N}$ que descompone el bloque de imagen en una suma de frecuencias espaciales. Los coeficientes y_{kl} de la DCT para bloques x_{ij} de 8×8 se expresan como:

$$y_{kl} = \frac{c(k)c(l)}{4} \sum_{i=0}^7 \sum_{j=0}^7 x_{ij} \cos \left(\frac{(2i+1)k\pi}{16} \right) \cos \left(\frac{(2j+1)l\pi}{16} \right),$$

donde $k, l = 0, 1, \dots, 7$ y $c(x) = \begin{cases} \frac{1}{2} & \text{si } x = 0 \\ 1 & \text{si } x \neq 0 \end{cases}$. Su inversa, IDCT-2D,

$$x_{ij} = \sum_{k=0}^7 \sum_{l=0}^7 y_{kl} \frac{c(k)c(l)}{4} \cos \left(\frac{(2i+1)k\pi}{16} \right) \cos \left(\frac{(2j+1)l\pi}{16} \right).$$

El bloque de coeficientes de la DCT está ordenado de modo que la componente continua corresponde al elemento y_{00} y la frecuencia espacial crece con los índices k y l siendo y_{77} el coeficiente correspondiente a la mayor frecuencia.

En la figura 11.1 se representa un conjunto de 64 funciones base bidimensionales (imágenes base) que se generan multiplicando un conjunto de funciones base unidimensionales de ocho puntos ($N=8$) orientadas horizontalmente, por un conjunto verticalmente orientado de las mismas funciones. Las imágenes base orientadas horizontalmente representan las frecuencias horizontales y las orientadas verticalmente representan las frecuencias verticales. La fila superior y la columna de la izquierda tienen variaciones de intensidad en una sola dimensión. Para propósitos de ilustración, un gris neutro representa cero en estas figuras, el blanco representa amplitudes positivas, y el negro representa amplitudes negativas.




Figura 11.1

La ventaja que tiene la DCT frente a la DFT para la compresión de imágenes, a parte de solo utilizar números reales, es que produce una mejor compactación de la energía (consigue concentrar la mayor parte de la información en pocos coeficientes) y un menor efecto de bloque. Este efecto se esquematiza en la figura 11.2.

El efecto de bloque se produce cuando se divide la imagen en bloques de 8×8 píxeles o macrobloques de 16×16 píxeles para poder ejecutar los algoritmos de transformación. Cuando se lleva a cabo la DFT del bloque, se asume la periodicidad del mismo (que se repite a lo largo de todo el plano bidimensional que contiene la imagen). En la transformada de Fourier el píxel B del borde derecho será tratado por el algoritmo como si estuviera seguido por el píxel A. Si los niveles de gris en cada píxel difieren considerablemente cualquier reconstrucción del bloque a partir de únicamente un número limitado de coeficientes de Fourier dará lugar a valores erróneos en A y B. Este fenómeno es lo que se conoce como efecto de bloque, que tiende a hacer muy visibles los límites de los bloques en la compresión, especialmente cuando la proporción de compresión es elevada. Sin embargo, mientras que la teoría de Fourier implica la repetición de los bloques $L \times L$, la teoría de la DCT impone esta repetición sobre bloques $2L \times 2L$, que están relacionados con los bloques originales $L \times L$ a través de simetrías especulares. La consecuencia




Figura 11.2: Compactación de la energía de una TCD comparada con una TFD

de esta simetría especular es que después del píxel B, le sigue otro píxel B, eliminando así la discontinuidad, esto provoca una reducción considerable del efecto de bloque. En la figura 11.3 se muestra la periodicidad de un bloque 4×4 en la TFD y la TCD.




Figura 11.3: Periodicidad supuesta de un bloque 4×4 de una TFD (a) y una TCD (b)

La transformación lineal óptima que minimiza el error cuadrático medio entre la imagen original y la imagen recuperada (después de transformar y comprimir la imagen) es la transformada de Karhunen-Loève (KLT). La KLT realiza una descomposición de componentes principales (PCA) de los bloques de la imagen, por lo que las funciones bases (y la matriz de la transformación) dependen de las propiedades estadísticas de la imagen. Las funciones base (y su matriz de transformación) de la DCT dependen

únicamente del orden N . Por lo que como se mencionó antes, fijado el número de puntos estas son siempre iguales sea cual sea la imagen. Una de las ventajas de la DCT es que siendo fija la transformación su eficiencia de compresión se aproxima a la de la KLT (la óptima) para imágenes con alto grado de correlación espacial.

12 | La Transformada de Laplace

E NUNCIADA por Pierre-Simon Laplace, Francia, 1749-1827,



esta transformada integral es similar a la de Fourier. Mientras ésta es una función compleja de una variable real, la frecuencia, la de Laplace es una función compleja de una variable compleja.

Definición 12.1 Dada una función $f(t)$ definida en $[0, \infty)$, su **Transformada de Laplace** es la función

$$F(s) = \mathcal{L}\{f\} = \int_0^{\infty} e^{-st} f(t) dt.$$

La transformada de Laplace es un operador: definido para funciones y que transforma funciones en otras funciones. En general s es una variable compleja. Como la integral de la definición es impropia, al evaluarla hay que considerar $\lim_{c \rightarrow \infty} \int_0^c e^{-st} f(t) dt$.

La transformada de Laplace mejora algunas de las prestaciones de la Transformada de Fourier al no exigir que la señal $f(t)$ sea absolutamente integrable. La Transformada de Laplace es invertible en un gran número de funciones.

Ejemplo 12.1 Consideremos la función $f(t)$ definida por

$$f(t) = \begin{cases} 0 & \text{si } t < 0 \\ Ae^{-at} & \text{si } t \geq 0. \end{cases}$$

Su transformada de Laplace es

$$\begin{aligned} \mathcal{L}\{f(t)\} &= \int_0^{\infty} Ae^{-at} e^{-st} dt \\ &= \int_0^{\infty} Ae^{-(s+a)t} dt \\ &= A \frac{e^{-(s+a)t}}{-(s+a)} \Big|_0^{\infty} = \frac{A}{s+a}, \end{aligned}$$

supuesto que $s + a > 0$. Es decir se lleva a cabo la correspondencia

$$Ae^{-at} (t \geq 0) \Leftrightarrow \frac{A}{s + a}.$$

Ejemplo 12.2 Sea ahora $f(t) = 1$. La transformada de Laplace es

$$\mathcal{L}\{1\} = \int_0^{\infty} e^{-st} dt = -\frac{1}{s}e^{-st} \Big|_0^{\infty} = \frac{1}{s}.$$

Ejemplo 12.3 Sea ahora $f(t) = t$. La transformada de Laplace es

$$\mathcal{L}\{t\} = \int_0^{\infty} e^{-st} t dt = -\frac{t}{s}e^{-st} \Big|_0^{\infty} + \frac{1}{s} \int_0^{\infty} e^{-st} dt = \frac{1}{s^2}.$$

Algunas funciones útiles para ingeniería y control de procesos, y sus transformadas de Laplace, se listan en la tabla del cuadro 12.1.

La Transformada de Laplace hace sombra a la de Fourier en algunas aplicaciones ingenieriles como el control de procesos industriales, el análisis de sistemas lineales, la electrónica industrial y otros afines. Su uso y estudio está ampliamente extendido para ayudar a entender problemas donde las funciones que surgen están definidas en un tiempo finito y están acotadas. También para integración numérica de ecuaciones diferenciales ordinarias.

El operador transformada de Laplace permite transformar un problema de funciones en un problema de sus respectivas transformadas. Éste se resuelve si se puede mediante ecuaciones algebraicas y después se vuelve hacia atrás (problema inverso) recobrando la solución original ahora en funciones. Por ejemplo, la transformada de Laplace permite cambiar el dominio tiempo por el dominio frecuencia en problema de ecuaciones diferenciales, convirtiéndolo en ecuaciones lineales, la convolución en multiplicación, etc.

Para terminar con una osada comparativa rápida general:

- La transformada de Laplace “mapea” o transforma una función en otra en el plano complejo con variable compleja; la de Fourier transforma una función en otra compleja con variable real (la frecuencia).
- La transformada de Laplace se usa para estudios de estabilidad de señales y sistemas mientras que la de Fourier para analizar el comportamiento de sistemas ante entradas sinusoidales.
- La primera para señales permanentes; la segunda para señales dinámicas o transitorias.
- La transformada de Fourier se usa para integrar ecuaciones diferenciales de problemas de contorno en la recta real; la de Laplace para problemas de valor inicial.

$f(t), t \in [0, \infty)$	$\mathcal{L}\{f\}$
1	$\frac{1}{s}$
$e^{at}, a \in \mathbb{R}$	$\frac{1}{s-a}$
$t^n, n \in \mathbb{N}$	$\frac{n!}{s^{n+1}}$
$\text{sen } wt, w \in \mathbb{R}$	$\frac{w}{s^2+w^2}$
$\cos wt, w \in \mathbb{R}$	$\frac{s}{s^2+w^2}$
$\sinh wt, w \in \mathbb{R}$	$\frac{w}{s^2-w^2}$
$\cosh wt, w \in \mathbb{R}$	$\frac{s}{s^2-w^2}$
$e^{at} \text{ sen } wt, a, w \in \mathbb{R}$	$\frac{w}{(s-a)^2+w^2}$
$e^{at} \cos wt, a, w \in \mathbb{R}$	$\frac{s-a}{(s-a)^2+w^2}$
$t \text{ sen } wt, w \in \mathbb{R}$	$\frac{2ws}{(s^2+w^2)^2}$
$t \cos wt, w \in \mathbb{R}$	$\frac{s^2-w^2}{(s^2+w^2)^2}$

Cuadro 12.1

13 | Cálculo estocástico y simulación

UN proceso estocástico o aleatorio se puede concebir en términos de variables aleatorias ligadas al paso del tiempo (en la escala que sea), o a la ubicación en el espacio. Muchos modelos matemáticos de realidades económicas, físicas, ambientales, sociales, financieras o ingenieriles consideran cantidades que cambian aleatoriamente con el paso del tiempo. Tales modelos se suelen formular y analizar en términos de procesos estocásticos.

En este apartado perseguimos dos objetivos. El primero es proporcionar al lector cierta base teórica sobre procesos estocásticos y espacios de probabilidad, que se usan para modelizar matemáticamente fenómenos aleatorios en el tiempo o el espacio, y sus herramientas de cálculo básicas. El segundo, repasar algunos fundamentos matemáticos de los algoritmos más usados para generar muestras con las que utilizar o analizar esos modelos. Sigo esencialmente a Nualart [2017] y Sauer [2012].

13.1 Variables aleatorias y espacios de probabilidad

Cada resultado posible de un experimento o experiencia aleatoria, ω , es un evento o *suceso elemental*. El conjunto de todos los posibles sucesos es el *conjunto muestral*, designado habitualmente por Ω .

Ejemplo 13.1 En una sucesión de cálculos realizados con un ordenador observamos los primeros 9 dígitos no tenidos en cuenta al truncar los resultados de las operaciones con una cierta cifra decimal. En este caso el conjunto muestral es $\Omega = \{(a_1, \dots, a_k) : a_i \in \mathbb{Z}, 0 \leq a_i \leq 9\}$. ●

Ejemplo 13.2 Se lanza un dado varias veces y se cuenta el número de lanzamientos hasta que salga el 6 por primera vez. En este caso el conjunto muestral es el conjunto de números naturales, $\mathbb{N}$. Es decir $\Omega = \{1, 2, 3, \dots\}$. ●

Ejemplo 13.3 Si se mide la presión y la temperatura en una estación meteorológica, $\Omega = \{(p, t) : p > 0, t \in \mathbb{R}\}$. ●

En la práctica, al realizar un experimento, suele interesar saber si algún subconjunto de sucesos de Ω se repite o se da bajo distintas formas. Interesa por lo tanto en considerar *familias de subconjuntos* de Ω , significadas por $\mathcal{F}$.

Definición 13.1 Una familia $\mathcal{F}$ de subconjuntos de un conjunto muestral Ω se dice que tiene una estructura de **σ -álgebra** si satisface estas condiciones:

1. $\emptyset \in \mathcal{F}$;
2. Al realizar un experimento algo ocurre, es decir $\Omega \in \mathcal{F}$. A Ω se le denomina

evento o *suceso cierto*;

3. Si $A \in \mathcal{F}$ su complemento A^c (*no ocurre A*), también pertenece a $\mathcal{F}$: $A^c \in \mathcal{F}$;
4. Si los sucesos $A_1, A_2, \dots, A_n, \dots$ ocurren, el suceso *ocurre alguno de los A_n* también es un suceso o evento. Es decir, $A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.

Definición 13.2 La σ -álgebra generada por los conjuntos abiertos de $\mathbb{R}^n$ se denomina **σ -álgebra de Borel** de $\mathbb{R}^n$, representándose por $\mathcal{B}_{\mathbb{R}^n}$.

Debe su nombre a Félix Édouard Justin Émile Borel, Francia 1871-1956.



Ahora definamos el entorno general de probabilidad en el que nos vamos a enmarcar.

Definición 13.3 Un **espacio de probabilidad** es una terna $(\Omega, \mathcal{F}, P)$ formada por

- I Un conjunto muestral Ω que representa el conjunto de posibles resultados de un experimento aleatorio.
- II Una familia $\mathcal{F}$ de subconjuntos de Ω que tiene estructura de σ -álgebra.
- III Una aplicación $P : \mathcal{F} \rightarrow [0, 1]$, denominada **probabilidad**, que cumple que:
 - a) $P(\emptyset) = 0, P(\Omega) = 1$.
 - b) Para todo $A \in \mathcal{F}$, $P(A) \geq 0$. La probabilidad de un suceso cualquiera A es un número real no negativo.
 - c) Si $A_1, A_2, \dots \in \mathcal{F}$ son conjuntos disjuntos dos a dos (es decir, $A_i \cap A_j = \emptyset$ si $i \neq j$), entonces

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Si $P(F) = 1$ diremos que el suceso F ocurre con probabilidad uno, o casi seguramente. Algunas reglas básicas del cálculo de probabilidades son:

$$P(A \cap B) = P(A) + P(B) \text{ si } A \cup B = \emptyset$$

$$P(A^c) = 1 - P(A)$$

$$A \subset B \implies P(A) \leq P(B)$$

Ejemplo 13.4 Elegimos un número al azar en el intervalo $[0, 2]$. $\Omega = [0, 2]$, $\mathcal{F}$ es la σ -álgebra de Borel generada por los intervalos de $[0, 2]$. La probabilidad de cualquier intervalo $[a, b] \subset [0, 2]$ será

$$P([a, b]) = \frac{a - b}{2}.$$

Se dice que un espacio de probabilidad $(\Omega, \mathcal{F}, P)$ es *completo* si dado un suceso A de probabilidad cero, todos los subconjuntos de A pertenecen a la σ -álgebra $\mathcal{F}$.

Definición 13.4 Una **variable aleatoria** definida sobre un espacio de probabilidad $(\Omega, \mathcal{F}, P)$ es una aplicación $X(\omega) : \Omega \rightarrow \mathbb{R}$ que es $\mathcal{F}$ -medible, es decir, $X^{-1}(B) \in \mathcal{F}$, para todo conjunto B de la σ -álgebra de Borel de $\mathbb{R}$, $\mathcal{B}_{\mathbb{R}}$.

De forma más sencilla, una variable aleatoria es una función real definida en el espacio de probabilidad $(\Omega, \mathcal{F}, P)$ que otorga un valor numérico a un experimento aleatorio.

Una variable aleatoria determina una σ -álgebra $\{X^{-1}(B), B \in \mathcal{B}_{\mathbb{R}}\} \subset \mathcal{F}$ que se denomina σ -álgebra generada por X .

Una variable aleatoria determina una probabilidad en la σ -álgebra de Borel $\mathcal{B}_{\mathbb{R}}$ definida por $P_X = P \circ X^{-1}$, es decir,

$$P_X(B) = P(X^{-1}(B)) = P(\{\omega : X(\omega) \in B\}).$$

El símbolo $\circ$ denota composición de funciones y X^{-1} la preimagen. La probabilidad P_X se denomina *la ley o distribución* de la variable X .

Definición 13.5 Se dice que una variable aleatoria X tiene una **densidad de probabilidad** f_X si $f_X(x)$ es una función positiva, medible respecto de la σ -álgebra de Borel y tal que

$$P(a < X < b) = \int_a^b f_X(x) dx,$$

para todo $a < b$.

Ejemplo 13.5 Una variable aleatoria tiene ley normal $N(m, \sigma^2)$ si

$$P(a < X < b) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_a^b e^{-\frac{(x-m)^2}{2\sigma^2}} dx,$$

para todo par de números reales $a < b$. ●

Las variables discretas que toman un conjunto finito o numerable de valores distintos x_k no tienen densidad de probabilidad y su ley está determinada por la *función de probabilidad*

$$p_k = P(X = x_k).$$

Ejemplo 13.6 Una variable aleatoria tiene ley binomial $B(n, p)$ si

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k},$$

para $k = 0, 1, \dots, n$. ●

Definición 13.6 La distribución de una variable aleatoria X puede caracterizarse mediante su **función de distribución** definida como la probabilidad acumulada

$$F_X(x) = P(X \leq x) = P_X((-\infty, x]).$$

La función $F_X : \mathbb{R} \rightarrow [0, 1]$ es creciente, continua por la derecha y con límites iguales a cero en $-\infty$ y 1 en $+\infty$. Si la variable tiene densidad f_X , entonces

$$F_X(x) = \int_{-\infty}^x f_X(y) dy,$$

y si la densidad es continua, $F'_X(x) = f_X(x)$.

Definición 13.7 La **esperanza matemática** de una variable aleatoria X se define como la integral de X con respecto a la probabilidad P , considerada como una medida en el espacio $(\Omega, \mathcal{F})$. En particular, si X es una variable elemental que toma los valores $\alpha_1, \dots, \alpha_n$ en los conjuntos $A_1, \dots, A_n$, su esperanza matemática valdrá

$$E(X) = \sum_{i=1}^n \alpha_i P(A_i).$$

El cálculo de la esperanza matemática de una variable aleatoria se efectúa integrando la función X respecto de la ley de probabilidad de la variable. Es decir, si X es una variable que tiene esperanza ($E(|X|) < \infty$) se tiene que

$$E(X) = \int_{\Omega} X(\omega) dP(\omega) = \int_{-\infty}^{\infty} x dP_X(x).$$

En general, si $g : \mathbb{R} \rightarrow \mathbb{R}$ es una función medible respecto de la σ -álgebra de Borel y $E(g(X)) < \infty$ entonces la esperanza de la variable $g(X)$ se puede calcular integrando la función g respecto de la ley de la variable X , es decir

$$E(g(X)) = \int_{\Omega} g(X(\omega)) dP(\omega) = \int_{-\infty}^{\infty} g(x) dP_X(x).$$

La integral $\int_{-\infty}^{\infty} g(x) dP_X(x)$ se calcula utilizando la densidad o función de probabilidad de la variable X :

$$\int_{-\infty}^{\infty} g(x) dP_X(x) = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx & f_X(x) \text{ es la densidad de } X \\ \sum_k g(x_k) P(x = x_k) & X \text{ es variable discreta.} \end{cases}$$

Ejemplo 13.7 Si X es una variable aleatoria con ley normal $N(0, \sigma^2)$ y λ es un número real,

$$\begin{aligned} E(e^{\lambda X}) &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} e^{\lambda x} e^{-\frac{x^2}{2\sigma^2}} dx \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{\sigma^2 \lambda^2}{2}} \int_{-\infty}^{\infty} e^{-\frac{(x - \sigma^2 \lambda)^2}{2\sigma^2}} dx \\ &= e^{\frac{\sigma^2 \lambda^2}{2}}. \end{aligned}$$

Definición 13.8 La **varianza** de una variable aleatoria X se define por

$$\sigma_X^2 = \text{Var}(X) = E((X - E(X))^2) = E(X^2) - [E(X)]^2.$$

La varianza mide el grado de dispersión de los valores de la variable respecto de su esperanza.

Por ejemplo, si X es una variable aleatoria con ley normal $N(m, \sigma^2)$ se tiene que

$$\begin{aligned} P(m - 1,96\sigma \leq X \leq m + 1,96\sigma) &= P(-1,96 \leq \frac{X - m}{\sigma} \leq 1,96) \\ \Phi(1,96) - \Phi(-1,96) &= 0,95, \end{aligned}$$

donde Φ es la función de distribución de la ley $N(m, \sigma^2)$. Es decir, la probabilidad de que la variable X tome valores en el intervalo $[m - 1,96\sigma, m + 1,96\sigma]$ es igual a 0,95.

Definición 13.9 Se dice que $X = [X_1, \dots, X_n]^\top$ es un **vector aleatorio** n -dimensional si sus coeficientes, o componentes, son variables aleatorias.

La *esperanza matemática* de un vector aleatorio n -dimensional X será el vector $E(X) = (E(X_1), \dots, E(X_n))$

Definición 13.10 La **matriz de covarianzas** de un vector aleatorio n -dimensional X es la matriz

$$\Gamma_X = (\text{cov}(X_i, X_j))_{1 \leq i, j \leq n},$$

donde $\text{cov}(X_i, X_j) = E[(X_i - E(X_i))(X_j - E(X_j))]$.

Es decir, los coeficientes de la diagonal principal de esta matriz son las varianzas de las variables X_i y fuera de la diagonal están las covarianzas entre dos variables X_i y X_j .

La *ley o distribución* de un vector aleatorio n -dimensional X es la probabilidad definida en el σ -álgebra de Borel $\mathcal{B}_{\mathbb{R}^n}$ por $P_X(B) = P(X^{-1}(B)) = P(X \in B)$, para todo conjunto B de la σ -álgebra de Borel de $\mathbb{R}$.

Se dice que un vector aleatorio n -dimensional X tiene una *ley normal* $N(m, \Gamma)$, donde $m \in \mathbb{R}^n$ y Γ es una matriz simétrica y definida positiva, si

$$P(a_i \leq X_i \leq b_i, i = 1, \dots, n) = \int_{a_n}^{b_n} \cdots \int_{a_1}^{b_1} (2\pi \det \Gamma)^{-\frac{n}{2}} e^{-\frac{1}{2} \sum_{i,j=1}^n (x_i - m_i)(x_j - m_j) \Gamma_{ij}^{-1}} dx_1 \cdots dx_n.$$

En tal caso, se tiene que $m = E(X)$ y $\Gamma = \Gamma_x$. Si la matriz Γ es diagonal,

$$\Gamma = \begin{bmatrix} \sigma_1^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_n^2 \end{bmatrix}$$

entonces la densidad del vector X será el producto de n densidades normales unidimensionales:

$$f_X(x_1, \dots, x_n) = \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x_i - m_i)^2}{2\sigma_i^2}} \right).$$

Existen también leyes normales degeneradas en las que la matriz Γ es singular. En este caso no existe la densidad de probabilidad y la ley de X queda determinada por su función característica:

$$E(e^{it'X}) = e^{(it'm - \frac{1}{2}t'\Gamma t)},$$

donde $t \in \mathbb{R}^n$. En esta fórmula t' es un vector fila $1 \times n$ y t una columna $n \times 1$.

Si X es un vector normal n -dimensional con ley $N(m, \Gamma)$ y A es una matriz $m \times n$, entonces AX es un vector normal m -dimensional con ley $N(Am, A\Gamma A')$.

Se dice que una variable tiene media de orden $p \geq 1$ si $E(|X|^p) < \infty$. En tal caso se define el *momento de orden p* de la variable aleatoria X como $m_p = E(X^p)$.

El conjunto de las variables que tienen media de orden p se representa por

$$L^p(\Omega, \mathcal{F}, P).$$

Sea X una variable aleatoria con función característica $\varphi_X(t) = E(e^{itX})$. Los momentos de la variable aleatoria pueden calcularse a partir de las derivadas de la función característica en el origen

$$m_n = \frac{1}{i^n} \varphi_X^{(n)}(t) \Big|_{t=0}.$$

Un concepto fundamental en probabilidades es el de la independencia.

Definición 13.11 Dos sucesos $A, B \in \mathcal{F}$ se dicen **independientes** si

$$P(A \cap B) = P(A)P(B).$$

Si se tiene una sucesión finita o infinita de sucesos $\{A_i, i \in I\}$, se dice que los sucesos de la colección son independientes si

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \dots P(A_{i_k})$$

para todo conjunto finito de índices $\{i_1, \dots, i_k\} \subset I$.

Una colección de conjuntos de sucesos $\{\mathcal{G}_i, i \in I\}$ se dice que es independiente si cualquier colección de sucesos $\{A_i, i \in I\}$ tal que $A_i \in \mathcal{G}_i$ para todo $i \in I$ es independiente.

Una colección de variables aleatorias $\{X_i, i \in I\}$ se dice que es independiente si la colección de σ -álgebras $\{X_i^{-1}(\mathcal{B}_{\mathbb{R}^n}), i \in I\}$ lo es. Esto significa que

$$P(X_{i_1} \in B_{i_1}, \dots, X_{i_k} \in B_{i_k}) = P(X_{i_1} \in B_{i_1}) \dots P(X_{i_k} \in B_{i_k}),$$

para todo conjunto finito de índices $\{i_1, \dots, i_k\} \subset I$, donde los B_j son conjuntos de Borel.

Si dos variables aleatorias reales X e Y son independientes y tienen esperanza finita, el producto XY tiene esperanza finita y se cumple que $E(XY) = E(X)E(Y)$.

En general, si las variables $X_1, \dots, X_n$ son independientes,

$$E[g_1(X_1) \dots g_n(X_n)] = E[g_1(X_1)] \dots E[g_n(X_n)].$$

donde las g_i son funciones medibles tales que $E[|g_i(X_i)|] < \infty$.

Las componentes de un vector aleatorio de variables aleatorias son independientes si y sólo si su densidad o función de probabilidad es igual al producto de las densidades o funciones de probabilidad de cada componente.

Definición 13.12 La **probabilidad condicionada** de un suceso A por un suceso B , suponiendo $P(B) > 0$, se define como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

Dos sucesos A y B son independientes si y sólo si $P(A|B) = P(A)$. La probabilidad condicionada $P(A|B)$ representa la probabilidad del suceso A suponiendo sabemos que B ha ocurrido. La aplicación $A \mapsto P(A|B)$ define una nueva probabilidad en el σ -álgebra $\mathcal{F}$ que se concentra en el conjunto B . Se puede calcular la *esperanza condicionada* por B de una variable aleatoria integrable X :

$$E(X|B) = \frac{1}{P(B)} E(X \mathbf{1}_B),$$

donde $\mathbf{1}_B$ representa la *función indicatriz* del suceso B , definida por

$$\mathbf{1}_B = \begin{cases} 1 & \text{si } \omega \in B \\ 0 & \text{si } \omega \notin B. \end{cases}$$

13.2 Procesos estocásticos

Definición 13.13 Un **proceso estocástico** es una familia de variables aleatorias reales $\{X_t, t \geq 0\}$, es decir, de funciones medibles, $X_t(\omega) : \Omega \rightarrow \mathbb{R}$, definidas en un espacio de probabilidad $(\Omega, \mathcal{F}, P)$, e indexadas en un conjunto $\mathcal{T} \in [0, \infty)$. A $t \rightarrow X_t(\omega)$ se le denomina función de muestra o **trayectoria** del proceso estocástico. Si $\mathcal{T} = \mathbb{N}$ el proceso estocástico se dice **discreto**. Si $\mathcal{T} = [0, \infty)$ el proceso se denomina **continuo**.

En la figura 13.1 se ven cuatro muestras de un proceso estocástico. El valor de $X(t)$ cambia con el tiempo y de muestra a muestra.




Figura 13.1

Si fijamos un conjunto finito de instantes $\{0 \leq t_1 < \dots < t_n\}$ tendremos un vector aleatorio $(X_{t_1}, \dots, X_{t_n}) : \Omega \rightarrow \mathbb{R}^n$. Las distribuciones de probabilidad $P_{t_1, \dots, t_n} = P \circ (X_{t_1}, \dots, X_{t_n})^{-1}$ se denominan *distribuciones en dimensión finita* del proceso.

La *media* (muestral) y la *autocovarianza* de un proceso estocástico se definen así:

$$\begin{aligned} m_X(t) &= E(X_t) \\ \Gamma_X(s, t) &= \text{Cov}(X_s, X_t) \\ &= E((X_s - m_X(s))(X_t - m_X(t))). \end{aligned}$$

La *varianza* (muestral) del proceso X se define por $\sigma_X^2(t) = \Gamma_X(t, t) = \text{Var}(X_t)$.

Se dice que un proceso estocástico $\{X_t, t \geq 0\}$ es *gaussiano* o *normal* si sus distribuciones en dimensión finita son leyes normales multidimensionales. En el caso de un proceso estocástico gaussiano, la media $m_X(t)$ y la autocovarianza $\Gamma_X(s, t)$ determinan las distribuciones de dimensión finita del proceso.

La media $m_X(t)$ y la varianza $\sigma_X^2(t)$ nos permiten conocer dónde se concentran los valores de la variable X_t así como su grado de dispersión, para cada instante t fijo. Por ejemplo, en el caso de un proceso gaussiano,

$$P(m_X(t) - 2\sigma_X(t) \leq X_t \leq m_X(t) + 2\sigma_X(t)) \simeq 0,95.$$

Un proceso estocástico $\{X_t, t \geq 0\}$ es continuo en probabilidad si para todo $\varepsilon > 0$ y todo $t \geq 0$, $\lim_{s \rightarrow t} P(|X_y - X_s| > \varepsilon) = 0$. Si el proceso tiene una $E(|X_t|^p) < \infty$

para todo $t \geq 0$, con $p \geq 1$, se dice que el proceso es continuo en media de orden p si $\lim_{s \rightarrow t} E(|X_t - X_s|^p) = 0$. La continuidad en media de orden p implica la continuidad en probabilidad. La continuidad de media de orden p no implica necesariamente la continuidad de las trayectorias.

Acotaciones adecuadas de los momentos de los incrementos del proceso, permiten deducir la continuidad de las trayectorias. Este es el contenido del siguiente criterio de continuidad, debido a Kolmogorov.

Proposición 13.1 *Criterio de continuidad de Kolmogorof. Supongamos que un proceso estocástico $\{X_t, t \geq 0\}$ cumple la condición siguiente:*

$$E(|X_t - X_s|^p) \leq c_T |t - s|^\alpha$$

para todo $0 \leq s < t \leq T$, donde $\alpha > 1$ y $p > 0$. Entonces existe una versión del proceso estocástico X_t que tiene trayectorias continuas.

Toma su nombre de Andréi Nikoláyevich Kolmogórov, Rusia 1903-1987.



13.2.1 Ejemplos

Sea $X(t) = A \cos(10t)$, $t \geq 0$, donde A es una variable aleatoria uniformemente distribuida en el intervalo $[0, 1]$. $X(t)$ es un proceso estocástico pues para cada tiempo dado t_0 , $X(t_0)$ es una variable aleatoria uniforme. En la figura 13.2 se ven tres ejemplos de $X(t)$, para $0 \leq t \leq 1$.




Figura 13.2

13.2.1.1 Proceso de Bernoulli

Debido a Daniel Bernoulli, Groningen (Países Bajos), 1700-Basilea, Suiza, 1782.



Es uno de los procesos estocásticos más simples. Los constituyen secuencias de variables aleatorias independientes e idénticamente distribuidas, cada una de las cuales toma el valor 1, con probabilidad p , o el 0, con probabilidad $1 - p$.

Un ejemplo típico es el de lanzar al aire una moneda un número de veces. Cada lanzamiento lo representa una variable aleatoria de Bernoulli con probabilidad p de que salga cara y $1 - p$ de que salga cruz.

13.2.1.2 Paseo aleatorio

Bajo esta denominación tan general se encuentran un buen número de procesos estocásticos.

Definición 13.14 Un **paseo aleatorio** es una sucesión $S_n = \sum_{i=1}^n \xi_i$, donde las ξ_i son variables aleatorias independientes idénticamente distribuidas y definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{F}, P)$. Cuando las variables ξ_i toman valores enteros se dice que el paseo aleatorio lo es en valores discretos y cuando $\xi_i \in [-1, 1]$ el paseo aleatorio se denomina **simple**.

Un paseo aleatorio S_t se define en la recta real comenzando en $S_0 = 0$ y avanzando un paso de longitud ξ_i en cada unidad de tiempo entera i . Asumiremos que cada ξ_i es $+1$ o -1 con la misma probabilidad, igual a $1/2$.

El **movimiento browniano discreto** fue observado por primera vez por Robert Brown, Reino Unido, 1773-1857, en el movimiento irregular de los granos de polen en suspensión.



Se define como el paseo aleatorio dado por la sucesión de pasos acumulados

$$S_t = S_0 + \xi_1 + \xi_2 + \cdots + \xi_t, \quad t = 0, 1, 2, \dots$$

En la figura 13.3 se pueden ver dos desarrollos típicos de movimiento browniano discreto. El programa de MATLAB del cuadro 13.1 lleva a cabo un paseo aleatorio de 10 pasos.




Figura 13.3: Paseos aleatorios típicos

```
% Movimiento browniano de 10 pasos
%
t=10; w=0;
for i=1:t
    if rand>1/2
        w=w+1;
    else
        w=w-1;
    end
end
```

Cuadro 13.1

La esperanza matemática de cada paso ξ_i del paseo aleatorio S_t es $E(\xi_i) = (0,5)(1) + (0,5)(-1) = 0$. Su varianza $\text{Var}(\xi) = E[(\xi_i - 0)^2] = (0,5)(1)^2 + (0,5)(-1)^2 = 1$. La esperanza matemática del paseo aleatorio después de t pasos es $E(S_t) = E(\xi_1 + \dots + \xi_t) = E(\xi_1) + \dots + E(\xi_t) = 0$ y la varianza $\text{Var}(S_t) = \text{Var}(\xi_1 + \dots + \xi_t) = \text{Var}(\xi_1) + \dots + \text{Var}(\xi_t) = t$, pues la varianza es aditiva sobre las variables aleatorias independientes.

El hecho de que la media de S_t sea 0 y su varianza t indica que al calcular n diferentes desarrollos de la variable aleatoria S_t , la media muestral

$$m_S(t) = E(S_t) = \frac{S_t^1 + \dots + S_t^n}{n}$$

y la varianza muestral

$$\Gamma_S(t, t) = \text{Var}(S_t) = \frac{(S_t^1 - E_S)^2 + \dots + (S_t^n - E_S)^2}{n - 1}$$

deberían aproximarse a 0 y t , respectivamente. La *desviación estándar muestral*, que es

la raíz cuadrada de la varianza muestral, también se conoce como el error estándar de la media.

Si se reduce cada paso del paseo aleatorio en términos de amplitud y altura del mismo, por factores k y $1/\sqrt{k}$ respectivamente, se conseguirá que la esperanza matemática del proceso siga siendo la misma, al igual que la varianza. Esto es así pues la multiplicación de una variable aleatoria por una constante hace que su varianza cambie en términos de la raíz cuadrada de esa constante.

Si S_t^k es la variable aleatoria de paso $1/k$ del de S_t , y de altura un $\pm 1/\sqrt{k}$, con igual probabilidad, la esperanza matemática después de t pasos es

$$E(S_t^k) = \sum_{i=1}^{kt} E(S_i^k) = \sum_{i=1}^{kt} 0 = 0.$$

La varianza será

$$\text{Var}(S_t^k) = \sum_{i=1}^{kt} \text{Var}(S_i^k) = \sum_{i=1}^{kt} \left[\left(\frac{1}{\sqrt{k}} \right)^2 (0,5) + \left(-\frac{1}{\sqrt{k}} \right)^2 (0,5) \right] = \frac{kt}{k} = t.$$

La figura 13.4 muestra un paseo aleatorio discreto con 10 pasos y otro con $k = 25$, es decir con 250.





Figura 13.4

El límite de esta subdivisión de S_t cuando $k \rightarrow \infty$ da lugar al *movimiento browniano continuo* en el que t es una variable real y $W_t = S_t^\infty$ es una variable aleatoria para cada $t \geq 0$. Se conoce más concretamente como **Proceso de Wiener**, por Norbert Wiener, EE.UU. 1894-1964, que fue quien estableció en los años 20 del siglo XX el modelo

matemático del movimiento browniano basado en la teoría de los procesos estocásticos.



Definición 13.15 Un proceso estocástico $\{W_t, t \geq 0\}$ es un **proceso de Wiener** —o movimiento browniano continuo— en el espacio $(\Omega, \mathcal{F}, P)$ si se cumplen estas condiciones:

- I $W_0 = 0$.
- II Fijados unos instantes $0 \leq t_1 < \dots < t_n$, los incrementos $W_{t_n} - W_{t_{n-1}}, \dots, W_{t_2} - W_{t_1}$ son variables aleatorias independientes.
- III Si $s < t$, el incremento $W_t - W_s$ tiene una ley normal $N(0, t - s)$.
- IV Las trayectorias del proceso son funciones continuas.

La condición III es consecuencia del *teorema central del límite*.

El proceso de Wiener es un proceso gaussiano ya que la ley de un vector aleatorio $(W_{t_1}, \dots, W_{t_n})$ es normal ya que éste es una transformación lineal de $(W_{t_1}, W_{t_2} - W_{t_1}, \dots, W_{t_n} - W_{t_{n-1}})$ que tiene ley normal ya que tiene las componentes independientes y normales.

La esperanza matemática o media y la autocovarianza son

$$\begin{aligned} E(W_t) &= 0 \\ E(W_s W_t) &= E(W_s(W_t - W_s + W_s)) \\ &= E(W_s(W_t - W_s)) + E(W_s^2) = s = \min(s, t) \end{aligned}$$

si $s \leq t$. Si un proceso gaussiano tiene media cero y función de autocovarianza $\Gamma_X(s, t) = \min(s, t)$, cumple las condiciones I, II y III.

El programa de MATLAB del cuadro 13.2, que utiliza el generador de números aleatorios normales `randn`, genera un proceso de Wiener con un paso $\Delta t = 1/25$ como se veía en la figura 13.4.

```
% Proceso de Wiener de 250 pasos
%
k=250;
sqdelt=sqrt(1/25);
b=0;
for i=1:k
    b=b+sqdelt*randn;
end
```

Cuadro 13.2

13.2.1.3 Procesos de Poisson

Toman su nombre de Siméon Denis Poisson, Francia, 1781-1840.

Definición 13.16 Un proceso de Poisson $\{N_t, t \geq 0\}$ es un proceso estocástico caracterizado por las siguientes propiedades:

- I $N_0 = 0$.
- II Fijados unos instantes $0 \leq t_1 < \dots < t_n$, los incrementos $N_{t_n} - N_{t_{n-1}}, \dots, N_{t_2} - N_{t_1}$ son variables aleatorias independientes.
- III Si $s < t$, el incremento $N_t - N_s$ tiene una ley de Poisson de parámetro $\lambda(t - s)$, es decir

$$P(N_t - N_s = k) = e^{-\lambda(t-s)} \frac{[\lambda(t-s)]^k}{k!}, \quad k = 0, 1, 2, \dots$$

Un proceso de Poisson se construye a partir de una sucesión $\{Y_n, n \geq 1\}$ de variables aleatorias independientes y con una ley geométrica de parámetro λ . Es decir, para todo $x \geq 0$, $P(Y_n \geq x) = e^{-\lambda x}$. Si se hace $T_0 = 0$ y para $n \geq 1$, $T_n = Y_1 + \dots + Y_n$, entonces el proceso N_t definido por $N_t = n$ si $T_n \leq t < T_{n+1}$ es un proceso de Poisson de parámetro λ , denominado *intensidad*.

Las trayectorias del proceso de Poisson tienen saltos de amplitud 1 y son constantes en cada par de saltos. Los tiempos entre cada par de saltos son variables aleatorias independientes con leyes exponenciales de parámetro λ . Las trayectorias no son continuas, aunque si lo son en media cuadrática:

$$\begin{aligned} E[(N_t - N_s)^2] &= \sum_{k=1}^{\infty} e^{-\lambda(t-s)} \frac{k^2 [\lambda(t-s)]^k}{k!} \\ &= \lambda(t-s) + [\lambda(t-s)]^2 \xrightarrow{s \rightarrow t} 0. \end{aligned}$$

13.2.1.4 Procesos de Markov

Toman su nombre de Andrey Andreyevich Markov, Rusia 1856-1922.



Definición 13.17 Un proceso estocástico $\{X_n, n \geq 0\}$, en el que las variables aleatorias están definidas en un espacio medible, es un **proceso o cadena de Markov** si para cualquier n y cualquier conjunto A se cumple que $P(X_{n+1} \in A | X_0, \dots, X_n) =$

$P(X_{n+1} \in A|X_n)$. A los procesos que se comportan de esta manera se dicen, en general, que cumplen la **propiedad de Markov**.

Lo que quiere decir que dado el presente cualquier otra información del pasado es redundante o irrelevante para predecir el futuro. La definición es equivalente a la identidad $E(f(X_{n+1})|X_1, \dots, X_n) = E(f(X_{n+1})|X_n)$.

Los procesos de Bernoulli, Wiener, brownianos y de Poisson son procesos que cumplen esta propiedad.

13.3 Simulación

Los modelos matemáticos, para ser creíbles y robustos ante distintos escenarios de actuación, necesitan simular sus prestaciones a partir de patrones de situaciones ya dadas o de datos imaginados. Esto permite analizarlos para conocer sus debilidades numéricas o teóricas y así mejorarlos. Si se alimentan con datos que fijen un punto de partida adecuado y unas condiciones de contorno previsibles, pueden permitir, con el resultado de su operación, tomar decisiones con un grado de certeza o riesgo más o menos aceptable de acuerdo con el grado de dificultad o entidad de la decisión.

Los modelos de procesos estocásticos se basan en situaciones probables, aunque inciertas, dentro de unos determinados márgenes de actuación. Su evolución es aleatoria y dotada de ruido por lo que para simular su comportamiento es necesario generar números aleatorios que imiten o reproduzcan hasta donde sea posible ese ruido o aleatoriedad. En los apartados anteriores hemos presentado unos ejemplos muy sencillos de cómo hacer unas modestas simulaciones con la ayuda de MATLAB para generar paseos aleatorios, procesos de Wiener, etc.

Aunque todos disponemos intuitivamente de una cierta noción de un número aleatorio, no es nada fácil definirlo con precisión. Tampoco es fácil imaginar cómo generarlos mediante una máquina y que su patrón de ocurrencia responda a una distribución concreta como la normal, la exponencial, la gaussiana, etc.

13.3.1 Generación de números aleatorios

Aunque el objetivo a alcanzar sería producir números aleatorios sucesivamente de tal manera que cualquiera de ellos fuese absolutamente independiente de los anteriores y su distribución idéntica, independientemente de su posición en el orden dado, lo cierto es que tal aspiración, con los medios finitos de que disponemos y con el sistema de numeración implícito en los ordenadores actuales tan limitado, es imposible. Sí se pueden conseguir números *pseudo-aleatorios* o *cuasi-aleatorios* con patrones de aproximación a las características ideales más o menos adecuadas al objetivo en cada caso.

La mayoría de los números aleatorios generados por los ordenadores actuales son pseudo-aleatorios, donde la secuencia se repite a partir de un “cebado” inicial con una frecuencia determinada. Las prestaciones de estos números es buena en general, pero no son tan aleatorios como, por ejemplo, los sofisticados números generados por el ruido

atmosférico electromagnético utilizado como fuente de entropía.

La serie de valores pseudo-aleatorios generados está generalmente determinada por un número fijo llamado semilla (*seed*), que desencadena la sucesión. Uno de los algoritmos más comunes es el denominado *congruencial lineal* que utiliza la fórmula de recurrencia $x_{n+1} = (ax_n + b) \bmod m$, donde a , b y m son números enteros grandes. El número máximo de números que la fórmula puede producir es el módulo m .

La mayoría de los lenguajes de programación informática incluyen funciones o rutinas que proporcionan números aleatorios. El generador de números aleatorios más utilizado y reconocido en la actualidad se basa en el algoritmo **Mersenne Twister**, del tipo *minimal standard random number generator*. Se suele inicializar utilizando como semilla el reloj de tiempo real del ordenador. Su nombre proviene de un monje, Marin Mersenne, Francia 1588-1648, que estudió los números primos que llevan su nombre (primos iguales a una potencia de 2 menos 1).



Ejemplo 13.8 Vamos a utilizar este generador de números aleatorios para, siguiendo a Sauer [2012], y adelantándonos a la introducción de la técnica Monte Carlo, calcular el área del conjunto de puntos (x, y) que satisfacen

$$4(2x - 1)^4 + 8(2y - 1)^8 < 1 + 2(2y - 1)^3(3x - 2)^2.$$

La idea es generar 10.000 pares de puntos (x, y) de tal manera que los que cumplan esta inecuación se registran. Al final del proceso se cuentan cuántos de estos hay en total, y esa cantidad dividida por 10.000 nos dará el área más probable que encierra a ese conjunto de puntos. En la figura 13.5 se puede ver el resultado de la simulación —que numéricamente es 0,547— y el área cubierta por los puntos que cumplen la inecuación.

Un pequeño código de MATLAB para llevar a efecto estos cálculos se lista en el cuadro 13.3. Se puede ensayar con diversos valores de n para comprobar el resultado.

13.3.2 Simulación de variables aleatorias

Teniendo un generador de números aleatorios (o pseudo-aleatorios), **rand**, suficientemente bueno, podremos simular variables aleatorias con distribuciones diferentes de la uniforme en $[0, 1]$. Esto se logra casi siempre mediante transformaciones de lo producido por ese generador con métodos como los que siguen.




Figura 13.5

```
function x=MoCa_1(n)
xy=rand(n,2); k=0;
for i=1:n
    if 4*(xy(i,1)*2-1)^4+8*(2*xy(i,2)-1)^8<1+2*(2*xy(i,2)-1)^3*(3*xy(i,1)-2)^2
        k=k+1;
    end
end
x=k/n;
end
```

Cuadro 13.3

13.3.2.1 Variables aleatorias discretas

Si X tiene una distribución de probabilidad discreta dada por los pares suceso-probabilidad de la matriz que sigue

$$X = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix},$$

se definen unos números $0 = q_0 < q_1 < \cdots < q_n = 1$ tales que

$$q_0 = 0, q_1 = p_1, q_2 = p_1 + p_2, \dots, q_n = p_1 + p_2 + \cdots + p_n = 1.$$

Para simular la variable aleatoria discreta X se utiliza el generador **rand** y se hace igual a x_1 si $0 \leq \mathbf{rand} < q_1$, x_2 si $q_1 \leq \mathbf{rand} < q_2$, y así sucesivamente. Si la distribución de probabilidad es muy extensa, se puede truncar a un valor de n suficientemente grande.

13.3.2.2 El método de las funciones inversas

Se basa en que si X es una variable aleatoria con una función de distribución F_X , la variable aleatoria $Y = F_X(X)$ está uniformemente distribuida en $[0, 1]$. Invirtiendo la función de distribución F_X y aplicándola a Y se puede recuperar X .

Si se quiere simular una variable aleatoria con una función de distribución invertible F , primero se simula una variable aleatoria uniforme en $[0, 1]$ y luego se le aplica al resultado la función F^{-1} . El método falla, por supuesto, si no se puede explicitar F^{-1} .

Ejemplo 13.9 Apliquemos este método para simular una variable aleatoria X con distribución exponencial y parámetro λ . Recordemos que la función de densidad de probabilidad en este caso es $f_X(x) = \lambda e^{-\lambda x}$, $x > 0$, por lo que $F_X = 1 - e^{-\lambda x}$, $x > 0$, y

$$F_X^{-1}(y) = -\frac{1}{\lambda} \log(1 - y).$$

Como $1 - \text{rand}$ tiene la misma distribución en $[0, 1]$ que rand , se deduce que $-\log(\text{rand})/\lambda$ tiene la distribución exponencial con parámetro λ que se desea obtener. ●

13.3.2.3 El método de Box-Müller

Este método se usa para simular variables aleatorias con distribución normal. Toma su nombre del trabajo de George Edward Pelham Box, Reino Unido 1919-EE.UU. 2013,



y Mervin Edgar Müller. Se basa en este resultado.

Proposición 13.2 Dadas dos variables Y_1 e Y_2 uniformemente distribuidas en $[0, 1]$, las variables aleatorias

$$X_1 = \sqrt{-2 \log(1 - Y_1)} \cos(2\pi Y_2) \text{ y } X_2 = \sqrt{-2 \log(1 - Y_1)} \sin(2\pi Y_2)$$

son independientes y de distribución normal $N(0, 1)$.

De acuerdo con él, para simular una variable aleatoria de distribución normal de media $\mu = 0$ y varianza $\sigma^2 = 1$, se puede utilizar rand para obtener dos números, rand1 y rand2 de tal manera que

$$X_1 = \sqrt{-2 \log(\text{rand1})} \cos(2\pi \text{rand2}) \text{ y } X_2 = \sqrt{-2 \log(\text{rand1})} \sin(2\pi \text{rand2})$$

sean dos variables aleatorias normales independientes.

13.3.2.4 Método basado en el teorema central del límite

Habitualmente se usa este procedimiento para simular una variable aleatoria normal:

1. Simular doce variables independientes $X_1, X_2, \dots, X_{12}$ uniformemente distribuidas mediante rand .

2. Hacer $Y = X_1 + X_2 + \cdots X_{12} - 6$.

La distribución de la variable aleatoria Y es muy próxima a una normal pero no exactamente (pues $P(Y > 6) = 0$ pero $P(Z > 6) \neq 0$ para una auténtica normal). Esto es así como consecuencia de este resultado.

Teorema 13.3 Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias independientes que tienen la misma distribución. Sea $\mu = E(X_1) = E(X_2) = \cdots$ y $\sigma^2 = \text{Var}(X_1) = \text{Var}(X_2) = \cdots$. La sucesión de variables aleatorias normales

$$\frac{(X_1 + X_2 + \cdots X_n) - n\mu}{\sigma \sqrt{n}}$$

converge a una variable aleatoria normal.

El que se escojan 12 u otro número de variables depende de la experiencia y de la bondad de los resultados con la que se simulen los datos que se requieran.

13.3.2.5 Vector de variables

El esquema general para simular un vector de variables aleatorias normales de media μ y matriz de covarianzas Γ sería este:

1. Simular n variables aleatorias independientes y con ellas construir el vector $\boldsymbol{y}$.
2. Calcular la descomposición de Cholesky $\boldsymbol{A}^T \boldsymbol{A} = \Gamma$.
3. El vector que se necesita se obtiene haciendo $\boldsymbol{Y} = \boldsymbol{yA} + \mu$.

13.3.3 El método Montecarlo

Este método materializa mediante un procedimiento de cálculo el conocimiento de procesos estocásticos y sus resultados a base de llevar a cabo múltiples muestreos de los datos esenciales de las variables que constituyen los problemas que estudian y analizan. Contra más muestras se hagan del problema, y de la dinámica de como evoluciona éste, mejores serán los resultados que el procedimiento consiga. Ya hemos visto alguna de sus prestaciones y posibilidades para calcular el área dentro de una determinada curva.

En su versión moderna se debe al trabajo de Stanislaw Marcin Ulam, Lemberg, Austria-Hungría 1909-EE.UU. 1984 y John von Neumann, Budapest, Austria-Hungría 1903-EE.UU. 1957.



Von Neumann es, como decía Newton, **uno de los grandes gigantes** que ha dado la naturaleza humana. Sus contribuciones en los 53 años de su vida a múltiples disciplinas relacionadas con las matemáticas son absolutamente portentosas. No cabe duda de que a

hombros de él los avances de muchas áreas a las que dedicamos este libro han permitido ver e ir mucho más lejos de lo que él comenzó.

El método Montecarlo está basado en este interesante resultado.

Teorema 13.4 *Ley de los grandes números. Sea $X_1, X_2, \dots$ una sucesión de variables aleatorias independientes que tienen la misma distribución y la función $g : \mathbb{R} \rightarrow \mathbb{R}$ tal que $\mu = E[g(X_1)] = E[g(X_2)] = \dots$. Se cumple que*

$$\frac{g(X_1) + g(X_2) + \dots + g(X_n)}{n} \rightarrow \mu = \int_{-\infty}^{\infty} g(x) f_{X_1}(x) dx \quad \text{al } n \rightarrow \infty.$$

De acuerdo con él, la estrategia de cálculo del método de Montecarlo es la siguiente:

Supóngase que una cantidad que se quiere determinar se puede escribir como $y = \int_{-\infty}^{\infty} g(x) f_X(x) dx$ para alguna variable aleatoria X con función de densidad de probabilidad f_X , y para alguna función concreta g . También, que los números $x_1, x_2, \dots$ son muestras aleatorias de la distribución de f_X . Entonces, la media

$$\frac{1}{n}(g(x_1) + g(x_2) + \dots + g(x_n))$$

aproxima el valor de y con una precisión aproximada dada por $1/\sqrt{n}$.

En la actualidad se usa masivamente para calcular expectativas de precios de derivados financieros, predicciones de evolución en bolsa de determinados productos y posiciones, procesos estocásticos complicados, etc.

13.4 Ecuaciones diferenciales estocásticas

Una variante de las ecuaciones diferenciales cada día más extendida surge cuando la dinámica del proceso que modelizan está afectada por movimientos aparentemente aleatorios, o ruidos. En tal caso nos encontraremos con ecuaciones diferenciales estocásticas.

Lo que sigue es una breve introducción a la solución de las mismas, que son procesos estocásticos continuos como, por ejemplo, el movimiento browniano que acabamos de ver un poco más arriba.

La resolución de una ecuación diferencial ordinaria, convertida en ecuación diferencial estocástica —EDS—, trata de obtener la solución de

$$\begin{cases} dy = r dt + \sigma dB_t \\ y(0) = 0, \end{cases}$$

donde r y σ son constantes —coeficiente de deriva y coeficiente de difusión, respectivamente— y B_t un proceso estocástico, como el movimiento browniano. La solución tendrá la forma $y(t) = rt + \sigma B_t$.

Muchos procesos estocásticos, como el movimiento browniano, son continuos pero no diferenciables. La EDS

$$dy = f(t, y) dt + g(t, y) dB_t$$

expresa por definición la ecuación

$$y(t) = y(0) + \int_0^t f(s, y) ds + \int_0^t g(s, y) dB_s,$$

donde la segunda integral se denomina *integral de Itô*. Su nombre proviene de Kiyosi Itô, Japón 1915-2008.



La integral de Itô, de forma parecida a como se define la integral de Riemann, es

$$\int_a^b f(t) dB_t = \lim_{\Delta t \rightarrow 0} \sum_{i=1}^n f(t_{i-1}) \Delta B_i,$$

donde $\Delta B_i = B_{t_i} - B_{t_{i-1}}$, es un paso browniano a lo largo del intervalo de integración.

La integral de Itô, $I = \int_a^b f(t) dB_t$ es una variable aleatoria. El diferencial dI es $dI = f dB_t$. El diferencial dB_t se denomina *ruido blanco*.

Si en la ecuación diferencial estocástica $dy(t) = r dt + \sigma dB_t$, $y = f(t, x)$, la regla de la cadena en términos estocásticos define la *fórmula de Itô*

$$dy = \frac{\partial f}{\partial t}(t, x) dt + \frac{\partial f}{\partial x}(t, x) dx + \frac{1}{2} \frac{\partial^2 f}{\partial x^2}(t, x) dx dx,$$

donde $dx dx$ se puede interpretar en términos de $dt dt = 0$, $dt dB_t = dB_t$, $dt = 0$ y $dB_t dB_t = dt$.

La fórmula de Itô permite resolver explícitamente algunas ecuaciones diferenciales estocásticas.

Ejemplo 13.10 Comprobemos si la ecuación de movimiento browniano geométrico

$$y(t) = y_0 e^{(r - \frac{1}{2}\sigma^2)t + \sigma B_t}$$

satisface la ecuación diferencial estocástica

$$dy = ry dt + \sigma y dB_t.$$

Hagamos $y = f(t, x) = y_0 e^x$, donde $x = (r - \frac{1}{2}\sigma^2)t + \sigma B_t$. Mediante la fórmula

$$dy = y_0 e^x + \frac{1}{2} y_0 e^x dx dx,$$

donde $dx = (r - \frac{1}{2}\sigma^2)dt + \sigma dB_t$. Haciendo uso de los valores diferenciales de la fórmula de Itô, se tiene que $dx dx = \sigma^2 dt$. En consecuencia,

$$\begin{aligned} dy &= y_0 e^x \left(r - \frac{1}{2}\sigma^2 \right) dt + y_0 e^x \sigma dB_t + \frac{1}{2} y_0 \sigma^2 e^x dt \\ &= y_0 e^x r dt + y_0 e^x \sigma dB_t \\ &= ry dt + \sigma y dB_t. \end{aligned}$$

Esta ecuación se utiliza habitualmente en modelos financieros. En concreto, es la fórmula detrás del modelo de Black-Scholes para poner precio a los derivados financieros. ●

Muchas ecuaciones diferenciales estocásticas no pueden resolverse explícitamente. Por ello es conveniente disponer de métodos numéricos que permiten la simulación de soluciones.

13.4.1 Integración numérica de ecuaciones diferenciales estocásticas

El método de Euler-Maruyama, similar al de Euler para integrar EDO, toma su nombre de Gisiro Maruyama, Japón 1916-1986.



Se trata de resolver el problema

$$\begin{cases} dy(t) = f(t, y) dt + g(t, y) dB_t \\ y(a) = y_a \end{cases}$$

Se subdivide el intervalo de integración $[a, b]$ en n subintervalos de longitud Δt_i .

La fórmula de recurrencia que utiliza es

$$w_{i+1} = w_i + f(t_i, w_i)\Delta t_i + g(t_i, w_i)\Delta B_i.$$

En ella $\Delta t_i = t_{i+1} - t_i$, $\Delta B_i = B_{t_{i+1}} - B_{t_i}$ y $w_0 = y_a$.

Lo crucial es modelizar el movimiento browniano ΔB_i . Para ello basta con obtener valores de n variables aleatorias $\xi_1, \dots, \xi_n$ independientes con ley $N(0, 1)$ y substituir ΔB_i por $\xi_i \sqrt{\Delta t_i}$.

El error que comete este procedimiento al aproximar $y(T)$ por $w(T)$, en función del Δt escogido es

$$e = E[|y(T) - w(T)|]^2 \leq c(\Delta t)^{1/2}.$$

El método de Euler-Maruyama puede mejorarse mediante una corrección adicional como la que introduce el método de Grigori N. Milstein. Su idea es incorporar más información de segundas derivadas a los procesos $f(t, y)$ y $g(t, y)$ de la ecuación diferencial estocástica, con el concurso de la fórmula de Itô. La fórmula de recurrencia que utiliza es esta:

$$w_{i+1} = w_i + f(t_i, w_i)\Delta t_i + g(t_i, w_i)\Delta B_i + \frac{1}{2}g(t_i, w_i)\frac{\partial g}{\partial y}(t_i, w_i)((\Delta B_i)^2 - \Delta t_i).$$

El error que se comete en este caso es $e = E[|y(T) - w(T)|]^2 \leq c(\Delta t)$.

Una mejora de esta variante la constituye la que incorpora la idea de los métodos de Runge-Kutta en el caso de ecuaciones diferenciales ordinarias. Su objetivo es evitar la necesidad del cálculo de las derivadas parciales que requiere lo propuesto por Milstein, aproximándolas mediante la fórmula

$$\frac{\partial g}{\partial y}(t_i, w_i) \approx \frac{g(t_i, w_i + g(t_i, w_i)\sqrt{\Delta t_i}) - g(t_i, w_i)}{g(t_i, w_i)\sqrt{\Delta t_i}}.$$

La fórmula de recurrencia queda así:

$$w_{i+1} = w_i + f(t_i, w_i)\Delta t_i + g(t_i, w_i)\Delta B_i + \frac{1}{2\sqrt{\Delta t_i}} \left[g(t_i, w_i + g(t_i, w_i)\sqrt{\Delta t_i}) - g(t_i, w_i) \right] [(\Delta B_i)^2 - \Delta t_i].$$

13.5 Aplicación del cálculo estocástico a la cobertura y valoración de derivados financieros. El modelo de Black y Scholes

El área financiera, tan omnipresente en nuestras vidas en la actualidad, es donde probablemente más uso se hace de la simulación y optimización de procesos estocásticos.

Los derivados financieros son instrumentos cuyo valor *deriva* de otro instrumento. En particular, una *opción* es el derecho a llevar a efecto una determinada transacción financiera sin estar obligado a ello.

Una *opción de compra* (*European call option*) da a su comprador el derecho a comprar una acción o activo a un precio predeterminado —*strike price*— en una fecha concreta —*exercise date*—. El vendedor de la opción de compra tiene la obligación de vender el activo en el caso de que el comprador ejerza el derecho a comprar. Las opciones se usan por las empresas para gestionar el riesgo de sus operaciones especulativas y posiciones financieras. Los particulares las usan como estrategias de inversión y para cubrir

riesgos en otras operaciones. Todo esto conforma todo un entramado hoy en día difícilmente controlable y entendible por sus infinidad de ramificaciones e interpretaciones. Ni qué decir tiene que los cálculos para valorar opciones y los datos en qué basarlos no están al alcance de cualquiera, por lo que son las grandes corporaciones o los analistas y gestores especializados los que saben cómo usarlos y cuándo.

En estas breves líneas simplemente esbozamos cómo se puede calcular el precio de esas opciones y el modelo de Black y Scholes, por Fischer Sheffey Black, EE.UU. 1938-1995, y Myron Samuel Scholes, EE.UU. 1941,



que a la postre les valió para conseguir el Premio Nobel de Economía.

Un sencillo ejemplo para contextualizar las fórmulas que emplearemos se refiere a una opción de compra de acciones de la compañía IBD por 15 € el 1 de diciembre. Si el precio de las acciones de esta compañía, tan aparentemente atractiva, el 1 de junio está en 12 €, la pregunta es ¿cuál es el valor de esa opción o derecho de compra? El valor o precio de la acción el día del vencimiento será K euros. Si X es el valor de la acción en un momento dado, el de la opción esperable será el $\max\{X - K, 0\}$. Si $X > K$, el valor de la opción el día de la ejecución es positivo e igual a $X - K$ euros. Si $X < K$ el valor será cero para el comprador de la opción.

El modelo para valorar estos derivados se basa en un movimiento browniano de tipo geométrico con la fórmula

$$dX = mX dt + \sigma X dB_t,$$

donde m es la deriva, o *tasa de crecimiento* del precio de la acción, y σ es la constante de difusión, o *volatilidad*. Estos dos parámetros se pueden estimar estadísticamente en función de los valores a los que ha cotizado la acción los últimos tiempos.

El razonamiento de Black y Scholes para deducir su fórmula se basa en considerar —una propuesta de arbitraje al respecto, nada más— que el valor correcto de esa opción, a T meses o años vista, debería ser el valor presente del valor esperado de la opción el día de su vencimiento teniendo en cuenta que el valor real de la acción subyacente $X(t)$ satisface la ecuación diferencial estocástica

$$dX = rX dt + \sigma X dB_t.$$

Esto resulta en que si el precio de la acción objeto de análisis es $X = X_0$ en el instante $t = 0$, el valor esperable de la opción en el instante de su vencimiento $t = T$ es

$$C(X, T) = e^{-rT} E[\max(X(T) - K, 0)],$$

donde $X(t)$ es el valor determinado por la ecuación diferencial estocástica anterior. Lo sorprendente de esta fórmula es que la deriva m se reemplaza por la tasa de interés o rentabilidad r . De hecho, el previsible crecimiento de la cotización de la acción es irrelevante para el valor de la opción, lo cual se desprende de la suposición de no arbitrage, base de la teoría de Black y Scholes, que viene a decir que no existen ganancias libres de riesgos en un mercado realmente eficiente.

La última fórmula depende del valor de la esperanza matemática de la variable aleatoria $X(t)$, que sólo se puede conocer mediante simulación, como sabemos. Si se aporta esa información, la expresión compacta del valor de la opción que dedujeron Black y Scholes es

$$C(X, T) = XN(d_1) - Ke^{-rT}N(d_2),$$

donde $N(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-s^2/2} ds$ es la función de distribución normal acumulada,

$$d_1 = \frac{\ln(X/K) + (r + \frac{1}{2}\sigma^2) T}{\sigma\sqrt{T}} \quad \text{y} \quad d_2 = \frac{\ln(X/K) + (r - \frac{1}{2}\sigma^2) T}{\sigma\sqrt{T}}.$$

Bibliografía

- [1] AASEN, J.O. 1971. *On the Reduction of a Symmetric Matrix to Tridiagonal Form*. BIT 11, pp. 233-242.
- [2] ABADIE, J. ED. 1970. *Integer and Nonlinear Programming*. North-Holland.
- [3] ABERTH, O. 2007. *Introduction to Precise Numerical Methods*. Elsevier.
- [4] ABELL, M.L. Y BRASELTON, J.P. 2004. *Mathematica by Example*. Elsevier.
- [5] ACTON, F.S. 1990. *Numerical Methods that Work*. The Mathematical Association of America.
- [6] ADAMS, J.C., BRAINERD, W.S., MARTIN, J.T., SMITH, B.T. Y WAGENER, J.L. 1992. *Fortran 90 Handbook. Complete ANSI/ISO Reference*. McGraw-Hill.
- [7] ADOBE SYSTEMS INCORPORATED. 1986. *PostScript Language. Tutorial and Cookbook*. Addison-Wesley.
- [8] ADOBE SYSTEMS INCORPORATED. 1990. *PostScript Language. Reference Manual*. Addison-Wesley.
- [9] AHUJA, R.K., MAGNATI, T.L. Y ORLIN, J.B. 1989. *Network Flows*. En *Handbooks in Operations Research and Management Science*. Volume 1: Optimization. Nemhauser, G.L., Rinnooy Kan, A.H.G. y Todd, M.J. eds. North-Holland.
- [10] ALJ, A. Y FAURE, R. 1988. *Investigación operativa. Elementos fundamentales*. Vol. 1. Masson.
- [11] ALVARADO, F.L. 1979. *A Note on Sorting Sparse Matrices*. Proceedings of the IEEE 67, pp. 1362-1363.
- [12] ALVARADO, F.L. 1990. *Manipulation and Visualization of Sparse Matrices*. ORSA J. Computing 2, pp. 186-207.
- [13] ALLAIRE, G. Y KABER, S.M. 2008. *Numerical Linear Algebra*. Springer.
- [14] ANDERS, G.J. 1990. *Probability Concepts in Electric Power Systems*. Wiley.
- [15] ANDERSON, E., BAI, Z., BISCHOF, C., DEMMEL, J., DONGARRA, J., DU CROZ, J., GREENBAUM, A., HAMMARLING S., MCKENNEY, A., OSTROUCHOV, S. Y SORENSEN, D. 1992. *LAPACK User's Guide*. SIAM.
- [16] ANDERSON, E., BAI, Z., BISCHOF, C., DEMMEL, J., DONGARRA, J., DU CROZ, J., GREENBAUM, A., HAMMARLING S., MCKENNEY, A., OSTROUCHOV, S. Y SORENSEN, D. 1995. *LAPACK User's Guide*. Second Edition. SIAM.
- [17] ANTONIOU, A. Y LU, W-S. 2007. *Practical Optimization. Algorithms and Engineering Applications*. Springer.

- [18] ARBEL, A. 1993. *Exploring Interior-Point Linear Programming. Algorithms and Software*. MIT Press.
- [19] ARMIJO, L. 1966. *Minimization of Functions Having Lipschitz Continuous First Partial Derivatives*. Pacific J. Math. 16, pp. 1-3.
- [20] ARRILLAGA, J. Y ARNOLD, C.P. 1990. *Computer Analysis of Power Systems*. Wiley.
- [21] ASCHER, U.M. Y GREIF, C. 2011. *A First Course in Numerical Methods*. SIAM.
- [22] ATKINSON, K. 1993. *Elementary Numerical Analysis*. Wiley.
- [23] ATKINSON, K. Y HAN, W. 2009. *Theoretical Numerical Analysis. A Functional Analysis Framework*. Third Edition, Springer.
- [24] ATKINSON, K., HAN, W. Y STEWART, D.E. 2009. *Numerical Solution of Ordinary Differential Equations*. Wiley.
- [25] ATKINSON, L.V., HARLEY, P.J. Y HUDSON, J.D. 1989. *Numerical Methods with Fortran 77. A Practical Introduction*. Addison-Wesley.
- [26] ATTAWAY, S. 2012. *MATLAB. A Practical Introduction to Programming and Problem Solving*. Elsevier.
- [27] ATTEIA, M. Y PRADEL, M. 1990. *Éléments d'Analyse Numérique*. Cepadues-Editions.
- [28] AUZINGER, W. 2013. *Iterative Solution of Large Linear Systems*. TU Wien, Institute for Analysis and Scientific Computing.
<http://www.asc.tuwien.ac.at/~winfried/teaching/101.403/SS2012/downloads/iter.pdf>
- [29] AVRIEL, M. 1976. *Nonlinear Programming. Analysis and Methods*. Prentice Hall.
- [30] AXELSSON, O. 1996. *Iterative Solution Methods*. Cambridge.
- [31] BARRETT, R., BERRY, M., CHAN, T.F., DEMMEL, J., DONATO, J.M., DONGARRA, J., EIJKHOUT, V., POZO, R., ROMINE, C. Y VAN DER VORST, H. 1994. *Templates for the Solution of Linear Systems: Building Blocks for Iterative Methods*. Second Edition. SIAM.
- [32] BÁRISOV, A.S. 1988. *Qué es la Programación Lineal*. Editorial Mir.
- [33] BARTELS, R.H. Y GOLUB, G.H. 1969. *The Simplex Method of Linear Programming Using LU Decomposition*. Communications of the ACM 12, pp. 266-268.
- [34] BASHIROV, A.E. 2014. *Mathematical Analysis Fundamentals*. Elsevier.
- [35] BAZARAA, M.S. Y JARVIS, J.J. 1977. *Linear Programming and Network Flows*. Wiley.
- [36] BAZARAA, M.S., JARVIS, J.J. Y SHERALI, H.D. 1990. *Linear Programming and Network Flows*. Wiley.
- [37] BAZARAA, M.S. Y SHETTY, C.M. 1979. *Nonlinear Programming. Theory and Algorithms*. Wiley.
- [38] BAZARAA, M.S., SHERALI, H.D. Y SHETTY, C.M. 1994. *Nonlinear Programming. Theory and Algorithms*. Second Edition. Wiley.
- [39] BEALE, E.M.L. 1954. *An Alternative Method for Linear Programming*. Proceedings of the Cambridge Philosophical Society 50, pp. 513-523.
- [40] BEASLEY, J.E. 1996. *Advances in Linear and Integer Programming*. Oxford University Press.
- [41] BECKMANN, M.J. 1968. *Dynamic Programming of Economic Decisions*. Springer.
- [42] BELLMAN, R. Y DREYFUS, S.E. 1962. *Applied Dynamic Programming*. Princeton University Press.
- [43] BELLMAN, R. 1970. *Introduction to Matrix Analysis*. SIAM.

-
- [44] BELLMAN, R. 1972. *Dynamic Programming*. Princeton University Press.
 - [45] BELLMAN, R. 1985. *Introducción al análisis matricial*. Editorial Reverté.
 - [46] BERGE, C. 1970. *Graphes et Hypergraphes*. Dunod.
 - [47] BEN-TAL, A. Y NEMIROVSKI, A. 2001. *Lecture Notes on Modern Convex Optimization. Analysis, Algorithms, and Engineering Applications*. SIAM.
 - [48] BERGEN, A.R. 1986. *Power Systems Analysis*. Prentice Hall.
 - [49] BERMAN, A. Y PLEMMONS, R.J. 1974. *Codes and Iterative Methods for Best Least Squares Solutions of Linear Systems*. SIAM J. Numer. Anal. 11, pp. 145-154.
 - [50] BERTSEKAS, D.P. 1982. *Constrained Optimization and Lagrange Multiplier Methods*. Academic Press.
 - [51] BERTSEKAS, D.P. 1991. *Linear Network Optimization: Algorithms and Codes*. The MIT Press.
 - [52] BERTSEKAS, D.P. 1995. *Nonlinear Programming*. Athena Scientific.
 - [53] BERTSEKAS, D.P. 2003. *Convex Analysis and Optimization*. Athena Scientific.
 - [54] BERTSEKAS, D.P. 2009. *Convex Optimization Theory*. Athena Scientific.
 - [55] BERTSEKAS, D.P. 2015. *Convex Optimization Algorithms*. Athena Scientific.
 - [56] BERTSEKAS, D.P. Y TSITSIKLIS, J.N. 1989. *Parallel and Distributed Computation. Numerical Methods*. Prentice Hall.
 - [57] BERTSIMAS, D.P. Y TSITSIKLIS, J.N. 1997. *Introduction to Linear Optimization*. Athena Scientific.
 - [58] BEST, M.J. Y RITTER, K. 1985. *Linear Programming. Active Set Analysis and Computer Programs*. Prentice Hall.
 - [59] BHATTI, M.A. 2000. *Practical Optimization Methods*. Springer.
 - [60] BIEGLER, L.T. 2010. *Nonlinear Programming. Concepts, Algorithms, and Applications to Chemical Processes*. SIAM.
 - [61] BJÖRK, Å. 1990. *Least Squares Methods*. En Handbook of Numerical Analysis. Volume 1: Finite Difference Methods (Part 1); Solution of Equations in $\mathbb{R}^n$ (Part 1). Ciarlet, P.G. y Lions, J.L. eds. North-Holland.
 - [62] BJÖRK, Å. 1996. *Numerical Methods for Least Squares Problems*. SIAM.
 - [63] BJÖRK, Å. 2015. *Numerical Methods in Matrix Computations*. Springer.
 - [64] BJÖRK, Å Y ELFVING, T. 1979. *Accelerated Projection Methods for Computing Psudoinverse Solutions of Systems of Linear Equations*. BIT 19, pp. 145-163.
 - [65] BLACKFORD, L.S., CHOI, J., CLEARY, A., D'AZEVEDO, E., DEMMEL, J., DHILLON, I., DONGARRA, J., HAMMARLIG, S., HENRY, G., PETITE, A., STANLEY, K., WALKER, D. Y WHALEY, R.C. 1997. *ScaLAPACK Users' Guide*. SIAM.
 - [66] BLANCHARD, P., DEVANEY, R.L. Y HALL, G.R. 1999. *Ecuaciones diferenciales*. Thomson.
 - [67] BLAND, R.G. 1977. *New Finite Pivoting Rules for the Simplex Method*. Mathematics of Operations Research 2, pp. 103-107.
 - [68] BOGGS, P.T., BYRD, R.H. Y SCHNABEL, R.B. EDS. 1985. *Numerical Optimization 1984*. SIAM.
 - [69] BORSE, G.J. 1997. *Numerical Methods with MATLAB*. PWS.

- [70] BOT, R.I., GRAD, S.M. Y WANKA, G. 2009. *Duality in Vector Optimization*. Springer.
- [71] BOYCE, W.E. Y DIPRIMA, R.C. 2009. *Elementary Differential Equations and Boundary Value Problems*. Ninth Edition. Wiley.
- [72] BOYD, S. Y VANDENBERGHE, L. 2004. *Convex Optimization*. Cambridge.
- [73] BONNANS, J.F., GILBERT, J.C., LEMARÉCHAL, C. Y SAGASTIZÁBAL, C.A. 2006. *Numerical Optimization. Theoretical and Practical Aspects*. Second Edition. Springer.
- [74] BRADLEY, G.H., BROWN, G.G. Y GRAVES, G.W. 1977. *Design and Implementation of Large Scale Transshipment Algorithms*. Management Science 24, pp. 1-34.
- [75] BRAINERD, W.S., GOLDBERG, C.H. Y ADAMS, J.C. 1990. *Programmer's Guide to Fortran 90*. McGraw-Hill.
- [76] BRAINERD, W.S., GOLDBERG, C.H. Y ADAMS, J.C. 1996. *Programmer's Guide to Fortran 90*. Springer.
- [77] BRAESS, D. 2007. *Finite Elements. Theory, Fast Solvers, and Applications in Elasticity Theory*. Cambridge.
- [78] BRANDIMARTE, P. 2006. *Numerical Methods in Finance and Economics. A MATLAB-Based Introduction*. Wiley.
- [79] BRENNER, S.C. Y SCOTT, L.R. 2008. *The Mathematical Theory of Finite Element Methods*. Springer.
- [80] BRIGGS, W.L. Y HENSON, V.E. 1995. *The DFT. An owner's manual for the Discrete Fourier Transform*. SIAM.
- [81] BRIGHAM, E.O. 1988. *The Fast Fourier Transform and its Applications*. Prentice Hall.
- [82] BROOKE, A., KENDRICK, D. Y MEERAUS, A. 1988. *GAMS. A User's Guide*. The Scientific Press.
- [83] BROWN, H.E. 1975. *Solution of Large Networks by Matrix Methods*. Wiley.
- [84] BROYDEN, C.G. 1965. A Class of Methods for Solving Nonlinear Simultaneous Equations. Mathematics of Computation 19, pp. 577-593.
- [85] BUNCH, J.R. Y KAUFMAN, L. 1977. Some Stable Methods for Calculating Inertia and Solving Symmetric Linear Systems. Mathematics of Computation 31, pp. 163-179.
- [86] BUNCH, J.R. Y PARLETT, B.N. 1971. Direct Methods for Solving Symmetric Indefinite Systems of Linear Equations. SIAM J. Numer. Anal. 8, pp.639-655.
- [87] BUNCH, J.R. Y ROSE, D.J. EDS. 1976. *Sparse Matrix Computations*. Academic Press.
- [88] BUNCH, J.R., KAUFMAN, L. Y PARLETT, B.N. 1976. Decomposition of a Symetric Matrix. Numerische Mathematik 27, pp. 95-109.
- [89] BUNCH, J.R. 1971. Analysis of the Diagonal Pivoting Method. SIAM J. Numer. Anal. 8, pp. 656-680.
- [90] BUNCH, J.R. 1974. Partial Pivoting Strategies for Symmetric Matrices. SIAM J. Numer. Anal. 11, pp. 521-528.
- [91] BURDEN, R.L. Y FAIRES, J.D. 1985. *Análisis numérico*. Grupo Editorial Iberoamérica.
- [92] BURDEN, R.L. Y FAIRES, J.D. 2011. *Numerical Analysis*. Ninth Edition. Brooks/Cole.
- [93] BUTCHER, J.C. 2008. *Ordinary Differential Equations*. Wiley.
- [94] BUTT, R. 2010. *Introduction to Numerical Analysis using MATLAB*. Jones and Barlett.
- [95] BUZZI-FERRARIS, G. 1993. *Scientific C++. Building Numerical Libraries the Object-Oriented Way*. Addison-Wesley.

- [96] BYRD, R.H., GILBERT, J.C. Y NOCEDAL, J. 1996. *A Trust Region Method Based on Interior Point Techniques for Nonlinear Programming*. INRIA.
- [97] CAJORI, F. 1991. *A History of Mathematics*. Fifth Edition. Chelsea Publishing Company.
- [98] CANUTO, C. Y TABACCO, A. 2015. *Mathematical Analysis Vols I y II*. Second Edition. Springer.
- [99] CARREIRA-PERPIÑAN, M.A. 2016. *Lecture Notes on Optimization-EECS260*. University of California Merced, Electrical Engineering and Computer Science Dpt.
- [100] CHAITIN-CHATELIN, F. Y FRAYSSÉ, V. 1996. *Lectures on Finite Precision Computations*. SIAM.
- [101] CHAMBERLAND, L. 1995. *Fortran 90. A Reference Guide*. Prentice Hall.
- [102] CHAN, T.F. 1982. *Algorithm 581: An Improved Algorithm for Computing the Singular Value Decomposition*. ACM Trans. on Mathematical Software 8, pp. 84-88.
- [103] CHAN, T.F. 1982. *An Improved Algorithm for Computing the Singular Value Decomposition*. ACM Trans. on Mathematical Software 8, pp. 72-83.
- [104] CHAPRA, S.C. 2012. *Applied Numerical Methods with MATLAB for Engineers and Scientists*. McGraw-Hill.
- [105] CHAPRA, S.C. Y CANALE, R.P. 2002. *Numerical Methods for Engineers with Applications and Programming Applications*. Fourth Edition. McGraw-Hill.
- [106] CHENEY, W. Y KINCAID, D. 1985. *Numerical Mathematics and Computing*. Brooks/Cole.
- [107] CHIVERS, I. Y SLEIGHTHOLME, J. 1995. *Introducing Fortran 90*. Springer.
- [108] CHONG, E.K.P. Y ŽAK, S.H. 2001. *An Introduction to Optimization*. Second Edition. Wiley.
- [109] CHU, E., GEORGE, A., LIU, J. Y NG, E. 1984. *SPARSPAK: Waterloo Sparse Matrix Package. User's Guide for SPARSPAK-A*. Research Report CS-84-36, Department of Computer Science, University of Waterloo, Waterloo, Ontario, Canadá.
- [110] CHVÁTAL, V. 1983. *Linear Programming*. W.H. Freeman and Company.
- [111] CIARLET, P.G. Y LIONS, J.L. EDS. 1990. *Handbook of Numerical Analysis. Volume 1: Finite Difference Methods (Part 1); Solution of Equations in $\mathbb{R}^n$ (Part 1)*. North-Holland.
- [112] CIARLET, P.G. 1988. *Introduction à L'Analyse Numérique Matricielle et à L'Optimisation*. Masson, S.A.
- [113] CIARLET, P.G. 1989. *Introduction to Numerical Linear Algebra and Optimisation*. Cambridge.
- [114] CIARLET, P.G. 2002. *The Finite Element Method for Elliptic Problems*. SIAM.
- [115] CIRIANI, T.A. Y LEACHMAN, R.C. 1993. *Optimization in Industry. Mathematical Programming and Modeling Techniques in Practice*. Wiley.
- [116] CLINE, A.K., MOLER, C.B., STEWART, G.W. Y WILKINSON, J.H. 1979. *An Estimate for the Condition Number of a Matrix*. SIAM J. Numer. Anal. 16, pp. 368-375.
- [117] CODDINGTON, E.A. Y CARLSON, R. 1997. *Linear Ordinary Differential Equations*. SIAM.
- [118] COLEMAN, T.F. Y LI, Y. EDS. 1990. *Large-Scale Numerical Optimization*. SIAM.
- [119] COLEMAN, T.F. Y VAN LOAN, C. 1988. *Handbook for Matrix Computations*. SIAM.
- [120] COLEMAN, T.F., EDENBRANDT, A. Y GILBERT, J.R. 1986. *Predicting Fill for Sparse Orthogonal Factorization*. Journal ACM 33, pp. 517-532.

- [121] CONTE, S.D. Y DE BOOR, C. 1987. *Elementary Numerical Analysis. An Algorithmic Approach*. McGraw-Hill.
- [122] CONTRERAS, M. 2016. *Análisis de Fourier*. Universidad de Sevilla.
<http://personal.us.es/contreras/>
- [123] COOK, T.M. Y RUSSELL, R.A. 1977. *Introduction to Management Science*. Prentice Hall.
- [124] CORDENO, A., HUESO, J., MARTÍNEZ, E. Y TORREGOSA, J.R. 2006. *Problemas resueltos de métodos numéricos*. Thomson.
- [125] CORMEN, T.H., LEISERSON, C.E. Y RIVEST, R.L. 1992. *Introduction to Algorithms*. The MIT Press.
- [126] COWELL, W.R. ED. 1984. *Sources and Development of Mathematical Software*. Prentice Hall.
- [127] COURANT, R. 1943. *Variational Methods for the Solutions of Problems of Equilibrium and Vibrations*. Bulletin of the American Mathematical Society, Vol. 49, No. 1, pp. 1-23.
- [128] CUTHILL, E. Y MCKEE, J. 1969. *Reducing the bandwidth of Sparse Symmetric Matrices*. Proceedings of the 24th National Conference of the Association for Computing Machinery (ACM), pp. 157-172. Brandon Systems Press.
- [129] DAHLQUIST, G. Y BJÖRK, Å. 1974. *Numerical Methods*. Prentice Hall.
- [130] DACOROGNA, B. 2004. *Introduction to the Calculus of Variations*. Imperial College Press.
- [131] DAKIN, R.J. 1965. *A Tree-Search Algorithm for Mixed Integer Programming Problems*. Computer Journal 8, pp. 250-255.
- [132] DANAILA, I., JOLY, P., KABER, S.M. Y POSTEL, M. 2007. *A, Introduction to Scientific Computing. Twelve Computational Projects Solved with MATLAB*. Springer.
- [133] DANILINA, N.I., DUBROVSKAYA, N.S., KVASHA, O.P. Y SMIRNOV, G.L. 1988. *Computational Mathematics*. Mir Publishers.
- [134] DANTZIG, G.B. 1963. *Linear Programming and Extensions*. Princeton University Press.
- [135] DANTZIG, G.B. 1987. *Origins of the Simplex Method*. Technical Report SOL 87-5. Systems Optimization Laboratory, Department of Operations Research, Stanford University.
- [136] DANTZIG, G.B. Y WOLFE, PH. 1960. *Decomposition Principle for Linear Programming*. Operations Research 8, pp. 101-111.
- [137] DARST, R.B. 1991. *Introduction to Linear Programming: Applications and Extensions*. Marcel Dekker.
- [138] DATTA, B.N. 1995. *Numerical Linear Algebra and Applications*. Brooks/Cole.
- [139] DATTORRO, J. 2016. *Convex Optimization † Euclidean Distance Geometry 2ε*. Μεβoo Publishing.
- [140] DAVENPORT, J.H. SIRET, Y. Y TOURNIER, E. 1993. *Computer Algebra. Systems and Algorithms for Algebraic Computation*. Academic Press.
- [141] DAVIS, T.A. 2006. *Direct Methods for Sparse Linear Systems*. SIAM.
- [142] DAVIS, P.J. Y RABINOWITZ, P. 1984. *Methods of Numerical Integration*. Second Edition. Academic Press.
- [143] DAVIS, T.A. Y SIGMAN, K. 2005. *MATLAB Primer*. Seventh Edition. Chapman and Hall/CRC.
- [144] DE LA FUENTE, J.L. Y LUMBRERAS, J. 1987. *A New Implementation of an Optimal Power Flow System Based on a General Purpose Nonlinear Programming Program*. Proc. IEEE PICA, pp. 422-428.

- [145] DE LA FUENTE, J.L. 1986. *Programación en redes no lineales. El problema de redes eléctricas*. Actas Optimización de Flujos en Redes'86.
- [146] DE LA FUENTE, J.L. 1987. *Programación no lineal: Aplicaciones en análisis, gestión y planificación de sistemas eléctricos*. Actas I Seminario Internacional de Investigación Operativa-Programación Matemática'86. J.P. Vilaplana y L.F. Escudero eds., pp. 255-278.
- [147] DE LA FUENTE, J.L. 1988. *Application of Nonlinear Network Optimization Techniques to Large Scale Power Scheduling Problems*. TIMS/ORSA National Meeting.
- [148] DE LA FUENTE, J.L. 1989. *La programación matemática y la planificación de redes eléctricas*. Actas Programación Matemática'89.
- [149] DE LA FUENTE, J.L. 1998. *Técnicas de cálculo para sistemas de ecuaciones, programación lineal y programación entera*. Segunda edición. Reverté.
- [150] DE LA FUENTE, J.L. 2016. *Matemáticas y algoritmos numéricos. Definiciones, notación y proposiciones esenciales para un curso avanzado*. Cículo Rojo.
- [151] DE LA FUENTE, J.L. 2017. *Ingeniería de los algoritmos y métodos numéricos. Un acercamiento práctico y avanzado a la computación científica e ingenieril con MATLAB*. Cículo Rojo.
- [152] DEMBO, A. 2013. *Stochastic Processes*. Department of Statistics. Stanford University. <http://statweb.stanford.edu/~adembo/math-136/nnotes.pdf>
- [153] DEMMEL, J.W. 1997. *Applied Numerical Linear Algebra*. SIAM.
- [154] DEMIDOVICH, B.P. Y MARON, I.A. 1985. *Cálculo Numérico Fundamental*. Paraninfo.
- [155] DENNIS, J.E. Y SCHNABEL, R.B. 1983. *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*. Prentice Hall.
- [156] DENNIS, J.E. Y SCHNABEL, R.B. 1996. *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*. SIAM.
- [157] DOMMEL, H.W. Y TINNEY, W.F. 1968. *Optimal Power Flow Solutions*. IEEE Trans. on Power Apparatus and Systems PAS-87, pp. 1866-1876.
- [158] DONGARRA, J.J., BUNCH, J.R., MOLER, C.B. Y STEWART, G.W. 1979. *LINPACK Users' Guide*. SIAM.
- [159] DONGARRA, J.J., DUFF, I.S., SORENSEN, D.C. Y VAN DER VORST, H.A. 1991. *Solving Linear Systems on Vector and Shared Memory Computers*. SIAM.
- [160] DORFMAN, R., SAMUELSON, P. Y SOLOW, R. 1958. *Linear Programming and Economic Analysis*. McGraw-Hill.
- [161] DUBIN, D. 2003. *Numerical and Analytical Methods for Scientists and Engineers Using Mathematica*. Wiley.
- [162] DUFF, I.S. 1981. *MA32 - A Package for Solving Sparse Unsymmetric Systems Using the Frontal Method*. AERE Harwell Report AERE-R 10079. Computer Science & Systems Division, AERE Harwell.
- [163] DUFF, I.S., ERISMAN, A.M. Y REID, J.K. 1986. *Direct Methods for Sparse Matrices*. Oxford University Press.
- [164] DUFF, I.S., GRIMES, G. Y LEWIS, J.G. 1989. *Sparse Matrix Test Problems*. ACM Trans. on Mathematical Software 15, pp. 1-14.
- [165] DUFF, I.S. Y REID, J.K. 1979. *Some Design Features of a Sparse Matrix Code*. ACM Trans. on Mathematical Software 5, pp.18-35.
- [166] DUFF, I.S. Y STEWART, G.W. EDS. 1979. *Sparse Matrix Proceedings 1978*. SIAM.

- [167] DUOANDIKOETXEA, J. 2007. *200 años de convergencia de las series de Fourier*. La Gaceta de la RSME, Vol. 10, No. 3.
- [168] EISELT, H.A. Y SANDBLOM, C.L. 2007. *Linear Programming and its Applications*. Springer.
- [169] EISENTAT, S.C., SCHULTZ, M.H. Y SHERMAN, A.H. 1981. *Algorithms and Data Structures for Sparse Symmetric Gaussian Elimination*. SIAM J. Sci. and Statist. Comput. 2, pp. 225-237.
- [170] ELDÉN, L., WITTMAYER-KOCH, L. Y BRUUN NIELSEN, H. 2004. *Introduction to Numerical Computation. Analysis and MATLAB Illustrations*. Studentlitteratur AB.
- [171] ELGERD, O.I. 1983. *Electric Energy Systems Theory: An Introduction*. McGraw-Hill.
- [172] EL-HAWARY, M.E. Y CHRISTENSEN, G.S. 1979. *Optimal Economic Operation of Electric Power Systems*. Academic Press.
- [173] ELLIS, T.M.R., PHILIPS, I.R. Y LAHEY, T.M. 1994. *Fortran 90 Programming*. Addison-Wesley.
- [174] ENGELN-MÜLLGES, G. Y UHLIG, F. 1996. *Numerical Algorithms with Fortran*. Springer.
- [175] ENGELN-MÜLLGES, G. Y UHLIG, F. 1996. *Numerical Algorithms with C*. Springer.
- [176] EPPERSON, J.F. 2013. *An Introduction to Numerical Methods and Analysis*. Second Edition. Wiley.
- [177] ERISMAN, A.M., NEVES, K.W. Y DWARAKANATH, M.H. EDS. 1980. *Electric Power Problems: The Mathematical Challenge*. SIAM.
- [178] EVANS, L.C. 1997. *Partial Differential Equations*. American Mathematical Society.
- [179] EVANS, J.R. Y MINIEKA, E. 1992. *Optimization Algorithms for Network and Graphs*. Marcel Dekker.
- [180] FAIRES, J.D. Y BURDEN, R.L. 1993. *Numerical Methods*. PWS.
- [181] FANG, S.C., PUTHENPURA, S. 1993. *Linear Optimization and Extensions. Theory and Algorithms*. Prentice Hall.
- [182] FARIN, G. 1988. *Curves and Surfaces for Computer Aided Geometric Design*. Academic Press.
- [183] FARKAS, J. 1902. *Theorie der Einfachen Ungleichungen*. Journal für die Reine und Angewandte Mathematik 124, pp. 1-27.
- [184] FERRIS, M.C., MANGASARIAN, O.L. Y WRIGHT, S.J. 2007. *Linear Programming with MATLAB*. SIAM.
- [185] FIACCO, A.V. Y MCCORMICK, G.P. 1968. *Nonlinear Programming: Sequential Unconstrained Minimization Techniques*. Wiley.
- [186] FIACCO, A.V. Y MCCORMICK, G.P. 1990. *Nonlinear Programming: Sequential Unconstrained Minimization Techniques*. SIAM.
- [187] FIELD, R.V. 2008. *Stochastic Models: Theory and Simulation*. Sandia National Laboratories.
<http://prod.sandia.gov/techlib/access-control.cgi/2008/081365.pdf>
- [188] FILBERT, F. 2009. *Analyse numérique. Algorithme et étude mathématique*. Dunod.
- [189] FLETCHER, R. 1987. *Practical methods of optimization*. Wiley.
- [190] FLOWERS, B.H. 1995. *An Introduction to Numerical Methods in C++*. Clarendon Press.
- [191] FORD, L.R. Y FULKERSON, D.R. 1962. *Flows in Networks*. Princeton University Press.

- [192] FORREST, J.H. Y TOMLIN, J.A. 1972. *Updated Triangular Factors of the Basis to Maintain Sparsity in the Product Form Simplex Method*. Mathematical Programming 2, pp. 263-278.
- [193] FORSGREN, A., GILL, P.E. Y WRIGHT, M.H. 2002. *Interior Methods for Nonlinear Optimization*. SIAM Review, Vol. 44, No. 4, pp. 525-597.
- [194] FORSYTHE, G.E., MALCOLM, M.A. Y MOLER, C.B. 1977. *Computer Methods for Mathematical Computations*. Prentice Hall.
- [195] FORTIN, A. 2011. *Analyse numérique pour ingénieurs*. Presses internationales Polytechnique.
- [196] FOURER, R., GAY, D.M. Y KERNIGHAM, B.W. 1993. *AMPL. A Modeling Language for Mathematical Programming*. Boyd and Fraser.
- [197] FRANDSEN, P.E., JONASSON, K., NIELSEN, H.B. Y TINGLEFF, O. 2004. *Unconstrained Optimization*. Technical University of Denmark, Informatics.
- [198] FREUND, R.M. 2009. *Introduction to Semidefinite Programming (SDP)*. MIT Open Course Ware.
https://ocw.mit.edu/courses/electrical-engineering-and-computer-science/6-251j-introduction-to-mathematical-programming-fall-2009/readings/MIT6_251JF09_SDP.pdf
- [199] GAL, T. 1979. *Postoptimal Analysis, Parametric Programming, and Related Topics*. McGraw-Hill.
- [200] GANDER, W. Y HŘEBÍČEK, J. 1993. *Solving Problems in Scientific Computing Using Maple and MATLAB*. Springer.
- [201] GANDER, W. Y HŘEBÍČEK, J. 1997. *Solving Problems in Scientific Computing Using Maple and MATLAB*. Third Edition. Springer.
- [202] GANDER, W., GANDER, M.J. Y KWOK, F. 2014. *Scientific Computing. An Introduction using Maple and MATLAB*. Springer.
- [203] GANDER, M.J. Y WANNER, G. 2012. *From Euler, Ritz, and Galerkin to Modern Computing*. SIAM Review, Vol. 54, No. 4. SIAM.
- [204] GARBOW, B.S., BOYLE, J.M., DONGARRA, J.J. Y MOLER, C.B. 1977. *Matrix Eigensystem Routines-EISPACK Guide Extension*. Springer.
- [205] GARCÍA, C.B. Y ZANGWILL, W.I. 1981. *Pathways to Solutions, Fixed Points, and Equilibria*. Prentice Hall.
- [206] GARFINKEL, R.S. Y NEMHAUSER, G.L. 1972. *Integer Programming*. Wiley.
- [207] GAUTSCHI, W. 2012. *Numerical Analysis*. Second Edition. Springer
- [208] GENTLE, J.E. 2007. *Matrix Algebra*. Springer
- [209] GENTLE, J.E. 2007. *Matrix Algebra. Theory, Computations, and Applications in Statistics*. Springer
- [210] GEORGE, A. Y HEATH, M.T. 1980. *Solution of Sparse Linear Least Squares Problems Using Givens Rotations*. Linear Algebra and its Applications 34, pp. 69-83.
- [211] GEORGE, A. Y LIU, J.W. 1979. *An Implementation of a Pseudoperipheral Node Finder*. ACM Trans. on Mathematical Software 5, pp. 284-295.
- [212] GEORGE, A. Y LIU, J.W. 1979. *The Design of a User Interface for a Sparse Matrix Package*. ACM Trans. on Mathematical Software 5, pp. 139-162.
- [213] GEORGE, A. Y LIU, J.W. 1981. *Computer Solution of Large Sparse Positive Definite Systems*. Prentice Hall.

- [214] GEORGE, A. Y NG, E. 1984. *SPARSPAK: Waterloo Sparse Matrix Package. User's Guide for SPARSPAKB*. Research Report CS-84-37, Department of Computer Science, University of Waterloo, Waterloo, Ontario, Canadá.
- [215] GEORGE, A. Y NG, E. 1985. *An Implementation of Gaussian Elimination with Partial Pivoting for Sparse Systems*. SIAM J. Sci. and Statist. Comput. 6, pp. 390-409.
- [216] GEORGE, A. 1971. *Computer Implementation of the Finite Element Method*. Ph.D. Dissertation, Computer Science Department Report STAN-CS-71208, Stanford University.
- [217] GEORGE, A. 1980. *An Automatic One-way Dissection Algorithm for Irregular Finite Element Problems*. SIAM J. Numer. Anal. 17, pp. 740-751.
- [218] GERALD, C.F. Y WHEATLEY, P.O. 1994. *Applied Numerical Analysis*. Addison-Wesley.
- [219] GIBBS, N.E., POOLE, W.G. Y STOCKMEYER, P.K. 1976. *An Algorithm for Reducing the Bandwidth and profile of a Sparse Matrix*. SIAM J. Numer. Anal. 13, pp. 236-250.
- [220] GILL, P.E. Y MURRAY, W. 1974. *Numerical Methods for Constrained Optimization*. Academic Press.
- [221] GILL, P.E., MURRAY, W. Y WRIGHT, M.H. 1981. *Practical Optimization*. Academic Press.
- [222] GILL, P.E., MURRAY, W. Y WRIGHT, M.H. 1991. *Numerical Linear Algebra and Optimization. Volume 1*. Addison-Wesley.
- [223] GILL, P.E., MURRAY, W., SAUNDERS, M.A. Y WRIGHT, M.H. 1986. *Maintaining LU Factors of a General Sparse Matrix*. Technical Report SOL 86-8. Systems Optimization Laboratory, Department of Operations Research, Stanford University.
- [224] GILL, P.E., MURRAY, W., SAUNDERS, M.A., TOMLIN, J.A. Y WRIGHT, M.H. 1986. *On Projected Newton Barrier Methods for Linear Programming and an Equivalence to Karmarkar's Projective Method*. Technical Report SOL 85-11R, revision of May 1986. Systems Optimization Laboratory, Department of Operations Research, Stanford University.
- [225] GILLET, B.E. 1976. *Introduction to Operations Research: A Computer Oriented Algorithmic Approach*. McGraw-Hill.
- [226] GOLDBERG, S. 1958. *Introduction to Difference Equations*. Wiley.
- [227] GOLDFARB, D. Y TODD, M.J. 1989. *Linear Programming*. En *Handbooks in Operations Research and Management Science. Volume 1: Optimization*. Nemhauser, G.L., Rinnooy Kan, A.H.G. y Todd, M.J. eds. North-Holland.
- [228] GOLDSTEIN, A.A. 1965. *On Steepest Descent*. SIAM J. Control 3, pp. 147-151.
- [229] GOLOVINA, L.I. 1974. *Algebra lineal y algunas de sus aplicaciones*. Editorial Mir.
- [230] GOLUB, G.H. Y MEURANT, G.A. 1983. *Résolution Numérique des Grands Systèmes Linéaires*. Editions Eyrolles.
- [231] GOLUB, G.H. Y O'LEARY, D.P. 1989. *Some History of the Conjugate Gradient and Lanczos Algorithms: 1948-1976*. SIAM Review 31, pp.50-102.
- [232] GOLUB, G.H. Y ORTEGA, J.M. 1992. *Scientific Computing and Differential Equations. An Introduction to Numerical Methods*. Academic Press.
- [233] GOLUB, G.H. Y REINSCH, C. 1970. *Singular Value Decomposition and Least Squares Solutions*. Numerische Mathematik 14, pp. 403-20.
- [234] GOLUB, G.H. Y VAN LOAN, C.F. 1983. *Matrix Computations*. The Johns Hopkins University Press.

-
- [235] GOLUB, G.H. Y VAN LOAN, C.F. 1989. *Matrix Computations*. Second Edition. The Johns Hopkins University Press.
 - [236] GOLUB, G.H. Y VAN LOAN, C.F. 1996. *Matrix Computations*. Third Edition. The Johns Hopkins University Press.
 - [237] GOLUB, G.H. Y VAN LOAN, C.F. 2013. *Matrix Computations*. Fourth Edition. The Johns Hopkins University Press.
 - [238] GOMORY, R.E. 1960. *An Algorithm for the Mixed Integer Problem*. RAND Corporation paper RM-2597.
 - [239] GOMORY, R.E. 1963. *An Algorithm for Integer Solutions to Linear Programs*. Recent Advances in Mathematical Programming. Graves, R. y Wolfe, Ph. eds. McGraw-Hill.
 - [240] GONDRAN, M. Y MINOUX, M. 1979. *Graphes et Algorithmes*. Editions Eyrolles.
 - [241] GONIN, R. Y MONEY, A.H. 1989. *Nonlinear L_p Estimation*. Marcel Dekker.
 - [242] GOOSSENS, M., MITTELBACH, F. Y SAMARIN, A. 1994. *The $\LaTeX$ Companion*. Addison-Wesley.
 - [243] GOOSSENS, M., MITTELBACH, F. Y SAMARIN, A. 2004. *The $\LaTeX$ Companion*. Second Edition. Addison-Wesley.
 - [244] GOOSSENS, M., RAHTZ, S. Y MITTELBACH, F. 1997. *The $\LaTeX$ Graphics Companion. Illustrating Documents with $\TeX$ and PostScript*. Addison-Wesley.
 - [245] GRAINGER, J.J. Y STEVENSON JR., W.D. 1994. *Power Systems Analysis*. McGraw-Hill.
 - [246] GRANÉ, A. *Análisis de Componentes Principales*. Departamento de Estadística, Universidad Carlos III de Madrid.
 - [247] GREENBAUM, A. 1997. *Iterative Methods for Solving Linear Systems*. SIAM.
 - [248] GREENBERG, H. 1971. *Integer Programming*. Academic Press.
 - [249] GRIFFITHS, D.F. Y HIGHAM, D.J. 2010. *Numerical Methods for Ordinary Differential Equations. Initial Value Problems*. Springer.
 - [250] GRIGORIADIS, M.D. 1986. *An Efficient Implementation of the Network Simplex Method*. Mathematical Programming Study 26, pp. 83-111.
 - [251] GRIVA, I., NASH, S.G. Y SOFER, A. 2009. *Linear and Nonlinear Optimization*. SIAM.
 - [252] GRÖTSCHEL, M., LOVÁSZ, L. Y SCHRIJVER, A. 1988. *Geometric Algorithms and Combinatorial Optimization*. Springer.
 - [253] GUTKNECHT, M.H. 2008. *Iterative Methods*. ETH Zurich, Seminar for Applied Mathematics.
<http://www.sam.math.ethz.ch/~mhg/unt/SWNLA/itmethSWNLA08.pdf>
 - [254] HÄFELE, W. Y KIRCHMAYER, L.K. EDS. 1981. *Modeling of Large-Scale Energy Systems*. Pergamon Press.
 - [255] HABERMAN, R. 2013. *Applied Partial Differential Equations with Fourier Series and Boundary Value Problems*. Pearson.
 - [256] HAGER, W.W. 1984. *Condition Estimates*. SIAM J. Sci. and Statist. Comput. 5, pp. 311-316.
 - [257] HAGER, W.W. 1988. *Applied Numerical Linear Algebra*. Prentice Hall.
 - [258] HAHN, B. Y VALENTINE, D.T. 2007. *Essential MATLAB for Engineers and Scientists*. Third Edition. Elsevier.
 - [259] HEATH, M.T. 2002. *Scientific Computing. An Introductory Survey*. Second Edition. McGraw-Hill.

- [260] HALL, M. 1956. *An Algorithm for Distinct Representatives*. Amer. Math. Monthly 63, pp. 716-717.
- [261] HALMOS, P.R. 1974. *Finite-Dimensional Vector Spaces*. Springer.
- [262] HAMMER, P.L., JOHNSON, E.L. Y KORTE, B.H. EDS. 1979. *Discrete Optimization III*. North-Holland.
- [263] HÄMMERLIN, G. Y HOFFMANN, K. H. 1991. *Numerical Mathematics*. Springer.
- [264] HAMMING, R.W. 1986. *Numerical Methods for Scientists and Engineers*. Dover Publications.
- [265] HANSELMAN, D. Y LITTLEFIELD, B. 1998. *Mastering MATLAB 5. A Comprehensive Tutorial and Reference*. Prencite Hall.
- [266] HARMAN, T.L., DABNEY, J. Y RICHERT, N. 2000. *Advanced Enginerring Mathematics with MATLAB*. Second Edition. Brooks/Cole.
- [267] HARWELL LABORATORY 1987. *HARWELL Subroutine Library: A Catalogue of Subroutines (1987)*. Computer Science and Systems Division, AERE Harwell.
- [268] HEATH, M.T. 2002. *Scientific Computing. An Introductory Survey*. Second Edition. McGraw-Hill.
- [269] HELLERMAN, E, Y RARICK, D. 1971. *Reinversion with the Preassigned Pivot Procedure*. Mathematical Programming 1, pp. 195-216.
- [270] HELLERMAN, E, Y RARICK, D. 1972. *The Partitioned Preassigned Pivot Procedure (P^4)*. En Sparse Matrices and their Applications. Rose, D.J. y Willoughby, R.A. eds. Plenum Press.
- [271] HERDRIX, E.M.T. Y TÓTH, B.G. 2010. *Introduction to Nonlinear and Global Optimization*. Springer.
- [272] HENRICI, P. 1982. *Essentials of Numerical Analysis with Pocket Calculator Demonstrations*. Wiley.
- [273] HÉRON, B., ISSARD-ROCH, F. Y PICARD, C. 2005. *Analyse numérique. Exercices et problèmes corrigés*. Dunod.
- [274] HESTENES, M. 1980. *Conjugate Direction Methods in Optimization*. Springer.
- [275] HIAI, F. Y PETZ, D. 2014. *Introduction to Matrix Analysis and Applications*. Springer.
- [276] HIGHAM, N.J. 1995. *The Test Matrix Toolbox for MATLAB*. Numerical Analysis Report No. 276. The University of Manchester.
<http://www.ma.man.ac.uk/MCMM>.
- [277] HIGHAM, N.J. 1996. *Accuracy and Stability of Numerical Algorithms*. SIAM.
- [278] HIGHAM, N.J. 2002. *Accuracy and Stability of Numerical Algorithms*. Second Edition. SIAM.
- [279] HIGHAM, N.J. 2002. *The Matrix Computation Toolbox for MATLAB*. Numerical Analysis Report No. 410. The University of Manchester.
<http://www.ma.man.ac.uk/MCMM>.
- [280] HIGHAM, D.J. Y HIGHAM, N.J. 2000. *MATLAB Guide*. SIAM.
- [281] HIGHAM, D.J. Y HIGHAM, N.J. 2005. *MATLAB Guide*. Second Edition. SIAM.
- [282] HILDEBRAND, F.B. 1987. *Introduction to Numerical Analysis*. Dover Publications.
- [283] HILLIER, F.S. Y LIEBERMAN, G.J. 1974. *Introduction to Operations Research*. Holden-Day.

- [284] HILLIER, F.S. Y LIEBERMAN, G.J. 1995. *Introduction to Mathematical Programming*. McGraw-Hill.
- [285] HILLIER, F.S. Y LIEBERMAN, G.J. 2010. *Introducción a la Investigación de Operaciones*. McGraw-Hill.
- [286] HIMMELBLAU, D.M. ED. 1973. *Decomposition of Large-Scale Problems*. North-Holland.
- [287] HOCKNEY, R.W. 1996. *The Science of Computer Benchmarking*. SIAM.
- [288] HOFFMAN, J.D. 2001. *Numerical Methods for Engineers and Scientists*. CRC Press.
- [289] HOLMES, M.H. 2007. *Introduction to Numerical Methods in Differential Equations*. Springer.
- [290] HOPCROFT, J.E. Y KENNEDY, K.W. CHAIRS 1989. *Computer Science. Achievements and Opportunities*. SIAM.
- [291] HORN, R.A. Y JOHNSON, C.R. 1985. *Matrix Analysis*. Cambridge.
- [292] HOUSEHOLDER, A.S. 1975. *The Theory of Matrices in Numerical Analysis*. Dover Publications.
- [293] HU, T.C. 1970. *Integer Programming and Network Flows*. Addison-Wesley.
- [294] HUNT, B.R., LIPSMAN, R.L. Y ROSENBERG, J.M. 2006. *A Guide to MATLAB for Beginners and Experienced Users*. Second Edition. Cambridge.
- [295] HURLBERT, G. 2010. *Linear Optimization. The Simplex Workbook*. Springer.
- [296] HUYNH, H.T., LAI, V.S. Y SOUMARE, I. 2008. *Stochastic Simulation and Applications in Finance with MATLAB Programs*. Wiley.
- [297] HWANG, K. Y BRIGGS, F.A. 1985. *Computer Architecture and Parallel Processing*. McGraw-Hill.
- [298] IGNIZIO, J.P. Y CAVALIER, T.M. 1994. *Linear Programming*. Prentice Hall.
- [299] ILIĆ, M.D. Y LIU, S. 1996. *Hierarchical Power Systems Control. Its Value in a Changing Industry*. Springer.
- [300] INFANGER, G. 1994. *Planning under Uncertainty. Solving Large-Scale Stochastic Linear Programs*. Boyd & Fraser Publishing Company.
- [301] ISAACSON, E. Y KELLER, H.B. 1994. *Analysis of Numerical Methods*. Dover Publications.
- [302] JACOBS, D. ED. 1977. *The State of the Art in Numerical Analysis*. Academic Press.
- [303] JAMES, G. 2011. *Advanced Modern Engineering Mathematics*. Fourth Edition. Pearson.
- [304] JAMES, G. 2015. *Modern Engineering Mathematics*. Fifth Edition. Pearson.
- [305] JAHN, J. 2007. *Introduction to the Theory of Nonlinear Optimization*. Springer.
- [306] JARRE, F. Y STOER, J. 2004. *Optimierung*. Springer.
- [307] JENNINGS, A. Y MCKEOWN, J.J. 1992. *Matrix Computation. Second Edition*. Wiley.
- [308] KARLOFF, H. 1991. *Linear Programming*. Birkhäuser.
- [309] KARMARKAR, N. 1984. *A New Polynomial-Time Algorithm for Linear Programming*. Combinatorics 4, pp. 373-395.
- [310] KARRIS, S.T. 2004. *Numerical Analysis using MATLAB and Spreadsheets*. Orchard Publications.
- [311] KARUSH, W. 1939. *Minima of Functions of Several Variables with Inequalities as Side Constraints*. M.Sc. Dissertation, Department of Mathematics, University of Chicago.
- [312] KAUFMANN, A. Y HENRY-LABORDÈRE, A. 1974. *Méthodes et Modèles de la Recherche Opérationnelle*. Dunod.

- [313] KELLEY, C.T. 1995. *Iterative Methods for Linear and Nonlinear Equations*. SIAM.
- [314] KELLEY, C.T. 1999. *Iterative Methods for Optimization*. SIAM.
- [315] KENNINGTON, J.L. Y HELGASON, R.V. 1980. *Algorithms for Network Programming*. Wiley.
- [316] KERN, M. 2005. *Éléments finis aspects mathématiques*. INRIA.
http://mms2.ensmp.fr/ef_paris/formulation/transparents/f_MathMef.pdf
- [317] KHARAB, A. Y GUENTHER, R.B. 2012. *An Introduction to Numerical Methods. A MATLAB Approach*. CRC Press.
- [318] KINCAID, D.R. Y HAYES, L.J. EDS. 1990. *Iterative Methods for Large Linear Systems*. Academic Press.
- [319] KIUSALAAS, J. 2010. *Numerical Methods in Engineering with MATLAB*. Cambridge.
- [320] KLEE, V. Y MINTY, G.J. 1972. *How good is the Simplex Algorithm?* En *Inequalities III*. Shisha, O. ed. Academic Press.
- [321] KLINGMAN, D., NAPIER, A. Y STUTZ, J. 1974. *NETGEN-A Program for Generating Large-scale (Un)Capacitated Assignment, Transportation and Minimum Cost Flow Network Problems*. *Management Science* 20, pp. 814-821.
- [322] KNIGHT, A. 2000. *Basics of MATLAB and Beyond*. Chapman and Hall/CRC.
- [323] KOLMAN, B. Y BECK, R.E. 1995. *Elementary Linear Programming with Applications*. Academic Press.
- [324] KOLMOGOROV, A.M. Y FOMIN, S.V. 1972. *Elementos de la teoría de funciones y del análisis funcional*. Editorial Mir.
- [325] KOLMOGOROV, A.M. Y FOMIN, S.V. 1975. *Introductory Real Analysis*. Dover Publications.
- [326] KOPCHENOVA, N.V. Y MARON, I.A. 1975. *Computational Mathematics. Worked Examples and Problems with Elements of Theory*. Mir Publishers.
- [327] KOPKA, H. Y DALY, P.W. 1995. *A Guide to L^AT_EX 2_ε. Document Preparation for Beginners and Advanced Users*. Addison Wesley.
- [328] KOROVKIN, P.P. 1976. *Desigualdades*. Editorial Mir.
- [329] KRANTZ, S.G. Y PARKS, H.R. 2003. *The Implicit Function Theorem. History, Theory, and Applications*. Birkhäuser.
- [330] KRESSNER, D. 2005. *Numerical Methods for General and Structured Eigenvalue Problems*. Springer.
- [331] KREYSZIG, E. 2011. *Advanced Engineering Mathematics*. Wiley.
- [332] KUESTER, J.L. Y MIZE, J.H. 1973. *Optimization Techniques with Fortran*. McGraw-Hill.
- [333] KUHN, H.W. Y TUCKER, A.W. 1951. *Nonlinear Programming*. En *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*. University of California Press.
- [334] KÜNZI, H.P. Y KRELLE, W. 1969. *La Programmation Non Linéaire*. Gauthier-Villars.
- [335] LAMPORT, L. 1994. *L^AT_EX. A Document Preparation System. User's Guide and Reference Manual*. Addison-Wesley.
- [336] LAND, A. Y POWELL, S. 1973. *Fortran Codes for Mathematical Programming*. Wiley.
- [337] LANG, S. 1968. *Analysis. Vols. I y II*. Addison-Wesley.
- [338] LANG, S. 1983. *Linear Algebra*. Addison-Wesley.

-
- [339] LARSON, R.E. 1968. *State Increment Dynamic Programming*. American Elsevier.
 - [340] LARSSON, S. Y THOMÉE, V. 2009. *Partial Differential Equations with Numerical Methods*. Springer.
 - [341] LASCAUX, P. Y THÉODOR, R. 1986. *Analyse Numérique Matricielle Appliquée a l'Art de l'Ingénieur. Vols. I y II*. Masson, S.A.
 - [342] LASDON, L.S. 1970. *Optimization Theory for Large Systems*. Macmillan Publishing Company.
 - [343] LAWLER, E.L. 1976. *Combinatorial Optimization: Networks and Matroids*. Holt, Rinehart and Winston.
 - [344] LAWSON, C.L. Y HANSON, R.J. 1974. *Solving Least Squares Problems*. Prentice Hall.
 - [345] LAWSON, C.L. Y HANSON, R.J. 1995. *Solving Least Squares Problems*. SIAM.
 - [346] LAY, D.C. 2012. *Álgebra lineal y sus aplicaciones*. Cuarta edición. Pearson educación.
 - [347] LAY, D.C. 2015. *Linear Algebra and its Applications*. Fourth Edition. Addison-Wesley.
 - [348] LAY, D.C. Y LAY, S.R. 2015. *Linear Algebra and its Applications*. Fifth Edition. Pearson.
 - [349] LEIFMAN, L.J. ED. 1990. *Functional Analysis, Optimization, and Mathematical Economics*. Oxford University Press.
 - [350] LEBOUcq, R.B., SORENSSEN, D.C. Y YANG, C. 1998, *ARPACK Users' Guide: Solution of Large-Scale Eigenvalue Problems with Implicitly Restarted Arnoldi Methods*. SIAM.
 - [351] LEMKE, C.E. 1954. *The Dual Method of Solving the Linear Programming Problem*. Naval Research Logistics Quarterly 1, pp. 36-47.
 - [352] LERMAN, S.R. 1993. *Problem Solving and Computation for Scientists and Engineers. An Introduction Using C*. Prentice Hall.
 - [353] LEW, A. Y MAUCH, H. 2007. *Dynamic Programming. A Computational Tool*. Springer.
 - [354] LEYFFER, S. Y MAHAJAN, A. 2010. *Software for Nonlinear Constrained Optimization*. Argonne National Laboratory, Mathematics and Computer Science Division.
 - [355] LEVENBERG, K. 1944. *A Method for the Solution of Certain Problems in Least Squares*. Quart. Appl. Math. 2, pp. 164-168.
 - [356] LIEBMAN, J., LASDON, L., SCHRAGE, L. Y WARREN, A. 1986. *Modeling and Optimization with GINO*. The Scientific Press.
 - [357] LINDFIELD, G. Y PENNY, J. 1995. *Numerical Methods Using MATLAB*. Ellis Horwood.
 - [358] LOEHR, N 2014. *Advanced Linear Algebra*. CRC Press.
 - [359] LONGLEY, J.W. 1984. *Least Squares Computations Using Orthogonalization Methods*. Marcel Dekker.
 - [360] LUENBERGER, D.G. 1969. *Optimization by Vector Space Methods*. Wiley.
 - [361] LUENBERGER, D.G. 1984. *Linear and Nonlinear Programming*. Addison-Wesley.
 - [362] LUENBERGER, D.G. 1989. *Programación lineal y no lineal*. Addison-Wesley Iberoamericana.
 - [363] LUENBERGER, D.G. Y YE, Y. 2016. *Linear and Nonlinear Programming*. Fourth Edition. Springer.
 - [364] LUSTIG, I.J., MARSTEN, R.E. Y SHANNO, D.F. 1992. *On Implementing Mehrotra's Predictor-Corrector Interior-Point Method for Linear Programming*. SIAM J. Optimization, Vol. 2, No. 3, pp. 435-449.

- [365] MADDEN, N. 2012. *Numerical Solution to Differential Equations using MATLAB: Part 2. Finite Element Methods*. National University of Ireland Galway, School of Mathematics, Statistics and Applied Mathematics.
<http://www.maths.nuigalway.ie/~niall/teaching/Archive/1112/Finite-V02.pdf>
- [366] MADDEN, N. 2012. *Numerical Solution to Differential Equations using MATLAB: Part 3. A finite element implementation for 2D elliptic problem*. National University of Ireland Galway, School of Mathematics, Statistics and Applied Mathematics.
<http://www.maths.nuigalway.ie/~niall/teaching/Archive/1112/Finite-V01.pdf>
- [367] MADSEN, K. Y NIELSEN, H.B. 2010. *Introduction to Optimization and Data Fitting*. Technical University of Denmark, Informatics.
- [368] MADSEN, K., NIELSEN, H.B. Y TINGLEFF, O. 2004. *Methods for Nonlinear Least Squares Problems*. Technical University of Denmark, Informatics.
- [369] MADSEN, K., NIELSEN, H.B. Y TINGLEFF, O. 2004. *Optimization with Constraints*. Technical University of Denmark, Informatics.
- [370] MANDL, C. 1979. *Applied Network Optimization*. Academic Press.
- [371] MANASSAH, J.T. 2001. *Elementary Mathematical and Computational Tools for Electrical and Computer Engineers Using MATLAB*. CRC Press.
- [372] MANGASARIAN, O.L. 1994. *Nonlinear Programming*. SIAM.
- [373] MANNEBACK, P. 1985. *On Some Numerical Methods for Solving Large Sparse Linear Least Squares Problems*. Ph.D. Dissertation, Facultés Iniversitaires Notre-Dame de la Paix, Namur, Bélgica.
- [374] MARCHUK, G.I. Y DYMNIKOV, V.P. 1985. *Problems of Computational Mathematics and Mathematical Modelling*. Mir Publishers.
- [375] MARCUS, M. Y MING, H. 1964. *A Survey of Matrix Theory and Matrix Inequalities*. Allyn and Bacon.
- [376] MARTINEZ, W.L. Y MARTÍNEZ, A.R. 2002. *Computational Statistics Handbook with MATLAB*. Chapman and Hall/CRC.
- [377] MARKOWITZ, H.M. 1957. *The Elimination Form of the Inverse and its Application to Linear Programming*. Management Science 3, pp. 255-269.
- [378] MARQUARDT, D. 1963. *An Algorithm for Least Squares Estimation of Nonlinear Parameters*. SIAM J. Appl. Math. 11, pp. 431-441.
- [379] MATHEWS, J.H. 1992. *Numerical Methods for Mathematics, Science, and Engineering*. Prentice Hall.
- [380] MATHEWS, J.H. Y FINK, K.D. 2000. *Métodos numéricos con MATLAB*. Prentice Hall.
- [381] MCMAHON, D. Y TOPA, D.M. 2006. *A Beginners's Guide to Mathematica*. Chapman and Hall/CRC.
- [382] MCCORMICK, G.P. 1983. *Nonlinear Programming*. Wiley.
- [383] MEHROTRA, S. 1992. *On the Implementation of a Primal-Dual Interior Point Method*. SIAM J. Optimization, Vol. 2, No. 4, pp. 575-601.
- [384] MESIROV, J.P. ED. 1991. *Very Large Scale Computation in the 21st Century*. SIAM.
- [385] METCALF, M. Y REID, J. 1990. *Fortran 90 Explained*. Oxford University Press.
- [386] METCALF, M. Y REID, J. 1996. *Fortran 90/95 Explained*. Oxford University Press.
- [387] MEYER, C.D. 2000. *Matrix Analysis and Applied Linear Algebra*. SIAM.

-
- [388] MEYER, Y. 1993. *Wavelets. Algorithms and Applications*. SIAM.
 - [389] MIERSEMANN, E. 2012. *Partial Differential Equations. Lecture notes*. Department of Mathematics, Leipzig University.
<http://www.math.uni-leipzig.de/~miersemann/pdebook.pdf>
 - [390] MINOUX, M. Y BARTNIK, G. 1986. *Graphes, Algorithmes, Logiciels*. Dunod.
 - [391] MINOUX, M. 1986. *Mathematical Programming: Theory and Algorithms*. Wiley.
 - [392] MOIN, P. 2010. *Fundamentals of Engineering Numerical Analysis*. Cambridge.
 - [393] MOLER, C.B. 2004. *Numerical Computing with MATLAB*. SIAM.
 - [394] MOLER, C.B., LITTLE, J.N. Y BANGERT, S. 1987. *PC-MATLAB User's Guide*. The Math-Works.
 - [395] MORÉ, J.J. Y WRIGHT, S.J. 1993. *Optimization Software Guide*. SIAM.
 - [396] MORGAN, S.S. 1997. *A Comparison of Simplex Method Algorithms*. University of Florida, Computer and Information Science and Engineering Dept.
 - [397] MOTZ, L. Y WEAVER, J.H. 1993. *The Story of Mathematics*. Avon Books.
 - [398] MORGANSTERN, R.E. 2014. *Numerical Análisis I*. Self Edition.
 - [399] MORGANSTERN, R.E. 2014. *Numerical Análisis II*. Self Edition.
 - [400] MURTAGH, B.A. Y SAUNDERS, M.A. 1978. *Large Scale Linearly Constrained Optimization*. Mathematical Programming 14, pp. 41-72.
 - [401] MURTAGH, B.A. Y SAUNDERS, M.A. 1982. *A Projected Lagrangian Algorithm and its Implementation for Sparse Nonlinear Constraints*. Mathematical Programming Study 16, pp. 84-117.
 - [402] MURTAGH, B.A. Y SAUNDERS, M.A. 1987. *MINOS 5.1 User's Guide*. Systems Optimization Laboratory, Department of Operations Research, Stanford University.
 - [403] MURTY, K.G. 1983. *Linear Programming*. Wiley.
 - [404] MURTY, K.G. 1992. *Network Programming*. Prentice Hall.
 - [405] NAG 1992. *C Library Manual*. Numerical Algorithms Group, Mark 2, Oxford, England.
 - [406] NAG 1993. *Fortran Library Manual*. Numerical Algorithms Group, Mark 16, Oxford, England.
 - [407] NAGLE, R.K., SAFF, E.B. Y SNIDER, A.D. 2005. *Ecuaciones diferenciales y problemas con valores en la frontera*. Pearson.
 - [408] NAKAMURA, S. 1996. *Numerical Analysis and Graphic Visualization with MATLAB*. Prentice Hall PTR.
 - [409] NASH, S.G. Y SOFER, A. 1996. *Linear and Nonlinear Programming*. McGraw-Hill.
 - [410] NEMHAUSER, G.L. Y WOLSEY, L.A. 1988. *Integer and Combinatorial Optimization*. Wiley.
 - [411] NEMHAUSER, G.L. Y WOLSEY, L.A. 1989. *Integer Programming*. En *Handbooks in Operations Research and Management Science. Volume 1: Optimization*. Nemhauser, G.L., Rinnooy Kan, A.H.G. y Todd, M.J. eds. North-Holland.
 - [412] NEMHAUSER, G.L., RINNOOY KAN, A.H.G. Y TODD, M.J. EDS. 1989. *Handbooks in Operations Research and Management Science. Volume 1: Optimization*. North-Holland.
 - [413] NERING, E.D. Y TUCKER, A.W. 1993. *Linear Programs and Related Problems*. Academic Press.

- [414] NESTEROV, Y. Y NEMIROVSKII, A. 1994. *Interior-Point Polynomial Algorithms in Convex Programming*. SIAM.
- [415] NIEDERREITER, H. 1992. *Random Number Generation and Quasi-Monte Carlo Methods*. SIAM.
- [416] NOCEDAL, J. Y WRIGHT, S.J. 2006. *Numerical Optimization*. Springer.
- [417] NUALART, D. 2017. *Stochastic Processes* The University of Kansas.
<https://www.math.ku.edu/~nualart/StochasticCalculus.pdf>
- [418] OLVER, P.J. 2014. *Introduction to Partial Differential Equations*. Springer.
- [419] OLVER, P.J. Y SHAKIBAN, C. 2006. *Applied Linear Algebra*. Pearson.
- [420] O'NEIL, P.V. 2010. *Advanced Engineering mathematics*. Brooks/Cole.
- [421] ORCHARD-HAYS, W. 1968. *Advanced Linear Programming Computing Techniques*. McGraw-Hill.
- [422] ORTEGA, J.M. Y RHEINBOLDT, W.C. 1970. *Iterative Solution of Nonlinear Equations in Several Variables*. Academic Press.
- [423] ORTEGA, J.M. 1988. *Introduction to Parallel and Vector Solution of Linear Systems*. Plenum Press.
- [424] PADBERG, M. 1995. *Linear Programming and Extensions*. Springer.
- [425] PAI, M. A. 1986. *Computer Techniques in Power System Analysis*. McGraw-Hill.
- [426] PAIGE, C.C. 1979. *Computer Solution of Perturbation Analysis of Generalized Linear Least Squares Problems*. Mathematics of Computation 33, pp. 171-184.
- [427] PAIGE, C.C. 1979. *Fast Numerically Stable Computations for Generalized Linear Least Squares Problems*. SIAM J. Numer. Anal. 16, pp. 165-171.
- [428] PANIK, M.J. 1996. *Linear Programming: Mathematics, Theory and Algorithms*. Kluwer Academic Publishers.
- [429] PANNELL, D.J. 1997. *Introduction to Practical Linear Programming*. Wiley.
- [430] PARKER, R.G. Y RARDIN, R.L. 1988. *Discrete Optimization*. Academic Press.
- [431] PARTER, S.V. 1961. *The Use of Linear Graphs in Gaussian Elimination*. SIAM Review 3, pp. 119-130.
- [432] PATEL, R.V., LAUB, A.J. Y VAN DOOREN, P.M. EDS. 1994. *Numerical Linear Algebra Techniques for Systems and Control*. IEEE Press.
- [433] PEDREGAL, P. 2004. *Introduction to Optimization*. Springer.
- [434] PETERSEN, K.B. Y PEDERSEN, M.S. 2012. *The Matrix Cookbook*.
<http://matrixcookbook.com>
- [435] PEÑA SÁNCHEZ DE RIVERA, D. 1986. *Estadística. Modelos y métodos. 1. Fundamentos*. Alianza Universidad Textos.
- [436] PFAFFENBERGER, R.C. Y WALKER, D.A. 1976. *Mathematical Programming for Economics and Business*. The Iowa State University Press.
- [437] PHAN, D. 2010. *Introduction au calcul des variations*. EPFL.
- [438] PHILLIPS, C. Y CORNELIUS, B. 1986. *Computational Numerical Methods*. Ellis Horwood Limited.
- [439] PHILLIPS, D.T., RAVINDRAN, A. Y SOLBERG, J. 1976. *Operations Research: Principles and Practice*. Wiley.

-
- [440] PHILLIPS, G.M. Y TAYLOR, P.J. 1996. *Theory and Applications of Numerical Analysis*. Second Edition. Academic Press.
 - [441] PIERRE, D.A. Y LOWE, M.J. 1975. *Mathematical Programming Via Augmented Lagrangians. An Introduction with Computer Programs*. Addison-Wesley.
 - [442] PIERRE, D.A. 1986. *Optimization Theory with Applications*. Dover Publications.
 - [443] PIKE, R.W. 1986. *Optimization for Engineering Systems*. Van Nostrand Reinhold Company.
 - [444] PISSANETZKY, S. 1984. *Sparse Matrix Technology*. Academic Press.
 - [445] PLATO, R. 2003. *Concise Numerical Mathematics*. American Mathematical Society.
 - [446] PLYBON, B.F. 1992. *An Introduction to Applied Numerical Analysis*. PWS-Kent Publishing Company.
 - [447] POWELL, M.J.D. ED. 1982. *Nonlinear Optimization*. Academic Press.
 - [448] PRESS, W.H., FLANNERY, B.P., TEUKOLSKY, S.A. Y VETTERLING, W.T. 1986. *Numerical Recipes in Fortran. The Art of Scientific Computing*. Cambridge.
 - [449] PRESS, W.H., TEUKOLSKY, S.A., VETTERLING, W.T. Y FLANNERY, B.P. 1992. *Numerical Recipes in C. The Art of Scientific Computing*. Second Edition. Cambridge.
 - [450] PRESS, W.H., TEUKOLSKY, S.A., VETTERLING, W.T. Y FLANNERY, B.P. 1996. *Numerical Recipes in Fortran 90. The Art of Parallel Scientific Computing*. Cambridge.
 - [451] PRESS, W.H., TEUKOLSKY, S.A., VETTERLING, W.T. Y FLANNERY, B.P. 2007. *Numerical Recipes. The Art of Scientific Computing*. Third Edition. Cambridge.
 - [452] PYTLAK, R. 2009. *Conjugate Gradient Algorithms in Nonconvex Optimization*. Springer.
 - [453] QUARTERONI, A., SACCO, R. Y SALERI, F. 2000. *Numerical Mathematics*. Springer.
 - [454] QUARTERONI, A., SALERI, F. Y GERVASIO, P. 2010. *Scientific Computing with MATLAB and Octave*. Springer.
 - [455] RAO, S.S. 2002. *Applied Numerical Methods for Engineers and Scientists*. Prentice Hall.
 - [456] RAO, K.R., KIM, D.N. Y HWANG, J.J. 2010. *Fast Fourier Transform: Algorithms and Applications*. Springer.
 - [457] RAVINDRA, A., RAGSDELL, K.M. Y REKLAITIS, G.V. 2006. *Engineering Optimization. Methods and Applications*. Second Edition. Wiley.
 - [458] REDFERN, D. Y CAMPBELL, C. 1998. *The MATLAB 5 Handbook*. Springer.
 - [459] RECKTENWALD, G. 2000. *Numerical Methods with MATLAB. Implementation Application*. Prentice Hall.
 - [460] REDWINE, C. 1995. *Upgrading to Fortran 90*. Springer.
 - [461] REGISTER, A.H. 2007. *A Guide to MATLAB Object Oriented Programming*. Chapman and Hall/CRC.
 - [462] REID, J.K. ED. 1971. *Large Sparse Sets of Linear Equations*. Academic Press.
 - [463] REID, J.K. 1982. A Sparsity-Exploiting Variant of the Bartels-Golub Decomposition for Linear Programming Bases. *Mathematical Programming* 24, pp. 55-69.
 - [464] REKLAITIS, G.V., RAVINDRAN, A. Y RAGSDELL, K.M. 1983. *Engineering Optimization. Methods and Applications*. Wiley.
 - [465] RHEINOLDT, W.C. 1988. *Methods for Solving Systems of Nonlinear Equations*. SIAM.
 - [466] RIAZA, R. Y ÁLVAREZ, M. 1996. *Cálculo infinitesimal. Vols. I y II*. Sociedad de Amigos de la Escuela Técnica Superior de Ingenieros Industriales de Madrid.

- [467] RÍBNIKOV, K. 1987. *Historia de las matemáticas*. Editorial Mir.
- [468] RICE, J.R. 1966. *Experiments on Gram-Schmidt Orthogonalization*. Mathematics of Computation 20, pp. 325-328.
- [469] RICE, J.R. 1983. *Matrix Computations and Mathematical Software*. McGraw-Hill.
- [470] RICE, J.R. 1993. *Numerical Methods, Software, and Analysis*. Academic Press.
- [471] ROCKAFELLAR, R.T. 1970. *Convex Analysis*. Princeton University Press.
- [472] ROOS, C. TERLAKY, T. Y VIAL, J. 1997. *Theory and Algorithms for Linear Optimization. An Interior Point Approach*. Wiley.
- [473] ROOS, C. TERLAKY, T. Y VIAL, J. 2005. *Interior Point Methods for Linear Optimization*. Springer.
- [474] ROSE, D.J. Y WILLOUGHBY, R.A. EDS. 1972. *Sparse Matrices and Their Applications*. Plenum Press.
- [475] ROSEN, J.B., MANGASARIAN, O.L. Y RITTER, K. EDS. 1970. *Nonlinear Programming*. Academic Press.
- [476] RUTISHAUSER, H. 1990. *Lectures on Numerical Mathematics*. Birkhäuser.
- [477] SAAD, Y. 1994. *SPARSKIT: A Basic Tool Kit for Sparse Matrix Computations. Version 2*. Computer Science Department, University of Minnesota, Minneapolis, EE. UU.
- [478] SAAD, Y. 1996. *Iterative Methods for Sparse Linear Systems*. PWS.
- [479] SAIGAL, R. 1995. *Linear Programming. A Modern Integrated Analysis*. Kluwer Academic Publishers.
- [480] SALKIN, H.M. 1975. *Integer Programming*. Addison-Wesley.
- [481] SALKIN, H.M. Y MATHUR, K. 1989. *Introduction to Integer Programming*. North-Holland.
- [482] SALKIN, H.M. Y SAHA, J. EDS. 1975. *Studies in Linear Programming*. North-Holland.
- [483] SARGENT, R.W.H. Y WESTERBERG, A.W. 1964. *Speed-up in Chemical Engineering Design*. Trans. Inst. Chem. Eng. 42, pp.190-197.
- [484] SAUER, T. 2012. *Numerical Analysis*. Second Edition. Pearson.
- [485] SAUER, T. 2013. *Análisis numérico*. Segunda edición. Pearson educación.
- [486] SAUNDERS, M.A. 1976. *A Fast Stable Implementation of the Simplex Method using Bartels-Golub Updating*. En *Sparse Matrix Computations*. Bunch, J.R. y Rose, D.J. eds. Academic Press.
- [487] SAVILLE, D.J. Y WOOD, G.R. 1991. *Statistical Methods: The Geometric Approach*. Springer.
- [488] SAYAS, F.J. 2015. *A Gentle Introduction to the Finite Element Method*.
- [489] SCHATZMAN, M. 1991. *Analyse numérique. Cours et exercices pour la licence*. InterEditions.
- [490] SCHENDEL, U. 1989. *Sparse Matrices. Numerical Aspects with Applications to Scientists and Engineers*. Ellis Horwood Limited.
- [491] SCHERER, C.R. 1977. *Estimating Electric Power System Marginal Costs*. North-Holland.
- [492] SCHITTKOWSKI, K. ED. 1985. *Computational Mathematical Programming*. Springer.
- [493] SCHITTKOWSKI, K. 1980. *Nonlinear Programming Codes. Information, Tests, Performance*. Lecture Notes in Economics and Mathematical Systems, 183. Springer.
- [494] SCHITTKOWSKI, K. 1981. *Test Examples for Nonlinear Programming Codes*. Lecture Notes in Economics and Mathematical Systems, 187. Springer.

-
- [495] SCHITTKOWSKI, K. 2009. *Test Examples for Nonlinear Programming Codes. All Problems from the Hock-Schittkowski-Collection*. Department of Computer Science, University of Bayreuth.
 - [496] SCHRAGE, L. 1989. *User's Manual for Linear, Integer, and Quadratic Programming with LINDO*. The Scientific Press.
 - [497] SCHRAGE, L. 1991. *LINDO. An Optimization Modeling System*. Boyd and Fraser Publishing Company.
 - [498] SCHRIJVER, A. 1986. *Theory of Linear and Integer Programming*. Wiley.
 - [499] SCOTT, L.R. 2011. *Numerical Analysis*. Princeton University Press.
 - [500] SEDGEWICK, R. 1992. *Algorithms in C++*. Addison-Wesley.
 - [501] SEN, R. 2013. *A First Course in Functional analysis. Theory and Applications*. Anthem Press.
 - [502] SENIOR, T.B.A. 1986. *Mathematical Methods in Electrical Engineering*. Cambridge.
 - [503] SHAMPINE, L.F., GLADWELL, I. Y THOMPSON, S. 2003. *Solving ODEs with MATLAB*. Cambridge.
 - [504] SHAPIRO, J.F. 1979. *Mathematical Programming. Structures and Algorithms*. Wiley.
 - [505] SHEWCHUK, J.R. 1994. *An Introduction to Conjugate Gradient Method without the Agonizing Pain*. School Of Computer Science, Carnegie Mellon University.
 - [506] SIDDALL, J.N. 1982. *Optimal Engineering Design. Principles and Applications*. Marcel Dekker.
 - [507] SIERKSMA G. 1996. *Linear and Integer Programming: Theory and Practice*. Marcel Dekker.
 - [508] SIMONNARD, M. 1972. *Programmation Linéaire. Technique du Calcul Économique. Fondements*. Dunod.
 - [509] SIMONNARD, M. 1973. *Programmation Linéaire. Technique du Calcul Économique. Extensions*. Dunod.
 - [510] SKORNIAKOV, L.A. 1988. *Sistemas de Ecuaciones Lineales*. Editorial Mir.
 - [511] SMITH, B.T., BOYLE, J.M., DONGARRA, J.J., GARBOW, B.S., IKEBE, Y., KLEMA, V.C. Y MOLER, C.B. 1976. *Matrix Eigensystem Routines-EISPACK Guide*. Springer.
 - [512] SÓBOL, I.M. 1983. *Método de Montecarlo*. Editorial Mir.
 - [513] SOLODÓVNIKOV, A.S. 1980. *Sistemas de Desigualdades Lineales*. Editorial Mir.
 - [514] SORDET, J. 1970. *La Programmation Linéaire Appliquée à l'Entreprise*. Dunod.
 - [515] SORENSEN, D.C. 2015. *CAAM 454 Lecture Notes: Iterative Methods for Linear Systems*. Rice University, Department of Computational and Applied Mathematics
<http://www.caam.rice.edu/~caam551/NOTES/Notes454.pdf>
 - [516] SPEDICATO, E. ED. 1991. *Computer Algorithms for Solving Linear Algebraic Equations. The State of the Art*. Springer, NATO Scientific Affairs.
 - [517] STAGG, G.W. Y EL-ABIAD, A.H. 1968. *Computer Methods in Power Systems Analysis*. McGraw-Hill.
 - [518] STAHEL, A. 2012. *Numerical Methods*.
 - [519] STEVENSON, W. D. 1984. *Elements of Power System Analysis*. McGraw-Hill.
 - [520] STEWART, G.W. 1973. *Introduction to Matrix Computations*. Academic Press.
 - [521] STEWART, G.W. 1996. *Afternotes on Numerical Analysis*. SIAM.

- [522] STEWART, G.W. 1998. *Matrix Computations. Vol 1: Basic Decompositions*. SIAM.
- [523] STEWART, J. 2015. *Calculus*. Eighth Edition. Brooks/Cole.
- [524] STOER, J. Y BULIRSCH, R. 1980. *Introduction to Numerical Analysis*. Springer.
- [525] STOTT, B. Y ALSAC, O. 1974. *Fast Decoupled Load Flow*. IEEE Trans. on Power Apparatus and Systems PAS-93, pp. 859-869.
- [526] STRANG, G. 1976. *Linear Algebra and its Applications*. Academic Press.
- [527] STRANG, G. 1988. *Linear Algebra and its Applications*. Harcourt Brace Jovanovich.
- [528] STRAUSS, W.A. 2008. *Partial Differential Equations. An Introduction*. Second Edition. Wiley.
- [529] SÜLI, E. Y MAYERS, D. 2003. *An Introduction to Numerical Analysis*. Cambridge.
- [530] SULTAN, A. 1993. *Linear Programming. An Introduction with Applications*. Academic Press.
- [531] SÜLLI, E. 2012. *Lecture Notes on Finite Element Methods for Partial Differential Equations*. Mathematical Institute University of Oxford.
<http://people.maths.ox.ac.uk/suli/fem.pdf>
- [532] SUN, W. Y YUAN, Y-X. 2006. *Optimization Theory and Methods. Nonlinear Programming*. Springer.
- [533] TARJAN, R. 1972. *Depth-First Search and Linear Graph Algorithms*. SIAM J. Computing 1, pp. 146-160.
- [534] TEWARSON, R.P. 1973. *Sparse Matrices*. Academic Press.
- [535] THOMAS, B.J. 1996. *The Internet for Scientists and Engineers*. Oxford University Press.
- [536] THOMAS, G.B. 2014. *Thomas' Calculus*. Thirteenth Edition. Pearson.
- [537] TINNEY, W.F. Y WALKER, J.W. 1967. *Direct Solution of Sparse Network Equations by Optimally Ordered Triangular Factorizations*. Proceedings of the IEEE 55, pp.1801-1809.
- [538] TITS, A.L., WÄCHTE, A., BAKHTIARI, S., URBAN, T.J. Y LAWRENCE, G.T. 2003. *A Primal-Dual Interior-Point Method for Nonlinear Programming with Strong and Local Convergence Properties*. SIAM J. Optimizaton, Vol. 14, No. 1, pp. 173-199.
- [539] TOMLIN, J.A. 1970. *Branch-and-Bound Methods for Integer and Non-Convex Programming*. En Integer and Nonlinear Programming. Abadie, J. ed. North-Holland.
- [540] TOMLIN, J.A. 1972. *Pivoting for Size and Sparsity in Linear Programming*. J. Inst. Maths. Applics. 10, pp. 289-295.
- [541] TREFETHEN, L.N. Y BAU, D. 1997. *Numerical Linear Algebra*. SIAM.
- [542] TREFETHEN, L.N. 2005. *Who invented the great numerical algorithms?* Oxford University Mathematical Institute, Oxford University.
<http://www.maths.ox.ac.uk/~trefethen>
- [543] TYRRELL ROCKAFELLAR, R. 1972. *Convex Analysis*. Princeton University Press.
- [544] TYRRELL ROCKAFELLAR, R. Y WETS, R.J-B. 1997. *Variational Analysis*. Springer.
- [545] UEBERHUBER, C.W. 1995. *Numerical Computation. Methods, Software, and Analysis. Vols I y II*. Springer.
- [546] VAN DE PANNE, C. 1976. *Linear Programming and Related Techniques*. North-Holland.
- [547] VAN DER VORST, H.A. 2003. *Iterative Krylov Methods for Large Linear Systems*. Cambridge.

- [548] VAN LOAN, C.F. 1997. *Introduction to Scientific Computing. A Matrix-Vector Approach Using MATLAB*. Prentice Hall.
- [549] VANDERBEI, R.J. 2001. *Linear Programming. Foundations and Extensions*. Princeton University, Operations Research and Financial Engineering Dept.
- [550] VANDERBEI, R.J. 1999. *LOQO: An Interior Point Code for Quadratic Programming*. Journal on Optimization Methods and Software, Vol. 11, pp. 451-484
- [551] VARGA, R.S. 1962. *Matrix Iterative Analysis*. Prentice Hall.
- [552] VENKATARAMAN, P. 2002. *Applied Optimization with MATLAB Programming*. Wiley.
- [553] VILENKIN, N.YA. 1984. *Método de Aproximaciones Sucesivas*. Editorial Mir.
- [554] VILLANUEVA, I. 2016. *Apuntes de Ampliación de Cálculo*. Universidad Complutense de Madrid.
<http://www.mat.ucm.es/~cruizb/Informatica-2/Apuntes-i/Otros-Grupos/AC-Fourier.pdf>
- [555] WÄCHTER, A. Y BIEGLER, L.T. 2006. *On the Implementation of a Primal-Dual Interior Point Filter Line Search Algorithm for Large-Scale Nonlinear Programming*. Mathematical Programming 106, pp. 25-57.
- [556] WALSH, G.R. 1975. *Methods of Optimization*. Wiley.
- [557] WATKINS, D.S. 1991. *Fundamentals of Matrix Computations*. Wiley.
- [558] WATKINS, D.S. 2002. *Fundamentals of Matrix Computations*. Second Edition. Wiley.
- [559] WATKINS, D.S. 2007. *The Matrix Eigenvalue Problem. GR and Krylov Subspace Methods*. SIAM.
- [560] WELLIN, P., KAMIN, S. Y GAYLORD, R. 2005. *An Introduction to programming with Mathematica*. Cambridge.
- [561] WENTZEL, E.S. 1983. *Operations Research. A Methodological Approach*. Mir Publishers.
- [562] WHEEDEN, R.L. Y ZYGMUND, A. 2015. *Measure and Integral. An Introduction to Real Analysis*. Second Edition. CRC Press.
- [563] WHITE, R.E. 1985. *An Introduction to Finite Element Method with Applications to Nonlinear Problems*. Wiley.
- [564] WHITEHOUSE, G.E. Y WECHSLER, B. 1976. *Applied Operations Research: A Survey*. Wiley.
- [565] WILKINSON, J.H. 1965. *The Algebraic Eigenvalue Problem*. Oxford University Press.
- [566] WILKINSON, J.H. 1994. *Rounding Errors in Algebraic Processes*. Dover Publications.
- [567] WILSON, D.I. 2015. *Numerical Methods with MATLAB for Engineers*. Auckland University of Technology.
- [568] WILSON, H.B., TURCOTTE, L.H. Y HALPERN, D. 2003. *Advanced Mathematics and Mechanics Applications Using MATLAB*. Third Edition. Chapman and Hall/CRC.
- [569] WINSTON, W.L. 1994. *Operations Research. Applications and Algorithms*. Duxbury Press.
- [570] WOLFE, M.A. 1978. *Numerical Methods for Unconstrained Optimization. An Introduction*. Van Nostrand Reinhold Company.
- [571] WOLFE, P. 1961. *A Duality Theorem for Non-Linear Programming*. Quart. Appl. Math. 19, Nº 3.
- [572] WOLFE, P. 1967. *Methods of Nonlinear Programming*. En Nonlinear Programming. Abadie J. ed. North-Holland.

- [573] WONNACOTT, T.H. Y WONNACOTT, R.J. 1972. *Introductory Statistics for Business and Economics*. Wiley.
- [574] WOOD, A.J. Y WOLLENBERG, B.F. 1984.cc *Power Generation Operation and Control*. Wiley.
- [575] WRIGHT, M.H. 2004. *The Interior-Point Revolution in Optimization: History, Recent Developments, and lasting Consequences*. Bulletin of The American Mathematical Society, Vol. 42, No. 1, pp. 39-56.
- [576] WRIGHT, M.H. 1991. *Interior Methods for Constrained Optimization*. ATT Bell Laboratories. Acta Numerica.
- [577] WRIGHT, S.J. 1997. *Primal-Dual Interior Point Methods*. SIAM.
- [578] YANG, W.Y., CAO, W., CHUNG, T.-S. Y MORRIS, J. 2005. *Applied Numerical Methods Using MATLAB*. Wiley.
- [579] YOUNG, D.M. Y GREGORY, R.T. 1988. *A Survey of Numerical Mathematics. Vols. I y II*. Dover Publications.
- [580] ZIENKIEWICZ, O.C., TAYLOR, R.L. Y ZHU, J.Z. 2005. *The Finite Element Method: Its Basis and Fundamentals*. Second Edition. Elsevier.
- [581] ŽITKOVIĆ, G. 2017. *Introduction to Stochastic Processes. Lecture notes*. Department of Mathematics. The University of Texas at Austin.
https://www.ma.utexas.edu/users/gordanz/notes/introduction_to_stochastic_processes.pdf

Índice de materias y autores

A

- Abierto, conjunto o subconjunto, [13](#)
- Adherencia, [13](#)
 - de un conjunto, [13](#)
 - punto de, [13](#)
- Afinmente dependiente, independiente, [72](#)
- Álgebra, [32](#)
 - Teorema fundamental del Álgebra, [39](#)
 - σ -álgebra de Borel, [200](#)
- Algoritmo, [1](#)
 - Mersenne Twister, [214](#)
- Aliasing*, fenómeno en señales, [186](#)
- Aplicación, [2](#)
 - biyectiva, [3](#)
 - dominio de definición, origen, [3](#)
 - dominio de valores, [3](#)
 - imagen, [3](#)
 - inyectiva, [3](#)
 - lineal, [17](#)
 - núcleo, [17](#)
 - permutaciones, [3](#)
 - suprayectiva, [3](#)
 - traspuesta, [17](#)
- Autovalor, o valor propio, [34](#)

B

- Banach, S. [15](#)
 - espacio vectorial de, [15](#), [19](#)
- Base, de un espacio vectorial, [8](#)
 - canónica, [8](#)
- Bernoulli, D. [208](#)
- Bilineal, forma, [21](#)
- Biyectiva, aplicación, [3](#)
- Black, F.S. [222](#)
- Bola,
 - abierta, en un espacio vectorial normado, [12](#)
 - cerrada, en un espacio vectorial normado, [12](#)
 - euclídea, [78](#)
 - norma, [79](#)

- Borel, F.E.J.E. [200](#)
- Box, G.E.P. [216](#)
- Brown, R. [208](#)
- Browniano, movimiento, [208](#)

C

- $\mathbb{C}$, cuerpo de los números complejos, [1](#), [3](#)
- Campo escalar, [122](#)
- Campo vectorial, [122](#)
- Canónica,
 - base de un espacio vectorial, [8](#)
- Cantor, G.F.L.P. [1](#)
- Cara, de un politopo, [78](#)
- Carathéodory, C. [75](#)
- Cauchy, A.L. [15](#)
 - sucesión de, [15](#)
- Cauchy-Schwarz, desigualdad de [22](#)
- Cayley, A. [40](#), [29](#)
- Combinaciones convexas, [71](#)
 - estrictamente, [71](#)
- Combinación lineal, de vectores, [7](#)
- Compacto, subconjunto o conjunto, [14](#)
- Complemento, de un subconjunto, [2](#)
- Completo, espacio vectorial, [15](#)
- Componentes principales, [153](#)
- Compresión de imágenes y vídeo, JPG, MP3, [189](#)
- Condición,
 - de complementariedad de holguras, en programación lineal, [90](#)
 - de Lipschitz, R.O.S. [52](#)
 - número de, de una matriz, [253](#)

Condiciones,
necesarias y suficientes de primer y
segundo orden de un mínimo, 69

Conjugada de Fenchel, 103

Conjunto(s), 1

$\mathbb{N}$, 1

$\mathbb{Z}$, 1

$\mathbb{R}$, 1

$\mathbb{C}$, 1

$\mathbb{Q}$, 1

abierto, subconjunto de un espacio

normado, 13

entorno, 12

afín, 72

aplicación, función, transformación o

mapeo entre conjuntos, 1

imagen, conjunto imagen, 3

origen o dominio de definición, 3

dominio de valores, 3

inyectiva, 3

suprayectiva, 3

biyectiva, 3

cerrado, 13

compacto, 14

complemento, de un subconjunto, 2

convexo, 70, 71

cota superior mínima o supremo, 1

cota inferior máxima o ínfimo, 1

elemento o miembro, 1

elemento mínimo, 80

elemento máximo, 80

elemento minimal, 80

estructura algebraica en conjuntos, 3

grupo, 3

anillo, 3

cuerpo, 3

espacio vectorial, 3

frontera o borde de, 13

interior de, 13

intersección, 1

numerable, 3

sucesión de elementos, 3

límite superior de la sucesión, 3

límite inferior de la sucesión, 3

unión, 1

vacío, 1

Cono, 75

convexo, 75

dual, 81

norma, 79

puntiagudo 79

verdadero o apropiado, 79

Continuidad, 51

γ de Lipschitz, 52

Convergencia, de una sucesión en espacio

vectorial normado, 13

Convergencia puntual, 58

Convergencia uniforme, 58

Convexo,

conjunto, 70, 71

cono, 75

Convolución, de dos funciones, 183

Cooley, J.W. 185

Coordenadas baricéntricas, 73

Correlación, 154

coeficiente, matriz, 154

Cota

inferior máxima, o ínfimo, 2

superior mínima, o supremo, 2

Criterio o regla

de Weierstrass, 61

de Nyquist, 186

Cuadrática, forma, 48

D

Definida positiva,

forma cuadrática, 48

matriz, 36

Desnsidad de probabilidad, 201

Dependencia lineal, vectores de espacio

vectorial, 7

Derivada de una función, 53

Derivada de Fréchet, 54

Derivada de Gâteaux, 54

Descomposición,

o triangularización de Schur, 42

de Jordan, 42

en valores singulares, 45

espectral, 42

Desigualdad,

de Cauchy-Schwarz, 22

de Fenchel-Young, 105

Desigualdades generalizadas, 80

Diagonal dominante, matriz de, 37

Diferenciabilidad, 53
 Dimensión, de espacio vectorial, 8
 Dirac, P.A.M. 146
 función delta de, 146
 Dirección,
 de un politopo, 91
 extrema, 91
 Dirichlet, P.G.L. 135
 Distancia,
 en espacio vectorial normado, 10, 19
 Divergencia, de un campo vectorial 128
 Dominio
 de definición, de una aplicación, 2
 de valores, de una aplicación, 2
 Dual,
 espacio vectorial, 17
 Dualidad, en programación lineal, 100, 102
 débil, 97

E

Ecuación de Poisson, 133
 Ecuación característica, de una matriz, 39
 Elemento de un conjunto, 1
 Elemento minimal, 80
 Elemento mínimo, 80
 Elemento máximo, 80
 Eipsoide(s), 78
 degenerado, 78
 Endomorfismo, 17
 Entorno, de un punto en un conjunto, 13
 Envoltura afín, 72
 Envoltura cónica, 75
 Envoltura convexa, 71
 Epigrafo de una función, 51
 Escalar(es), 5
 Espacio afín, o variedad lineal, 76
 Espacio(s) vectorial(es), 5
 $\mathbb{P}_n$, 7
 $\mathbb{R}^n$, 7
 ℓ^p , 18
 L^p , 18
 aplicación, función o transformación, 17
 imagen y núcleo, 17
 variedad lineal, 17
 continua, 17
 base, 8
 base canónica o base estándar, 8

combinación lineal de vectores, 7
 completo, 15
 de Lebesgue, 26
 de Sobolev, 28
 de probabilidad, 200
 dimensión, 8
 distancia en espacio vectorial, 10
 elementos o vectores, 5
 elemento neutro o nulo, 5
 familia libre, 8
 funcional, elementos son funciones, 15
 generado o engendrado por un subconjunto, 8
 parte generadora, 8
 dual, 17
 métrico, 10, 19
 norma vectorial, 10
 norma euclídea, 11
 norma infinito o norma del supremo, 11
 p de Hölder, 11
 normado, 10
 bola abierta, en un espacio vectorial normado, 12
 bola cerrada, en un espacio vectorial normado, 12
 completo, 15
 de Banach, 19
 de Hilbert, 22
 euclídeo, 11, 22
 prehilbertiano, 21
 subespacio vectorial, 7
 subespacios suplementarios, 8
 variedad lineal o subespacio afín, 76
 vectores linealmente independientes, 7
 vectores linealmente dependientes, 7
 Esperanza matemática, de variable aleatoria, 202
 Espectral, norma de una matriz, 34
 Espectro de una matriz, 39
 Estrictamente dominante, matriz, 37
 Euclídeo, espacio vectorial, 22
 Euclides de Alejandría, 11
European call option, 222

F

Faceta, de un politopo, 78
 Factores *twiddle*, 162

Familia libre, en espacio vectorial, 8
Farkas, G. 88
Farkas, lema, 88
Fenchel, M.W. 71
 desigualdad de Fenchel-Young, 105
 función conjugada de, 103
Fermat, P. 70
Forma,
 bilineal, 21, 48
 cuadrática, 48
 rango, 48
 signatura, 48
 hermítica, 21
 lineal, 17
 sesquilineal, 21
Fórmula de Black y Scholes, 222
Formulación débil, 133, 135, 137
Formulación fuerte, 134
Fourier, J.B.J. 167
Fréchet, M. 54
Frecuencia de Nyquist, 186
Frobenius, F.G. 33
 norma de, 33
Frontera, o borde de un conjunto, 13
Fubini, G. 121
Función, 2
 afín, 52
 conjugada, 103
 de distribución, 202
 dual, 96, 97, 98, 100
 continua, 52
 continua γ de Lipschitz, 52
 convexa, 70
 matriz Hessiana de, 55
 objetivo, de un programa lineal, 69
 subdiferenciable, 56
Funcional, función de funciones, 145

G

Galerkin, B.G. 133
Gap de dualidad, 95, 98, 101, 103
 en condiciones de punto óptimo de
 Programación Lineal, 90
Gâteaux, R.E. 54
Gerschgorin, S.A. 44
 teorema de, 44
Gibbs, J.W. 174

 fenómeno de, 174
Goursat, É. 165
Gradiente, vector gradiente de una función, 53
Gráfico de una función, 51
Green, G. 136

H

Hadamard, J.S. 108
Hamilton, W.R. 40
Hermítica, forma, 21
Hessenberg, K.A. 38
 matriz de, 38
Hesse, L.O. 55
 matriz hessiana, 55
Hessiana, matriz de una función, 55
Hilbert, D. 22
 espacio vectorial, 22
Hiperplano, variedad lineal, 76
 separador, 85
 teorema de existencia, 84
 soporte, o de apoyo 78, 87
 teorema de existencia, 86
 vector característico, 76
Hipografo de una función, 51
Hölder, O. 11
 normas p de Hölder, 11
Homomorfismo, 17
Hotelling, H. 153

I

Imagen,
 de una aplicación, 2
 de una matriz, 31
 subespacio, 17
Independencia lineal, vectores en espacio
 vectorial, 7
Infimo, o cota inferior máxima, 2
Integral definida, 25, 58
Integral doble, 120
Integral de Cauchy, 165
Integral de Fourier, 179
Integral de Itô, 219
Integral de Riemann, 58
Integral de Lebesgue, 25
Integral en línea, 122, 123, 125
Interior, de un conjunto, 13
 punto, 13

Intersección, de conjuntos, 1
 Inyectiva, aplicación, 3
 Isométrico, operador, 22
 Itô, K. 219

J

Jacobi, C.G.J. 53
 Jacobiana, matriz, 53
 Jordan, M.E.C. 43

K

Karush, W. 90
 Karush-Kuhn-Tucker, condiciones en
 programación lineal, 90
 Kolmogorof, A.N. 207
 Kronecker, L. 140
 Krylov, A. 40
 subespacio de, 40
 Kuhn, H.W. 90

L

ℓ^p , espacio vectorial, 18
 L^p , espacio vectorial, 18
 Lagrange, J.L. 95
 multiplicadores, 100
 Laplace, P.S. 195
 Lebesgue, H.L. 26
 integral de, 25
 espacio de, 26
 Libre, familia, en espacio vectorial, 8
 Límite, de una sucesión, 19
 Lineal, forma, 17
 Lipschitz, R.O.S. 52
 condición de, 52
 función continua, 52

M

Markov, A.A. 212
 Maruyama, G. 220
 Matriz, 29
 congruente ortogonal, 43
 definida negativa, 36
 de covarianzas, 154, 203
 de diagonal dominante, 37
 de diagonal estrictamente dominante, 37
 de Hankel, 38
 de Hessenberg, 38
 de permutación, 39

 de proyección, 39
 de proyección ortogonal, 39
 de Vandermonde, 38
 ecuación característica, 39
 espectro, 39
 estrictamente dominante, 37
 hermítica, 36
 Hessiana, de una función, 55
 imagen, 31
 indefinida, 37
 Jacobiana, de una función vectorial, 53
 normal, 36
 núcleo, 31
 número de condición,
 ortogonal, 36
 pseudoinversa, 47
 radio espectral, 39
 rango, 31
 completo, 31
 regular, 31
 semejante a otra, 42
 semidefinida negativa, 36
 semidefinida positiva, 36
 simétrica, 36
 singular, 31
 unitaria, 36
 Matriz simétrica, 36
 definida negativa, 36
 definida positiva, 36
 indefinida, 36
 semidefinida positiva, 36
 semidefinida negativa, 36
 Matriz compañera, de un polinomio, 41, 40
 Matriz diagonalizable por semejanza, 42, 43
 Matriz de proyección, 39
 Matriz de proyección ortogonal, 39
 Matriz pseudoinversa, 47
 Menores, números de una matriz, 48
 Método Box-Müller, 216
 Método de Euler-Maruyama, 220
 Mersenne, M. 214
 Métrico, espacio vectorial, 19
 Mínimo global, 69
 Mínimo local, 69
 Mínimo local estricto, 69
 Minkowski, H.M. 10
 desigualdad de, 10

Modelo de Black y Scholes, 222

Moivre, A. 162

números de Moivre, 162

Montecarlo, método, 217

Moreau, J.J. 71

Movimiento Browniano, 208

Muestreo de señales, 185

Multiplicadores de Lagrange, en optimización

lineal, 90

en optimización, 90, 95, 99

N

$\mathbb{N}$, conjunto de los números naturales, 1

Neumann, K.G. 135

Norma,

bola, 79

cono, 79

de energía, 28

matricial, 31, 32

consistente, 32

de Frobenius, 32

espectral, 34

inducida, 34

$\|A\|_1$, 34

$\|A\|_\infty$, 34

vectorial, 10

$\|x\|_1$, 11

$\|x\|_\infty$, 11

euclídea, 11

p de Hölder, 11

Núcleo,

de una aplicación, 17

de una matriz, 31

Numerable, conjunto, 3

Número de condición de una matriz, 253

Nyquist, H. 186

O

Opción de compra, 222

Operador,

adjunto, 22

autoadjunto, 22

hermítico, 22

isométrico, 22

lineal 17

simétrico, 22

unitario, 22

Optimización, 69

sin condiciones, existencia de punto

mínimo, 69

con condiciones, lineales, 69

con condiciones, no lineales, 69

escalar, 111

optimización vectorial, 111

Óptimo de Pareto, 113

Ortante no negativo $\mathbb{R}_+^n$, 81, 96

Ortogonal(es),

matriz, 36

subespacio, 22

vectores, 22

Ortonormales, vectores, 22

P

Parte generadora, de un espacio vectorial, 7

Pareto, V.F. 113

Parseval, M-A. 178

Paseo aleatorio, 208

Pearson, K. 153

Permutación, matriz de, 36

Plano afín, 72

Poliedro, 78

Polinomio característico, de una matriz, 39

Polinomio de Taylor, 63

Polinomio mínimo de una matriz, 41

Polinomio mónico, 40

Polinomio trigonométrico, 167

coeficientes de Fourier, 167

frecuencia fundamental, 167

grado, 167

Politopo(s), 78

arista, 78

cara, 78

cónico, 78

dirección de un politopo, 91

extrema, 91

faceta, 78

y región factible de un programa lineal, 91

vértice, 78

Poisson, S.D. 133

Prehilbertiano, espacio vectorial, 21

Probabilidad, 200

condicionada, 205

densidad, 201

espacio de, 200

Problema de optimización escalar, 111
 Problema de optimización vectorial, 111
 Proceso, de Markov, 212
 Proceso, de Poisson, 212
 Proceso, de Wiener, 210
 Proceso estocástico, 206
 Producto escalar, o producto interior, en un espacio vectorial, 22
 Producto exterior, 31
 Programa dual, de uno lineal, 100, 102
 Proyección,
 matriz de, 39
 ortogonal de un vector, 39
 matriz de, 39
 teorema de la, 23
 Proyector suplementario, 39
 Punto,
 de acumulación, 13
 de adherencia, 13
 extremo de una región factible, 75
 de conjunto convexo, 75
 estacionario, 69
 interior, 13
 Punto extremo o vértice de una región factible, 75

Q

$\mathbb{Q}$, conjunto de los números racionales, 1

R

$\mathbb{R}$, cuerpo de los números reales, 1, 3
 Radio espectral de una matriz, 39
 Rango,
 de una forma cuadrática, 48
 de una matriz, 31
 completo, 31
 Región factible,
 punto extremo, o vértice, 75
 y politopo, 91
 Regla,
 del triángulo, 10
 desigualdad de Minkowski, 10
 Resto de Taylor, 63
 Riemann, G.F.B. 58
 Riesz, F 110
 Ritz, W. 131
 Rockafellar, R.T. 71

Rolle, M. 65

S

Sampleo de señales, 185
 Scholes, M.S. 222
 Schur, I. 42
 Schwarz, K.H.A. 22
 Schwarz, desigualdad de Cauchy-Shwarz, 22
 Semidefinida negativa,
 matriz, 36
 Semidefinida positiva,
 matriz, 36
 Semiespacio,
 abierto, 76
 cerrado, 76
 Separador, hiperplano, 85
 Serie de Taylor, 63
 Serie trigonométrica de Fourier, 167
 Sesquilineal, forma, 21
 en un espacio vectorial, 21
 Shannon, C.E. 186
 Signatura, de una forma cuadrática, 48
 Símplex, o simplejo, 72
 símplex unidad, 73
 Stokes, G.G. 129
 Subconjunto, 1
 abierto, 13
 cerrado, 13
 compacto, 13
 Subespacio(s),
 de Krylov, 40
 imagen, de una aplicación, 17
 ortogonal, 23
 propio, 39
 suplementarios, 8
 vectorial, 7
 Subdiferencial, de una función, 56
 Subgradiente, de una función, 56
 Sucesión, 3
 convergencia en un espacio vectorial normado, 19
 de Cauchy, 15
 de elementos de un conjunto, aplicación, 3
 límite de, 19
 Suma directa, de dos subespacios vectoriales, 8
 Suprayectiva, aplicación, 3
 Supremo, o cota superior mínima, 2

Sylvester, J.J. 29

T

Taylor, B. 63

teorema de, 63

desarrollo en serie de, 63

polinomio de, 63

resto de, 63

serie de, 63

Teorema,

central del límite, 217

de Abel, 62

de Cayley-Hamilton, 39

de Fermat, 70

de Fubini, 120

de Green, 127

de Nyquist-Shannon, 186

de Parseval, 178

de Riesz-Fréchet, 110

de Rolle, 65

de Stokes, 129

de Taylor, 63

de la divergencia, 136

de la dualidad fuerte, 99

de la función implícita, 67

del valor intermedio, 64

del valor medio, 64

espectral, 42

fundamental del álgebra, 39

fundamental del cálculo, 58

fundamental de la Programación Lineal, 93

fundamental de las integrales en línea, 125

Weierstrass, 52

Transformación,

de Fenchel, 103

Transformada de Fourier, 181

Transformada de Fourier discreta, 183

Transformada de Karhunen-Loève, 192

Transformada de Laplace, 195

Transformada del coseno discreta, 189

Transformada inversa de Fourier, 181

Transformada rápida de Fourier, 185

Triángulo, regla, 10

Tucker, A.W. 90

Tukey, J. 185

U

Ulam, S.M. 217

Unidad imaginaria, 161

Unión, de conjuntos, 1

V

Valor(es) propio(s), 39

defectuoso, 39

dominante, 41

multiplicidad algebraica, 39

multiplicidad geométrica, 39

Valor(es) singular(es), 43

descomposición en, 45

Vandermonde, A.T. 38

Vandermonde, matriz de, 38

Variable aleatoria, 201

densidad de probabilidad, 201

esperanza matemática, 202

función de distribución, 202

varianza, 202

Variedad afín, variedad lineal, 72

Variedad lineal, hiperplano, 76

separador, 85

teorema de existencia, 84

soporte, 78, 87

teorema de existencia, 86

vector característico, 76

Vector(es), 3

aleatorio, 203

alineados, 23

característico, de un hiperplano o variedad lineal, 76

formado ángulo obtuso, 23

formado ángulo agudo, 23

gradiente, 53

linealmente dependientes, 7

linealmente independientes, 7

opuestos, 23

ortogonales, 22

ortonormales, 22

Vector propio, 41

Vértice de una región factible, 75

de un politopo, 78

Von Neumann, J. 217

W

Weierstraß, K.T.W. 14

criterio de, [61](#)

teorema de, [52](#)

Wiener, N. [210](#)

Wiener, Proceso de, [210](#)

Wolfe, P.S. [102](#)

Z

$\mathbb{Z}$, conjunto (anillo) de los números enteros, [1](#)

