

Matemáticas y algoritmos numéricos

Definiciones, notación y proposiciones
esenciales para un curso avanzado

José Luis de la Fuente O'Connor

www.jldelafuenteoconnor.es

Matemáticas y Algoritmos Numéricos. Definiciones, notación y proposiciones
esenciales para un curso avanzado

Primera edición: agosto 2016

© Derechos de edición reservados.

Editorial Círculo Rojo.

www.editorialcirculorojo.com

info@editorialcirculorojo.com

Colección© Investigación

Edición: Editorial Círculo Rojo

Maquetación: © JLFO

Fotografía de cubierta: © Fotolia.com

Diseño de portada: © Nieves Molina

Producido por: Editorial Círculo Rojo.

ISBN: 978-84-9140-231-2

DEPÓSITO LEGAL: AL-1201-2016

Ninguna parte de esta publicación, incluido el diseño de cubierta, puede ser reproducida, almacenada o transmitida en manera alguna y por ningún medio, ya sea electrónico, químico, mecánico, óptico, de grabación, en Internet o de fotocopia, sin permiso previo del editor o del autor. Todos los derechos reservados. Editorial Círculo Rojo no tiene por qué estar de acuerdo con las opiniones del autor o con el texto de la publicación, recordando siempre que la obra que tiene en sus manos puede ser una novela de ficción o un ensayo en el que el autor haga valoraciones personales y subjetivas.

«Cualquier forma de reproducción, distribución, comunicación pública o transformación de esta obra sólo puede ser realizada con la autorización de sus titulares, salvo excepción prevista por la ley. Diríjase a CEDRO (Centro Español de Derechos Reprográficos) si necesita fotocopiar o escanear algún fragmento de esta obra (www.conlicencia.com; 91 702 19 70 / 93 272 04 47)».

IMPRESO EN ESPAÑA – UNIÓN EUROPEA

A mi familia

Índice

Prefacio	v
1 Conjuntos	1
2 Espacios vectoriales	2
2.1 Espacios normados, espacios métricos	6
2.2 Espacios con producto interior	10
2.3 Aplicaciones lineales	12
3 Topología	13
4 Matrices	15
4.1 Normas de matrices	18
4.2 Matrices ortogonales, unitarias, simétricas, Hessenberg, de permutación y de proyección	21
4.3 Valores propios, valores singulares y formas cuadráticas	24
4.3.1 Valores propios	24
4.3.2 Valores singulares	28
4.3.3 Formas cuadráticas	31
5 Teorema de la proyección	33
6 Funciones	34
6.1 Condiciones necesarias y suficientes de punto mínimo	40
6.2 Teorema de la función implícita	41
7 Optimización y Programación Matemática	42
7.1 Conjuntos convexos	43
7.2 Caracterización del problema de optimización y condiciones de punto óptimo	54
7.3 Dualidad	58
7.3.1 Dualidad Lagrangiana	63
7.3.2 Dualidad de Wolfe	64
7.3.3 Ejemplo	64
8 Sobre el método de los elementos finitos para resolver ecuaciones en derivadas parciales	65
8.1 Solución de una ecuación en derivadas parciales	69
8.1.1 El problema en forma débil o variacional	70

8.1.2	Espacios de trabajo	72
8.1.3	Discretización del problema en un subespacio de elementos finitos lineales	74
8.1.4	Reformulación del problema como un sistema de ecuaciones lineales	78
8.2	Algo sobre funcionales y cálculo de variaciones	79
8.2.1	Proposiciones esenciales	83
9	Análisis de componentes principales	85
9.1	Algunos conceptos de estadística	86
9.2	Planteamiento del problema matemático	88
10	Números complejos	93
11	Bibliografía	96

Prefacio

El contenido de este libro es una introducción de referencia y apoyo a todo el contexto matemático y algorítmico de la asignatura *Matemáticas de la Especialidad-Ingeniería Eléctrica* que desde hace varios años dicto en la Escuela Técnica Superior de Ingenieros Industriales, de la Universidad Politécnica de Madrid. Esta adscrita al Grado de Tecnologías Industriales de esa Escuela.

Dado que recopila de forma sencilla conceptos útiles para asuntos de interés matemático diverso sobre los que trabajan los alumnos y futuros ingenieros, han sido muchos los compañeros y amigos que me han animado a formatearlo como un libro y ponerlo en el dominio público para que, además de en mi sitio web —donde ha estado desde hace bastantes años—, pueda ser leído, consultado o estudiado con una hechura tradicional.

En el contenido del libro el lector encontrará conceptos, referencias históricas, definiciones, relaciones y resultados básicos de matemáticas que yo considero útiles tener a mano para poder seguir el desarrollo de la citada asignatura, así como similares, de manera provechosa, y poder recordarlos si ha lugar en el futuro de forma rápida y en un mismo volumen. Su énfasis es en las matemáticas que respaldarán los procedimientos numéricos prácticos que necesita comprender y desarrollar la ingeniería y ciencias aplicadas con las que tendrán que lidiar ingenieros y graduados en su desempeño profesional. Prácticamente todo lo escrito lo he estudiado y abordado en el curso de mi trayectoria profesional y en la asignatura indicada, así como en otras dictadas a lo largo de mi carrera docente.

Con los conceptos y resultados vertidos puede ser mucho más intuitivo comprender cómo funcionan las matemáticas inherentes a muchos de los algoritmos y métodos que hoy en día están presentes en bastantes de los desarrollos del *Big Data*, optimización matemática y otras cuestiones de la tan de moda *economía digital*, con la que convivimos todos los días. Con ellos como referencia se puede imaginar cómo pueden ser mejorados o hacerlos evolucionar para desarrollar las nuevas herramientas de optimización no lineal, integración de ecuaciones diferenciales complicadas, etc. que se necesitan en estos desafíos y otros que se pondrán por delante.

Lo que se expone en las pocas páginas del libro es una síntesis o guía práctica de muchos años dedicado a investigar, primero y enseñar lo practicado y seguir investigando después, sobre todo lo que tiene que ver con las técnicas y algoritmos numéricos que nos permiten, mediante el Cálculo y Análisis Matemático, y la Ingeniería de sus Métodos Numéricos, simular la realidad con la que nos enfrentamos a diario para identificarla y atacar los diversos problemas prácticos que nos acucian y que la inteligencia humana decide abordar. En especial algunos ejemplos se refieren a la ingeniería eléctrica, pero que son extensibles a otros muchos

campos del conocimiento y la ciencia.

Mediante el diseño e ingeniería de los procedimientos numéricos podemos estudiar y resolver problemas prácticos también de las ciencias sociales, medicina y otras áreas de conocimiento importantes para la vida de las personas —aquellos de base científica que se modelizan y simulan en términos matemáticos— y analizar la idoneidad de sus resultados para el interés general y para otras ramas que se puedan beneficiar de un trasvase de ideas y resultados. Todo ello ayudado con los ordenadores a nuestro alcance y con programas muy probados y potentes que nos permiten realizar pasos intermedios muy eficazmente y a mucha velocidad.

El libro en ningún caso recoge un exhaustivo recordatorio de las matemáticas que debe conocer un ingeniero, pues según se adentra en nuevas parcelas del saber y la investigación el panorama se agranda enormemente. La notación que se introduce, de forma sistemática y sencilla, es para poderla usar en todas las lecciones y presentaciones que explicamos y enseñamos en las clases mencionadas, y como medio para uniformizar todo el contexto de la exposición y aprendizaje si ello es posible.

Al final del libro se lista un conjunto de referencias básicas. No pretende sino apuntar con qué libros o artículos se pueden estudiar y aprender los fundamentos de casi todo lo expuesto en este libro, y algo más.

El el sitio web que se cita más abajo se pueden encontrar los guiones y apuntes de lecciones teóricas y prácticas que dicto en la universidad tomando como base el contenido de este libro; también, *software* para dar significación práctica a esas lecciones y apostillar mediante pequeños programas muchos de los resultados que se presentan en este volumen.

Si algún amable lector tiene a bien aportarme cualquier sugerencia, lo agradeceré infinitamente.

José Luis de la Fuente O'Connor

Alcobendas, 20 de julio de 2016

www.jldelafuenteoconnor.es

1 Conjuntos

LAS matemáticas modernas tienen mucho que ver con los conjuntos. Un *conjunto* es una colección de objetos: los números naturales, las soluciones de un problema determinado, los municipios de una provincia, etc. Se identifica por una letra mayúscula: el conjunto S , el conjunto de los números naturales $\mathbb{N}$, el de los enteros $\mathbb{Z}$, el de los reales $\mathbb{R}$, complejos $\mathbb{C}$, racionales $\mathbb{Q}$, etc.

Cada uno de los objetos en la colección es un *elemento* o *miembro* del conjunto. Si un elemento a pertenece a un conjunto se indica $a \in S$. Los conjuntos se definen mediante la enumeración entre llaves de sus elementos, $S = \{a, b, \dots\}$, o especificando, también entre llaves, la propiedad que los caracteriza, $S = \{x : x \in \mathbb{R}, x \leq 2\}$: números reales menores o iguales que dos.

El conjunto sin elementos se denomina *vacío*, designándose $\emptyset$. Ejemplo: el conjunto S de los números reales x que son mayores que 1 y menores que 0: esto es, $S = \{x \in \mathbb{R} : x > 1, x < 0\}$.

Si S y S' son dos conjuntos y todos los elementos del conjunto S' lo son de S , se dice que S' es un *subconjunto* del conjunto S , o que está contenido en S' , expresándose $S' \subset S$ o $S \supset S'$.

La *unión* de dos conjuntos S y T , expresada $S \cup T$, es el conjunto formado por los elementos que pertenecen a S o a T .

La *intersección* de S y T , expresada $S \cap T$, es el conjunto formado por los elementos que pertenecen a S y a T .

Si S' es un subconjunto de S , el *complemento* de S' en S es el conjunto formado por los elementos de S que no pertenecen a S' .

Si a y b son números reales, y $a \leq b$, el conjunto de números x de la recta real tales que $a \leq x \leq b$ se indica $[a, b]$. El formado por los x tales que $a < x \leq b$, por $(a, b]$. El de los x que verifican que $a < x < b$, por (a, b) .

Si S es un conjunto no vacío de números reales acotados superiormente —mayorados—, existe un número real mínimo y tal que $x \leq y$ para todo $x \in S$. Al número y se le denomina *cota superior mínima* o *supremo* de S ; se expresa así:

$$\sup_{x \in S} (x) \quad \text{o} \quad \sup \{x : x \in S\}.$$

De forma similar se define la *cota inferior máxima* —o *ínfimo*— de un conjunto S no vacío de números reales acotados inferiormente o minorados:

$$\inf_{x \in S} (x) \quad \text{o} \quad \inf \{x : x \in S\}.$$

Dados dos conjuntos S y T , una *aplicación*, *transformación* o *mapeo* f de S en T , expresada como $f : S \rightarrow T$, es una asociación o criterio que a cada elemento de S hace corresponder uno de T .

La *imagen* de un elemento $x \in S$ con la aplicación $f : S \rightarrow T$ es el elemento $f(x) \in T$. El *conjunto imagen* $f(S) = \{f(x) \in T, \text{ para todo } x \in S\}$. La imagen de un subconjunto $S' \subset S$ con la aplicación f sería, por consiguiente, el subconjunto $\text{imagen } f(S')$. El conjunto S se conoce como *origen* o *dominio de definición* y el T como *dominio de valores*. Una aplicación $f : S \rightarrow T$ se dice *inyectiva* si para cualquier par de elementos $x, y \in S$, $x \neq y$, se cumple que $f(x) \neq f(y)$. Ejemplo, la aplicación $f : \mathbb{R} \rightarrow \mathbb{R}$, definida por $f(x) = x^2$, no es inyectiva, pues $f(1) = f(-1) = 1$.

Una *función* es un caso particular de aplicación en donde los conjuntos origen e imagen son conjuntos de números: $\mathbb{R}$, $\mathbb{C}$, $\mathbb{Z}$, $\mathbb{N}$, etc.

Una aplicación $f : S \rightarrow T$ se dice *suprayectiva* —sobreyectiva, epiyectiva, suryectiva o exhaustiva— si el conjunto imagen $f(S)$ es igual a todo el conjunto T ; es decir, para todo $y \in T$ existe un $x \in S$ tal que $f(x) = y$.

Una aplicación se dice *biyectiva* si es inyectiva y suprayectiva. Ejemplo, si J_n es el conjunto de los números enteros de 1 a n , $J_n = \{1, \dots, n\}$, y se define una aplicación $\sigma : J_n \rightarrow J_n$ que modifica el orden de disposición de los elementos de J_n —estas aplicaciones se denominan *permutaciones*—, tal aplicación es biyectiva.

Un conjunto S se dice *numerable* si existe una biyección entre $\mathbb{N}$ y S : a cada uno de los n elementos k , $1 \leq k \leq n$, se le asocia un elemento $a_k \in S$, esto es: $k \mapsto a_k$.

Una *sucesión* de elementos de un conjunto T es una aplicación de $\mathbb{N}$ en T : a cada elemento $n \geq 1$ se le hace corresponder un $x^{(n)} \in T$: $n \mapsto x^{(n)}$. Tal sucesión se expresa como $\{x^{(1)}, x^{(2)}, \dots\}$ o $\{x^{(n)}\}_{n \geq 1}$.


Los conjuntos dotados de ciertas leyes de composición o asociación interna —adición, multiplicación, división o cualquier otra—, se dice que poseen una *estructura*. Las estructuras algebraicas fundamentales son *grupo*, *anillo* ($\mathbb{Z}$ por ejemplo), *cuerpo* ($\mathbb{R}$ y $\mathbb{C}$, por ejemplo) y *espacio vectorial*.

2 Espacios vectoriales

UN *espacio vectorial* E es una estructura algebraica creada a partir de un conjunto no vacío, una ley de composición interna, *adición*, definida para los elementos del conjunto con las siguientes propiedades —grupo conmutativo—

$$\begin{aligned}x + y &= y + x \\(x + y) + z &= x + (y + z) \\x + \emptyset &= x \\x + (-x) &= \emptyset\end{aligned}$$

y una ley de composición externa, *producto por un escalar*, definida entre dicho



conjunto y otro conjunto, K , con estructura de cuerpo, con las siguientes propiedades,

$$\begin{aligned}
 1 \cdot x &= x \\
 \alpha(\beta x) &= (\alpha\beta)x \\
 (\alpha + \beta)x &= \alpha x + \beta x \\
 \alpha(x + y) &= \alpha x + \alpha y,
 \end{aligned}$$

válidas cualesquiera que sean x, y, z en E y α, β en K . A $\emptyset$ se le denomina elemento neutro y a $-x$ el opuesto de x . Es usual denominar *vectores* a los elementos de E y *escalares* a los de K . En las aplicaciones que se estudian habitualmente los casos más importantes ocurren cuando $K = \mathbb{R}$ o $K = \mathbb{C}$. Con la notación $\mathbf{K}$ designaremos a cualquiera de los cuerpos $\mathbb{R}$ o $\mathbb{C}$ y por x un vector cualquiera de un espacio vectorial.

El paradigma de espacio vectorial lo constituye el formado por sucesiones ordenadas de n elementos cualesquiera de K , o n -uplas $x = [x_1, \dots, x_n]$, definiendo la suma de vectores mediante

$$[x_1, \dots, x_n] + [y_1, \dots, y_n] = [x_1 + y_1, \dots, x_n + y_n]$$

y el producto por un escalar mediante

$$\alpha[x_1, \dots, x_n] = [\alpha x_1, \dots, \alpha x_n].$$

Si los elementos están definidos en $\mathbb{R}$, el espacio vectorial se denomina $\mathbb{R}^n$, si lo están en $\mathbb{C}$, el espacio vectorial es $\mathbb{C}^n$. Si $\Omega \subset \mathbb{R}^n$ es un conjunto abierto de $\mathbb{R}^n$, el

conjunto de todas las funciones continuas en Ω forman un espacio vectorial lineal $C(\Omega)$ en $\mathbb{R}^n$ con las operaciones suma y producto por un escalar,

$$(f + g)(\mathbf{x}) = f(\mathbf{x}) + g(\mathbf{x}), \quad \mathbf{x} \in \Omega$$

$$(\alpha f)(\mathbf{x}) = \alpha f(\mathbf{x}), \quad \mathbf{x} \in \Omega.$$

Mediante $C(\overline{\Omega})$ se designa el espacio vectorial lineal de las funciones continuas en el conjunto cerrado $\overline{\Omega}$. Este último espacio, y $C(\Omega)$, son una variedad de espacio vectorial denominada *espacio funcional* pues sus elementos son funciones en vez de vectores propiamente dichos. Cualquier función continua en $C(\overline{\Omega})$ es claramente continua en $C(\Omega)$. Igualmente, si $f \in C(\Omega)$ es continua en Ω y Ω está acotado, la función f se puede suponer continua también en $\partial\Omega$, la frontera o borde de Ω , y entenderse que es continua por tanto en $C(\Omega)$ y pertenece a dicho conjunto. Recordemos también que f se supone continua (o uniformemente continua) en Ω si para cualquier $\varepsilon > 0$ existe un $\delta = \delta(f, \varepsilon) > 0$ tal que $|f(\mathbf{x}) - f(\mathbf{y})| < \varepsilon$, cualesquiera sean $\mathbf{x}, \mathbf{y} \in \Omega$ con $\|\mathbf{x} - \mathbf{y}\| < \delta$.

Otro espacio vectorial interesante es $C^m(\Omega)$, el de funciones continuas con derivadas parciales continuas hasta orden m en Ω , o $C^m(\overline{\Omega})$ en $\overline{\Omega}$. También $C_p(2\pi)$, de funciones continuas periódicas- 2π , es decir, funciones $f \in C(-\infty, \infty)$ tales que $f(x + 2\pi) = f(x)$, $-\infty < x < \infty$. O $C_p^k(2\pi)$ de funciones continuas periódicas- 2π con derivadas continuas hasta orden k . Alguna vez se indica $C_p^0(2\pi)$ para referirse a $C_p(2\pi)$.

Otros espacios vectoriales habituales son $\mathbb{P}_n$, de polinomios de grado n , $p_n(x) = \sum_{k=0}^n a_k x^k$, con coeficientes a_k reales o complejos.

El conjunto $L_1[a, b]$ de todas las funciones del cuerpo de los números reales cuyo valor absoluto es integrable en el intervalo $[a, b]$ es un espacio vectorial funcional. También lo es $L_2[a, b]$, el conjunto de todas las funciones reales al cuadrado integrables en $[a, b]$. Es de destacar que en ambos casos estas funciones no tienen por qué ser continuas en ese intervalo.

Un *subespacio vectorial* M de un espacio vectorial E sobre un cuerpo K es un subconjunto no vacío que es un espacio vectorial sobre K . Es decir, es cerrado respecto de las operaciones de adición y producto por un escalar: que cumple que

$$\forall \mathbf{x}, \mathbf{y} \in M \implies \mathbf{x} + \mathbf{y} \in M,$$

$$\forall \mathbf{x} \in M \text{ y } \forall \lambda \in K \implies \lambda \mathbf{x} \in M.$$

La intersección de una familia cualquiera de subespacios de E es también un subespacio.

Si X es un subconjunto cualquiera de E el subespacio $\text{Gen}\{X\}$, *generado o engendrado* por X , es la intersección de todos los subespacios que contienen a X . Cuando $\text{Gen}\{X\} = E$, se dice que X es una *parte generadora* de E .

Dados vectores $\mathbf{x}_1, \dots, \mathbf{x}_n$ y escalares $\lambda_1, \dots, \lambda_n$, el vector formado según la expresión

$$\mathbf{x} = \lambda_1 \mathbf{x}_1 + \dots + \lambda_n \mathbf{x}_n$$

se dice que es una *combinación lineal* de los vectores $\mathbf{x}_1, \dots, \mathbf{x}_n$ de coeficientes $\lambda_1, \dots, \lambda_n$. Un subconjunto X de E es un subespacio si y sólo si contiene a cualquier combinación lineal de cualquier subconjunto finito de vectores de X . También se demuestra que el subespacio $\text{Gen}\{X\}$ es el conjunto de todas las combinaciones lineales de vectores de X .

Un conjunto de vectores $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ se dicen *linealmente dependientes* si existen escalares λ_i , no todos cero, tales que $\sum_{i=1}^k \lambda_i \mathbf{x}_i = \mathbf{0}$; *linealmente independientes*, si

$$\sum_{i=1}^k \lambda_i \mathbf{x}_i = \mathbf{0} \implies \lambda_i = 0, \quad 0 \leq i \leq k.$$

Una parte X de un espacio vectorial E se dice que es una *familia libre* si los vectores de cualquier subconjunto finito de X son linealmente independientes.

La *dimensión* de un subespacio es el máximo número de vectores linealmente independientes en el subespacio.

Una *base* de un espacio vectorial E es cualquier subconjunto B de E que sea, simultáneamente, una parte libre y generadora de E ; dicho de otra forma, una base de un espacio vectorial es un conjunto —normalmente se supone ordenado (numerado)— de vectores linealmente independientes que generan (o engendran) dicho espacio. Se demuestra que cualquier espacio vectorial tiene una base y que todas las bases de un mismo espacio tienen la misma cardinalidad —se pueden poner en biyección—. Cuando el cardinal de las bases es un número natural, $n \in \mathbb{N}$, se dice que el espacio es de dimensión finita n . En un espacio vectorial K^n ,

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \dots, \mathbf{e}_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix},$$

forman una base en dicho espacio; éste, por tanto, tiene dimensión n . Esta base se denomina *base canónica* o *base estándar* de K^n . En esta base, cualquier vector $\mathbf{x}^T = [x_1, x_2, \dots, x_n]$ se puede expresar de la siguiente forma:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} + \dots + x_n \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}.$$

Es decir $\mathbb{R}^n = \text{Gen}\{e_1, \dots, e_n\}$. La base estándar de $\mathbb{P}_n$ es $S = \{1, t, t^2, \dots, t^n\}$.

Si A y B son subconjuntos de un espacio vectorial E , el conjunto $A + B$ se define como:

$$A + B = \{a + b : a \in A, b \in B\}.$$

Cuando A y B son subespacios, también lo es la suma $A + B$. Si además $A \cap B = \emptyset$, la suma se denomina *directa*, escribiéndose $A \oplus B$. Si $A \oplus B = E$, cualquier vector $c \in E$ se descompone de manera única como $c = a + b$, con $a \in A$ y $b \in B$; también se dice que A y B son *subespacios suplementarios*.

2.1 Espacios normados, espacios métricos

Si en un espacio vectorial E sobre $\mathbf{K}$ ($\mathbb{R}$ o $\mathbb{C}$) se define una *norma vectorial* como una aplicación $\|\cdot\| : E \rightarrow \mathbb{R}$ que verifica

$$\|v\| = 0 \implies v = 0 \text{ y } x \neq 0 \implies \|x\| > 0,$$

$$\|\alpha v\| = |\alpha| \|v\| \text{ para } \alpha \in K \text{ y } v \in E,$$

$$\|u + v\| \leq \|u\| + \|v\| \quad \forall u, v \in E,$$

se dice que E es un *espacio vectorial normado*.




Figura 2.1: Representación gráfica de la regla del triángulo

La condición $\|u + v\| \leq \|u\| + \|v\|$ es la desigualdad de Minkowski —por Hermann Minkowski, Lituania 1864-1909—; se conoce también como *regla del triángulo*. Es una generalización del hecho de que un lado de un triángulo no puede ser mayor que la suma de los otros dos: ver figura 2.1. Una variante de esta regla es la siguiente: $\|u - v\| \geq \|u\| - \|v\|$.

En un espacio vectorial normado se define la *distancia* entre dos elementos u y v mediante

$$d(u, v) = \|u - v\|.$$

Esta definición convierte a cualquier espacio vectorial normado en un *espacio métrico*. El espacio de los números reales, por ejemplo, con la distancia $\rho(x, y) = |x - y|$ es el espacio métrico $\mathbb{R}^1$.

En el espacio vectorial $\mathbf{K}^n$, para $1 \leq p < \infty$, se tiene la familia de normas

$$\|\mathbf{x}\|_p = \sqrt[p]{|x_1|^p + \cdots + |x_n|^p}$$

denominadas *normas p de Hölder* —por Otto Hölder, Alemania 1859-1937—. Casos particulares lo constituyen las correspondientes a $p = 1$ y $p = 2$:

$$\begin{aligned}\|\mathbf{x}\|_1 &= \sum_{i=1}^n |x_i| \\ \|\mathbf{x}\|_2 &= \sqrt{|x_1|^2 + \cdots + |x_n|^2}.\end{aligned}$$

Esta última se denomina en $\mathbb{R}^n$ *norma euclídea*, por Euclides de Alejandría, Grecia, 325-265 a.C. También en $\mathbf{K}^n$ es una norma la dada por

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

Estas normas cumplen, cualquiera que sea $\mathbf{x} \in \mathbf{K}^n$, que

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq n \|\mathbf{x}\|_\infty.$$

Si la bola cerrada unidad en $\mathbb{R}^2$ es el conjunto $\{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\| \leq 1\}$, su forma en espacios vectoriales normados por la 1, 2, ∞ y p son las que representa la figura 2.2.

En el espacio $C[0, 1]$ de funciones continuas del intervalo $[0, 1]$ en $\mathbb{C}$, son normas las dadas por

$$\|f\|_p = \left[\int_0^1 |f(t)|^p dt \right]^{1/p}$$

donde, si $f : \mathbb{C} \rightarrow \mathbb{C}$, se define la *integral definida* de esta función en el intervalo $[a, b]$,

$$I(f) = \int_a^b f(x) dx,$$

como el límite de las sumas de Riemann, por Georg Friedrich Bernhard Riemann, Alemania 1826-1866, $R_n = \sum_{i=1}^n (x_{i+1} - x_i) f(t_i)$, $x_1 = a$, $x_{n+1} = b$, $x_i \leq t_i \leq x_{i+1}$, cuando la partición en subintervalos se hace muy fina. También en una norma la dada por

$$\|f\|_\infty = \max_{t \in [0, 1]} |f(t)|.$$




Figura 2.2: Forma de la bola unidad para diferentes normas en $\mathbb{R}^2$

Los espacios de funciones $L_p([0, 1])$, $p > 1$, con la norma

$$\|x\| = \left(\int_0^1 |x(t)|^p dt \right)^{1/p}, \text{ donde } x(t) \in L_p([0, 1]),$$

en los que si $y(t) \in L_p([0, 1])$ se cumple que

$$\left(\int_0^1 |x(t)|^p dt \right)^{1/p} < \infty$$

son también espacios¹ normados.

En particular, el conjunto de todas las funciones tales que

$$\int f^2(x) dx < \infty$$

con la distancia entre dos de ellas $f_1(x)$ y $f_2(x)$ definida por

$$\sqrt{\int (f_1(x) - f_2(x))^2 dx}$$

¹Casos particulares son $L_1([a, b])$ de funciones cuyo valor absoluto es integrable en $[a, b]$ y $L_2([a, b])$ de funciones al cuadrado integrables en $[a, b]$.

es el espacio métrico $L_2(\mathbb{R})$.

Sea E un espacio vectorial normado; se dice que una sucesión² $\{\mathbf{x}^{(n)}\}$ en E *converge* a un *límite* $\mathbf{v} \in E$, si para todo $\varepsilon > 0$, existe un $N \in \mathbb{N}$ tal que a partir de él, $n \geq N$, se cumple que $\|\mathbf{x}^{(n)} - \mathbf{v}\| < \varepsilon$.

Cuando una sucesión $\{\mathbf{x}^{(n)}\}$ admite un vector límite $\mathbf{v}$ sólo tiene ese vector como límite.³ Se escribe $\lim_{n \rightarrow \infty} \mathbf{x}^{(n)} = \mathbf{v}$. Es equivalente decir que $\lim_{n \rightarrow \infty} \mathbf{x}^{(n)} = \mathbf{v}$ y que $\lim_{n \rightarrow \infty} \|\mathbf{x}^{(n)} - \mathbf{v}\| = 0$. En particular, $\mathbf{x}^{(n)} \rightarrow 0$ si y sólo si $\|\mathbf{x}^{(n)}\| \rightarrow 0$.

Una sucesión $\{\mathbf{x}^{(n)}\}$ en un espacio vectorial normado por $\|\cdot\|$ se denomina *sucesión de Cauchy* si para cada $\varepsilon > 0$ existe un $n \in \mathbb{N}$ tal que cualesquiera que sean $p, q \geq n$, se cumple que $\|\mathbf{x}^{(p)} - \mathbf{x}^{(q)}\| < \varepsilon$. Toda sucesión convergente es una sucesión de Cauchy pero pueden existir espacios normados con sucesiones de Cauchy que no son convergentes. Un espacio vectorial normado se dice *completo* si toda sucesión de Cauchy en él tiene límite.

Un *espacio de Banach* —por Stefan Banach, Polonia 1892-1945— es un espacio vectorial completo respecto de la norma a él asociada. Todo espacio vectorial normado de dimensión finita es un espacio de Banach. En un espacio de dimensión infinita esto no es cierto; por ejemplo, es fácil ver que en $C[0, 1]$ la sucesión de funciones cuyas gráficas son las de la figura 2.3 es una sucesión de Cauchy para cualquier norma $\|\cdot\|_p$, pero no tiene límite en $C[0, 1]$.




Figura 2.3: Gráfica de una de las funciones de una sucesión de Cauchy

²Cuando así lo aconseja la dificultad de la notación, una sucesión también se designa por $\{\mathbf{x}_n\}$; sus integrantes, $\mathbf{x}^{(k)}$.

³Si existe límite es único.

2.2 Espacios con producto interior

Sea E un espacio vectorial sobre un cuerpo $\mathbf{K}$ ($\mathbb{R}$ o $\mathbb{C}$); una *forma sesquilineal* —vez y media lineal— sobre E es una aplicación $\langle \cdot | \cdot \rangle : E \times E \rightarrow \mathbf{K}$ que verifica⁴:

$$1) \langle \alpha \mathbf{u} + \beta \mathbf{v} | \mathbf{w} \rangle = \alpha \langle \mathbf{u} | \mathbf{w} \rangle + \beta \langle \mathbf{v} | \mathbf{w} \rangle \quad \text{y}$$

$$2) \langle \mathbf{u} | \alpha \mathbf{v} + \beta \mathbf{w} \rangle = \bar{\alpha} \langle \mathbf{u} | \mathbf{v} \rangle + \bar{\beta} \langle \mathbf{u} | \mathbf{w} \rangle,$$

cualesquiera que sean $\mathbf{u}, \mathbf{v}, \mathbf{w}$ en E y α, β en $\mathbf{K}$. Si además se cumple que $\langle \mathbf{u} | \mathbf{v} \rangle = \overline{\langle \mathbf{v} | \mathbf{u} \rangle}$, la forma se denomina *hermítica*. Es claro que $\langle \mathbf{u} | \mathbf{u} \rangle$ es siempre un número real. Cuando se cumple que

$$\mathbf{u} \neq \mathbf{0} \implies \langle \mathbf{u} | \mathbf{u} \rangle > 0,$$

se dice que la forma es definida positiva, denominándosela también *producto escalar*. Una forma sesquilineal sobre $\mathbb{R}$ es siempre una *forma bilineal*.

Un *espacio prehilbertiano* es un espacio vectorial sobre $\mathbf{K}$ dotado de una forma hermítica definida positiva. Todo espacio prehilbertiano es un espacio normado mediante

$$\|\mathbf{v}\| = \sqrt{\langle \mathbf{v} | \mathbf{v} \rangle}.$$

En la demostración de que esta definición corresponde a la de una norma en E juega un papel importante la *desigualdad de Cauchy-Schwarz* —por Augustin Louis Cauchy, Francia 1789-1857 y Karl Hermann Amandus Schwarz, Prusia 1843-Alemania 1921— a saber,

$$|\langle \mathbf{u} | \mathbf{v} \rangle| \leq \|\mathbf{u}\| \cdot \|\mathbf{v}\|.$$

Si Ω es un abierto de $\mathbb{R}^n$, el espacio vectorial de las *funciones al cuadrado integrables* en Ω ⁵ es

$$L_2(\Omega) = \left\{ f : \Omega \rightarrow \mathbb{R}, \int_{\Omega} |f(x)|^2 dx < \infty \right\}$$

que es un espacio prehilbertiano si se le dota del producto escalar

$$\langle f, g \rangle = \int_{\Omega} f(x)g(x)dx.$$

Un *espacio de Hilbert* —por David Hilbert, Prusia Oriental 1862-1943— es un espacio prehilbertiano completo respecto de la norma asociada al producto escalar

⁴La barra designa complejo conjugado.

⁵También se suelen designar $L^2(\Omega)$.

$\|\cdot\| = \sqrt{\langle \cdot, \cdot \rangle}$. Dicho de otra forma, un espacio prehilbertiano que con esta norma da un espacio de Banach. Todo espacio de Hilbert es un espacio de Banach, pero el recíproco no es cierto.

El espacio vectorial $L_2(\Omega)$ dotado de la norma $\langle f, g \rangle = \int_{\Omega} f(x)g(x)dx$ es un espacio de Hilbert.

El *espacio euclídeo* n -dimensional, expresado $\mathbb{R}^n$ o $\mathbb{E}^n$, es un espacio de Hilbert de dimensión finita. Visto así, un espacio de Hilbert sería la generalización de un espacio euclídeo, incluida la dimensión infinita. El producto escalar en un espacio euclídeo es una forma bilineal. En particular, dados dos vectores en $\mathbb{R}^2$ de la forma $\mathbf{u} = [a, b]^T$ y $\mathbf{v} = [c, d]^T$, su producto escalar viene dado por $\langle \mathbf{u}, \mathbf{v} \rangle = ac + bd$, que se puede verificar que es una forma bilineal.

Dos vectores cuyo producto escalar es cero se denominan *ortogonales*; si sus $\|\cdot\|_2$ son la unidad se denominan *ortonormales*. Para dos vectores ortogonales se tiene la identidad

$$\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2,$$

que es una generalización del teorema de Pitágoras. En un espacio prehilbertiano el único vector ortogonal a todos los vectores del espacio es el vector nulo; si este espacio es de dimensión finita es posible construir una base ortonormalizada.

En un espacio euclídeo n -dimensional el ángulo entre dos vectores $\mathbf{x}$ e $\mathbf{y}$ es

$$\theta = \arccos \left(\frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} \right),$$

donde

$$\rho = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

cumple que $-1 \leq \rho \leq 1$, para cualesquiera $\mathbf{x}$ e $\mathbf{y}$.

Dos vectores son ortogonales si $\mathbf{x}^T \mathbf{y} = 0$ ($\theta = \pi/2, \rho = 0$); alineados, si $\mathbf{x}^T \mathbf{y} = \|\mathbf{x}\| \|\mathbf{y}\|$ ($\theta = 0, \rho = 1$); opuestos, si $\mathbf{x}^T \mathbf{y} = -\|\mathbf{x}\| \|\mathbf{y}\|$ ($\theta = \pi, \rho = -1$). Forman un ángulo agudo si $\mathbf{x}^T \mathbf{y} > 0$ ($\theta < \pi/2, \rho > 0$) y un ángulo obtuso si $\mathbf{x}^T \mathbf{y} < 0$ ($\theta > \pi/2, \rho < 0$).

Una familia cualquiera de vectores distintos del nulo y ortogonales dos a dos es una familia libre. Si M es un subespacio de un espacio prehilbertiano E de dimensión finita, el *subespacio ortogonal* de M , $M^\perp$, es el subespacio formado por todos los vectores ortogonales a los de M , siendo un subespacio suplementario de M ; es decir $M \oplus M^\perp = E$. Cualquier $\mathbf{x} \in E$, por consiguiente, se puede expresar como $\mathbf{x} = \mathbf{a} + \mathbf{b}$, con $\mathbf{a} \in M$ y $\mathbf{b} \in M^\perp$.

2.3 Aplicaciones lineales

Dados dos espacios vectoriales E y F sobre el mismo cuerpo K se define una *aplicación lineal*, *transformación lineal*, *mapeo*, *operador lineal* u *homomorfismo*, f , de E en F , como una aplicación $f : E \rightarrow F$ que verifica

$$f(\lambda x + \mu y) = \lambda f(x) + \mu f(y),$$

cualesquiera que sean los vectores x, y de E y los escalares λ y μ . Existen dos casos particulares interesantes: el primero cuando $E = F$, en este caso se dice que f es un *operador lineal* de E o *endomorfismo* de E ; el segundo cuando $F = K$ —el cuerpo base—, en cuyo caso la aplicación se denomina *forma lineal* sobre E .

El conjunto $\mathcal{L}(E, F)$ de todas las aplicaciones lineales del espacio E en el espacio F se estructura como un espacio vectorial si se definen las siguientes operaciones:

$$\text{adición } (f + g) : \quad (f + g)(x) = f(x) + g(x), \quad \forall x \in E;$$

$$\text{producto por un escalar } \lambda f : \quad (\lambda f)(x) = \lambda f(x), \quad \forall x \in E \text{ y } \forall \lambda \in K.$$

En particular, el conjunto $\mathcal{L}(E, K)$ de formas lineales es un espacio vectorial denominado *dual* de E , representándose con E^* .

Para una aplicación lineal $f : E \rightarrow F$, el conjunto de vectores de F que son la imagen de los de un subespacio de E forma un subespacio de F . En particular, la imagen de todo E es un subespacio de F que se denomina *subespacio imagen* de f , representándose mediante $\text{Im}(f)$. Análogamente, el conjunto anti-imagen de un subespacio de F forma un subespacio de E . En particular, la anti-imagen del subespacio nulo de F forma lo que se denomina el *núcleo* de la aplicación, representándose por $\ker(f)$. Así pues

$$\ker(f) = \{x \in E : f(x) = 0\}.$$

Si $b \in F$, la ecuación lineal $f(x) = b$ tiene solución si y sólo si $b \in \text{Im}(f)$. En ese caso el conjunto de todas las soluciones es la *variedad lineal* —traslación de un subespacio— dada por $x_0 + \ker(f)$, donde x_0 es una solución particular de la ecuación. En particular, la aplicación es inyectiva si y sólo si $\ker(f) = \emptyset$.

Sean E y F dos espacios prehilbertianos sobre el cuerpo $\mathbf{K}$; si $f : E \rightarrow F$ es una aplicación lineal, la *aplicación traspuesta* de f es la aplicación $f^* : F \rightarrow E$ que cumple

$$\langle x | f^*(y) \rangle = \langle f(x) | y \rangle,$$

cualesquiera que sean los vectores $x \in E$ e $y \in F$. Particularmente importante es el caso en que $E = F$: f^* se dice entonces que es el *operador adjunto* de

f . Cuando un operador f de E cumple que $f^* = f$ se denomina *operador autoadjunto*. En el caso de que E sea un espacio vectorial real, también se dice que f es un *operador simétrico* y cuando es un espacio vectorial complejo, que f es un *operador hermítico*. Un operador simétrico cumple que

$$\langle \mathbf{x} | f(\mathbf{y}) \rangle = \langle f(\mathbf{x}) | \mathbf{y} \rangle,$$

mientras que uno hermítico, que

$$\langle \mathbf{x} | f(\mathbf{y}) \rangle = \overline{\langle f(\mathbf{x}) | \mathbf{y} \rangle}.$$

Un operador f de E es *unitario* cuando es invertible y su inverso coincide con su adjunto. Es decir, si $f^* = f^{-1}$. Para un operador unitario se tiene que

$$\langle f(\mathbf{x}) | f(\mathbf{y}) \rangle = \langle f^*(f(\mathbf{x})) | \mathbf{y} \rangle = \langle \mathbf{x} | \mathbf{y} \rangle,$$

de manera que $\|f(\mathbf{x})\| = \|\mathbf{x}\|$. Por este motivo a los operadores unitarios también se les denomina *operadores isométricos*.

Dada una transformación lineal, aplicación lineal, o mapeo, $f : E \rightarrow E$, se dice que un subespacio W de E es un *subespacio invariante* frente a f (o f -invariante) si para todo vector $\mathbf{w} \in W$ se cumple que $f(\mathbf{w}) \in W$. Dicho de otra manera, W es un subespacio invariante si $f(W) \subset W$.

3 Topología

EN un espacio vectorial normado se define una *bola abierta*, $S(\mathbf{x}_0, r)$, de centro $\mathbf{x}_0$ y radio r , como el conjunto de puntos $\mathbf{x}$ que verifican $\|\mathbf{x} - \mathbf{x}_0\| < r$. Es decir:

$$S(\mathbf{x}_0, r) = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{x}_0\| < r\}.$$

Una *bola cerrada*, $\bar{S}(\mathbf{x}_0, r)$, se define, por el contrario, como el conjunto de puntos $\mathbf{x}$ que verifican $\|\mathbf{x} - \mathbf{x}_0\| \leq r$. Es decir:

$$\bar{S}(\mathbf{x}_0, r) = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{x}_0\| \leq r\}.$$

Consideraremos en lo que sigue de este apartado un subconjunto S del espacio vectorial métrico hasta ahora estudiado (puede ser, por ejemplo, $\mathbb{R}^n$).

Un punto $\mathbf{y} \in S$ es un *punto interior* del conjunto S si existe un ε tal que

$$\|\mathbf{x} - \mathbf{y}\| < \varepsilon \Rightarrow \mathbf{x} \in S.$$

En otras palabras, existe una bola abierta $S(\mathbf{y}, \varepsilon)$ de centro $\mathbf{y}$ y radio ε contenida íntegramente en S .

El conjunto de todos los puntos interiores del conjunto S se denomina *interior* de S . Este conjunto puede, evidentemente, ser vacío. Ejemplo: un plano del espacio $\mathbb{R}^3$.

Un subconjunto de S se dice *abierto* si coincide con su interior; es decir, si alrededor de todo punto de S existe una bola abierta contenida íntegramente en S . Dos ejemplos: la bola abierta unidad, $S(\mathbf{x}, 1) = \{\mathbf{x} : \|\mathbf{x}\| < 1\}$ y el espacio $\mathbb{R}^n$ en su totalidad. En general los subconjuntos o conjuntos abiertos se caracterizan por no tener límites definidos o ser disjuntos de su frontera (ver más adelante la definición del concepto frontera).

Un *entorno* de un punto $\mathbf{x}$, $\mathcal{E}(\mathbf{x})$, es un conjunto abierto que contiene a $\mathbf{x}$. En otras palabras, $\mathcal{E}(\mathbf{x})$ es un entorno de $\mathbf{x}$ si contiene una bola abierta de centro $\mathbf{x}$.

Se dice que un punto $\mathbf{x}$ es un *punto de acumulación* del subconjunto S si en todo entorno de $\mathbf{x}$ existen un número infinito de puntos de S .

Un punto $\mathbf{x}$ se denomina *punto de adherencia* del subconjunto S cuando todo entorno de dicho punto $\mathbf{x}$ contiene al menos un punto de S ; es decir, para todo ε existe un $\mathbf{y} \in S$ tal que $\|\mathbf{x} - \mathbf{y}\| < \varepsilon$. El conjunto de todos los puntos de adherencia se denomina *adherencia* —en la literatura anglosajona y latinoamericana, *clausura* $cl(S)$ —. La adherencia de la bola abierta $S(\mathbf{x}, 1) = \{\mathbf{x} : \|\mathbf{x}\| < 1\}$ es la cerrada $\bar{S}(\mathbf{x}, 1) = \{\mathbf{x} : \|\mathbf{x}\| \leq 1\}$.

Se denomina *frontera* de un conjunto a la parte de la adherencia que no está en el interior.

Un conjunto, o subconjunto, se dice *cerrado* si coincide con su adherencia. La adherencia de cualquier conjunto S es el conjunto cerrado más pequeño que contiene a S . Se puede demostrar que un conjunto es cerrado si y sólo si toda sucesión convergente de elementos de S tiene un límite en ese conjunto.

Un conjunto, o subconjunto, se dice *compacto* si es cerrado y acotado (contenido en una bola de radio $r < \infty$). Un importante resultado, debido a Weierstrass, dice que si S es un conjunto compacto, de cada sucesión o sucesión infinita $\{\mathbf{x}^{(n)}\}_{n \in \mathbb{N}}$ de elementos de dicho conjunto es posible extraer una subsucesión

$$\{\mathbf{x}^{(\ell)}\}_{\ell \in L} \quad L \subset \mathbb{N}$$

que converge a un elemento del propio conjunto S .

Si $\{r^{(k)}\}$ es una sucesión de números reales y $s^{(k)} = \sup\{r^{(i)} : i \geq k\}$, entonces $\{s^{(k)}\}$ converge a un número real s_0 ; a este número se le denomina *límite superior* de $\{r^{(k)}\}$ y se expresa como

$$\limsup \left(r^{(k)} \right) \quad \text{o} \quad \overline{\lim}_{k \rightarrow \infty} \left(r^{(k)} \right).$$

El límite superior de una sucesión de números reales es el mayor punto de acumulación de la sucesión. De forma similar se define el límite inferior.

4 Matrices

UNA *matriz* es una formación rectangular de números reales o complejos ordenados en m filas y n columnas

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

El conjunto de todas las matrices de números reales o complejos se designa, respectivamente, $\mathbb{R}^{m \times n}$ y $\mathbb{C}^{m \times n}$. Si $m = n$ la matriz es cuadrada y de orden n . Un vector columna es también una matriz $\mathbb{R}^{m \times 1}$, que se escribe $\mathbb{R}^m$.

Las matrices de m filas y n columnas con coeficientes en el cuerpo $\mathbb{R}$ o $\mathbb{C}$ forman un espacio vectorial, $\mathbb{R}^{m \times n}$ o $\mathbb{C}^{m \times n}$, sobre dichos cuerpos.

El primero en usar el término matriz en matemáticas fue James Joseph Sylvester, Reino Unido 1814-1897. Arthur Cayley, Reino Unido, 1821-1895, contribuyó de forma decisiva a que $A = (a_{ij})$ se concibiese como una cantidad algebraica única.

Si en álgebra lineal E y F son dos espacios vectoriales de dimensiones finitas n y m sobre el mismo cuerpo K . Una aplicación lineal $g : E \rightarrow F$, $g \in \mathcal{L}(E, F)$, está caracterizada o representada en dos bases $\{e_1, e_2, \dots, e_n\}$ de E y $\{f_1, f_2, \dots, f_m\}$ de F por una tabla de coeficientes, *matriz* asociada, de m filas y n columnas:

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in K^{m \times n}.$$

Los coeficientes a_{ij} están definidos por

$$g(e_j) = \sum_{i=1}^m a_{ij} f_i, \quad 1 \leq j \leq n.$$

El vector columna j -ésimo

$$\begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{bmatrix}$$

representa el vector $g(e_j)$ en la base (f_i) . A partir de la matriz A se pueden calcular los coeficientes $y_1, y_2, \dots, y_m$ del vector $y = g(x)$ en la base (f_i) , cono-

ciendo los coeficiente $x_1, x_2, \dots, x_n$ en la base (e_j) . En efecto:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = x_1 \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{bmatrix} + \dots + x_n \begin{bmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{bmatrix}.$$

Expresión que también se puede escribir de la siguiente forma:

$$y = \sum_{i=1}^n x_i a_i,$$

donde a_i es el vector columna i -ésimo de la matriz A . Así pues, si se fijan dos bases en E y F , cada aplicación lineal, $g : E \rightarrow F$, queda unívocamente representada por una matriz. Recíprocamente, toda matriz en $K^{m \times n}$ define unívocamente una aplicación lineal entre dos espacios E y F de dimensiones n y m en los que se han fijado dos bases. En particular, se pueden identificar las matrices $m \times n$ con las aplicaciones lineales de K^n en K^m .

Las matrices de m filas y n columnas con coeficientes en el cuerpo K forman un espacio vectorial, $K^{m \times n}$, sobre dicho cuerpo K .

Si E y F son dos espacios de dimensión finita dotados de un producto escalar y la aplicación $\alpha \in \mathcal{L}(E, F)$ se representa en dos bases ortonormalizadas mediante una matriz A , la aplicación $\alpha^T \in \mathcal{L}(F, E)$, traspuesta de α , viene representada por la matriz A^T , traspuesta de A .

El *núcleo* y la *imagen* de una matriz $A \in K^{m \times n}$, $\ker(A)$ y $\text{Im}(A)$, respectivamente, se definen como los subespacios de K^n y K^m que son el núcleo y la imagen de la aplicación lineal asociada:

$$\left. \begin{aligned} \ker(A) &= \{x \in K^n : Ax = 0\} \\ \text{Im}(A) &= \{y \in K^m : y = Ax, x \in K^n\} \end{aligned} \right\} \Bigg|_{A \in K^{m \times n}}.$$

Dicho de otra forma, la imagen de una matriz es el subespacio generado por los vectores columna de la matriz; los vectores fila también generan un subespacio que no es otro que la imagen de A^T .

Para una matriz $A \in \mathbb{R}^{m \times n}$ se cumple que:

$$\begin{aligned} \ker(A^T) &= (\text{Im}(A))^\perp \\ \text{Im}(A^T) &= (\ker(A))^\perp \\ \ker(A) &= (\text{Im}(A^T))^\perp \\ \text{Im}(A) &= (\ker(A^T))^\perp. \end{aligned}$$

De acuerdo con esto, si $A \in \mathbb{R}^{m \times n}$, se cumple que

$$\ker(A) \oplus \operatorname{Im}(A^T) = \mathbb{R}^n.$$

En la figura 4.4 se muestran estos subespacios.




Figura 4.4: Subespacios fundamentales determinados por $A^{m \times n}$

El *rango* de una matriz es la dimensión⁶ de su subespacio imagen:

$$\operatorname{rango}(A) = \dim(\operatorname{Im}(A)).$$

Una matriz $A \in K^{m \times n}$ se dice de *rango completo* si $\operatorname{rango}(A) = \min(m, n)$. Una matriz cuadrada $A \in K^{n \times n}$ se denomina *singular* si $\operatorname{rango}(A) < n$; *regular* si $\operatorname{rango}(A) = n$. También se cumple que $\operatorname{rango}(A) = \operatorname{rango}(A^T)$.

La aplicación asociada a una matriz $A \in \mathbb{R}^{m \times n}$ es suprayectiva cuando $\operatorname{rango}(A) = m$. Para una matriz $A \in K^{m \times n}$ se cumple que

$$\dim(\ker(A)) + \operatorname{rango}(A) = n,$$

o, alternativamente, $\dim(\ker(A)) = n - \operatorname{rango}(A)$. La aplicación lineal asociada a A es, por tanto, inyectiva, si y sólo si $\operatorname{rango}(A) = n$. Por otro lado $\dim(\ker(A^T)) + \operatorname{rango}(A^T) = m$.

El *producto exterior* uv^T de un vector columna $n \times 1$ por un vector fila $1 \times n$ es una matriz $A^{n \times n}$ de rango 1.

$$A = uv^T = \begin{bmatrix} u_1 v_1 & u_1 v_2 & \cdots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \cdots & u_2 v_n \\ \vdots & \vdots & & \vdots \\ u_n v_1 & u_n v_2 & \cdots & u_n v_n \end{bmatrix}$$

⁶Recordemos: máximo número de vectores linealmente independientes.

4.1 Normas de matrices

Aun cuando en lo que sigue nos limitaremos a *matrices cuadradas*, la mayor parte de las definiciones y resultados son extensibles a matrices rectangulares; también supondremos que las matrices son reales.

Las matrices cuadradas de orden n forman un espacio vectorial con un producto, esto es, un *álgebra*. Una *norma matricial* es una norma vectorial compatible con el producto. Se define formalmente sobre $\mathbb{R}^{m \times n}$ como una aplicación $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ que cumple:

- 1) $\|A\| = 0 \implies A = 0$.
- 2) $\|\lambda A\| = |\lambda| \cdot \|A\|$.
- 3) $\|A + B\| \leq \|A\| + \|B\|$.
- 4) $\|AB\| \leq \|A\| \cdot \|B\|$.

Existen normas sobre el espacio $\mathbb{R}^{m \times n}$ que no son normas matriciales pues no cumplen la propiedad 4). Así, si se define

$$\|A\| = \max_{1 \leq i, j \leq n} |a_{ij}|,$$

se satisfacen 1), 2) y 3); sin embargo, tomando $A = B = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$, es fácil ver que $\|AB\| = 2 > \|A\| \cdot \|B\| = 1$, por lo que no se cumple 4).

Un ejemplo importante de norma matricial es la *norma de Frobenius*, definida como:

$$\|A\|_F^2 = \sum_{1 \leq i, j \leq n} a_{ij}^2 = \text{traza}(A^T A),$$

donde la *traza* de una matriz A de orden n es $\sum_{i=1}^n a_{ii}$. Es fácil ver que esta norma deriva del producto escalar $\langle A | B \rangle = \text{traza}(A^T B)$, que configura al espacio de las matrices cuadradas como un espacio prehilbertiano. La norma de Frobenius cumple que

$$\|AB\|_F \leq \|A\|_F \cdot \|B\|_F.$$

Una norma matricial $\|\cdot\|$ sobre $\mathbb{R}^{m \times n}$ se dice *consistente* con una norma vectorial $\|\cdot\|'$ sobre $\mathbb{R}^n$ cuando para cada matriz A y cada vector x se cumple que

$$\|Ax\|' \leq \|A\| \cdot \|x\|'.$$

Por ejemplo, la norma de Frobenius y la norma euclídea de $\mathbb{R}^n$ son consistentes pues

$$\|Ax\|_2 \leq \|A\|_F \cdot \|x\|_2.$$

Se demuestra que para toda norma matricial es posible construir una norma vectorial consistente. Recíprocamente, a toda norma vectorial sobre $\mathbb{R}^n$ se le puede asociar una norma matricial consistente. Una norma matricial consistente con una cierta norma vectorial $\|\cdot\|$ se construye mediante la definición

$$\|A\| = \sup_{\mathbf{0} \neq \mathbf{x} \in \mathbb{R}^n} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|}.$$

Esta norma matricial se dice *inducida* por la norma vectorial. Ejemplo: la norma matricial inducida por la norma euclídea de $\mathbb{R}^n$ es la *norma espectral*:

$$\|A\|_2 = \sup_{\mathbf{0} \neq \mathbf{x} \in \mathbb{R}^n} \left[\frac{\mathbf{x}^T A^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \right]^{1/2} = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A),$$

donde λ designa un valor propio de A y σ un valor singular. Si $\|\cdot\|$ es la norma inducida por una cierta norma vectorial y $\|\cdot\|'$ es una norma matricial cualquiera consistente con esa norma vectorial, se cumple, para toda matriz A , que $\|A\| \leq \|A\|'$. En particular, para la norma espectral y la norma de Frobenius, se cumple que

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{n} \|A\|_2.$$

También que $\|AB\|_F \leq \|A\|_F \cdot \|B\|_2$ y $\|AB\|_F \leq \|A\|_2 \cdot \|B\|_F$. Como casos particulares, $\|I\|_2 = 1$ y para una matriz diagonal, $\|D\|_2 = \max_i |d_i|$.

Las normas matriciales inducidas más usadas son

$$\begin{aligned} \|A\|_1 &= \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad y \\ \|A\|_\infty &= \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|. \end{aligned}$$

Ejemplo 4.1 El efecto que produce aplicar la transformación lineal basada en la matriz

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$$

sobre la bola unidad, explicado a partir de las normas $\|\cdot\|_1$, $\|\cdot\|_2$ y $\|\cdot\|_\infty$ en $\mathbb{R}^2$, se representa en la figura 4.5. La aplicación transforma el vector $\mathbf{e}_1 = [1, 0]^T$ en sí mismo y $\mathbf{e}_2 = [0, 1]^T$ en $[2, 2]^T$. Con la norma 1, el vector unitario que más se amplifica al aplicarle la transformación es $[0, 1]^T$ (o $[0, -1]^T$), que pasa a ser $[2, 2]^T$. Su factor de amplificación, en términos de la norma 1, es 4.




Figura 4.5: Efecto de una aplicación lineal sobre la bola unidad para diferentes normas

Con la norma 2, el vector unitario que más se amplifica es el que se representa en la figura con una recta discontinua. El factor de amplificación es 2,9208.

Para la norma ∞ , igualmente, el vector unitario que más se amplifica es el que se representa también con la recta discontinua: $[1, 1]^T$, que pasa a transformarse en $[3, 2]^T$. El factor de amplificación correspondiente es en este caso 3 ya que

$$\|[1, 1]^T\|_{\infty} = 1$$

$$\|[3, 2]^T\|_{\infty} = 3.$$

●

Además de las normas vectoriales y matriciales ya presentadas, otra norma vectorial muy utilizada es

$$\|x\|_A = \|A^{1/2}x\|_2 = \sqrt{\langle Ax|x \rangle} = \sqrt{x^T A x},$$

denominada *norma A* o *norma de energía*⁷ del vector $\mathbf{x}$, para una matriz A simétrica y definida positiva. A $\langle \mathbf{x} | \mathbf{y} \rangle_A = \langle A\mathbf{x} | \mathbf{y} \rangle$ se le denomina *producto interior de A* o *producto escalar de energía*. La matriz $A^{1/2}$ es la única matriz definida positiva solución de la ecuación matricial $X^2 = X \cdot X = A$.

4.2 Matrices ortogonales, unitarias, simétricas, Hessenberg, de permutación y de proyección

Una matriz $Q \in \mathbb{R}^{m \times n}$ se dice *ortogonal* si verifica que $Q^T Q = I$; es decir, cuando sus vectores columna son ortogonales dos a dos y de norma euclídea unitaria (ortonormales). Si $Q \in \mathbb{R}^{n \times n}$ es ortogonal, se cumple que $Q Q^T = Q^T Q = I$.

Las matrices ortogonales $Q \in \mathbb{R}^{m \times n}$ verifican:

$$\left. \begin{array}{l} \|Q\|_2 = 1 \\ \|Q\|_F = n^{1/2} \\ \|QA\|_2 = \|A\|_2 \\ \|QA\|_F = \|A\|_F \end{array} \right\} \quad \text{si } m \geq n \quad y \quad \left. \begin{array}{l} \|Q\|_2 = 1 \\ \|Q\|_F = m^{1/2} \\ \|AQ\|_2 = \|A\|_2 \\ \|AQ\|_F = \|A\|_F \end{array} \right\} \quad \text{si } m \leq n.$$

Una matriz ortogonal no modifica ni los ángulos ni las normas de los vectores a los que se aplica la transformación que representan: $(Q\mathbf{x})^T (Q\mathbf{y}) = \mathbf{x}^T Q^T Q \mathbf{y} = \mathbf{x}^T \mathbf{y}$. Si $\mathbf{y} = \mathbf{x}$, $\|Q\mathbf{x}\|_2 = \|\mathbf{x}\|_2$.

La extensión de las matrices ortogonales al campo complejo son las matrices *unitarias*. Son matrices, $U \in \mathbb{C}^{n \times n}$, cuya inversa es su compleja conjugada: $U^H U = U U^H = I$. Todos los valores propios de las matrices unitarias tienen módulo unidad. Como las ortogonales, una matriz unitaria no modifica ni los ángulos ni las normas, $(U\mathbf{x})^H (U\mathbf{y}) = \mathbf{x}^H U^H U \mathbf{y} = \mathbf{x}^H \mathbf{y}$. Si $\mathbf{y} = \mathbf{x}$, $\|U\mathbf{x}\|_2 = \|\mathbf{x}\|_2$.

Una *matriz de permutación* es una matriz cuadrada cuyas columnas están formadas por las de la matriz unidad permutadas. Una matriz de permutación es una matriz ortogonal.

Una matriz se dice *simétrica* si se verifica que $A = A^T$. Para una matriz cualquiera $A \in \mathbb{R}^{m \times n}$, la matriz $A^T A$ es simétrica. Si $A \in \mathbb{C}^{n \times n}$ es igual a su traspuesta conjugada, $A = B = A^H$, $b_{ij} = \bar{a}_{ji}$, se dice *hermítica*.

Una matriz A se dice *definida positiva* si $\mathbf{x}^T A \mathbf{x} > 0$ para todo vector $\mathbf{x} \neq \mathbf{0}$. De forma similar se definen matrices *semidefinida positiva*, *definida negativa* y *semidefinida negativa*, si $\mathbf{x}^T A \mathbf{x} \geq 0$, < 0 y ≤ 0 , respectivamente, para todo vector $\mathbf{x} \neq \mathbf{0}$. La matriz A se dice *indefinida* si $\mathbf{x}^T A \mathbf{x}$ es positivo para algún $\mathbf{x}$

⁷Pues suele corresponder con la energía física de ciertos sistemas.

y negativo para otros. También $A \in \mathbb{C}^{n \times n}$ se dice definida positiva si para todo $x \in \mathbb{C}^n$, $x \neq 0$, se cumple que $x^H A x > 0$.

Si $A \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva se puede descomponer de la forma $A = Q D Q^T$ donde Q es una matriz ortogonal y D , diagonal, tiene todos sus coeficientes positivos por lo que $A^{\frac{1}{2}} = Q D^{\frac{1}{2}} Q^T$ satisfaciéndose que $A^{\frac{1}{2}} A^{\frac{1}{2}} = A$.

Se dice que una matriz $A \in \mathbb{C}^{n \times n}$ de coeficientes a_{ij} es de *diagonal dominante* por filas cuando cumple que

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, \dots, n.$$

Análogamente, se dice diagonal dominante por columnas si

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ji}|, \quad i = 1, \dots, n.$$

Si las desigualdades se verifican estrictamente la matriz A se denomina *diagonal estrictamente dominante*.

Lema 4.1 Para que una matriz simétrica sea definida positiva es necesario que todos los coeficientes de la diagonal principal sean positivos.

Lema 4.2 Para que una matriz simétrica A sea definida positiva es necesario que el coeficiente de mayor valor absoluto esté en la diagonal principal. Más concretamente,

$$\max_{i \neq j} |a_{ij}| < \max_k a_{kk}.$$

Lema 4.3 Si en cada fila de una matriz simétrica A el coeficiente de la diagonal principal es mayor que la suma de los valores absolutos de todos los demás coeficientes de la fila, es decir, si

$$a_{kk} > \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \quad k = 1, \dots, n,$$

A es definida positiva.

Es importante destacar que este último criterio define una condición suficiente, no necesaria. En efecto, la matriz $Q = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}$ es definida positiva pues

$$x^T Q x = x_1^2 + x_2^2 + x_3^2 + 2(x_1 + x_2 + x_3)^2,$$

cualquiera que sea $\mathbf{x} \neq \mathbf{0}$, es siempre positiva. Esa matriz, sin embargo, no satisface el lema 4.3.


Una *matriz de Vandermonde* —por Alexandre-Théophile Vandermonde, Francia 1735-1796— es una matriz que presenta una progresión geométrica en cada fila; como esta:

$$V = \begin{bmatrix} 1 & \alpha_1 & \alpha_1^2 & \dots & \alpha_1^{n-1} \\ 1 & \alpha_2 & \alpha_2^2 & \dots & \alpha_2^{n-1} \\ 1 & \alpha_3 & \alpha_3^2 & \dots & \alpha_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \alpha_n & \alpha_n^2 & \dots & \alpha_n^{n-1} \end{bmatrix}.$$

Una *matriz de Hankel* —por Hermann Hankel, Alemania 1839-1873— es una matriz cuadrada con todas sus diagonales de derecha a izquierda paralelas numéricamente. Es decir, tiene la forma

$$H = \begin{bmatrix} a & b & c & d & e \\ b & c & d & e & f \\ c & d & e & f & g \\ d & e & f & g & h \\ e & f & g & h & i \end{bmatrix}.$$

Una *matriz de Hessenberg* —por Karl Adolf Hessenberg, Alemania 1904-1959— es una matriz triangular excepto por una subdiagonal adyacente a la diagonal principal.



Cualquier matriz se puede reducir a la forma de *Hessenberg* mediante transformaciones ortogonales de *Householder* o *Givens*. Si la matriz original es *simétrica*, al reducirla a la forma de *Hessenberg* se obtendrá una *tridiagonal*.

Se denomina *proyector* o *matriz de proyección* a una matriz $\mathbf{P} \in \mathbb{R}^{n \times n}$ que verifica que $\mathbf{P}^2 = \mathbf{P}$. Si $\mathbf{P}$ además es simétrica, se denomina *proyector ortogonal* o *matriz de proyección ortogonal*. Si, en este último caso, F es el subespacio imagen de la matriz $\mathbf{P}$ (el mismo que el de la matriz $\mathbf{P}^T$), $\mathbf{P}\mathbf{x}$ define la *proyección ortogonal* del vector $\mathbf{x}$ sobre F .

Se denomina *proyector suplementario* de $\mathbf{P}$ al proyector $\mathbf{S} = \mathbf{I} - \mathbf{P}$. Si $F = \text{Im}(\mathbf{P})$ y $G = \text{ker}(\mathbf{P})$, entonces $F = \text{ker}(\mathbf{S})$ y $G = \text{Im}(\mathbf{S})$.

En el caso de un proyector ortogonal $\mathbf{P}$ en el que $F = \text{Im}(\mathbf{P})$, se tiene que $\mathbb{R}^n = F \oplus F^\perp$, verificándose que $\|\mathbf{P}\mathbf{x}\|_2 \leq \|\mathbf{x}\|_2$ y que

$$\|\mathbf{x} - \mathbf{P}\mathbf{x}\|_2 = \min_{\mathbf{y} \in \text{Im}(\mathbf{P})=F} \|\mathbf{x} - \mathbf{y}\|_2.$$

4.3 Valores propios, valores singulares y formas cuadráticas

4.3.1 Valores propios

Si A es una matriz cuadrada de orden n y coeficientes en $\mathbf{K}$ ($\mathbb{R}$ o $\mathbb{C}$), un vector no nulo $\mathbf{u} \in \mathbf{K}^n$ se denomina *vector propio* de A si para algún $\lambda \in \mathbf{K}$ se cumple que

$$A\mathbf{u} = \lambda\mathbf{u}.$$

A este λ se le denomina *valor propio* o *autovalor* de la matriz A . El conjunto de los valores propios de una matriz A se denomina *espectro* de A , designándose por $\Lambda(A)$. El *radio espectral*, $\rho(A)$, se define de la siguiente manera:

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|.$$

Para que un número λ sea valor propio de A , el sistema lineal y homogéneo de ecuaciones dado por $(\lambda I - A)\mathbf{x} = \mathbf{0}$ debe tener soluciones distintas de la trivial $\mathbf{x} = \mathbf{0}$. Esto equivale a que

$$\det(A - \lambda I) = 0.$$

Esta es una ecuación polinómica de grado n en λ que se denomina *ecuación característica*, o *polinomio característico*, de la matriz A . La ecuación característica admite la raíz $\lambda = 0$ si y sólo si $\det(A) = 0$. Una matriz es invertible, por tanto, si y sólo si no admite al cero como vector propio.

Para que exista una solución distinta de la trivial $\mathbf{x} = \mathbf{0}$, el valor propio λ deberá ser raíz del *polinomio característico* de grado n asociado a A , esto es $\det(A - \lambda I) = 0$. Lo que es igual a $\lambda^n + g_1\lambda^{n-1} + g_2\lambda^{n-2} + \dots + g_n = 0$.

El *Teorema fundamental del álgebra* establece que cada ecuación polinómica de grado n , con coeficientes complejos, tiene n raíces en el cuerpo de los complejos.

La *multiplicidad algebraica* del valor propio λ de A es la multiplicidad de la raíz correspondiente del polinomio característico asociado a A . La *multiplicidad geométrica* de λ es el número de vectores propios linealmente independientes que se corresponden con λ . La multiplicidad geométrica de un valor propio es menor o igual que su multiplicidad algebraica.

Por ejemplo, si $A = I$, $\lambda = 1$ es un valor propio con multiplicidad algebraica y geométrica n . El polinomio característico de A es $p(z) = (z - 1)^n$ y $\mathbf{e}_i \in \mathbb{C}^n$, $i = 1, \dots, n$, sus vectores propios. Si el valor propio λ tiene una multiplicidad geométrica menor que la algebraica, se dice *defectuoso*. Se dice que una matriz es defectuosa si tiene al menos un valor propio defectuoso. La matriz

$$\begin{bmatrix} 2 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & 2 \end{bmatrix}$$

tiene un valor propio, 2, de multiplicidad algebraica 3 y multiplicidad geométrica 1; $\mathbf{u} = [100]^T$. Si una matriz $\mathbf{A} \in \mathbb{C}^{n \times n}$ no es defectuosa, dispone de un conjunto de n vectores propios linealmente independientes.

Un resultado interesante debido a dos matemáticos del siglo XIX, Arthur Cayley, británico, 1821-1895, y William Rowan Hamilton, irlandés, 1805-1865, dice que cualquier matriz $\mathbf{A} \in \mathbb{C}^{n \times n}$ satisface su propia ecuación característica. Es decir,

$$\mathbf{A}^n + g_1 \mathbf{A}^{n-1} + g_2 \mathbf{A}^{n-2} + \cdots + g_n \mathbf{I} = \mathbf{0}.$$

Si $\mathbf{A}$ es invertible, como consecuencia de ello,

$$\mathbf{A}^{-1} = -\frac{1}{g_n} \mathbf{A}^{n-1} - \frac{g_1}{g_n} \mathbf{A}^{n-2} - \cdots - \frac{g_{n-1}}{g_n} \mathbf{I}.$$

A partir del teorema de Cayley-Hamilton también es fácil comprobar que existe un polinomio p de grado máximo $n - 1$ tal que $\mathbf{A}^{-1} = p(\mathbf{A})$. Como ejemplo, la matriz $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ tiene como polinomio característico $x^2 - 5x - 2$. El teorema de Cayley-Hamilton dice que $\mathbf{A}^2 - 5\mathbf{A} - 2\mathbf{I} = \mathbf{0}$, lo cual se puede comprobar inmediatamente. La inversa de $\mathbf{A}$ se puede obtener de esta ecuación a partir de $\mathbf{A}(\mathbf{A} - 5\mathbf{I}) = 2\mathbf{I}$. En efecto, $\mathbf{A}^{-1} = \frac{1}{2}(\mathbf{A} - 5\mathbf{I})$.

Para $\mathbf{A} \in \mathbb{C}^{n \times n}$ y $\mathbf{0} \neq \mathbf{b} \in \mathbb{C}^{n \times 1}$, al subespacio

$$\mathcal{K}_j(\mathbf{A}, \mathbf{b}) = \text{Gen}\{\mathbf{b}, \mathbf{A}\mathbf{b}, \dots, \mathbf{A}^{j-1}\mathbf{b}\}$$

se le denomina *subespacio de Krylov*.

Igual que cualquier matriz tiene asociado un polinomio característico, cualquier polinomio tiene asociado una *matriz compañera*. La matriz compañera de un polinomio mónico⁸ $p(t) = c_0 + c_1 t + \cdots + c_{n-1} t^{n-1} + t^n$ es

$$\mathbf{C}(p) = \begin{bmatrix} 0 & 0 & \cdots & 0 & -c_0 \\ 1 & 0 & \cdots & 0 & -c_1 \\ 0 & 1 & \cdots & 0 & -c_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -c_{n-1} \end{bmatrix}$$

Los valores propios de esta matriz $\mathbf{C}(p)$ son las raíces del polinomio $p(t)$. El polinomio mínimo $q(t)$ de una matriz $\mathbf{A}$ es el polinomio mónico único de grado mínimo tal que $q(\mathbf{A}) = \mathbf{0}$.

Una matriz real de orden n no tiene necesariamente valores propios reales pero, como consecuencia del teorema fundamental del álgebra, cualquier matriz compleja tiene al menos un valor propio complejo. El número máximo de valores propios es n .

⁸Un polinomio $a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n$ se dice que es mónico si $a_n = 1$.

Al aplicársele a *cualquier vector* la transformación que representa A ese vector tiende a orientarse en la dirección del *vector propio dominante* de A . Si aquel vector está en la *dirección* de alguno de los *vectores propios* de A , se *expande o contrae* por un *factor* que determina el correspondiente *valor propio*. La matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ tiene como valores propios 3 y 1. Los vectores propios asociados son $[1 \ 1]^T$ y $[-1 \ 1]^T$. El efecto de aplicarla sobre distintos vectores se puede ver en la figura 4.6: en magenta y azul los vectores propios; otros en rojo.




Figura 4.6: Efecto de aplicársele a diversos vectores la transformación que representa la matriz $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

Siendo λ un valor propio de una matriz A , el conjunto de soluciones del sistema de ecuaciones

$$(\lambda I - A)x = 0$$

es un subespacio de $\mathbf{K}^n$ que se denomina *subespacio propio* asociado al valor propio λ , designándose con E_λ . Si n_λ es la multiplicidad de λ como raíz de la ecuación característica de A , se cumple que

$$\dim(E_\lambda) \leq n_\lambda.$$

La intersección de subespacios propios correspondientes a valores propios distintos se reduce al subespacio nulo; esto es $\lambda \neq \mu \implies E_\lambda \cap E_\mu = \emptyset$.

De este modo, la suma de subespacios propios es directa. Se cumple que $\bigoplus_{\lambda \in \Lambda(A)} E_\lambda = \mathbf{K}^n$ si y sólo si para cada $\lambda \in \Lambda(A)$, $\dim(E_\lambda) = n_\lambda$; en ese caso existe una base de $\mathbf{K}^n$ formada toda ella por vectores propios de A .

El teorema central en el estudio de los métodos y algoritmos numéricos para el cálculo y análisis de valores y vectores propios es el de la descomposición de Schur —por Issai Schur, Alemania 1875-1941—.

Teorema 4.4 *Descomposición o triangularización de Schur* Para cualquier $A \in \mathbb{C}^{n \times n}$ existe una matriz unitaria U y una matriz triangular superior, T , tal que

$$AU = UT \quad \text{o} \quad U^H AU = T.$$

Los valores propios de A son los coeficientes de la diagonal principal de R .

Teorema 4.5 Para cualquier matriz hermítica $A \in \mathbb{C}^{n \times n}$ existe una matriz unitaria U tal que

$$U^H AU = D,$$

donde D es una matriz diagonal.

1. Los valores propios de A son números reales.
2. Se pueden obtener vectores propios de A que sean ortonormales.

En este caso se dice que la matriz A es *semejante* a una matriz diagonal: la matriz A es *diagonalizable por semejanza*. Dos matrices semejantes tienen el mismo polinomio característico y los mismos valores propios. Una matriz $A \in \mathbb{C}^{n \times n}$ es normal, es decir $AA^H = A^H A$, si y sólo si $A = U \Lambda U^H$, donde U es una matriz unitaria y Λ una diagonal cuyos coeficientes son los valores propios de A . Los vectores propios son los vectores columna de U .

Toda matriz real y simétrica tiene todos sus valores propios reales y es diagonalizable por semejanza. Se demuestra además que los subespacios propios correspondientes a valores propios distintos son ortogonales. De aquí se sigue que es siempre posible formar una base ortonormalizada de vectores propios para una matriz real y simétrica A . Existe entonces una matriz ortogonal Q tal que verifica $Q^T A Q = D$, con $Q^T = Q^{-1}$ y, de aquí que, toda matriz real y simétrica es *congruente ortogonal* con su reducida diagonal. Este resultado fundamental de la teoría de matrices es la versión para matrices simétricas del denominado *Teorema espectral*. Da lugar a la *Descomposición espectral* de A .

Teorema 4.6 *Descomposición de Jordan* Para una matriz $A \in \mathbb{C}^{n \times n}$ existe una matriz regular $X \in \mathbb{C}^{n \times n}$ tal que $X^{-1} A X = \text{diag}(J_1, \dots, J_k)$ donde

$$J_i = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & 1 & 0 \\ & & \ddots & \\ 0 & & & 1 \\ & & & & \lambda_i \end{bmatrix} \in \mathbb{C}^{n_i \times n_i}$$

y $n_1 + \dots + n_k = n$. Las J_i son las matrices o bloques de Jordan y los λ_i los valores propios de A .

Una matriz simétrica definida positiva tiene todos sus valores propios reales y positivos; si es semidefinida, alguno es cero. Si la matriz es negativa definida,

todos sus valores propios son negativos.

Si A es hermítica, el producto $\mathbf{x}^H A \mathbf{x}$ es un número real. Los *valores propios* de una *matriz hermítica*, en consecuencia, son *números reales*. En una matriz hermítica los vectores propios correspondientes a dos valores propios distintos son ortogonales entre sí.

Un resultado importante para averiguar el orden de magnitud de los valores propios de una matriz es el que sigue.

Teorema 4.7 Geršgorin Los valores propios de una matriz $A \in \mathbb{C}^{n \times n}$ se encuentran en la unión de los n discos de Gershgorin, cada uno de los cuales está centrado en a_{kk} , $k = 1, \dots, n$, y tiene de radio

$$r_k = \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$$

DEMOSTRACIÓN. Sea λ un valor propio de A y $\mathbf{x}$ su vector propio asociado. De $A\mathbf{x} = \lambda\mathbf{x}$ y $(\lambda I - A)\mathbf{x} = \mathbf{0}$ se tiene que

$$(\lambda - a_{kk})x_k = \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}x_j, \quad k = 1, \dots, n,$$

donde x_k es el componente k -ésimo del vector $\mathbf{x}$.

Si x_i es el coeficiente de $\mathbf{x}$ más grande en valor absoluto, como $|x_j|/|x_i| \leq 1$ para $j \neq i$, se tiene que

$$|\lambda - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|.$$

Luego λ está contenido en el disco $\{\lambda : |\lambda - a_{ii}| \leq r_i\}$. ■

4.3.2 Valores singulares

La noción de valor propio, o autovalor, no tiene significado para matrices rectangulares. En éstas, por el contrario, si lo tiene, como en las cuadradas, el concepto de *valor singular*. Si A es una matriz cualquiera $m \times n$ con coeficientes en $\mathbb{R}$, se definen sus *valores singulares* σ_i , $i = 1, \dots, \min\{m, n\}$, como las raíces cuadradas positivas de los valores propios de la matriz cuadrada $A^T A \in \mathbb{R}^{n \times n}$.

Teorema 4.8 *Descomposición en valores singulares* Si $A \in \mathbb{R}^{m \times n}$ es una matriz de rango r existen matrices ortogonales $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ tales que

$$A = U \Sigma V^T,$$

donde $\Sigma = \begin{bmatrix} \Sigma_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$, $\Sigma \in \mathbb{R}^{m \times n}$ y $\Sigma_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$. Si las matrices U y V se escriben como $U = [u_1, \dots, u_m]$ y $V = [v_1, \dots, v_n]$, los u_i y v_i son los vectores singulares izquierdos y derechos, respectivamente, correspondientes a los valores singulares σ_i , $i = 1, \dots, r$.

DEMOSTRACIÓN. Sean $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dos vectores tales que

$$\|x\|_2 = \|y\|_2 = 1 \quad \text{y} \quad Ax = \sigma y, \quad \text{con} \quad \sigma = \|A\|_2.$$

La existencia de estos vectores x e y está garantizada por la definición de $\|A\|_2$.

Sean las dos matrices ortogonales

$$V = [x \ V_1] \in \mathbb{R}^{n \times n} \quad \text{y} \quad U = [y \ U_1] \in \mathbb{R}^{m \times m}$$

(siempre es posible ampliar un conjunto de vectores ortogonales hasta formar una base ortonormal de $\mathbb{R}^n$). Como $U_1^T Ax = \sigma U_1^T y = \mathbf{0}$, la matriz $U^T A V$ tiene la siguiente estructura:

$$A_1 = U^T A V = \begin{bmatrix} y^T \\ U_1^T \end{bmatrix} A [x \ V_1] = \begin{bmatrix} \sigma & w^T \\ 0 & B \end{bmatrix},$$

donde $B = U_1^T A V_1 \in \mathbb{R}^{(m-1) \times (n-1)}$ y $w^T = y^T A V_1$.

Dado que $\|A_1 \begin{bmatrix} \sigma \\ w \end{bmatrix}\|_2 = \left\| \begin{bmatrix} \sigma^2 + w^T w \\ Bw \end{bmatrix} \right\|_2 \geq \sigma^2 + w^T w$, como

$$\|A_1 \begin{bmatrix} \sigma \\ w \end{bmatrix}\|_2 \leq \|A_1\|_2 \left\| \begin{bmatrix} \sigma \\ w \end{bmatrix} \right\|_2 = \|A_1\|_2 \sqrt{(\sigma^2 + w^T w)^2},$$

se cumple que $\|A_1\|_2 \geq (\sigma^2 + w^T w)^{1/2}$. Como las matrices U y V son ortogonales, $\|A_1\|_2 = \|A\|_2 = \sigma$ y por consiguiente $w = \mathbf{0}$. La argumentación de la demostración se completa por inducción. ■

La matriz $A^{m \times n} = U \Sigma V^T$, de rango r , se puede escribir como la suma de r matrices de rango uno así

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T,$$

donde los u_i y v_i son los vectores columna i -ésimos de U y V .

La mejor aproximación de A de rango $p \leq r$, en el sentido de mínimos cuadrados, se obtiene de la suma de los primeros p términos de esta última suma. Por

ejemplo —de Sauer [2013]—, el mejor subespacio de dimensión uno de los puntos $[3, 2]$, $[2, 4]$, $[-2, -1]$ y $[-3, -5]$ en el sentido de mínimos cuadrados se obtiene de

$$\begin{aligned} A &= \begin{bmatrix} 3 & 2 & -2 & -3 \\ 2 & 4 & -1 & -5 \end{bmatrix} = U \Sigma V^T \\ &= \begin{bmatrix} 0,5886 & -0,8084 \\ 0,8084 & 0,5886 \end{bmatrix} \begin{bmatrix} 8,2809 & 0 & 0 & 0 \\ 0 & 1,8512 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0,4085 & 0,5327 & -0,2398 & -0,7014 \\ -0,6741 & 0,3985 & 0,5554 & -0,2798 \\ 0,5743 & -0,1892 & 0,7924 & -0,0801 \\ 0,2212 & 0,7223 & 0,0780 & 0,6507 \end{bmatrix}. \end{aligned}$$

Como $p = 1$, la mejor aproximación de A es $u_1 = [0,5886, 0,8084]$. Del sumatorio anterior, haciendo $\sigma_2 = 0$,

$$\begin{aligned} A_1 &= \begin{bmatrix} 0,5886 & -0,8084 \\ 0,8084 & 0,5886 \end{bmatrix} \begin{bmatrix} 8,2809 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0,4085 & 0,5327 & -0,2398 & -0,7014 \\ -0,6741 & 0,3985 & 0,5554 & -0,2798 \\ 0,5743 & -0,1892 & 0,7924 & -0,0801 \\ 0,2212 & 0,7223 & 0,0780 & 0,6507 \end{bmatrix} \\ &= \begin{bmatrix} 1,9912 & 2,5964 & -1,1689 & -3,4188 \\ 2,7364 & 3,5657 & -1,6052 & -4,6951 \end{bmatrix}. \end{aligned}$$

El proceso se esquematiza en la figura 4.7.




Figura 4.7: Proyección de cuatro vectores en el subespacio de dimensión uno que mejor los representa: recta de trazos

Dada la descomposición en valores singulares de A , de rango r , los vectores singulares a la izquierda $\{u_1, \dots, u_r\}$ conforman una base ortonormal de $\text{Im}(A)$ y $\{u_{r+1}, \dots, u_m\}$ otra base ortonormal de $\ker(A^T)$. Igualmente, $\{v_{r+1}, \dots, v_n\}$ es una base ortonormal de $\ker(A)$ y $\{v_1, \dots, v_r\}$ una base ortonormal de $\text{Im}(A^T)$.

Los valores singulares de A son las longitudes de los semiejes del hiperelipsoide E definido, a partir de la esfera unidad y el operador A , por

$$E = \{y : y = Ax, \|x\|_2 = 1\}.$$




Figura 4.8: Representación en dos dimensiones de una transformación lineal de la esfera unidad

En la figura 4.8 se describe gráficamente el caso en que $m = n = 2$.

El *número de condición* de una matriz es la relación entre sus valores singulares mayor y menor. Una matriz se dice mal condicionada si ese número es grande o muy grande. Una matriz singular tiene un número de condición infinito.

Si A es una matriz $n \times n$, $|\det(A)| = \sigma_1 \cdot \sigma_2 \cdots \sigma_n$. Para una matriz $A \in \mathbb{R}^{m \times n}$ cuya descomposición en valores singulares es $A = U \Sigma V^T$, se define su *matriz pseudoinversa*, $A^\dagger$, como

$$A^\dagger = V \Sigma^\dagger U^T,$$

donde

$$\Sigma^\dagger = \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}, 0, \dots, 0) \in \mathbb{R}^{n \times m}.$$

Si $A \in \mathbb{R}^{m \times n}$ es de rango completo y $m > n$, $A^\dagger = (A^T A)^{-1} A^T$; si $m < n$, $A^\dagger = A^T (A A^T)^{-1}$.

Para cualquier matriz $A \in \mathbb{R}^{m \times n}$, la matriz $A^\dagger A$ es la matriz $n \times n$ de proyección ortogonal sobre el subespacio de los vectores fila de A , $A A^\dagger$ la $m \times m$ de proyección ortogonal sobre la imagen de la matriz A (subespacio de sus vectores columna) y $(I - A^\dagger A)$ la de proyección ortogonal sobre el núcleo de A , $\ker(A)$.

4.3.3 Formas cuadráticas

Una *forma cuadrática* en n variables es un polinomio de segundo grado en esas variables. La expresión más general de una forma cuadrática es

$$q(x) = x^T Q x,$$

donde $\mathbf{Q} = \mathbf{Q}^T$ es una matriz simétrica de orden n . Nos limitaremos al análisis de formas cuadráticas con coeficientes reales.

Mediante una transformación lineal de variables, $\mathbf{x} = \mathbf{T} \mathbf{y}$, una forma cuadrática se puede reducir a la forma canónica de *suma de cuadrados* siguiente:

$$q(\mathbf{x}) = \sum_{i=1}^p y_i^2 - \sum_{i=p+1}^{p+q} y_i^2.$$

El *rango* de la forma es $p + q$ y la *signatura* $p - q$ (p números positivos y q negativos).

Una forma cuadrática real es *definida positiva* si para todo vector $\mathbf{x} \neq \mathbf{0}$, $q(\mathbf{x}) > 0$. El rango y signatura de una forma cuadrática definida positiva valen n . Si $\mathbf{Q}$ la forman los coeficientes q_{ij} y se introducen los números *menores* como

$$\Delta_i = \det \begin{bmatrix} q_{11} & q_{12} & \cdots & q_{1i} \\ q_{21} & q_{22} & \cdots & q_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ q_{i1} & q_{i2} & \cdots & q_{ii} \end{bmatrix},$$

la forma cuadrática asociada a $\mathbf{Q}$ es definida positiva si y sólo si todos los menores Δ_i son positivos.

Sean $\lambda_1, \dots, \lambda_n$ los valores propios —que sabemos son reales— de la matriz $\mathbf{Q}$. Por el teorema espectral, existe una matriz ortogonal $\mathbf{P}$ tal que $\mathbf{P}^T \mathbf{Q} \mathbf{P} = \text{diag}(\lambda_1, \dots, \lambda_n)$. Haciendo en la forma cuadrática $q(\mathbf{x}) = \mathbf{x}^T \mathbf{Q} \mathbf{x}$ el cambio de variables $\mathbf{x} = \mathbf{P} \mathbf{y}$, se tiene que

$$q(\mathbf{x}) = \mathbf{y}^T \mathbf{P}^T \mathbf{Q} \mathbf{P} \mathbf{y} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2,$$

por lo que el rango de la forma cuadrática es el número total —teniendo en cuenta las multiplicidades— de valores propios no nulos de $\mathbf{Q}$, mientras que la signatura coincide con la diferencia entre los números de valores propios positivos y negativos. En particular, la forma cuadrática asociada a $\mathbf{Q}$ es definida positiva si y sólo si todos los valores propios de $\mathbf{Q}$ son positivos.

En ciertos casos es importante acotar el cociente de una forma cuadrática al cuadrado de la norma euclídea, es decir, el cociente

$$r(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{Q} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}, \quad \mathbf{x} \neq \mathbf{0}.$$

Mediante una transformación ortogonal $\mathbf{x} = \mathbf{P} \mathbf{y}$, este cociente se escribe como

$$r(\mathbf{x}) = \frac{\lambda_1 y_1^2 + \cdots + \lambda_n y_n^2}{y_1^2 + \cdots + y_n^2},$$

de manera que se deducen las acotaciones

$$\lambda_{\min}(\mathbf{Q}) \leq \frac{\mathbf{x}^T \mathbf{Q} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \leq \lambda_{\max}(\mathbf{Q}).$$

Estas acotaciones no se pueden mejorar ya que si $\mathbf{Q} \mathbf{v} = \lambda \mathbf{v}$, $\frac{\mathbf{v}^T \mathbf{Q} \mathbf{v}}{\mathbf{v}^T \mathbf{v}} = \lambda$.

5 Teorema de la proyección

GRAN parte de las teorías de sistemas de ecuaciones y de optimización están basadas en unos pocos resultados simples e intuitivos. Entre estos, quizás el más sencillo y usado sea el teorema de la proyección. Su aplicación en la teoría de mínimos cuadrados lineales es fundamental. En un espacio Euclídeo ordinario de tres dimensiones determina que la distancia más corta de un punto exterior a un plano a ese plano la proporciona la perpendicular al plano desde dicho punto. La expresión formal de este teorema en espacios de Hilbert es la que sigue.

Teorema 5.1 Sea H un espacio de Hilbert y M un subespacio cerrado de H . Para todo vector $\mathbf{x} \in H$ existe un único vector $\mathbf{m}_0 \in M$ tal que $\|\mathbf{x} - \mathbf{m}_0\|_2 \leq \|\mathbf{x} - \mathbf{m}\|_2$, para todo $\mathbf{m} \in M$. La condición necesaria y suficiente además para que $\mathbf{m}_0 \in M$ sea el vector mínimo único es que $\mathbf{x} - \mathbf{m}_0$ sea ortogonal a M .

DEMOSTRACIÓN. Primero probaremos que si $\mathbf{m}_0$ es un vector que minimiza $\|\mathbf{x} - \mathbf{m}\|$, $\mathbf{x} - \mathbf{m}_0$ es ortogonal a M . Supongamos para ello, por el contrario, que existe un $\mathbf{m}$ que no es ortogonal a $\mathbf{x} - \mathbf{m}_0$; sin pérdida de generalidad podemos suponer que $\|\mathbf{m}\| = 1$ y que $\langle \mathbf{x} - \mathbf{m}_0 | \mathbf{m} \rangle = \delta \neq 0$. Definamos el vector $\mathbf{m}_1 \in M$ como $\mathbf{m}_1 = \mathbf{m}_0 + \delta \mathbf{m}$. Tendremos que

$$\begin{aligned} \|\mathbf{x} - \mathbf{m}_1\|_2^2 &= \|\mathbf{x} - \mathbf{m}_0 - \delta \mathbf{m}\|_2^2 \\ &= \|\mathbf{x} - \mathbf{m}_0\|_2^2 - \langle \mathbf{x} - \mathbf{m}_0 | \delta \mathbf{m} \rangle - \langle \delta \mathbf{m} | \mathbf{x} - \mathbf{m}_0 \rangle + |\delta|^2 \\ &= \|\mathbf{x} - \mathbf{m}_0\|_2^2 - |\delta|^2 < \|\mathbf{x} - \mathbf{m}_0\|_2^2. \end{aligned}$$

De esta manera, si $\mathbf{x} - \mathbf{m}_0$ no es ortogonal a M , $\mathbf{m}_0$ no es el mínimo que decíamos.

Veamos ahora cómo, si $\mathbf{x} - \mathbf{m}_0$ es ortogonal al subespacio M , $\mathbf{m}_0$ es el único vector de M que minimiza $\|\mathbf{x} - \mathbf{m}\|_2$. En efecto, para todo $\mathbf{m} \in M$, el teorema de Pitágoras dice que

$$\|\mathbf{x} - \mathbf{m}\|_2^2 = \|\mathbf{x} - \mathbf{m}_0 + \mathbf{m}_0 - \mathbf{m}\|_2^2 = \|\mathbf{x} - \mathbf{m}_0\|_2^2 + \|\mathbf{m}_0 - \mathbf{m}\|_2^2.$$

Por lo tanto $\|\mathbf{x} - \mathbf{m}\|_2 > \|\mathbf{x} - \mathbf{m}_0\|_2$ para $\mathbf{m} \neq \mathbf{m}_0$.

Demostremos ahora la existencia de un $\mathbf{m}_0$ que minimiza $\|\mathbf{x} - \mathbf{m}\|_2$. Si $\mathbf{x} \in M$, entonces $\mathbf{m}_0 = \mathbf{x}$ y todo estaría probado como es obvio. Si $\mathbf{x} \notin M$, definamos un $\delta = \inf_{\mathbf{m} \in M} \|\mathbf{x} - \mathbf{m}\|_2$; lo que queremos es obtener un $\mathbf{m}_0 \in M$ tal que $\|\mathbf{x} - \mathbf{m}_0\|_2 = \delta$.

A tal fin, sea $\{\mathbf{m}^{(i)}\}$ una sucesión de vectores en M tal que $\|\mathbf{x} - \mathbf{m}^{(i)}\|_2 \rightarrow \delta$. Por la ley del paralelogramo⁹ se tiene que

$$\begin{aligned} \left\|(\mathbf{m}^{(j)} - \mathbf{x}) + (\mathbf{x} - \mathbf{m}^{(i)})\right\|_2^2 + \left\|(\mathbf{m}^{(j)} - \mathbf{x}) - (\mathbf{x} - \mathbf{m}^{(i)})\right\|_2^2 = \\ 2\left\|\mathbf{m}^{(j)} - \mathbf{x}\right\|_2^2 + 2\left\|\mathbf{x} - \mathbf{m}^{(i)}\right\|_2^2. \end{aligned}$$

Reordenando, se obtiene

$$\left\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\right\|_2^2 = 2\left\|\mathbf{m}^{(j)} - \mathbf{x}\right\|_2^2 + 2\left\|\mathbf{x} - \mathbf{m}^{(i)}\right\|_2^2 - 4\left\|\mathbf{x} - \frac{\mathbf{m}^{(i)} + \mathbf{m}^{(j)}}{2}\right\|_2^2.$$

Para todo i, j , el vector $(\mathbf{m}^{(i)} + \mathbf{m}^{(j)})/2$ está en M pues éste es un espacio vectorial (lineal). De la definición de δ se deduce que $\|\mathbf{x} - (\mathbf{m}^{(i)} + \mathbf{m}^{(j)})/2\|_2 \geq \delta$, por lo que

$$\left\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\right\|_2^2 \leq 2\left\|\mathbf{m}^{(j)} - \mathbf{x}\right\|_2^2 + 2\left\|\mathbf{x} - \mathbf{m}^{(i)}\right\|_2^2 - 4\delta^2.$$

Como $\|\mathbf{m}^{(i)} - \mathbf{x}\|_2^2 \rightarrow \delta^2$ cuando $i \rightarrow \infty$, $\|\mathbf{m}^{(j)} - \mathbf{m}^{(i)}\|_2^2 \rightarrow 0$ cuando $i, j \rightarrow \infty$. Es decir, $\{\mathbf{m}^{(i)}\}$ es una sucesión de Cauchy; como M es un subespacio cerrado, la sucesión $\{\mathbf{m}^{(i)}\}$ tiene un límite $\mathbf{m}_0$ en M y, debido a la continuidad de la norma, $\|\mathbf{x} - \mathbf{m}_0\|_2 \rightarrow \delta$. ■

El teorema de la proyección pone en evidencia que la solución del problema

$$\underset{t}{\text{minimizar}} \quad \|t\mathbf{x} - \mathbf{y}\|$$

es el vector proyección ortogonal de $\mathbf{y}$ sobre $\mathbf{x}$: $t\mathbf{x}$ en la figura 5.9.

6 Funciones

RECORDEMOS que una función es un caso particular de aplicación donde los conjuntos origen e imagen son conjuntos de números.

Una función $f: \mathbb{R}^n \rightarrow \mathbb{R}$ se dice *continua* en $\mathbf{x}$ si para toda sucesión $\{\mathbf{x}^{(k)}\}$ que

⁹Para $\mathbf{u}, \mathbf{w} \in M$, $|\mathbf{u} + \mathbf{w}|^2 + |\mathbf{u} - \mathbf{w}|^2 = 2|\mathbf{u}|^2 + 2|\mathbf{w}|^2$.




Figura 5.9: Solución de minimizar $_t \|tx - y\|$

converge a x (expresado $x^{(k)} \rightarrow x$), se cumple que $f(x^{(k)}) \rightarrow f(x)$. De forma equivalente, f se dice continua en x si dado un $\varepsilon > 0$, existe un $\delta > 0$ tal que

$$\|y - x\| < \delta \implies \|f(y) - f(x)\| < \varepsilon.$$

Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ tiene como derivada la función

$$f'(x) = \frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

supuesto ese límite existe. Una función f que es derivable en un punto $x = a$ es continua en a .

Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ se dice satisface la *condición de Lipschitz* con constante γ en un conjunto X , si para todo x e y pertenecientes a X se cumple que

$$|f(x) - f(y)| \leq \gamma |x - y|.$$

Una función que satisface la condición de Lipschitz en un conjunto X se dice *continua γ -Lipschitz* en ese X , designándose $f \in \text{Lip}_\gamma(X)$.

Dada una norma vectorial $\|\cdot\|$ en $\mathbb{R}^n$ y otra matricial $\|\cdot\|$ en $\mathbb{R}^{m \times n}$, $m, n > 0$, una función $g : \mathbb{R}^n \rightarrow \mathbb{R}^{m \times n}$ se dice satisface la *condición de Lipschitz* con constante γ en un abierto $D \subset \mathbb{R}^n$, si para todo x e y pertenecientes a D se cumple que

$$\|g(x) - g(y)\| \leq \gamma \|x - y\|.$$

Una función g que satisface la condición de Lipschitz en D se dice *continua γ -Lipschitz* en ese D , designándose $g \in \text{Lip}_\gamma(D)$.

Un resultado muy interesante referido a funciones continuas es el *teorema de Weierstrass*, que dice que una función continua definida en un conjunto compacto S tiene un punto donde alcanza un mínimo en S . Es decir, existe un $x^* \in S$ tal que para todo $x \in S$, $f(x) \geq f(x^*)$.

Un conjunto de funciones $f_1, f_2, \dots, f_m$ de $\mathbb{R}^n$ en $\mathbb{R}$ se puede considerar como una función vectorial

$$\mathbf{f} = [f_1, f_2, \dots, f_m]^T.$$

Esta función asigna a todo vector $\mathbf{x} \in \mathbb{R}^n$ otro vector $\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})]^T$ de $\mathbb{R}^m$. Tal función vectorial se dice continua si lo es cada uno de sus componentes $f_1, f_2, \dots, f_m$.

Si cada una de las funciones de $\mathbf{f} = [f_1, f_2, \dots, f_m]^T$ es continua en algún conjunto abierto de $\mathbb{R}^n$, se dice $\mathbf{f} \in C$. Si además cada función componente tiene derivadas parciales de primer orden continuas en ese abierto, se dice que $\mathbf{f} \in C^1$. En general, si las funciones componentes tienen derivadas parciales de orden p continuas, se indica $\mathbf{f} \in C^p$.

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $f \in C^1$, se define el *vector gradiente* de f como el vector

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T.$$

También se puede ver expresado alguna vez como $f_{\mathbf{x}}(\mathbf{x})$.

Si $f \in C^2$, se define la *matriz Hessiana* de f en $\mathbf{x}$ —por Ludwig Otto Hesse, Alemania 1811-1874— como la matriz $n \times n$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial^2 x_n} \end{bmatrix}.$$

A esta matriz también se la puede ver designada como $\mathbf{F}(\mathbf{x})$.

Para la función vectorial $\mathbf{f} = [f_1, f_2, \dots, f_m]^T$, $\mathbf{f} \in C^1$, se define la *matriz Jacobiana* —por Carl Gustav Jacob Jacobi, Alemania 1804-1851— como la matriz $m \times n$

$$\nabla \mathbf{f}(\mathbf{x}) = \mathbf{J}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_1(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \frac{\partial f_m(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}.$$

Si $f \in C^2$, es posible definir m Hessianas $F_1(x), F_2(x), \dots, F_m(x)$ para cada una de las $f_1, \dots, f_m$.

Una función $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ es *afín* si es la suma de una función lineal y una constante; es decir, tiene la forma $f(x) = Ax + b$, donde $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$.

Teorema 6.1 Teorema de Taylor Si $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $f \in C^1$ en una región que contiene el segmento $[x_1, x_2]$, es decir puntos $\alpha x_1 + (1-\alpha)x_2$, $0 \leq \alpha \leq 1$, existe un θ , $0 \leq \theta \leq 1$, tal que $f(x_2) = f(x_1) + \nabla^T f(\theta x_1 + (1-\theta)x_2)(x_2 - x_1)$. Además, si $f \in C^2$, existe un θ , $0 \leq \theta \leq 1$, tal que $f(x_2) = f(x_1) + \nabla^T f(x_1)(x_2 - x_1) + \frac{1}{2}(x_2 - x_1)^T F(\theta x_1 + (1-\theta)x_2)(x_2 - x_1)$, donde F denota la matriz Hessiana de f .

Si la función $f: \mathbb{R} \rightarrow \mathbb{R}$ es continua y derivable $k+1$ veces en un intervalo, o segmento, $[x, x_0]$, existe un b entre x y x_0 tal que

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \frac{f'''(x_0)}{3!}(x - x_0)^3 + \dots + \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k + \frac{f^{(k+1)}(b)}{(k+1)!}(x - x_0)^{k+1}.$$

Las aproximaciones por este teorema para una función concreta, $\sin(x)$, se pueden ver en la figura 6.10.




Figura 6.10: Función $\sin(x)$ y, en $x = 0$, las aproximaciones por Taylor de **primer orden**, de orden 3, 5, 7, 9, 11 y 13

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se dice *convexa* (figura 6.11) si cumple que $f(\alpha x + \beta y) \leq \alpha f(x) + \beta f(y)$ para todo $x, y \in \mathbb{R}^n$ y todo $\alpha, \beta \in \mathbb{R}$, con $\alpha + \beta = 1$, $\alpha \geq 0$, $\beta \geq 0$. Si $S \subseteq \mathbb{R}^n$ es un conjunto convexo y $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es una función afín, la imagen de $f(S) = \{f(x) : x \in S\}$ es un conjunto convexo. De forma similar, si $f : \mathbb{R}^k \rightarrow \mathbb{R}^n$ es una función afín, la imagen inversa $f^{-1}(S) = \{x : f(x) \in S\}$ también es convexa.




Figura 6.11: Función convexa

Teorema 6.2 *Teorema del valor intermedio* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$, toma todos los valores entre $f(a)$ y $f(b)$. Más concretamente, si y es un número entre $f(a)$ y $f(b)$, existe un número c dentro de $[a, b]$, es decir, tal que $a \leq c \leq b$, en el que $f(c) = y$.




Figura 6.12: Teorema del valor intermedio

Teorema 6.3 *Teorema del valor medio* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua y derivable en el intervalo $[a, b]$, existe un número c entre a y b tal que $f'(c) = (f(b) - f(a))/(b - a)$.




Figura 6.13: Teorema del valor medio

Teorema 6.4 Teorema de Rolle Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua y derivable en el intervalo $[a, b]$ y suponemos que $f(a) = f(b)$, existe un número c , entre a y b , tal que $f'(c) = 0$. GENERALIZACIÓN Si f es continua y derivable $n - 1$ veces en $[a, b]$ y la derivada de orden n existe en el abierto (a, b) , y existen n intervalos $a_1 < b_1 \leq a_2 < b_2 \leq \dots \leq a_n < b_n$ en $[a, b]$, tales que $f(a_k) = f(b_k)$ para todo $k = 1 \dots n$, existe un número c en (a, b) tal que la derivada de orden n de f en c es cero.




Figura 6.14: Teorema de Rolle

Teorema 6.5 Primer teorema del valor medio de las integrales Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$, existe entonces al menos un número c entre a y b tal que

$$\int_a^b f(x) dx = f(c)(b - a).$$




Figura 6.15: Teorema del valor medio de las integrales

Teorema 6.6 *Segundo teorema del valor medio de las integrales* Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$ y $g : \mathbb{R} \rightarrow \mathbb{R}$ una función integrable que no cambia de signo en $[a, b]$, existe entonces un número c entre a y b tal que

$$\int_a^b f(x)g(x) dx = f(c) \int_a^b g(x) dx.$$

Teorema 6.7 Si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua en el intervalo $[a, b]$ y $a \leq c \leq b$, entonces

$$\frac{d}{dx} \int_c^x f(t) dt = f(x)$$

para todo x en $[a, b]$.

Teorema 6.8 *Integración por partes* Sean $u(x)$ y $v(x)$ funciones reales continuas con derivadas continuas. Entonces

$$\int u'(x)v(x) dx = u(x)v(x) - \int u(x)v'(x) dx.$$

6.1 Condiciones necesarias y suficientes de punto mínimo

Se trata de definir condiciones necesarias y suficientes para determinar si dada $f : \Omega \rightarrow \mathbb{R}$, $\Omega \in \mathbb{R}^n$, un punto x^* hace mínima esa función.

Un punto $x^* \in \Omega$ se dice que es un *mínimo local* de la función $f : \Omega \rightarrow \mathbb{R}$ si existe un $\epsilon > 0$ tal que $f(x) \geq f(x^*)$ para todo $x \in \Omega$ a una distancia menor que ϵ de x^* . Es decir, para todo $x \in \Omega$ tal que $|x - x^*| < \epsilon$. Si $f(x) > f(x^*)$ para todo $x \in \Omega$, $x \neq x^*$, a una distancia menor que ϵ de x^* , se dice que x^* es un *mínimo local estricto* de f en Ω .

Teorema 6.9 *Condiciones necesarias de primer orden* Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^1$. Si $\mathbf{x}^*$ es un mínimo local de f en Ω , se cumple que $\nabla f(\mathbf{x}^*) = 0$.

Si en $\mathbf{x}^*$ se cumple que $\nabla f(\mathbf{x}^*) = 0$, $\mathbf{x}^*$ se denomina *punto estacionario*.

Teorema 6.10 *Condiciones necesarias de segundo orden* Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^2$. Si $\mathbf{x}^*$ es un mínimo local de f en Ω , se cumple que $\nabla f(\mathbf{x}^*) = 0$ y $\nabla^2 f(\mathbf{x}^*)$ es semidefinida positiva.

Teorema 6.11 *Condiciones suficientes de segundo orden* Sea Ω un subconjunto de $\mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, $f \in C^2$. Si se cumple que $\nabla f(\mathbf{x}^*) = 0$ y $\nabla^2 f(\mathbf{x}^*)$ es definida positiva, $\mathbf{x}^*$ es un mínimo local estricto de f en Ω .

Teorema 6.12 Si f es convexa, cualquier mínimo local $\mathbf{x}^*$ es un mínimo global de f . Si además f es derivable, cualquier mínimo local $\mathbf{x}^*$ es un mínimo global.

6.2 Teorema de la función implícita

Teorema 6.13 Sea $\mathbf{x}_0 = [x_{01}, x_{02}, \dots, x_{0n}]^T$ un punto de $\mathbb{R}^n$ que satisface:

(a) Las m funciones $f_i \in C^p$, $i = 1, 2, \dots, m$, en algún entorno de $\mathbf{x}_0$, para alguna $p \geq 1$.

(b) $f_i(\mathbf{x}_0) = 0$, $i = 1, 2, \dots, m$.

(c) La matriz Jacobiana de la función vectorial, $\nabla f(\mathbf{x}_0) = \begin{bmatrix} \frac{\partial f_1(\mathbf{x}_0)}{\partial x_1} & \dots & \frac{\partial f_1(\mathbf{x}_0)}{\partial x_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x}_0)}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x}_0)}{\partial x_m} \end{bmatrix}$, es regular.

Entonces existe un entorno de $\hat{\mathbf{x}}_0 = [x_{0m+1}, x_{0m+2}, \dots, x_{0n}]^T \in \mathbb{R}^{n-m}$ tal que para $\hat{\mathbf{x}} = [x_{m+1}, x_{m+2}, \dots, x_n]^T$ en ese entorno existen funciones $\phi_i(\hat{\mathbf{x}})$, $i = 1, 2, \dots, m$ tales que:

(i) $\phi_i \in C^p$.

(ii) $x_{0i} = \phi_i(\hat{\mathbf{x}}_0)$, $i = 1, 2, \dots, m$.

(iii) $f_i(\phi_1(\hat{\mathbf{x}}), \phi_2(\hat{\mathbf{x}}), \dots, \phi_m(\hat{\mathbf{x}}), \hat{\mathbf{x}}) = 0$, $i = 1, 2, \dots, m$.

Este teorema¹⁰ es muy útil para respaldar la caracterización de puntos ópti-

¹⁰Sus orígenes están asociados a Newton, Leibnitz y Lagrange, aunque fue formulado por Cauchy

mos en programación matemática con y sin condiciones, solución de ecuaciones lineales y no lineales y bastantes otras cuestiones.

Supóngase que se tiene una función vectorial $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ que cumple que $f_i(\mathbf{x}) = 0, i = 1, 2, \dots, m$. El teorema de la función implícita estudia, si $n - m$ de las variables son fijas, si el problema se puede resolver en m incógnitas. Es decir, si $x_1, x_2, \dots, x_m$ se pueden expresar en función de las restantes $n - m$ de la forma

$$x_i = \phi_i(x_{m+1}, x_{m+2}, \dots, x_n), \quad i = 1, 2, \dots, m.$$

A las funciones $\phi_i : \mathbb{R}^{n-m} \rightarrow \mathbb{R}$, si existen, se las denomina *funciones implícitas*.

Ejemplo 6.1 Consideremos la ecuación $x_1^2 + x_2 = 0$. Una solución de la misma es $x_1 = 0, x_2 = 0$. En un entorno de esta solución, sin embargo, no hay función ϕ tal que $x_1 = \phi(x_2)$. En esta solución no se cumple la condición (c) del teorema de la función implícita. En cualquier otra solución si existe dicha ϕ . ●

Ejemplo 6.2 Sea A una matriz $m \times n$ y considérese el sistema de ecuaciones lineales $A\mathbf{x} = \mathbf{b}$. Si A se estructura así, $A = [B, C]$, donde B es $m \times m$, entonces se satisface la condición (c) del teorema de la función implícita si, y sólo si, B es regular. Esta condición se corresponde con los requisitos y enunciados de la teoría de ecuaciones lineales. La función implícita se puede considerar como una generalización no lineal de la teoría lineal. ●

7 Optimización y Programación Matemática

L A *Optimización o Programación Matemática* tiene por objeto el estudio del problema

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimizar}} && f(\mathbf{x}) \\ & \text{sujeta a} && c_i(\mathbf{x}) = 0, \quad i \in \mathcal{E}, \\ & && c_j(\mathbf{x}) \geq 0, \quad j \in \mathcal{I}. \end{aligned}$$

Las *función objetivo* f y las *condiciones* c_i y c_j son, en general, no lineales, continuas y tienen derivadas parciales continuas hasta al menos primer orden. Los conjuntos $\mathcal{E}$ y $\mathcal{I}$ contienen los índices de las condiciones que son de igualdad y de desigualdad, respectivamente. El conjunto de puntos que satisfacen todas las condiciones se denomina *región factible*.

Para caracterizar las soluciones de estos problemas y definir sus algoritmos y procedimientos de resolución la optimización presta una atención fundamental a los conjunto convexos.




Figura 7.16: Conjuntos convexos –izquierda–; no convexos –derecha–

7.1 Conjuntos convexos

Un conjunto $C \subseteq \mathbb{R}^n$ se dice *convexo* si y sólo si para todo par de puntos $\mathbf{x}_1, \mathbf{x}_2 \in C$ todas las combinaciones de la forma $\mathbf{x} = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2$, con $0 \leq \lambda \leq 1$, están en C . Es decir, cuando para cada par de puntos del conjunto convexo todos los de la recta que los une están en el conjunto.

La expresión $\mathbf{x} = \lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2$, $0 \leq \lambda \leq 1$, define la *combinación convexa* de $\mathbf{x}_1$ y $\mathbf{x}_2$. Si $0 < \lambda < 1$, es decir $\lambda \in (0, 1)$, la combinación se denomina *estrictamente convexa*.

El concepto de combinación convexa se puede generalizar a cualquier número finito de puntos de la siguiente manera:

$$\mathbf{x} = \sum_{i=1}^p \lambda_i \mathbf{x}_i,$$

donde $\sum_{i=1}^p \lambda_i = 1$, $\lambda_i \geq 0$, $i = 1, \dots, p$.




Figura 7.17: Optimización (minimización) de $f(x, y) = -x - y$ en un conjunto convexo y en otro que no lo es.

El conjunto intersección de todos los conjuntos convexos que contienen a un subconjunto $S \subseteq \mathbb{R}^n$ se llama *envoltura convexa* de S (figura 7.18) y se designa por $\text{conv}(S)$.




Figura 7.18: Envoltura convexa de dos conjuntos de $\mathbb{R}^2$. La de la izquierda de 15 puntos; la de la derecha de un conjunto no convexo

Un conjunto $C \subseteq \mathbb{R}^n$ se dice que es *afín* (también se dice que C es una variedad afín o una variedad lineal) si para cualesquiera $\mathbf{x}, \mathbf{y} \in C$ y cualquier $\lambda \in \mathbb{R}$ se tiene que $(1 - \lambda)\mathbf{x} + \lambda\mathbf{y} \in C$. El conjunto vacío es afín. Una *combinación afín* de vectores $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ es una combinación lineal $c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n$ en la que $c_1 + \dots + c_n = 1$.

Un conjunto $C \subseteq \mathbb{R}^n$ es afín si y sólo si es de la forma

$$C = \{\mathbf{a} + \mathbf{l} : \mathbf{a} \in \mathbb{R}^n, \mathbf{l} \in L\},$$

donde L es un subespacio vectorial de $\mathbb{R}^n$ asociado a C . Es decir, un conjunto afín es un subespacio desplazado del origen. La dimensión de un conjunto afín $\mathbf{x} + L$ es la de su correspondiente subespacio L . Un *plano afín* en $\mathbb{R}^n$ es un traslado de un subespacio de $\mathbb{R}^n$. Una *recta* en $\mathbb{R}^n$ es un plano afín de dimensión 1. Es evidente que cualquier conjunto afín es convexo aunque el recíproco no es cierto en general.

Si $S \subseteq \mathbb{R}^n$, la *envoltura afín* de S , $\text{aff}(S)$, es la intersección de todos los conjuntos afines que contienen a S . Como se puede comprobar, $\text{aff}(S) = \text{aff}(\text{conv}(S))$.

Un conjunto de puntos o vectores $\{\mathbf{v}_1, \dots, \mathbf{v}_p\}$ de $\mathbb{R}^n$ es *afínmente dependiente* si existen números reales $c_1, \dots, c_p$ no todos cero tales que $c_1 + \dots + c_p = 0$ y $c_1\mathbf{v}_1 + \dots + c_p\mathbf{v}_p = \mathbf{0}$. De lo contrario será *afínmente independiente*.

Un *simplex* o *simplejo* es la envoltura convexa de un conjunto finito de vectores afínmente independientes. Para construir un simplex k -dimensional —o k -simplex— se procede como sigue (ver figura 7.19):

0-simplex S^0 : un solo punto $\{\mathbf{v}_1\}$

1-simplex S^1 : $\text{conv}(S^0 \cup \{\mathbf{v}_2\})$ con $\mathbf{v}_2$ no en $\text{aff}(S^0)$

2-simplex S^2 : $\text{conv}(S^1 \cup \{\mathbf{v}_3\})$ con $\mathbf{v}_3$ no en $\text{aff}(S^1)$




Figura 7.19: El simplex S^1 es un segmento de recta. El triángulo S^2 proviene de seleccionar un punto v_3 que no está en la recta que contiene a S^1 y después formar la envolvente convexa con S^1 . El tetraedro S^3 se produce al elegir un punto v_4 que no esté en el plano de S^2 y después formar la envolvente convexa con S^2

Sea $S = \{v_1, \dots, v_k\}$ un conjunto afínmente independiente. Para cada punto p en $\text{aff}(S)$ los coeficientes $c_1, \dots, c_k$ de la representación¹¹ $p = c_1 v_1 + \dots + c_k v_k$ son las *coordenadas baricéntricas* de p . Estas coordenadas tienen interpretaciones físicas y geométricas de interés. Fueron originalmente definidas en 1827 por August F. Möbius, Alemania 1790-1868. Si $a = \begin{bmatrix} 1 \\ 7 \end{bmatrix}$, $b = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$, $c = \begin{bmatrix} 9 \\ 3 \end{bmatrix}$ y $p = \begin{bmatrix} 5 \\ 3 \end{bmatrix}$, el punto p en el centro de la figura 7.20 tiene por coordenadas baricéntricas tres números no negativos m_a, m_b y m_c tales que p es el centro de masa de un sistema que consiste en el triángulo (sin masa) y las masas m_a, m_b y m_c en los vértices correspondientes. Las masas están unívocamente determinadas al requerir que su suma sea 1.

Proposición 7.1 *El conjunto de soluciones de un sistema de ecuaciones lineales, $C = \{x : Ax = b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m\}$, es un conjunto afín.*

DEMOSTRACIÓN. En efecto, supongamos que $x_1, x_2 \in C$, es decir, $Ax_1 = b$, $Ax_2 = b$. Entonces, para cualquier θ ,

$$\begin{aligned}
 A(\theta x_1 + (1 - \theta)x_2) &= \theta Ax_1 + (1 - \theta)Ax_2 \\
 &= \theta b + (1 - \theta)b \\
 &= b,
 \end{aligned}$$

¹¹Única.




Figura 7.20: Punto $p = ra + sb + tc$. En este caso $r = \frac{1}{4}$, $s = \frac{1}{3}$ y $t = \frac{5}{12}$.

lo que prueba que la combinación afín $\theta x_1 + (1 - \theta)x_2$ está también en el conjunto C . El subespacio asociado con el conjunto afín C en este caso es el espacio nulo de A , $\ker(A)$. ■

Un conjunto $C \subseteq \mathbb{R}^n$ se dice un *cono* si para todo $x \in C$, $\lambda x \in C$, para




Figura 7.21: Tres conos: el primero y el segundo no son convexos; el tercero si

todo escalar $\lambda \in \mathbb{R}$ tal que $\lambda \geq 0$. Un cono que también es convexo se denomina *cono convexo* (figura 7.21). En este caso, para todo $x_1, x_2 \in C$ y $\theta_1, \theta_2 \geq 0$, $\theta_1 x_1 + \theta_2 x_2 \in C$.

El conjunto $\{x \in \mathbb{R}^m : x = A\alpha, A \in \mathbb{R}^{m \times n}, \alpha \in \mathbb{R}^n, \alpha \geq 0\}$ es un cono convexo generado por los vectores columna de la matriz A .

El conjunto de todas las combinaciones cónicas de los puntos de un conjunto C , $\theta_1 x_1 + \dots + \theta_k x_k$, $\theta_1, \dots, \theta_k \geq 0$, es la *envoltura cónica* de C , $\text{cone}(C)$.

Un punto x es un *punto extremo o vértice* de un conjunto convexo C si y sólo si no es interior a un segmento de recta contenido en C . Es decir, si y sólo si

$$x = (1 - \beta)y + \beta z \text{ con } 0 < \beta < 1 \text{ y } y, z \in C \Rightarrow x = y = z.$$




Figura 7.22: Envoltura cónica de los dos conjuntos de la figura 7.18

Dos resultados importantes de Constantin Carathéodory, Alemania, 1873-1950, dicen que si $X \subseteq \mathbb{R}^n$ y $x \in \text{cone}(X)$, existen x_i y λ_i , $i = 1, \dots, n$, tales que $x = \sum_{i=1}^n \lambda_i x_i$. Es decir, cualquier elemento de la envoltura cónica de X es combinación cónica de, a lo sumo, n puntos de X . Igualmente, si $X \subseteq \mathbb{R}^n$ y $x \in \text{conv}(X)$, existen x_i y λ_i , $i = 1, \dots, n + 1$, tales que $x = \sum_{i=1}^{n+1} \lambda_i x_i$. Es decir, cualquier elemento de la envoltura convexa de X es combinación convexa de, a lo sumo, $n + 1$ puntos de X . La figura 7.23 ilustra estos resultados.




Figura 7.23: El teorema de Carathéodory

Llamaremos *hiperplano* H de *vector característico* $a \in \mathbb{R}^n$, $a \neq 0$, al conjunto $H = \{x \in \mathbb{R}^n : a^T x = c\}$, con $c \in \mathbb{R}$. Un hiperplano es el *conjunto de soluciones de una ecuación lineal* en $\mathbb{R}^n$.

Un hiperplano en $\mathbb{R}^n$ es un espacio afín o una variedad lineal $(n - 1)$ dimensional.

Dado un hiperplano H , $a^T x = c$, llamaremos *semiespacios cerrados de borde* H a los conjuntos $H_+ = \{x \in \mathbb{R}^n : a^T x \geq c\}$ y $H_- = \{x \in \mathbb{R}^n : a^T x \leq c\}$. *Semiespacios abiertos de borde* H a $\overset{\circ}{H}_+ = \{x \in \mathbb{R}^n : a^T x > c\}$ y $\overset{\circ}{H}_- = \{x \in \mathbb{R}^n : a^T x < c\}$. Los semiespacios de borde H son convexos; la unión de H_+ y H_- es el espacio $\mathbb{R}^n$. En la figura 7.24 se representa el hiperplano $-x_1 + 4x_2 =$

11, su vector característico $\mathbf{a} = [-1, 4]^T$ y los semiespacios H_+ y H_- .




Figura 7.24: Hiperplano $-x_1 + 4x_2 = 11$ y los semiespacios en los que divide $\mathbb{R}^2$

En un hiperplano $\mathbf{a}^T \mathbf{x} = c$ la constante c determina el desplazamiento del hiperplano del origen. Un hiperplano se puede expresar de la forma $\{\mathbf{x} : \mathbf{a}^T (\mathbf{x} - \mathbf{x}_0) = 0\}$, donde $\mathbf{x}_0$ es cualquier punto del hiperplano ($\mathbf{a}^T \mathbf{x}_0 = c$). Esa última expresión se puede trabajar un poco más pues $\{\mathbf{x} : \mathbf{a}^T (\mathbf{x} - \mathbf{x}_0) = 0\} = \mathbf{x}_0 + \mathbf{a}^\perp$, donde $\mathbf{a}^\perp$ es el complemento ortogonal de $\mathbf{a}$, es decir $\{\mathbf{v} : \mathbf{a}^T \mathbf{v} = 0\}$. Lo que lleva a que un hiperplano consiste en un desplazamiento $\mathbf{x}_0$ más todos los vectores ortogonales al vector característico $\mathbf{a}$: el conjunto de soluciones de $\mathbf{a}^T \mathbf{x} = c$: $\mathbf{x}_0 + \ker(\mathbf{a})$, recordemos.

Un *politopo* es un conjunto formado por la intersección de un número finito de semiespacios cerrados. Un *politopo cónico* es un conjunto formado por la intersección de un número finito de semiespacios cerrados que pasan por un punto.

Un *poliedro* es un politopo acotado y no vacío: ver figura 7.25. Es fácil comprobar que la intersección de conjuntos convexos es convexa y que, por lo tanto, los *politopos* y los *poliedros* son conjuntos convexos. Si un politopo P es un poliedro, cualquier punto se puede expresar como combinación convexa de sus puntos extremos o vértices.

Teorema 7.2 Sea C un conjunto convexo e $\mathbf{y}$ un punto exterior a la adherencia de C . Existe un vector $\mathbf{a}$ tal que $\mathbf{a}^T \mathbf{y} < \inf_{\mathbf{x} \in C} \mathbf{a}^T \mathbf{x}$.

DEMOSTRACIÓN. Sea

$$\delta = \inf_{\mathbf{x} \in C} \|\mathbf{x} - \mathbf{y}\|_2 > 0.$$

Existe un $\mathbf{x}_0$ en la frontera de C tal que $\|\mathbf{x}_0 - \mathbf{y}\|_2 = \delta$. Esto es así pues la función continua $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{y}\|_2$ alcanza su mínimo en cualquier conjunto




Figura 7.25: Diversos politopos; el del centro es un poliedro

cerrado y acotado por lo que sólo es necesario considerar $\mathbf{x}$ en la intersección de la adherencia de C y la bola abierta de centro $\mathbf{y}$ y radio 2δ .

A continuación probaremos que $\mathbf{a} = \mathbf{x}_0 - \mathbf{y}$ satisface las condiciones del enunciado del teorema. En efecto, para cualquier α , $0 \leq \alpha \leq 1$, al ser C un conjunto convexo, el punto $\mathbf{x}_0 + \alpha(\mathbf{x} - \mathbf{x}_0) \in C$, por lo que

$$\|\mathbf{x}_0 + \alpha(\mathbf{x} - \mathbf{x}_0) - \mathbf{y}\|_2^2 \geq \|\mathbf{x}_0 - \mathbf{y}\|_2^2.$$

Desarrollando,

$$2\alpha(\mathbf{x}_0 - \mathbf{y})^T(\mathbf{x} - \mathbf{x}_0) + \alpha^2\|\mathbf{x} - \mathbf{x}_0\|_2^2 \geq 0.$$

Considerando esta expresión cuando $\alpha \rightarrow 0+$, se tiene que

$$(\mathbf{x}_0 - \mathbf{y})^T(\mathbf{x} - \mathbf{x}_0) \geq 0$$

o que

$$\begin{aligned} (\mathbf{x}_0 - \mathbf{y})^T \mathbf{x} &\geq (\mathbf{x}_0 - \mathbf{y})^T \mathbf{x}_0 = (\mathbf{x}_0 - \mathbf{y})^T \mathbf{y} + (\mathbf{x}_0 - \mathbf{y})^T(\mathbf{x}_0 - \mathbf{y}) \\ &= (\mathbf{x}_0 - \mathbf{y})^T \mathbf{y} + \delta^2. \end{aligned}$$

Haciendo $\mathbf{a} = \mathbf{x}_0 - \mathbf{y}$ queda probado el teorema. ■

La interpretación geométrica de este teorema es que dado un conjunto convexo C y un punto $\mathbf{y}$ exterior a la adherencia de C existe un hiperplano que contiene a $\mathbf{y}$, sin tocar a C , estando C en uno de sus semiespacios abiertos. Ese hiperplano, de vector característico $\mathbf{a}$ en el teorema, se denomina *hiperplano separador* de C e $\mathbf{y}$.

Si C y D son dos conjuntos convexos disjuntos, $C \cap D = \emptyset$, existe entonces un $\mathbf{a} \neq 0$ y un $\mathbf{b}$ tales que $\mathbf{a}^T \mathbf{x} \leq \mathbf{b}$, para todo $\mathbf{x} \in C$, y $\mathbf{a}^T \mathbf{x} \geq \mathbf{b}$, para todo $\mathbf{x} \in D$. Dicho de otra manera, la función $\mathbf{a}^T \mathbf{x} - \mathbf{b}$ es no positiva en C y no negativa en D . El hiperplano $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = \mathbf{b}\}$ es un hiperplano separador de los conjuntos C y D como se ve en la figura 7.26.




Figura 7.26: Hiperplano separador entre C y D

Existen bastantes principios de *dualidad* (en especial en la teoría y técnicas de optimización) que relacionan un problema en términos de vectores en un espacio vectorial con otro en términos de subespacios en ese espacio. En varios de esos principios está presente la relación que se ilustra en la figura 7.27 que indica que la distancia más corta de un punto a un conjunto convexo es igual al máximo de las distancias desde el punto a los hiperplanos que separan el conjunto convexo del punto. El problema original de minimización sobre vectores se convierte en otro de maximización sobre hiperplanos.




Figura 7.27: Distancia más corta de un punto a un conjunto convexo en términos de hiperplanos separadores

Teorema 7.3 Sea C un conjunto convexo e y un punto frontera de C . Existe un hiperplano que contiene a y y a C en uno de sus semiespacios cerrados.

DEMOSTRACIÓN. Sea $\{y^{(k)}\}$ una sucesión de puntos exteriores a la adherencia de C . Sea $\{a^{(k)}\}$ la sucesión de puntos normalizados, $\|a^{(k)}\|_2 = 1$, obtenida de

aplicar el teorema anterior a la sucesión anterior, tales que,

$$\left(\mathbf{a}^{(k)}\right)^T \mathbf{y}^{(k)} < \inf_{\mathbf{x} \in C} \left(\mathbf{a}^{(k)}\right)^T \mathbf{x}.$$

Como $\{\mathbf{a}^{(k)}\}$ es una sucesión acotada, una subsucesión $\{\mathbf{a}^{(k)}\}$, $k \in \mathcal{H}$, convergerá a un límite $\mathbf{a}$. Para este $\mathbf{a}$ se tiene que, para cualquier $\mathbf{x} \in C$,

$$\mathbf{a}^T \mathbf{y} = \lim_{k \in \mathcal{H}} \left(\mathbf{a}^{(k)}\right)^T \mathbf{y}^{(k)} \leq \lim_{k \in \mathcal{H}} \left(\mathbf{a}^{(k)}\right)^T \mathbf{x} = \mathbf{a}^T \mathbf{x}.$$

■

Un hiperplano que contiene un conjunto convexo C en uno de sus semiespacios cerrados y que contiene algún punto frontera de C se denomina *hiperplano de apoyo* de C .

De acuerdo con esta definición, el teorema anterior dice que dado un conjunto convexo C y un punto frontera $\mathbf{y}$ de C existe un hiperplano de apoyo de C que contiene $\mathbf{y}$.

En la figura 7.28 $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = \mathbf{a}^T \mathbf{x}_0\}$ es el hiperplano de apoyo de C en el




Figura 7.28: Hiperplano de apoyo de C en $\mathbf{x}_0$

punto $\mathbf{x}_0$: el punto $\mathbf{x}_0$ y el conjunto C están separados por el hiperplano $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = \mathbf{a}^T \mathbf{x}_0\}$. Geométricamente quiere decir que el hiperplano $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = \mathbf{a}^T \mathbf{x}_0\}$ es tangente al conjunto C en $\mathbf{x}_0$ y el semiespacio $\mathbf{x} : \mathbf{a}^T \mathbf{x} \leq \mathbf{a}^T \mathbf{x}_0$ contiene a C .

Si S es un politopo de dimensión 3 en $\mathbb{R}^3$ —un cubo— y H un plano que se traslada en $\mathbb{R}^3$ hasta que apenas se apoya en el cubo, pero no corta el interior de éste, hay tres posibilidades para $H \cap S$ dependiendo de la orientación de H . Se ven en la figura 7.29.




Figura 7.29: $H \cap S$ es una cara cuadrada bidimensional del cubo, una arista unidimensional del cubo o un vértice de dimensión 0 del cubo

Lema 7.4 (Farkas) *El sistema de ecuaciones*

$$(I) \quad Ax = b, \quad x \geq 0,$$

no tiene solución si y sólo si la tiene el sistema

$$(II) \quad y^T A \leq 0^T, \quad b^T y > 0,$$

donde $A \in \mathbb{R}^{m \times n}$.

DEMOSTRACIÓN. El lema —por Farkas Bolyai, Hungría 1775-1856— se puede reformular de la siguiente manera. Si existe un $x \geq 0$ tal que $Ax = b$, no existe ningún y tal que $y^T A \leq 0^T$ y $b^T y > 0$. Recíprocamente, si no existe ningún $x \geq 0$ tal que $Ax = b$, existe un y tal que $y^T A \leq 0^T$ y $b^T y > 0$.

Supongamos que el sistema (I) tiene una solución x tal que $Ax = b$ y $x \geq 0$. Sea y un punto tal que $y^T A \leq 0^T$. En este caso $b^T y = x^T A^T y \leq 0$ pues $x \geq 0$ y $y^T A \leq 0^T$. Esto demuestra que $b^T y$ no puede ser positivo y, por lo tanto, el sistema (II) no tiene solución.

Supongamos ahora que el sistema (I) no tiene solución. Esto quiere decir que $b \notin S = \{v = Ax : x \geq 0\}$; es decir que b no pertenece al polítopo cónico S . Observando la figura 7.30, está claro que si $b \notin S$, existe un hiperplano separador definido por un y , que separa S y b , y para el cual $y^T a_i \leq 0$, $i = 1, \dots, n$ y $y^T b > 0$, es decir, y forma un ángulo de más de 90 grados con cada uno de los vectores columna de A y de menos de 90 grados con b .¹² Esto verifica que el sistema (II) tiene solución. ■

¹²El hiperplano separador del polítopo cónico S de la figura debería “casi” tocar a éste a lo largo de a_5 . El hiperplano de apoyo correspondiente, sí tocaría a a_5 .




Figura 7.30: Demostración del lema de Farkas

El lema de Farkas es un resultado importante para el estudio de sistemas lineales de inecuaciones. Su interpretación geométrica es la siguiente:

1. Si $a_i, i = 1, \dots, n$, son los n vectores columna de la matriz A , que se cumpla que $b = Ax, x \geq 0$, quiere decir que el vector $b = \sum_{i=1}^n a_i x_i, x_i \geq 0$; en otras palabras, que b pertenece al politopo cónico generado por los vectores columna de A . En la figura 7.31, a la izquierda, se muestra un ejemplo donde el sistema (I) no tiene solución: el vector b no pertenece al cono generado por a_1, a_2, a_3 y a_n . La intersección del cono $\{y : y^T A \leq 0^T\}$ (conjunto formado por los vectores y que forman un ángulo mayor o igual de 90° con los vectores columna de la matriz A) y el semiespacio abierto $\{y : b^T y > 0\}$, no es el conjunto vacío: el sistema (II) tiene solución, pues b y cualquier y en el cono que define la zona sombreada forma un ángulo menor de 90° y, por lo tanto, $b^T y > 0$.
2. El sistema (II) no tiene solución si la intersección del cono $\{y : y^T A \leq 0^T\}$ y




Figura 7.31: Izquierda: El sistema (I) del lema de Farkas no tiene solución; si (II). Derecha: El sistema (II) no tiene solución; la tiene (I)

el semiespacio abierto $\{y : b^T y > 0\}$ es el conjunto vacío. En la figura 7.31 a la derecha se muestra un ejemplo donde el sistema (II) no tiene solución. Todo vector y en la zona que define el cono indicado forma un ángulo mayor de 90° con b . La tiene sin embargo (I) pues b pertenece al cono generado por a_1, a_2 y a_n .

7.2 Caracterización del problema de optimización y condiciones de punto óptimo

Volvamos al problema general de Optimización

$$\begin{aligned} & \underset{x \in \mathbb{R}^n}{\text{minimizar}} && f(x) \\ & \text{sujeta a} && c_i(x) = 0, \quad i \in \mathcal{E}, \\ & && c_j(x) \geq 0, \quad j \in \mathcal{I}, \end{aligned}$$

donde las *función objetivo* f y las *condiciones* c_i y c_j son, en general, no lineales, continuas y tienen derivadas parciales continuas hasta al menos primer orden. Los conjuntos $\mathcal{E}$ y $\mathcal{I}$ contienen los índices de las condiciones que son de igualdad y de desigualdad, respectivamente. El conjunto de puntos que satisfacen todas las condiciones se denomina *región factible*.

Un punto $\mathbf{x}$ que satisfaga todas las condiciones se dice *regular* si los vectores gradiente del conjunto de condiciones activas en ese punto son linealmente independientes.

Un caso particular del problema de programación matemática enunciado es uno de *Programación Lineal*:

$$\begin{aligned} \min. \quad & \mathbf{c}^T \mathbf{x} \\ \text{s. a} \quad & \mathbf{A} \mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

Así expresado se denomina en *forma estándar*. La región factible, o conjunto de soluciones del programa lineal, $P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A} \mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$, es un politopo convexo.

Teorema 7.5 *Condiciones de óptimo de primer orden de Karush-Kuhn-Tucker*

Supóngase que $\mathbf{x}^*$ es un punto regular y mínimo local del problema general de programación matemática anterior. Existe un vector de multiplicadores de Lagrange, $\boldsymbol{\lambda}^*$, con coeficientes $\lambda_i, i \in \mathcal{E} \cup \mathcal{I}$, tal que se cumple que

$$\begin{aligned} \nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*) &= \nabla f(\mathbf{x}^*) - \boldsymbol{\lambda}^{*T} \mathbf{c}(\mathbf{x}^*) = \mathbf{0}, \\ \mathbf{c}_i(\mathbf{x}^*) &= \mathbf{0}, \text{ para todo } i \in \mathcal{E}, \\ \mathbf{c}_i(\mathbf{x}^*) &\geq \mathbf{0}, \text{ para todo } i \in \mathcal{I}, \\ \lambda_i^* &\geq 0, \text{ para todo } i \in \mathcal{I}, \\ \lambda_i^* \mathbf{c}_i(\mathbf{x}^*) &= 0, \text{ para todo } i \in \mathcal{E} \cup \mathcal{I}. \end{aligned}$$

Teorema 7.6 *Equivalencia entre puntos extremos y soluciones básicas* Sean $\mathbf{A} \in \mathbb{R}^{m \times n}$ una matriz de rango m , $\mathbf{b} \in \mathbb{R}^m$ y el politopo convexo

$$P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{A} \mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}.$$

Un $\mathbf{x} \in P$ es un punto extremo de P si y sólo si los vectores columna de $\mathbf{A}$ asociados a los coeficientes positivos de $\mathbf{x}$ son linealmente independientes.

DEMOSTRACIÓN. Supongamos sin pérdida de generalidad que los p primeros coeficientes del vector $\mathbf{x}$ son positivos y los $n - p$ últimos cero. Si $\mathbf{x} = [\bar{\mathbf{x}}^T, \mathbf{0}^T]^T$, $\bar{\mathbf{x}} > \mathbf{0}$, y designamos por $\bar{\mathbf{A}}$ las p primeras columnas de la matriz $\mathbf{A}$, se tiene que $\mathbf{A} \mathbf{x} = \bar{\mathbf{A}} \bar{\mathbf{x}} = \mathbf{b}$.

Probemos primero la necesidad de la condición enunciada. Supongamos que las columnas de $\bar{\mathbf{A}}$ no son linealmente independientes. En este caso existirá un vector $\bar{\mathbf{w}} \neq \mathbf{0}$ tal que $\bar{\mathbf{A}} \bar{\mathbf{w}} = \mathbf{0}$. De aquí que $\bar{\mathbf{A}}(\bar{\mathbf{x}} \pm \varepsilon \bar{\mathbf{w}}) = \bar{\mathbf{A}} \bar{\mathbf{x}} = \mathbf{b}$ y, para un ε suficientemente pequeño, que $(\bar{\mathbf{x}} \pm \varepsilon \bar{\mathbf{w}}) \geq \mathbf{0}$. Los puntos $\mathbf{y}' = \begin{bmatrix} \bar{\mathbf{x}} + \varepsilon \bar{\mathbf{w}} \\ \mathbf{0} \end{bmatrix}$ y

$y'' = \begin{bmatrix} \bar{x} - \varepsilon \bar{w} \\ \mathbf{0} \end{bmatrix}$ están, por consiguiente, en P . Además, dado que $x = (y' + y'')/2$, x no puede ser un punto extremo de P . Como consecuencia de esto, si x es un punto extremo, las columnas de la matriz $\bar{A}$ son linealmente dependientes.

Probemos ahora la suficiencia. Supongamos que x no es un punto extremo de P . Esto quiere decir que $x = \lambda y' + (1 - \lambda)y''$, donde $y', y'' \in P$, $y' \neq y''$ y $0 < \lambda < 1$. Como x y y' están en P , $A(x - y') = Ax - Ay' = b - b = \mathbf{0}$. Además, dado que λ y $1 - \lambda$ son estrictamente positivos, los últimos $n - p$ coeficientes de y' y, por consiguiente, de $x - y'$, han de ser cero pues lo son los de x . Las columnas de la matriz $\bar{A}$, en consecuencia, son linealmente dependientes. De aquí que, si las columnas de $\bar{A}$ son linealmente independientes, x es un punto extremo. ■

Una *dirección* del politopo $P = \{x \in \mathbb{R}^n : Ax = b, x \geq \mathbf{0}\}$ es un vector no nulo, $d \in \mathbb{R}^n$, tal que para todo $x_0 \in P$ el rayo $\{x \in \mathbb{R}^n : x = x_0 + \lambda d, \lambda \geq 0\}$ pertenece a P .

Una *dirección* d de un politopo P se dice *extrema* si no puede ponerse como combinación lineal no negativa de dos direcciones diferentes de P . Es decir, no existen dos direcciones d_1 y d_2 en P , $d_1 \neq d_2$, y unos $\alpha_1, \alpha_2 > 0$, tales que $d = \alpha_1 d_1 + \alpha_2 d_2$.

Cualquier dirección de un politopo se puede expresar como combinación lineal no negativa de las direcciones extremas del politopo. Si P es un poliedro, obviamente, no tiene direcciones.

Teorema 7.7 *Teorema de la representación* Todo punto del politopo $P = \{x \in \mathbb{R}^n : Ax = b, x \geq \mathbf{0}\}$ se puede expresar de la forma

$$x = \sum_{i \in I} \lambda_i v_i + d,$$

donde $\{v_i : i \in I\}$ es el conjunto de puntos extremos o vértices de P , $\sum_{i \in I} \lambda_i = 1$, $\lambda_i \geq 0$, y d , o es una dirección de P , o $d = \mathbf{0}$.

DEMOSTRACIÓN. La haremos por inducción en p , número de coeficientes positivos de x . Si $p = 0$, el teorema es obvio, pues $x = \mathbf{0}$ es un punto extremo. Supongamos que se cumple lo enunciado para puntos con menos de p coeficientes positivos y que x tiene p coeficientes positivos.

Si x es un punto extremo, como $x = v_i$ para algún $i \in I$, el teorema es obvio. Supongamos por tanto que x no es un punto extremo. En este caso existe un vector $w \neq \mathbf{0}$, con $w_i = 0$ si $x_i = 0$, tal que $Aw = \mathbf{0}$. Se pueden dar los tres casos siguientes:

- (a) *Que w tenga coeficientes positivos y negativos.* Consideremos los puntos $x(\theta) = x + \theta w$ en la recta que pasa por x que determina w , y sean θ' y θ''

el menor valor positivo y mayor valor negativo, respectivamente, de θ para los que $\mathbf{x}(\theta)$ tiene al menos un coeficiente cero más que los que tiene $\mathbf{x}$. Los puntos $\mathbf{x}' = \mathbf{x}(\theta')$ y $\mathbf{x}'' = \mathbf{x}(\theta'')$ pertenecen claramente a P por lo que, por la hipótesis de inducción, al tener un coeficiente nulo más, se pueden expresar según lo enunciado en el teorema. En consecuencia, como $\mathbf{x}$ está en la recta que une $\mathbf{x}'$ y $\mathbf{x}''$, se puede expresar de la siguiente manera

$$\begin{aligned}\mathbf{x} &= \mu \mathbf{x}' + (1 - \mu) \mathbf{x}'' && \text{donde } \mu = -\theta'' / (\theta' - \theta'') \\ &= \mu \left(\sum_{i \in I} \lambda'_i \mathbf{v}_i + \mathbf{d}' \right) + (1 - \mu) \left(\sum_{i \in I} \lambda''_i \mathbf{v}_i + \mathbf{d}'' \right) \\ &= \sum_{i \in I} \left(\mu \lambda'_i + (1 - \mu) \lambda''_i \right) \mathbf{v}_i + \mu \mathbf{d}' + (1 - \mu) \mathbf{d}''.\end{aligned}$$

Como $0 < \mu < 1$, $\lambda'_i \geq 0$ y $\lambda''_i \geq 0$ para todo $i \in I$, $\sum_{i \in I} \lambda'_i = \sum_{i \in I} \lambda''_i = 1$ y $A\mathbf{d}' = A\mathbf{d}'' = \mathbf{0}$, $\mathbf{d}' \geq \mathbf{0}$ y $\mathbf{d}'' \geq \mathbf{0}$. Se deduce entonces que

$$\lambda_i = \mu \lambda'_i + (1 - \mu) \lambda''_i \geq 0 \quad \text{para todo } i \in I, \quad \sum_{i \in I} \lambda_i = 1,$$

$$\mathbf{d} = \mu \mathbf{d}' + (1 - \mu) \mathbf{d}'' \geq \mathbf{0} \quad \text{y} \quad A\mathbf{d} = \mathbf{0},$$

quedando probado que $\mathbf{x}$ se puede expresar de la forma enunciada.

- (b) *Que $\mathbf{w} \leq \mathbf{0}$.* Definamos $\mathbf{x}'$ como en el caso (a). El punto $\mathbf{x}$ se puede expresar como $\mathbf{x} = \mathbf{x}' + \theta'(-\mathbf{w})$, con $\theta' > 0$. Como $\mathbf{x}'$ se puede expresar por inducción en la forma deseada y $(-\mathbf{w})$ es una dirección en P , $\mathbf{x}$ también se puede expresar de la forma enunciada.
- (c) *Que $\mathbf{w} \geq \mathbf{0}$.* Este caso se prueba igual que el caso (b) sin más que sustituir $\mathbf{x}'$, θ' y $-\mathbf{w}$ por $\mathbf{x}''$, $-\theta''$ y $\mathbf{w}$, respectivamente. ■

Corolario 7.8 Si el politopo $P = \{\mathbf{x} \in \mathbb{R}^n : A\mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ es no vacío, tiene al menos un punto extremo o vértice.

Corolario 7.9 Si el politopo $P = \{\mathbf{x} \in \mathbb{R}^n : A\mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ es cerrado y acotado (es un poliedro), todo punto $\mathbf{x} \in P$ se puede expresar como combinación convexa de sus puntos extremos.

Teorema 7.10 Teorema fundamental de la Programación Lineal Dado un politopo no vacío $P = \{\mathbf{x} \in \mathbb{R}^n : A\mathbf{x} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ de soluciones de un PL, el valor mínimo de la función objetivo $\mathbf{c}^T \mathbf{x}$, para $\mathbf{x} \in P$, se alcanza en un punto extremo de P (solución básica factible óptima), o $\mathbf{c}^T \mathbf{x}$ no está acotada inferiormente en P .




Figura 7.32: Representación de un punto de un politopo (poliedro) como combinación convexa de puntos extremos

DEMOSTRACIÓN. Sea $V = \{v_i : i \in I\}$ el conjunto de puntos extremos de P . Como P es no vacío, al menos tiene un punto extremo $v_i \in V$. De acuerdo con el teorema de la representación, o el politopo P posee una dirección d tal que $c^T d < 0$, o tal dirección no existe. Consideremos estos dos casos.

- (a) El politopo P tiene una dirección d tal que $c^T d < 0$. En este caso P no está acotado y el valor de la función objetivo tiende a $-\infty$ en la dirección d .
- (b) El politopo P no tiene una dirección d tal que $c^T d < 0$. En este caso cualquier $x \in P$ se puede expresar de una de las dos maneras siguientes:

$$x = \sum_{i \in I} \lambda_i v_i \quad \text{donde} \quad \sum_{i \in I} \lambda_i = 1, \quad \lambda_i \geq 0 \quad \text{o}$$

$$x = \sum_{i \in I} \lambda_i v_i + \bar{d} \quad \text{donde} \quad \sum_{i \in I} \lambda_i = 1, \quad \lambda_i \geq 0 \quad \text{y} \quad c^T \bar{d} \geq 0.$$

En ambos casos, suponiendo que $c^T v_{min}$ es el menor de los elementos del conjunto $\{c^T v_i : i \in I\}$, se tiene que

$$c^T x \geq \sum_{i \in I} \lambda_i (c^T v_i) \geq c^T v_{min} \left(\sum_{i \in I} \lambda_i \right) = c^T v_{min}.$$

Es decir, el mínimo de $c^T x$ se alcanza en un punto extremo de P : v_{min} . ■

7.3 Dualidad

La Dualidad juega un papel destacado en Programación Lineal y no lineal. Sirve para caracterizar y verificar la optimalidad de un proceso iterativo y las con-

diciones en que se da el óptimo, para analizar la sensibilidad de una solución a la variación de los parámetros del problema, para estudiar la velocidad de convergencia de determinados algoritmos de optimización que usan su formulación y contemplar diversos aspectos geométricos que permiten interpretar mejor lo que se está haciendo en la búsqueda de una solución.

Las ideas y formulación que exponemos a continuación siguen enteramente lo que expone al respecto el libro de Luenberger citado en el apartado de bibliografía. Se basa en una forma elegante y global de contemplar la dualidad en términos de conjuntos e hiperplanos que tocan esos conjuntos. Evidencia el papel de los multiplicadores de Lagrange como definidores de hiperplanos que pueden ser considerados los duales de puntos en un espacio vectorial. Esta forma teórica de enfrentarse a la dualidad proporciona una simetría entre los problemas primal y dual, la cual puede considerarse perfecta si los problemas son convexos. Si no lo son, la *imperfección* la plasma el denominado *gap de dualidad* o *brecha dual*, que tiene una interpretación geométrica muy sencilla en este contexto y mucha importancia en los algoritmos de programación lineal y no lineal.

En el problema dual las incógnitas por resolver son los *multiplicadores de Lagrange* del problema primal, que miden las sensibilidades del primal a variaciones en los coeficientes que determinan las condiciones de este problema y determinan como unas penalizaciones que se introducen en su función objetivo por no utilizar adecuadamente los recursos que fijan esas condiciones. La función de Lagrange incorpora así toda la información disponible del problema.

La teoría global que se expone en este apéndice es la base general sobre la que construir dualidades de tipo local de los diversos problemas lineales y no lineales, incluso sin la existencia de convexidad, o en algoritmos especializados para problemas de Programación Lineal como los de punto interior, dual del *Símplex*, etc.

De momento vamos a referirnos a problemas de programación matemática como

$$\begin{aligned} & \underset{x \in \mathbb{R}^n}{\text{minimizar}} && f(x) \\ & \text{sujeta a} && \mathbf{g}(x) \leq \mathbf{0} \\ & && x \in \Omega, \end{aligned} \tag{1}$$

donde $\Omega \in \mathbb{R}^n$ es un conjunto convexo y las funciones, la escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y la vectorial $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^p$, están definidas en Ω . Este problema no es necesariamente convexo pero se asume que tiene al menos un punto factible. Esta notación es perfectamente compatible con otras que se utilizan sin más que adoptar la convención de signos adecuada.

La *función primal* asociada a (1) se define, para un $z \in \mathbb{R}^p$, como

$$\omega(z) = \inf \{f(x) : g(x) \leq z, x \in \Omega\}. \quad (2)$$

Se llega a ella dejando que el término de la derecha de la inecuación que definen las condiciones pueda tomar valores arbitrarios. Se entiende que (2) está definida en el conjunto $D = \{z : g(x) \leq z, \text{ para algunos } x \in \Omega\}$.

Si el problema (1) tiene una solución x^* con un valor de la función objetivo igual a $f^* = f(x^*)$, entonces f^* es el punto de eje vertical de $\mathbb{R}^{p+1}$ donde la función primal se cruza con ese eje. Si (1) no tiene solución ese punto de cruce es $f^* = \inf \{f(x) : g(x) \leq 0, x \in \Omega\}$.

El principio de dualidad se deduce de la consideración de todos los hiperplanos que quedan por debajo de la función primal. Como ilustra la figura 7.33, todos los hiperplanos que se indican se cruzan con el eje vertical por debajo de f^* , o en f^* .




Figura 7.33: Hiperplano por debajo de $\omega(z)$.

Para expresar esta propiedad se define la *función dual* en el cono positivo de $\mathbb{R}^p$ como

$$\phi(\mu) = \inf \{f(x) + \mu^T g(x) : x \in \Omega\}. \quad (3)$$

En general, ϕ puede que no sea finita dentro del ortante positivo, $\mathbb{R}_+^p$, pero la región donde está definida es convexa.

Proposición 7.11 *La función dual es cóncava en la región donde es finita.*

DEMOSTRACIÓN. Supóngase que μ_1 y μ_2 están en la región finita y sea $0 \leq \alpha \leq 1$. Entonces

$$\begin{aligned}\phi(\alpha\mu_1 + (1-\alpha)\mu_2) &= \inf \{f(x) + (\alpha\mu_1 + (1-\alpha)\mu_2)^T g(x) : x \in \Omega\} \\ &\geq \inf \{\alpha f(x_1) + \alpha\mu_1^T g(\mu_1) : x_1 \in \Omega\} \\ &\quad + \inf \{(1-\alpha)f(x_2) + (1-\alpha)\mu_2^T g(x_2) : x_2 \in \Omega\} \\ &= \alpha\phi(\mu_1) + (1-\alpha)\phi(\mu_2).\end{aligned}$$

Se define $\phi^* = \sup \{\phi(\mu) : \mu \geq \mathbf{0}\}$, suponiéndose que el supremo se extiende a toda la región donde ϕ es finita.

Proposición 7.12 Forma débil de dualidad. $\phi^* \leq f^*$.

DEMOSTRACIÓN. Para todo $\mu \geq \mathbf{0}$ se tiene que

$$\begin{aligned}\phi(\mu) &= \inf \{f(x) + \mu^T g(x) : x \in \Omega\} \\ &\leq \inf \{f(x) + \mu^T g(x) : g(x) \leq \mathbf{0}, x \in \Omega\} \\ &\leq \inf \{f(x) : g(x) \leq \mathbf{0}, x \in \Omega\} = f^*.\end{aligned}$$

Adoptando e supremos de $\phi(x)$ se tiene que $\phi^* \leq f^*$.

De acuerdo con este resultado la función dual proporciona cotas inferiores del valor óptimo de f .

La función dual tiene una interpretación geométrica interesante. Si se considera el vector $[1 \ \mu^T]^T \in \mathbb{R}^{p+1}$, con $\mu \geq \mathbf{0}$ y la constante c , el conjunto de vectores $[r \ z^T]^T \in \mathbb{R}^{p+1}$ tales que el producto interior $[1 \ \mu^T][r \ z^T]^T \equiv r + \mu^T z = c$ define un hiperplano en $\mathbb{R}^{p+1}$. Para diferentes valores de c se tiene diferentes hiperplanos, todos paralelos entre si.

Para un vector dado $[1 \ \mu^T]^T$ consideremos el hiperplano más bajo posible de esa forma que casi toca —soporta— la región de encima de la función primal del problema (1). Supongamos que x_1 define ese punto de contacto y que $r = f(x_1)$ y $z = g(x_1)$. Se tendrá que $c = f(x_1) + \mu^T b(x_1) = \phi(\mu)$.

Ese hiperplano se cruzará con el eje vertical en un punto de la forma $[r_0 \ \mathbf{0}]^T$. Este punto también satisfará que $[1 \ \mu^T]^T [r_0 \ \mathbf{0}]^T = c = \phi(\mu)$. Lo que lleva a que $c = r_0$. Por lo que ese punto dará $\phi(\mu)$ directamente. La función dual en μ es igual al punto donde se cruzan el hiperplano definido por μ que justo toca el epigrafo —el conjunto de puntos situados por encima del gráfico de una función— de la función primal.

Además, como indica la figura 7.34, ese punto de cruce (y el valor de la función dual) se maximiza con el multiplicador de Lagrange que corresponde al plano más




Figura 7.34: Hiperplano más alto.

alto posible que intercepta el eje vertical, siendo el punto de esa intercepción menor o igual que el valor óptimo f^* . La diferencia constituye el *gap de dualidad*.

Si se incorporan suposiciones de convexidad el análisis que estamos haciendo se completa con el teorema de la dualidad fuerte cuando no hay gap de dualidad y la intersección de esos planos con el eje vertical es el propio f^* . Se puede ver en la figura 7.35.

El teorema de la dualidad fuerte lo referimos al problema general

$$\begin{aligned} & \underset{x \in \mathbb{R}^n}{\text{minimizar}} && f(x) \\ & \text{sujeta a} && \mathbf{h}(x) = \mathbf{0} \\ & && \mathbf{g}(x) \leq \mathbf{0} \\ & && x \in \Omega, \end{aligned} \tag{4}$$

donde $\mathbf{h} : \mathbb{R}^m \rightarrow \mathbb{R}^n$ es afín, $\mathbf{g} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ es convexa y Ω es convexo. La función dual de este problema es

$$\phi(\lambda, \mu) = \inf \{ f(x) + \lambda^T \mathbf{h}(x) + \mu^T \mathbf{g}(x) : x \in \Omega \}, \tag{5}$$

y $\phi^* = \sup \{ \phi(\lambda, \mu) : \lambda \in \mathbb{R}^m, \mu \in \mathbb{R}^p, \mu \geq \mathbf{0} \}$.

Un punto x que satisfaga todas las condiciones que se cumplen se dice *regular* si los vectores gradiente del conjunto de condiciones activas en ese punto son linealmente independientes. Una función $\mathbf{h}(x)$ es *regular* con respecto a Ω si el conjunto $C = \{ y : \mathbf{h}(x) = y \text{ para algún } x \in \Omega \}$ de $\mathbb{R}^n$ contiene una bola abierta en torno a $\mathbf{0}$; es decir, C contiene un conjunto de la forma $\{ y : |y| < \varepsilon \}$ para algún $\varepsilon > 0$. Esto viene a decir que $\mathbf{h}(x)$ puede hacerse $\mathbf{0}$ y variar arbitrariamente en




Figura 7.35: Expresión gráfica del teorema de la dualidad fuerte. No hay gap de dualidad.

torno a $\mathbf{0}$ en cualquier dirección. Esta condición es similar a la definición de punto regular en el contexto de las condiciones de óptimo de primer orden.

Teorema 7.13 *Teorema de la dualidad fuerte* Supongamos que en el problema (4) $\mathbf{h}$ es regular con respecto a Ω y que existe un punto $\mathbf{x} \in \Omega$ en el que $\mathbf{h}(\mathbf{x}) = \mathbf{0}$ y $\mathbf{g}(\mathbf{x}) \leq \mathbf{0}$.

Supongamos que el problema tiene como solución $\mathbf{x}^*$ con un valor de la función objetivo $f(\mathbf{x}^*) = f^*$. Entonces, para todo $\boldsymbol{\lambda}$ y todo $\boldsymbol{\mu} \geq \mathbf{0}$ se cumple que

$$\phi^* \leq f^*.$$

Además, existen unos $\boldsymbol{\lambda}$ y $\boldsymbol{\mu} \geq \mathbf{0}$ tales que $\phi(\boldsymbol{\lambda}, \boldsymbol{\mu}) = f^*$ y por lo tanto $\phi^* = f^*$. Los vectores $\boldsymbol{\lambda}$ y $\boldsymbol{\mu}$ son los multiplicadores de Lagrange del problema.

7.3.1 Dualidad Lagrangiana

Es una forma de denominar lo que acabamos de exponer. La *función de Lagrange* del problema (4) escrito

$$\begin{aligned} &\underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimizar}} && f(\mathbf{x}) \\ &\text{sujeta a} && \mathbf{h}(\mathbf{x}) = \mathbf{0} \\ &&& \mathbf{g}(\mathbf{x}) \geq \mathbf{0} \\ &&& \mathbf{x} \in \Omega, \end{aligned} \tag{6}$$

es $L(x, \lambda, \mu) = f(x) - \lambda^T h(x) - \mu^T g(x)$. La función de Lagrange dual es

$$q(\lambda, \mu) \stackrel{\text{def}}{=} \inf_x L(x, \lambda, \mu).$$

Si las funciones $h(x)$ y $g(x)$ son convexas, con $\mu \geq 0$, la función de Lagrange es convexa y define una cota inferior del valor óptimo de la función objetivo de (6). El problema dual de éste es

$$\begin{aligned} &\text{maximizar } q(\lambda, \mu) \\ &\text{sujeta a } \mu \geq 0, \end{aligned}$$

que es siempre convexo.

7.3.2 Dualidad de Wolfe

Es ligeramente distinta de las anteriores. Es la que sirve de referencia a los métodos de punto interior. El problema dual es

$$\begin{aligned} &\text{max. } L(x, \lambda, \mu) \\ &\text{s. a } \nabla_x L(x, \lambda, \mu) = 0 \\ &\quad \mu \geq 0. \end{aligned}$$

7.3.3 Ejemplo

En el caso de un problema de Programación Lineal en forma estándar

$$\begin{aligned} &\text{minimizar } c^T x \\ &\quad x \in \mathbb{R}^n \\ &\text{sujeta a } Ax = b \\ &\quad x \geq 0, \end{aligned}$$

la función de Lagrange es $L(x, \lambda, \mu) = c^T x - \lambda^T (Ax - b) - \mu^T x$, o

$$L(x, \lambda, \mu) = \lambda^T b + (c - A^T \lambda - \mu)^T x.$$

Su problema dual

$$\begin{aligned} \text{max. } q(\lambda, \mu) &= \inf \{L(x, \lambda, \mu)\} = \lambda^T b + \inf_x \{(c - A^T \lambda - \mu)^T x\} \\ &= \begin{cases} \lambda^T b & \text{si } c - A^T \lambda - \mu = 0 \\ -\infty & \text{si } c - A^T \lambda - \mu \neq 0 \end{cases} \\ \text{s. a } \mu &\geq 0. \end{aligned}$$

Si $c - A^T \lambda - \mu \neq 0$ el ínfimo es claramente $-\infty$, por lo que hay que excluir del problema aquellos λ para los que se den esos casos. De acuerdo con ello, el problema dual queda

$$\begin{aligned} &\text{maximizar } \lambda^T b \\ &\text{s. a } \quad c - A^T \lambda - \mu = 0, \quad \mu \geq 0. \end{aligned}$$

El dual de Wolfe sería exactamente el mismo. El *gap de dualidad* es

$$c^T x - \lambda^T b = c^T x - \lambda^T A x = x^T (c - A^T \lambda) = x^T \mu.$$

8 Sobre el método de los elementos finitos para resolver ecuaciones en derivadas parciales

DESDE tiempos de C.F. Gauss, Alemania 1777-1855 y W. Thompson Irlanda, 1775-1833, la equivalencia entre los problemas de ecuaciones en derivadas parciales con condiciones de contorno y los de cálculo de variaciones ha ocupado un puesto destacado en el análisis matemático. En un principio el esfuerzo se concentró en los aspectos teóricos de los problemas; posteriormente, dos físicos, Lord Rayleigh —John William Strutt, Reino Unido 1842-1919— y Walther Ritz, Suiza 1878-1909, independientemente al parecer, concibieron la idea de utilizar esa equivalencia para calcular numéricamente soluciones de problemas habituales de física mediante la sustitución de los problemas de cálculo de variaciones por otros más simples de obtención de extremos con un número finito de parámetros por determinar.

Sus métodos atrajeron pronto a ingenieros y físicos —los principios físicos de la mecánica son más sugestivos que las ecuaciones diferenciales— y se empezaron a aplicar a muchos problemas cercanos. El resultado era lógica consecuencia del esquema conceptual de cómo se tratan en análisis matemático —y en muchos aspectos de la vida cotidiana— los problemas difíciles: Un problema P con solución S se reemplaza por otro más o menos relacionado o próximo, P_n , más simple de resolver, cuya solución es S_n . Luego se mejora la aproximación P_n de P de tal forma que la solución S_n , paso a paso, tienda a la deseada S . Lo esencial es escoger la sucesión de aproximaciones P_n de una manera adecuada.

Una de las cuestiones más interesantes y con más posibilidades de futuro que contemplan las aplicaciones de las matemáticas para simular y resolver muchos problemas de la vida cotidiana es el de utilizar modelos matemáticos expresados en forma de ecuaciones diferenciales e integrales que reproducen procesos y fenómenos complejos de la física y otras ciencias naturales y sociales cuyos orígenes

y evolución suelen estar distribuidos en el tiempo y en el espacio. Se modelan de esta forma la propagación del sonido o del calor, la electrostática, la electrodinámica, la dinámica de fluidos, la elasticidad, la mecánica cuántica, las emisiones de contaminantes, los fenómenos meteorológicos, la valoración de opciones y derivados financieros y muchos otros. El enfoque para resolverlos de forma práctica sigue exactamente el principio enunciado más arriba.

La idea esencial que seguiremos en estas notas es la de convertir el problema con ecuaciones diferenciales, integrales o ecuaciones en derivadas parciales, suponiendo que tiene solución con unas determinadas características, en uno formulado en términos de cálculo de variaciones de funciones continuas —la minimización de un funcional— para así caracterizar en qué condiciones se da una solución u óptimo del mismo. Luego se discretiza ese problema continuo con un número infinito de grados de libertad mediante un problema discreto, o sistema de ecuaciones, con un número de variables finito y más fácil de resolver y se resuelve mediante alguna de las diversas técnicas que existen para ello.

Cuando se empieza a trabajar y aprender métodos numéricos para resolver problemas matemáticos el de las diferencias finitas sigue ideas muy intuitivas: simplemente se aproxima una derivada de una curva en un punto de ella por una línea secante. Si se estudia el método del volumen finito, también su idea es bastante sencilla: cada elemento de volumen es simplemente un pequeño equilibrio del flujo o de fuerzas. El método de los elementos finitos sigue esa senda más o menos, con alguna pequeña modificación.

La base matemática para el método de los elementos finitos se encuentra en el entorno de los espacios de Hilbert. Un espacio de Hilbert es una manera de tratar una función como un vector, por lo que podemos hacer algunos trucos de matemáticas vectoriales con él. Recordemos que un vector es una serie de valores, o escalares, multiplicados por un conjunto de vectores de una base ortogonal (como los vectores unitarios que definen la direcciones x , y y z , o los $\mathbf{i}$, $\mathbf{j}$ y $\mathbf{k}$). Podemos utilizar una técnica paralela para definir una función. Primeramente seleccionamos un conjunto de funciones de base en vez de aquellos vectores (esas funciones deben ser ortogonales entre sí) y luego definimos la función original como una suma de unos coeficientes multiplicados por las funciones de la base: de esta forma

$$u = \sum_{k=1}^{\infty} \alpha_k \phi_k,$$

donde cada una de las ϕ_k es una función de la base.

El siguiente paso es convertir nuestra ecuación diferencial en algo llamado *su formulación débil*. Esto se hace básicamente multiplicando por una *función de prueba* y luego integrando en el espacio. Sin entrar en los detalles de momento, se trata de hacer lo mínimo necesario para convertir nuestra ecuación diferencial en algo en lo que podamos utilizar nuestras matemáticas de espacios vectoriales. Esencialmente, donde exista una forma de "producto interior", en nuestro caso con funciones como la de prueba en vez de vectores, y la solución. Este producto interior será una integral y podremos usar integración por partes para convertirlo en formatos más manejables.

Después nos desharemos de alguna manera de la abstracción empleada y comprobaremos que realmente estamos tratando con un espacio vectorial de dimensión finita: los vectores función no son infinitos ni estamos sumando infinitos términos. Este proceso es lo que se entiende por *discretización* en las técnicas de los elementos finitos. La discretización que se utiliza está determinada por una malla o retícula¹³ —*mesh* como la de la figura 8.36— y normalmente se emplean dos funciones de base a cada lado de un elemento de la malla.




Figura 8.36: Discretización de una pieza sencilla.

Con esas funciones de base la solución de nuestra ecuación diferencial se representaría de esta manera

$$u' = \sum_{k=1}^n \alpha_k \phi_k.$$

La única diferencia con la expresión anterior es el límite superior del sumatorio.

El siguiente paso es hacer que nuestra función de prueba sea una función de base. También habrá que asegurarse que las funciones base no se superpongan, lo cual garantiza el que sean ortogonales como pretendíamos antes y nos permite aproximar más fácilmente la solución en el dominio de interés. Las funciones de base que se suelen usar son polinomios (especialmente polinomios lineales o cuadráticos).

Después de lo que puede parecer que es complicar el problema original agregando toda esta abstracción y matemáticas para llegar a lo que hemos llegado, ¿qué hemos conseguido realmente? Pues convertir el problema en una ecuación algebraica matricial sencilla para poderlo resolver por medio del álgebra que conoce-

¹³Una retícula de por ejemplo 20×20 daría como resultado 441 funciones base únicas.

mos. Si el problema fuese lineal, simplemente tendríamos que resolver la ecuación $A\mathbf{x} = \mathbf{b}$.

Para un problema simple como el de la *ecuación de Poisson* —Siméon Denis Poisson, Francia, 1781-1840—

$$\Delta u(x, y) = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = f(x, y)$$

la matriz A es muy fácil de calcular y se denomina la *matriz de rigidez* en homenaje a los principios de las técnicas de elementos finitos en problemas de elasticidad. Esta matriz —muy dispersa (con pocos coeficientes distintos de cero) y diagonal dominante— está formada por el producto interior de las funciones de base con ellas mismas, multiplicadas si es el caso por la constante que aparezca en la ecuación original. El vector solución de ese sistema se multiplica por el de las funciones de base y se obtiene la del problema original, o una que se aproxima mucho a la misma.

Resumiendo, el procedimiento de resolución del método de los elementos finitos consta de las siguientes fases u operaciones:

- Conversión del problema original de dimensión infinita, mediante las propiedades de los espacios de Hilbert, en uno similar próximo en un espacio vectorial de dimensión finita de cara a estudiar la existencia y unicidad de la solución.
- Creación de una *formulación débil* del problema original con la que podamos usar las herramientas de producto interior y medida.
- Discretización del dominio de definición del problema y elección de una base de funciones que sean ortogonales entre sí.
- Conversión de los productos interiores entre funciones de base en sistemas lineales de ecuaciones.
- Resolución de ese sistema lineal resultante mediante técnicas de matrices dispersas.

Las ventajas de este método frente a otros son muchas en bastantes ámbitos de la ingeniería, la ciencia y la investigación por lo que su extensión y precisión, así como los algoritmos que emplea, cada vez son más amplios, ambiciosos y potentes.

Para concretar con cierto detalle los pasos del método, vamos a desarrollar el estudio de un problema preciso habitual. Seguiremos esencialmente el trabajo de Francisco Javier Sayas, [2015], de la Universidad de Delaware, EE.UU.

8.1 Solución de una ecuación en derivadas parciales

Consideraremos en lo que sigue el siguiente problema de una ecuación en derivadas parciales elíptica de segundo orden con condiciones de contorno:

$$\begin{cases} -\Delta u(x, y) + cu(x, y) = f(x, y) & \text{dentro de } \Omega \\ u(x, y) = g_0(x, y) & \text{en la frontera } \Gamma_D \\ \partial_n u(x, y) = g_1(x, y) & \text{en la frontera } \Gamma_N. \end{cases}$$

Esta forma de formularlo se denomina *forma fuerte*.

- La geometría del entorno físico esquemático en el que se desenvolverá será tan simple como la de la figura 8.37, o una generalización de ella. En este




Figura 8.37: Dominio de definición Ω y condiciones de contorno.

caso concreto es un subconjunto abierto $\Omega \in \mathbb{R}^d$ representado por un polígono en el plano $\mathbb{R}^2$, “pegado” o adherido en su frontera a la curva que define Γ , dividida ésta en dos partes: la que define Γ_D , que materializan unas *condiciones de contorno de Dirichlet* —por Johann Peter Gustav Lejeune Dirichlet, Alemania 1805-1859— y la Γ_N , con *condiciones de contorno de Neumann* —por Karl Gottfried Neumann, Alemania 1832-1925—. En términos físicos, las condiciones de Dirichlet determinan unos posibles desplazamientos físicos de esa frontera, mientras que las de Neumann unas posibles tensiones máximas o mínimas.

- La ecuación en derivadas parciales propiamente dicha, la primera en la formulación, se denomina habitualmente *ecuación difusión-reacción*. El término que representa la difusión es $-\Delta u$ y el de reacción cu , cuando $c > 0$. La constante c es no negativa; en principio puede adoptar los valores 0 ó 1.
- La función escalar $u(x, y) : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida en el dominio Ω , es la incógnita de este problema.

- La función $f(x, y)$ está definida en Ω y se puede considerar como una densidad superficial de fuerzas.
- Las dos funciones que expresan las condiciones de contorno, $g_0(x, y)$ y $g_1(x, y)$, están definidas en dos partes diferentes de la frontera. La función g_0 deberá ser continua; la g_1 puede ser discontinua.
- El símbolo ∂_n designa la derivada normal hacia afuera, es decir

$$\partial_n u = \nabla u \cdot \mathbf{n},$$

donde $\mathbf{n}$ es el vector unidad hacia afuera en puntos de la frontera Γ y ∇u es el gradiente de u . Supondremos que existe.

8.1.1 El problema en forma débil o variacional

Siguiendo cada uno de los pasos de la estrategia enunciada para resolver este problema, vamos a formularlo de una forma diferente de la original denominada *forma débil* o *forma variacional*.

Para ello utilizaremos el teorema de Green —por George Green, Reino Unido 1793-1841—, a menudo denominado *primera fórmula o identidad de Green*, derivada del *teorema de la divergencia*, que no es sino una forma de integración por partes. Aplicado a nuestro caso dice que

$$\int_{\Omega} (\Delta u) v + \int_{\Omega} \nabla u \cdot \nabla v = \int_{\Gamma} (\partial_n u) v.$$

La función v es una *función de prueba*, continua, en principio definida en $\overline{\Omega} = \Omega \cup \Gamma$. En esa expresión hay dos tipos de integrales: las dos del miembro de la izquierda son integrales de superficie, en el dominio Ω . La del derecho es una integral lineal en el borde o frontera Γ . Hemos prescindido de los diferenciales correspondientes para compactar la notación. El resultado sería aplicable también a tres dimensiones: las dos integrales de la izquierda serían de volumen; la de la derecha de superficie. El punto de la segunda integral del miembro de la izquierda se refiere al producto interior de dos vectores, es decir $\nabla u \cdot \nabla v = \frac{\partial u}{\partial x} \frac{\partial v}{\partial x} + \frac{\partial u}{\partial y} \frac{\partial v}{\partial y}$.

La identidad expresada es una consecuencia del resultado del *teorema de la divergencia* que dice que para un subconjunto $V \in \mathbb{R}^n$ —en el caso de tres dimensiones V representa un volumen como el de la figura 8.38—, en principio compacto, de superficie o borde S continua a trozos (expresada por $\partial V = S$), si $\mathbf{F}$ es un campo vectorial con derivadas parciales de primer orden continuas definido en un entorno de V , se cumple que

$$\iiint_V (\nabla \cdot \mathbf{F}) dV = \oint_S (\mathbf{F} \cdot \mathbf{n}) dS.$$




Figura 8.38: Región o volumen V acotada por la superficie o frontera $S = \partial V$ con la normal a la superficie $\mathbf{n}$.

Aplicado a una función escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y un vector constante $\mathbf{c}$ distinto de cero

$$\iiint_V \mathbf{c} \cdot \nabla f \, dV + \iiint_V f(\nabla \cdot \mathbf{c}) \, dV = \oint_S (\mathbf{c} f) \cdot d\mathbf{S},$$

donde $d\mathbf{S}$ expresa de forma compacta $\mathbf{n} dS$.

Haciendo $f = \nabla u$ y $\mathbf{c} = \mathbf{v}$ se tiene la expresión anterior de la primera identidad de Green.

Si sustituimos $\Delta u = f - cu$ en la expresión obtenida a partir de la identidad de Green en donde se integra en Ω y que $\partial_n u = g_1$ en Γ_N , después de reordenar un poco se llega a

$$\int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v + \int_{\Gamma_D} (\partial_n u) v.$$

Como no sabemos el valor de $\partial_n u$ en Γ_D imponemos que la función v sea cero en esa parte de la frontera o borde: $v = 0$ en Γ_D . A partir de ahí,

$$\int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \quad \text{si } v = 0 \text{ en } \Gamma_D.$$

La expresión del miembro de la izquierda es lineal en las funciones u y v . Es una forma bilineal de las variables u y v . La de la derecha es lineal en v . Todavía no hemos hecho uso de la condición de Dirichlet en la frontera, $u = g_0$ en Γ_D .

La *formulación débil* del problema queda: así: Determinar una función u tal que:

$$\left\{ \begin{array}{l} u = g_0 \text{ en } \Gamma_D \\ \int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \\ \text{para todo } v \text{ tal que } v = 0 \text{ en la frontera } \Gamma_D. \end{array} \right.$$

En esta formulación la condición de Dirichlet —desplazamientos dados— se impone como una condición aparte que ha de cumplir la función de prueba v . Se denomina *condición esencial de borde o frontera*. La condición de Neumann —fuerzas normales— aparece como una *condición de frontera natural* dentro de la formulación del problema.

Como indicábamos anteriormente, la función de prueba v chequea la ecuación que satisface u . Juega un papel de función de ponderación para comprobar el comportamiento medio de la ecuación. En alguna referencia interesante se la denomina *desplazamiento virtual* para enfatizar que no es una incognita sino algo utilizado para formular el problema de esta manera: mediante desplazamientos virtuales de la realidad, si se llega a conocer.

8.1.2 Espacios de trabajo

Hasta ahora hemos dado por hecho que el contexto matemático donde se desenvuelve este problema y las formulaciones que estamos utilizando cumplen una serie de requisitos matemáticos que permiten su existencia y solución. Vamos a formalizarlo un poco. El primer espacio que estamos utilizando¹⁴ es el espacio vectorial de las *funciones al cuadrado integrables* en Ω , es decir,

$$L^2(\Omega) = \left\{ f : \Omega \rightarrow \mathbb{R} \left| \int_{\Omega} |f|^2 < \infty \right. \right\}.$$

Su estricta definición requeriría la introducción de la *integral de Lebesgue*¹⁵, la métrica o medida de Lebesgue y el *espacio de Lebesgue* —por Henri Léon Lebesgue, Francia 1875-1941—. Simplificadamente, si $\int_{\Omega} f(x) dx$ es la integral de Lebesgue de $f(x)$ y se define la norma $\|f\|_{L^p(\Omega)} = (\int_{\Omega} f^p dx)^{1/p}$, para $1 \leq p < \infty$, los espacios de Lebesgue son

$$L^p(\Omega) = \{f(x) : \|f\|_{L^p(\Omega)} < \infty\}.$$

El segundo es el *espacio de Sobolev* —por Sergéi Lvóvich Sobolév, Rusia 1908-1989—. Es un espacio vectorial de funciones dotado de una norma que es combinación de normas L_p de la función y de sus derivadas hasta un orden dado. Formalmente para dos dimensiones es

$$H^1(\Omega) = \left\{ u \in L^2(\Omega) \left| \frac{\partial u}{\partial x_1}, \frac{\partial u}{\partial x_2} \in L^2(\Omega) \right. \right\}.$$

¹⁴Ya introducido antes en estos apuntes.

¹⁵Que generaliza la noción de la integral de Riemann extendiendo el concepto de área bajo una curva para incluir funciones discontinuas.



Las derivadas de este espacio se entienden en un *sentido débil*¹⁶ que hagan que el espacio sea completo¹⁷ y por lo tanto sea un espacio de Banach. La norma correspondiente de este espacio es

$$\|u\|_{1,\Omega} = \left(\int_{\Omega} |\nabla u|^2 + \int_{\Omega} |u|^2 \right)^{1/2} = \left(\int_{\Omega} \left| \frac{\partial u}{\partial x_1} \right|^2 + \int_{\Omega} \left| \frac{\partial u}{\partial x_2} \right|^2 + \int_{\Omega} |u|^2 \right)^{1/2},$$

denominada en ingeniería *norma de energía*. Las funciones que usan esta forma finita son funciones de energía finita. Intuitivamente, un espacio de Sobolev es un espacio de funciones con derivadas de orden suficiente para un dominio de aplicación determinado y equipado con una norma que mida adecuadamente tamaño y regularidad en las funciones. Un subespacio de interés de ese espacio $H^1(\Omega)$ es

$$H_{\Gamma_D}^1(\Omega) = \{v \in H^1(\Omega) \mid v = 0 \text{ en } \Gamma_D\}.$$

Establecido todo este aparato matemático, la formulación débil del problema original queda así:

$$\begin{cases} \text{Determinar una función } u \in H^1(\Omega) \text{ tal que} \\ u = g_0 \text{ en } \Gamma_D \\ \int_{\Omega} \nabla u \cdot \nabla v + c \int_{\Omega} uv = \int_{\Omega} f v + \int_{\Gamma_N} g_1 v, \text{ para todo } v \in H_{\Gamma_D}^1(\Omega). \end{cases}$$

La condición que se impone a la función de prueba, $v \in H_{\Gamma_D}^1(\Omega)$, es la misma que

$$v \in H^1(\Omega) \text{ tal que } v = 0 \text{ en } \Gamma_D,$$

lo que quiere decir que v está en el mismo espacio de la función que se busca u pero satisface una versión homogénea de la condición esencial de borde o frontera.

Los datos del problema están en los siguientes espacios $f \in L^2(\Omega)$, $g_1 \in L^2(\Gamma_N)$ y $g_0 \in H^{1/2}(\Gamma_D)$. El segundo espacio restringe el dominio de las integrales en la línea que marca Γ_N en vez de en Ω . Que $g_0 \in H^{1/2}(\Gamma_D)$ quiere decir que existe al menos una función $u_0 \in H^1(\Omega)$ tal que $u_0 = g_0$ en Γ_D . De hecho, todas las demás que cumplen esta condición pertenecen a $u_0 + H_{\Gamma_D}^1(\Omega) = \{u_0 + v \mid v \in H_{\Gamma_D}^1(\Omega)\} = \{w \in H^1(\Omega) \mid w = g_0 \text{ en } \Gamma_D\}$. Que g_0 pertenezca a $H^{1/2}(\Gamma_D)$ significa que no se busca la solución en el conjunto vacío.

¹⁶Una generalización del concepto de derivada a funciones no necesariamente derivables pero si integrables localmente en el sentido de Lebesgue en un dominio dado Ω de $L^p(\Omega)$.

¹⁷Si toda sucesión de Cauchy en él tiene límite.

8.1.3 Discretización del problema en un subespacio de elementos finitos lineales

Como venimos anunciando, la resolución del problema que estudiamos con el concurso de “elementos finitos” está basada en la aproximación del espacio $H^1(\Omega)$ mediante funciones polinomiales sencillas por tramos o trozos.

Para conseguirlo se utiliza una partición del dominio de cálculo Ω en subdominios, a los que se denomina *mallado*. El más sencillo es aquel en el que Ω es un intervalo de la recta real, por ejemplo el abierto $(0, 1)$, en el que se tiene la partición $0 = x_0 < x_1 < \dots < x_n = 1$ dividida en subintervalos $I_j = (x_{j-1}, x_j)$ de longitud $h_j = x_j - x_{j-1}$, $j = 1, \dots, n$. Si $h = \max h_j$ y V_h es el espacio lineal de funciones v tal que $v \in C^0([0, 1])$, $v|_{[x_{j-1}, x_j]}$ es un polinomio lineal, $i = 1, \dots, n$, perteneciente por tanto a $\mathbb{P}_1$, y $v(0) = 0$.

Para cada $i = 1, \dots, n$ se define la función ϕ_i de tal forma que

$$\phi_i(x_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases},$$

delta de Kronecker —por Leopold Kronecker, Polonia 1823-Alemania 1891—, según se indica en la figura 8.39. Se tiene que $\{\phi_i : 1 \leq i \leq n\}$ es una base de V_h .




Figura 8.39: Función de base lineal por tramos.

El conjunto $\{\phi_i\}$ es una *base nodal* de V_h y $\{v(x_i)\}$ son los valores nodales de una función v . Los puntos (x_i) se denominan *nodos* o *nudos*.

Dada una función $v \in C^0([0, 1])$, el *interpolante*, o función de interpolación, $v_h \in V_h$ de v se obtiene mediante $v_h = \sum_{i=1}^n v(x_i)\phi_i$ como se aprecia en la figura 8.40. Si $v \in V_h \Rightarrow v = v_i$.

Otra partición —quizás la más utilizada— consiste en *triangularizar* un dominio de dos dimensiones, como Ω , en pequeños triángulos que lo cubran enteramente. En la figura 8.41 se ve la correspondiente al dominio con el que venimos experimentando en estas notas.

Para simplificar se supone que la frontera o borde, Γ , del dominio Ω es una curva poligonal. Si no lo es, primero se le aproxima a un polígono. La triangulari-




Figura 8.40: Aproximación mediante v_h de una función de base lineal por tramos.




Figura 8.41: Triangularización del dominio Ω .

zación consiste en dividir Ω en un conjunto de triángulos $\mathcal{T}_h = K_1, \dots, K_m$ que no se solapen y que solo compartan lados completos, o lo que es lo mismo, que ningún vértice de ningún triángulo caiga en algún lado de otro. Se cumplirá que

$$\Omega = \bigcup_{K \in \mathcal{T}_h} K = K_1 \cup K_2 \dots \cup K_m.$$

El subespacio V_h de $H^1(\Omega)$ es ahora

$$V_h = \{ \text{funciones } v \in C(\Omega) \mid v|_K \text{ es lineal para todo } K \in \mathcal{T}_h, v = 0 \text{ en } \Gamma \},$$

donde $v|_K \in \mathbb{P}_1$ se refiere a la función v restringida a K . Recordemos que $\mathbb{P}_1$ es el espacio de polinomios lineales del tipo $a_0 + a_1x_1 + a_2x_2$, donde los coeficientes a_0, a_1 y a_2 serían los parámetros de cada triángulo.

Los parámetros que definirán la función $v \in V_h$ serán los valores $v(N_i)$ de v en los nodos $N_i, i = 1, \dots, M$ de $\mathcal{T}_h$ excluyendo aquellos en los bordes pues $v = 0$ en Γ . Los valores de los nodos de la triangularización del dominio son los grados

de libertad que determinan un elemento de V_h . Una numeración de esos nodos para nuestro dominio de trabajo sería la de la figura 8.42. Los nodos se indican mediante el vector $\mathbf{x}_i$, donde $i = 1, \dots, M$, el número de nodos.




Figura 8.42: Numeración de los nodos del dominio Ω .

Si se fija un nodo del dominio y se le asocia el valor 1 y 0 a todos los demás, existe una función única $\phi_i \in V_h$, *función de base de nodo*, tal que

$$\phi_i(\mathbf{x}_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}, \quad i, j = 1, \dots, M.$$

El aspecto de una de estas funciones es el de la figura 8.43. Si un triángulo K no




Figura 8.43: Gráfica de la funciones de base de los nodos del dominio Ω .

tiene a $\mathbf{x}_i$ como uno de sus vértices, ϕ_i es cero en todo el triángulo pues el valor de la función en todos sus vértices es cero. El soporte por tanto de ϕ_i —la envoltura del conjunto de puntos donde ϕ_i no es cero— es la misma que la unión de todos los triángulos que comparten $\mathbf{x}_i$ como vértices. Ver figura 8.44.




Figura 8.44: Soporte de dos funciones de base del dominio Ω .

Una función cualquiera $u_h \in V_h$ se representa entonces como

$$u_h = \sum_{j=1}^M u_h(\mathbf{x}_j) \phi_j(\mathbf{x}_i) = \sum_{j=1}^M u_h(\mathbf{x}_j) \delta_{ji} = \sum_{j=1}^M u_h(\mathbf{x}_j) \phi_j.$$

El conjunto $\{\phi_i, i = 1, \dots, M\}$ es una base de V_h .

Hasta ahora no hemos tenido en cuenta si los nodos de la frontera están en el segmento de borde tipo Dirichlet o Neumann. Si teníamos hasta ahora el espacio

$$H_{\Gamma_D}^1(\Omega) = \{v \in H^1(\Omega) \mid v = 0, \text{ en } \Gamma_D\},$$

ahora nos interesa

$$V_h^{\Gamma_D} = V_h \cap H_{\Gamma_D}^1(\Omega) = \{v_k \in V_h \mid v_k = 0, \text{ en } \Gamma_D\}.$$

La idea es llevar constancia de qué nodos son Dirichlet —Dir— y cuáles no, independientes, —Ind—. En el caso del ejemplo que tratamos,

$$\text{Dir} = \{9, 13, 14, 15, 17, 18\}$$

$$\text{Ind} = \{1, 2, 3, 4, 5, 6, 7, 8, 10, 11, 12, 16\}.$$

Entonces, un elemento de V_h se podría escribir como

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} u_j \phi_j, \quad u_j = u_h(\mathbf{x}_j)$$

y uno de $V_h^{\Gamma_D}$ así

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j.$$

8.1.4 Reformulación del problema como un sistema de ecuaciones lineales

Recapitulando, el método nos ha hecho llegar a la siguiente formulación para determinar la función u_h

$$\begin{cases} \text{Determinar una función } u_h \in V_h \text{ tal que} \\ u_h(x_j) = g_0(x_j) \quad \forall j \in \text{Dir} \\ \int_{\Omega} \nabla u_h \cdot \nabla \phi_i + c \int_{\Omega} u_h \phi_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i, \quad \forall i \in \text{Ind}. \end{cases}$$

Para ello:

- Hemos convertido el espacio de Sobolev en el que buscamos la función solución en uno de dimensión finita, V_h . Es decir, hemos reducido el problema a calcular u_h en los vértices de una triangularización —los nodos— y a un número finito de incógnitas.
- Hemos sustituido las condiciones tipo Dirichlet fijando condiciones a los nodos Dirichlet, lo que reduce aún más el número de incógnitas: a los nodos *independientes*.
- Hemos reducido el espacio de prueba de $H_{\Gamma_D}^1(\Omega)$ a un subespacio discreto $V_h^{\Gamma_D}$, lo que reduce un número infinito de pruebas en la formulación débil a un número finito de ecuaciones lineales.

Para obtener finalmente el sistema de ecuaciones lineales escribimos u_h en términos de las funciones de base de los nodos:

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} u_j \phi_j.$$

Luego sustituimos en esta expresión las condiciones de Dirichlet discretizadas:

$$u_h = \sum_{j \in \text{Ind}} u_j \phi_j + \sum_{j \in \text{Dir}} g_0(x_j) \phi_j.$$

Finalmente incorporamos esta expresión en la formulación variacional discreta:

$$\int_{\Omega} \nabla u_h \cdot \nabla \phi_i + c \int_{\Omega} u_h \phi_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i,$$

linealizando, teniendo en cuenta que

$$\nabla u_h = \sum_{j \in \text{Ind}} u_j \nabla \phi_j + \sum_{j \in \text{Dir}} g_0(x_j) \nabla \phi_j$$

y reordenando llegamos a

$$\sum_{j \in \text{Ind}} \left(\int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i + c \int_{\Omega} \phi_j \phi_j \right) u_j = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i - \sum_{j \in \text{Dir}} \left(\int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i + c \int_{\Omega} \phi_j \phi_j \right) g_0(\mathbf{x}_j).$$

Este es un sistema de ecuaciones lineales con un número de ecuaciones igual al número de incógnitas ($\# \text{Ind} = \dim V_h^{\Gamma_D}$), que son precisamente los valores de la función u_h en los nodos libres de la triangularización llevada a cabo.

Hay dos matrices importantes en este sistema de ecuaciones, la *matriz de rigideces*,

$$W_{ij} = \int_{\Omega} \nabla \phi_j \cdot \nabla \phi_i$$

y la *matriz de masas*

$$M_{ij} = \int_{\Omega} \phi_j \phi_i.$$

Ambas son simétricas. La de masas es definida positiva. La de rigideces semidefinida positiva. Si hacemos $\mathbf{b}_i = \int_{\Omega} f \phi_i + \int_{\Gamma_N} g_1 \phi_i$, $i \in \text{Ind}$, se llega a

$$\sum_{j \in \text{Ind}} \left(W_{ij} + c M_{ij} \right) u_j = \mathbf{b}_i - \sum_{j \in \text{Dir}} \left(W_{ij} + c M_{ij} \right) g_0(\mathbf{x}_j), \quad i \in \text{Ind}.$$

Estas matrices poseen *patrones de dispersidad* muy pronunciados pues sólo interactúan nodos que están unidos entre sí por lados de triángulos. Ello las hacen propicias para ordenaciones en torno a la diagonal principal. Su manipulación es sencilla y las operaciones necesarias para resolver los gigantescos sistemas de ecuaciones lineales a que pueden dar lugar son perfectamente tratables por los ordenadores disponibles actualmente.

8.2 Algo sobre funcionales y cálculo de variaciones

Un *funcional* es una función que tiene funciones como argumento a las que asigna un valor real. Es decir, una función cuyo dominio es un conjunto de funciones. En la figura 8.45 se esquematiza¹⁸ la diferencia entre una función ordinaria y un funcional.

¹⁸Fuente: <http://www.colorado.edu/engineering/CAS/courses.d/AVMM.d/AVMM.Ch01.d/AVMM.Ch01.pdf>.




Figura 8.45: Diagrama de bloques que ilustra la diferencia formal en una dimensión entre una función ordinaria y un funcional. (a) Una función ordinaria $y = y(x) = f(x)$ de una variable independiente x ; (b) Un funcional $J(y) = J(x, y)$ de la función $y(x)$; (c) Un funcional $J(y) = J(x, y, y')$ de la función $y(x)$ y su derivada $y' = dy/dx$.

El *funcional básico unidimensional* lineal más típico tiene la forma

$$J(y) = \int_a^b F(x, y(x), y'(x)) dx, \quad x = [a, b], \quad a \leq b, \quad y(a) = \hat{y}_a, \quad y(b) = \hat{y}_b.$$

En palabras, la función $y = y(x)$ está definida en el segmento $x \in [a, b]$, $a \leq b$, de la recta real. Dado un x , $y(x)$ se supone real y único. Además, $y(x)$ es continua y derivable por lo que $y'(x)$ existe al igual que la integral enunciada. La función debe satisfacer en $x = a$ y en $x = b$ unas determinadas *condiciones de contorno*: concretamente, $\hat{y}_a = y(a)$ y $\hat{y}_b = y(b)$.

Así era cómo la palabra funcional fue utilizada inicialmente en el cálculo de variaciones, donde el integrando a ser minimizado debía ser un funcional, aplicada a una todavía desconocida función que satisfacía solamente una cierta condición de contorno, y condiciones de derivabilidad.

Otro funcional lineal habitual es la *función delta de Dirac* —por Paul Adrien

Maurice Dirac, Reino Unido, 1902-1984—

$$\delta_t[f(\cdot)] = f(t)$$

que se puede escribir también como $\delta_t[f(\cdot)] = \int_a^b f(x)\delta(x-t) dt$.

Un problema de cálculo de variaciones o *problema variacional* típico sería el de encontrar la función $y \in [a, b] \rightarrow \mathbb{R}$ que minimiza el funcional anterior, $J(y)$, con las condiciones de contorno indicadas.

En varios campos de la ingeniería, la física matemática, el reconocimiento de imágenes y otros muchos, el cálculo de variaciones es un interesante problema matemático consistente en buscar máximos y mínimos (o más generalmente extremos relativos) de funcionales continuos definidos sobre algún espacio funcional. Constituyen una generalización del cálculo elemental de máximos y mínimos de funciones reales de una variable. Muchos problemas de este tipo¹⁹ son fáciles de formular pero sus soluciones implican a menudo, a su vez, difíciles procedimientos de cálculo diferencial, los cuales generalmente suponen usar ecuaciones diferenciales ordinarias —*Ordinary Differential Equations*—, así como las ecuaciones (diferenciales) en derivadas parciales —*Partial Differential Equations*—.

En la figura 8.46 se pueden ver algunos problemas clásicos de funcionales en una dimensión.




Figura 8.46: Ejemplos unidimensional clásicos de funcionales: (a) Área debajo de una curva, $\int_a^b y(x) dx$; (b) Longitud de un arco de curva, $\int_a^b \sqrt{1 + (y'(x))^2} dx$; (c) Curva braquistócrona, $\int_a^b \sqrt{\frac{1 + (y'(x))^2}{2gy}} dx$.

Por regla general, no todas las funciones pueden encajar en un funcional. La figura 8.47 ilustra algunos tipos de funciones permitidas y otras no permitidas, grosso modo.

Si se considera un funcional general

$$I = \int_{x_1}^{x_2} F(x, y, y') dx$$

¹⁹Por ejemplo el de encontrar la curva de longitud más corta que una dos puntos.




Figura 8.47: Mustrario de funciones admisibles en un funcional: (a) Funciones continuas, C^1 , con un sólo valor para cada x y que cumplen las condiciones de contorno; (b) Inadmisibles: La 1 y la 3 tienen derivadas discontinuas; la 2 es discontinua y admite varios valores para un x ; la 4 admite varios valores para un x y la 5 no cumple las condiciones de contorno.

donde F es una función conocida con derivadas continuas hasta segundo orden respecto a x , y y y' . El valor de I dependerá de la trayectoria de la función entre (x_1, y_1) y (x_2, y_2) ; es decir, dependerá de la función $y(x)$ que se escoja.

Si se introduce como prueba la familia de trayectorias

$$\tilde{y}(x) = y(x) + \varepsilon \eta(x),$$

donde ε es un parámetro y $\eta(x)$ una función derivable a la que se le pide que $\eta(x_1) = \eta(x_2) = 0$, resulta que se pueden generar una infinidad de trayectorias para una $\eta(x)$ dada sin más que variar el parámetro ε . Todas ellas pasan por (x_1, y_1) y (x_2, y_2) . Consideremos

$$\tilde{I} = \int_{x_1}^{x_2} F(x, \tilde{y}, \tilde{y}') dx = \int_{x_1}^{x_2} F(x, y + \varepsilon \eta, y' + \varepsilon \eta') dx$$

Es evidente que los funcionales I y $\tilde{I}$ alcanzarán el mismo valor extremo (valor máximo o mínimo) cuando $\varepsilon = 0$. Desarrollando, se tiene que

$$\tilde{I} = (\tilde{I})_{\varepsilon=0} + \left(\frac{d\tilde{I}}{d\varepsilon} \right)_{\varepsilon=0} \varepsilon + \left(\frac{d^2\tilde{I}}{d\varepsilon^2} \right)_{\varepsilon=0} \frac{\varepsilon^2}{2!} + \dots$$

Para que $\tilde{I}$ sea extremo cuando $\varepsilon = 0$ es necesario que

$$\left(\frac{d\tilde{I}}{d\varepsilon} \right)_{\varepsilon=0} = 0.$$

Es decir que

$$\left\{ \int_{x_1}^{x_2} \left(\frac{\partial F}{\partial \tilde{y}} \frac{d\tilde{y}}{d\varepsilon} + \frac{\partial F}{\partial \tilde{y}'} \frac{d\tilde{y}'}{d\varepsilon} \right) dx \right\}_{\varepsilon=0} = 0.$$

Dado que $d\tilde{y}/d\varepsilon = \eta$, que $d\tilde{y}'/d\varepsilon = \eta'$ y que quitar las tildes de $\tilde{y}$ y de $\tilde{y}'$ en las derivadas de F es lo mismo que hacer $\varepsilon = 0$ según se requería más arriba, la ecuación anterior se puede reescribir así:

$$\int_{x_1}^{x_2} \left(\frac{\partial F}{\partial y} \eta + \frac{\partial F}{\partial y'} \eta' \right) dx = 0.$$

Integrando por partes el segundo término,

$$\int_{x_1}^{x_2} \frac{\partial F}{\partial y'} \eta' dx = \left. \frac{\partial F}{\partial y'} \eta \right|_{x_1}^{x_2} - \int_{x_1}^{x_2} \left[\frac{d}{dx} \left(\frac{\partial F}{\partial y'} \right) \right] \eta dx.$$

Cuando $\eta = 0$ en los extremos la primera expresión del miembro de la derecha de esta ecuación se hace cero. Sustituyendo lo que queda en la anterior se tiene que

$$\int_{x_1}^{x_2} \left[\frac{\partial F}{\partial y} - \frac{d}{dx} \left(\frac{\partial F}{\partial y'} \right) \right] \eta dx = 0.$$

Cualquiera que sea la función $\eta(x)$ entre los puntos extremos, según la *fórmula de Euler-Lagrange* se tiene que

$$\boxed{\frac{d}{dx} \frac{\partial F}{\partial y'} - \frac{\partial F}{\partial y} = 0}$$

que es la condición que debe cumplir $y(x)$ para ser un máximo o un mínimo: un extremo. Si en esta expresión se sustituye F por su expresión $F(x, y, y')$ resulta una ecuación diferencial de segundo orden en $y(x)$.

8.2.1 Proposiciones esenciales

Lema 8.1 *Lema fundamental del Cálculo de Variaciones* Sea $M(x)$ una función continua definida en el intervalo $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$ se tiene que

$$\int_a^b M(x) \zeta(x) dx = 0.$$

Se cumple entonces que

$$M(x) = 0 \text{ para todo } x \in [a, b].$$

DEMOSTRACIÓN. Supongamos que $M(x)$ no es cero en algún punto $x_0 \in (a, b)$. Concretamente que $M(x_0) > 0$. Por la continuidad de $M(x)$, existe un $\delta > 0$ tal que

$$-\frac{M(x_0)}{2} < M(x) - M(x_0) < \frac{M(x_0)}{2} \quad \text{para } |x - x_0| < \delta \quad \text{con } x \in [a, b].$$

En consecuencia, $M(x) > M(x_0)/2$ en ese intervalo. Escojamos una función




Figura 8.48: Lema fundamental del Cálculo de Variaciones.

$\zeta(x)$ tal que, como se ve en la figura 8.48,

$$\zeta(x) = \begin{cases} 0 & \text{si } a \leq x \leq a_1 = \max(x_0 - \delta, a) \\ > 0 & \text{si } |x - x_0| < \delta, x \in [a, b] \\ 0 & \text{si } \min(x_0 + \delta, b) = b_1 \leq x \leq b. \end{cases}$$

Se tiene entonces que

$$0 = \int_a^b M(x) \zeta(x) dx = \int_{a_1}^{b_1} M(x) \zeta(x) dx > \frac{1}{2} M(x_0) \int_{a_1}^{b_1} \zeta(x) dx > 0,$$

lo cual es una contradicción.

Si $M(x_0) < 0$ el argumento sería idéntico sustituyendo $M(x)$ por $-M(x)$. Si $x_0 = a$ o $x_0 = b$ la demostración sería casi igual con pequeñas modificaciones en la línea argumental. ■

Corolario 8.2 El resultado del Lema 8.1 sigue siendo aplicable si $\zeta(a) = \zeta(b) = 0$.

Corolario 8.3 Supóngase que $M(x)$ es continua en el intervalo $I = [a, b]$ y que $\{\varphi_n(x)\}_{n=1}^{\infty}$ es un conjunto de funciones base. Supóngase además que

$$\int_a^b M(x)\varphi_n(x) dx = 0 \quad \text{para } n = 1, 2, \dots$$

Se cumple entonces que $M(x) = 0$ para todo $x \in [a, b]$.

Lema 8.4 Sea $M(x)$ una función continua en $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$, de derivada continua, se tiene que

$$\int_a^b M(x)\zeta'(x) dx = 0$$

para $\zeta(a) = \zeta(b) = 0$. Se cumple así que $M(x) = cte$ para todo $x \in [a, b]$.

Lema 8.5 Sea $M(x)$ una función continua definida en el intervalo $a \leq x \leq b$. Supongamos que para cualquier función continua $\zeta(x)$, de derivadas continuas al menos hasta segundo grado, se tiene que

$$\int_a^b M(x)\zeta''(x) dx = 0$$

para $\zeta(a) = \zeta(b) = 0$ y $\zeta'(a) = \zeta'(b) = 0$. Se cumple entonces que $M(x) = c_0 + c_1x$ para todo $x \in [a, b]$, donde c_0 y c_1 son constantes.

9 Análisis de componentes principales

EL análisis de componentes principales —ACP en español, PCA en inglés— tiene como objetivo representar la información de n observaciones de p variables con un número sustancialmente menor de unas nuevas variables construidas como combinaciones lineales de las originales. Sirve para hallar las causas fundamentales de la variabilidad de un conjunto de datos y ordenarlas por importancia. Es uno de los instrumentos básicos del análisis de datos y del Big_Data que tanto interés despiertan en la actualidad para explicar multitud de tendencias y comportamientos de la vida cotidiana.

Técnicamente, el ACP busca la proyección del espacio original de variables en un subespacio en el cual los datos queden adecuadamente representados en términos de mínimos cuadrados lineales de unos *componentes principales* —variables

artificiales independientes entre sí—, perdiéndose la menor cantidad de información original posible. Comporta el cálculo de la descomposición en valores propios de la matriz de covarianza de los datos, una vez centrados en la media de cada atributo. La PCA Es una extensión inmediata de lo apuntado en la sección 4.3.2 dedicada a valores singulares de este documento, en la página 28.

El análisis de componentes principales fue formulado por Harold Hotelling, EE.UU. 1895-1973. Sus orígenes se remontan al trabajo sobre ajustes ortogonales por mínimos cuadrados de Karl Pearson, Reino Unido, 1857-1936. Permite transformar las variables originales de los datos de un problema, en general correladas, en un número menor de nuevas variables incorreladas, facilitando así la interpretación de esos datos.

9.1 Algunos conceptos de estadística

Sea $[X_1 \cdots X_n]$ una matriz $p \times n$ de n observaciones de p variables. La *media* de esta muestra es

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

La *desviación típica*, o estándar,

$$\sigma(X) = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}}.$$

La *varianza*, medida de la dispersidad de la muestra, es la desviación típica al cuadrado, esto es,

$$\text{var}(X) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}.$$

El grado de asociación lineal más simple de cada variable con las demás, dos a dos, es lo que configura la *matriz de covarianzas*, de dimensión $p \times p$,

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n} = \Sigma.$$

Si la covarianza entre dos variables es positiva, cuando una de ellas se incrementa la otra hace lo mismo. Si es negativa, cuando una de ellas se incrementa, la otra decrece. Si es cero, las dos variables son independientes entre si. Los coeficientes de la diagonal principal de la matriz de covarianzas son las varianzas de cada variable individual. La matriz de covarianzas es simétrica. La varianza total de los datos es la suma de cada varianza individual por lo que la traza de la matriz de covarianzas es precisamente esa varianza total. En la figura 9.49 se ilustran unos patrones de datos y las matrices de covarianzas correspondientes.




Figura 9.49: La matriz de covarianzas expresa la forma de los datos. La variabilidad en torno a la diagonal la determina la covarianza mientras que alrededor de los ejes la define la varianza

La matriz de covarianzas es semidefinida positiva, es decir, $\mathbf{x}^T \text{cov}(X, Y) \mathbf{x} \geq 0$ para cualquier vector $\mathbf{x} \neq \mathbf{0}$.

La covarianza como medida de asociación tiene el inconveniente de que depende de las unidades de medida de las variables. Si por ejemplo la covarianza entre la estatura de una persona, medida en centímetros, y su peso, en gramos, es 200, si se expresa el peso en kilogramos, la covarianza será 0,002. Para construir una media adimensional se divide la covarianza por un término con sus mismas dimensiones. Se define así el *coeficiente de correlación* y a partir de él la *matriz de correlación*, de dimensión también $p \times p$, es

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X)\sigma(Y)} = \mathbf{R}.$$

Se utiliza para *estandarizar* los diversos datos. Es también semidefinida positiva.

La matriz de covarianzas y la matriz de correlación están relacionadas mediante la expresión

$$\text{corr}(X, Y) = \mathbf{D}^{-1} \text{cov}(X, Y) \mathbf{D}^{-1},$$

donde $\mathbf{D}$ es una matriz diagonal construida con las desviaciones típicas de las variables.

Una medida global escalar de la variabilidad conjunta de k variables es la *varianza generalizada*, que es el determinante de la matriz de covarianzas. Mide aproximadamente el área, volumen o hipervolumen ocupado por el conjunto de datos.

La matriz de covarianzas —o la matriz de correlación— determinará si existen altas correlaciones entre las variables y por tanto existe información redundante entre ellas, es decir, una misma información vista desde varias perspectivas. Cuanto mayor sea la variabilidad de los datos (varianza), más rica la información disponible.

Si

$$\mathbf{M} = \frac{1}{n} (\mathbf{X}_1 + \cdots + \mathbf{X}_n)$$

y $\hat{\mathbf{X}}_k = \mathbf{X}_k - \mathbf{M}$, la matriz de covarianzas es

$$\text{cov}(\mathbf{X}, \mathbf{Y}) = \frac{1}{n} \begin{bmatrix} \hat{\mathbf{X}}_1 & \hat{\mathbf{X}}_2 & \cdots & \hat{\mathbf{X}}_n \end{bmatrix} \begin{bmatrix} \hat{\mathbf{X}}_1^T \\ \hat{\mathbf{X}}_2^T \\ \vdots \\ \hat{\mathbf{X}}_n^T \end{bmatrix} = \frac{1}{n} \mathbf{B} \mathbf{B}^T.$$

9.2 Planteamiento del problema matemático

Se trata de encontrar un subespacio de dimensión menor a p tal que al proyectar sobre él los puntos de la muestra se conserve su estructura con la menor distorsión posible. Para ello se construye una transformación lineal que determina un nuevo sistema ortogonal de coordenadas para el conjunto de datos original en el cual la varianza de mayor tamaño de los datos define el primer eje —primer *Componente Principal*—, la segunda varianza el segundo eje y así sucesivamente. Esto se lleva a efecto mediante la *descomposición espectral* de la matriz de covarianzas,

$$\text{cov}(\mathbf{X}, \mathbf{Y}) = \mathbf{\Sigma} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T,$$

donde $\mathbf{U}$, $\mathbf{U}^T \mathbf{U} = \mathbf{U} \mathbf{U}^T = \mathbf{I}$, es una matriz ortogonal $p \times p$ formada por los vectores propios correspondientes a los valores propios $\lambda_1, \dots, \lambda_p$ y $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$.

Se cumple que $\lambda_1 \leq \dots \leq \lambda_p$ y que los Componentes Principales son los p vectores fila de la matriz, $p \times n$, $\mathbf{U}^T \mathbf{B}$.

El subespacio generado por los k primeros vectores propios es, de todos los posibles del espacio de dimensión p , el que mejor representa en términos de mínimos cuadrados lineales los datos originales.

Si la matriz de covarianzas de los datos es diagonal las varianzas son iguales a los valores propios de esa matriz y los vectores propios coinciden con los ejes x e y —las covarianzas son cero—. Si la matriz de covarianzas no es diagonal, las covarianzas no son cero pero los valores propios siguen indicando la magnitud de la varianza en las direcciones ortogonales de los vectores propios, de mayor a menor, que ya no coinciden con x e y . Esto se ilustra en la figura 9.50²⁰ donde un mismo conjunto de datos está rotado diversos ángulos para visualizar en qué consiste la matriz de covarianzas.




Figura 9.50: Valores y vectores propios de un mismo conjunto de datos pero rotado ángulos distintos

La matriz de covarianzas, desde el punto de vista del álgebra lineal, representa una transformación lineal. El utilizarla en estos algoritmos es como tratar de des-

²⁰Fuente: <http://www.visiondummy.com/2014/04/geometric-interpretation-covariance-matrix/>.

correlar los datos originales para encontrar sus componentes subyacentes o *principales* —llevar los datos a unos ejes donde se perciba el menor ruido posible—.

Para proceder numéricamente con este método y obtener esta transformación primero se adaptan los datos originales para tratarlos según convenga. Luego de construye la matriz de covarianzas. A continuación, como esquematiza²¹ el diagrama de bloques numéricos de la figura 9.51, se puede proceder de dos maneras:

- Se calculan los valores propios y los correspondientes vectores propios de la matriz de covarianzas. Luego se proyectan en esos vectores propios los datos. Una versión de esta forma de actuar en Matlab sería el programa `pca1` de la figura 9.52.
- Se calcula la descomposición en valores singulares de $\frac{B}{\sqrt{n}}$ y se obtiene las varianzas. El programa `pca2` materializa esta variante.

Como ejemplo de introducción a este análisis por componentes principales estudiamos los datos del cuadro 1.

Construcción	X_1 =Duración media hipoteca (años)	X_2 =Precio medio (millones euros)	X_3 =Superficie media (m ²) de cocina
1	8,7	0,3	3,1
2	14,3	0,9	7,4
3	18,9	1,8	9,0
4	19,0	0,8	9,4
5	20,5	0,9	8,3
6	14,7	1,1	7,6
7	18,8	2,5	12,6
8	37,3	2,7	18,1
9	12,6	1,3	5,9
10	25,7	3,4	15,9

Cuadro 1: Datos sobre pisos que promocionan diversas constructoras en España

En él se presenta información sobre pisos construidos por 10 constructoras distintas en diversos lugares de España. Se trata de considerar sólo tres variables X_1 , X_2 y X_3 . La salida que proporciona una sesión de Matlab con los datos de la tabla y los programas apuntados es la que se puede ver en la figura 9.53.

Como se puede observar en esa salida, la matriz de covarianzas de los datos estudiados es

$$\Sigma = \begin{bmatrix} 56,9685 & 5,1705 & 30,4775 \\ 5,1705 & 0,8941 & 3,6479 \\ 30,4775 & 3,6479 & 18,7641 \end{bmatrix}.$$

Los valores propios son $\Lambda = \text{diag}(74,3739, 2,1580, 0,0948)$.

²¹Fuente: <http://mengnote.blogspot.com/2013/05/an-intuitive-explanation-of-pca.html>.




Figura 9.51: Esquema de la transformación del ACP mediante descomposición en valores propios y descomposición en valores singulares

Los componentes principales de este ejemplo son

$$PC_1 = 0,8714X_1 + 0,0853X_2 + 0,4832X_3,$$

$$PC_2 = 0,4798X_1 - 0,3542X_2 - 0,8027X_3 \quad y$$

$$PC_3 = -0,1026X_1 + 0,9313X_2 + 0,3495X_3.$$

Los porcentajes de variabilidad que explican cada componente principal son

$$\frac{74,3739}{76,6267} \times 100 = 97,06 \%, \quad \frac{2,1580}{76,6267} \times 100 = 2,82 \% \quad y \quad \frac{0,0948}{76,6267} \times 100 = 0,12 \%.$$

Con el primer componente, y por supuesto con los dos primeros, sería suficiente para representar casi perfectamente este conjunto de datos.

```

function [signals,PC,V] = pca1(data)
% Se analizan datos por Componentes Principales
% data-matriz MxN con los datos, M dimensiones y N datos
% signals-matriz MxN de datos proyectados;
% PC, cada componente en columna
% V-Mx1 matrix de variances
%
[~,N] = size(data);

% subtract off the mean for each dimension
mn = mean(data,2); data = data - repmat(mn,1,N);

% calculate the covariance matrix
covariance = 1/N * (data * data')

% find the eigenvectors and eigenvalues
[PC, V] = eig(covariance);

% extract diagonal of matrix as vector
V = diag(V);

% sort the variances in decreasing order
[~,rindi] = sort(-1*V); V = V(rindi); PC = PC(:,rindi);

% project the original data set
signals = PC'*data;

end

function [signals,PC,V] = pca2(data)
% Se analizan datos por Componentes Principales
% data-matriz MxN con los datos, M dimensiones y N datos
% signals-matriz MxN de datos proyectados;
% PC, cada componente en columna
% V-Mx1 matrix de variances
%
[~,N] = size(data);

% subtract off the mean for each dimension
mn = mean(data,2); data = data - repmat(mn,1,N);

% construct the matrix Y
Y = data'/sqrt(N);

% SVD does it all
[u,S,PC] = svd(Y);

% calculate the variances
S = diag(S); V = S .* S;

% project the original data
signals = PC' * data;

end

```

Figura 9.52: Dos programas de Matlab para llevar a cabo un análisis PCA

```

>> datos=[1 2 3 4 5 6 7 8 9 10;
8.7 14.3 18.9 19.0 20.5 14.7 18.8 37.3 12.6 25.7;
0.3 0.9 1.8 0.8 0.9 1.1 2.5 2.7 1.3 3.4;3.1 7.4 9.0 9.4 8.3 7.6 12.6 18.1 5.9 15.9]

datos =
    1.0000    2.0000    3.0000    4.0000    5.0000    6.0000    7.0000    8.0000    9.0000   10.0000
    8.7000   14.3000   18.9000   19.0000   20.5000   14.7000   18.8000   37.3000   12.6000   25.7000
    0.3000    0.9000    1.8000    0.8000    0.9000    1.1000    2.5000    2.7000    1.3000    3.4000
    3.1000    7.4000    9.0000    9.4000    8.3000    7.6000   12.6000   18.1000    5.9000   15.9000

>> [signal PC V]=pca1(datos(2:4,1:10))

covariance =
    56.9685    5.1705    30.4775
    5.1705    0.8941    3.6479
    30.4775    3.6479    18.7641

signal =
   -12.3363   -5.3219   -0.4638   -0.2687    0.5154   -4.8597    1.2482   20.0429   -7.4938    8.9318
    0.9063   -0.1713    0.4326    0.5136    2.0809   -0.2107   -2.7532    1.6367    0.0756   -2.4195
   -0.0723   0.2971   -0.4540    0.6069   -0.0247    0.1397    0.1627   -0.0090   -0.4252   -0.2302

PC =
    0.8714    0.4798   -0.1026
    0.0853   -0.3542   -0.9313
    0.4832   -0.8027    0.3495

V =
    74.3739
    2.1500
    0.0948

>> [signal PC V]=pca2(datos(2:4,1:10))

signal =
   -12.3363   -5.3219   -0.4638   -0.2687    0.5154   -4.8597    1.2482   20.0429   -7.4938    8.9318
    0.9063   -0.1713    0.4326    0.5136    2.0809   -0.2107   -2.7532    1.6367    0.0756   -2.4195
   -0.0723   0.2971   -0.4540    0.6069   -0.0247    0.1397    0.1627   -0.0090   -0.4252   -0.2302

PC =
    0.8714    0.4798   -0.1026
    0.0853   -0.3542   -0.9313
    0.4832   -0.8027    0.3495

V =
    74.3739
    2.1500
    0.0948

```

Figura 9.53: Sesión de Matlab para analizar los datos sobre pisos construidos

10 Números complejos

Los números del cuerpo $\mathbb{C}$ de lo complejos surgen para dar sentido a raíces de números negativos, $\sqrt{-a^2} = \pm a\sqrt{-1}$ pues así se usan para representar modelos y problemas en muchas áreas de la ciencia e ingeniería. Para ello se utiliza la *unidad imaginaria* $i = \sqrt{-1}$.

Cualquier número complejo $z = x + yi$, donde x es la parte real e y la imaginaria (ambas reales), se representa geoméricamente en el plano complejo como se ve en la figura 10.54. El *módulo* de z , $|z| = r = \sqrt{x^2 + y^2}$.




Figura 10.54: Un número en el plano complejo

Las operaciones elementales con números complejos, si $z = a + ib$ y $w = c + id$, son la suma, $z + w = (a + c) + (b + d)i$ y la multiplicación, $zw = (ac - bd) + i(ad + bc)$. Como $i \cdot i = i^2 = -1$, $\frac{1}{i} = -i$ y $i(-i) = 1$.

El *complejo conjugado* de un número complejo $z = x + iy$ es $\bar{z} = x - iy$. Sólo si z es real se cumple que $z = \bar{z}$. Es decir, su imagen en el espejo que define el eje x . Además, $\overline{z + w} = \bar{z} + \bar{w}$, $\overline{zw} = \bar{z} \bar{w}$ y $\overline{\bar{z}} = z$. Estas fórmulas se extienden a sumas y productos de más de dos números complejos y a integrales (recordemos que son el límite de una suma de infinitos sumandos), así

$$\overline{\int f(t)g(t) dt} = \int \overline{f(t)} \overline{g(t)} dt.$$

El cociente z/w es

$$\begin{aligned} \frac{z}{w} &= \frac{a + bi}{c + di} \\ &= \frac{a + bi}{c + di} \frac{c - di}{c - di} \\ &= \frac{(a + bi)(c - di)}{c^2 + d^2} = \frac{(ac + bd) + (bc - ad)i}{c^2 + d^2}. \end{aligned}$$

En su *forma polar* un número complejo se escribe²² $z = re^{i\varphi} = r(\cos \varphi + i \sin \varphi)$, donde $r = \sqrt{x^2 + y^2}$ y $\varphi = \arctan(y/x)$.

La *circunferencia de radio unidad* en el plano complejo es el lugar geométrico de los números complejos con $r = 1$ —figura 10.55—. Si se multiplican dos




Figura 10.55: Circunferencia de radio unidad en el plano complejo

números $e^{i\theta}$ y $e^{i\gamma}$ de esa circunferencia,

$$\begin{aligned} e^{i\theta} e^{i\gamma} &= (\cos \theta + i \sin \theta)(\cos \gamma + i \sin \gamma) \\ &= \cos \theta \cos \gamma - \sin \theta \sin \gamma + i(\sin \theta \cos \gamma + \sin \gamma \cos \theta). \end{aligned}$$

Reordenando,²³ $e^{i(\theta+\gamma)} = \cos(\theta + \gamma) + i \sin(\theta + \gamma)$. Por tanto, el producto de dos números complejos en la circunferencia de radio unidad es otro número de la misma circunferencia cuyo *ángulo es la suma* de los dos precedentes.

Los números *Moivre*, z tales que $z^n - 1 = 0$, *raíces n-ésimas de la unidad*, por Abraham de Moivre, Francia, 1667-1754, tienen interés:

- En la recta de números reales sólo hay dos: -1 y 1 .
- En el plano complejo hay muchos. Por ejemplo, i es una raíz cuarta de 1 :

$$i^4 = (\sqrt{-1})^4 = (-1)^2 = 1.$$

Están localizados en la circunferencia del plano complejo de radio la unidad: forman los vértices de un polígono regular de n lados con un vértice en 1 como se ve en la figura 10.56 para $n = 5$.

²²A $e^{i\varphi} = \cos \varphi + i \sin \varphi$ se la conoce como identidad de Euler

²³Es interesante saber que $\cos \theta = \frac{e^{i\theta} + e^{-i\theta}}{2}$ y $\sin \theta = i \frac{e^{-i\theta} - e^{i\theta}}{2}$.




Figura 10.56: Circunferencia de radio unidad en el plano complejo y números de Moivre para $n = 5$

Una raíz n -ésima de la unidad se denomina *primitiva*²⁴ si no es una raíz k -ésima para $k < n$. Así, -1 es una raíz segunda primitiva de la unidad y cuarta no primitiva de ella.

Es fácil ver que, para una n cualquiera, el número complejo $\omega_n = e^{-i2\pi/n}$ es una raíz n -ésima primitiva de la unidad (también lo es $\omega_n = e^{i2\pi/n}$).

En la figura 10.57 se ve la raíz cuarta primitiva de la unidad, $\omega_4 = e^{-i2\pi/4}$, y las otras tres. También la figura anterior. Son, en general, las potencias ω_4^k , $k = 0, 1, 2, 3$.

Las ω_n^k se denominan también *factores twiddle*.

Se puede verificar que la raíz n -ésima de la unidad, $\omega = e^{-i2\pi/n}$, con $n > 1$, cumple que

$$\begin{aligned}
 1 + \omega + \omega^2 + \omega^3 + \cdots + \omega^{n-1} &= 0, \\
 1 + \omega^2 + \omega^4 + \omega^6 + \cdots + \omega^{2(n-1)} &= 0, \\
 1 + \omega^3 + \omega^6 + \omega^9 + \cdots + \omega^{3(n-1)} &= 0, \\
 &\vdots \\
 1 + \omega^{n-1} + \omega^{(n-1)2} + \omega^{(n-1)3} + \cdots + \omega^{(n-1)(n-1)} &= 0.
 \end{aligned}$$

²⁴De otra manera, la raíz n -ésima de la unidad α es primitiva, si sólo si sus k -ésimas potencias, $k = 0, 1, \dots, n-1$ son distintas. Las raíces cuartas de 1 son: 1, -1 , i , $-i$. En el caso de 1 sus potencias de grado 0, 1, 2 y 3 son iguales; no es raíz primitiva. Para i , se calcula que las potencias de grado 0, 1, 2, 3 son, respectivamente, 1, i , -1 , $-i$, distintas, luego i es una raíz cuarta primitiva de 1.




Figura 10.57: Raíz cuarta primitiva de la unidad $\omega_4 = e^{-i2\pi/4}$ y las otras tres; los números de Moivre para $n = 8$

También que

$$1 + \omega^n + \omega^{2n} + \omega^{3n} + \cdots + \omega^{n(n-1)} = 1 + 1 + 1 + 1 + \cdots + 1 = n.$$

Además, si k es un número entero,

$$\sum_{j=0}^{n-1} \omega^{jk} = \begin{cases} n & \text{si } k/n \text{ es entero,} \\ 0 & \text{en otro caso.} \end{cases}$$

11 Bibliografía

BERTSEKAS, D.P. 2003. *Convex Analysis and Optimization*. Athena Scientific.

BOYD, S. Y VANDENBERGHE, L. 2004. *Convex Optimization*. Cambridge University Press.

DE LA FUENTE, J.L. 1998. *Técnicas de cálculo para sistemas de ecuaciones, programación lineal y programación entera*. Segunda edición. Reverté.

DUOANDIKOETXEA, J. 2007. *200 años de convergencia de las series de Fourier*. La Gaceta de la RSME, Vol. 10, No. 3.

FLETCHER, R. 1987. *Practical methods of optimization*. John Wiley & Sons, Ltd.

GANDER, M.J. Y WANNER, G. 2012. *From Euler, Ritz, and Galerkin to Modern Computing*. SIAM Review, Vol. 54, No. 4. Society for Industrial and Applied Mathematics.

- GRANÉ, A. *Análisis de Componentes Principales*. Departamento de Estadística, Universidad Carlos III de Madrid.
- HALMOS, P.R. 1974. *Finite-Dimensional Vector Spaces*. Springer Verlag.
- KOLMOGOROV, A.M. Y FOMIN, S.V. 1975. *Introductory Real Analysis*. Dover Publications.
- KUHN, H.W. Y TUCKER, A.W. 1951. *Nonlinear Programming*. Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability. University of California Press. Verlag.
- LAY, D.C. 2012. *Álgebra lineal y sus aplicaciones*. Cuarta edición. Pearson educación.
- LUENBERGER, D.G. 1969. *Optimization by Vector Space Methods*. John Wiley and Sons.
- LUENBERGER, D.G. Y YE, Y. 2016. *Linear and Nonlinear Programming*. Fourth Edition. Springer Verlag.
- NOCEDAL, J. Y WRIGHT, S.J. 2006. *Numerical Optimization*. Springer Verlag.
- PEÑA SÁNCHEZ DE RIVERA, D. 1986. *Estadística. Modelos y métodos. 1. Fundamentos*. Alianza Universidad Textos.
- RIAZA, R. Y ÁLVAREZ, M. 1996. *Cálculo infinitesimal. Vol. I*. Sociedad de Amigos de la Escuela Técnica Superior de Ingenieros Industriales de Madrid.
- RIAZA, R. Y ÁLVAREZ, M. 1997. *Cálculo infinitesimal. Vol. II*. Sociedad de Amigos de la Escuela Técnica Superior de Ingenieros Industriales de Madrid.
- ROCKAFELLAR, R.T. 1970. *Convex Analysis*. Princeton University Press.
- SAUER, T. 2013. *Análisis numérico*. Segunda edición. Pearson educación.
- SAYAS, F.J. 2015. *A gentle introduction to the Finite Element Method*.
- WOLFE, P. 1961. *A Duality Theorem for Non-Linear Programming*. Quart. Appl. Math. 19, N° 3.